

课程笔记

CME 295 课程笔记: Lecture 2

Transformer-Based Models & Tricks

Codex

2026-04-13



视频作者/频道: Stanford Online

发布日期: 2025-10-17

视频时长: 1:47:19

视频链接: <https://www.youtube.com/watch?v=yT84Y5zCnaA>

目录

1 从原始 Transformer 到现代变体：本讲的目标	2
1.1 本章小结	2
2 位置编码的演进：从绝对位置到相对位置信息	2
2.1 为什么必须注入位置信息	2
2.2 正弦位置编码的公式与动机	2
2.3 从绝对位置到相对位置：ALiBi 与 RoPE	3
2.4 本章小结	4
3 层归一化与训练稳定性：Post-Norm 到 Pre-Norm	4
3.1 本章小结	5
4 注意力近似与结构省算：局部窗口、MQA 与 GQA	5
4.1 全局自注意力的代价	5
4.2 局部与全局注意力的折中	5
4.3 从 MHA 到 MQA/GQA	6
4.4 本章小结	7
5 Transformer-based 模型家族与 BERT 深入解析	7
5.1 三大模型家族	7
5.2 为什么是 BERT	8
5.3 BERT 的预训练任务	8
5.4 从预训练到微调	9
5.5 本章小结	9
6 BERT 的局限与两类变体：DistilBERT、RoBERTa	9
6.1 BERT 的局限	9
6.2 DistilBERT：更小更快	10
6.3 RoBERTa：把预训练做得更扎实	10
6.4 本章小结	10
7 总结与延伸	10

1 从原始 Transformer 到现代变体：本讲的目标

第二讲不是重新介绍 Transformer，而是回答两个更工程化的问题：原始 Transformer 中哪些部件后来被改掉了，以及为什么要改。课程先用上一讲的 attention map 和架构图做 recap，再明确本讲的主题包括位置编码、层归一化、注意力近似、Transformer-based 模型家族，以及 BERT 的深入分析。

这一讲的总体逻辑非常清楚：Transformer 的主干思想几乎没变，但一些局部机制会显著影响长度外推能力、训练稳定性、推理内存占用和任务适配方式。因此，理解“tricks”不是记零散技巧，而是理解现代模型为何在原论文基础上继续演化。

1.1 本章小结

第二讲的定位是“结构细化课”。它默认你已经理解自注意力与 encoder-decoder 主干，现在开始讨论哪些设计在实践里更稳、更省、更适合现代大模型。

2 位置编码的演进：从绝对位置到相对位置信息

2.1 为什么必须注入位置信息

自注意力允许任意 token 直接交互，但这也意味着如果不额外处理，模型只看到一个集合，而看不到顺序。课程把这个问题表述为：direct links 会“丢掉”位置信息。所以原始 Transformer 需要把 position embedding 加到 token embedding 上。

最早的做法是每个位置学一个独立向量，然后直接相加。优点是简单；缺点是如果训练时只见过长度 L 的序列，那么位置 $L + 1$ 之后就没有学习到的 embedding，长度外推会失败。




图 1: 原始 Transformer 用正弦和余弦构造硬编码位置向量。

2.2 正弦位置编码的公式与动机

课程随后转向 hardcoded position embeddings，也就是经典的正弦位置编码：

$$\text{PE}_{(m,2i)} = \sin\left(\frac{m}{10000^{2i/d}}\right), \quad \text{PE}_{(m,2i+1)} = \cos\left(\frac{m}{10000^{2i/d}}\right)$$


符号说明如下：

- m : 序列中的位置索引；
- i : embedding 维度中的第 i 个频率块；
- d : 位置向量总维度；
- 偶数维用正弦，奇数维用余弦；
- 不同频率让模型同时编码近距离和远距离的位置信号。

这类编码的关键优势不是“更优雅”，而是可以无须为每个位置单独学习参数，因此天然支持更长序列的外推。课程还特别强调，相似位置在这种表示下会有可解释的几何关系。

Hardcoded position embeddings

Idea. Hardcode values of position embedding



Stanford University "Attention Is All You Need", Vaswani et al., 2017, "Transformer Architecture: The Positional Encoding", by Kazemnejad, 2019.

ICME

图 2: 正弦位置编码既给出随位置变化的波形，也诱导出位置之间的相似性结构。

2.3 从绝对位置到相对位置：ALiBi 与 RoPE

讲者随后指出，注意力真正关心的往往不是“绝对第几位”，而是“彼此相距多远”。这就引出相对位置思想：不要只在输入端相加位置向量，而要直接在 attention 打分里引入位置信息。

ALiBi 的做法是在 query-key 分数中加入线性 bias，使距离更远的 token 在没有特殊证据时自然受到更强惩罚。它参数更少，也有不错的长度外推表现。

如今更常见的选择是 RoPE (Rotary Position Embeddings)。RoPE 的思想不是额外加一个位置向量，而是对 query 与 key 做旋转变换。二维情形下可以写成：

$$R_m = \begin{bmatrix} \cos(m\theta) & -\sin(m\theta) \\ \sin(m\theta) & \cos(m\theta) \end{bmatrix}$$

其中：

- m : 位置；
- θ : 不同维度块使用的旋转频率；

- $R_m q$ 与 $R_n k$ 的内积会自然带出 $m - n$ 的相对位置信息。

Default choice nowadays: rotations in attention layer

Idea. Rotate query and key vectors with rotation matrix



Stanford University "RoFormer: Enhanced Transformer with Rotary Position Embeddings", Su et al., 2021.
Figure from "Super Study Guide: Transformers & Large Language Models", Amidi et al., 2024.

ICME

图 3: RoPE 把位置信息写进 query/key 的旋转变换，而不是只加到输入 embedding 上。

为什么 RoPE 在现代模型里常见

因为它把相对位置信息直接注入相似度计算本身，既贴合 attention 的工作位置，又兼顾外推能力和工程简洁度。课程也指出今天大量模型都使用 RoPE 或其变体。

2.4 本章小结

位置编码的演进可以概括为三步：先有可学习绝对位置向量，再有可外推的正弦位置编码，最后进一步发展到直接作用于注意力分数或 query/key 表示的相对位置方法。今天主流选择偏向 RoPE，本质上是因为它更贴近注意力机制本身。

3 层归一化与训练稳定性：Post-Norm 到 Pre-Norm

课程提醒我们，Transformer 之所以能堆很多层，不只靠注意力本身，也靠归一化和残差连接控制训练动态。Layer Normalization (LN) 是在单个样本内部、沿特征维做标准化：

$$\text{LN}(x) = \gamma \odot \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta$$

其中：

- x : 某个位置的隐藏向量；
- μ, σ^2 : 该向量各维度上的均值与方差；
- ϵ : 防止分母为零的稳定项；
- γ, β : 可学习的缩放和平移参数。

Different kinds of layer normalization




图 4: 课程用结构图比较 LayerNorm 放在子层前后带来的差异。

原始 Transformer 采用 Post-Norm, 也就是先做子层计算与残差相加, 再归一化。后来很多模型改成 Pre-Norm, 即先归一化, 再进入 attention 或 FFN 子层。讲者给出的核心判断是: Pre-Norm 往往更利于深层网络的梯度传播, 因此“如今”更常见。

从理解上说, 归一化并不是附属模块, 它决定了深层堆叠是否稳定。只要模型层数、参数量和训练语料继续上升, 这类稳定性设计就会持续重要。

3.1 本章小结

LayerNorm 的公式不复杂, 但位置放置会影响整个模型的优化路径。现代大模型偏向 Pre-Norm, 不是因为原论文错了, 而是因为规模继续扩大后, 训练稳定性成为首要工程约束。

4 注意力近似与结构省算: 局部窗口、MQA 与 GQA

4.1 全局自注意力的代价


如果每个 token 都和所有 token 交互, 那么长度为 n 的序列需要计算 $n \times n$ 的相关性矩阵。随着 context 增大, 显存和计算都会迅速上涨。因此现代模型不再总是坚持“所有位置全连”。

4.2 局部与全局注意力的折中

课程先介绍 sliding window attention (SWA): 每个 token 只看局部邻域, 而不是整段序列。它的思想与卷积类似, 利用语言中很多依赖是局部的事实, 把昂贵的全局关系计算近似成局部窗口运算。

Leveraging local and global attention

SWA = Sliding Window Attention



Variations include **interleaving local** and **global attention layers**

Stanford University

ICME

图 5: SWA 只保留局部邻域的注意力连接，用更低成本保留主要局部依赖。

课程也提到可以交替使用 local 与 global attention 层。换句话说，局部近似不是否认长程依赖，而是把“每一层都全局交互”改成“有计划地稀疏化交互”。


4.3 从 MHA 到 MQA/GQA

另一个省算方向出现在 head 的 key/value 组织方式上。标准 multi-head attention 中，每个 query head 都有自己独立的 key 和 value 投影，这会推高 KV cache 和推理内存。

MQA (Multi-Query Attention) 让多个 query head 共享同一组 key/value; GQA (Grouped-Query Attention) 则在两者之间折中，让若干 query head 共享一组 key/value。这样做会牺牲一部分自由度，但可以显著降低推理内存压力。

Sharing attention heads

Idea. Share key/value attention heads within groups of queries



Stanford University

Figure from "Super Study Guide: Transformers & Large Language Models", Amidi et al., 2024.

ICME

图 6: 课程用共享示意图说明 MQA/GQA 如何减少 key/value 的冗余存储。

这一节的统一视角

不论是 SWA 还是 MQA/GQA，它们都不是在改变 Transformer 的基本语义，而是在回答同一个工程问题：当序列更长、模型更大时，如何让注意力的表达能力和推理成本保持平衡。

4.4 本章小结

现代 Transformer 的 “tricks” 很多都围绕注意力成本展开：要么减少可见连接数，要么压缩 key/value 的复制开销。理解这一点后，后面看到长上下文模型和高吞吐服务框架时，就不会把它们误认为完全不同的架构。

5 Transformer-based 模型家族与 BERT 深入解析

5.1 三大模型家族


课程先回到高层分类。常见 Transformer-based 模型主要有三类：

- encoder-decoder
- encoder-only
- decoder-only

Overview of Transformer-based models

3 categories of Transformer-based models:

Encoder-decoder	Text to text	T5, mT5, ByT5
------------------------	--------------	---------------



Stanford University Figure adapted from "Attention is All You Need", Vaswani et al., 2017.

ICME

图 7: 三类 Transformer-based 模型的结构与典型任务：编码-解码、纯编码、纯解码。


这三类结构并不是谁替代谁，而是分别对应不同任务偏好：

- encoder-decoder 更适合 text-to-text 变换；
- encoder-only 更适合分类、检索、抽取等“先编码再判别”的任务；
- decoder-only 更适合自回归生成。

5.2 为什么是 BERT

BERT 是 Bidirectional Encoder Representations from Transformers。它保留原始 Transformer 的 encoder 部分, 去掉 decoder, 从而得到一个能双向聚合上下文的编码模型。课程专门强调了“bidirectional”这一点: 它不是只看左侧上下文, 而是能同时利用左右信息。

BERT architecture



Stanford University Figure adapted from "Attention Is All You Need", Vaswani et al., 2017.

ICME

图 8: BERT 继承原始 Transformer 的 encoder 堆栈, 把重点放在输入表示学习而非文本生成。


在输入构造上, BERT 不只是 token embedding, 还会加入 position embedding 和 segment embedding, 用来区分句对输入中的不同句子。特殊 token 如 [CLS] 和 [SEP] 也在后续任务适配中扮演关键角色。

5.3 BERT 的预训练任务

课程讲了 BERT 的两个经典 proxy task:

- MLM (Masked Language Modeling): 随机挑出部分 token 做预测;
- NSP (Next Sentence Prediction): 判断两个句子是否相邻。

Proxy task: Masked Language Modeling



Idea. 15% of input tokens are set up for prediction where:

- 80% are masked
- 10% are changed to a random word
- 10% are unchanged

Benefits

- Network learns language modeling based on contextual information
- Regularization reflects probabilistic nature of language

Stanford University Figure adapted from "Attention Is All You Need", Vaswani et al., 2017.

ICME

图 9: MLM 通过掩码预测学习双向上下文表征, 是 BERT 预训练的核心任务。

其中 MLM 是最本质的一项。课程明确提到典型设置是 15% token 参与预测，其中大部分替换为 [MASK]，少部分替换成随机词或保持不变。这么做的目的是避免模型只会识别 [MASK] 这个特殊训练场景。

5.4 从预训练到微调

BERT 的强项在于它学到的 contextual embeddings 可以直接迁移到下游任务。做情感分类时，可以把 [CLS] 的最终表示接一个小型分类头；做问答时，则可以在每个位置上预测答案起点与终点。




图 10: BERT 微调示意：把预训练 encoder 产生的上下文表示接到具体任务头上。

这也是 BERT 曾经如此成功的原因：它把“大量无监督语料上的表示学习”和“小数据监督任务上的快速适配”分离开来，大幅提高了 NLP 任务的迁移效率。

5.5 本章小结

BERT 的意义不只是一个模型名，而是一个范式：先用大语料学强表征，再用简单任务头做下游适配。它代表了 encoder-only 路线的成熟形态，也为后续各种判别式文本模型打下了基础。

6 BERT 的局限与两类变体：DistilBERT、RoBERTa

6.1 BERT 的局限

课程总结了 BERT 的几个现实限制：

- 上下文长度有限，原始版本通常只到 512；
- 参数量和延迟仍然偏高；
- 预训练目标是否最优并不确定，尤其 NSP 的必要性值得怀疑。

这些问题催生了两条不同方向的改进：一条是更省，一条是更强。

6.2 DistilBERT: 更小更快

DistilBERT 的核心思路是蒸馏。教师模型输出的不只是硬标签，而是一整条概率分布；这条分布比单点标签包含更多关于类别相似性和不确定性的知识。学生模型通过拟合教师分布，在更小参数规模下尽量保留性能。




图 11: 蒸馏把教师模型的软分布迁移给学生模型，以更少层数换取更快推理。

课程在口头解释里还补充了一个很重要的判断：DistilBERT 之所以高效，不只是因为层数减半，更因为它把“老师学到的结构性概率信息”也迁移了过去。

6.3 RoBERTa: 把预训练做得更扎实

RoBERTa 并没有发明全新结构，而是系统地审视 BERT 训练流程：如果拿掉 NSP、改成动态 masking、增大数据量、训练更久，会发生什么？课程给出的结论是，这些训练层面的改良本身就能显著提升性能。

这一结论的启发

很多模型改进并不来自结构创新，而来自训练设定的重新审视。RoBERTa 说明“把已有架构训练对”本身就是一种重要研究方向。

6.4 本章小结

DistilBERT 和 RoBERTa 分别代表了两种不同优化目标：前者是在性能可接受前提下更省资源，后者是在同类结构上把预训练流程打磨到更高上限。它们说明 BERT 之后的进展，不只是“换架构”，也包括“换训练策略”和“换部署成本曲线”。

7 总结与延伸

第二讲把第一讲的骨架真正拉成了现代模型设计图。最值得提炼的认识有四点：

1. **位置信息不是附件，而是自注意力成立的前提。**从 learned PE 到 sinusoidal PE，再到 ALiBi 和 RoPE，变化的是注入方式，不变的是“必须显式处理顺序”。
2. **模型能否稳定堆深，取决于归一化与残差布局。**LayerNorm 的放置位置是训练工程的重要决策。
3. **注意力的成本决定了现代架构细节。**局部窗口、MQA、GQA 都是在为长上下文和低内存推理让路。
4. **BERT 展示了 encoder-only 路线的威力。**通过预训练表示再微调任务头，NLP 进入了大规模迁移学习时代。

如果第一讲回答的是“Transformer 是什么”，那么第二讲回答的是“为什么今天的模型长得不完全像 2017 年论文里的样子”。现代大模型并没有背离 Transformer，恰恰相反，它们是在保留主干思想的前提下，不断修补最影响长度、稳定性和成本的局部机制。理解这些变化，后面再看 LLM、KV cache、长上下文和推理优化时，就能把它们放回同一条技术脉络之中。