

课程笔记

CME 295 第 9 讲: Current Trends

五道口纳什 & Codex

2025-12-05



视频作者/频道: Stanford Online

发布日期: 2025-12-09

视频时长: 1:51:31

视 频 链 接: <https://www.youtube.com/watch?v=Q86qzJ1K1Ss&list=PLoROMvodv4r0CXd21gf0CF4xr35yINe0y&index=9>

目录

1 全课地图回放：这门课到底串起了什么	2
1.1 本章小结	2
2 Transformer 不只属于文本：从视觉到多模态	2
2.1 为什么要跳出“文本专用”的想象	2
2.2 ViT 与视觉语言模型的两条路径	3
2.3 本章小结	3
3 从自回归到 Diffusion：文本生成是否必须逐 token 展开	3
3.1 当前主流范式的局限	3
3.2 先从图像 diffusion 理解直觉	4
3.3 文本中的 Masked Diffusion Model	5
3.4 本章小结	6
4 2025 的几条大趋势：跨模态借鉴、效率优先与硬件回归	6
4.1 跨模态 ideas 正在互相流动	6
4.2 第二条 Pareto frontier：质量之外，更看重成本	6
4.3 硬件重新进入叙事中心	7
4.4 本章小结	7
5 Closing Thoughts：真实世界会如何消化这些能力	7
5.1 日常工作与学习已经被重塑	7
5.2 Agent 的民主化与 OS-level 想象	8
5.3 仍未解决的长期难题	8
5.4 本章小结	9
6 总结与延伸	9

1 全课地图回放：这门课到底串起了什么

最后一讲的开场不是继续堆新名词，而是试图把整个季度的内容重新连成一张地图。讲者把课程分成三部分：先回顾整个学期的逻辑，再讨论 2025 年正在冒头的趋势，最后给出一些面向学生的 closing thoughts。

这种安排本身就揭示了课程的判断：大模型领域变化太快，单独记住每一篇论文、每一个技巧没有意义，更重要的是理解“哪一类问题催生了哪一类设计”。因此回顾部分并不是简单复述前八讲，而是把每一讲放回一条共同的能力演化链上。

课程回顾大致可以浓缩为：

1. Lecture 1-2：理解 Transformer 及其关键构件，如 self-attention、位置编码、结构改造；
2. Lecture 3-5：理解 LLM 的规模化、训练、对齐与推理增强；
3. Lecture 6-8：理解 RAG、tool calling、agents 与 evaluation 如何把模型嵌进真实系统。

讲者在口头回顾里还特别强调了模型生命周期视角：initialized model、pretraining、finetuning、preference tuning 这些阶段并不是彼此孤立，而是在不断把“会生成文本的模型”塑造成“更能满足用户需求的系统”。

最后一讲的阅读方式

本讲不是单一技术专题，而是“复习 + 展望 + 方法论建议”的混合体。阅读时最好把它理解为一门课的系统整合，而不是一篇单独的技术讲义。

1.1 本章小结

回顾部分帮助我们z把课程主线重新压缩成一条能力演化路径：从 Transformer 结构，到 LLM 训练与对齐，再到把模型接入知识、工具、agent 和评测体系。后面的趋势讨论，都是建立在这条路径之上的。

2 Transformer 不只属于文本：从视觉到多模态


2.1 为什么要跳出“文本专用”的想象

课程先提醒我们，Transformer 最早并不是为“聊天机器人”设计的，而是为机器翻译提出的通用序列建模架构。它依赖 query、key、value 与 self-attention 的组合，本质上是在处理“对象之间的关系”，而不是只处理自然语言。

因此，一个自然问题是：如果图像也能被切分成 token-like 的 patch，那么 attention 能不能同样建模图像内部的关系？这就是课程转向 Vision Transformer 的动机。

Vision Transformer

ViT = Vision Transformer



Stanford University "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale", Dosovitskiy et al., 2020.

ICME

图 1: Vision Transformer 的基本结构: 把图像切成 patch, 线性投影后加上位置编码, 再送入 Transformer encoder。

2.2 ViT 与视觉语言模型的两条路径

ViT 的关键思想很直接: 把图像分成固定大小的 patch, 对每个 patch 做线性映射, 再像文本 token 一样送入 Transformer。这样, 原本针对序列设计的架构就可以迁移到视觉任务中。课程用它来说明 “Transformer 的归纳能力并不局限于文字”。

沿着这个方向, 课程进一步介绍了视觉语言模型的两类常见设计:

1. 复用 decoder-only 结构: 把视觉表示转成某种可被语言模型消费的 token 序列, 再让模型做 text-in, text-out;
2. 在语言生成器里加入 cross-attention: 让文本生成过程显式读取视觉 encoder 的表示。

这部分的重点不是区分谁绝对更好, 而是说明多模态系统的发展常常是 “把已有文本架构改造得能消费别的模态”。这会在后文的 diffusion LLM 讨论里再次出现。

2.3 本章小结

这一节说明了 Transformer 的两个特征: 一是结构足够通用, 可以迁移到视觉和多模态; 二是很多趋势并非全新范式, 而是把既有结构重新编码到新的输入与任务上。

3 从自回归到 Diffusion: 文本生成是否必须逐 token 展开

3.1 当前主流范式的局限

课程先重新回到 autoregressive modeling。传统 LLM 按 token 顺序一步步预测下一个词, 这种方式概念清晰、训练成熟, 但它也天然带来串行生成瓶颈: 后一个 token 必须等待前一个 token, 推理延迟因此受到限制。

讲者在口头部分把这个问题和成本趋势连起来看：如果未来很多能力需求已经“基本够用”，研究重点就会越来越转向成本、速度与部署效率，而不是单纯再多刷几个 benchmark 点数。这也正是 diffusion-based text models 被拿出来讨论的原因。

Alternative approach in the news




图 2: 课程展示的 2025 新闻切片：Google、Inception、ByteDance 等都在推动 diffusion-based text/code 模型，说明它已从纯研究话题变成产业关注方向。


3.2 先从图像 diffusion 理解直觉

为了让文本 diffusion 更容易理解，课程先回到图像生成。标准 diffusion 图景可以概括为两步：


1. 正向过程：不断向真实样本加噪，把它推向接近纯噪声的分布；
2. 反向过程：训练模型逐步去噪，从噪声恢复出真实样本。

Intuition behind diffusion for images

1. Add noise to image (forward process)



2. Learn to denoise it (reverse process)



Stanford University "Denoising Diffusion Probabilistic Models", Ho et al., 2020.

ICME

图 3: 图像 diffusion 的核心直觉: 前向加噪、反向去噪。课程用它作为过渡, 解释为什么文本也可以尝试“非自回归地逐步恢复内容”。


在图像里, 加噪通常是连续空间里的高斯噪声; 但文本 token 是离散符号, 不能直接像像素那样加连续噪声。所以课程接着用 masked diffusion 的思路把图像 diffusion 迁移到文本: 不是对 token 加实值噪声, 而是以一定概率把 token mask 掉, 再让模型逐步恢复。

3.3 文本中的 Masked Diffusion Model

Diffusion in LLMs

MDM = Masked Diffusion Model

Decoding done in fewer forward passes!



Stanford University

ICME

图 4: 课程给出的 MDM 示意: 以 mask 代替连续噪声, 在更少的 forward passes 中同时恢复多个 token。

Masked Diffusion Model 的诱人之处在于：一次前向可以同时更新多个位置，因此潜在地比严格自回归生成更快。课程把它的卖点概括为“decoding done in fewer forward passes”。如果把自回归视为每一步只补一个 token，那么 masked diffusion 更像是每轮并行修复一批未知位置。

但课程也没有把它讲成银弹。讲者在口头说明里提到几个现实障碍：

1. 文本是离散空间，forward / reverse process 的设计比图像复杂；
2. 很多后训练技术，如偏好优化、强化学习、对齐流程，原本是围绕自回归接口建立的，迁移到 diffusion LLM 并不直接；
3. benchmark 提升不等于工程落地，训练稳定性、评测协议、部署接口都要重写。

课程的核心判断

Diffusion LLM 值得认真关注，但目前更像一个正在快速探索的方向，而不是已经完全替代自回归 LLM 的既成事实。

3.4 本章小结

这一节完成了从 ARM 到 diffusion 的范式对照：自回归方式成熟、稳定，但串行；masked diffusion 可能更快、更并行，却需要为离散文本重新设计训练与对齐方法。它代表的是“体系结构仍未定型”这一现实。

4 2025 的几条大趋势：跨模态借鉴、效率优先与硬件回归

4.1 跨模态 ideas 正在互相流动

课程明确提出一个趋势：不同模态之间会互相借鉴有效设计。图像领域的 diffusion 思想开始进入文本；文本领域的对齐、工具调用和 agent 框架又会反过来影响多模态系统。这种 cross-pollination 意味着，未来不一定再有严格的“NLP 技术”和“CV 技术”边界。

讲者同时提醒，基础研究并没有结束。相反，微观设计层面的差异仍然很多，包括数据配比、位置编码、注意力变体、训练阶段划分、是否引入 mid-training、是否混入模型生成数据等。尤其在口头结尾中，他提到 model collapse 风险和高质量数据稀缺，说明“数据工程”本身会继续成为核心竞争力。


4.2 第二条 Pareto frontier：质量之外，更看重成本

回顾 2025 的系统选型，讲者给出一个很有洞察力的说法：过去几年大家主要在追求 benchmark 更高；但当很多 use case 已经“够用了”，接下来的竞争会越来越落在第二条 Pareto frontier 上，也就是“在保持足够高质量的同时，把推理成本、延迟和能耗继续压低”。

这也是 small language models、routing、更细的 serving optimization 会持续升温的原因。未来的研究重点不只是“能不能做”，更是“能不能便宜地做、稳定地做、大规模地做”。

4.3 硬件重新进入叙事中心

Hardware optimization



Stanford University

Figures adapted from "Analog in-memory computing attention mechanism for fast and energy-efficient large language models", Leroux et al., 2025.

ICME

图 5: 课程中的硬件优化示意: 不是仅仅改软件 kernel, 而是尝试把 attention 所需的一部分算子与数据流更深地编码进硬件。

课程在这里把话题从模型算法拉回到硬件现实。GPU 擅长矩阵乘法, 但 Transformer 的注意力并不只需要矩阵乘法, 它还高度依赖 KV 读写、内存搬运和中间状态管理。FlashAttention 一类工作已经说明, 很多瓶颈来自 memory movement, 而不是算子本身。

更进一步, 讲者介绍了一类模拟硬件方向的工作, 尝试把某些 attention 相关计算直接体现在电路和信号流里。无论这条路最终是否成为主流, 它都说明一个事实: 大模型系统性能的上限, 并不只由算法决定, 也受制于底层计算介质。

4.4 本章小结

这一节想表达的不是“某个具体热点会胜出”, 而是三种长期张力: 跨模态借鉴会继续、效率竞争会增强、硬件与系统实现会重新变得像模型结构一样重要。

5 Closing Thoughts: 真实世界会如何消化这些能力

5.1 日常工作与学习已经被重塑

课程的 closing thoughts 不是抽象口号, 而是从学生和工程师的日常体验出发。讲者认为, coding assistants、浏览器级 AI、文案与创意草稿、课堂中即时用 ChatGPT 澄清概念, 这些都已经是现实存在的价值场景。尤其对学习而言, 得到一个“即时讨论对象”和“低成本反馈回路”本身就是很大的增益。

这段话与整门课前面的内容其实是一致的: 真正有价值的系统未必是最炫的 benchmark 冠军, 而是能把知识获取、执行效率和认知负担降下来。

5.2 Agent 的民主化与 OS-level 想象

More use cases to be expected

Tomorrow.

Democratization of existing agents (e.g. Google Workspace launch)


Near term.

Browser? (e.g. OpenAI's Atlas launch). Looking further: OS-level LLM?

Introducing ChatGPT Atlas

The browser with ChatGPT built in.

Download for macOS



Stanford University "Introducing ChatGPT Atlas", OpenAI, October 21, 2025.

ICME

图 6: 课程以 Atlas 等产品作为“近未来”信号: agentic workflow 可能从专家工具走向更广泛用户界面, 先浏览器化, 再逐步操作系统化。

讲者判断, 未来几年一个重要方向是 agent 能力的 democratization。也就是说, 今天只有熟悉该领域的人会用的 agentic workflow, 会逐渐通过自然语言界面进入普通人的日常工作流。浏览器级助手、桌面级助手、移动端 OS-level assistant, 都属于这条演化链的一部分。

但课程同样保留了现实主义: agent 步数越多, 失败概率越高; 安全、权限、注入攻击、防止越权执行, 仍然是阻碍大规模普及的主要因素。讲者甚至把“你是否愿意真的让 AI 客服替代人工客服”当作一个现实测试, 借此说明 empathy、groundedness 和对隐性规则的把握, 仍然是困难问题。

5.3 仍未解决的长期难题

最后一讲没有用“AGI 快到了”之类的句子收尾, 而是回到几个更朴素但更硬的问题:

1. 固定权重问题: 模型训练完成后权重冻结, RAG 和 tools 只是绕开了连续学习问题, 并没有真正解决它;
2. Hallucination 问题: 从 next-token prediction 目标出发, 模型天生不是“事实数据库”;
3. Personalization、interpretability、safety: 这些都还远未被彻底解决。

讲者给学生的最后建议则非常具体: 想持续跟进该领域, 就去看 arXiv、NeurIPS / ICML / ICLR / ACL / EMNLP 等 venue; 不要只读论文, 也要读作者给出的代码; 此外, Hugging Face 的 trending papers 这类入口, 可以帮助你快速捕捉近期热点。

课程结尾的现实判断

未来突破未必只来自更大的模型或更高的 benchmark。它同样可能来自更好的数据、更便宜的推理、更合适的硬件、更新的体系结构, 或者更贴近真实任务的产品接口。

5.4 本章小结

Closing thoughts 把技术趋势重新落回真实使用场景：LLM 已经开始深刻改变学习、编码与信息获取方式，但要走向普遍可依赖的 agent 系统，还需要解决稳定性、安全性和连续学习等长期问题。

6 总结与延伸

第 9 讲并没有试图预测某一条唯一正确的未来路线，而是用回顾与展望告诉我们：大模型领域仍然处在快速重构阶段。课程至少给出了四个值得长期记住的判断。

1. Transformer 很重要，但未必是最终形态；它已经扩展到视觉、多模态，也可能被新的结构部分替代。
2. 自回归 LLM 依然是今天的主流，但 diffusion、并行生成等路线说明“逐 token 串行生成”并非唯一答案。
3. 未来竞争会越来越看重质量与成本的联合最优，而不是单维 benchmark。
4. 真正决定产品形态的，不只是模型分数，还包括硬件、系统接口、安全边界与用户 workflow。

如果把整门课的收获压成一句话，可以说：**理解大模型，不只是理解一个网络结构，而是理解一个不断在数据、训练、推理、外部工具、评测体系和真实世界约束之间重新平衡的系统。**

对已经学完这门课的人来说，最有价值的下一步不是死记热点，而是练习两种能力：第一，能把任何新论文放回“它在解决哪一类老问题”的坐标系里；第二，能把任何新模型放回“它是否真的改善了我的任务、成本和风险”的工程坐标系里。

这也正是本课程最后一讲的意义所在：它不只是总结学期内容，而是在训练一种继续学习这门领域的方法。