


课程笔记

CS224R 课程笔记: Lecture 2 Imitation Learning

Codex

2026-04-13



视频作者/频道: CS224R / Stanford

发布日期: 课程讲次日期: 2025-04-04

视频时长: 未在本地图元数据中提供

视频链接: https://www.youtube.com/watch?v=WxRDy0brm_M

目录

1 模仿学习问题的基本设定	2
1.1 数据、目标与未知专家策略	2
1.2 Behavior Cloning: 版本 0	2
1.3 本章小结	2
2 为什么仅用均值回归不够：需要表达性策略分布	2
2.1 多峰动作分布与均值灾难	2
2.2 从单点动作到条件分布	3
2.3 为什么“网络表达力强”不等于“分布表达力强”	4
2.4 从研究示例到工业落地	4
2.5 本章小结	4
3 模仿学习的核心风险：Compounding Errors	4
3.1 监督学习的假设为什么在行为学习里破裂	4
3.2 为什么错误会越滚越大	5
3.3 本章小结	5
4 如何缓解分布失配：DAgger 与 Human-Gated DAgger	6
4.1 Dataset Aggregation 的基本思路	6
4.2 Human-Gated DAgger: 更实用的人机接口	6
4.3 本章小结	7
5 演示从哪里来：收集方式与 Embodiment Gap	7
5.1 数据收集并不总是理所当然	7
5.2 为什么机器人不能直接模仿人类或动物视频	7
5.3 本章小结	8
6 总结与延伸	8

1 模仿学习问题的基本设定

第二讲从上一节建立的 RL 记号继续往前走，但这次不直接做在线试错，而是假设我们已经有了专家演示数据。模仿学习的直觉非常自然：如果某个专家能够高质量完成任务，那么能否直接从专家的轨迹里学出一个策略？

1.1 数据、目标与未知专家策略

课程把演示数据记作

$$\mathcal{D} = \{(s_1, a_1, \dots, s_T, a_T)\},$$

也就是若干条由专家收集的轨迹。这里隐含着一个关键假设：这些数据样本来自某个未知的专家策略 π_{expert} ，但我们看不到策略本身，只能看到它留下的行为轨迹。

模仿学习的目标是学出一个策略 π_θ ，使它在任务上的表现接近专家。与强化学习直接从奖励优化不同，模仿学习试图利用更强的监督信号，把“专家在这个状态下做了什么”当作可学习的标签。

1.2 Behavior Cloning: 版本 0

最直接的办法是 behavior cloning。对于确定性策略，课上把它写成一个标准监督学习问题：给定状态 s ，预测动作 $\hat{a} = \pi_\theta(s)$ ，再让它尽可能接近专家动作 a 。

$$\min_{\theta} \frac{1}{|\mathcal{D}|} \sum_{(s,a) \in \mathcal{D}} \|a - \hat{a}\|_2^2.$$

符号说明如下：

- $\mathcal{D}$: 专家演示数据集；
- a : 专家动作；
- $\hat{a}$: 策略在相同状态上的预测动作；
- $\|\cdot\|_2^2$: 在连续动作空间里常见的平方误差。

这就是课件所说的 imitation learning version 0。它的优点是简单、可扩展、容易放进常规深度学习训练管线。很多实际系统都会先用这一步做初始化。

1.3 本章小结


模仿学习把 RL 问题暂时转写成“从专家行为监督学习策略”的问题。最简单的形式就是 behavior cloning，用状态预测动作，训练快、实现简单，但它的表达能力和分布泛化能力都还没有被认真处理。

2 为什么仅用均值回归不够：需要表达性策略分布


2.1 多峰动作分布与均值灾难

讲者用自动驾驶例子指出，演示数据往往不是单峰的。面对同一个路况，专家有可能选择并道向左，也有可能保持直行。若我们用 L_2 回归学习一个确定性动作，模型很容易输出“两个模式的平均值”，而这个平均值本身可能根本不是一个可执行的好动作。

What could go wrong?



Question: what might policy trained with ℓ_2 -regression do?



How can we represent more than the mean?

How often does this happen in practice? All the time!

Esp. when data collected by multiple people.

7


图 1: 当演示数据包含多个合理动作模式时, 单一均值回归会输出危险的“平均动作”。

这个现象在讲者口头说明里被描述得非常明确: 当数据由多个人收集、或者任务本身就存在多个合理解时, 这种问题会一直出现。也就是说, 网络更深并不能自动解决“输出分布错了”的问题。

2.2 从单点动作到条件分布

课程随后把目标从学习单点 $\hat{a}$ 改成学习条件分布 $p(a | s)$ 。这一步的意义不是“为了更 fancy”, 而是承认动作本身可能具有不确定性、多模态与组合结构。

Generative models for policies (approximating $p(\mathbf{a} | \mathbf{s})$)



Question: how are these different from ℓ_2 loss with larger network?

Important Note: Neural network expressivity is often distinct from distribution expressivity!

图 2: 表达性策略分布的三条常见路线: 高斯混合、自回归离散化和 diffusion。

讲者先回顾了离散动作和连续动作中最常见的简单参数化：

- 离散动作可以输出 categorical distribution；
- 连续动作可以输出高斯分布的均值与方差。

但这些方法仍然可能不够 expressive。于是课程引入更强的 generative policy 建模方式：

- Mixture of Gaussians：允许多个峰值，适合表达多模态连续动作；
- Discretize + Autoregressive：把动作维度离散化后按顺序建模条件概率；
- Diffusion：通过迭代去噪生成动作样本。

2.3 为什么“网络表达力强”不等于“分布表达力强”

这一讲特别提醒，不能把“神经网络很强”与“动作分布建模得好”混为一谈。即使用一个很大的网络预测动作，如果目标函数仍然只是把多峰数据压成单个均值，它学到的仍可能是一个坏策略。

这讲的关键判断

表达性策略分布之所以重要，不是因为生成模型流行，而是因为模仿学习要面对的监督对象本来就是“同一状态下可能存在多种合理动作”。

2.4 从研究示例到工业落地

课件还给出两类具体应用：

- 机器人操控里，diffusion policy 一类方法能更好地捕捉复杂动作分布；
- 自动驾驶里，自回归离散化预测被用于更稳定地表示高维控制输出。

讲者在总结页里把要点概括成一句话：如果数据来自单一且高度一致的专家，简单分布也许足够；但一旦动作分布是多峰的，就必须用更有表达力的生成式策略。

2.5 本章小结

模仿学习的第一个真正难点不是“怎么优化”，而是“策略究竟应该输出什么对象”。当专家行为具有多模态结构时，确定性均值回归会系统性失败，因此课程把策略从单点预测升级为条件分布建模问题。


3 模仿学习的核心风险：Compounding Errors

3.1 监督学习的假设为什么在行为学习里破裂

behavior cloning 的第二个问题比“均值灾难”更深。普通监督学习默认测试时输入仍然来自训练分布；而行为学习里，模型预测出来的动作会改变下一步访问到的状态。这意味着一个早期小错误会把策略带到专家数据稀少的新状态区间，再导致更大的错误。

What can go wrong in imitation learning?

Compounding errors



18

图 3: 行为监督学习与普通监督学习的差别在于: 预测动作会影响未来状态, 因此误差会随时间累积。

课程把这件事写成 covariate shift:

$$p_{\text{expert}}(s) \neq p_{\pi}(s).$$

左边是专家访问到的状态分布, 右边是当前学习策略实际访问到的状态分布。只要两者不同, 策略在训练时没见过的状态就会在测试时不断冒出来。

3.2 为什么错误会越滚越大

讲者用图示说明这个过程: 如果在 s_2 的动作稍微偏了一点, 后面就会落到一个不同的 s_3 。而 s_3 可能根本不在专家分布的高密区域内, 此时模型只能在陌生状态上继续猜动作, 结果又把自己带得更偏。

这就是 compounding errors。它不是偶然 bug, 而是 behavior cloning 在顺序决策里天然会碰到的结构性问题。

为什么这比普通泛化误差更危险

因为这里的输入偏移是策略自己造成的。模型不是被动地接收分布外样本, 而是在每一步决策后主动把自己推进新的分布区域。

3.3 本章小结

模仿学习的第二个核心难点是分布失配。训练集来自专家, 部署时状态由学习到的策略自己诱导, 因此小误差会沿时间累计并不断放大, 最终让策略远离演示分布。

4 如何缓解分布失配: DAgger 与 Human-Gated DAgger

4.1 Dataset Aggregation 的基本思路

解决 compounding errors 的直接办法, 是不要只在专家原始分布上学, 而要让数据集逐步覆盖学习策略真实会访问到的状态。课程给出的第一种方法是 DAgger (dataset aggregation)。




图 4: DAgger 的基本循环: 让当前策略访问状态, 再查询专家动作并把这些纠正样本聚合进数据集。

它的核心步骤是:

1. 用当前 learned policy rollout 一批轨迹;
2. 在这些实际访问到的状态上查询专家动作 $a^* \sim \pi_{\text{expert}}(\cdot | s)$;
3. 把新收集到的 (s, a^*) 与原数据聚合;
4. 重新训练或继续更新策略。


它的优点是数据效率高, 而且纠正样本正好落在策略会犯错的状态区域。于是训练分布和部署分布的差距被逐步缩小。

4.2 Human-Gated DAgger: 更实用的人机接口

但标准 DAgger 有一个实际问题: 如果智能体全程自主运行, 专家必须持续观察并随时标注访问到的状态, 接口不够自然。为此课程介绍了 human-gated DAgger。

Addressing Compounding Errors with Interventions

Collect **corrective behavior data** while taking full control



21

图 5: Human-Gated DAgger 让专家只在策略明显出错时介入，并从介入点开始提供局部纠正示范。

它的流程更贴近真实系统：

- 学习策略开始执行；
- 一旦专家发现策略要出错，就在时刻 t 接管；
- 从该接管状态起，专家给出部分 demonstration；
- 把这些局部纠正片段并入数据集再训练。

这个版本的好处是交互更自然，更适合人类在机器人或驾驶等系统上实时提供纠正。代价是需要可靠地发现“什么时候该介入”。

4.3 本章小结

DAgger 的核心不是简单加数据，而是让新数据来自学习策略真正访问到的状态。HG-DAgger 则把这一思想改造成更可操作的人机协作流程，从而更实际地缓解 compounding errors。

5 演示从哪里来：收集方式与 Embodiment Gap

5.1 数据收集并不总是理所当然

课程最后提醒，模仿学习依赖 demonstrations，但 demonstrations 的来源高度依赖具体领域。在驾驶或文本等场景中，人类本来就在自然地产生可记录的行为；而在机器人领域，收集高质量示范往往更加昂贵。

5.2 为什么机器人不能直接模仿人类或动物视频


讲者给出的答案是 embodiment gap。人类、动物和机器人之间在两个层面可能不一致：

- 外观不同，视觉输入中的身体和环境结构不一致；
- 物理能力、关节结构、自由度和执行约束不同。

Can robots directly use videos of people, animals?

Embodiment gap: - difference in appearance
 - difference in physical capabilities, degrees of freedom

Hard to directly imitate human & animal data, but can potentially guide exploration.



Peng, Kanazawa, Malik, Abbeel, Levine. SFV: Reinforcement Learning of Physical Skills from Videos. SIGGRAPH Asia 2018.
 24

图 6: 人类 / 动物视频与机器人动作之间存在 embodiment gap，因此不能简单逐帧照搬。

这意味着“看视频学动作”不是不可能，而是不能天真地把人类动作直接当作机器人动作标签。更现实的做法通常是把人类 / 动物视频当作探索、奖励或技能先验的弱指导，而不是直接的一一对应监督。

5.3 本章小结

模仿学习的成功很大程度上取决于演示质量与采集接口。不同领域的数据可得性差异很大，而机器人场景还会额外遇到 embodiment gap，使跨主体模仿变成一个单独的研究问题。

6 总结与延伸

第二讲把 imitation learning 从“看起来像监督学习”变成了一个更真实的顺序决策问题。课程先说明最基础的 behavior cloning 形式，再指出两个决定性困难：第一，动作分布往往是多峰的，单一均值预测不够；第二，策略会改变自己未来访问到的状态，因此 compounding errors 会不断累积。

围绕这两个问题，这讲给出了两组解决思路。第一组是让策略输出真正有表达力的动作分布，例如高斯混合、自回归和 diffusion。第二组是让数据分布逐步靠近部署分布，例如 DAgger 与 HG-DAgger。二者分别解决“你学的对象对不对”和“你学到的数据是不是部署时会遇到的状态”。

因此，模仿学习并不是“有示范就万事大吉”。它真正的研究问题在于：

- 如何表示复杂、随机、多峰的行为分布；
- 如何控制训练分布与部署分布的偏移；
- 如何用合适的人机接口持续收集高质量纠正数据；

- 如何跨越 embodiment gap, 把非机器人数据转化为对机器人仍然有用的学习信号。

从课程节奏看, 这一讲也起到了承前启后的作用。它一方面保留了监督学习式的强信号, 另一方面已经把大家带到“策略影响状态分布”的核心 RL 难点上, 为之后进入在线 RL 和 policy gradients 做了铺垫。