

课程笔记

CS224R Lecture 7: 离线强化学习

五道口纳什 & Codex

2025-04-23



视频作者/频道: Stanford Online

发布日期: 2025-12-08 (YouTube 上传)

视频时长: 1:07:50

视频链接: <https://www.youtube.com/watch?v=1RDaXnPizks>

目录

1 问题设定与动机	2
1.1 从在线 RL 过渡到离线 RL	2
1.2 为什么要做离线 RL	2
1.3 本章小结	2
2 离线 RL 的核心困难：分布偏移与过估计	2
2.1 为什么直接套用 off-policy 方法会出问题	2
2.2 过估计是如何形成的	3
2.3 为什么这和模仿学习不同	3
2.4 本章小结	3
3 从加权模仿到隐式策略约束	4
3.1 先从模仿学习出发	4
3.2 AWR 的关键瓶颈：优势函数从哪来	4
3.3 IQL：只在数据动作上学习，但把价值学得更乐观	4
3.4 为什么 IQL 的不对称损失用在 V 而不是 Q	5
3.5 本章小结	5
4 保守方法：Conservative Q-Learning	6
4.1 保守思想：主动压低数据外动作的价值	6
4.2 CQL 的目标函数怎样理解	6
4.3 CQL 与 IQL 的分工	6
4.4 本章小结	7
5 应用案例与实践选择	7
5.1 LinkedIn 通知优化案例	7
5.2 算法选型建议	7
5.3 本章小结	8
6 总结与延伸	8

1 问题设定与动机

1.1 从在线 RL 过渡到离线 RL

这节课首先回顾了前面已经见过的在线强化学习范式。无论是 policy gradient、actor-critic 还是 off-policy Q-learning，它们都依赖一个共同循环：先由当前策略与环境交互收集数据，再利用这些新数据更新价值函数和策略。只要还能持续在线采样，这个循环就允许算法不断修正自己对价值的估计。

离线强化学习 (offline RL) 把这个前提拿掉了。我们不再拥有“边训练边采样”的权限，而是只拿到一个已经固定的数据集 D ，它可能来自人工操作、旧版本策略、历史系统日志，或者此前实验中累积下来的经验。训练目标仍然是学习一个高回报策略 π_θ ，但所有更新都必须在这份静态数据上完成。

离线 RL 的基本对象

设离线数据集为

$$D = \{(s, a, r, s')\},$$

它由未知行为策略 π_β 采集。离线 RL 的目标不是重建 π_β ，而是在不新增交互的前提下，学习性能更好的 π_θ 。

1.2 为什么要做离线 RL

课程里给出三个非常现实的动机。第一，很多场景已经天然拥有海量历史数据，例如自动驾驶的人类驾驶记录、医疗处置日志、机器人历史轨迹、产品推荐系统日志。第二，在线试错往往昂贵、危险，甚至根本不允许；如果一开始策略就很差，直接部署采样可能造成严重风险。第三，哪怕在线训练可行，重新采样也非常浪费，因为每次改动算法都要重新与环境交互，硬件与时间成本都很高。

因此，离线 RL 的价值并不是“它比在线 RL 更强”，而是“它在不能安全探索、但又有历史数据时，提供了继续改进策略的可能性”。

1.3 本章小结

离线 RL 的核心变化不是目标函数变了，而是数据获取方式变了。训练者失去了在线纠错能力，因此任何估计偏差都更难通过后续采样修复，这也直接引出了后面的核心难点。

2 离线 RL 的核心困难：分布偏移与过估计


2.1 为什么直接套用 off-policy 方法会出问题

如果把前面课程中的 off-policy actor-critic 或 Q-learning 直接搬到离线场景，一个直观想法是：数据本来就不是当前策略采的，off-policy 方法不就是为这种情况设计的吗？本讲的回答是否定的，因为离线场景里的分布偏移比普通 replay buffer 更严重。

在普通 off-policy 学习中，虽然数据来自旧策略，但训练过程中仍然在不断收集新数据，因此策略偏移太远时，系统还有机会把新的状态-动作对补回 buffer。离线 RL 没有这个补救步骤。一旦当前策略倾向于选择数据支持之外 (out-of-distribution, OOD) 的动作，Q 函数就会在没有监督的区域上被查询，而这些区域往往恰好容易出现虚高估计。

How to mitigate overestimation in offline RL?

Recall: Randomly init. Q -function for state s'



Can we discourage overestimation?
without explicitly modeling the behavior policy

What if we just push down on large Q-values?

$$\hat{Q}^\pi = \arg \min_Q \max_{\mu} E_{(s,a,s') \sim D} \left[\underbrace{\left(Q(s,a) - (r(s,a) + \gamma E_{\pi} [Q(s',a')]) \right)^2}_{\text{standard critic update}} \right] + \underbrace{\alpha E_{s \sim D, a \sim \mu(\cdot|s)} [Q(s,a)]}_{\text{push down on large Q-values}}$$

Can show that $\hat{Q}^\pi \leq Q^\pi$ for large enough α

Slide adapted from Sergey Levine

25

图 1: 离线 RL 中的核心风险: 策略会去追逐数据支持外、但被 Q 函数高估的动作。

2.2 过估计是如何形成的

可以把问题想成一条动作轴上的函数逼近。对于某个状态 s' ，数据只覆盖一小段动作区间，但随机初始化的 $Q(s', a')$ 在整个动作空间上都有数值。当策略更新时，它会倾向于选择当前看起来 Q 值最大的动作；如果这个动作恰好落在未覆盖区域，那么 critic 就会用一个没有真实标签约束的位置来驱动 actor 更新。

形式上，标准 off-policy critic 往往使用类似

$$\min_Q \mathbb{E}_{(s,a,s') \sim D} \left[\left(Q(s,a) - (r(s,a) + \gamma \mathbb{E}_{a' \sim \pi(\cdot|s')} Q(s',a')) \right)^2 \right].$$

问题在于上式中的 $a' \sim \pi(\cdot|s')$ 可能来自当前学习策略，而这个动作不一定出现于数据中。于是 bootstrapping 会把“未验证的高值”递归写进目标，最终放大误差。

离线 RL 最怕什么

在在线 RL 里，错误的高估值还能通过继续交互被纠正；在离线 RL 里，策略一旦离开数据支持，训练过程就没有新证据来纠错，误差会被 Bellman backup 反复放大。

2.3 为什么这和模仿学习不同

模仿学习只在数据里的动作上做监督学习，因此它通常不会主动走到 OOD 动作上。但它的代价也很明显：如果数据里混有坏的行为，纯粹做行为克隆只能复制平均表现，难以利用回报信号去“拼接”更优策略。离线 RL 的难点恰恰就在这里：既想超过行为策略，又不能为此跑出数据支持。

2.4 本章小结

离线 RL 不是单纯的“没有在线采样的 off-policy RL”，而是一个受限更强的问题。限制的本质是：一旦策略查询了数据外动作，Q 函数就会在无监督区域产生过估计，而这恰好是策略更新最敏

感的信号。

3 从加权模仿到隐式策略约束

3.1 先从模仿学习出发

课程接着提出一个更保守的问题：如果完全不查询数据外动作，能不能仍然利用奖励信息做得比普通行为克隆更好？答案是肯定的。一个自然思路是仍然在数据里的动作上训练策略，但让“更好的动作”获得更高权重。

这种思想可以写成 advantage-weighted regression (AWR)：

$$\theta \leftarrow \arg \max_{\theta} \mathbb{E}_{(s,a) \sim D} [\log \pi_{\theta}(a|s) \exp(A(s,a))].$$

其中 $\log \pi_{\theta}(a|s)$ 像标准模仿学习一样鼓励复现数据动作，而 $\exp(A(s,a))$ 则把动作优劣显式编码进权重。

Advantage-weighted regression

Could we weight each transition depending on how good the action is?

$$\theta \leftarrow \arg \max_{\theta} E_{s,a \sim D} [\log \pi_{\theta}(a|s) \exp(A(s,a))]$$

standard imitation learning with advantage weights

Key question: How to estimate the advantage function?

First simple
approach

Estimate $V^{\pi_{\theta}}(s)$ with Monte Carlo: $\min_{\phi} \sum_{s_t \sim D} \|\hat{V}_{\phi}^{\pi_{\theta}}(s_t) - \sum_{t'=t}^T r(s_{t'}, a_{t'})\|^2$

Approximate $\hat{A}^{\pi_{\theta}}(s_t, a_t) = \sum_{t'=t}^T r(s_{t'}, a_{t'}) - \hat{V}_{\phi}^{\pi_{\theta}}(s_t)$ ← empirical return

Question: What do you learn
for deterministic policy π_{θ} ?

Peng, Kumar, Zhang, Levine. Advantage-Weighted Regression. '19

18

图 2: AWR：在模仿学习的 log-likelihood 上加入 advantage 权重，只偏向数据中更优的动作。

3.2 AWR 的关键瓶颈：优势函数从哪来

AWR 看起来很合理，但真正困难的是如何估计 $A(s,a)$ 。如果直接用 Monte Carlo return 去拟合价值，再用

$$\hat{A}(s_t, a_t) = \sum_{t'=t}^T r(s_{t'}, a_{t'}) - \hat{V}(s_t),$$

就会遇到两个限制。第一，Monte Carlo 估计方差高；第二，如果行为策略是确定性的或者数据覆盖不足，很多状态下实际上只观测到一种动作，这时“相对更优的动作”很难从数据中读出来。

3.3 IQL：只在数据动作上学习，但把价值学得更乐观

Implicit Q-Learning (IQL) 的关键观察是：不必直接对数据外动作做 maximization，也可以通过“价值回归方式”的改变，隐式地偏向更好的动作。它仍然只使用数据里的 (s,a) 更新 Q 与 V ,

但在学习状态价值 V 时，不再回归平均 Q ，而是回归一个较高 expectile，对应“在该状态下，行为策略中表现较好的那部分动作”。

expectile regression 的损失写作

$$\ell_2^\lambda(x) = \begin{cases} (1-\lambda)x^2, & x < 0, \\ \lambda x^2, & x \geq 0. \end{cases}$$


当 $\lambda > 0.5$ 时，损失会更偏向拟合高于当前估计的样本，从而把状态价值拉向较优动作对应的 Q 值。随后再通过 advantage-weighted 的方式抽出策略，整个过程都不需要显式查询 OOD 动作。

Aside: Expectile regression

Instead of getting the mean of a random variable, can we get a higher or lower expectile?


Expectile regression loss:

$$\ell_2^\lambda(x) = \begin{cases} (1-\lambda)x^2 & \text{if } x < 0 \\ \lambda x^2 & \text{otherwise} \end{cases}$$



Kostrikov, Nair, Levine. Implicit Q-Learning. ICLR '22

Example with a 2D random variable



22

图 3: Expectile regression: 用不对称二次损失把状态价值往较高回报的动作分位上拉。

3.4 为什么 IQL 的不对称损失用在 V 而不是 Q

讲者特别强调了一个容易混淆的点：对 V 用不对称损失，是在同一状态下偏向更好的动作；对 Q 也这么做则会把环境随机性里的“运气好”也当成策略应该追求的目标。换句话说，价值函数的不对称回归应该发生在“动作选择”这一层，而不是发生在“状态转移噪声”这一层。

IQL 的哲学

IQL 的目标不是大胆外推，而是在严格待在数据支持内的前提下，利用价值函数的回归方式把“更优动作”从行为数据里分离出来。

3.5 本章小结

这一节给出的主线是：想在离线数据上超过行为克隆，可以先不碰 OOD 动作，而是通过加权模仿、优势估计与 expectile 价值学习，在数据支持内完成策略改进。IQL 是这一思路的代表。

4 保守方法：Conservative Q-Learning

4.1 保守思想：主动压低数据外动作的价值

另一条路线并不回避 OOD 动作，而是承认策略更新过程中会考虑它们，然后显式把这些动作的 Q 值往下压。CQL (Conservative Q-Learning) 的直觉非常直接：如果数据外区域的 Q 无法被准确监督，不如在这些地方系统性悲观一些。

课程先给出原型目标：在标准 critic loss 之外，再加入一项，对某个辅助分布 $\mu(\cdot|s)$ 下采到的动作施加惩罚，使高 Q 动作被压低；与此同时，再对数据中的 (s, a) 加一个“抬高”项，避免把数据支持内的 Q 一起压扁。

How to mitigate overestimation in offline RL?

Can we discourage overestimation?
without explicitly modeling the behavior policy

$$\hat{Q}^\pi = \arg \min_Q \max_\mu E_{(s, \mathbf{a}, s') \sim D} \left[\underbrace{\left(Q(s, \mathbf{a}) - (r(s, \mathbf{a}) + \gamma E_\pi[Q(s', \mathbf{a}')]) \right)^2}_{\text{standard critic update}} \right] + \underbrace{\alpha E_{s \sim D, \mathbf{a} \sim \mu(\cdot|s)}[Q(s, \mathbf{a})]}_{\text{push down on large Q-values}} - \underbrace{\alpha E_{(s, \mathbf{a}) \sim D}[Q(s, \mathbf{a})]}_{\text{push up on Q-values for } (s, \mathbf{a}) \text{ in the data}}$$

No longer guaranteed that $\hat{Q}^\pi \leq Q^\pi$ for all $(s, \mathbf{a})$.

BUT, guaranteed that $E_{\pi(\mathbf{a}|s)}[\hat{Q}^\pi(s, \mathbf{a})] \leq E_{\pi(\mathbf{a}|s)}[Q^\pi(s, \mathbf{a})]$ for all $s \in D$.

Conservative Q-learning (CQL)

Slide adapted from Sergey Levine

26

图 4: CQL 的核心目标：压低高估的 OOD Q 值，同时保留数据支持内动作的相对高值。

4.2 CQL 的目标函数怎样理解

概念上可以写成

$$\mathcal{L}_{\text{CQL}} = \mathcal{L}_{\text{critic}} + \alpha \left(\mathbb{E}_{s \sim D, \mathbf{a} \sim \mu(\cdot|s)}[Q(s, \mathbf{a})] - \mathbb{E}_{(s, \mathbf{a}) \sim D}[Q(s, \mathbf{a})] \right).$$

这里第一项是普通 TD 训练；第二项则体现“悲观性”。如果某个动作不在数据支持中、却被 Q 函数赋了很高分，那么它会在第一项里缺乏监督，在第二项里却被主动压低。这样训练出来的 critic 不是追求全局精确，而是追求对训练分布附近更可靠、对分布外更保守。

讲者还提到，若进一步给 μ 加熵正则，可以得到一个与 $\log \sum \exp Q(s, a)$ 有关的闭式形式，于是实践里并不一定要显式维护一个辅助策略 μ 。

4.3 CQL 与 IQL 的分工

从这节课的结尾建议看，IQL 和 CQL 更像是两种偏好不同的设计点。IQL 更强调完全不查询数据外动作，因此天然与“离线预训练再上线微调”的流程兼容。CQL 则在 critic 级别构造保守下界，超参数相对少，概念也更统一，适合希望直接做离线策略学习的情形。

4.4 本章小结

CQL 的关键不是“让策略更胆小”，而是承认数据外估计不可置信，因此在目标函数里显式植入悲观性。它用较小的估计偏差换取更可靠的策略改进。


5 应用案例与实践选择

5.1 LinkedIn 通知优化案例

这节课给了一个很好的工业例子：用离线 RL 学习“什么时候给用户发送通知”。这个任务和机器人控制不一样，但结构几乎完全一致。系统需要在多目标之间折中：希望通知被点击、希望用户活跃，但又不想发送太多通知而造成打扰。

An example application

Optimizing policy for sending notifications to users on LinkedIn



WAU: weekly active users
Volume: total # of notifications

CTR: click-through-rate
of notifications

Metric	DDQN vs. Baseline	DDQN + CQL vs. Baseline
Sessions	not stat sig	+ 0.24%
WAU	-0.69%	+ 0.18%
Volume	+7.72%	-1.73%
CTR	-7.79%	+2.26%

Table 1: Online A/B test results for DDQN with and without CQL

Prabhakar, Yuan, Yang, Sun, Muralidharan. Multi-Objective Optimization of Notifications Using Offline RL. '22

31

图 5: LinkedIn 通知投放的离线 RL 应用：策略学习、批量训练与线上 A/B 测试结合。

课上的结论是，把 CQL 项加到 DDQN 之类的离线训练流程中，能够在真实线上实验中提升点击率，同时减少总通知量，并略微提高周活用户。这说明“保守外推”并不只是一种理论修补，而是真能在高风险业务里提供可用收益。

5.2 算法选型建议

讲者最后给了一个很实用的经验总结：

- 如果只是想先安全地利用离线数据，一个简单起点是 filtered behavior cloning。
- 如果希望在纯离线 setting 中利用回报、又不显式跑出数据支持，IQL 是很强的默认选择。
- 如果希望通过 critic 直接控制 OOD 过估计，且能接受悲观正则带来的偏差，CQL 是更自然的方案。
- 如果最终目标是“离线预训练 + 在线微调”，IQL 往往更有吸引力，因为它能在离线阶段学到较稳健的初始化。

5.3 本章小结

实践上没有万能算法，只有与你的数据质量、动作空间、是否允许后续在线微调相匹配的设计。课程最后传达的信息很清楚：离线 RL 仍然是活跃研究方向，但 IQL 与 CQL 已经构成了非常强的现代基线。

6 总结与延伸

这讲围绕一个核心矛盾展开：我们希望仅凭历史数据学出比历史行为更好的策略，但一旦离开数据支持，价值估计就会失真。为此，课程给出了两类主流解法。

第一类方法尽量不去碰数据外动作，把离线 RL 重写为“加权模仿 + 价值筛选”的问题。AWR 和 IQL 属于这一类，它们依靠 advantage 或 expectile，把数据中更优的行为提炼出来。第二类方法则承认策略会看向数据外动作，因此用 CQL 之类的悲观目标主动压低 OOD Q 值，避免策略追逐幻觉高分。

从教学线索上看，这节课真正想让学生掌握的并不是某个公式，而是一个判断标准：在不能继续采样时，所有泛化都必须尊重数据支持。谁能在“利用奖励”与“约束外推”之间处理好平衡，谁就更适合离线强化学习。进一步阅读时，可以把 IQL、CQL 以及后续结合 diffusion policy 的 IDQL 一并对照来看，重点关注它们究竟如何处理“只靠静态数据还能改进多少”这个问题。