


课程笔记

CS224R Lecture 8: 奖励学习

五道口纳什 & Codex

2025-04-25



视频作者/频道: Stanford Online

发布日期: 2025-12-08 (YouTube 上传)

视频时长: 1:05:58

视频链接: <https://www.youtube.com/watch?v=PDIXDhA9Z6Y>

目录

1 开场：从离线 RL 过渡到奖励学习	2
1.1 本讲在课程中的位置	2
1.2 为什么本讲必须讨论奖励	2
1.3 本章小结	2
2 任务指定为什么难	3
2.1 手写奖励在真实任务中往往不自然	3
2.2 proxy reward 的价值与风险	3
2.3 本章小结	3
3 从例子中学习奖励：目标分类器	3
3.1 核心思想：把“成功状态”变成分类问题	3
3.2 为什么它比纯模仿更灵活	4
3.3 机器人案例中的实际效果	4
3.4 本章小结	5
4 从人类偏好中学习奖励	5
4.1 为什么偏好比绝对打分更可靠	5
4.2 Bradley-Terry 形式与训练目标	6
4.3 偏好数据为什么仍然很难	7
4.4 本章小结	7
5 面向 LLM 的奖励学习：RLHF 与 RLAI	7
5.1 LLM 场景中的三阶段流程	7
5.2 为什么要加 KL 约束	8
5.3 从人类反馈到 AI 反馈	8
5.4 本章小结	9
6 总结与延伸	9

1 开场：从离线 RL 过渡到奖励学习


1.1 本讲在课程中的位置

这节课前半段先收束上一讲尚未讲完的 conservative offline RL，后半段正式转入 reward learning。这样的安排非常自然，因为前几讲的强化学习算法都默认“奖励函数已经给定”，而现实任务里最难的问题之一恰恰是：奖励往往并不直接存在。

讲者先快速回顾离线 RL 的关键矛盾：离线数据来自行为策略 π_β ，当前优化的策略 π_θ 一旦偏离数据支持，就会在 critic 上产生分布外查询和过估计。CQL 的做法是把这类高估的 OOD Q 值系统性压低，从而在没有在线采样的情况下仍保持策略更新稳定。

How to mitigate overestimation in offline RL?

Recall: Randomly init. Q -function for state $\mathbf{s}'$



Can we discourage overestimation?
while still estimating value of the learned policy

What if we just push down on large Q-values?

$$\hat{Q}^\pi = \arg \min_Q \max_{\mu} E_{(\mathbf{s}, \mathbf{a}, \mathbf{s}') \sim D} \left[\underbrace{\left(Q(\mathbf{s}, \mathbf{a}) - (r(\mathbf{s}, \mathbf{a}) + \gamma E_{\mathbf{a}' \sim \pi} [Q(\mathbf{s}', \mathbf{a}')]) \right)^2}_{\text{standard critic update}} \right] + \underbrace{\alpha E_{\mathbf{s} \sim D, \mathbf{a} \sim \mu(\cdot|\mathbf{s})} [Q(\mathbf{s}, \mathbf{a})]}_{\text{push down on large Q-values}}$$

Can show that $\hat{Q}^\pi \leq Q^\pi$ for large enough α

Slide adapted from Sergey Levine

5

图 1: CQL 回顾：在标准 critic 更新之外，再显式压低数据支持外的大 Q 值。

1.2 为什么本讲必须讨论奖励

把 offline RL 讲清楚之后，课程立刻追问更底层的问题：即使算法稳定了，奖励从哪里来？在 Atari 这类游戏环境里，得分可以直接当 reward；但机器人倒水、自动驾驶、对话系统、推荐系统都没有这种天然的标量反馈。很多真实任务甚至连“成功”都很难用一条手写规则完整刻画。

因此，reward learning 的目标并不是发明一个更复杂的 RL 算法，而是把人类的目标、偏好或示例转换成可以供 RL 使用的监督信号。

1.3 本章小结

离线 RL 解决的是“已有数据时如何安全优化策略”，奖励学习解决的是“根本没有现成奖励时如何定义目标”。两者在现代应用里经常一起出现。

2 任务指定为什么难

2.1 手写奖励在真实任务中往往不自然

讲者用了几个例子来说明奖励指定的困难。机器人把水从壶里倒进杯子，看上去是个简单任务，但真要手工写奖励，就得同时判断水是否进杯、是否洒出、姿态是否平稳、过程是否安全。自动驾驶更复杂，因为舒适性、规则遵守、安全性和效率都需要被同时考虑。聊天机器人也一样，用户不会在每句回复后直接给出一个准确的标量奖励。

这意味着“真实目标”与“可计算奖励”之间通常存在巨大的建模缺口。工程上当然可以设计 proxy reward，例如点击率、成功率、是否完成目标等，但 proxy 往往只是目标的近似，而不是目标本身。

2.2 proxy reward 的价值与风险

proxy 的优点是便宜、可批量采集、能直接进入优化回路；缺点则是容易把系统推向代理指标而非真实目标。比如点击率高并不等价于用户长期满意；某种机器人中间状态得分高，也不一定说明任务真正完成。reward learning 的出发点，正是希望利用更贴近人类意图的监督方式来替代这些粗糙代理。

为什么“奖励黑客”总会出现

只要训练目标是某个可计算 proxy，而 proxy 又没有完全表达真实偏好，策略就会寻找 proxy 的漏洞。reward learning 的意义并不是彻底消灭这一点，而是尽可能让监督信号更靠近人类真正关心的东西。

2.3 本章小结

任务指定困难的根源在于：真实目标往往是语义性的、组合性的、依赖上下文的，而传统 reward 必须是即时、可计算、数值化的。两者之间天然存在表达鸿沟。

3 从例子中学习奖励：目标分类器

3.1 核心思想：把“成功状态”变成分类问题

课程给出的第一类方案是 goal classifier。它不要求人类为每一步动作打分，而是只需要提供成功状态与失败状态的示例。然后训练一个二分类器判断当前状态是否属于目标集合 G ，再把分类器输出作为奖励信号喂给 RL。

Goal classifiers

Key idea: Learn to discern goal states from other states

Example task: put pencil case behind notebook


Positive examples



Negative examples



Trained binary classifier



Use output as reward signal.

1. Collect examples of **successful** & **unsuccessful** states
(states inside and outside of goal set G)
2. Train binary classifier
(with inputs s_i and labels $1(s_i \in G)$)
3. Run RL with classifier as reward.

15

图 2: 目标分类器: 先收集成功/失败状态, 再把分类概率当作 reward。

这种做法的优点是监督形式很自然。很多视觉任务里, 人类虽然很难写出明确 reward, 但很容易指出“这张图像是目标状态”或“这不是”。于是 reward learning 被重写成了监督学习。

3.2 为什么它比纯模仿更灵活

如果只有 demonstrations, 最直接的做法是行为克隆; 但行为克隆会强行复制整条轨迹, 无法区分“为了到达目标, 可以有哪些不同路径”。目标分类器则只关心哪些状态是好的, 因此能给 RL 留出探索与组合的空间。策略未必要复制示范动作, 只要能走到被分类器判为成功的状态即可。

3.3 机器人案例中的实际效果

课上用机器人操作举了一个很具体的例子: 收集几十条 demonstration, 把最终状态当作 success examples, 再用这些终态初始化 replay buffer、训练 goal classifier, 并让 RL 利用该分类器继续优化。结果是, 直接模仿 demonstrations 的成功率明显低于“用学习到的分类器做奖励再训练”的方法。


Goal classifiers for robotic reinforcement learning

Collect 50 demonstrations:

- use final states as **success state examples**
- initialize RL replay buffer with demos


Important to regularize
the classifier!

Directly imitating demos:



26% success rate

RL policy trained with learned classifier:



62% success rate

Sharma, Ahmed, Ahmad, Finn. Self-Improving Robots: End-to-End Autonomous Visuomotor Reinforcement Learning. '23

图 3: 机器人案例: 使用学习到的 goal classifier 作为奖励, 可显著优于直接模仿示范。

讲者特别提醒必须对分类器做 regularization。原因很简单: 一旦分类器在狭窄的数据分布上过拟合, RL policy 就会专门去找它的判别漏洞, 而不是学会真正完成任务。

目标分类器方法的边界

这类方法最适合“成功状态可以被视觉上或语义上明确识别”的任务; 如果任务质量更多取决于轨迹过程、交互风格或隐含偏好, 而不是终态本身, 就需要更强的监督形式。

3.4 本章小结

目标分类器把 reward learning 转化为“成功状态识别”。它降低了标注成本, 也比纯模仿更能利用 RL 的搜索能力, 但前提是终态能够稳定表达任务目标。

4 从人类偏好中学习奖励

4.1 为什么偏好比绝对打分更可靠

当任务结果难以用二值成功定义时, 人类仍然常常能回答一个更简单的问题: 两个轨迹里, 哪个更好? 讲者指出, 人类给绝对分数往往噪声更大、刻度也不稳定; 但做 pairwise comparison 往往更一致。因此 reward learning 的另一条主线是: 让人类比较两段 rollout 或两个结果, 然后从偏好数据反推出奖励函数。

How to learn a reward function from human preferences?

Human says τ_w is better than τ_l . (can write it as $\tau_w \succ \tau_l$)

Note: τ could be a *full* or *partial* roll-out!

We want a reward r_θ such that $\sum_{(s,a) \in \tau_w} r_\theta(s,a) > \sum_{(s,a) \in \tau_l} r_\theta(s,a)$.

$\underbrace{\hspace{10em}}$
shorthand $r_\theta(\tau_w)$

Humans are classifying which trajectory is better.

Reward should be discriminative as well.

24

图 4: 偏好学习的核心设定: 如果人类认为 $\tau_w \succ \tau_l$, 奖励模型就应使优胜轨迹的累计奖励更高。

如果记轨迹偏好为 $\tau_w \succ \tau_l$, 可以要求学习到的奖励满足

$$\sum_{(s,a) \in \tau_w} r_\theta(s,a) > \sum_{(s,a) \in \tau_l} r_\theta(s,a).$$

这并不意味着要恢复“真实奖励”的绝对值, 而只要求奖励在排序意义上与人类偏好一致。

4.2 Bradley-Terry 形式与训练目标

课程进一步把轨迹累计奖励差映射成偏好概率:

$$P(\tau_w \succ \tau_l) = \sigma(r_\theta(\tau_w) - r_\theta(\tau_l)),$$

其中 $\sigma(\cdot)$ 是 sigmoid。于是就可以得到对数似然目标:

$$\max_{\theta} \mathbb{E}_{(\tau_w, \tau_l)} [\log \sigma(r_\theta(\tau_w) - r_\theta(\tau_l))].$$

How to learn a reward function from human preferences?

Human says τ_w is better than τ_l . (can write it as $\tau_w > \tau_l$)

Note: τ could be a *full* or *partial* roll-out!

We want a reward r_θ such that $\sum_{(s,a) \in \tau_w} r_\theta(s,a) > \sum_{(s,a) \in \tau_l} r_\theta(s,a)$.

$\underbrace{\hspace{10em}}$
shorthand $r_\theta(\tau_w)$

We can define $\sigma(r_\theta(\tau_a) - r_\theta(\tau_b))$ to be the estimated probability that $\tau_a > \tau_b$.

Then, we can maximize log probability: $\max_{\theta} \mathbb{E}_{\tau_w, \tau_l} [\log \sigma(r_\theta(\tau_w) - r_\theta(\tau_l))]$

25

图 5: Bradley-Terry 风格的偏好建模：只拟合轨迹优劣差，而不需要绝对奖励标尺。

这里最重要的思想是：人类没有直接告诉模型“这条轨迹的 reward 是多少”，而只是告诉模型“哪条更好”。所以 reward model 真正在做的是一个排序兼容的标量刻画。

4.3 偏好数据为什么仍然很难

讲者专门强调了偏好学习并不干净。人类偏好可能噪声大、前后不一致，甚至不满足传递性：有时会出现 $A \succ B$ 、 $B \succ C$ 、但又 $C \succ A$ 的情况。即便如此，这种噪声监督仍然足以带来可观提升。换句话说，reward learning 依赖的不是完美标签，而是足够有信息量的比较信号。

4.4 本章小结

偏好学习把“写 reward”替换成“做人类比较”。它非常适合没有唯一标准答案、但人类能辨别优劣的任务，也是后面 RLHF 与 DPO 的基础。

5 面向 LLM 的奖励学习：RLHF 与 RLAIIF

5.1 LLM 场景中的三阶段流程

进入大模型场景后，讲者把流程组织成经典三步：先做大规模预训练，再做 supervised fine-tuning (SFT)，最后基于偏好数据训练 reward model，并用 RL 去最大化这个奖励。

Learning rewards from human feedback for LLMs




图 6: LLM 奖励学习的典型流程：预训练，SFT，再用偏好数据训练 reward model 并做 RL 优化。

对于 prompt x 和模型输出 y , reward model 学习一个标量 $r(x, y)$, 用来判断回答对这个 prompt 有多好。随后优化目标可以写成

$$\mathbb{E}_{\hat{y} \sim p_{\theta}(\cdot|x)}[R(x, \hat{y})].$$

而 RL 之所以需要出现，是因为语言模型输出的是离散 token 序列，即使 reward model 本身可微，也无法直接把梯度穿过离散采样步骤稳定地反传回生成模型。

5.2 为什么要加 KL 约束

讲者还解释了 RLHF 实践里非常关键的一点：reward model 并不完美，如果直接朴素地最大化 learned reward，策略会开始 exploit reward model 的漏洞。因此通常要在目标中加入对初始模型的 KL penalty，使优化后的策略不要偏离 SFT 模型太远。这等价于告诉系统：可以朝着更受偏好的方向改，但不要把语言模型带离原有分布太远。

5.3 从人类反馈到 AI 反馈


除了直接让人类比较回复，课上还提到 RLAI (Reinforcement Learning from AI Feedback) 或 constitutional RL 的方向：让另一个语言模型执行批判与偏好判断。其直觉是“critique 往往比 generation 更容易”，因此在大规模系统中，用 AI 监督 AI 能显著降低人工标注成本。

Learning rewards from human AI feedback

Reinforcement learning with AI feedback (RLAIF)

Ask another language model “which of these responses is less harmful?”

Key insight: critique is easier than generation!



Bai et al. Constitutional AI: Harmlessness from AI Feedback. 2022.

图 7: RLAIF/Constitutional RL: 让模型先学会批判, 再把这种批判转化为偏好监督。

5.4 本章小结

在 LLM 场景里, reward learning 不再只是给机器人一个标量, 而是在 prompt-response 层面拟合“人类更喜欢哪种回答”。RLHF 的关键贡献, 是把这种偏好信号转化成可优化的后训练目标。

6 总结与延伸

这节课把 reward learning 按监督强度从弱到强排出了一条清晰路线。最弱的是手写 proxy reward, 它便宜但容易错位; 再往上是 goal classifier, 它要求人类指出成功状态; 再往上是 preference learning, 它直接让人类在候选结果中做比较; 在大模型领域, 这条线最终延伸成 RLHF 与 RLAIF。

如果把课程主旨压缩成一句话, 那就是: 很多时候, 强化学习真正困难的并不是“如何优化奖励”, 而是“如何得到一个足够贴近人类意图的奖励”。reward learning 给出的答案不是单一算法, 而是一组将人类监督转写为 reward 的方法论。

从进一步学习的角度, 本讲之后最值得继续追踪的有三类问题。第一, 如何降低偏好数据成本, 同时处理噪声与不一致性; 第二, 如何避免 reward hacking, 让 learned reward 在分布外仍然稳健; 第三, 如何把 reward learning 与更大规模的语言模型后训练结合起来。后面的 RLHF、DPO、constitutional AI 等方法, 都是沿着这三条线继续展开的。