

课程笔记

CS224R 课程笔记: Lecture 18 Frontiers

Codex

2026-04-13



视频作者/频道: Stanford Online

发布日期: 讲次日期 2025-05-30; YouTube 上传 2025-12-08

视频时长: 1:10:49

视频链接: https://www.youtube.com/watch?v=FacJ_1tTSx4

目录

1 前沿问题之一：没有清晰奖励、也没有可靠验证的领域	2
1.1 为什么这是 RL 的根问题	2
1.2 本章小结	3
2 前沿问题之二：如何利用先验数据、知识与 world models	3
2.1 先验并不总该以预训练权重的形式进入 RL	3
2.2 视频生成模型会成为 RL 的 world model 吗	3
2.3 本章小结	4
3 前沿问题之三：如何规模化、如何安全部署、如何评价 generalist systems	4
3.1 规模化 RL 目前仍偏短视与高在线成本	4
3.2 安全与 hallucination 不是附加要求，而是部署核心	4
3.3 评价 generalist systems 比评价单任务 agent 更难	5
3.4 本章小结	5
4 如何做深度 RL 研究：从选题、转向到分享结果	5
4.1 研究不是寻找完美点子，而是管理高失败率	5
4.2 problem-driven 与 idea-driven 可以并存	6
4.3 何时 pivot：比大多数人更早承认当前路径不对	6
4.4 分享研究不是附属劳动，而是研究产出本身	7
4.5 本章小结	7
5 总结与延伸	7

1 前沿问题之一：没有清晰奖励、也没有可靠验证的领域

这讲前半部分谈 open problems，后半部分谈如何做研究。前沿问题里，讲者首先挑出的不是优化器或架构，而是 **problem setup**：很多真正重要的场景根本没有现成奖励，也没有可自动验证的正确答案。

Non-rewarding, non-verifiable domains

No problem

Games

Math reasoning

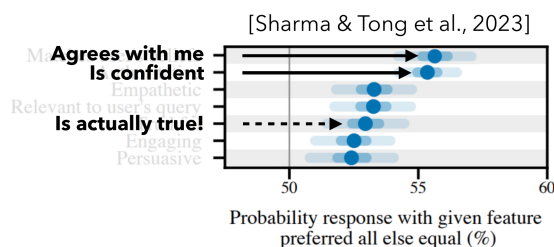
Coding problems

Challenge: rewards don't exist, or very delayed

1. LLMs for chatbots

Right now: preference optimization

"what you want to hear"



People don't actually give good preferences!

Personalization vs. polarization.

Balancing multiple objectives that may compete with each other.

5

5

图 1：“non-rewarding, non-verifiable domains” 的典型例子：聊天机器人、复杂机器人任务、推荐系统与科学推理。

传统游戏、数学标准答案题和编码 benchmark 之所以适合 RL，一个重要原因是“能打分”。但现实系统里，经常不是这样：

- 聊天机器人很难用单一 reward 概括“真实、有用、不迎合”的回答；
- 机器人很多任务只有粗糙的二值成功信号，或者手工 shaping reward；
- 推荐系统的点击、停留时长、点赞本身都只是 proxy，而且这些 proxy 的权重往往靠人为调参；
- 科学实验、长链推理和开放式学习常常根本不存在立即可验证的终点。

讲者对 preference optimization 的批评非常到位：偏好反馈并不天然等于真实目标，尤其当“用户更喜欢的回答”与“事实更正确的回答”不一致时，系统容易被推向迎合、自信、极化而不一定更真实。

1.1 为什么这是 RL 的根问题

如果 reward 本身不可靠，那么再高效的策略优化也可能只是把代理目标优化得更彻底。换句话说，前沿系统的瓶颈往往不是“算法没学好”，而是“目标没定义好”。

1.2 本章小结

本讲最先指出的 open problem 并不是更深的 network，而是更难的目标定义问题。很多现实场景并非 reward 缺失，而是 reward 只是偏置很强的近似量。

2 前沿问题之二：如何利用先验数据、知识与 world models

2.1 先验并不总该以预训练权重的形式进入 RL

默认做法通常是：用预训练权重初始化模型，再用离线数据初始化 replay buffer。讲者认为这只是“最容易想到”的方法，而不是唯一合理的方法。更抽象的先验，比如规则、提示、新闻、外部知识、历史经验，有可能比权重或数据集本身更值得利用。

更关键的是，预训练有时还可能过于约束优化。讲者提到一个经验现象：某些工作里，只初始化 buffer、但不初始化 policy 权重，反而比把权重也预训练后再微调效果更好。一个合理解释是，预训练输出层可能过早收敛到狭窄、确定性的模式，从而抑制探索。

2.2 视频生成模型会成为 RL 的 world model 吗

接着，讲者把话题转向视频生成模型与 world models。直觉上，这些模型显然蕴含丰富世界知识，因此理应有助于 RL；但真正把它们用起来并不简单。

How to leverage video gen models?

Rich world knowledge. They **should** be useful.

But there are large, nuanced challenges!

Example: Train $s_t, a_{t:t+h} \rightarrow s_{t+1:t+h}$ on demos + one policy's roll-outs

Evaluate if new policy's actions $\tilde{a}_{t:t+h}$ lead to good outcomes

These will be out of distribution!

+ Small physical inaccuracies lead to poor performance!

Possible solution 1: Train on data from more policies?

Possible solution 2: Use the model in other ways?

e.g. train $s_t \rightarrow s_{t+1:t+h}$ on only demos
predict future video + run goal-conditioned policy



Source: <https://deepmind.google/models/veo/>

图 2: 视频生成 world model 的机会与风险：模型有丰富世界知识，但 policy 诱导的动作分布可能把未来视频推到分布外。

难点至少有两个。第一，action-conditioned future prediction 在 policy 改变后很容易 OOD，因为新策略采样的动作序列并不一定出现在训练数据里。第二，视频看起来逼真，不代表其物理细节足够精确；对控制来说，细微误差可能就会造成灾难性后果。

因此讲者提出的思路更克制：与其直接把视频模型拿来闭环控制，不如先把它用在更安全的位置，例如只用 demonstrations 训练未来视频，再把预测结果交给 goal-conditioned policy。

2.3 本章小结

这一部分的主旨是：先验和 world model 很重要，但它们不能只靠“规模更大”就自动转化成更好的 RL。如何既继承预训练知识、又不被它束缚，是一个核心前沿问题。

3 前沿问题之三：如何规模化、如何安全部署、如何评价 generalist systems

3.1 规模化 RL 目前仍偏短视与高在线成本

讲者指出，今天大规模 RL 在 LLM 上很热，但大多仍属于较短时程、较强在线采样依赖的范式。比如偏好优化经常只看单轮回复，不看整段对话的全局结果；推理 RL 则常常需要海量在线 rollout 穿插参数更新。

How to scale up?

Large scale RL for LLMs is exciting! Yet, currently fairly short-horizon or very online.

Can we do large-scale RL with longer horizons & with less online data?

1. Can we train & use accurate value functions at scale?

Algorithms like PPO only use value functions for reducing gradient variance, may not be accurate enough for actor-critic algorithms

2. Can we enable large-scale “batch online” RL?

Hard to interleave model updates & data collection in many applications, esp for large models!
(e.g. when collecting dialog with real users, when collecting data on real robots)

More practical: few iterations of
[collect large batch of data, update model]
(possibly asynchronously!)

New considerations, e.g. expressive policies for enough data breadth

15




图 3: 规模化 RL 的核心问题：能否支持更长 horizon、更少在线数据、更准确 value function，以及更适合大模型的数据更新节奏。

这里的几个关键疑问包括：

- value function 能否在大规模系统里真正训练得足够准确；
- 能否做 “batch online RL”，即收集一大批数据后再更新，而不是高度交错地在线更新；
- expressive policies 是否会比传统高斯策略更适合支撑大规模探索。

3.2 安全与 hallucination 不是附加要求，而是部署核心

在部署部分，讲者明确表示：对大规模模型而言，安全是 open-world problem，几乎不可能被彻底证明。尤其在机器人和自动驾驶等领域，单次错误就可能造成高代价后果，因此不能满足于“平均表现不错”。

与安全相关但稍弱的一层问题是 inaccuracies / hallucinations。模型即使不在安全关键场景里，也会给出自信但错误的结论。讲者用视觉读数错误、错误解释图像等例子提醒大家：高置信输出并不意味着高可信输出。

3.3 评价 generalist systems 比评价单任务 agent 更难

如果系统越来越 generalist，评价方式也必须变化。单一 benchmark 上测 reward 已经不够，因为不同任务之间的 trade-off、泛化能力、任务切换能力和开放环境鲁棒性都需要新的评估设计。

3.4 本章小结

规模化、安全与评价三个问题彼此相连。系统越大、越通用，越不能只看一个平均 reward。需要同时考虑长时程优化、部署风险和跨任务评估。

4 如何做深度 RL 研究：从选题、转向到分享结果

4.1 研究不是寻找完美点子，而是管理高失败率

讲者后半部分从 personal backstory 切入，强调研究最常见的现实是：绝大多数想法都不会成功。研究之所以有价值，恰恰因为没有人知道哪条路会通。

What to work on

Step 1: Need two things: (1) an important problem (2) a plan for how to approach it

Examples: Solve climate change	<- I'm missing (2)
A really cool algorithm that will make the robot 1% more successful	<- I'm missing (1)

What will the outcome look like if you are very successful?

34

图 4: 选题标准的压缩表达：好项目至少同时满足“重要问题”和“可行推进路径”。

讲者给出一个非常实用的选题判据：一个研究项目至少需要两样东西，

1. 它要解决的重要问题；
2. 它要有一个你知道如何切入的计划。

只有大问题没有路径，会沦为空想；只有小改进没有问题意识，则很难形成有力度的研究。

4.2 problem-driven 与 idea-driven 可以并存

讲者并不主张只从 idea 出发或只从 problem 出发，而是强调两者都能成功。problem-driven research 往往更容易对齐长期价值，idea-driven research 则可能在方法上更灵活。真正重要的是，研究过程中要不断检查：当前工作是否仍然朝着高价值目标推进。

4.3 何时 pivot：比大多数人更早承认当前路径不对

Deciding when to pivot

Often considered later than it should be considered!

“sunk cost fallacy”

Formulating the decision:

~~“continue working on current project” vs. “switch to starting a new project”~~

This is a super nebulous thing!

“continue working on current project” vs. “work on project B” vs. “work on project C” vs. ...

This decision is a lot more straightforward,
less anxiety inducing! 🥳

Advice: spend time thinking
about other research projects!

44

图 5: 关于转向的建议：不要只问“是否继续当前项目”，而要把多个候选方向一起放进决策面。

这一页给出极其实用的建议。与其把问题表述成“坚持还是放弃当前项目”，不如把它写成“项目 A、B、C 哪个更值得投入”。一旦视野扩大，很多被 sunk cost 绑架的犹豫就会明显缓解。

4.4 分享研究不是附属劳动，而是研究产出本身

How to share your research

Why?

What is the **output** of research? Ideas, knowledge, learnings.

Almost always **not**: product, service

If no one knows about the learnings, then there was no output!!

(+ even companies have massive marketing efforts!)

But it feels like self promotion! :(You are teaching people and sharing cool findings

But it didn't work *that well*. Still very useful, since other people may think of the idea!

But it's all obvious to me now. After enough research, you will know far more than others!

46

图 6: 分享研究成果的理由：研究的输出是 ideas、knowledge 与 learnings；如果没人知道，就等于没有真正输出。

讲者最后把“如何分享研究”提到很高的位置。研究输出常常不是产品，而是 ideas、knowledge、learnings。如果没有论文、报告、海报和清晰讲述，这些输出就无法进入共同体，影响也会大打折扣。

这部分给学生最重要的信号

不要把研究看成“想出天才点子然后一击命中”。更真实的过程是：选高价值问题，容忍失败，及时 pivot，并认真把所得经验传播出去。

4.5 本章小结

后半部分提供的是研究方法论而不是技术公式：选题要同时看问题重要性和切入路径，过程里要能承受高失败率，必要时及时转向，而传播结果本身就是研究工作的一部分。

5 总结与延伸

Lecture 18 有两个看似分开的主题，但实际上高度统一。前半部分讨论的是 RL 还没解决好的前沿难题：奖励难定义、先验难利用、world model 难落地、规模化难兼顾长时程与低在线成本、安全与评价标准都还远未成熟。后半部分讨论的是，面对这样一片未定型的问题空间，研究者应当如何行动。

把两部分连起来，可以得到一个非常强的结论：**前沿研究的难点，不只是把某个 loss 再调高一点，而是先认清什么问题真正值得解决，以及现有工具为什么还不够。**

对学习这门课的人来说，这讲至少留下三条长期线索：

- 任何成功的 RL 系统，最终都要面对 reward misspecification。

- foundation models 与 RL 的结合值得期待，但不能忽视分布外与物理精度问题。
- 做研究需要同时管理价值判断、方法设计、实验执行和结果传播。

因此，这讲既是课程的 frontier survey，也是一次研究训练。它提醒我们：真正值得做的工作，往往处在 reward 不清、验证困难、方法尚不成熟的灰区里。