


课程笔记

CS231N 2025 第 2 讲：线性分类与图像分类基础

Codex Harness Worker 1

2026-04-15



视频作者/频道：Stanford Online

发布日期：2025-09-02

视频时长：1:07:01

视频链接：<https://www.youtube.com/watch?v=pdqofxJeBN8>

目录


1 图像分类：从像素到语义	2
1.1 本章小结	2
2 数据驱动范式：训练集、验证集与测试集	2
2.1 本章小结	3
3 kNN：从记忆训练集到投票决策	3
3.1 本章小结	4
4 线性分类器的三种视角	4
4.1 本章小结	5
5 损失函数：Softmax 与 SVM	5
5.1 本章小结	6
6 从线性模型走向神经网络	6
6.1 本章小结	6
7 总结与延伸	6
7.1 拓展阅读	7

1 图像分类：从像素到语义

图像分类 (image classification) 的定义看起来简单：输入一张图像，输出一个来自固定类别集合的标签。但这一任务之所以值得放在整门课前面，是因为它把视觉建模中最核心的困难压缩到了最小形式。对计算机来说，图像只是一个三维张量；对人来说，图像却天然携带对象、场景、属性与上下文含义。如何从像素数组走到语义标签，这就是所谓语义鸿沟 (semantic gap)。

讲者反复强调，后续的目标检测、图像分割、视频理解乃至视觉语言，并不是和分类完全无关的新问题，而是在分类的基础上继续追问“对象在哪里”“边界是什么”“时间上如何变化”“语言如何对齐”等结构。因此，把分类任务真正学透，等于为后面一整个视觉课程打地基。

The Problem: Semantic Gap



11805	112	180	111	184	99	186	99	96	183	112	119	184	97	93	871	
1	92	98	182	186	184	79	98	183	99	183	123	136	128	185	881	
1	76	85	98	185	128	185	87	86	95	99	115	112	186	183	99	851
1	99	81	81	93	128	131	127	189	95	88	182	99	96	93	181	841
1	186	91	61	64	69	91	88	85	181	187	189	98	75	84	96	951
1	114	188	85	55	55	69	64	54	64	87	112	129	98	74	84	951
1	133	137	147	183	65	81	88	65	54	74	84	182	93	85	851	
1	128	137	144	148	189	95	86	78	62	65	63	63	68	73	86	1811
1	125	133	148	137	119	121	117	94	65	79	68	65	54	64	72	1881
1	127	125	135	147	133	127	126	131	111	96	89	75	61	64	72	841
1	115	114	189	123	158	148	131	118	113	189	188	92	74	65	72	781
1	88	93	98	97	188	147	131	118	113	114	113	189	186	95	77	8891
1	63	77	86	81	77	79	182	123	117	115	117	125	125	138	135	871
1	62	65	82	78	71	88	181	124	126	119	181	187	114	131	118	1181
1	63	65	75	88	89	71	62	81	128	138	135	185	81	98	138	1181
1	87	65	71	87	186	95	69	45	76	138	126	187	92	84	185	1121
1	118	97	82	86	117	123	116	66	41	51	95	89	89	95	182	1871
1	164	146	112	88	82	128	124	184	78	48	65	88	181	182	188	181
1	157	178	137	128	93	86	114	132	112	97	89	55	78	82	99	841
1	138	128	134	181	139	189	189	118	121	134	114	87	65	53	69	861
1	128	112	96	117	158	144	128	115	184	187	182	93	87	81	72	781
1	123	187	98	86	83	112	153	149	122	189	184	75	88	187	112	991
1	122	121	182	88	67	86	94	117	145	145	113	182	58	78	92	1871
1	122	164	148	183	71	56	78	83	93	183	119	139	182	61	69	8411

What the computer sees

An image is a tensor of integers
between [0, 255]:

e.g. 800 x 600 x 3
(3 channels RGB)

图 1：“语义鸿沟 (semantic gap)” 示意：人看到的是物体与场景，计算机看到的是像素张量。图像分类的全部建模工作，本质上都在弥合这一鸿沟。

教材化理解

把图像分类当成一个完整系统，而不是一个 benchmark。它至少包含五个组件：输入表示、训练数据、打分函数、损失函数和评估协议。后面所有深模型都只是把这些组件做得更强、更复杂，而不是抛弃这套框架。

图像分类是视觉中的基础任务，因为它把表示、决策与泛化问题压缩到了最小形式。语义鸿沟提醒我们：视觉模型必须学到比像素更抽象的中间表示。

1.1 本章小结

2 数据驱动范式：训练集、验证集与测试集

这一讲的第一个方法论转折，是从“手写规则”转向“数据驱动 (data-driven)”。如果视觉世界中的变化来自视角、光照、遮挡、背景、类内形变与上下文，那么与其为每种变化单独写规则，不如让模型直接从带标签数据中学习哪些变化是重要的、哪些变化应该被忽略。

这就引出标准的监督学习设置：给定训练集学习参数，使用验证集选择超参数（hyperparameters），最后只在测试集上报告一次最终性能。这里验证集的角色尤其关键，因为很多初学者会不自觉地用测试集反复调参，最终得到被“测试集信息泄漏”污染的结果。课程在这里的态度非常明确：验证集用来做选择，测试集用来做最后的外部评估。

从工程角度看，这对应三层完全不同的问题：训练集解决“能否拟合”；验证集解决“该选哪个 K 、哪种正则化、什么学习率”；测试集解决“这个模型是否真的能泛化到未见数据”。如果三者混用，那么你看到的不是模型能力，而是评估协议的错误。

数据驱动方法的核心不是“有数据就行”，而是配套的训练/验证/测试协议。验证集负责超参数选择，测试集必须保留为一次性最终评估。

2.1 本章小结

3 kNN：从记忆训练集到投票决策

最直接的数据驱动分类器是最近邻（Nearest Neighbor）与 k 近邻（ k -Nearest Neighbors, kNN ）。它不学习显式参数，而是把训练集整个记住：测试时先计算测试图像与每个训练样本的距离，再把最近的一个或若干个样本的标签作为预测结果。

如果使用 L_1 或 L_2 距离，最简单的分类规则可以写成

$$\hat{y} = y_{\arg \min_i d(x, x_i)}, \quad d_{L_1}(x, x_i) = \sum_j |x_j - x_{i,j}|, \quad d_{L_2}(x, x_i) = \sqrt{\sum_j (x_j - x_{i,j})^2}.$$

其中， x 是测试图像的像素向量， x_i 是第 i 个训练样本， $d(\cdot, \cdot)$ 是距离函数， $\hat{y}$ 是最终预测标签。符号解释非常重要：它说明 kNN 的“模型”并不在参数里，而是在训练样本与距离度量共同定义的邻域结构里。

K-Nearest Neighbors

Instead of copying label from nearest neighbor,
take majority vote from K closest points




图 2: 不同 K 值下 kNN 决策边界的变化。它说明惰性学习方法靠“邻居结构”工作，模型复杂度主要体现在存储与检索，而不是显式参数。

这种方法的优点是零训练成本、概念直观；缺点也同样明显：需要存储整个训练集，推理时需要与所有样本比较，并且在高维像素空间里距离常常不再可靠。 K 太小，边界极其锯齿化，容易过

拟合； K 太大，边界又会被过度平滑。因此 kNN 更像一个帮助我们理解“什么叫数据驱动分类”的教学基线，而不是现代视觉系统的终点。

kNN 通过“距离 + 投票”完成分类，但它把复杂度留给了存储与检索。它教会我们的不是如何构建最强模型，而是什么叫数据驱动决策边界。

3.1 本章小结

4 线性分类器的三种视角

为了摆脱 kNN 的存储和推理负担，我们需要参数化模型 (parametric model)。线性分类器把图像映射到类别分数：

$$f(x, W, b) = Wx + b.$$


其中， $x \in \mathbb{R}^D$ 是展开后的图像向量， $W \in \mathbb{R}^{C \times D}$ 是权重矩阵， $b \in \mathbb{R}^C$ 是偏置， C 为类别数。输出向量中每一维都是一个类别分数 (score)。其中， W 的每一行都可以被看成某一类的线性模板。

讲者要求学生同时从三个角度理解这个式子。第一是代数视角：它只是矩阵乘法。第二是视觉视角：把 W 的每一行重新 reshape 成图像后，会发现模型实际上为每个类别学到了一张模板。第三是几何视角：每个类别之间的比较对应输入空间里的超平面，分类边界是若干超平面的组合。

Hard cases for a linear classifier


Class 1:
First and third quadrants

Class 2:
Second and fourth quadrants



Class 1:
 $1 \leq L2 \text{ norm} \leq 2$

Class 2:
Everything else



Class 1:
Three modes

Class 2:
Everything else




图 3: 把线性分类器权重重新可视化为模板后，可以直观看到每个类别在“喜欢”怎样的像素模式。

这里必须注意，线性分类器的能力与其参数量并不等价。即便参数很多，它依然只能表达线性可分的模式，无法自然捕捉部件组合、层级结构或复杂非线性形变。这正是下一讲神经网络登场的原因。

线性分类器是第一个真正可训练、可部署的参数化分类器。但它的表达能力受限于线性结构，因此只能作为深模型的起点。

4.1 本章小结

5 损失函数：Softmax 与 SVM

有了打分函数之后，还需要一个损失函数（loss function）来回答“当前参数好不好”。本讲重点介绍两类经典选择：Softmax 交叉熵和多类 SVM hinge loss。

Softmax 先把分数变成概率：

$$p(y = c | x) = \frac{e^{s_c}}{\sum_j e^{s_j}}, \quad s = Wx + b.$$

对应的交叉熵损失写成

$$L_i = -\log p(y = y_i | x_i).$$

其中， s_c 是第 c 类分数， $p(y = c | x)$ 是预测概率， y_i 是样本 x_i 的真实标签。这个损失鼓励正确类概率尽可能大，因此它更容易给出“概率化解释”。

Softmax Classifier (Multinomial Logistic Regression)



Want to interpret raw classifier scores as probabilities

$$s = f(x_i; W)$$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax
Function

cat	3.2
car	5.1
frog	-1.7

图 4: Softmax 把原始分数转成归一化概率分布，是从“打分器”走向“概率模型”的关键一步。

多类 SVM 则关心 margin：正确类分数至少要比错误类高一个边际。其常见形式是

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + \Delta).$$

其中， s_{y_i} 是真实类别分数， s_j 是任一错误类别分数， Δ 是期望间隔，通常取 1。如果真实类已经比所有错误类至少高出 Δ ，该样本损失为零。

Reading Assignment – SVM Loss

图 5: 多类 SVM hinge loss 用 margin 约束“正确类比分错类高多少”，强调判别边界而非概率解释。

两者都能训练出有效分类器，但强调点不同：Softmax 更像概率建模，SVM 更像 margin 驱动的判别学习。课程真正要学生掌握的，不是“哪一个永远更好”，而是：损失函数决定了参数更新到底在推动什么样的判别结构。

Softmax 把分数转成概率并最大化正确类对数概率。SVM 强调真实类与错误类之间的 margin。两种损失都在为后续神经网络做准备。

5.1 本章小结

6 从线性模型走向神经网络

把 Lecture 2 当成一章教材来读，最重要的收获不是记住几个公式，而是理解一条技术演化路径：从惰性记忆的 kNN，到显式参数化的线性分类器，再到需要更强表达能力的非线性模型。课程之所以接着讲神经网络，不是因为线性分类器“过时”，而是因为我们已经清楚看见了它的结构性边界。

换句话说，本讲真正完成的是问题设定的搭建：输入是什么，标签是什么，训练协议是什么，损失如何定义，评价如何进行。下一讲开始，课程将把注意力转向如何在保留这些训练协议的同时，大幅增强模型表示能力。

Lecture 2 完成了图像分类问题的最小数学闭环。后续所有深模型都可以被视为在线性分类器基础上的表示能力升级。

6.1 本章小结

7 总结与延伸

这一讲把图像分类从任务定义一路推进到可训练目标函数。我们看到，kNN 提供了最直接的数据驱动基线，线性分类器提供了可学习参数化模型，而 Softmax 与 SVM 则把“什么叫做好模型”具体化为可优化的损失。

从教材视角看, 这一讲最重要的不是某个单独公式, 而是它建立了现代深度学习的统一接口: 输入 x , 参数化打分 $f(x; \theta)$, 损失 L , 训练/验证/测试协议。下一讲关于正则化与优化, 实际上就是在回答: 给定这个接口, 怎样才能把参数学出来, 并且学得稳、学得能泛化。

7.1 拓展阅读

- Image Classification Problem
- Linear Classification