


课程笔记

CS231N 2025 第 5 讲：卷积神经网络与图像分类

Codex Harness Worker 1

2026-04-15



视频作者/频道: Stanford Online

发布日期: 2025-09-02

视频时长: 1:08:04

视频链接: <https://www.youtube.com/watch?v=f3g1zGdxptI>

目录


1	为什么要从全连接走向卷积	2
1.1	本章小结	2
2	卷积网络的历史角色：从 LeNet 到现代视觉	2
2.1	本章小结	3
3	卷积层：局部连接与参数共享	3
3.1	本章小结	4
4	池化、步幅与感受野	4
4.1	本章小结	5
5	卷积网络的典型堆叠方式与视觉表征	5
5.1	本章小结	6
6	总结与延伸	6
6.1	拓展阅读	6

1 为什么要从全连接走向卷积

虽然上一讲的多层感知机已经比线性分类器强得多，但它仍然把图像视为一长串无结构的像素向量。这样做的问题在于：图像具有明显的二维局部性与平移结构，邻近像素通常相关，边缘与纹理会在局部区域中重复出现，而全连接层并不会自动利用这些归纳偏置。

因此，课程在一开始就通过多个例子说明：如果仍然在像素空间里做全连接学习，模型不仅参数巨大，而且对平移、局部扰动和组合结构缺乏天然鲁棒性。卷积神经网络 (CNN) 之所以重要，不是因为它“又深了一些”，而是因为它把图像的空间结构直接编码进了模型架构。

Pixel space



Stanford CS231n 10th Anniversary

Lecture 5 - 20

April 15, 2025

图 1: 像素空间中的线性分类器缺乏对局部结构的归纳偏置，因此面对平移、形变和组合结构时表现脆弱。

全连接网络忽略了图像的二维结构，这会带来参数低效和泛化不足。卷积网络的价值首先来自对视觉输入结构的尊重，而不是单纯参数更多。

1.1 本章小结

2 卷积网络的历史角色：从 LeNet 到现代视觉

课程先用历史回顾提醒读者：CNN 并不是突然出现的。它吸收了生物视觉中的层级感受野直觉，也继承了早期 Neocognitron 和 LeNet 的结构思想。在 ImageNet 时代，AlexNet 把这种结构与大规模数据和 GPU 训练结合起来，才让 CNN 成为计算机视觉的默认主干。

这段历史尤其重要，因为它说明“卷积”并不是一个只服务于某个 benchmark 的技巧，而是一种长期有效的表示假设：低层提取局部边缘与纹理，中层组合成部件，高层形成类别相关的语义激活。即使在 Transformer 盛行之后，卷积关于局部性和层级性的直觉仍然持续影响视觉模型设计。

CNN 的成功既依赖结构设计，也依赖数据、算力和训练机制的成熟。局部到全局的层级表示，是卷积网络最持久的思想遗产。

2.1 本章小结


3 卷积层：局部连接与参数共享

卷积层的核心操作可以写成

$$y_{o,i,j} = b_o + \sum_{c=1}^{C_{in}} \sum_{u=1}^K \sum_{v=1}^K W_{o,c,u,v} x_{c,i+u,j+v}.$$

其中， x 是输入特征图， W 是卷积核权重， b_o 是第 o 个输出通道的偏置， $y_{o,i,j}$ 是第 o 个输出通道在空间位置 (i,j) 的响应。这个公式表达了两件事：卷积核在空间维上滑动，同时对输入的所有通道做加权求和。

Next: Convolutional Neural Networks




Stanford CS231n 10th Anniversary

Lecture 5 - 30

April 15, 2025

图 2: 卷积与池化把“局部特征提取 + 空间下采样”组织成层级表示，是早期深度视觉系统的核心套路。

Convolution Layer



Stanford CS231n 10th Anniversary

Lecture 5 - 50

April 15, 2025

图 3: 卷积核在空间维上滑动、在通道维上全连接，输出是一组激活图。图中把输入体、卷积核和输出体的维度关系画得很清楚。

和全连接层相比，卷积层最大的不同是参数共享 (parameter sharing)：同一个卷积核会被应用到整张图的多个位置，因此模型不需要为每个空间位置单独学习一组权重。这既大幅减少参数量，也自然引入了对平移的等变性 (translation equivariance)。

卷积层通过局部连接降低参数复杂度，通过参数共享提升对重复模式的利用效率。卷积核在整个图像上扫描，形成一组激活图而不是一个单独分数。

3.1 本章小结

4 池化、步幅与感受野

卷积网络不仅要提取局部特征，还要逐步扩大上下文范围并控制空间分辨率。池化 (pooling) 与步幅 (stride) 就是实现这件事的标准工具。它们减少特征图的空间尺寸，提升局部扰动下的稳定性，也让更深层神经元能够“看到”更大输入区域。


课程中一个必须掌握的量是输出尺寸。若输入宽度为 W ，卷积核大小为 F ，填充为 P ，步幅为 S ，则常见输出宽度为

$$W_{\text{out}} = \frac{W - F + 2P}{S} + 1.$$

其中， W_{out} 是输出特征图尺寸。这个公式直接决定了网络每层的空间分辨率，也是检查架构是否可行的基本算术。

Receptive Fields

For convolution with **kernel size K** , each element in the output depends on a $K \times K$ receptive field in the input



Slide inspiration: Justin Johnson

Stanford CS231n 10th Anniversary

Lecture 5 - 80

April 15, 2025

图 4: 感受野 (receptive field) 把“某个高层神经元到底看到了输入的哪一块区域”具体化, 是理解 CNN 层级结构的关键概念。

感受野则回答另一个问题: 某个高层激活到底受原图哪一块区域影响? 随着卷积层、步幅和池化的堆叠, 有效感受野会不断增大。这就是为什么浅层卷积倾向于响应边缘和纹理, 而深层卷积更容易响应部件和对象。


池化与步幅让网络在保持关键信息的同时逐层压缩空间维度。感受野把“层级表示”落成了可计算的空间依赖范围。

4.1 本章小结

5 卷积网络的典型堆叠方式与视觉表征

从系统视角看, 一个典型 CNN 往往由若干重复模块组成: 卷积层提取特征, 激活函数提供非线性, 池化层调整空间尺度, 最后用全连接层或全局池化把高维表示映射到类别空间。课程多次把这种模式画成从输入体到输出体的连续变换。

Hierarchical organization



Stanford CS231n 10th Anniversary

Lecture 5 - 140

April 15, 2025

图 5: 从边缘、纹理到部件再到对象类别的层级组织，说明 CNN 为什么适合视觉感知任务。

Lecture 5 的收束点不是“卷积已经解决了一切”，而是说明卷积网络建立了现代视觉表征的基线。后续无论是更深的 CNN、混合架构还是视觉 Transformer，几乎都在和 CNN 的三个关键问题对话：局部性如何编码？层级表示如何形成？全局上下文如何整合？

CNN 是现代视觉表示学习的起点，而不是终点。后续更强模型往往是在保留卷积核心直觉的同时，引入更强的全局建模能力。

5.1 本章小结

6 总结与延伸

Lecture 5 解释了卷积网络为什么会成为视觉中的基本架构：它把图像的二维结构、局部统计规律和层级组合关系直接写进了模型。通过卷积、池化和感受野这些概念，课程把“为什么视觉需要特殊网络结构”这件事讲得非常清楚。

从教材脉络看，这一讲的地位类似一个桥梁：它把前几讲的优化、损失和反向传播，真正装进了能够处理图像结构的网络中。下一讲转向 CNN 的训练技巧和经典架构时，读者要持续带着一个问题：这些新技巧究竟是在改善优化、增加表达能力，还是改变归纳偏置？

6.1 拓展阅读

- Convolutional Networks