

课程笔记

CS231N 2025 第 6 讲：CNN 训练技巧与经典架构

Codex Harness Worker 1

2026-04-15



视频作者/频道：Stanford Online

发布日期：2025-09-02

视频时长：1:11:07

视频链接：<https://www.youtube.com/watch?v=aVJy405T0k8>

目录

1 训练深 CNN：归一化、激活与初始化	2
1.1 本章小结	2
2 Normalization layer 到底在做什么	2
2.1 本章小结	3
3 训练细节：正则化、数据增强与学习率	3
3.1 本章小结	3
4 架构案例：AlexNet、VGG、ResNet	3
4.1 本章小结	5
5 迁移学习：把预训练网络变成通用视觉骨干	5
5.1 本章小结	6
6 总结与延伸	6
6.1 拓展阅读	6

1 训练深 CNN：归一化、激活与初始化

当卷积网络加深之后，问题不再只是“结构是否合理”，还包括“能否稳定训练”。Lecture 6 一开始就把训练深网络的几个核心组件并列起来：归一化层（normalization layer）、激活函数（activation function）、权重初始化（weight initialization）和优化策略。它们共同决定前向信号和反向梯度在深层网络中是否会失真。

以归一化为例，课程用 LayerNorm 说明其基本机制：先把输入标准化，再通过可学习参数恢复必要的尺度和偏移。写成公式就是

$$\hat{x} = \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}}, \quad y = \gamma \hat{x} + \beta.$$

其中， μ 与 σ^2 是所选归一化维度上的均值与方差， ϵ 用于数值稳定， γ, β 是可学习的缩放与平移参数。这个公式说明归一化不是把特征“洗平”，而是在可控标准化之后再交还表达能力。

Example Normalization Layer: LayerNorm

High-level Idea: Learn parameters that let us **scale / shift the input data**

1. Normalize input data
2. Scale / shift using learned parameters

Ba, Kiros, and Hinton, "Layer Normalization", arXiv 2016

Stanford CS231n 10th Anniversary

Lecture 6 - 10

April 17, 2025

图 1: 归一化层通过“标准化 + 可学习缩放平移”改善优化地形，使更深网络更容易训练。

深 CNN 的训练稳定性取决于信号如何在层间传播，而不仅仅是模型深度。归一化、激活与初始化是深网络可训练性的三根支柱。

1.1 本章小结

2 Normalization layer 到底在做什么

课程虽然用 LayerNorm 举例，但它真正要学生掌握的是一类统一思想：通过控制中间表示的统计分布，让优化更平滑、梯度更稳定、训练更快收敛。BatchNorm、LayerNorm、GroupNorm 的差别，主要在于统计量是沿 batch、特征还是分组维度计算，以及它们各自适合的任务与 batch 设置。

教材化理解时，可以把归一化层看成“可学习的数值调节器”。它不是直接增加模型表达能力，而是改善优化几何，使更深、更复杂的网络也能被标准的一阶优化器训练起来。换句话说，归一化

层的最大贡献往往不是测试时多了几个点，而是让原本训练不了的网络变得可训练。

不同 normalization 变体的核心目标相同：改善优化条件。它们的区别主要来自统计量计算维度以及 batch 大小的耦合方式。

2.1 本章小结

3 训练细节：正则化、数据增强与学习率

深 CNN 的性能不只来自主干结构，还来自训练细节。课程把 dropout、数据增强、学习率策略与训练时长放在同一章节中，正是在强调这一点。Dropout 的核心是训练期随机屏蔽一部分激活，抑制神经元之间的共适应 (co-adaptation)；数据增强则通过人工扩展输入分布，让模型把注意力放在更稳定的语义模式上，而不是偶然像素细节。

Regularization: A common pattern

Training: Add some kind of randomness

$$y = f_W(x, z)$$

Testing: Average out randomness (sometimes approximate)

$$y = f(x) = E_z[f(x, z)] = \int p(z)f(x, z)dz$$

Example: Dropout

Training:
Randomly drop activations

Testing: Use all activations and average values with p

Stanford CS231n 10th Anniversary

Lecture 6 - 70

April 17, 2025

图 2: Dropout 通过训练期随机失活神经元抑制共适应，是经典的正则化工具。

这些技巧表面上彼此不同，但其实都在围绕泛化展开：dropout 从模型内部增加随机性，数据增强从输入侧增加变化，学习率策略则从优化动力学上影响最终收敛点。真正成熟的 CNN 训练流程，往往不是押宝某一项单独技巧，而是把这些因素作为一个整体系统去调。

深网络训练效果往往由一串“细节决策”共同决定，而不是单一技巧决定。正则化、增强和学习率共同服务于泛化，而不只是服务于训练误差。

3.1 本章小结

4 架构案例：AlexNet、VGG、ResNet



Lecture 6 的下半部分通过几个经典架构把“如何设计 CNN”具体化。AlexNet 代表了 ImageNet 时代深卷积网络的起点：更深、更宽、使用 ReLU、配合大规模数据和 GPU 训练。VGG 则展示了

另一种思路：用大量统一的 3×3 卷积堆叠深度，以结构简洁换取表示能力和可分析性。

Case Study: VGGNet

[Simonyan and Zisserman, 2014]

Q: What is the effective receptive field of three 3×3 conv (stride 1) layers?



Stanford CS231n 10th Anniversary

Lecture 6 - 40

April 17, 2025

图 3: VGG 用大量 3×3 卷积堆叠深度，展示了“简单模块重复”也能形成强大表征。

ResNet 的贡献更像是训练理论上的突破。它不直接让若干层去逼近目标映射 $H(x)$ ，而是改成学习残差映射 $F(x)$ ，使输出满足


$$y = F(x) + x.$$

其中， x 是输入特征， $F(x)$ 是由若干卷积层学习到的残差。这个公式的意义在于：如果最优映射接近恒等映射，网络只需把残差学成接近零即可，从而显著缓解深层优化困难。

Case Study: ResNet

[He et al., 2015]

Solution: Use network layers to fit a residual mapping instead of directly trying to fit a desired underlying mapping



Stanford CS231n 10th Anniversary

Lecture 6 - 50

April 17, 2025

图 4: ResNet 通过残差连接让网络学习 $F(x)+x$ ，而不是直接学习 $H(x)$ ，从而缓解深层优化困难。

经典架构的价值在于它们各自解决了不同历史阶段的核心瓶颈。学架构时，应优先理解它“解决了什么问题”，其次才是背具体配置。


4.1 本章小结

5 迁移学习：把预训练网络变成通用视觉骨干

课程最后把训练好的 CNN 放回更大的应用图景中，这就是迁移学习 (transfer learning)。一个在大规模数据集上预训练好的视觉主干，往往学到了足够通用的底层与中层特征，因此面对新任务时，可以选择两条常见路径：要么把 backbone 当成固定特征提取器，只训练上层分类头；要么以较小学习率对整个网络进行微调 (fine-tuning)。

Transfer Learning with CNNs

1. Train on Imagenet (or internet scale data)



Donahue et al, "DeCAF: A Deep Convolutional Activation Feature for Generic Visual Recognition", ICML, 2014
Razavian et al, "CNN Features Off-the-Shelf: An Astounding Baseline for Recognition", CVPR Workshops 2014

Stanford CS231n 10th Anniversary

Lecture 6 -

80

April 17, 2025

图 5: 迁移学习 (transfer learning) 展示了预训练视觉特征的通用性: 同一个 backbone 可以作为固定特征提取器, 也可以端到端微调。

这部分内容之所以重要, 是因为它把“经典 CNN 架构”与今天的大模型实践连接起来。无论是 ViT、CLIP 还是多模态 backbone, 本质上都在重复同一个模式: 先在大规模任务上学通用表示, 再在下游任务上复用或微调。

迁移学习说明视觉 backbone 的价值不只体现在原任务上, 更体现在可复用的表示。从预训练到微调的工作流, 后来成为视觉大模型和多模态模型的共同范式。

5.1 本章小结

6 总结与延伸

Lecture 6 把“会搭 CNN”提升为“会训练、会分析、会复用 CNN”。归一化、激活、初始化、正则化与学习率策略解决的是训练可行性问题; AlexNet、VGG、ResNet 解决的是架构设计问题; 迁移学习则把这些架构变成了可复用的视觉骨干。

如果把前六讲合起来看, 到这里课程已经建立了一个完整的深视觉基础: 任务定义、损失函数、优化方法、神经网络、卷积结构和经典架构。之后进入检测、分割、视频、自监督、生成、多模态与机器人学习时, 这些工具会不断重现, 只是输入输出接口和归纳偏置发生变化。

6.1 拓展阅读

- AlexNet
- VGGNet
- GoogLeNet

- ResNet