

课程笔记

CS231n Lecture 10: Video Understanding

Codex Harness

2026-04-15



目录

1	为什么视频理解比图像理解更难	2
1.1	本章小结	2
2	从 2D baseline 到 3D CNN	2
2.1	本章小结	3
3	运动信息: Optical Flow 与 Two-Stream	3
3.1	本章小结	3
4	更长时间尺度: RNN、Non-local 与 I3D	4
4.1	本章小结	5
5	视频 Transformer、时序定位与多模态扩展	5
5.1	本章小结	7
6	总结与延伸	7

1 为什么视频理解比图像理解更难

本讲一开始就把一个非常朴素但关键的事实讲透了：视频不是“很多张图像简单堆起来”。一段视频至少比单张图像多出三类困难：

- **时间维**：动作和事件往往依赖帧与帧之间的变化，而不是单帧内容。
- **数据规模**：视频帧数远大于图像像素通道数带来的常规模型输入规模。
- **任务形式**：可能是 clip 级分类，也可能是逐帧标签、时序定位、时空检测，甚至音视频联合理解。

因此，课程很早就强调了一个工程事实：训练通常不会把整段视频一次性送进网络，而是以 **clips** 为单位做采样。clip 既是可计算性约束，也是建模假设的一部分。

1.1 本章小结

视频理解的真正难点，不在于多了一个输入轴，而在于时间、计算与任务定义都变得更加复杂。

2 从 2D baseline 到 3D CNN

课程先按时间顺序回顾了几类经典 baseline：

- **single-frame CNN**：每次只看一帧，本质上忽略运动。
- **late fusion**：先独立编码多帧，再在高层做 pooling 或融合。
- **early fusion**：把多帧在输入通道上拼接，尽早让网络看到时间上下文。

这些方法都能工作，但都存在明显局限。single-frame CNN 几乎看不到运动；late fusion 难以建模细粒度时序交互；early fusion 又把时间信息粗暴塞进 2D 卷积里。

Video Classification: 3D CNN




图 1: 3D CNN 直接在时空体上卷积，比 early/late fusion 更自然地统一建模空间与时间。

所以，3D CNN 的出现是顺理成章的：把卷积核从 (H, W) 扩成 (T, H, W) ，让网络直接学习时空局部模式。课程用 C3D 作为代表性模型，强调它在视频里扮演的角色类似图像中的 VGG：结构规整，便于理解和扩展。

2.1 本章小结

3D CNN 的意义在于把“时间”从后处理对象变成卷积运算的内生维度。

3 运动信息: Optical Flow 与 Two-Stream

仅靠 RGB 帧并不总能可靠识别动作，因为外观和运动往往混在一起。课程于是引出 optical flow：它不是直接描述“画面长什么样”，而是描述“像素往哪里动”。




图 2: Two-stream networks 把 appearance 与 motion 分别建模，再在更高层融合。

two-stream network 的想法因此很直白：

- 空间流（spatial stream）处理 RGB appearance。
- 时间流（temporal stream）处理 optical flow。
- 在高层把两者融合，得到更稳健的动作表征。

这条路线的教学价值很高，因为它说明视频理解并不总是追求“一个更大更统一的模型”；在很多阶段，把外观和运动分开建模本身就是重要归纳偏置。

3.1 本章小结

optical flow 和 two-stream 的贡献，是把“运动”从隐含因素提升成显式表征对象。

4 更长时间尺度: RNN、Non-local 与 I3D

局部 3D 卷积虽然能看见短时间窗口，但它仍然难以捕捉更长程的时序结构。课程因此回顾了
两类延伸路径。

第一类是把局部特征交给 RNN/LSTM 或 recurrent convolutional network 继续沿时间聚合。这条路线本质上是“先做短时视觉编码，再做长时序建模”。

第二类则来自注意力思想: non-local block / spatio-temporal self-attention 允许模型直接在远距离时空位置之间建立连接，而不必把信息沿局部卷积层层传递。




图 3: Non-local / spatio-temporal self-attention 为视频提供了长距离依赖建模能力。

I3D (Inflated 3D ConvNet) 则体现了另一种很聪明的工程路线: 既然 2D 图像网络已经非常成熟，不如把 2D kernels inflation 成 3D kernels，在视频上复用这些设计经验和初始化思路。


Inflating 2D Networks to 3D (I3D)

There has been a lot of work on architectures for images.
Can we reuse image architectures for video?

Idea: take a 2D CNN architecture.

Replace each 2D $K_h \times K_w$ conv/pool layer with a 3D $K_t \times K_h \times K_w$ version

Can use weights of 2D conv to initialize 3D conv: copy K_t times in space and divide by K_t
This gives the same result as 2D conv given “constant” video input



Carreira and Zisserman, "Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset", CVPR 2017

Stanford CS231n 10th Anniversary

Lecture 10 - 75

May 1, 2025

图 4: I3D 通过 kernel inflation 把 2D 架构平滑迁移到视频场景。


4.1 本章小结

面对长时依赖，课程给出的答案不是唯一的：可以用 recurrence、attention，也可以通过 I3D 这样的架构迁移延续卷积路线。

5 视频 Transformer、时序定位与多模态扩展

随着上一讲 Transformer 的铺垫完成，本讲很自然地把视频建模继续推进到 ViViT、Video Transformer、VideoMAE 等模型。它们的共同点是：不再把时间维只看成卷积扩展，而是把视频拆成 token，再通过 attention 建模全局关系。

Vision Transformers for Video



Stanford CS231n 10th Anniversary

Lecture 10 - 77


May 1, 2025

图 5: Video Transformer 把视频的时空块 token 化，用 attention 统一处理长距离依赖。

与此同时，课程也提醒读者不要把目标局限在 short clip classification。真实任务还包括：

- **Temporal Action Localization**: 动作在长视频里什么时候发生。
- **Spatio-temporal Detection**: 不仅要知道什么时候发生，还要知道在画面哪里发生。
- **Audio-Visual Understanding**: 联合声音和视觉做 source separation、事件理解。
- **Egocentric & Video + LLM**: 把第一视角视频、语言 and 高层推理结合起来。

Video Understanding + LLMs



Stanford CS231n 10th Anniversary

Lecture 10 - 102

May 1, 2025 102

图 6: Video understanding 与 LLM 的结合，代表了课程对未来多模态视频系统的指向。

效率始终是视频任务的硬约束

视频长度、分辨率和模态数一旦同时上升，计算成本会迅速失控。因此高质量视频模型几乎总要和 clip sampling、sparse processing、预训练或多模态压缩一起讨论。

5.1 本章小结

视频理解不再只是“视频分类”问题，而是一个覆盖时序定位、检测、多模态融合和语言推理的任务族。

6 总结与延伸

本讲把视频理解从最基础的时间维扩展讲到了现代多模态方向。核心脉络非常清楚：

- 用 clips 和 baseline 明确问题边界；
- 用 3D CNN 与 two-stream 建立时空与运动建模的经典方案；
- 用 RNN、non-local 和 I3D 扩展长时间尺度；
- 用 video transformers 和多模态系统把问题推向更大范围。

如果说图像模型的难点主要是空间表征，那么视频模型真正多出来的，是**时空范围、推理成本和模态协同**三重压力。后面的课程走向大规模训练与基础模型时，这三个压力会进一步放大。