


课程笔记

CS231n Lecture 12: Self-Supervised Learning

Codex Harness

2026-04-15



目录

1	为什么需要自监督学习	2
1.1	本章小结	2
2	从图像变换到重建: 经典 pretext task 家族	2
2.1	本章小结	3
3	MAE: reconstruction-based learning 的现代版本	3
3.1	本章小结	4
4	对比学习总式与 InfoNCE	4
4.1	本章小结	5
5	SimCLR、MoCo 与实例级对比学习	5
5.1	本章小结	6
6	CPC 与时序级对比学习	6
6.1	本章小结	6
7	DINO: 不靠显式负样本的自蒸馏路线	6
7.1	本章小结	7
8	总结与延伸	7

1 为什么需要自监督学习

这讲的出发点很明确：现代视觉模型确实能学到强表征，但如果每一步都依赖大规模人工标注，训练成本会非常高。课程因此提出一个关键问题：**能否利用数据本身生成监督信号，而不是依赖人工标签？**

这就是自监督学习（self-supervised learning, SSL）的核心。课程把它拆成两个阶段：

- **Pretext Task**：利用数据自身构造目标，例如预测旋转角度、补全缺失区域、区分正负样本。
- **Downstream Task**：把学到的表示迁移到分类、检测、分割等真正关心的任务上。

相应地，评价一个 SSL 方法也不只看 pretext task 做得多好，还包括：

- linear evaluation 表现如何；
- transfer 到下游任务后的性能如何；
- 是否具有鲁棒性与泛化能力；
- 训练是否足够高效。

1.1 本章小结


自监督学习的目标不是“把标签换个名字”，而是利用无标签数据学出可迁移表示。

2 从图像变换到重建：经典 pretext task 家族

课程先回顾了一大批经典 pretext tasks：rotation prediction、relative patch location、jigsaw puzzle、inpainting、colorization，甚至 video colorization。它们表面不同，但都共享同一逻辑：**人为对数据做某种扰动，再让模型恢复被扰动前的结构。**

Self-supervised pretext tasks

Example: learn to predict image transformations / complete corrupted images



1. Solving the pretext tasks allow the model to learn good features.
2. We can automatically generate labels for the pretext tasks.

图 1: 经典 pretext tasks 的共同点是：标签由输入图像自身生成，而不是由人工标注。

这些任务之所以有效，是因为模型若想解决它们，就必须学习对象形状、相对位置、纹理一致性和语义结构。例如：

- 旋转预测要求模型知道“正常物体应当朝哪个方向”。
- jigsaw/relative patch location 迫使模型理解局部块之间的空间关系。
- inpainting 与 colorization 则迫使模型从上下文推断缺失内容。

课程还特别提到 video colorization 中“tracking emerges from colorization”的现象：为了把颜色稳定传播到时间维上，模型会自发学习到跨帧对应关系。这非常形象地说明，SSL 学到的往往不是任务本身，而是完成任务所需的潜在结构。

2.1 本章小结

经典 pretext task 家族为后续所有 SSL 方法提供了直觉基础：用可自动构造的任务逼迫模型学习通用结构。

3 MAE: reconstruction-based learning 的现代版本

Masked Autoencoders (MAE) 是本讲 reconstruction 路线的现代代表。它的关键设计不是“做重建”本身，而是只让 encoder 处理可见 patch，把被遮挡 patch 的恢复交给轻量 decoder。

Masked Auto Encoders (MAE)

Reconstruction with a larger masked portion



He et al., 2021 Masked Autoencoders Are Scalable Vision Learners

Stanford CS231n 10th Anniversary

Lecture 12 - 52

May 8, 2025

图 2: MAE 通过高比例 masking，把重建任务变成“从少量可见 token 恢复完整图像”的表征学习过程。

其训练目标通常可以写成：

$$\mathcal{L}_{\text{MAE}} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \|\hat{x}_i - x_i\|_2^2$$

其中：

- $\mathcal{M}$: 被 mask 的 patch 集合。
- x_i : 真实 patch。
- $\hat{x}_i$: decoder 重建出的 patch。

课程强调了 MAE 的几个关键经验：

- masking ratio 可以很高，高遮挡反而迫使模型学习更全局的表征；
- encoder 只看可见 patch，使主干计算保持高效；
- linear probing 与 full fine-tuning 的效果不完全一致，因此评价 SSL 不应只看单一 protocol。

3.1 本章小结

MAE 说明 reconstruction 并未过时，关键在于如何把重建任务设计成既高效又能逼出语义表示。

4 对比学习总式与 InfoNCE

本讲后半进入 contrastive learning。课程把它写成一个非常清楚的通式：给定一个 anchor、一个正样本和若干负样本，让模型对“正确配对”分配更高分数。

标准 InfoNCE 可写成：

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(\text{sim}(q, k^+)/\tau)}{\exp(\text{sim}(q, k^+)/\tau) + \sum_{j=1}^K \exp(\text{sim}(q, k_j^-)/\tau)}$$

其中：

- q : anchor query。
- k^+ : 正样本 key。
- k_j^- : 负样本 keys。
- $\text{sim}(\cdot, \cdot)$: 相似度函数，常用 cosine similarity 或点积。
- τ : temperature, 控制 softmax 分布的尖锐程度。

A formulation of contrastive learning

Loss function given 1 positive sample and $N - 1$ negative samples:

$$L = -\mathbb{E}_X \left[\log \frac{\exp(s(f(x), f(x^+)))}{\exp(s(f(x), f(x^+))) + \sum_{j=1}^{N-1} \exp(s(f(x), f(x_j^-)))} \right]$$

Commonly known as the InfoNCE loss ([van den Oord et al., 2018](#))

A lower bound on the mutual information between $f(x)$ and $f(x^+)$

$$MI[f(x), f(x^+)] - \log(N) \geq -L$$

The larger the negative sample size (N), the tighter the bound

Detailed derivation: [Poole et al., 2019](#)

图 3: 对比学习把表征学习组织成“让正样本更近、负样本更远”的 softmax 分类问题。

下面这段伪代码把课程里 contrastive pretraining 的训练循环压缩成最小实现骨架：

```
1 x1, x2 = augment(image), augment(image)
2 q = encoder_q(x1)
3 k_pos = encoder_k(x2)
4 k_neg = queue.sample()
5 loss = info_nce(q, k_pos, k_neg)
6 loss.backward()
7 update(encoder_q)
```

Listing 1: contrastive pretraining 的最小训练循环

4.1 本章小结

InfoNCE 的价值，在于它把“学好表示”改写成一个结构清楚、可批量化的分类问题。

5 SimCLR、MoCo 与实例级对比学习

SimCLR 和 MoCo 是实例级对比学习最经典的两条路线。

SimCLR 的设计重点是：

- 强数据增强，构造正样本对；
- 大 batch，提供足够多的负样本；
- projection head，让对比损失作用在更适合分离的空间里。

MoCo 则用另一种工程思路回答“负样本不够怎么办”：

- 使用 momentum encoder 生成更稳定的 key；
- 维护一个 queue，累积大量负样本；
- 因而不强依赖超大 batch。

“MoCo V2”

Improved Baselines with Momentum Contrastive Learning

Xinlei Chen Haoqi Fan Ross Girshick Kaiming He
Facebook AI Research (FAIR)

A hybrid of ideas from SimCLR and MoCo:

- From SimCLR: non-linear projection head and strong data augmentation.
- From MoCo: momentum-updated queues that allow training on a large number of negative samples (no TPU required!).

Source: [Chen et al., 2020](#)

Stanford CS231n 10th Anniversary

Lecture 12 - 90

May 8, 2025

图 4: MoCo 的 momentum encoder + queue，是实例级对比学习最有代表性的工程设计之一。

MoCo v2 进一步吸收了 SimCLR 的一些优点，例如更强的数据增强和非线性 projection head。课程借此强调一个很重要的经验：SSL 的效果不只来自“大思想”，还高度依赖 augmentation、projection head、batch/queue 大小等工程细节。

5.1 本章小结

SimCLR 偏向“用更强增强和更大 batch 学表示”，MoCo 偏向“用动量编码器和样本队列换取更高效的负样本组织”。

6 CPC 与时序级对比学习

Contrastive Predictive Coding (CPC) 把对比学习从实例级扩展到了序列级。课程里它既用于音频，也用于视觉上下文，核心思想都是：根据当前上下文预测未来表示，并用 InfoNCE 判断哪个未来片段才是真的。

这意味着对比学习并不一定只能围绕图像增强做“同图不同视角”的匹配，它也可以围绕时间结构做“当前上下文 vs 未来信号”的匹配。这使 CPC 特别适合序列、音频和视频场景。

6.1 本章小结

CPC 证明了对比学习并不限于静态图像，而是一种更一般的时序表示学习框架。

7 DINO: 不靠显式负样本的自蒸馏路线

DINO 与 DINOv2 代表了另一条路线：不再显式构造负样本，而是用 teacher-student 自蒸馏在无标签数据上学习一致性目标。

DINO

Algorithm 1 DINO PyTorch pseudocode w/o multi-crop.

```
# gs, gt: student and teacher networks
# C: center (K)
# tps, tpt: student and teacher temperatures
# l, m: network and center momentum rates
gt.params = gs.params
for x in loader: # load a minibatch x with n samples
    x1, x2 = augment(x), augment(x) # random views

    s1, s2 = gs(x1), gs(x2) # student output n-by-K
    t1, t2 = gt(x1), gt(x2) # teacher output n-by-K

    loss = H(t1, s2)/2 + H(t2, s1)/2
    loss.backward() # back-propagate

    # student, teacher and center updates
    update(gs) # SGD
    gt.params = l*gt.params + (1-l)*gs.params
    C = m*C + (1-m)*cat([t1, t2]).mean(dim=0)

def H(t, s):
    t = t.detach() # stop gradient
    s = softmax(s / tps, dim=1)
    t = softmax((t - C) / tpt, dim=1) # center + sharpen
    return - (t * log(s)).sum(dim=1).mean()
```

Caron et al. 2021 Emerging Properties in Self-Supervised Vision Transformers

图 5: DINO 用 teacher-student 自蒸馏学习视觉表示，展示了“无显式负样本”也能学到强表征。

教学上，DINO 的意义很大，因为它告诉我们：对比学习虽然强大，但“负样本组织”并不是唯一可行路径。只要目标设计得当，表征也可以通过蒸馏一致性学出来。

7.1 本章小结

DINO 把 SSL 从“正负样本对比”进一步扩展到“无标签蒸馏”，表明 SSL 目标设计仍有很大空间。

8 总结与延伸

本讲把自监督学习的主要路线完整串了起来：

- pretext tasks 用人为扰动逼迫模型学习结构；
- MAE 用高遮挡重建学习视觉表示；
- SimCLR / MoCo 用 InfoNCE 做实例级对比；
- CPC 把对比学习带到时序建模；
- DINO 则展示了不依赖显式负样本的自蒸馏路径。

最重要的认识不是“哪篇论文最好”，而是理解这些方法在目标设计上的不同取舍：有的更依赖重建，有的更依赖样本对比，有的依赖 teacher-student 一致性。但它们共享一个更高层的目标：在没有人工标签的情况下学出能迁移到分类、检测、分割乃至视频任务的表征。