


课程讲义

CS231N Spring 2025 课程讲义: Lecture 13 Generative Models 1

Codex Worker 3

2026-04-15



视频作者/频道: Stanford Online

发布日期: 2025-09-02

视频时长: 1:12:30

视频链接: <https://www.youtube.com/watch?v=zbHXQRUNlH0>

目录

1	生成式模型的任务定义与动机	2
1.1	本章小结	3
2	自回归模型：把生成问题改写成链式条件概率	3
2.1	本章小结	4
3	变分自编码器：从自动编码器到概率生成模型	4
3.1	拓展阅读	6
3.2	本章小结	6
4	总结与延伸	6

1 生成式模型的任务定义与动机

这一讲首先把上一讲的自监督学习 (self-supervised learning) 重新拉回到一个更宽的视角里：如果我们能只靠数据本身学习表示，那么能否进一步直接学习“数据是如何被生成出来的”？这正是生成式模型 (generative models) 要回答的问题。讲者没有把它当作一个孤立分支，而是把它放在无监督学习、概率建模和现代大模型发展的共同背景下讨论。

课程先对监督学习与无监督学习做了重新定位。监督学习以带标签样本 (x, y) 为输入，目标是学得一个从输入到目标的映射；无监督学习则只有 x ，目标往往不是“立刻输出标签”，而是理解数据结构、提炼潜在变量、或学习可迁移表示。生成式建模就是其中一种更强的目标：不仅学习特征，还要学习数据分布本身。

Generative vs Discriminative Models




图 1: 生成式模型与判别式模型在概率对象上的差异：前者试图刻画数据分布或联合分布，后者直接刻画条件分布。

在这个框架里，判别式模型 (discriminative models) 通常学习 $p(y | x)$ ，也就是“已知输入时输出类别的条件概率”；而生成式模型则学习 $p(x)$ 或 $p(x, y)$ 。这两者并不只是“一个做分类，一个做生成”这么简单，差别在于它们的归一化对象与建模目标完全不同。讲者反复强调，生成式模型试图把概率质量分配到所有可能的数据上，因此如果你想提高一个样本的概率，就必须重新分配整张概率版图。

利用 Bayes 规则，两类模型之间还存在可转换关系：

$$p(y | x) = \frac{p(x | y)p(y)}{p(x)}$$

这里：

- x 是观测数据，例如一张图像；
- y 是标签或条件；
- $p(x | y)$ 描述某一类别如何“生成”观测；
- $p(y)$ 是先验；

- $p(x)$ 是对所有可能类别边缘化后的证据项。

这也是为什么讲者会说，生成式模型不仅能做“生成”，还能够通过组合概率项来支持条件预测、补全和推断。换言之，学习数据分布往往意味着获得更通用的建模能力，而不是仅获得一个会“画图”的模型。

为什么生成式建模在今天重新重要

讲者给出的理由并不是单一的“图像更好看了”，而是：现代深度学习终于有能力把早年“模糊垃圾图”的生成模型扩展到真正有表达力的规模。随着数据、算力和模型容量上升，生成式方法第一次在实践里兑现了其概率建模承诺。

1.1 本章小结

本讲前半部分完成了两个关键定位：第一，生成式模型不是和分类无关的旁枝，而是更底层的概率建模视角；第二，它的目标是刻画数据分布本身，因此天然能支持采样、条件推断和表示学习。后面所有具体模型，都是对这一目标的不同工程化实现。

2 自回归模型：把生成问题改写成链式条件概率

讲者接下来介绍了第一类最直接、也最“概率论教科书化”的方法：自回归模型（autoregressive models）。它的核心思想非常简单：把一个高维样本拆成序列，然后利用链式法则逐步生成。

对一个序列化后的样本 $x = (x_1, x_2, \dots, x_T)$ ，模型写作：

$$p_{\theta}(x) = \prod_{t=1}^T p_{\theta}(x_t \mid x_1, \dots, x_{t-1})$$

符号说明如下：

- x_t ：第 t 个 token、像素或离散化后的局部变量；
- T ：序列长度；
- p_{θ} ：由参数 θ 决定的条件分布；
- 条件项 $p_{\theta}(x_t \mid x_{<t})$ 表示“在前文已知的情况下，当前元素最可能是什么”。


训练时通常直接做最大似然（maximum likelihood estimation, MLE），也就是最大化训练样本在模型下的概率，或者等价地最小化负对数似然。课程在这里把“显式写下 $p(x) = f(x, W)$ ”作为最大似然建模的出发点：你需要先承诺一个明确的概率模型，然后再通过数据拟合参数。

Autoregressive Models of Images

Treat an image as a sequence of 8-bit subpixel values (scanline order)

Predict each subpixel as a classification among 256 values [0...255]

Model with an RNN or Transformer



Van den Oord et al, "Pixel Recurrent Neural Networks", ICML 2016
Van den Oord et al, "Conditional Image Generation with PixelCNN Decoders", NeurIPS 2016

Stanford CS231n 10th Anniversary

Lecture 13 - 57

May 15, 2025

图 2: 把图像改写为序列之后, 自回归模型就可以像语言模型一样逐步预测下一个 token 或像素。

这种方法的优势在于概率目标非常明确: 每一步都在优化真正的似然, 而不是某种代理目标。它与大语言模型 (LLMs are autoregressive models) 之间也有天然联系。讲者专门点出, 语言模型之所以能统一训练和采样, 是因为“下一个 token 预测”本身就是严格的自回归分解。

但把图像转换成序列时, 自回归模型也会暴露一些代价。首先, 图像原本是二维结构, 序列化之后会引入人为顺序; 其次, 长程依赖会把采样过程变成严格串行; 最后, 虽然训练时 teacher forcing 很稳定, 推理时却要一步一步滚动生成, 速度天然受限。

自回归方法为什么仍然重要

课程并没有把自回归模型当作“旧时代方案”。相反, 它把它视为生成建模的一条基线: 如果你愿意接受串行采样, 自回归方法提供了最干净、最可解释的似然目标。后来很多方法, 本质上都在试图保留这种明确概率语义, 同时缓解它的采样或表示局限。

2.1 本章小结

自回归模型把复杂生成问题拆成一串条件预测问题, 因此目标函数最直接、理论最干净。它的局限主要来自表示方式和串行采样成本, 而不是来自概率建模本身。

3 变分自编码器: 从自动编码器到概率生成模型

在引出 VAE 之前, 讲者先回顾了普通自动编码器 (autoencoder)。普通自动编码器通过 encoder 把输入压缩到潜变量, 再由 decoder 试图重建原始输入。它能学到压缩表示, 但并不自动提供一个“好的、可采样的”潜空间。原因在于: 编码后的 latent code 只是训练样本的压缩结果, 空间中不同点未必对应合理样本, 也没有统一的概率结构可供采样。

于是, VAE 的核心改造是: 不要让 encoder 输出一个点, 而是输出一个分布 $q_\phi(z|x)$; 同时假设一个简单先验 $p(z)$, 并通过训练让每个样本对应的后验分布都尽量贴近这个先验。这样, 潜空间就变成一个被规则化的概率空间, 而不再只是离散散点云。

课程在这里强调了 latent variable model 的张力：如果有联合分布

$$p_{\theta}(x, z) = p_{\theta}(x | z)p(z),$$

那么理论上只要把 z 积分掉，就能得到

$$p_{\theta}(x) = \int p_{\theta}(x | z)p(z) dz.$$

问题恰恰出在这个积分上。讲者反复指出，这个积分“杀死了我们”：当 decoder 是神经网络时， $p_{\theta}(x | z)$ 会是一个复杂非线性函数，几乎不可能直接精确边缘化。所以 VAE 的难点从来不是“有没有潜变量”，而是“如何在不可解积分面前仍然训练生成模型”。

Variational Autoencoders (ELBO)

$$\log p_{\theta}(x) = \log \frac{p_{\theta}(x | z)p(z)}{p_{\theta}(z | x)}$$

Bayes' Rule

图 3: ELBO 把难以直接优化的对数似然下界化为重建项与 KL 正则项之和，是 VAE 训练的核心。

为了绕开这个困难，VAE 采用变分近似：用一个可学习的近似后验 $q_{\phi}(z | x)$ 去逼近真实后验 $p_{\theta}(z | x)$ ，并优化证据下界（Evidence Lower Bound, ELBO）：

$$\log p_{\theta}(x) \geq \mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x | z)] - D_{KL}(q_{\phi}(z | x) || p(z)).$$

这条公式的两部分各有明确职责：

- 第一项是重建项（reconstruction term），要求 decoder 在给定 z 时能够重建出输入 x ；
- 第二项是 KL 散度，要求 encoder 输出的潜变量分布不要偏离简单先验 $p(z)$ 太远；
- 当 $p(z)$ 选成单位高斯时，潜空间就会被压成一个结构规整、可直接采样的区域。

讲者随后结合 transcript 解释了实际参数化方式：encoder 不直接输出样本，而输出潜变量高斯分布的均值 $\mu(x)$ 与标准差或方差参数 $\sigma(x)$ 。这使得一个神经网络可以输出“一个分布”，而不是只输出单个向量。

在采样时，课程强调的直觉非常清楚：如果你只是让 decoder 学习“某个 code 到某个样本”的映射，那么随机采样 code 并不可靠；但如果 KL 正则让所有样本的后验都围绕一个简单先验展开，那么我们就可以直接从 $p(z)$ 采样，再交给 decoder 生成新数据。

Variational Autoencoders: Sampling

1. Sample z from the prior
2. Run through decoder to get an image




图 4: 当潜变量空间被规则化后, 可以直接从简单先验采样, 再通过解码器生成新样本。

为什么 VAE 通常比普通自编码器更适合“生成”

普通 autoencoder 学到的是压缩映射; VAE 学到的是带概率语义的潜空间。前者擅长表示压缩, 后者才真正具备“从先验出发生成新样本”的机制。

课程最后还提到 disentangling 的愿景: 如果潜变量的不同维度学到相对可分离的语义属性, 那么我们就可以通过操控潜空间局部方向, 分别控制形状、风格、姿态等属性。这里讲者保持了谨慎态度, 没有把 disentanglement 说成必然结果, 而是把它作为 VAE 类模型一个很有吸引力、但需要额外条件才能稳定出现的目标。

3.1 拓展阅读

官方 reading 链接到一篇 ELBO 解释博客。把它与本讲一起看时, 最有价值的不是记住推导细节, 而是抓住 ELBO 的两个工程含义: 一是它用近似后验替代了不可解积分, 二是它把“生成质量”和“潜空间规整性”写进了同一个训练目标。

3.2 本章小结

VAE 解决的是“如何让潜变量生成模型既能训练又能采样”的问题。它通过近似后验、ELBO 和 KL 正则, 把潜空间从普通 autoencoder 的压缩空间变成了可解释、可采样的概率空间。

4 总结与延伸

Lecture 13 的真正主线不是罗列三类模型, 而是把生成建模的三种典型思路摆在同一张地图上: 自回归模型直接分解似然; 普通 autoencoder 学表示但不保证可采样; VAE 通过变分推断把潜变量生成模型变成可训练对象。三者都在回答同一个问题: 如何让模型学会“数据从哪里来”。

如果从自学角度整理, 本讲最应掌握的有三点。第一, 生成式模型和判别式模型的差别首先是概率对象不同, 不是输出形式不同。第二, 自回归方法提供了最直接的似然建模基线, 因此后续方

法的改进都应与其对照。第三，VAE 的关键不在于“encoder-decoder”外观，而在于 ELBO 让不可解边缘似然获得了可优化下界。

从课程安排看，本讲把生成式建模的概率基础、序列化思路和潜变量思路都铺好了；下一讲进一步进入 GAN、diffusion 等更强调样本质量和大规模生成能力的方法时，读者就能更清楚地看见：不同生成模型之间，真正竞争的是训练目标、潜空间约束、采样路径和工程稳定性，而不是一句“谁生成得更像”。