

课程讲义

CS231N Spring 2025 课程讲义: Lecture 17 Robot Learning

Codex Worker 3

2026-04-15



视频作者/频道: Stanford Online

发布日期: 2025-09-02

视频时长: 1:18:32

视频链接: https://www.youtube.com/watch?v=XSfmOH_xVSU

目录

1	从视觉任务到机器人决策：问题形式与感知环路	2
1.1	本章小结	2
2	强化学习：成功案例、价值函数与现实瓶颈	3
2.1	本章小结	3
3	模型学习与 model-based planning	3
3.1	本章小结	4
4	模仿学习：从 behavior cloning 到 diffusion policy	4
4.1	本章小结	5
5	机器人 foundation models、world models 与评测难题	5
5.1	本章小结	6
6	总结与延伸	6

1 从视觉任务到机器人决策：问题形式与感知环路

这讲最重要的转折，是把课程从“给定输入预测输出”的视觉范式，推向“智能体在环境中持续行动”的机器人范式。讲者一开始就用 Cart-Pole、robot locomotion、Atari、Go、text generation 和 cloth folding 等例子说明：机器人学习（robot learning）真正处理的是 action problem，而不是单次预测问题。

一个标准目标可以写成最大化期望回报：


$$\pi^* = \arg \max_{\pi} \mathbb{E} \left[\sum_{t=0}^T \gamma^t r_t \right].$$

这里：

- π 是策略（policy），决定在状态下采取什么动作；
- r_t 是第 t 步的即时奖励；
- γ 是折扣因子，用来平衡短期与长期收益；
- 期望是对环境随机性和策略随机性求的。

与监督学习相比，这里没有一个现成的“正确标签动作”总是摆在眼前。机器人必须通过交互、试错、示范或模型预测来学会行动。更关键的是，机器人只能看到不完整、带噪声的观测，因此 perception 本身已经是决策问题的一部分。

The Perception-Action Loop



Yunzhu Li

Lecture 17 - 28

May 29, 2025

图 1: 机器人学习的核心不是静态预测，而是 perception-action loop 中的闭环决策。

课程用 sensors for robotics 与 perception-action loop 两页把这一点讲得很清楚：视觉、触觉、深度、状态估计等感知通道并不是附属输入，而是与动作共同组成闭环。机器人不是先“看完”再“做”，而是在做的同时继续看、继续修正、继续规划。

1.1 本章小结


Robot learning 的第一原则是闭环。只要任务需要持续交互、长期回报和部分可观测环境，问题就不再等价于普通监督学习。

2 强化学习：成功案例、价值函数与现实瓶颈

课程随后把 Reinforcement Learning (RL) 放在机器人语境中讨论。RL 的吸引力在于，它允许智能体仅根据奖励学习策略，而不需要每一步的动作标签。以 DQN 为代表的方法，把高维感知输入直接映射为动作价值：

$$Q(s, a) \approx Q(s, a; \theta),$$

其中 $Q(s, a)$ 表示在状态 s 选择动作 a 后的长期价值估计。



Yunzhu Li

Lecture 17 - 40

May 29, 2025

图 2: DQN 代表深度强化学习把高维感知输入直接映射为动作价值的经典范式。

讲者用 Atari、Go、locomotion 与 dexterous manipulation 的例子说明了 RL 的力量：一旦交互足够多、奖励足够明确、环境足够可重复，trial-and-error 的方法确实可能学出超过人类的策略。但课程同样非常坦诚地指出，robotics 中的 model-free RL 直到今天仍然面临严重瓶颈：真实世界交互昂贵、训练样本需求极大、成功演示往往来自被精挑细选的视频、且对环境分布变化非常敏感。

这里的关键批评不是“RL 没用”，而是“RL 的成功条件比公开视频演示暗示得更苛刻”。很多看起来华丽的 locomotion 演示，背后仍然依赖人类高层选路、任务设定受控、环境被精心构造。真正走向家庭或开放世界时，sample efficiency 与 robustness 会立刻成为瓶颈。


2.1 本章小结

RL 证明了试错学习在高维决策中的潜力，但课程也明确指出：如果没有更好的先验、模型或示范，仅靠 model-free trial-and-error 很难支撑开放环境中的大规模机器人部署。

3 模型学习与 model-based planning

为了缓解 RL 的低效，课程转向 model learning 与 model-based planning。核心思想是：先学一个环境动力学模型，让机器人在“想象”里预测未来，再把规划或搜索建立在这个模型之上，而不是每一步都去真实世界撞南墙。

Pixel Dynamics - Deep Visual Foresight



Finn and Levine, "Deep Visual Foresight for Planning Robot Motion", ICRA 2017

Yunzhu Li

Lecture 17 - 56

May 29, 2025

图 3: Model learning 通过预测未来视觉状态或关键变量，把规划问题变成可模拟、可搜索的问题。

讲者列举了 pixel dynamics、keypoint dynamics、particle dynamics 等路线，它们的共同点是把复杂环境压缩成更容易滚动预测的状态表示。课程给出的多个物理操作案例很有代表性：颗粒重排、字母堆积、面团塑形、dumpling-making robot 等任务都说明，一旦模型能预测未来状态，机器人就能通过 rollout、采样或优化，在执行前先比较“哪条动作序列更接近目标”。

这部分最值得注意的是蒸馏思想：纯粹在测试时大量采样动作很慢，所以可以先用模型做离线规划或搜索，生成高质量轨迹，再训练一个快得多的 policy network 近似这些规划结果。于是，model-based planning 与 policy learning 并不是对立，而是可以形成“模型搜索生成老师，策略网络学习学生”的两阶段系统。

3.1 本章小结


model learning 的价值不只是“预测下一帧”，而是把行动问题变成可内化的搜索问题。只要模型足够准，机器人就能把昂贵的试错从真实世界转移到内部模拟中。

4 模仿学习：从 behavior cloning 到 diffusion policy

机器人并不只靠试错学习，人类示范 (demonstrations) 本身就是强监督信号。课程在 imitation learning 部分把这条路线分成几种层次：最直接的是 behavior cloning (BC)，即把示范当监督数据，学习从观测到动作的映射；更高级的路线包括 inverse reinforcement learning (IRL)、implicit behavior cloning (IBC) 以及 diffusion policy。

Diffusion Policies

Visuomotor Policy Learning via Action Diffusion



Yunzhu Li

Lecture 17 - 77

May 29, 2025

图 4: Diffusion policy 把生成模型思想带回 imitation learning，用来处理多模态动作分布。

讲者解释 diffusion policy 的方式很有启发性：很多操作任务的动作分布本来就是多模态的，不存在唯一“正确动作”。生成模型恰好擅长表达多模态分布，因此可以把动作序列当作要生成的对象，用 diffusion 或 energy-based 方法做推断。这样一来，生成式学习和机器人控制在这里再次汇合。

课程借此给出一个重要方法论：robot learning 并没有单一宗教。试错学习、模型学习、模仿学习、生成建模彼此之间并非竞争关系，而更像是在不同数据条件和任务约束下互相补位的工具箱。

4.1 本章小结


当示范可得时，模仿学习往往能比纯 RL 更高效；而 diffusion policy 等方法说明，生成模型不仅能生成图像，也能生成动作分布和控制策略。

5 机器人 foundation models、world models 与评测难题

课程结尾把主题提升到 robotic foundation models。讲者提到 RT-1、RT-2、RT-X、OpenVLA、Pi-Zero 等一系列系统，强调过去两年该方向的爆发式增长。它们共同追求的是：不要只在一个实验台上学一个 policy，而要学一个能跨任务、跨物体、跨环境迁移的底座模型。

Pi-Zero by Physical Intelligence

□ First released in October 2024



Yunzhu Li

Lecture 17 - 84

May 29, 2025

图 5: 机器人 foundation model 追求跨任务、跨场景的广泛泛化, 而不仅是单任务高成功率。

但课程也非常谨慎: 这些模型的视频演示确实令人振奋, 可“真正广泛泛化了吗”仍然很难回答, 因为 evaluation 太难。真实机器人任务高度多样、部署成本高、标准 benchmark 缺乏统一性, 很多系统的强弱只能通过少量公开视频去感受, 而不是通过成熟、可复现实验协议直接比较。

讲者最后把话题推进到 foundation policy 和 foundation world models, 并指出一个关键未来方向: 单个巨大 policy 未必足以支撑复杂开放世界, 也许还需要更高层抽象, 例如 scene graph、symbolic structure 或长期适应机制 (life-long learning)。换言之, 机器人 foundation model 可能不能只靠“把所有数据都喂给一个模型”解决, 还需要更结构化的中间表示与持续适应能力。

5.1 本章小结

机器人 foundation model 是一个高潜力方向, 但课程没有把它神化。真正的难点不只是模型训练, 而是任务抽象、真实世界泛化和可置信评测。

6 总结与延伸

Lecture 17 把本课程从静态视觉理解推向了 embodied intelligence。真正的收获不是记住若干算法名词, 而是看清 robot learning 的基本结构: 感知必须服务于行动; 单步预测必须服从长期回报; 单次演示必须能被转化为可泛化策略; 而大模型愿景最终仍要落在 world interaction、evaluation 和 adaptation 上。

从教材角度看, 本讲至少应记住四条线索。第一, robot learning 与监督学习的本质差别在于闭环与长期目标。第二, RL 提供试错能力, 但现实机器人中的 sample efficiency 与 robustness 是硬约束。第三, model-based planning 与 imitation learning 为实际系统提供了更高效的学习路径。第四, foundation models 在机器人里很有前景, 但如果没有更好的评测和中间表示, 泛化能力很难被可靠证明。