


课程讲义

CS231N Spring 2025 课程讲义: Lecture 18 Human-Centered AI

Codex Worker 3

2026-04-15



视频作者/频道: Stanford Online

发布日期: 2025-09-02

视频时长: 1:05:15

视频链接: <https://www.youtube.com/watch?v=g8UaBfj6Sh8>

目录

1 从“我们看见什么”到“我们珍视什么”	2
1.1 本章小结	2
2 从场景理解到社会语义：看见关系、差异与隐藏结构	2
2.1 本章小结	2
3 当“不看见”同样重要：隐私、医疗与 dark spaces of health	3
3.1 本章小结	3
4 把 AI 带回真实世界：机器人、偏好与以人为中心的任务选择	3
4.1 本章小结	3
5 总结与延伸	3

1 从“我们看见什么”到“我们珍视什么”

作为课程最后一讲,这一节并不继续讲某个新算法,而是把整门课重新放回“human perspective”下审视。讲者一开始就说明:这不是一次普通的技术递进课,而是一次研究与价值取向上的回望。她把主题概括为 what we see and what we value,意思是 AI 不仅关心能不能看见、能不能识别、能不能生成,更关心我们究竟希望它看见什么、帮助什么、以及在什么边界内行动。

Source Gap

本讲在 Spring 2025 课程页上没有公开官方 slides。本章完全依据公开视频字幕、课程页上下文与已有 structured evidence 做 best effort 重建,因此组织方式更接近 transcript-grounded 教材化整理,而不是 slide-by-slide 对齐讲义。

讲者随后把计算机视觉和 AI 的发展粗略回顾为几波:早期 parts-based object recognition 假设物体可由预定义部件组合而成,思想很优雅,但实际效果有限;随后统计机器学习时代到来,编程与统计模型结合,让系统开始真正从数据中学习;再后来深度学习把表示学习推到大规模阶段,性能大幅跃升,但也把社会影响、偏见与价值问题重新推到台前。

她之所以在课程终点讲这段历史,不是为了做怀旧回顾,而是为了提醒学生:每一波技术进展都扩大了“我们可以让机器看见什么”的能力,但也同时扩大了“机器看见以后会做什么”的责任范围。

1.1 本章小结

本讲开头最重要的收束是:技术路线并不是价值中立的。视觉能力越强,我们越需要明确地问,系统该服务于谁、在哪些场景里部署、又应当拒绝什么。

2 从场景理解到社会语义:看见关系、差异与隐藏结构

课程中段回顾了 scene understanding 的一条研究线:如果视觉系统只会识别孤立对象,它对现实世界的理解依然很浅。于是,研究开始转向 object relationships、scene graphs、story descriptions 等更结构化的表示。讲者以 Visual Genome 为例,说明即使是一张看似简单的图像,也可能包含对象、属性、关系、动作与叙事层级的密集结构。

她特别喜欢举 unusual relationships 的例子,例如 person riding a horse 很常见,但 horse wearing a hat 就非常少见。这个例子看似轻松,实际上指出了深刻问题:长尾世界(long tail world)中的罕见组合,往往才是真正考验模型泛化与常识约束的地方。只在海量常见共现上训练,模型容易学会统计频率,却未必真正学会结构关系。

讲者接着讨论 fine-grained recognition。无论是鸟类细粒度分类还是汽车 make/model/year 分类,都说明“看见某个大类”与“真正理解细微差异”之间还隔着很长距离。更有意思的是,这些细粒度视觉信号还可能被拿来推断区域、收入、消费水平等社会属性。也就是说,视觉系统不仅在做识别,还可能间接进入社会判断。

2.1 本章小结

场景图、细粒度识别与关系推理共同说明:视觉系统越深入现实世界,就越会从“物体识别器”变成“社会语义提取器”。这使得准确性与责任问题开始交织在一起。

3 当“看不见”同样重要：隐私、医疗与 dark spaces of health

讲者在这一部分提出了一个非常有力的观点：很多时候，AI 的目标不是尽可能多看，而是有边界地看。她把这类问题概括为 not seen。某些不可见空间本身是技术盲区，例如医院病房、病人家庭、制药现场、护理流程等缺乏足够人工关注的 dark spaces of health；另一些不可见则是我们主动希望保留的隐私边界。

因此，human-centered AI 在这里体现为一个双重任务：一方面，利用智能传感器和机器学习进入传统上“缺少眼睛”的空间，帮助医生、家庭成员或护理人员更早发现问题；另一方面，又要避免系统过度窥视，侵犯病人和家庭成员不希望暴露的信息。

讲者举了 patient room / home camera、hand hygiene、ambient intelligence for health 等实验室工作，想表达的不是某个特定论文细节，而是一个研究取向：AI 不该只去那些数据最干净、benchmark 最成熟的地方，也应该进入真正对人有帮助但长期被忽视的场景。可一旦进入这些场景，隐私、尊严、授权和解释责任就会立刻变成一等问题。

3.1 本章小结

“看得更多”并不自动等于“更好”。在医疗与家庭等敏感环境中，AI 的价值常常来自有边界、可审计、尊重隐私的帮助，而不是最大化感知覆盖。

4 把 AI 带回真实世界：机器人、偏好与以人为中心的任务选择

课程最后把话题转向机器人，但切入点不是控制算法，而是 task choice。讲者对“robots in the wild”给出的表述非常明确：如果我们总是在封闭环境里预定义任务集合，机器人系统看起来会很强，但并不真正面向现实世界。相比之下，人们真正需要的，往往是开放指令、开放场景和开放任务组合下的可靠帮助。

她提到实验室如何尝试让机器人接受开放式 instruction，并且讨论一个非常重要的问题：哪些任务值得优先教给机器人？答案不应只由技术可行性决定，还应由 human preference 决定。课程引用了对用户需求的排序结果：人们更希望机器人承担清洁、重复、低情感价值但高体力消耗的任务，而不是去替自己完成高度私人或高社会意义的活动。

这一点非常符合“human-centered”一词的真正含义。以人为中心，不只是让人更方便下 prompt，也不是让机器人看起来更聪明，而是要从任务定义开始，就把人的需求、偏好、伦理边界和社会接受度放进系统设计里。

4.1 本章小结

真正的 human-centered robotics，不是先造出一个能做很多事的机器人再找场景，而是先问清楚：哪些帮助是人真正想要的、愿意接受的、并且不会侵蚀自主性与尊严的。

5 总结与延伸

Lecture 18 之所以重要，不在于它增加了新的技术细节，而在于它为整门课加上了价值维度。前面 17 讲不断扩展了视觉系统的能力边界：识别、检测、分割、生成、三维理解、语言 grounding、机器人决策。最后这一讲提醒我们，能力边界的每一次扩展，都会把 AI 更深地带入社会结构、制度环境和人与人的关系中。

如果把这门课当成一本教材的最后一章来读，那么本讲给出的最终结论可以概括成三点。第一，AI 研究的历史从来不仅是算法历史，也是问题设定与价值设定的历史。第二，视觉与具身系统一旦进入健康、家庭、城市和劳动力场景，隐私、尊严、偏好和公平不再是附录，而是主问题。第三，以人为中心并不意味着放慢技术创新，而是要求我们从一开始就把“谁受益、谁承担风险、谁拥有选择权”写进系统设计中。