

UCB CS294/194-196 Agentic AI Fall 2025

第 07 讲: Multi-Agent AI

基于公开视频、slides、字幕与课程页整理

目录

1 课程定位: 为什么这一讲要从 Self-Play 讲起	2
2 从自我对弈到均衡: 零和博弈里的基本理论	2
2.1 Fictitious Play、Regret Matching 与 Hedge	3
3 为什么不完全信息博弈更难	4
4 从博弈到真实系统: Diplomacy、DORA 与人类环境	5
5 LLM 多智能体协作: 延迟、丰富性与 handoff	7
5.1 本章小结	9
6 总结与延伸	9

1 课程定位：为什么这一讲要从 Self-Play 讲起

Noam Brown 这一讲的核心不是“多放几个 agent 就更强”，而是把多智能体系统放回到一个更严格的理论与系统背景中：当问题本身具有对抗性、合作性或者混合动机时，智能体之间的交互关系本身就构成了学习信号。课程先用 AlphaGo 的类比说明一条更普遍的路径：先在高质量人类数据上预训练，再在推理阶段投入更多计算，最后借助递归式自我改进（recursive self-improvement）或自我对弈（self-play）把系统推向更强的策略。

这一讲的重要价值在于，它并不把 multi-agent AI 只理解成“多个聊天机器人互相商量”。相反，它把多智能体学习分成三层：

- 在零和或近似零和环境中，如何通过 self-play 学到接近 minimax equilibrium 的稳定策略。
- 在存在隐藏信息、联盟、承诺和信任成本的环境中，为什么单纯的单智能体 RL 视角会失效。
- 在 LLM 时代，如何用多 agent scaffold 把多样性、延迟和 handoff 设计成系统特性，而不是后处理补丁。

The AlphaGo Analogy

Step 1: Pretrain on high-quality human data

Step 2: Enable large-scale inference compute

Step 3: Recursive Self-Improvement (Self Play)

图 1: 课程用 AlphaGo 类比说明 multi-agent AI 的递进路径：预训练、高推理计算与递归式自我改进。

2 从自我对弈到均衡：零和博弈里的基本理论

在有限两人零和博弈中，self-play 之所以值得研究，是因为它提供了一个可以收敛到稳定解的学习范式。对任意策略 π 与对手策略 π' ，设收益函数为 $U(\pi, \pi')$ ，则理想目标是寻找 minimax equilibrium：

$$\pi^* \in \arg \max_{\pi} \min_{\pi'} U(\pi, \pi').$$

如果博弈满足零和结构且双方都有足够的记忆与计算，sound self-play algorithm 可以通过反复自我博弈逼近这一均衡。这里的关键不是“打赢当前自己”，而是让策略在面对任意对手时都具有稳定的最坏情形保证。

课程用 poker 和 rock-paper-scissors 来强调这一点：在这些环境里，单次胜率不等于策略质量，真正重要的是是否进入了没有明显 exploitable weakness 的区域。也正因为如此，fictitious play、regret matching 和 hedge 这类方法成为后续分析的主线。

2.1 Fictitious Play、Regret Matching 与 Hedge

Fictitious play 的直觉是：把对手过去的行为当作经验分布，然后对这个经验分布做 best response。它简单，但在复杂环境中往往收敛慢，且对最后一次迭代不够友好。

Regret matching 则更接近“后悔最小化”的语言。若在第 t 轮采取动作 a_t ，动作 a 的累计外部后悔可写作

$$R_t(a) = \sum_{\tau=1}^{t-1} (u_{\tau}(a) - u_{\tau}(a_{\tau})).$$

更新时只保留正后悔并进行归一化：

$$\pi_t(a) = \frac{\max(R_t(a), 0)}{\sum_{a'} \max(R_t(a'), 0)}.$$

其含义很直接：如果某个动作长期比当前选择更好，那么它在下一轮应获得更高概率；如果它并没有带来正向收益，则不应被放大。Hedge 则把这个思想写成指数加权形式：

$$\pi_{t+1}(a) \propto \pi_t(a) \exp(\eta \hat{r}_t(a)),$$

其中 $\hat{r}_t(a)$ 是当前轮的估计回报， η 是学习率。Hedge 的优点是平滑、可分析，缺点是需要更小心地处理步长与方差。

方法	核心思想	优点	局限
Fictitious play	对手经验分布上的 best response	直观、理论简单	收敛慢，最后一次迭代弱
Regret matching	按正后悔分配下一步概率	与博弈论联系紧密	需要处理噪声与方差
Hedge	指数加权多臂更新	稳定、平滑	对步长敏感

表 1: 课程中出现的三类典型多智能体学习更新。

Minimax Equilibrium

Minimax Equilibrium: a set of strategies in which no player can improve by deviating

In two-player zero-sum games, playing a minimax equilibrium ensures you will not lose in expectation

Exploitability: How much we'd lose to a best response

	Round 1	Round 2	Round 3
Us			
Best Response			

Our Exploitability = 1

图 2: Minimax equilibrium 的直观解释：在零和环境里，理想策略不是“偶尔赢很多”，而是“面对任意对手都不容易被剥削”。

3 为什么不完全信息博弈更难

课程明确指出，不完全信息游戏会让很多在 fully observed setting 中成立的直觉失效。扑克、Diplomacy 以及许多现实交互任务都包含隐藏信息、承诺、联盟与误导，因此学习者不能只看“动作是否最优”，还必须建模 belief、communication 和 opponent modeling。

这里的关键困难有三个：

- **信息缺失：**策略需要在不完全观测下行动，而不是依赖全局状态。
- **互相适应：**对手并不是静态环境，而是在持续学习。
- **最后一次迭代问题：**许多算法平均策略表现好，但最后一轮策略仍可能脆弱。

这也是为什么 Brown 特别强调“sound self-play algorithm”与“new last-iterate algorithms”。在复杂对抗环境中，策略不是只要均值收敛就够了，系统还要能在单次部署中表现稳定。

PPO in Rock-Paper-Scissors




图 3: PPO 在 Rock-Paper-Scissors 中的示意, 说明在简单对抗环境里也可以看到策略学习与均衡行为的关系。

4 从博弈到真实系统: Diplomacy、DORA 与人类环境

课程中一个重要转折是: 多智能体 AI 不应只被局限在“两个 agent 对打”。在 Diplomacy 这类任务中, support 是关键, 联盟和承诺比纯粹的局部动作更重要。No-press Diplomacy 的研究表明, 如果智能体可以在无语言协议下学习合作与竞争, 它们可能会发现人类未必显式设计出的策略结构。

DORA: No-press Diplomacy from Scratch [1]

- DORA learns no-press Diplomacy through self-play
 - Similar to AlphaZero
- Performance in 2-player no-press Diplomacy:
 - **Win rate: 86.5% $\pm$ 6.1%** vs human experts
- Performance in 7-player no-press Diplomacy:



1x $\downarrow$ vs 6x $\rightarrow$	DipNet [24]	SearchBot [11]	DORA	HumanDNVI-NPU
DipNet [24]	-	0.8% $\pm$ 0.4%	0.0% $\pm$ 0.0%	0.1% $\pm$ 0.0%
SearchBot [11]	49.4% $\pm$ 2.6%	-	1.1% $\pm$ 0.4%	0.5% $\pm$ 0.2%
DORA	22.8% $\pm$ 2.2%	11.0% $\pm$ 1.5%	-	2.2% $\pm$ 0.4%
HumanDNVI-NPU	45.6% $\pm$ 2.6%	36.3% $\pm$ 2.4%	3.2% $\pm$ 0.7%	-

[1] [Bakhtin, Wu, Lerer, Brown. NeurIPS 2021]

图 4: DORA 从 scratch 学习 no-press Diplomacy 的方式, 体现出多智能体学习不仅是博弈算法问题, 也是策略与协作结构设计问题。

这里有一个对 Agentic AI 特别重要的观点：有些任务中，人类并不是外部评测器，而是环境的一部分。换言之，agent 需要把人类的偏好、交互节奏、沟通习惯和信任机制纳入策略空间。CICERO 在 Diplomacy 和 Hanabi 中的结果说明，若要让系统和人类协作，策略空间必须同时包含语言、承诺与合作。

CICERO Plays with Humans

- We entered CICERO anonymously in an **online natural language Diplomacy league**
- CICERO placed in the top 10% of players, and **2nd of 19** players who played at least 5 games
 - Achieved **more than 2x the average human score**

Rank	Avg Score	# Games
1	35.0%	11
2	25.8%	40
3	24.5%	6
4	22.7%	8
5	21.0%	5
...		
19	3.0%	6
20	2.6%	7

图 5: CICERO 的人机协作场景说明，LLM agent 的能力不只在于决策，也在于与人类共同维持协作秩序。

Results in Hanabi

[Hu et al. arXiv-22]



	w/ Human Experts	w/ BR-BC	w/ piKL3
All Testers (56)	14.54 ± 1.47	16.73 ± 1.27	17.18 ± 1.28
Newcomer (2)	0.00 ± 0.00	0.00 ± 0.00	10.00 ± 7.07
Beginner (17)	9.12 ± 2.65	14.82 ± 2.42	14.47 ± 2.63
Intermediate (23)	14.57 ± 2.27	19.48 ± 1.64	18.52 ± 1.79
Expert (14)	23.14 ± 0.60	16.93 ± 2.41	19.29 ± 2.14

图 6: Hanabi 的结果强调：在部分可观测、强协作的任务中，communication 和共同信念往往比单步最优动作更重要。

5 LLM 多智能体协作：延迟、丰富性与 handoff

当课程转向 LLM 时，Brown 的重点变成了：如何把多智能体思想变成系统设计原则，而不是只停留在博弈论。OpenAI 的 o1 到 o3 路线被用来说明，强化推理、更多采样与 consensus 可能带来性能提升，但代价是延迟和计算开销。多智能体系统因此必须在三个维度之间取舍：

- **Latency**：答案要快，还是可以慢一点换更稳的结果。
- **Diversity**：多个 agent 的不同视角是否真的能减少盲点。
- **Scaffold**：什么时候让一个 agent 把任务 hand off 给另一个 agent，比继续单线程推理更有价值。

Multi-Agent AI: Latency

- CoT is inherently **serial**
 - Latency eventually becomes a bottleneck
- Other test-time scaling techniques are **parallel**
 - Best-of-N / consensus
 - Lower latency, but less compute-efficient




图 7: 多智能体系统里的 latency 约束：系统质量常常提升，但推理时延也会上升。

Multi-Agent AI: Diversity

- Reasoning models *can* multiply large numbers, but why do that?
- Diversity is a strength
 - Can use the best model for the particular query
- “Routing” is already a form of multi-agent AI




图 8: 多样性是 multi-agent AI 的核心资产之一: 不同采样轨迹、不同角色和不同上下文, 可能带来更强的整体决策。

Multi-Agent Collaboration Scaffolds Today




图 9: 今日的多智能体协作 scaffold: 手动分工、角色化交流与任务 handoff 已经成为工程上最现实的落点。

Brown 的最终判断并不夸张: field 仍然很早, 但多智能体 AI 已经从“可以讨论的概念”变成“可以用于构建系统的工程范式”。真正有潜力的路线, 不是把一个强模型无限放大, 而是让多个模型在合适的通信结构里互补。

5.1 本章小结

本讲给出的核心信息可以压缩成三句话。第一，self-play 的价值不在于“自我循环”本身，而在于它提供了一个可分析、可收敛的均衡学习框架。第二，一旦任务从零和走向不完全信息、合作与人机交互，单智能体 RL 的直觉就不够了，必须显式建模 communication、belief 和 support。第三，在 LLM 时代，多智能体协作更像系统设计问题：延迟、diversity 和 handoff 的权衡，决定了它到底只是一个 demo 还是一个可部署框架。

6 总结与延伸

这讲最值得延伸的方向有两个。其一是把博弈论中的 regret minimization 和现代 LLM 推理中的 self-consistency、best-of-N、debate 连接起来，研究它们是否可以共享同一套理论语言。其二是把 Diplomacy、Hanabi、协作写作和工具使用统一到“人机共生环境”里：在这类任务中，agent 不再只优化单步 reward，而是在长期交互中维护关系、可信度和分工结构。

如果把这一讲放回 Agentic AI 课程的大图景里，它其实是在回答一个很实用的问题：什么时候一个系统应该独立决策，什么时候应该找别的 agent，什么时候应该把人类放回回路中。这个问题在后续的编排、评测和科学发现章节里会反复出现。