

UCB CS294/194-196 Agentic AI Fall 2025

第 08 讲: Predictable Noise in LLM

基于公开视频、slides、字幕与官方 reading 整理

目录

1	课程问题: 为什么评测噪声现在成了核心议题	2
2	小样本时代的统计学: 显著性、功效与 paired comparison	2
3	Predictable Noise: 噪声为什么不是纯随机的	4
4	Eval-Arena 与 benchmark 建构者的视角	6
5	从 beta 分布到噪声区间	7
5.1	本章小结	8
6	总结与延伸	8

1 课程问题：为什么评测噪声现在成了核心议题

Sida Wang 这一讲从一个很现实的判断出发：LLM 时代的 benchmark 越来越小，而任务又越来越接近真实应用，因此“提升几个百分点”这件事已经不能直接等价于“模型真的变强了”。在 ImageNet 时代，十万级测试集加上单一准确率已经足够稳定；但在 HumanEval、SWE-bench、LiveCodeBench、T-Bench 以及各种 agentic benchmark 里，样本数更小，任务更开放，输出更长，评测过程更复杂，噪声就开始主导观测结果。

这不是说统计显著性不再重要，而是说显著性本身必须和任务结构一起看。课程把这个问题拆成两部分：第一，如何用标准统计工具理解噪声、方差和置信区间；第二，如何识别“可预测的噪声”(predictable noise)，也就是那些和 benchmark 设计、题目类型、模型能力曲线相关联的系统性波动。

A bit of reflection on evaluation

Do 10% better on ImageNet, and no more doubts about deep learning

- necessary condition: no doubt about statistical significance

Do we similarly trust our current LLM evaluations?

Many papers report 2-10% improvements on HumanEval, or a few % on SWEbench

How can we interpret this?

- old answer is statistical testing: 2.5% on HumanEval is not stats significant

图 1: 课程把 LLM 评测与 ImageNet 时代的经验作对照：小幅提升在小测试集上不一定有同样的解释力。

2 小样本时代的统计学：显著性、功效与 paired comparison

在最基础的一层，假设我们对某个 benchmark 的准确率做了 n 次独立评测，得到估计值

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i, \quad x_i \in \{0, 1\}.$$

其中， x_i 表示第 i 题是否答对， n 是样本数， $\hat{p}$ 是经验准确率。如果把每道题视为伯努利试验，那么标准误差可以写成

$$\text{SE}(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}.$$

这条公式在课程里不是为了“回顾统计课”，而是为了说明一个事实：当 n 很小的时候，即使平均准确率有一点点提升，误差条也可能覆盖掉这点提升。换句话说，很多论文里看上去“明显更好”的结果，可能只是抽样波动。

Test set sizes are now much smaller than MNIST

Deep learning was measured and validated by MNIST and ImageNet

Testset sizes: MNIST: **10k**, ImageNet: **100k**

LLM multiple choice: MMLU ~10k

Generative test-based eval (generate a short program)

HumanEval: 164, MBPP+: 378, CruxEval: 800, DS-1000: 1000, DMC: 165,
LiveCodeBench ~1000, Alder: 225

Agent Evals (often need 100k+ tokens)

SweBench: 2.3k, -Verified: 500, -lite: 300, -multimodal: 517

T-Bench: 80

图 2: 测试集规模的变化: agentic benchmarks 和 code benchmarks 的样本数往往比经典视觉基准小得多。

课程接着强调 paired comparison 的好处。若两个模型在同一批题目上进行对比, 记二者在第 i 题上的结果分别为 X_i 和 Y_i , 则差值

$$D_i = Y_i - X_i$$

的均值 $\bar{D}$ 比直接比较两个独立估计更稳, 因为

$$\text{Var}(\bar{D}) = \frac{1}{n} \text{Var}(D_i) = \frac{1}{n} (\text{Var}(X_i) + \text{Var}(Y_i) - 2\text{Cov}(X_i, Y_i)).$$

其中, X_i 和 Y_i 分别表示两个模型在第 i 题上的 0/1 结果, 协方差项越大, paired 设计带来的降噪效果就越明显。当两个模型在很多题目上的成败模式高度相关时, $\text{Cov}(X_i, Y_i)$ 会显著降低方差, 这就是 paired evaluation 的统计优势。课程的实际建议不是“永远做 paired”, 而是: 如果你能让两个模型在同样的题目、同样的随机性条件下比较, 就尽量做 paired; 如果不能, 就要明确说出你的独立性假设。

The super-population (basic stats, Miller 2024)

- With sample questions from a super population, then the mean and variance of the population can be estimated from these sample

On a evaluation, we compute the average of all N questions to get the mean accuracy

$$\bar{A} := \frac{1}{N} \sum_{i=1}^N A(x_i) \approx \mathbb{E}_x[A(x)].$$

The estimated variance of A and standard error (SE) of the mean $\bar{A}$ are respectively

$$\begin{aligned} \text{Var}_x[A(x)] &\approx \frac{1}{N} \sum_{i=1}^N (A(x_i) - \bar{A})^2, \\ \text{SE}(A) &= N^{-1/2} \cdot \text{Var}[A]^{1/2}. \end{aligned}$$

图 3: 课程用 super-population 视角解释评测：单次观测是总体分布的一个样本，而不是宇宙真理。

3 Predictable Noise: 噪声为什么不是纯随机的

这一讲最重要的概念是 predictable noise。直观地说，benchmark 的噪声并不完全像均匀白噪声那样随机分布，而是与题目难度、问题类型、模型整体准确率以及任务结构有关。换句话说，噪声不是“模型外面飘着的背景音”，而是 benchmark 本身的一部分。

课程给出的一个关键分解是总方差分解：

$$\text{Var}(Y) = \text{Var}(\mathbb{E}[Y | Z]) + \mathbb{E}[\text{Var}(Y | Z)],$$

其中 Z 表示题目特征、任务类别或 benchmark 的上下文变量。第一项是可预测部分，第二项是残余噪声。这个分解的意义在于：如果不同任务族之间的均值差异很大，那么 benchmark 的整体波动有一部分其实是可以解释的，不应该被简单归类成“统计误差”；反过来，如果残余噪声占主导，那么即使模型平均分更高，也未必代表稳定的能力跃迁。

Paired comparison

Paired comparison. When we have two models A and B , we can consider the paired standard deviation $\text{Var}_{x,\epsilon}[A(x, \epsilon) - B(x, \epsilon)]$, which also satisfy the law of total variance on $A - B$,

$$\text{Var}_{x,\epsilon}[A - B] = \text{Var}_x[\text{E}_\epsilon[A - B]] + \text{E}_x[\text{Var}_\epsilon[A - B]]. \quad (11)$$

This formula allows us to compute from the samples directly.

$$\text{Var}_{x,\epsilon}[A - B] = \text{Var}_{x,\epsilon}[A] + \text{Var}_{x,\epsilon}[B] - 2\text{Cov}_{x,\epsilon}[A, B] \quad (12)$$

$$= \text{Var}_{x,\epsilon}[A] + \text{Var}_{x,\epsilon}[B] - 2\text{Cov}_x[\text{E}_\epsilon[A], \text{E}_\epsilon[B]]. \quad (13)$$

By the law of total covariance, $\text{Cov}_{x,\epsilon}[A, B] = \text{Cov}_x[\text{E}_\epsilon[A], \text{E}_\epsilon[B]] + \text{E}_x[\text{Cov}_\epsilon[A, B]]$ where the second term is 0 since different random samples are independent.

图 4: paired comparison 的直觉解释：共享同一批题目时，差值的方差通常比两个独立估计的方差更小。

课程还讨论了一个很容易误解的点：**我们不能简单通过“加大 signal”来消除噪声**。在很多 benchmark 上，题目规模、题目形式与模型能力之间存在内在耦合，尤其是在 agentic benchmark 里，一些任务虽然样本少，但每个样本都很信息密集，因而单样本的方差并不低。即便你把数据量增加一点，评测噪声也不一定线性下降，因为任务本身可能不满足独立同分布的理想条件。

Predictable noise

$\text{SE}(A) \sim \text{SE}(A-B)$
are roughly similar
-> correlation ~ 0.5

benchmark_id	size	models	SE(A)	SE(A-B)	corr(A,B)
CRUXEval-input-T0.2	800	37	<u>1.7</u>	<u>1.8</u>	<u>56</u>
CRUXEval-input-T0.8	800	31	<u>1.6</u>	<u>1.8</u>	<u>69</u>
CRUXEval-output-T0.2	800	37	<u>1.7</u>	<u>1.6</u>	<u>64</u>
CRUXEval-output-T0.8	800	31	<u>1.7</u>	<u>1.6</u>	<u>75</u>
DS1000	1000	105	<u>1.3</u>	<u>1.5</u>	<u>46</u>
agi_english	2546	35	<u>0.93</u>	<u>1.1</u>	<u>25</u>
arc_challenge	1165	38	<u>1.4</u>	<u>1.3</u>	<u>62</u>
gsm8k	1319	37	<u>1.1</u>	<u>1.3</u>	<u>38</u>
hellaswag	10042	36	<u>0.41</u>	<u>0.26</u>	<u>77</u>
humaneval	164	78	<u>3.5</u>	<u>3.7</u>	<u>47</u>

图 5: Predictable noise 的核心直觉：不同 benchmark 族和不同模型能力区间会呈现系统性的噪声模式。

4 Eval-Arena 与 benchmark 建构者的视角

课程给出的实践型案例是 Eval-Arena。这里的重点不是某个单独分数，而是整个评测套件如何让研究者看到噪声的形状。Eval-Arena 试图把 docs、code、agentic tasks 和不同模型参与者放在统一框架中，从而帮助分析：

- 某个 benchmark 的噪声水平到底有多大；
- 噪声是否与整体准确率 A 相关；
- 采用 paired 设计之后，方差是否真正下降；
- 不同 task family 的 signal-to-noise ratio 是否值得继续投入。

Empirical probabilities follow a Beta distribution

Once performance is good, then the bimodal $\sim \text{Beta}(a, 1-a)$




图 6: 经验分布可以用 Beta 族近似，这让我们能用更直观的方式理解成功率与噪声的关系。

更实际的结论是：benchmark builder 应该把“噪声区间”当作交付物的一部分，而不是只给一个点估计。一个比较负责任的报告至少应该包括：

1. 点估计和置信区间；
2. paired / unpaired 设计说明；
3. 重复采样或 bootstrap 的不确定度；
4. benchmark 题型与模型族之间的噪声关系；
5. 与过去版本相比，噪声是否改变。

Signal to noise

The noise values allows us to interpret reported results. To get a sense of the quality of the benchmark, we need signal to noise ratio.

Signal: the gain from doubling the size of model in each series

Noise: implied standard deviation by statistical testing (same as bootstrapping)

$\text{sig/noise} = |A-B| / \text{SE}(A-B)$

sig/noise < 2: cannot reliably measure the improvement from doubling model size. True on most **code benchmarks!** [examples of inversion](#)

Simple multiple choice benchmarks have much better signal to noise ratio than complex generation benchmarks

benchmark_id	size	sig/noise
mmlu	14042	13.2
tqa	11313	12.6
gsm8k	1319	7.1
hellaswag	10042	6.4
nq	3610	5.9
agi_english	2546	5.1
CRUXEval-output	800	3.2
DS1000	1000	3.0
arc_challenge	1165	2.7
mbpp	378	1.9
CRUXEval-input	800	1.9
piqa	1838	1.7
lcb_codegen	400	1.6
mbpp+	378	1.6
humaneval	164	1.1
siqa	1954	0.93
humaneval+	164	0.50

图 7: 课程给出的 benchmark size 与 signal/noise 的对照，强调小规模基准并不天然等于高质量基准。

Paired comparisons




图 8: paired comparisons 仍然是最实用的降噪工具之一，但它的收益取决于任务结构是否允许共享样本。

5 从 beta 分布到噪声区间

课程把一些实际观测结果画成 Beta 分布族，是为了说明“成功率”本身也应被看作随机变量，而不是固定常数。若在某个 benchmark 上观察到 s 次成功、 f 次失败，并给定先验 $\text{Beta}(\alpha, \beta)$ ，则后验为

$$p \mid s, f \sim \text{Beta}(\alpha + s, \beta + f).$$

这让我们可以自然地给出不确定度区间，而不是只报一个最优点。对于小 benchmark 来说，这一点尤其关键，因为一次新结果可能只是在后验分布里移动了一小步，并不足以说明模型能力发生了结构性变化。

在实际工程里，课程建议不要只问“这个模型是不是更好”，而要问：

- 在多大概率下它更好；
- 在什么题型上更好；
- 噪声区间是否已经大于预期增益；
- 是否需要重新设计 benchmark 本身。

这使得评测从一次性排名转向了一种更接近科学实验的过程。

5.1 本章小结

这一讲的结论可以概括为：LLM 时代的评测问题不是“统计学失效了”，而是“统计学必须进入 benchmark 设计本身”。当 benchmark 变小、任务变难、输出变长时，噪声、方差和相关性就不再是背景知识，而是决定结论是否可信的核心变量。paired comparison、super-population 视角、Beta 后验和噪声区间，都是帮助我们“把一个分数”变成“一个可解释结论”的工具。

6 总结与延伸

如果把这讲扩展到 Agentic AI 的真实应用中，最重要的启发是：评测不应该只是模型发布之后的最后一步，而应该是系统开发的一部分。一个 agent 系统如果很难稳定复现 benchmark 提升，那么它在真实部署中同样可能不稳定。反过来，若 benchmark builder 能把噪声显式建模，那么研究者就能更早判断某个方法究竟是在改进能力，还是只是在利用评测偶然性。

因此，这讲不是在教“怎么算显著性”这么简单，而是在教如何把显著性、噪声与 benchmark 结构一起理解。对后续的系统、科学发现和 agent 设计章节，这种思维方式都很重要。