

课程讲义

Multimodal Agents: From Perception to Action

CS294/194-280: Advanced Large Language Model Agents

Caiming Xiong, Salesforce AI Research

中文教材化讲义 / Harness Build



The banner is split into two main sections. The left section has a dark blue background and features a circular portrait of Caiming Xiong, a man with glasses and a light blue shirt. Below the portrait, his name 'CAIMING XIONG' is written in white, followed by his title 'SVP OF AI RESEARCH & APPLIED RESEARCH' and the Salesforce logo. The right section has a lighter blue background. At the top, it says 'UC Berkeley Center for Responsible, Decentralized Intelligence'. Below that, the course title 'Advanced Large Language Model Agents MOOC' is displayed. The main title 'Multimodal Agents – From Perception to Action' is prominently featured in the center. At the bottom, the date 'March 17th, 2025' is shown. A decorative pattern of small white dots is visible in the bottom right corner of the right section.

UC Berkeley Center for Responsible, Decentralized Intelligence

Advanced Large Language Model Agents MOOC

Multimodal Agents – From Perception to Action

March 17th, 2025

CAIMING XIONG
SVP OF AI RESEARCH & APPLIED RESEARCH
salesforce

课程页: <https://rdi.berkeley.edu/adv-llm-agents/sp25>

录播: https://www.youtube.com/live/n__Tim8K2IY

Slides: https://rdi.berkeley.edu/adv-llm-agents/slides/Multimodal_Agent_caiming.pdf

核心 readings: OSWorld / AGUVIS

目录

1 本讲学习目标	2
2 从 benchmark taxonomy 到真实 computer-use agents	2
2.1 为什么 “computer use” 不是普通 web automation 的别名	2
2.2 OSWorld: 真实 computer environment + execution-based evaluation	3
3 OSWorld 的 baseline 结果说明了什么	4
3.1 当前 multimodal agents 仍远不是可靠的 digital assistants	4
3.2 这里的 benchmark distinction 不能被抹平	5
4 训练瓶颈: 为什么 agent data 比语言数据更稀缺	5
4.1 AgentTrek: 从教程文本到可回放轨迹	5
5 从 CoT 到 CoTA: 为什么 multimodal action model 需要 action-call capability	6
5.1 TACO / CoTA 的核心思想	6
5.2 质量比数量更重要	7
6 AGUVIS: Unified Pure Vision Agents	8
6.1 为什么要反对异构文本 GUI 表示	8
6.2 两阶段训练与 inner monologue	9
7 长视频与多模态 agent memory	10
7.1 xGen-MM-Vid: 为什么长视频首先是 memory 问题	10
7.2 GenS: 把 frame selection 变成条件生成	10
8 本章小结与跨讲联系	11
9 复习题	11
10 深入思考题	12
11 延伸阅读	12

1 本讲学习目标

本讲的标题是“从感知到动作”，但真正要回答的问题是：当 agent 进入真实 computer environment 之后，感知、grounding、reasoning、action 与 memory 应该如何被系统性设计。读完后，读者应当能够：

- 区分 **web benchmarks**、**OS / computer-use benchmarks**、**GUI grounding benchmarks** 和 **long-video benchmarks** 的任务对象与评测哲学。
- 解释为什么 **OSWorld** 把 task config、execution-based evaluation 和多 app workflows 放在 benchmark 的中心。
- 说明 **AgentTrek**、**CoTA/TACO** 这类数据与训练方案分别在解决什么瓶颈。
- 理解 **AGUVIS** 为什么要强调 pure-vision observation、统一 action space 和 inner monologue。
- 解释 **xGen-MM-Vid** 与 **GenS** 如何把 long-video memory / grounding 连接回 multimodal agent 的设计问题。

2 从 benchmark taxonomy 到真实 computer-use agents

2.1 为什么“computer use”不是普通 web automation 的别名

讲者开篇用一组 benchmark taxonomy 做了很重要的铺垫：coding agents、web agents、mobile agents、physical agents。这个 taxonomy 不是为了罗列论文，而是为了说明 **computer tasks 往往跨越多个 app、多个界面和多个状态通道**。例如更新账本、改代码、处理文件、查网页、切换表格和浏览器，这些都不是单一网站里的 click sequence。

因此，“computer use”比“web navigation”更广。它的 environment 包括操作系统、任意 app、文件 I/O、terminal 输出、跨窗口切换和多 app workflow。很多旧 benchmark 要么只有 demonstrations，要么只有静态状态，要么只覆盖某个子域，于是很难真正回答：**agent 是否能像人类那样在真实电脑上完成开放式任务？**

2.2 OSWorld: 真实 computer environment + execution-based evaluation

OSWorld

the first scalable, real computer environment

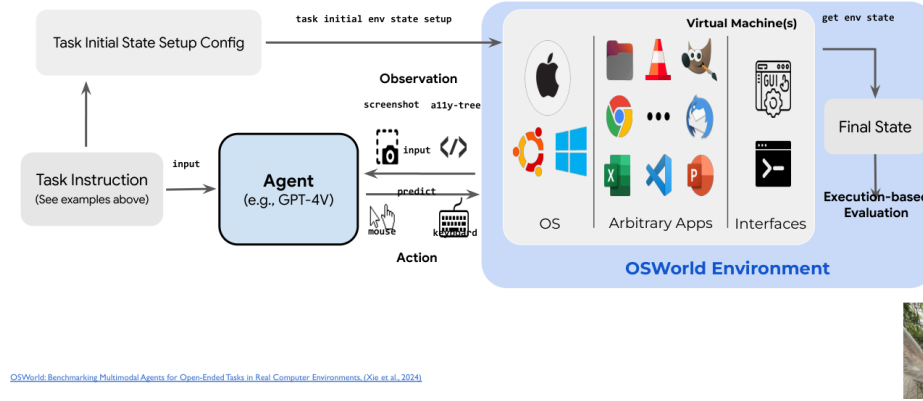


图 1: OSWorld 把 task instruction、virtual machine、observation 与 execution-based evaluation 放在同一个真实 computer environment 中。

OSWorld 的核心贡献，是把 environment realism 和 evaluation reliability 一起做出来。它不是只给几段轨迹，而是提供：

- task initial state setup config，用于还原任务开始时的虚拟机状态；
- 统一的真实 computer environment，可容纳 arbitrary apps；
- execution-based evaluation script，用于判断任务是否真正完成；
- 覆盖 open domains、多 app workflows、OS file I/O 的 369 个真实任务。

这使得任务可以自然写成一条 interaction loop：

Agent Observation



Agent can receive natural language instruction, screenshots, the a11y tree, and customized streams such as terminal outputs.

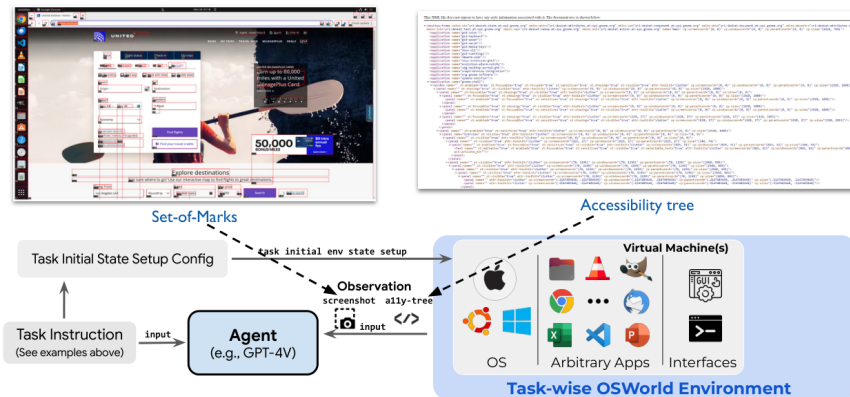


图 2: OSWorld 中 agent 的观测可以同时包括 screenshot、a11y tree 和其它 environment streams。

Agent Interaction Loop



The interaction loop between the agent and the environment repeats until an action that marks termination.

Task Instruction: monitor the system CPU for 30s and output the results





图 3: Instruction、observation、action、termination 和 evaluation 共同构成 OSWorld 的 interaction loop。

教材化地看, OSWorld 的最重要贡献在于: 它把 reward / success 从“字符串匹配”改成了 **execution-based correctness**。可以写成

$$R(\tau) = \mathbf{1}[\text{Eval}(s_T, \tau) = \text{success}],$$

其中 τ 是整条 trajectory, s_T 是最终环境状态, Eval 是 task-specific 的 evaluation function。这样做的意义是, 它允许存在 *multiple correct trajectories*, 而不必假设每个任务只有一种唯一文本答案。

为什么这个区别很关键

很多 computer tasks 的“答案”不是一句文本, 而是某个文件是否被改对、某个应用状态是否被正确设置、某个工作流是否真的执行完。没有 execution-based evaluation, 就无法严格比较 agent 与 human workflows。

3 OSWorld 的 baseline 结果说明了什么

3.1 当前 multimodal agents 仍远不是可靠的 digital assistants

OSWorld reading 和 lecture slides 都给出同一个结论: 当前最强 agent 与人类之间有非常大的差距。论文摘要里 humans 大约能完成 72.36% 的任务, 而强 baseline 约为 12.24%。这个 gap 说明问题并不是“模型偶尔点错按钮”, 而是系统级能力远未成熟。

Result analysis of LLM/VLM agent baselines



Higher screenshot resolution typically leads to improved performance




图 4: OSWorld baseline analysis: 分辨率、history 与 observation mode 都有影响，但距离 robust computer use 仍非常远。

slides 的分析特别值得展开成教材。它指出：

- 更高截图分辨率通常有帮助，因为很多 GUI 决策依赖细粒度视觉线索。
- 更长的 text-based trajectory history 通常也有帮助，因为它改善了状态跟踪；但 screenshot-only history 的收益没那么稳定，而且会带来效率问题。
- 模型在不同 OS 上的表现相关性很强，这说明它们遇到的是更底层的 **GUI grounding** 与 **operational knowledge** 问题，而不只是某个系统特有 API 的问题。

3.2 这里的 benchmark distinction 不能被抹平

这一段最容易被错误总结成“大家都在做 GUI agents”。这不够精确。必须区分：

- **Mind2Web / WebArena / VisualWebArena** 主要是 web-domain agents；它们强调网页环境、HTML 或视觉网页线索。
- **OSWorld** 是 open-ended real computer environment；它跨 app、跨 OS，并有明确的 execution-based setup 和 evaluation。
- **ScreenSpot** 一类数据更偏 GUI grounding benchmark，本身不等于 interactive environment。
- **Browser Use / AndroidWorld / Mind2Web-live** 等则在 online evaluation 维度补充特定平台或部署场景。

这个 distinction 很重要，因为它直接影响模型应当优化什么能力：是网页导航、跨 app workflow、视觉 grounding，还是实时 online robustness。

4 训练瓶颈：为什么 agent data 比语言数据更稀缺

4.1 AgentTrek：从教程文本到可回放轨迹

讲者随后把重点转向训练数据。问题很直接：LLM 的成功高度依赖海量现成文本，但 computer-use agents 需要的是带环境状态与动作序列的 trajectories，这类数据没有自然规模化的网页爬取版本。

于是 **AgentTrek** 的思路变得自然：既然互联网有大量 step-by-step GUI tutorials，为何不把它们转成可用的 agent training source？




图 5: AgentTrek 从 web tutorials 中抽取 task structure，再用 guided replay 合成 trajectories。

它的关键不在“把教程复制给模型”，而在于 **guiding replay**：先从教程中提炼平台、环境、任务描述和关键步骤，再把这些信息转进目标环境，合成更接近真实 interaction 的轨迹。这种方法的价值在于：

- 教程本身已经包含了人类如何完成 GUI tasks 的结构性先验。
- GUI tutorials 广泛存在于互联网，因此有潜在的规模优势。
- 它能把 *knowledge-rich instructions* 转成 *actionable trajectories*。

但它也有边界。教程经常针对特定版本、特定布局、特定语言环境；一旦 replay 环境变化，distribution shift 就会出现。因此 AgentTrek 更像一种 **data bootstrapping mechanism**，而不是终极答案。

5 从 CoT 到 CoTA: 为什么 multimodal action model 需要 action-call capability

5.1 TACO / CoTA 的核心思想

slides 接着提出一个尖锐问题：多模态 LLM 自身是否需要 **action call capability**？如果答案是肯定的，那么光靠 few-shot prompting 往往不够，因为模型需要学的不是“如何说出一个理由”，而是“如何在 reasoning 与 action 之间切换”。

Synthetic CoTA Generation Pipeline

图 6: Synthetic CoTA pipeline 同时生成 thought 和 action, 使模型学会 multimodal reasoning with tools/actions。

这就是 TACO / CoTA 的设计直觉。与普通 Chain-of-Thought 相比, 它不是只让模型生成 $t_{1:m}$ 这类 reasoning trace, 而是联合生成 $(t_{1:m}, a_{1:n})$:

$$\max_{\theta} \sum_{(x,t,a)} \log p_{\theta}(t_{1:m}, a_{1:n} | x).$$

这里 x 是多模态输入与任务指令, $t_{1:m}$ 是 thought tokens, $a_{1:n}$ 是 action sequence。直觉上, CoTA 让模型学到的不是“看完图后多解释一点”, 而是“什么时候该 reasoning, 什么时候该 call 一个 action, 动作之后如何继续 reasoning”。

```

1 sample multimodal task
2 generate thought-and-action trace
3 filter useless actions
4 finetune multimodal action model on CoTA data

```

5.2 质量比数量更重要

这一段的实验结论很值得教材化, 因为它提供了关于 agent training data 的一个普遍原则: **quality** » **quantity**。slides 指出, 小而高质量的 CoTA 数据集反而可能比混杂 Direct / CoT / CoTA 示例的大数据集更有效; 把 *action-useless* 数据过滤掉, 也会带来收益。

这个结论说明: 对 agent 来说, 数据是否真的对 **action grounding** 与 **deployment behavior** 有帮助, 比数据量本身更关键。很多普通视觉问答或纯描述性数据, 并不能自然转化为更强的 computer-use behavior。

6 AGUVIS: Unified Pure Vision Agents

6.1 为什么要反对异构文本 GUI 表示

Aguvis: Unified Pure Vision Agents for Autonomous GUI Interaction



- Heterogeneous textual GUI interface representation
→ **Unified Vision-based perception and action space for GUI Interaction**
- Limited visual grounding capability
→ **Improving visual action grounding capability through training**
- Perform “reactive” low-level actions directly without reasoning
→ **Explicit reasoning process / inner monologue**

Aguvis: Unified Pure Vision Agents for Autonomous GUI Interaction (Xu et. al, 2024)



图 7: AGUVIS 的立场是：直接在图像 observation 上做 GUI interaction, 而不是依赖 HTML / AXTree / XML 等异构文本表示。

讲者介绍 AGUVIS 的时候，重点不是模型规模，而是 problem formulation。它指出当前 GUI agents 常见的四个障碍：

- 依赖 HTML、AXTree、XML 等平台特有文本表示，导致 observation 不统一。
- action space 在 web、desktop、mobile 上异构，难以做跨平台学习。
- visual grounding 能力不足，导致模型知道该做什么却点不到正确目标。
- 很多方法只做 **reactive low-level actions**，缺乏显式 reasoning 与 planning。

AGUVIS 的回答是：既然用户本来就是看屏幕操作系统，那 agent 也应该优先以图像为主观测。于是它把动作抽象成统一形式

$$a_t = (\text{type}_t, x_t, y_t, \arg_t), \quad (x_t, y_t) = g_\theta(o_t, g, h_t),$$

其中 (x_t, y_t) 是屏幕空间中的 grounded target, g 是用户目标, h_t 是历史或 inner monologue。这个公式的重点不是数学复杂度，而是 **把 action grounding 统一到了视觉空间里**。

6.2 两阶段训练与 inner monologue

Two-Stage Training




图 8: AGUVIS 先学 GUI grounding, 再学 planning / reasoning, 这是一种明确的 curriculum design。

AGUVIS 的第二个关键设计是 two-stage training。原因是 GUI grounding 与 high-level planning 的优化目标不同：前者更像视觉定位与 element grounding，后者更像多步 decision making。如果一开始就混在一起训，模型很容易只学到局部 pattern，而学不到稳定的 reasoning policy。

slides 还特别强调了 inner monologue：

Analysis: Impact of Training Stages and Inner Monologue

- Both stages 1 and 2 contribute to Aguviz's performance.
- Inner monologue is crucial for both high-level reasoning and low-level action grounding.

Settings	ScreenSpot	Multimodal-Mind2Web			AndroidControl	
		Cross-Task	Cross-Website	Cross-Domain	High-Level	Low-Level
AGUVIS-7B	84.4	60.4	54.6	56.6	61.5	80.5
(a) w/o Stage 2	81.8	50.9	45.2	45.3	58.0	75.6
(b) w/o Stage 1	77.4	59.7	55.3	56.8	58.8	79.8
(c) w/o Stage 1 & 2	55.3	50.9	44.9	47.7	59.1	59.2
(d) w/o Inner Monologue	79.3	55.4	53.7	54.9	60.3	69.1

图 9: Inner monologue 不只是“多说两句”，而是连接高层 reasoning 与低层 grounding 的中间结构。

这点和很多读者的直觉相反。inner monologue 的作用不只是提升高层 reasoning，它还会改善低层 grounding。原因是：当模型显式写出自己正在寻找什么元素、当前屏幕上哪些区域相关、下一步想验证什么时，后续的坐标或元素选择就更是盲点操作。

一个常见误解

Pure-vision GUI agent 并不意味着“永远不需要文本”。它真正反对的是把不同平台的 HTML/AXTree/XML 当作不可替代的主表示，从而让 observation space 和 action space 在跨平台时失去统一性。

7 长视频与多模态 agent memory

7.1 xGen-MM-Vid: 为什么长视频首先是 memory 问题

讲者最后一部分表面上在讲 Video LLM，实则是在讨论 agent 的 **长程视觉记忆**。长视频任务和长程 agent 任务有一个共同困难：原始观测序列太长，不能原样喂给模型。于是 xGen-MM-Vid / BLIP-3-Video 的核心设计是通过 temporal encoder 把视频帧序列压缩成少量 token：

$$z_{1:K} = f_{\theta}(v_{1:T}), \quad K \ll T.$$

这里 $v_{1:T}$ 是原始帧序列， $z_{1:K}$ 是压缩后的 temporal tokens。直觉上，这相当于给长视频设计一个更高层的 memory representation。




图 10: xGen-MM-Vid 通过 temporal encoder 把长视频压缩成很少的视觉 token，从而把 memory 问题变成可计算问题。

这与 GUI / OS agents 的联系在于：**agent 不能无限保留所有原始 observation，它必须学会压缩、筛选和重访**。对 web tasks，压缩的是 history；对 long video，压缩的是 frame sequence；两者都在处理有限 context budget 下的 memory allocation。

7.2 GenS: 把 frame selection 变成条件生成

如果 xGen-MM-Vid 关注长视频 token compression, **GenS** 则更像是在解决 *instruction-conditioned frame selection*。slides 明确批评纯 CLIP-based sampling: 它难以捕捉 temporal relation, 也难以处理 multi-hop language reasoning。GenS 的做法是直接生成相关 frame spans 与其分数：

$$\hat{\mathcal{I}} = \{(i, r_i)\}_{i=1}^T, \quad r_i \in [0, 1].$$

其中 i 是帧索引或时间片, r_i 是与用户指令相关的置信分数。这种写法意味着 frame selection 不再只是 embedding similarity, 而是 **带语言条件的生成式 grounding**。

Generative Frame Sampler for Long Video Understanding



- Understanding long videos containing thousands of frames poses substantial challenge and computational burden to VideoLLMs
- How to efficiently sample representative frames from the original video sequence?

图 11: GenS 通过生成式方式预测 relevant frame spans, 而不是只做相似度检索。

教材化地看, GenS 的重要性在于: 它把 long-video grounding 明确纳入了 agent 设计问题。因为很多未来的 multimodal agents 不只看单张截图, 而是需要在长视频、桌面录屏或复杂交互历史中定位与目标相关的时序片段。

8 本章小结与跨讲联系

本讲把 multimodal agents 的问题分成六个维度: environment、data、models、reasoning、grounding、memory。这个分法非常有启发性, 因为它防止我们把一切都归结为“换个更强模型”。

与上一讲相比, 这一讲进一步把问题从 **web agents** 推向 **computer-use agents** 与 **GUI agents**。上一讲强调 benchmark realism、inference-time search 和 synthetic tasks; 这一讲则补上了 execution-based OS benchmarks、pure-vision grounding、action-call training 与 long-video memory。两讲放在一起, 才构成一套较完整的 multimodal agent textbook view。

9 复习题

1. 为什么 OSWorld 比只有 demonstrations 的数据集更适合评估 computer-use agents?
2. execution-based evaluation 与字符串匹配相比, 最大的优势是什么?
3. AgentTrek 的 guided replay 在数据生成中解决了什么问题?
4. CoTA 与普通 CoT 的关键差别是什么?
5. AGUVIS 为什么强调 pure-vision observation 和 unified action space?
6. xGen-MM-Vid 与 GenS 分别想解决长视频中的什么瓶颈?

10 深入思考题

1. 如果一个模型在 OSWorld 上分数低，但在 GUI grounding benchmark 上分数高，你会如何诊断它的问题？
2. inner monologue 在 deployment-time 是否一定值得保留？在什么场景下它的成本可能超过收益？
3. 长视频 frame selection 与 web-agent search 能否被统一看作对有限预算的 inference-time allocation？

11 延伸阅读

- OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments.
- AGUVIS: Unified Pure Vision Agents for Autonomous GUI Interaction.
- AgentTrek: agent trajectory synthesis via guiding replay with web tutorials.
- TACO / Synthetic Chains-of-Thought-and-Action.
- BLIP-3-Video / xGen-MM-Vid.
- Generative Frame Sampler for Long Video Understanding.