

课程讲义

Advanced topics in theorem proving

CS294/194-280: Advanced Large Language Model Agents

Sean Welleck, Carnegie Mellon University

中文教材化讲义 / Harness Build



The banner is split into two main sections. The left section has a white background with a circular portrait of Sean Welleck, a man with short brown hair wearing a white shirt, smiling. Below the portrait, the text 'SEAN WELLECK' is written in blue, and the 'Carnegie Mellon University' logo is in red. The right section has a blue background. At the top, it says 'UC Berkeley Center for Responsible, Decentralized Intelligence' in orange and white. Below that, 'Advanced Large Language Model Agents MOOC' is written in white. A horizontal line separates this from 'Bridging Informal and Formal Mathematical Reasoning', also in white. Another horizontal line follows, and then 'April 14th, 2025' is written in white. In the bottom right corner of the blue section, there is a decorative pattern of white dots.

课程页: <https://rdi.berkeley.edu/adv-llm-agents/sp25>

录播: <https://www.youtube.com/live/Gy5Nm17l9oo>

Slides: welleck2025_berkeley_bridging.pdf

补充 readings: DSP / miniCTX / Lean-STaR / ImProver

目录

1 本讲学习目标	2
2 背景与问题设置	2
2.1 为什么数学证明是 agent 的理想试验场	2
2.2 informal mathematics 与 formal mathematics 的区别	2
2.3 为什么 informal-formal gap 是真正瓶颈	3
3 从 thought 到 tactic: Lean-STaR	4
3.1 为什么要显式学习 thought	4
3.2 Lean-STaR 的训练与推理循环	5
3.3 为什么 informal thought 有用	5
3.4 实验结果与失败模式	5
4 用 informal sketch 指导 formal prover: Draft, Sketch, Prove	6
4.1 高层 reasoning 与低层 proving 的分工	6
4.2 DSP 的形式化视角	7
4.3 算法流程与小例子	7
4.4 为什么这种方法有效	7
5 LeanHammer: 在 Lean 中搭起低层自动证明系统	8
5.1 什么是 hammer	8
5.2 premise selection 是低层 proving 的瓶颈	8
5.3 LeanHammer 为什么比单纯检索更像 agent	9
5.4 量化结果、风险与边界条件	10
6 research-level formalization 与 miniCTX	10
6.1 为什么竞赛 benchmark 不够	10
6.2 miniCTX 在测什么	11
6.3 真实项目环境中的差异	13
7 reading 融合、proof optimization 与课程衔接	13
7.1 四篇 readings 如何补全本讲	13
7.2 与课程前后讲的联系	14
8 本章小结	14
9 复习题	14
10 深入思考题	14
11 延伸阅读	14

1 本讲学习目标

这一讲把课程从“agent 会不会推理”推向“agent 能否在 proof assistant 中稳定地产生、指导、改写与扩展证明”。读完本章后，读者应当能够回答：

- 为什么 theorem proving 对 agent 研究是高价值场景：它既需要复杂 reasoning，又提供了机器可检验的反馈。
- 什么是 informal mathematics、formal mathematics，以及它们之间的 **非形式到形式鸿沟(informal-formal gap)**。
- Lean-STaR 如何把 **思考 (thought)** 显式插入 tactic prediction 之前，并利用成功 proof 做 expert iteration。
- Draft, Sketch, Prove 为什么不是把自然语言证明直接当答案，而是把它当成 formal search 的结构偏置。
- LeanHammer 与 miniCTX 分别解决 theorem proving 里的哪一类瓶颈：一个偏低层自动证明与 premise selection，一个偏 research-level 长上下文依赖。
- “证明已经正确”与“证明已经优化”是两个不同问题；proof optimization 为什么会成为 agent 化的新任务。

2 背景与问题设置

2.1 为什么数学证明是 agent 的理想试验场


Sean Welleck 一开场先把数学放进 expert-domain agent 的谱系里：金融、医疗、数学都属于错误代价高、需要结构化 reasoning、又必须能解释中间过程的领域。与开放式对话不同，数学和形式验证的好处是：系统可以把问题写成 specification，把候选解写成 proof code，再让 proof assistant 做严格检查。这样一来，agent 并不是只在“像不像合理回答”的层面被评估，而是能收到 **编译是否通过、哪一步失败、缺了哪些前提**这样的环境反馈。

2.2 informal mathematics 与 formal mathematics 的区别

讲座先对两类数学对象做了清晰区分。所谓 **非形式数学 (informal mathematics)**，是论文、教材、草稿、板书、图示和自然语言讨论中的数学。这些材料灵活、可读、便于交流，但通常难以被自动校验。所谓 **形式数学 (formal mathematics)**，则更像 source code：命题需要写成精确 specification，证明需要写成 proof script 或 tactic trace，只要 proof assistant 接受，正确性就获得了机器层面的保证。

Key challenge: the informal-formal gap

Informal ideas, intuitions, and even proofs are difficult to express formally:



- Each step of reasoning needs to be specified in detail
- Requires a deep knowledge of the formal system

13

图 1: informal-formal gap: 自然语言中的证明直觉并不会自动变成 proof assistant 能接受的形式对象。

这一区分必须和上一讲的 **autoformalization**、**theorem proving** 等概念拆开来。autoformalization 是把自然语言题目或想法翻译成 formal statement；theorem proving 是在 formal statement 已经给定时搜索或构造证明；verification 则是让 proof assistant 或 verifier 检查候选证明的合法性。三者都与数学 reasoning 有关，但承担的角色不同。

本讲的关键区分

自然语言 proof sketch 不是 formal proof；formal proof 也不是 theorem discovery。前者提供高层语义结构，后者承担低层可检验正确性，而 discovery 还包括提出 conjecture、定义新对象或发现新规律。

2.3 为什么 informal-formal gap 是真正瓶颈

讲座的第一个核心论点是：许多重要数学直觉存在于 informal 层面，例如“这里应该做归纳”、“这个量需要先界定一个上界”、“这个证明实际上需要拆成两个子引理”。然而 proof assistant 只理解精细化的 formal state 与 tactic。于是即便一个 LLM 已经在自然语言中“知道该怎么做”，它也不一定能把这个想法翻译成逐步可执行的 proof。

这也是 theorem proving 和 L01 中 inference-time reasoning 的深层联系：在普通自然语言任务里，错误往往只在最终答案暴露；在 theorem proving 里，错误会以 type mismatch、missing premise、unsolved goal 等形式被环境立即指出。环境反馈更强，但 search space 也更离散、更脆弱。

3 从 thought 到 tactic: Lean-STaR

3.1 为什么要显式学习 thought

传统 neural theorem prover 往往直接学习 $p(a_t | s_t)$ ，即给定 proof state 预测下一个 tactic。问题在于，formal proof data 并不记录人类脑中的中间想法。一个数学家写下 tactic 之前，通常已经做了高层判断：当前应该归纳、需要把目标化成某个 lemma、或者先把等式改写成更容易的形式。Lean-STaR 的观察是：如果训练数据只有 tactic，而没有这些 thinking traces，模型学到的只是“如何模仿 proof script”，而不是“为什么在此刻做这个动作”。

1. Training models to “think” — Lean-STaR

Lean-STaR (Self-taught reasoner²)

Learn to generate thoughts via reinforcement learning

1. Initialization
2. Reinforcement learning

²Inspired by STaR: Bootstrapping Reasoning with Reasoning, Zelikman et al 2022

图 2: Lean-STaR 的结构：在 tactic 之前先生成 informal thought，再把成功证明反过来用于训练 thought+tactic policy。

因此，Lean-STaR 把策略改写成 thought 与 tactic 的联合生成：

$$\pi_{\theta}(z_t, a_t | s_t)$$

其中 π_{θ} 是参数为 θ 的模型， s_t 是第 t 步 proof state， z_t 是在该步之前生成的 informal thought， a_t 是随后执行的 tactic。这个公式的重要性不在于数学上有多复杂，而在于它明确说：**推理轨迹本身是策略的一部分，而不是 tactic 的附属注释。**

符号解释

- s_t : proof assistant 当前暴露给模型的目标、上下文和局部假设。
- z_t : 模型对“下一步应该怎么想”的自然语言或半结构化思考。
- a_t : 真正交给 Lean 执行的 tactic。
- π_{θ} : 把状态映射到 thought+tactic 联合动作的策略。

3.2 Lean-STaR 的训练与推理循环

Lean-STaR 并不是人工写 thought annotation, 而是从成功 proof 中合成 synthetic thoughts, 然后反复自训练。其过程可以概括为:

```
1 Initialize policy pi_theta(thought, tactic | state)
2 Collect successful proofs from search
3 Extract (state, thought, tactic) tuples
4 Fine-tune the policy on successful tuples
5 Run search again with the improved policy
```


这里的关键有两层。第一, thought 不再是纯 prompt engineering, 而是纳入训练目标的显式输出。第二, 系统不是一次训练完就结束, 而是像 expert iteration 一样, 把当前策略能找到的成功 proof 当成下一轮学习的监督信号。这与课程前几讲的“verification-backed self-improvement”有共通结构: 没有 verifier 的反馈, thought 只会变成长篇自言自语; 有 verifier 的反馈, thought 才可能变成有效的 search bias。

3.3 为什么 informal thought 有用

从本讲 slides 的角度看, thought 至少有三种功能。其一, 它帮助模型做 **状态压缩**: 把复杂 proof state 重新描述成高层任务, 如“此处要做归纳”、“先应用某个对称性 lemma”。其二, 它帮助模型做 **动作筛选**: 在 tactic space 非常大时, thought 能把候选动作压缩到语义相关的局部。其三, 它帮助模型做 **预算利用**: 当搜索预算增加时, thought 让额外计算不是盲目枚举 tactic, 而是沿着更像人类推理的路径展开。

3.4 实验结果与失败模式

Training models to “think” — Lean-STaR



27

图 3: Lean-STaR 在 miniF2F 上的结果: thought augmentation 与 expert iteration 都贡献了性能提升。

slides 给出的 miniF2F 结果说明: 仅仅引入 thoughts 就有帮助, 而进一步引入 expert iteration 效果更明显。更关键的是, 讲座还强调了一个非常 agent-oriented 的现象: **随着搜索预算增加, 带 thoughts 的系统更能把预算转化为真实通过率**。这点和 L01 里 “test-time compute 只有在结构化使用时才有效” 完全呼应。

Lean-STaR 不是 free lunch

thought 本身并不保证正确。若 synthetic thought 质量差、verifier 太弱、search 实现不稳定, 模型可能学到看似合理但会误导 tactic 的 explanations。换言之, thought 只是额外中间变量, 不是 correctness certificate。

4 用 informal sketch 指导 formal prover: Draft, Sketch, Prove

4.1 高层 reasoning 与低层 proving 的分工

第二部分的核心是: 高层 reasoning 很擅长提出 decomposition、类比和 overall strategy; 低层 prover 很擅长做严谨、可验证、细粒度的 proof search。若把两者强行混成同一个黑箱, 往往会两头都做不好。Draft, Sketch, Prove (DSP) 试图建立一个更清晰的接口: 先把 informal theorem 转成 formal theorem, 再把 informal proof 变成 formal sketch, 最后让 formal prover 在 sketch 引导下完成低层搜索。

Draft-Sketch-Prove

Draft, Sketch, Prove: Guiding Formal Theorem Provers with Informal Proofs

Albert Q. Jiang, Sean Welleck, Jin Peng Zhou
Jiacheng Liu, Wenda Li, Mateja Jamnik
Guillaume Lample, Yuhuai Wu
ICLR 2023 (Oral)

42

图 4: DSP 的代表论文页: 把 informal theorem 与 informal proof 变成 formal sketch-guided proving 的输入。

4.2 DSP 的形式化视角

可以把 DSP 理解为在 formal theorem x_F 上引入额外结构约束 σ :

$$\tau^* = \arg \max_{\tau \in \mathcal{T}(x_F, \sigma)} r(\tau)$$

这里 τ 表示候选 formal proof trajectory, $\mathcal{T}(x_F, \sigma)$ 表示在 theorem x_F 与 sketch σ 共同约束下可搜索的 proof 集合, $r(\tau)$ 是 prover 或 verifier 对轨迹的打分, 而 τ^* 是最终选中的证明轨迹。

这条公式传达的直觉非常重要: **sketch 的价值不是替代搜索, 而是重塑搜索空间**。也就是说, DSP 不是让 LLM 写一段漂亮的自然语言证明然后宣称任务完成, 而是把这段高层结构翻译成可操作的约束、子目标或搜索导向。


4.3 算法流程与小例子

```
1 Input informal theorem x_I
2 Generate a draft formal statement x_F
3 Produce sketch sigma from informal proof or LLM draft
4 Guide a low-level prover with sigma
5 Verify the resulting formal proof in the proof assistant
```

若读者想象一个简单例子: 自然语言证明可能说“先证明集合关系的两个方向, 再分别展开定义”。对人来说, 这只是常识; 对 prover 来说, 这相当于巨大 search space 中的关键坐标。DSP 的工作, 就是把这种高层提示变成 formal system 能消化的结构化支架。

4.4 为什么这种方法有效

slides 中的动机页强调: 单纯依赖低层自动证明器时, 搜索空间会爆炸, 因为系统既要决定整体策略, 又要填充每个局部步骤。DSP 通过引入 sketch, 把“整体路线”与“局部执行”分开, 降低了低层 prover 的组合负担。这样做还带来另一个好处: 当 informal proof 来自人类或强 LLM 时, 系统能直接利用这些高层语义, 而不是把它们丢掉再从 zero search。



45

图 5: DSP 中的 inference-time proof search scaling: 好的 sketch 会让额外搜索预算更有效。

根据 reading, sketch-guided proving 能把一组竞赛题上的成功率从 20.9% 提高到 39.3%。这不是“LLM 变得更会证明”的简单结论, 而更像是: 当高层结构被显式提供时, 低层 formal prover 的效率被显著放大。

失败模式

- 若 draft formal statement 本身错了, 后续 proving 会建立在错误目标上。
- 若 informal proof 太跳跃, sketch 无法映射到稳定子目标。
- 若低层 prover 无法利用 sketch 提供的信息, 系统仍会退化成 brute-force search。

5 LeanHammer: 在 Lean 中搭起低层自动证明系统

5.1 什么是 hammer

在 interactive theorem proving 社区, **hammer** 指的是把外部 automated theorem prover (ATP) 接入 proof assistant 的系统。它通常负责 premise selection、格式转换、调用 ATP、再把找到的证明重构回原 proof assistant。Sean Welleck 用 LeanHammer 这一部分强调: 如果说 DSP 主要是“把 informal reasoning 接进来”, 那 hammer 系统关注的就是“如何把低层 automation 做强”。

5.2 premise selection 是低层 proving 的瓶颈

自动证明器常见的失败原因不是理论上无法证明, 而是候选前提太多, 搜索分支太广。于是 premise selection 成为核心问题: 给定当前 goal g 与上下文 c , 应该从大规模 library 中挑出哪些 lemmas 或 definitions 送进 ATP?

$$p_{1:k}^* = \text{TopK}_{p \in \mathcal{P}} f_\phi(g, p, c)$$


这里 g 是当前目标, p 是候选 premise, $\mathcal{P}$ 是可检索的 premise 集, c 是文件或项目上下文, f_ϕ 是 premise selector 的相关性函数, $p_{1:k}^*$ 是排名靠前、最终送入 ATP 的前 k 个前提。

符号解释

- g 决定当前需要证明什么。
- c 提供额外环境信息, 例如当前文件、局部定义、打开的 namespace。
- f_ϕ 既可以是稀疏检索, 也可以是神经相关性评分器。
- Top- k 选择体现了“先检索, 再证明”的 agent workflow。

A hammer pipeline

A standard hammer pipeline:



51

图 6: 标准 hammer pipeline: 先做 premise selection, 再交给 ATP 与 proof reconstruction。

```


1 Given goal g and context c
2 Retrieve top-k premises with selector f_phi
3 Translate the proof state to ATP format
4 Run ATP and/or tree search
5 Reconstruct a Lean proof from the successful trace
  
```

5.3 LeanHammer 为什么比单纯检索更像 agent

slides 后半段明确展示, LeanHammer 不只是一个 retriever, 而是 premise selector、ATP 与 tree search 的组合系统。换句话说, 它有感知 (读 goal 与上下文)、检索 (挑 premise)、行动 (调用 prover / tree search)、反馈 (proof reconstruction 成败) 这几个 agent 环节。

LeanHammer — Putting it all together

Idea: combine the premise selector and ATP with a tree search



Tree search: *Aesop* [Limpert & From 2023]

53

图 7: LeanHammer 将 premise selector、ATP 与 tree search 组合起来，而不是把它们当成独立模块。

这一点和课程前几讲讲到的 workflow agent 很像：好的系统不是只会“调用一个工具”，而是知道何时调用哪个工具、失败后如何换轨、以及哪些中间信息要保留给下一轮。LeanHammer 把这些思想放到了 theorem proving 里。

5.4 量化结果、风险与边界条件

量化结果页说明，premise selector 的质量直接影响最终 proof rate。即便 ATP 本身很强，如果 premise selection 太差，也会因为无关前提太多而被淹没。反过来，若 premise selection 很准，却缺少可重构证明，系统也无法在 Lean 中落地。

不要把 hammer 误解为端到端数学推理


hammer 的强项是把现有 library 和自动证明器用得更好，而不是提出新的 conjecture 或自动完成 research-level 形式化。它解决的是低层 automation bottleneck，不是全部 theorem proving 问题。

6 research-level formalization 与 miniCTX

6.1 为什么竞赛 benchmark 不够

讲座最后一部分把视角拉到 research-level mathematics。slides 用 Terence Tao 的 blueprint 形式化项目作例子，强调真实数学项目往往跨文件、跨定义、跨引理地组织。这里的瓶颈不再只是单个 theorem 难不难，而是一个项目里哪些上下文真正相关、如何让使用者和模型都能进入该项目语境。

What does it look like to formalize research-level math?⁴



⁴ Formalizing the proof of PFR in Lean4 using Blueprint: a short tour by Terence Tao

图 8: research-level formalization 的问题形态: 不是单题求解, 而是依赖 blueprint、项目结构与新定义的协同工作。

这也是 slides 提到的 **accessibility gap** 与 **benchmarking gap**。前者是说, 真实 Lean 项目对普通用户和普通模型都不友好; 后者是说, 像 miniF2F 这样的竞赛 benchmark 很重要, 但它们过于自包含, 无法检验模型是否会利用项目上下文。

6.2 miniCTX 在测什么

miniCTX 正是为此而设计。它要求模型在证明 theorem 时读取更长的 preceding code context、文件级定义, 甚至跨文件依赖。于是 theorem proving 可以被写成:

$$\hat{\tau} = \text{Prove}(g \mid s_{\text{local}}, c_{\text{file}}, c_{\text{repo}})$$

其中 g 是 theorem goal, s_{local} 是局部 proof state, c_{file} 是当前文件前文上下文, c_{repo} 是跨文件项目上下文, 而 $\hat{\tau}$ 是系统产生的证明轨迹。

miniCTX: Neural Theorem Proving with (Long-)Contexts

Jiewen Hu, Thomas Zhu, Sean Welleck


ICLR 2025 (Oral)

65

图 9: miniCTX 关注真实项目中的长上下文 theorem proving，而非只看局部 state 的竞赛式 proving。

其教学意义在于，它把 theorem proving 从“会不会走 tactic”推向“能不能在真实软件与数学项目环境中工作”。对 agent 而言，这意味着不仅要学会 reasoning，还要学会上下文管理、检索与工作记忆。

6.3 真实项目环境中的差异



70

图 10: 真实项目的长上下文会显著区分方法能力; 竞赛 benchmark 上相近的方法, 落到真实项目上可能差很多。

slides 特别强调了一个经常被忽略的事实: 两个方法在竞赛 benchmark 上可以非常接近, 但在真实项目里却可能差异巨大。原因是竞赛题通常不依赖新定义、长文件上下文与项目规范; 而 research-level formalization 恰恰依赖这些。若系统只会在局部 state 上做模式匹配, 它在真实项目里就会迅速失效。

7 reading 融合、proof optimization 与课程衔接

7.1 四篇 readings 如何补全本讲

Lean-STaR 说明 *thinking before proving* 能提升 formal proof search; DSP 说明 *informal proof sketches* 可以引导 low-level prover; miniCTX 说明 真实项目上下文是新的 benchmark frontier; Im-Prover 则补上了 *proof optimization* 这一维度: agent 不仅能找到 proof, 还能在 correctness 不变时优化 proof 的长度、可读性与模块化。

这四篇 reading 放在一起, 可以看出一个清晰演化路径:

1. 先让模型在局部 state 上会走 tactic。
2. 再让模型显式地产生 thoughts, 利用更多 inference-time reasoning。
3. 再让系统把 informal sketch、retrieval、context management 接入 proving。
4. 最后让 agent 不只“找到一个 proof”, 而是能围绕 proof 做持续的搜索、重写与优化。

7.2 与课程前后讲的联系

与 L08/L09 相比, 这一讲更强调 theorem proving 内部的系统设计, 而不是单一 benchmark 成绩。与 L01 相比, 这一讲给出一个更尖锐的例子: **test-time compute 只有在 proof environment 提供 verifier 信号时, 才真正变成可靠的推理改进手段**。与下一讲关于 abstraction/discovery 的关系也很直接: 一旦 theorem proving 不再只靠局部 tactic, 而要利用高层 sketch、concept、context 和 project structure, abstraction 就成了下一步自然主题。

8 本章小结

本讲的主线可以概括成一句话: **高级 theorem proving 不只是“更强的证明模型”, 而是“把 informal reasoning、formal verification、retrieval、search 和 context management 组合成可验证的 agent workflow”**。Lean-STaR 让“想”成为策略的一部分, DSP 让高层 sketch 成为低层 proving 的搜索偏置, LeanHammer 把 premise selection 与 ATP 集成为低层 automation, miniCTX 则逼着我们直面真实项目的长上下文依赖。对 LLM agent 研究者而言, 这一讲的重要性在于它展示了一个极其清晰的范式: 当环境能给出强反馈时, agent 才真正可以在 reasoning、search 与 self-improvement 上形成闭环。

9 复习题

1. informal mathematics 与 formal mathematics 的主要差异是什么? 为什么 formal proof 更适合作为 agent 的训练或评估环境?
2. Lean-STaR 为什么要在 tactic 之前生成 thought? 这一步解决了传统 neural theorem proving 的哪个缺口?
3. Draft, Sketch, Prove 中的 sketch 为什么不能被理解成“最终证明”?
4. hammer 系统中的 premise selection 扮演什么角色? 若 premise selection 很差, 会发生什么?
5. miniCTX 想解决什么 benchmark blind spot?

10 深入思考题

1. 如果未来 frontier model 在自然语言证明上非常强, 是否还需要 proof assistant 反馈? 请结合 hallucination control 与 theorem proving 的要求回答。
2. 对 theorem proving 来说, thought 是不是总是越长越好? 什么时候更长的 thought 反而会伤害搜索?
3. research-level formalization 与 coding agents 在系统层面有哪些共同点?

11 延伸阅读

- Lean-STaR: Learning to Interleave Thinking and Proving
- Draft, Sketch, and Prove: Guiding Formal Theorem Provers with Informal Proofs

- miniCTX: Neural Theorem Proving with (Long-)Contexts
- ImProver: Agent-Based Automated Proof Optimization