

课程讲义

Towards building safe and secure agentic AI

CS294/194-280: Advanced Large Language Model Agents

Dawn Song, UC Berkeley

中文教材化讲义 / Codex Harness Build



The poster features a circular portrait of Dawn Song on the left. To the right, the text reads: 'UC Berkeley Center for Responsible, Decentralized Intelligence', 'Advanced Large Language Model Agents MOOC', 'Towards Building Safe and Secure Agentic AI', and 'April 28th, 2025'. Below the portrait, it says 'DAWN SONG', 'PROFESSOR, BERKELEY RDI CO-DIRECTOR', and 'UC Berkeley'. A grid of dots is in the bottom right corner.

UC Berkeley Center for Responsible,
Decentralized Intelligence

**Advanced Large Language
Model Agents MOOC**

**Towards Building Safe
and Secure Agentic AI**

April 28th, 2025

DAWN SONG
PROFESSOR, BERKELEY
RDI CO-DIRECTOR
UC Berkeley

课程页: <https://rdi.berkeley.edu/adv-llm-agents/sp25>

录播: <https://www.youtube.com/live/ti6yPE2VPZc>

Slides: dawn-agentic-ai.pdf

补充 readings: Privtrans / DataSentinel / AgentPoison / Progent

目录

1 本讲学习目标	2
2 背景与问题设置	2
2.1 为什么 agentic AI 的安全问题比普通 LLM 更难	2
2.2 为什么 2025 年是 agents 的一年, 同时也是 agentic risk 爆发的一年	3
3 攻击面与攻击链	4
3.1 LLM 输出如何进入攻击链	4
3.2 从传统 SQL injection / RCE 到 agentic 漏洞	5
3.3 Prompt injection: 直接注入、间接注入与 command-data mixing	6
3.4 AgentPoison: 为什么 memory poisoning 比单轮注入更持久	7
4 评测与红队: 为什么必须做系统级安全评估	8
4.1 LLM evaluation 与 agentic system evaluation 的区别	8
4.2 AgentXploit: black-box 条件下的 end-to-end red teaming	8
4.3 AgentXploit 的 fuzzing workflow	9
5 防御原则与机制	11
5.1 Defense-in-depth: 为什么不能只靠一种防御	11
5.2 Model hardening 与 input sanitization 的作用边界	12
5.3 Least privilege on tool calls	13
6 权限控制、系统边界与可证明安全	13
6.1 Progent: 把 least privilege 变成可编程、可执行的 runtime gate	13
6.2 Privilege management 与 privilege separation	15
6.3 Monitoring、IFT 与 formal verification	16
7 关键论文与课程 readings 的连接	17
7.1 Privtrans、AgentPoison、DataSentinel、Progent 各自补哪一层	17
8 例子、反例、失败模式和边界条件	18
8.1 为什么“把 prompt 写得更严一点”通常不够	18
8.2 最关键的安全边界: prompt、memory、tool、identity、information flow	18
9 与前后讲的联系	18
10 本章小结	19
11 复习题	19
12 深入思考题	20
13 延伸阅读	20

1 本讲学习目标

本讲讨论的不是“如何让模型回答得更礼貌”，而是更严格的问题：当 LLM 被放进 **agentic system** 中，能够读外部数据、调用工具、写入记忆、执行动作时，系统的安全边界应该如何设计？读完本章后，读者应当能够回答：

- 为什么 **agentic AI safety & security** 不能等价为传统的 LLM safety。
- 为什么 prompt injection、memory poisoning、knowledge-base poisoning、malicious tool usage 本质上都是**边界控制失效**问题。
- 为什么 stand-alone model benchmark 不足以评估 agentic system risk。
- AgentXploit 这类 end-to-end red teaming 框架在 black-box 条件下如何工作。
- 为什么 least privilege、privilege separation、information flow tracking、formal verification 必须进入 agent pipeline 设计，而不是只做附加 guardrail。
- Progent、Privtrans、DataSentinel 分别在 agent security 栈的哪一层起作用，它们之间如何互补。

2 背景与问题设置

2.1 为什么 agentic AI 的安全问题比普通 LLM 更难

Lecture 一开始先给出一个很重要的区分：**AI safety** 强调系统对外部世界造成的伤害，**AI security** 强调系统自身被攻击、被利用或被恶意操控。对于普通 stand-alone LLM，这两个问题已经存在；但在 agentic system 中，它们会被进一步耦合，因为外部攻击者可以通过数据、工具、环境反馈和长期记忆持续影响系统。

AI Safety vs. Security

- AI Safety: Preventing harm that a system might inflict upon the external environment
- AI Security: Protecting the system itself against harm and exploitation from malicious external actors
- AI safety needs to consider adversarial setting
 - E.g., alignment mechanisms need to be resilient/secure against attacks

图 1: Lecture 对 AI safety 与 AI security 的区分。

这一区分的关键不是词汇定义，而是**威胁模型 (threat model)** 的变化。普通 LLM 常常被理解为一性文本生成器；而 agentic AI 是一个持续运行的**混合系统 (hybrid/compound system)**，它

由神经组件、符号组件、工具接口、外部服务和用户交互共同组成。只要其中某一条边界没有定义清楚，攻击就可能沿着组件之间的转换链继续传播。

Agentic System: Hybrid/Compound System

- Hybrid/compound system vs. traditional system




图 2: Agentic system 是 hybrid system: 模型不再孤立运行，而是嵌在与工具、环境和外部世界的交互闭环中。

第 13 页给出了一条典型的 hybrid system 使用路径: host 部署系统, user 发出请求, system 调用模型, 模型与系统其他组件交互, system 再与外部世界交互, 最终响应用户, 且在长任务中持续运行。这个步骤分解的价值在于, 它迫使我们思考: 哪一步是命令, 哪一步是数据, 哪一步在升级权限, 哪一步在把模型输出变成真实动作?

本讲的统一视角

本讲可以被压缩成一句话: **agentic security** 的核心不是“让模型永不犯错”, 而是当模型可能出错、可能被诱导、可能读入恶意内容时, 系统仍然不把这些错误直接升级成高后果动作。

2.2 为什么 2025 年是 agents 的一年, 同时也是 agentic risk 爆发的一年

Lecture 前几页强调 frontier AI 与 agents 的快速发展。Web agents、computer-use agents、coding agents、robotics agents 都在快速落地。这意味着 AI 风险不再只是输出一段有害文本, 而可能是:

- 生成恶意 API 参数;
- 触发错误分支;
- 泄露系统 prompt 或敏感上下文;
- 调用高权限工具;
- 在长时记忆中植入持久恶意触发器;
- 让后续 agent 或 service 继续放大攻击效果。

因此, 安全问题从“单轮问答有没有违规回答”升级成“多组件系统如何在不可信输入与高权限动作之间建立硬边界”。

3 攻击面与攻击链

3.1 LLM 输出如何进入攻击链

Lecture 第 27 页是整讲最重要的系统安全页之一。它列出 LLM 输出在 agentic system 中的五种典型去向：

- U1: 对外展示的文本、图像等；
- U2: 作为后续模型调用或计算的参数；
- U3: 作为 branch/jump condition；
- U4: 作为函数调用参数；
- U5: 作为直接执行的代码片段。

LLM Generated Output Can Be Used as Part of Attack Chain

- U1: As user/external-facing output: text, image, etc.
May lead to information leakage
- U2: As parameters for further model invocation & computation
May lead to compounding bias and errors
- U3: As branch/jump conditions
May lead to unexpected system behavior
- U4: As parameters for further function calls
May lead to SQL injection, server-side request forgery (SSRF), etc.
- U5: As code snippets for direct execution
May lead to arbitrary code execution




图 3: LLM 输出一旦成为 branch condition、tool argument 或 executable code，就从“内容风险”升级为“系统控制风险”。

这张图说明：问题不在于模型“说错了什么”，而在于系统“拿模型输出去做了什么”。如果下游组件把模型输出直接拼进 SQL、shell command、HTTP request 或 privileged tool call，那么模型错误就会被放大成系统漏洞。

```
1 user_input -> llm_output -> tool_args / branch_condition / executable_code -> external_system
```

上面这个伪代码就是本讲对 attack chain 的最小抽象。它有三个工程含义：

- 输入输出边界不能只看文本表面，要看语义角色；
- 高风险动作必须在 LLM 之外做 **deterministic enforcement**；
- 任何把 model output 升级为 action 的步骤，都是 security boundary。

3.2 从传统 SQL injection / RCE 到 agentic 漏洞

Lecture 接着用 SQL injection 与 remote code execution 说明：传统软件漏洞在 hybrid system 中并没有消失，只是攻击链多了 LLM 这一层。

LLM used as part of the attack chain (I): SQL Injection



图 4: SQL injection 在 agentic system 中的危险，不只是用户输入本身恶意，还包括模型生成的 query 或 tool 参数被继续信任。

LLM used as part of the attack chain (II): Remote Code Execution




图 5: Remote code execution 在 hybrid system 中的典型风险：模型输出被包装成命令或代码后继续执行。

为什么朴素方法不够？因为很多 agent 开发者会默认认为“模型只是建议，不是真正执行者”。但在实践里，系统常常把模型输出自动转换成 tool arguments、database queries、browser actions 甚至 shell invocations。于是看似“只是建议”的文本，实际上已经拿到了**控制系统行为的权力**。

系统安全中的常见误判

把 LLM 放在攻击链中间后，很多传统的“输入验证”假设会失效。开发者容易只验证用户输入，却忽视模型生成出的二次输入。而这恰恰是 hybrid system 最脆弱的位置。

3.3 Prompt injection: 直接注入、间接注入与 command-data mixing

Lecture 之后进入 prompt injection。第 39 页的 direct prompt injection 页说明：当 system prompt、user prompt、外部文档内容都混在同一上下文窗口中时，攻击者可以用一段恶意 instruction 去和系统指令竞争。

Direct Prompt Injection





图 6: Direct prompt injection: 恶意输入直接进入 prompt 空间并竞争 system instruction。

但 Dawn Song 在这讲里更强调的是 **indirect prompt injection**。这类攻击的危险不在于攻击者亲自输入一条 “ignore previous instructions”，而在于系统会从外部网页、简历、文档、邮件、知识库等位置读取数据，然后把这些数据 and 命令一起交给模型。

Indirect Prompt Injection Example



Liu, Y., Jia, Y., Geng, R., Jia, J., & Gong, N. Z. (2024). Formalizing and benchmarking prompt injection attacks and defenses, USENIX Security 24

图 7: Indirect prompt injection 的本质是把外部数据当成了命令空间的一部分。

第 48 页对这个问题有非常精准的总结：**General issue: mixing command and data**。这句话几乎可以看成 agentic prompt injection 的总定义。系统本应把 “命令” 与 “数据” 区分开，但很多 agent pipeline 为了方便，直接把 retrieved document、browser DOM、memory snippet、tool result

全部拼接进上下文。这种设计让攻击者只要控制其中任一外部数据源，就能间接控制 agent。

Prompt Injection Attack Surface

- Manipulated user input
- Memory poisoning / Knowledge base poisoning
- Data poisoning from external reference source (during agent execution)
 - Supply chain attack
 - Poisoned open datasets, documents on public internet




图 8: Prompt injection attack surface 不只来自当前用户输入，还包括 memory poisoning、knowledge base poisoning、external data poisoning 与 supply-chain attack。

这也是为什么用户特别要求我们在本讲里把 **prompt injection**、**memory poisoning**、**privilege control** 和 **agentic security boundaries** 写清楚。它们不是四个并列话题，而是一条连续链：

1. 攻击者污染输入或外部数据；
2. agent 把污染数据读进上下文；
3. 模型把污染内容当成 instruction 或 credible evidence；
4. 系统把模型输出升级成高权限 tool call；
5. 结果演化成数据泄露、越权操作或持久后门。

3.4 AgentPoison：为什么 memory poisoning 比单轮注入更持久

AgentPoison 对上面的 attack surface 给出了更强的实例化。它不是只攻击一轮 prompt，而是污染 agent 的 long-term memory 或 RAG knowledge base。一旦 poisoning 成功，后续不同任务只要触发了相应 retrieval，就会反复召回恶意示例。

这与 direct prompt injection 最大的区别在于：

- 攻击不再依赖攻击者实时在线；
- 恶意内容可以在多个任务、多个会话中持续生效；
- 被污染的数据可能看起来像“可信历史经验”或“外部知识”；
- 开发者更难通过 prompt filtering 发现问题。

因此，memory poisoning 说明了一件更深刻的事：**agentic security** 的边界不只在 prompt 前后，也在 memory write、memory retrieve 和 KB ingestion 的每一个阶段。

4 评测与红队：为什么必须做系统级安全评估

4.1 LLM evaluation 与 agentic system evaluation 的区别

第 52 页非常明确：普通 LLM evaluation 主要测 stand-alone model behavior，而 agentic hybrid system evaluation 测的是 end-to-end system behavior。

Evaluation for LLM vs. Agentic Hybrid System

- LLM evaluation only focuses on evaluating stand-alone model behaviors
- Agentic hybrid system evaluation evaluates on end-to-end system behaviors





图 9: 评测对象从 model 行为变成 system 行为后，攻击面、责任边界和 failure mode 都变了。


这意味着一个模型即使在传统 benchmark 上“安全”，只要它所在的 system 会把输出直接交给 browser、OS、database、email client 或 payment API，它仍然可能在端到端层面表现得非常脆弱。Lecture 在这里顺带提到一类更一般的 trustworthiness benchmark，以及 RedCode 这种专门面向 code agents 的 benchmark，目的是提醒读者：**安全评测必须和任务环境、工具接口、执行后果一起定义。**

4.2 AgentXploit: black-box 条件下的 end-to-end red teaming

AgentXploit 是这讲里最具代表性的系统级攻击框架。它的威胁模型比较克制：攻击者不能改用户 query，不能看 agent internals，不能直接劫持内部数据流，也拿不到内部 LLM；攻击者能做的，只是污染外部数据源，并从 attack success / failure 的二值反馈中继续搜索。

AgentXploit: End-to-End Red-teaming of Black-Box AI Agents

- Agents combine LLMs with tools to complete complex user tasks
 - Code agents, web agents, personal assistant agents, etc.
 - Stronger capabilities, higher risks
- Security threat: Vulnerable to **indirect prompt injection**
 - Malicious inputs hidden in external data can hijack agent behavior
- Challenges in assessing risks
 - Black-box nature of commercial agents and LLMs
 - Diversity of tasks and agent designs
 - Complex, heterogeneous architectures
- Existing work: Lacks generalizability or targets only model-level or handcrafted attacks



AgentXploit: End-to-End Red-teaming of Black-Box AI Agents, 2025

图 10: AgentXploit 的动机: 商业 agents 常常是 black-box, 但这并不妨碍攻击者通过外部可控数据与反馈回路做红队搜索。

这很重要, 因为它说明系统安全不能假设 “看不到内部 prompt 就安全”。在 black-box 场景里, 攻击者照样可以利用 environment feedback 做搜索。

4.3 AgentXploit 的 fuzzing workflow


Lecture 把 AgentXploit 描述为 fuzzing-based framework。它的核心流程并不复杂, 但很符合 agentic 攻击的本质:

```
1 seed_db = initial_attack_instructions
2 while budget remains:
3     seed = select(seed_db)
4     mutated = mutate(seed)
5     run agent on tasks with mutated payload
6     feedback = evaluate(success, coverage)
7     update(seed_db, mutated, feedback)
```

AgentXploit: Methodology -- A Fuzzing-Based Framework

Core workflow:

- Start with a set of seed attack instructions
- Mutate and feed to target agent with a set of tasks
- Evaluate output and update seed database based on feedback



AgentXploit: End-to-End Redteaming of Black-Box AI Agents, 2025

图 11: AgentXploit 的核心 workflow: seed -> mutation -> task execution -> feedback -> seed database update。

这里最值得注意的是第 59 页提到的三个设计: adaptive scoring、MCTS-based seed selection 和 custom mutators。Lecture 没有把它们当成花哨技巧, 而是说明系统级攻击搜索需要同时平衡 exploitation 与 exploration。

$$s(x) = \alpha \cdot \text{ASR}(x) + \beta \cdot \text{Cov}(x)$$

符号说明:

- x : 当前候选 attack seed 或其变异版本。
- $\text{ASR}(x)$: 该 seed 导致 attack success 的经验概率。
- $\text{Cov}(x)$: 该 seed 对任务类型或状态空间的覆盖价值。
- α, β : 攻击成功率与覆盖度之间的权重。

这个公式是对 Lecture “adaptive scoring” 的讲义化形式化。它的直觉是: 一个好的攻击 seed 不只是当前能打穿一个任务, 还应该帮助攻击者探索更多任务分布。

AgentXploit: Evaluation

Evaluate AgentXploit on two benchmarks (AgentDojo and VWA-adv)

- Effectiveness: ~2x attack success rate vs. handcrafted baselines
- Transferability: high ASR on unseen tasks
- Ablation study: key components make significant contribution.

Benchmark	Task set	Attack	Success rate
AgentDojo	Fuzzing	Handcrafted	0.38
		AGENTXPLOIT	0.71
	Unseen	Handcrafted	0.34
		AGENTXPLOIT	0.65
VWA-adv	Fuzzing	Handcrafted	0.36
		AGENTXPLOIT	0.60
	Unseen	Handcrafted	0.44
		AGENTXPLOIT	0.54




图 12: AgentXploit 的评测提醒我们：真正重要的是 attack success、transferability 与 component contribution，而不是某个单点 prompt 是否生效。

系统级红队的意义

系统级红队最大的价值不是“找到一个炫技 payload”，而是暴露哪条系统边界会把不可信输入升级为高后果动作。这正是 agent 安全中最难靠静态审查发现的问题。

5 防御原则与机制

5.1 Defense-in-depth：为什么不能只靠一种防御

Lecture 第 65–68 页给出整讲的防御主线：Defense-in-depth、least privilege & privilege separation、safe-by-design / secure-by-design / provably secure。

Defense Principles

- Defense-in-depth
- Least privilege & privilege separation
- Safe-by-design, secure-by-design, provably secure




图 13: 三条总原则：分层防御、最小权限、以及设计阶段的安全性可证明性。

Defense Mechanisms

1. Harden models
2. Guardrail for input sanitization
3. Policy enforcement on actions
4. Privilege management
5. Privilege separation
6. Monitoring and detection
7. Information flow tracking
8. Secure-by-design and formal verification




图 14: Lecture 给出的八层 defense mechanisms。关键点是：这些机制面向不同边界，彼此互补。

为什么不能只做 model hardening? 因为很多攻击并不是“让模型说了不该说的话”，而是**让系统做了不该做的事**。模型级 hardening 可以降低被 prompt injection、jailbreak、data poisoning 影响的概率，但它不等价于 deterministic action enforcement。

因此 Lecture 把防御机制拆成八层：

1. harden models;
2. input sanitization guardrails;
3. policy enforcement on actions;
4. privilege management;
5. privilege separation;
6. monitoring and detection;
7. information flow tracking;
8. secure-by-design and formal verification.

其中真正决定 agentic 边界的，是 3–8 层。前两层更像“降低模型被诱导的概率”，后几层则是在回答：**即使模型已经被诱导，系统是否还能阻止高风险动作真正发生？**

5.2 Model hardening 与 input sanitization 的作用边界

第 71 页列举了 model hardening 的若干手段：data cleaning、safety pre-training、post-training alignment、machine unlearning 等。它们当然重要，但本讲刻意没有把它们作为终点。原因很简单：

- hardening 是概率性的，不是绝对隔离；
- 新攻击会不断出现，训练时见不到全部 attack variants；
- 训练越强，不代表 runtime boundary 越清晰；

- 一旦输出被升格为工具动作，后果成本会远高于普通文本失误。

所以从系统工程角度看，hardening 的角色是降低出错频率，而不是定义权限边界。

5.3 Least privilege on tool calls

第 75 页把 least privilege 放到 tool-call 之前：先生成 policy，再在执行期 enforce，并在工具调用前做 compliance confirmation。

Defense Mechanisms




图 15: Least privilege 的真正落点是 tool call boundary，而不是 prompt 文本本身。

这一步非常关键，因为 prompt injection、memory poisoning、tool misuse 最终都要跨过同一个门槛：从自然语言意图进入高权限动作执行。如果这个门槛没有 deterministic gate，那么任何 prompt-side 防御都可能在最后一跳失效。

6 权限控制、系统边界与可证明安全

6.1 Progent：把 least privilege 变成可编程、可执行的 runtime gate

Progent 是整讲最核心的防御论文。它的关键贡献不是单纯“加一些规则”，而是把 privilege control 做成：

- 用 DSL 表达的细粒度策略；
- 最小侵入式的 policy enforcement framework；
- 可在执行期更新的 dynamic policies；
- human-written 与 LLM-generated policies 的 hybrid combination；
- 对编码属性提供 deterministic security guarantees。

Progent: Programmable Privilege Control for LLM Agents --- Overview

Privilege control mechanism for LLM agents, enforcing the principle of least privilege

- Domain-specific language (DSL) for flexibly expressing privilege control & guardrail policies:
 - Flexible, extensible, expressive
- Policy enforcement framework:
 - Modular: requiring only minimal changes to existing implementations
 - Efficient, real-time
- Programmable policy updates during agent execution:
 - Dynamic
 - Balancing the utility and security
- Hybrid policies: combining human-written and LLM-generated policies




图 16: Progent 的核心是 DSL、wrapper-based enforcement 和 hybrid policies。

Lecture 特别强调 hybrid policy 的意义。纯人工规则太刚，难以覆盖动态上下文；纯模型生成策略又缺少稳定的安全保证。因此 Progent 采用“全局 deterministic rule + 局部 dynamic policy”的组合。

$$\text{allow}(a, s, u) = \mathbf{1}[P_h(a, s, u) \wedge P_d(a, s, u)]$$

符号说明：

- a : 待执行的 tool call 或 action。
- s : 当前 agent state 或上下文。
- u : 用户身份、能力或权限边界。
- P_h : human-written global policy。
- P_d : dynamic policy，例如由 agent state 或 LLM-generated guardrail 派生出的局部策略。

这个公式的直觉非常清楚：动态策略只能在全局安全边界之内调节 utility，不能绕过底层权限规则。

```
1 policy = compose(global_policy, dynamic_policy, user_capability)
2 if compliant(tool_call, policy):
3     execute(tool_call)
4 else:
5     trigger_fallback_or_block()
```

上面的伪代码体现了本讲的一个基本立场：模型可以建议，policy engine 才能决定。

Progent: Programmable Privilege Control for LLM Agents --- Evaluation

- Significantly reduces attack-success-rate (ASR) while maintaining utility with hybrid policies on AgentDojo benchmark




Figure 5: Comparison between vanilla agent (no defense), prior defenses, and defenses enabled by Progent on AgentDojo [8].

Progent: Programmable Privilege Control for LLM Agents, 2025

图 17: Progent 的评价标准是 ASR 与 utility 的折中，而不是单纯把 agent 关死。

这也是为什么 Progent 对 agentic security 很关键。它把“最小权限”从系统设计原则变成 runtime-enforceable mechanism，并直接作用在 tool layer。对于 prompt injection、memory poisoning、malicious tool usage 这类攻击，这一层往往比 prompt template 本身更决定结果。

6.2 Privilege management 与 privilege separation

Lecture 之后把权限问题再拆开：**privilege management** 回答“谁在什么时候拥有何种权限”，**privilege separation** 回答“系统结构如何拆，使高权限能力不与高风险逻辑耦合在一起”。

Defense Mechanisms




图 18: Privilege separation 的 agentic 版本：把不同任务和能​​力拆到不同 agent / sandbox 中运行。

这两者不能混为一谈。只做 privilege management 但不做 separation，往往意味着同一个进程、同一个 agent、同一段上下文同时拥有大量能力；一旦被 prompt injection 或 memory poisoning 打穿，攻击面会非常大。Privilege separation 则试图把系统拆成多个最小可信单元，让攻击者即使控制某一层，也不容易横向移动到所有高权限组件。

Privtrans: Automatic Privilege Separation




Figure 1: We automatically incorporate privilege separation into source code by partitioning it into two programs: the monitor which handles privileged operations and the slave which executes everything else. The programmer supplies a few annotations to help Privtrans decide how to properly partition the input source code.



Figure 4: The output of translation partitions the input source code to create two programs: the monitor and the slave. RPC between the monitor and slave is accomplished via the privwrap/privunwrap functions. The monitor may consult a policy engine when asked to perform a privileged function. Finally, the monitor may save results from a function call request in case later referenced by the slave.

name	src lines	# user annotations	# calls automatically changed
chfn	745	1	12
chsh	640	1	13
ping	2299	1	31
thttpd	21925	4	13
OpenSSH	98590	2	42
OpenSSL	211675	2	7

Table 1: Results for each program with privilege separation. The second column is the number of annotations the programmer supplied. The third column is the number of call sites automatically changed by Privtrans

Privtrans: Automatically Partitioning Programs for Privilege Separation, David Brumley and Dawn Song, USENIX Security Symposium 2004


图 19: Privtrans 代表了传统系统安全里的自动 privilege separation 思想。

Privtrans 之所以在今天的 lecture 里仍然重要，不是因为 agent 要重新回到 2004 年的程序转换工具，而是因为它提醒我们：**安全边界首先是架构问题，其次才是模型问题**。当高权限 monitor 与低权限 slave 被清楚分离时，trusted computing base 会明显缩小。这正是 agent 分层、sandbox 执行、tool wrapper 与 capability tokens 的系统学根源。

6.3 Monitoring、IFT 与 formal verification

Lecture 的最后一部分讨论 detection 和 provable security。DataSentinel 代表的是 monitoring / detection 层：

DataSentinel: A Game-Theoretic Detection of Prompt Injection Attacks



DataSentinel: A Game-Theoretic Detection of Prompt Injection Attacks, Liu et al., IEEE Security and Privacy Symposium, 2025

图 20: DataSentinel 把 prompt injection detection 建模成对抗式 minimax 问题。

这类工作的重要性在于，它承认攻击者会自适应，因此检测器也必须在对抗视角下训练。但本讲同样强调：**检测只能是 defense-in-depth 的一层，不能替代 privilege boundary**。检测器有漏报和误报；一旦系统后端没有 action gate，检测失败仍会造成高后果动作。

随后第 95 页讨论 information flow tracking (IFT)。这里的核心问题是：**敏感信息如何在 agent、tool、plugin、API 和外部世界之间流动**？如果系统不知道某段信息来自哪位用户、属于哪个 trust domain，也就无法判断一次 tool call 是否会导致越权泄露。

第 97 页把问题推到更高层：能否为 **agentic system** 建立 **formal specifications**，并证明系统在各种输入条件下满足某些安全属性？

Defense Mechanisms




图 21: Formal verification 的问题不只是“能不能证明”，更是“如何给含有 LLM 的系统写出足够清楚的 specification”。

对于安全研究者来说，这里有两个必须区分的层次：

- **informal reasoning**: 比如“模型看起来通常不会泄露系统 prompt”；
- **formal specification / verification**: 比如“在什么 action abstraction、capability model 和 information-flow policy 下，系统对哪些属性给出确定保证”。

Lecture 的立场非常明确：未来的 secure agent framework 不能只停留在经验性对齐或 ad hoc prompt patching 上，而要逐步走向 **policy-grounded**、**boundary-aware**、**possibly provable** 的系统设计。

7 关键论文与课程 readings 的连接

7.1 Privtrans、AgentPoison、DataSentinel、Progent 各自补哪一层

这四篇 readings 对应 Lecture 的四个关键层：

- **Privtrans**: 说明 privilege separation 是成熟系统安全原则，强调缩小 trusted base 和 monitor/slave 分解。
- **AgentPoison**: 说明攻击面不只在 prompt，而会长期驻留于 memory 与 knowledge base。
- **DataSentinel**: 说明检测器要对 adaptive prompt injection 有博弈论视角。
- **Progent**: 说明 least privilege 可以被 concretize 为 tool-layer runtime enforcement。

从课程结构看，这一讲与前面几讲的关系也很清楚。前面课程讲 reasoning、planning、tool use、code agents、multimodal agents、theorem proving；而本讲回答的是：当这些能力都在 agent 中组合起来时，如何防止“更强能力”直接变成“更大攻击面”。

8 例子、反例、失败模式和边界条件

8.1 为什么“把 prompt 写得更严一点”通常不够

一个朴素但常见的想法是：如果 prompt injection 会覆盖系统指令，那就写更长、更强硬的 system prompt。Lecture 实际上在整讲中都在否定这个想法。原因有四个：

1. 问题常常不是当前 prompt，而是外部 data ingestion；
2. memory poisoning 可以跨会话持续生效；
3. 工具权限和执行边界通常不在 prompt 中定义；
4. 攻击者能利用 environment feedback 做自适应搜索。

所以“更强 prompt”只能看作降低攻击成功率的一种**软约束**，它不能替代 privilege gate、sandbox、data/command separation 或 IFT。

8.2 最关键的安全边界：prompt、memory、tool、identity、information flow

本讲可以提炼出五类必须显式建模的边界：

- **Prompt boundary**：哪些 token 是命令，哪些只是外部数据？
- **Memory boundary**：哪些内容允许写入长期记忆，哪些 retrieval source 有 provenance？
- **Tool boundary**：哪些动作必须走 deterministic policy engine？
- **Identity boundary**：不同用户、不同 agent、不同 capability 如何区分？
- **Information-flow boundary**：敏感信息跨组件流动时，系统能否追踪并阻止泄露？

如果任何一条边界没有被显式编码，系统就会把 LLM 的概率性输出错误升级成确定性安全后果。

9 与前后讲的联系

与前面课程相比，这一讲不是在教一种新的 reasoning algorithm，而是在给整门课加“边界条件”。例如：

- 前面讲 tool use 与 coding agents，这一讲补上了 **least privilege** 和 **policy enforcement on actions**。
- 前面讲 memory 和 planning，这一讲补上了 **memory poisoning** 与 **knowledge-base trust**。
- 前面讲 web / multimodal agents，这一讲补上了 **indirect prompt injection** 和 **environment feedback-based attacks**。
- 前面讲 theorem proving 和 formal methods，这一讲则把 **formal verification** 引回 agent system design。

因此，本讲像是整门课的“安全总线”：它把此前的能力型技术全部重新放进 adversarial environment 里再审视一遍。

10 本章小结

Conclusion

- Overview of agentic AI safety & security
- Attacks in agentic AI
- Evaluation & risk assessment in agentic AI
- Defenses in agentic AI
 - Defense principles
 - Defense mechanisms

图 22: Lecture 结论: 攻击、评测、原则和机制必须一起存在, agentic security 才能落地。

本讲最重要的结论有三条:

1. **Agentic AI 的核心安全问题是边界问题。** Prompt、memory、tool、identity、information flow 都必须被显式建模和控制。
2. **Prompt injection 不是孤立漏洞, 而是更大 attack surface 的入口。** indirect prompt injection、memory poisoning、knowledge-base poisoning 和 malicious tools 都会沿着同一条系统链传播。
3. **防御必须是 harness-managed、layered、evaluator-gated 的。** 只做 model hardening 不够, 必须同时做 privilege control、separation、monitoring、IFT 和 formal reasoning。

如果把本讲压缩成一句教材式判断, 那就是: **更强的 LLM agents 只有在更强的 system boundary 上运行, 才能真正安全。**

11 复习题

1. 用自己的话区分 AI safety 与 AI security, 并说明为什么在 agentic system 中两者会耦合。
2. 为什么 LLM 输出作为 tool arguments、branch conditions 和 executable code 时, 风险会明显高于普通文本输出?
3. 直接 prompt injection 与间接 prompt injection 的关键区别是什么?
4. 为什么 memory poisoning / knowledge base poisoning 代表更持久的攻击面?
5. 什么是 end-to-end agent evaluation? 为什么它不能被 stand-alone model benchmark 替代?

12 深入思考题

1. 若一个 web agent 读取网页 DOM 后自动执行表单提交，你会把哪些地方定义为 security boundary?
2. 如果 detection layer 和 policy layer 冲突，你会如何设计 fail-closed 策略?
3. 在 multi-agent system 中，identity、capability 与 shared memory 应该如何组合，才能同时保证 utility 与 least privilege?

13 延伸阅读

- Privtrans: Automatically Partitioning Programs for Privilege Separation.
- DataSentinel: A Game-Theoretic Detection of Prompt Injection Attacks.
- AgentPoison: Red-teaming LLM Agents via Poisoning Memory or Knowledge Bases.
- Progent: Programmable Privilege Control for LLM Agents.
- Saltzer and Schroeder (1975), *The Protection of Information in Computer Systems*.