

第 03 讲：现代 Transformer architecture 与 hyperparameters

CS336 Spring 2026 public videos and official course materials

目录

1 本章导读	4
1.1 本章知识路线	4
1.2 结构图	4
2 本章主线	4
2.1 本章要解决的核心问题	5
2.2 从机制到资源账本	5
2.3 从课堂讲解到可复现实验	6
3 术语、符号与问题边界	6
3.1 关键词	6
4 Decoder-only Transformer 的骨架	6
4.1 为什么要讨论 Decoder-only Transformer 的骨架	7
4.2 Decoder-only Transformer 的骨架的机制	7
4.3 Decoder-only Transformer 的骨架的形式化表示	7
4.4 从 Decoder-only Transformer 的骨架到程序	7
4.5 边界条件与常见误解	7
4.6 与本章其他概念的关系	8
4.7 怎样检验 Decoder-only Transformer 的骨架	8
4.8 常见混淆：Decoder-only Transformer 的骨架	8
4.9 Decoder-only Transformer 的骨架的小结	9
5 Normalization、activation 与 position encoding	9
5.1 为什么要讨论 Normalization、activation 与 position encoding	9
5.2 Normalization、activation 与 position encoding 的机制	9
5.3 Normalization、activation 与 position encoding 的数学表达	9
5.4 从 Normalization、activation 与 position encoding 到程序	10
5.5 边界条件与常见误解	10

5.6	与本章其他概念的关系	10
5.7	怎样检验 Normalization、activation 与 position encoding	10
5.8	常见混淆：Normalization、activation 与 position encoding	11
5.9	Normalization、activation 与 position encoding 的小结	11
6	Hyperparameter 的规模化视角	11
6.1	为什么要讨论 Hyperparameter 的规模化视角	11
6.2	Hyperparameter 的规模化视角的机制	11
6.3	Hyperparameter 的规模化视角的数学表达	12
6.4	从 Hyperparameter 的规模化视角到程序	12
6.5	边界条件与常见误解	12
6.6	与本章其他概念的关系	12
6.7	怎样检验 Hyperparameter 的规模化视角	12
6.8	常见混淆：Hyperparameter 的规模化视角	13
6.9	Hyperparameter 的规模化视角的小结	13
7	综合讨论：从局部机制到完整系统	13
7.1	Decoder-only Transformer 的骨架在系统中的位置	14
7.2	Normalization、activation 与 position encoding 在系统中的位置	14
7.3	Hyperparameter 的规模化视角在系统中的位置	14
7.4	把本章知识用于读论文和复现实验	14
8	例题：把概念变成可计算检查	15
8.1	Pre-norm block 的信息路径	15
9	实验设计：从小例子到可复现结论	15
9.1	最小输入	15
9.2	资源账本	15
9.3	单变量消融	15
9.4	失败条件	16
9.5	记录与报告	16
10	课程资料与回看路径	16
10.1	视频回看路径	16
10.2	课程资料阅读路径	16
11	实践说明、历史位置与风险	17
12	复习要点	17

12.1 综合自测	18
13 总结与延伸	18
13.1 本章小结	18
13.2 延伸解释	18
13.3 练习	18

1 本章导读

本章讨论 **现代 Transformer architecture 与 hyperparameters**。CS336 的第一层目标不是把现成大模型当作黑箱使用，而是把 language model 从输入文本、训练目标、模型结构、数据、系统和评估这些部件重新拆开。只有拆开之后，读者才能判断一个设计选择究竟改变了什么。设想你要从论文表格里选择一个 decoder-only Transformer recipe。所有候选模型都叫 Transformer，但 pre-norm、RMSNorm、RoPE、SwiGLU、QK norm、head layout 和 learning rate schedule 不同；本章训练你判断哪些是核心机制，哪些是经验性工程选择。本章对应 CS336 Spring 2026 第 03 个公开视频，并结合课程页提供的可解析资料。视频和课程页给出事实边界；正文把这些材料改写为可自学的教材章节。阅读本章时，先理解问题为什么存在，再看定义、公式和实现形态，随后通过例题和练习检查自己是否能独立复现这条 reasoning chain。

Lecture 3

EVERYTHING YOU DIDN'T WANT TO KNOW ABOUT
LM ARCHITECTURE AND HYPERPARAMETERS

CS336
Tatsu H



图 1: 第 03 讲的课程图像锚点。

1.1 本章知识路线


- 本章首先说明现代 Transformer architecture 与 hyperparameters 为什么是 language modeling pipeline 中不可跳过的一环。
- 其次定义本章反复使用的术语，并说明这些术语对应的计算对象或系统对象。
- 随后用公式和伪代码表达主要机制，让概念能够落到可计算的变量上。
- 最后给出例题、风险讨论和练习，便于读者检查自己是否真正掌握了机制。

1.2 结构图

下面的图用于帮助读者定位本章的核心结构。先看概念之间的依赖，再回到正文中的公式、伪代码和例题。

2 本章主线

本章可以沿着三条线索阅读：课程为什么把这个主题放在这里，它改变了哪些变量，以及怎样用小实验检查这些变量。



Outline and goals

- ❖ Quick recap of a modern transformer (what you implement)
- ❖ What do most of the large LMs have in common?
- ❖ What are common variations to the architecture / training process?

Today's theme: the best way to learn is hands-on experience
the second best way is to try to learn from others' experience

图 2: 官方材料图页: 现代 Transformer architecture 与 hyperparameters 的课程页/PDF/script 图像锚点。

Lecture 3

EVERYTHING YOU DIDN'T WANT TO KNOW ABOUT
LM ARCHITECTURE AND HYPERPARAMETERS

CS336
Tatsu H



图 3: 官方材料图页: 现代 Transformer architecture 与 hyperparameters 的课程页/PDF/script 图像锚点。

2.1 本章要解决的核心问题

本讲从现代 decoder-only Transformer 的共同骨架出发, 比较 LLaMA-like 架构里的 pre-norm、RMSNorm、RoPE、SwiGLU、bias removal、QK norm 等设计。这一点对应的学习动作是: 找出对象, 写出变量, 说明变量如何被测量。若输入规模、硬件、数据分布或评估协议改变, 结论也必须重新检查。因此, 现代 Transformer architecture 与 hyperparameters 不应被读成若干名词的集合, 而应被读成一组可检验的机制。

2.2 从机制到资源账本

架构选择不能脱离 scale。小模型 ablation 中看似微弱的差异, 在大模型训练中可能表现为稳定性、吞吐、长上下文或超参数敏感性的差异。这一点对应的学习动作是: 找出对象, 写出变量, 说明变量如何被测量。若输入规模、硬件、数据分布或评估协议改变, 结论也必须重新检查。因此, 现代 Transformer architecture 与 hyperparameters 不应被读成若干名词的集合, 而应被读成一组可检验的机制。

2.3 从课堂讲解到可复现实验

hyperparameter 的有效读法是把每个选择对应到 failure mode: 学习率过大导致发散, batch 太小导致噪声过大, context 太长带来 attention 和 KV cache 成本, width/depth 比例影响计算形状。这一点对应的学习动作是: 找出对象, 写出变量, 说明变量如何被测量。若输入规模、硬件、数据分布或评估协议改变, 结论也必须重新检查。因此, 现代 Transformer architecture 与 hyperparameters 不应被读成若干名词的集合, 而应被读成一组可检验的机制。

3 术语、符号与问题边界

本章的术语横跨模型、数据和系统。读者需要先知道每个词指向的对象: 有些词描述数学目标, 有些词描述张量形状, 有些词描述硬件瓶颈, 还有一些词描述评估协议。术语边界不清, 后面的公式和实现就会变成空洞的缩写。

#	术语	阅读要求
1	Transformer architecture (Transformer 架构)	需要能说明它指向的对象、参与的公式或代码位置, 以及一个典型失败情形。
2	pre-norm (前归一化)	需要能说明它指向的对象、参与的公式或代码位置, 以及一个典型失败情形。
3	RMSNorm	需要能说明它指向的对象、参与的公式或代码位置, 以及一个典型失败情形。
4	RoPE (rotary positional embedding)	需要能说明它指向的对象、参与的公式或代码位置, 以及一个典型失败情形。
5	SwiGLU	需要能说明它指向的对象、参与的公式或代码位置, 以及一个典型失败情形。
6	hyperparameter (超参数)	需要能说明它指向的对象、参与的公式或代码位置, 以及一个典型失败情形。

这些术语之间有依赖关系。例如 tokenization 改变 sequence length, sequence length 又改变 attention FLOPs、KV cache 和 evaluation token budget; parallelism 改变显存占用, 也改变通信瓶颈和故障恢复方式。

3.1 关键词

下面的关键词在课程材料中反复出现。它们不代替定义, 只提示读者本章哪些对象需要在后文持续跟踪。

- attention, gemma, most, embeddings, position, many, notable, transformer, palm, rmsnorm, norm, layer-norm, rope, qwen

4 Decoder-only Transformer 的骨架

现在进入 Decoder-only Transformer 的骨架。本节关心的不是名称本身, 而是它把现代 Transformer architecture 与 hyperparameters 中的哪些对象变成可计算、可测量或可优化的量。

4.1 为什么要讨论 Decoder-only Transformer 的骨架

视频把 architecture 讲成现代论文中大量细节的集合，而不是单一的 Transformer block 图。decoder-only LM 的主干通常是 token embedding、若干层 causal self-attention 和 MLP、norm、residual connection、LM head。课程材料强调许多看似小的选择会影响 scale: normalization placement、activation、position encoding、head layout、optimizer schedule。推理阶段的关键区别在于请求是在线到达的，输出又是逐 token 生成的。训练时可以用大 batch 摊薄成本；服务时还要同时考虑首 token 延迟、吞吐、显存占用和长尾请求。

4.2 Decoder-only Transformer 的骨架的机制

视频把 architecture 讲成现代论文中大量细节的集合，而不是单一的 Transformer block 图。这给出本节对象和边界。读者需要把其中的名词对应到张量、数据记录、训练状态或系统状态，而不是停留在缩写层面。decoder-only LM 的主干通常是 token embedding、若干层 causal self-attention 和 MLP、norm、residual connection、LM head。因而同一个方法在小规模示例、单机实验和集群训练中的意义并不相同。比较方法时，问题规模、硬件条件、数据分布和评估口径必须同时给出。课程材料强调许多看似小的选择会影响 scale: normalization placement、activation、position encoding、head layout、optimizer schedule。这使本节具有可检验性：如果一个结论不能在公式、伪代码、profile trace、benchmark 或 ablation 中表现出来，它就还只是直觉。因此，Decoder-only Transformer 的骨架应当被理解为一组可以实现和测试的假设。CS336 反复强调 from scratch，正是因为只有能被复现的机制，才可能被稳定改进。

4.3 Decoder-only Transformer 的骨架的形式化表示

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V$$

符号说明： Q, K, V 是 query/key/value； d_k 是 head dimension； M 是 causal mask，用于禁止看见未来 token。这个关系式给出了本节最小的数学骨架。读者应检查每个变量的单位、取值范围和可观测性；如果某个量只能间接估计，后续实验就必须说明 proxy 是什么。例如，validation loss 常被用作模型质量的 proxy，tokens/s 用作吞吐 proxy，Jaccard 或 MinHash 用作近重复 proxy，reward model score 用作偏好 proxy。proxy 不是目标本身；它只在评估协议清楚时才可引用。

4.4 从 Decoder-only Transformer 的骨架到程序

本节机制可以写成下面的伪代码。它保留课程材料中的计算顺序和状态变化，但省略了工程代码中的错误处理、并行细节和框架样板。

```
x = token_embedding(tokens)
for block in transformer_blocks:
    x = x + causal_attention(norm(x))
    x = x + mlp(norm(x))
logits = lm_head(norm(x))
```

读这段伪代码时，重点不是语法，而是状态如何变化：输入是什么，中间变量是什么，主要计算或数据移动发生在哪里，哪些边界条件会破坏结果。

4.5 边界条件与常见误解

- 公开 slides 总结的是主流设计，不代表所有 frontier models 的真实 recipe。

- architecture comparison 必须控制参数量、训练 tokens、数据和 optimizer，否则容易把 scaling 效应误判为结构效应。
- 不要把小实验中的局部结论自动外推到 frontier-scale；scale、数据分布和硬件拓扑都会改变结论。
- 不要把 benchmark 或 profile 的单个数字当作机制解释；必须同时记录实验设置、输入形状、版本和评估口径。

4.6 与本章其他概念的关系

Decoder-only Transformer 的骨架与本章其他部分的关系是互补的：术语表给出对象名称，公式给出最小数学结构，伪代码给出执行顺序，例题则把这些内容压缩成一个可检查的计算。

4.7 怎样检验 Decoder-only Transformer 的骨架

检验 Decoder-only Transformer 的骨架的第一步是确定测量对象。这里的测量对象通常不是一个抽象名词，而是与 architecture、Transformer、attention、MLP、residual 有关的张量、样本、请求、奖励、通信操作或评估记录。如果对象没有被具体化，后面的实验就只能得到描述性观察，不能得到可复现结论。第二步是构造最小输入。最小输入应该足够小，使读者能手算或打印关键中间量；同时又要保留本节机制。对于 Decoder-only Transformer 的骨架，最小输入不追求逼真规模，而追求暴露因果关系：改变一个变量时，哪些输出、成本或错误会随之改变。第三步是写出资源账本。账本可以是 FLOPs、bytes moved、显存峰值、通信量、token 数、样本数、reward 分布或 benchmark 分数。符号说明： $\backslash(Q,K,V\backslash)$ 是 query/key/value； $\backslash(d_k\backslash)$ 是 head dimension； $\backslash(M\backslash)$ 是 causal mask，用于禁止看见未来 token。这类说明应被转化为单位明确的数量关系；如果数量只能间接观测，就必须说明使用了什么 proxy。第四步是设置对照。一个好对照只改变一个因素，例如 batch size、sequence length、vocabulary size、attention heads、filter threshold、learning rate、decoding 参数或 verifier。如果多个因素同时改变，实验最多说明系统表现不同，不能说明是哪一个机制在起作用。第五步是观察失败条件。教材中的成功路径往往最容易记住，但工程中真正决定方法边界的是失败案例。本节至少要记住这些限制：公开 slides 总结的是主流设计，不代表所有 frontier models 的真实 recipe；architecture comparison 必须控制参数量、训练 tokens、数据和 optimizer，否则容易把 scaling 效应误判为结构效应。复习时可以把这些限制改写成反例测试。最后，把实验结论放回现代 Transformer architecture 与 hyperparameters 的整体结构中。Decoder-only Transformer 的骨架不是孤立技巧：它会影响训练目标、数据选择、系统成本或评估解释中的至少一项。能说清楚这种影响，才说明读者已经从名词记忆进入机制理解。

4.8 常见混淆：Decoder-only Transformer 的骨架

architecture 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Decoder-only Transformer 的骨架”中改变了哪个变量或约束。Transformer 是现代 LM 的基本计算骨架。在“Decoder-only Transformer 的骨架”中，这个概念用于解释现代 Transformer architecture 与 hyperparameters 的一个具体机制。attention（注意力）提供 token 间交互，但长上下文下成本很高。在“Decoder-only Transformer 的骨架”中，这个概念用于解释现代 Transformer architecture 与 hyperparameters 的一个具体机制。MLP 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Decoder-only Transformer 的骨架”中改变了哪个变量或约束。residual 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Decoder-only Transformer 的骨架”中改变了哪个变量或约束。这些概念的共同点是：只有进入公式、代码或评估协议之后才有明确含义。单独背诵名称不会帮助判断一个训练 run、推理系统或数据 pipeline 是否正确。

4.9 Decoder-only Transformer 的骨架的小结

- Decoder-only Transformer 的骨架的任何性能结论都必须同时报告问题规模和评估口径，否则不可比较。
- 如果一个方法声称降低主要成本，它通常会把成本转移到另一个变量，例如显存、通信、数据质量、训练稳定性或评估复杂度。
- 公式和伪代码提供推理骨架；真实系统仍需要 profiler、ablation 和 held-out evaluation。

5 Normalization、activation 与 position encoding

现在进入 Normalization、activation 与 position encoding。本节关心的不是名称本身，而是它把现代 Transformer architecture 与 hyperparameters 中的哪些对象变成可计算、可测量或可优化的量。

5.1 为什么要讨论 Normalization、activation 与 position encoding

现代 LLM 常用 RMSNorm 或类似变体以降低开销并改善稳定性。RoPE 把位置信息编码进 query/key 的旋转关系，支持相对位置信息并常见于长上下文模型。SwiGLU/GeGLU 等 gated MLP 变体体现了课程第一讲的 caveat：有些设计先来自实验，再由经验固化。Normalization、activation 与 position encoding 的作用是把现代 Transformer architecture 与 hyperparameters 中的一个抽象问题变成可计算对象：哪些变量进入公式，哪些状态进入代码，哪些条件会让结果失效。

5.2 Normalization、activation 与 position encoding 的机制

现代 LLM 常用 RMSNorm 或类似变体以降低开销并改善稳定性。这给出本节的对象和边界。读者需要把其中的名词对应到张量、数据记录、训练状态或系统状态，而不是停留在缩写层面。RoPE 把位置信息编码进 query/key 的旋转关系，支持相对位置信息并常见于长上下文模型。因而同一个方法在小规模示例、单机实验和集群训练中的意义并不相同。比较方法时，问题规模、硬件条件、数据分布和评估口径必须同时给出。SwiGLU/GeGLU 等 gated MLP 变体体现了课程第一讲的 caveat：有些设计先来自实验，再由经验固化。这使本节具有可检验性：如果一个结论不能在公式、伪代码、profile trace、benchmark 或 ablation 中表现出来，它就还只是直觉。因此，Normalization、activation 与 position encoding 应当被理解为一组可以实现和测试的假设。CS336 反复强调 from scratch，正是因为只有能被复现的机制，才可能被稳定改进。

5.3 Normalization、activation 与 position encoding 的数学表达

$$\text{RMSNorm}(x) = g \odot \frac{x}{\sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon}}$$

符号说明： x 是 hidden vector， g 是可学习缩放， d 是 hidden dimension， ϵ 防止除零。这个关系式给出了本节最小的数学骨架。读者应检查每个变量的单位、取值范围和可观测性；如果某个量只能间接估计，后续实验就必须说明 proxy 是什么。例如，validation loss 常被用作模型质量的 proxy，tokens/s 用作吞吐 proxy，Jaccard 或 MinHash 用作近重复 proxy，reward model score 用作偏好 proxy。proxy 不是目标本身；它只在评估协议清楚时才可引用。

5.4 从 Normalization、activation 与 position encoding 到程序

本节机制可以写成下面的伪代码。它保留课程材料中的计算顺序和状态变化，但省略了工程代码中的错误处理、并行细节和框架样板。

```
def rms_norm(x, weight, eps=1e-6):
    scale = rsqrt(mean(x * x, dim=-1, keepdim=True) + eps)
    return weight * x * scale
```

读这段伪代码时，重点不是语法，而是状态如何变化：输入是什么，中间变量是什么，主要计算或数据移动发生在哪里，哪些边界条件会破坏结果。

5.5 边界条件与常见误解

- 归一化改善优化，但也可能改变表示尺度和 residual stream 的解释方式。
- 长上下文 extrapolation 不能只靠位置编码，还受训练数据、attention implementation 和评估分布影响。
- 不要把小实验中的局部结论自动外推到 frontier-scale；scale、数据分布和硬件拓扑都会改变结论。
- 不要把 benchmark 或 profile 的单个数字当作机制解释；必须同时记录实验设置、输入形状、版本和评估口径。

5.6 与本章其他概念的关系

Normalization、activation 与 position encoding 与本章其他部分的关系是互补的：术语表给出对象名称，公式给出最小数学结构，伪代码给出执行顺序，例题则把这些内容压缩成一个可检查的计算。

5.7 怎样检验 Normalization、activation 与 position encoding

检验 Normalization、activation 与 position encoding 的第一步是确定测量对象。这里的测量对象通常不是一个抽象名词，而是与 RMSNorm、RoPE、SwiGLU、pre-norm、position 有关的张量、样本、请求、奖励、通信操作或评估记录。如果对象没有被具体化，后面的实验就只能得到描述性观察，不能得到可复现结论。第二步是构造最小输入。最小输入应该足够小，使读者能手算或打印关键中间量；同时又要保留本节机制。对于 Normalization、activation 与 position encoding，最小输入不追求逼真规模，而追求暴露因果关系：改变一个变量时，哪些输出、成本或错误会随之改变。第三步是写出资源账本。账本可以是 FLOPs、bytes moved、显存峰值、通信量、token 数、样本数、reward 分布或 benchmark 分数。符号说明： $\langle x \rangle$ 是 hidden vector， $\langle g \rangle$ 是可学习缩放， $\langle d \rangle$ 是 hidden dimension， $\langle \epsilon \rangle$ 防止除零。这类说明应被转化为单位明确的数量关系；如果数量只能间接观测，就必须说明使用了什么 proxy。第四步是设置对照。一个好对照只改变一个因素，例如 batch size、sequence length、vocabulary size、attention heads、filter threshold、learning rate、decoding 参数或 verifier。如果多个因素同时改变，实验最多说明系统表现不同，不能说明是哪一个机制在起作用。第五步是观察失败条件。教材中的成功路径往往最容易记住，但工程中真正决定方法边界的是失败案例。本节至少要记住这些限制：归一化改善优化，但也可能改变表示尺度和 residual stream 的解释方式；长上下文 extrapolation 不能只靠位置编码，还受训练数据、attention implementation 和评估分布影响。复习时可以把这些限制改写成反例测试。最后，把实验结论放回现代 Transformer architecture 与 hyperparameters 的整体结构中。Normalization、activation 与 position encoding 不是孤立技巧：它会影响训练目标、数据选择、系统成本或评估解释中的至少一项。能说清楚这种影响，才说明读者已经从名词记忆进入机制理解。

5.8 常见混淆: Normalization、activation 与 position encoding

normalization (归一化) 影响优化稳定性和 residual path。在“Normalization、activation 与 position encoding”中, 这个概念用于解释现代 Transformer architecture 与 hyperparameters 的一个具体机制。RoPE (rotary positional embedding) 把位置信息编码进 query/key 的旋转关系。在“Normalization、activation 与 position encoding”中, 这个概念用于解释现代 Transformer architecture 与 hyperparameters 的一个具体机制。SwiGLU 在本节中应被看作一个技术对象, 而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估, 并说明它在“Normalization、activation 与 position encoding”中改变了哪个变量或约束。normalization (归一化) 影响优化稳定性和 residual path。在“Normalization、activation 与 position encoding”中, 这个概念用于解释现代 Transformer architecture 与 hyperparameters 的一个具体机制。position 在本节中应被看作一个技术对象, 而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估, 并说明它在“Normalization、activation 与 position encoding”中改变了哪个变量或约束。这些概念的共同点是: 只有进入公式、代码或评估协议之后才有明确含义。单独背诵名称不会帮助判断一个训练 run、推理系统或数据 pipeline 是否正确。

5.9 Normalization、activation 与 position encoding 的小结

- Normalization、activation 与 position encoding 的任何性能结论都必须同时报告问题规模和评估口径, 否则不可比较。
- 如果一个方法声称降低主要成本, 它通常会把成本转移到另一个变量, 例如显存、通信、数据质量、训练稳定性或评估复杂度。
- 公式和伪代码提供推理骨架; 真实系统仍需要 profiler、ablation 和 held-out evaluation。

6 Hyperparameter 的规模化视角

现在进入 Hyperparameter 的规模化视角。本节关心的不是名称本身, 而是它把现代 Transformer architecture 与 hyperparameters 中的哪些对象变成可计算、可测量或可优化的量。

6.1 为什么要讨论 Hyperparameter 的规模化视角

lecture 3 的核心态度是: 不要把 hyperparameters 当成小模型实验后的装饰参数, 它们决定大规模训练的稳定性和资源效率。batch size、learning rate、warmup、decay、weight decay、dropout、context length 和 width/depth ratio 都进入 compute-budget 约束。本书需要把每个超参数和其 failure mode 绑定: divergence、undertraining、overfitting、memory blow-up、communication bottleneck。Hyperparameter 的规模化视角的作用是把现代 Transformer architecture 与 hyperparameters 中的一个抽象问题变成可计算对象: 哪些变量进入公式, 哪些状态进入代码, 哪些条件会让结果失效。

6.2 Hyperparameter 的规模化视角的机制

lecture 3 的核心态度是: 不要把 hyperparameters 当成小模型实验后的装饰参数, 它们决定大规模训练的稳定性和资源效率。这给出本节的对象和边界。读者需要把其中的名词对应到张量、数据记录、训练状态或系统状态, 而不是停留在缩写层面。batch size、learning rate、warmup、decay、weight decay、dropout、context length 和 width/depth ratio 都进入 compute-budget 约束。因而同一个方法在小规模示例、单机实验和集群训练中的意义并不相同。比较方法时, 问题规模、硬件条件、数据分布和评估口径必须同时给出。本书需要把每个超参数和其 failure mode 绑定: divergence、undertraining、overfitting、memory blow-up、communication bottleneck。这使本节具有可检验性: 如果一个结论不能在公式、伪代码、profile trace、benchmark 或 ablation

中表现出来，它就还只是直觉。因此，Hyperparameter 的规模化视角应当被理解为一组可以实现和测试的假设。CS336 反复强调 from scratch，正是因为只有能被复现的机制，才可能被稳定改进。

6.3 Hyperparameter 的规模化视角的数学表达

$$\theta_{t+1} = \theta_t - \eta_t \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} - \eta_t \lambda \theta_t$$

符号说明：这是 AdamW 风格更新； η_t 是学习率， $\hat{m}_t, \hat{v}_t$ 是矩估计， λ 是 decoupled weight decay。这个关系式给出了本节最小的数学骨架。读者应检查每个变量的单位、取值范围和可观测性；如果某个量只能间接估计，后续实验就必须说明 proxy 是什么。例如，validation loss 常被用作模型质量的 proxy，tokens/s 用作吞吐 proxy，Jaccard 或 MinHash 用作近重复 proxy，reward model score 用作偏好 proxy。proxy 不是目标本身；它只在评估协议清楚时才可引用。

6.4 从 Hyperparameter 的规模化视角到程序

本节机制可以写成下面的伪代码。它保留课程材料中的计算顺序和状态变化，但省略了工程代码中的错误处理、并行细节和框架样板。

```
for run in sweep:
    train_small_proxy(run)
    reject_if_unstable_or_inefficient(run)
    scale_only_after_resource_accounting(run)
```

读这段伪代码时，重点不是语法，而是状态如何变化：输入是什么，中间变量是什么，主要计算或数据移动发生在哪里，哪些边界条件会破坏结果。

6.5 边界条件与常见误解

- 小规模最优超参数不一定可直接外推。
- hyperparameter search 的成本本身也是 scaling plan 的一部分。
- 不要把小实验中的局部结论自动外推到 frontier-scale；scale、数据分布和硬件拓扑都会改变结论。
- 不要把 benchmark 或 profile 的单个数字当作机制解释；必须同时记录实验设置、输入形状、版本和评估口径。

6.6 与本章其他概念的关系

Hyperparameter 的规模化视角与本章其他部分的关系是互补的：术语表给出对象名称，公式给出最小数学结构，伪代码给出执行顺序，例题则把这些内容压缩成一个可检查的计算。

6.7 怎样检验 Hyperparameter 的规模化视角

检验 Hyperparameter 的规模化视角的第一步是确定测量对象。这里的测量对象通常不是一个抽象名词，而是与 hyperparameter、learning rate、AdamW、warmup、scale 有关的张量、样本、请求、奖励、通信操作或评估记录。如果对象没有被具体化，后面的实验就只能得到描述性观察，不能得到可复现结论。第二步是构造最小输入。最小输入应该足够小，使读者能手算或打印关键中间量；同时又要保留本节机制。对于 Hyperparameter 的规模化视角，最小输入不追求逼真规模，而追求暴露因果关系：改变一个变量时，哪些输出、成本或错误会

随之改变。第三步是写出资源账本。账本可以是 FLOPs、bytes moved、显存峰值、通信量、token 数、样本数、reward 分布或 benchmark 分数。符号说明：这是 AdamW 风格更新； η_t 是学习率， $\hat{m}_t, \hat{v}_t$ 是矩估计， λ 是 decoupled weight decay。这类说明应被转化为单位明确的数量关系；如果数量只能间接观测，就必须说明使用了什么 proxy。第四步是设置对照。一个好对照只改变一个因素，例如 batch size、sequence length、vocabulary size、attention heads、filter threshold、learning rate、decoding 参数或 verifier。如果多个因素同时改变，实验最多说明系统表现不同，不能说明是哪一个机制在起作用。第五步是观察失败条件。教材中的成功路径往往最容易记住，但工程中真正决定方法边界的是失败案例。本节至少要记住这些限制：小规模最优超参数不一定可直接外推；hyperparameter search 的成本本身也是 scaling plan 的一部分。复习时可以把这些限制改写成反例测试。最后，把实验结论放回现代 Transformer architecture 与 hyperparameters 的整体结构中。Hyperparameter 的规模化视角不是孤立技巧：它会影响训练目标、数据选择、系统成本或评估解释中的至少一项。能说清楚这种影响，才说明读者已经从名词记忆进入机制理解。

6.8 常见混淆：Hyperparameter 的规模化视角

hyperparameter 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Hyperparameter 的规模化视角”中改变了哪个变量或约束。learning rate 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Hyperparameter 的规模化视角”中改变了哪个变量或约束。AdamW 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Hyperparameter 的规模化视角”中改变了哪个变量或约束。warmup 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Hyperparameter 的规模化视角”中改变了哪个变量或约束。scale 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Hyperparameter 的规模化视角”中改变了哪个变量或约束。这些概念的共同点是：只有进入公式、代码或评估协议之后才有明确含义。单独背诵名称不会帮助判断一个训练 run、推理系统或数据 pipeline 是否正确。

6.9 Hyperparameter 的规模化视角的小结

- Hyperparameter 的规模化视角的任何性能结论都必须同时报告问题规模和评估口径，否则不可比较。
- 如果一个方法声称降低主要成本，它通常会把成本转移到另一个变量，例如显存、通信、数据质量、训练稳定性或评估复杂度。
- 公式和伪代码提供推理骨架；真实系统仍需要 profiler、ablation 和 held-out evaluation。

7 综合讨论：从局部机制到完整系统

本章的主题是现代 Transformer architecture 与 hyperparameters，但它不应被读成几个相邻知识点的拼接。Decoder-only Transformer 的骨架、Normalization、activation 与 position encoding、Hyperparameter 的规模化视角共同回答同一个问题：语言模型系统中哪些对象可以被定义，哪些成本可以被估算，哪些结论必须通过实验或评估来确认。这些对象包括 Transformer architecture (Transformer 架构)、pre-norm (前归一化)、RMSNorm、RoPE (rotary positional embedding)、SwiGLU、hyperparameter (超参数)。读者可以把它们看成一组接口：有的接口连接文本和 token，有的连接模型结构和张量计算，有的连接数据样本和训练目标，有的连接离线评估和在线服务。接口一旦改变，后面的成本、错误类型和优化空间也会随之改变。

7.1 Decoder-only Transformer 的骨架在系统中的位置

Decoder-only Transformer 的骨架首先提供一个局部解释：视频把 architecture 讲成现代论文中大量细节的集合，而不是单一的 Transformer block 图。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，Decoder-only Transformer 的骨架会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，Decoder-only Transformer 的骨架不能脱离边界条件理解。一个关键 caveat 是：公开 slides 总结的是主流设计，不代表所有 frontier models 的真实 recipe。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.2 Normalization、activation 与 position encoding 在系统中的位置

Normalization、activation 与 position encoding 首先提供一个局部解释：现代 LLM 常用 RMSNorm 或类似变体以降低开销并改善稳定性。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，Normalization、activation 与 position encoding 会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，Normalization、activation 与 position encoding 不能脱离边界条件理解。一个关键 caveat 是：归一化改善优化，但也可能改变表示尺度和 residual stream 的解释方式。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.3 Hyperparameter 的规模化视角在系统中的位置

Hyperparameter 的规模化视角首先提供一个局部解释：lecture 3 的核心态度是：不要把 hyperparameters 当成小模型实验后的装饰参数，它们决定大规模训练的稳定性和资源效率。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，Hyperparameter 的规模化视角会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，Hyperparameter 的规模化视角不能脱离边界条件理解。一个关键 caveat 是：小规模最优超参数不一定可直接外推。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.4 把本章知识用于读论文和复现实验

读相关论文时，可以把本章变成一个检查表。第一，论文是否清楚定义了输入规模、模型规模、数据来源和评估协议；第二，论文声称的改进落在哪个变量上；第三，作者是否报告了会让结论失效的设置；第四，实验是否能分离模型结构、数据质量、优化设置和系统实现的影响。复现实验时，也应避免直接追求大规模。先用最小程序复现一个公式、一个伪代码分支或一个 profile 现象，再扩大输入规模。这样做的原因很简单：如果小规模程序无法解释中间量，大规模训练只会把错误隐藏在日志和随机波动里。把这些检查合在一起，本章给出的不是一个固定答案，而是一种阅读 CS336 的方法：每个模型机制都要落到变量，每个变量都要落到测量，每个测量都要说明协议，每个协议都要承认边界。因此，本章中的任何一句结论都可以被改写成一个可引用的完整句式：在给定数据、模型、硬件和评估协议下，某个机制改变了某个变量，并通过某个观测指标表现

出来。这样的句子比单独背诵术语更长，但它包含了自学、复现和引用时真正需要的信息。把本章用于自学时，可以按三遍阅读。第一遍只追踪对象和定义，确认每个术语到底指向文本、token、张量、样本、请求还是评估记录。第二遍追踪公式和伪代码，确认每一步改变了哪些状态。第三遍追踪实验和 caveat，确认哪些结论只在特定规模、数据或硬件条件下成立。把本章用于复习时，则应反过来操作：先从一个失败案例或异常指标出发，再回到相应机制。loss 曲线异常可能指向数据、优化或模型容量；吞吐异常可能指向 kernel、通信或调度；benchmark 异常可能指向 contamination、prompt protocol 或采样设置。能够从异常反推机制，是掌握本章的实用标准。

8 例题：把概念变成可计算检查

8.1 Pre-norm block 的信息路径

比较 post-norm 和 pre-norm residual block：二者都有 attention/MLP，但 normalization 放置不同。

- pre-norm 写作 `'x <- x + f(norm(x))'`，主 residual path 不直接穿过 normalization。
- post-norm 写作 `'x <- norm(x + f(x))'`，每层都会重标定 residual stream。
- 大模型训练中，pre-norm 常被偏好，因为梯度和 residual 信息路径更稳定。

结论。架构细节要从优化稳定性、表示尺度和实现成本一起解释，不能只画 block 图。这个例题的目的不是替代完整工程实现，而是给出一种最小推理形式：把问题转成变量，写出近似公式或伪代码，再说明近似何时失效。

9 实验设计：从小例子到可复现结论

学习现代 Transformer architecture 与 hyperparameters 不能停在概念层。一个教材化结论至少需要四件事：可构造的输入、可观测的中间量、可比较的指标，以及清楚的失败条件。下面的实验设计不是要求训练大模型，而是要求读者用小规模程序复现本章机制。

9.1 最小输入

先构造只触发本章核心机制的小输入。例如 tokenizer 章节可以用几个包含 rare words 和 Unicode 字符的字符串；GPU 章节可以用一个 elementwise kernel 和一个 GEMM；data 章节可以用十几篇近重复文档。小输入的价值在于它让错误可见。

9.2 资源账本

对同一输入写下 FLOPs、bytes moved、显存峰值、通信量或样本数量的估算。估算不需要一开始就精确，但必须说明单位和近似假设。随后用 profiler、benchmark、validation loss 或人工检查去验证估算是否同量级。

9.3 单变量消融

一次只改变一个因素，例如 vocabulary size、head 数、batch size、filter threshold、reward scale、decoding temperature 或 GPU 数量。若多个变量同时变化，实验只能说明系统变了，不能说明机制是什么。

9.4 失败条件

最后要刻意触发失败：极端 context length、错误 dtype、过小 batch、污染 benchmark、低质量数据或不可靠 verifier。失败条件常常比成功曲线更能说明一个方法的边界。

9.5 记录与报告

实验记录应能让另一个读者复现同一结论。最少要写清楚输入构造、代码版本、随机种子、硬件、batch shape、数据版本、评价指标和异常处理方式。报告结论时不要只写“更快”或“更好”，而要说明快在哪里、好在哪个指标上，以及是否牺牲了内存、稳定性、数据质量或可解释性。常见报告错误是把局部现象写成普遍规律。例如一次小模型实验里的 loss 改善，不等于更大模型或不同数据分布上也会改善；一次 kernel benchmark 的吞吐提升，不等于端到端 serving latency 一定降低。教材中的实验报告应始终把结论限定在可复现条件内。

10 课程资料与回看路径

教材正文已经把主要概念、公式和实现逻辑组织成连续叙述；本节只提供回到课程材料的阅读路径。读者复习时可以先完成前文练习，再按下面的时间段或资料组核对细节。

10.1 视频回看路径

时间	关键词	复习任务
00:00:05-00:07:01	going, we're, different, there's, then, that's, architecture	回看定义、例子、推导或 caveat 在该段中的位置。
00:21:58-00:29:40	think, very, relu, going, architecture, then, output	回看定义、例子、推导或 caveat 在该段中的位置。
00:43:57-00:51:44	very, your, think, well, ratio, head, heads	回看定义、例子、推导或 caveat 在该段中的位置。
00:59:12-01:06:34	decay, think, very, weight, language, maybe, your	回看定义、例子、推导或 caveat 在该段中的位置。
01:21:33-01:29:08	attention, think, very, your, performance, full, it's	回看定义、例子、推导或 caveat 在该段中的位置。

这些时间段用于定位视频中的讲解顺序。严肃引用时，应回到视频片段确认讲者表述、板书或幻灯片内容。回看视频时，不必逐字抄录字幕。更有效的方法是把每个时间段判定为定义、例子、推导、代码解释或 caveat，再把它放回本章对应小节。

10.2 课程资料阅读路径

资料组	标题/页块	关键词
official_01	Lecture 3 E V E R Y T H I N G Y O U D I D N ' T W A N T T O K N O W A B O U T L M A R C H I T E ...	architecture, many, common, learn, layernorm, architectures, modern

official_02	Pre-vs-post-norm, the data Salazar and Ngyuen 2019 Figure from Xiong 2020	rmsnorm, notable, norm, bias, most, gated, original
official_03	Do gated linear units work? Yes, fairly consistently so. Shazeer 2020	embeddings, position, rope, at- tention, embedding, relative, lay- ers
official_05	Evidence on aspect ratio scaling [Kaplan et al 2020] [Tay et al 2021]	attention, head, dropout, weight, decay, softmax, total
official_06	Sparse / sliding window attention Attending to the entire context can be expensive ...	attention, gemma, sparse, full, info, rope, olmo

课程资料通常给出更稳定的标题、公式、图或代码结构；视频则补充动机和口头解释。两者合起来构成本章的事实边界。阅读资料时，可以把每个资料组拆成三个对象：一个定义，一个公式或伪代码动作，一个边界条件。这样比逐字翻译页面或脚本更容易形成可用知识。

11 实践说明、历史位置与风险

现代 Transformer architecture 与 hyperparameters 在 CS336 的课程结构中连接基础机制和规模化问题。基础机制解释方法为什么成立；规模化问题检验它在更大模型、更长上下文、更复杂数据或真实 serving workload 下是否仍成立。历史位置不等于模型年表。更重要的是识别问题如何迁移：早期方法解决小规模建模问题，现代方法常常解决同一问题在大规模数据、GPU 集群、长上下文或人类偏好约束下的新形态。

- 资料版本限制 (version risk): 课程页、公开视频和配套资料可能在学期中更新；引用时应注明访问日期或资料版本。
- 测量口径限制 (measurement risk): FLOPs、tokens/s、benchmark score、reward 等数字只有在协议完整时可比较。
- 规模外推限制 (scaling risk): 小模型或小 batch 的机制不必然外推到 frontier-scale。
- 数据分布限制 (data risk): 数据来源、过滤和去重策略会改变模型行为，也会改变 evaluation contamination 风险。

12 复习要点

下面的问题把本章内容压缩为可反复检查的条目。每个条目都应能回到前文的解释、公式、伪代码或例题。

条目	对象	检查动作
条目 1	Transformer architecture (Transformer 架构)	定义它；写出一个最小例子；说明一个 failure mode；指出它影响哪个资源或评估账本。
条目 2	pre-norm (前归一化)	定义它；写出一个最小例子；说明一个 failure mode；指出它影响哪个资源或评估账本。
条目 3	RMSNorm	定义它；写出一个最小例子；说明一个 failure mode；指出它影响哪个资源或评估账本。

条目 4	RoPE (rotary positional embedding)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 5	SwiGLU	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 6	hyperparameter (超参数)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。

12.1 综合自测

- 我能否不用课程原句，独立解释本章中心问题？
- 我能否把本章至少一个公式改写成可运行的估算函数？
- 我能否指出一个看似改进但实际转移成本的方法？
- 我能否回到视频和课程资料，找到支持本章关键论断的位置？
- 我能否设计一个最小 ablation，验证本章一个 caveat？

13 总结与延伸

13.1 本章小结

- 现代 Transformer architecture 与 hyperparameters 的核心不是记忆术语，而是理解对象、变量和机制之间的关系。
- 视频给出讲解顺序，课程资料提供可核对的公式、图、代码或页面结构。
- 复习时应把每个术语连接到至少一个变量、一个实现动作和一个失败模式。

13.2 延伸解释

本章中的延伸解释用于连接课程材料中的概念，例如说明公式里的 proxy、解释系统 tradeoff，或把多个材料片段串成一个完整推理链。若需要严肃引用，应回到课程视频和配套资料核对原始表述。

13.3 练习

- 定义题：用中英双语解释本章任意五个重要术语，并说明它们属于 compute、memory、data、optimization、evaluation 还是 deployment 账本。
- 推导题：选择本章一个公式，逐个解释符号、单位和近似假设，并说明哪个变量最难在真实系统中测量。
- 实现题：把本章伪代码改写成一个最小 Python sanity check，不要求训练大模型，但要输出可检查的中间量。
- 资料题：从“课程资料与回看路径”中选择一个视频时间段，回到原始视频核对讲者例子，并记录是否存在字幕误差。
- 评估题：为本章方法设计一个 ablation 或 benchmark，说明控制变量、数据版本、指标和 failure criteria。

- 边界题：说明本章一个结论在更长 context、更大 batch、更多 GPU 或更复杂数据分布下可能如何失效。
- 综合题：把本章内容和前一章或后一章连接起来，写出一个端到端训练/推理 pipeline 中的依赖关系。
- 批判题：指出一个容易被营销材料夸大的说法，并用本章的资源账本或评估协议反驳它。