

第 09 讲: Scaling laws 基础

CS336 Spring 2026 public videos and official course materials

目录

1 本章导读	4
1.1 本章知识路线	4
1.2 结构图	4
2 本章主线	4
2.1 本章要解决的核心问题	4
2.2 从机制到资源账本	5
2.3 从课堂讲解到可复现实验	5
3 术语、符号与问题边界	6
3.1 术语之间的关系	6
4 为什么 scaling laws 有用	6
4.1 课程目标与问题边界	6
4.2 为什么 scaling laws 有用的机制	7
4.3 资源、效率与效果的关系	7
4.4 把课程目标写成检查流程	7
4.5 边界条件与常见误解	7
4.6 与本章其他概念的关系	7
4.7 怎样检验这一课程目标	8
4.8 概念辨析: 为什么 scaling laws 有用	8
4.9 为什么 scaling laws 有用的小结	8
5 IsoFLOPs 与 compute-optimal tradeoff	8
5.1 为什么要讨论 IsoFLOPs 与 compute-optimal tradeoff	8
5.2 IsoFLOPs 与 compute-optimal tradeoff 的机制	9
5.3 IsoFLOPs 与 compute-optimal tradeoff 的数学表达	9
5.4 从 IsoFLOPs 与 compute-optimal tradeoff 到程序	9
5.5 边界条件与常见误解	9

5.6	与本章其他概念的关系	9
5.7	怎样检验 IsoFLOPs 与 compute-optimal tradeoff	10
5.8	概念辨析: IsoFLOPs 与 compute-optimal tradeoff	10
5.9	IsoFLOPs 与 compute-optimal tradeoff 的小结	10
6	从小实验到大训练的风险控制	10
6.1	为什么要讨论从小实验到大训练的风险控制	10
6.2	从小实验到大训练的风险控制的机制	11
6.3	从小实验到大训练的风险控制的数学表达	11
6.4	从从小实验到大训练的风险控制到程序	11
6.5	边界条件与常见误解	11
6.6	与本章其他概念的关系	11
6.7	怎样检验从小实验到大训练的风险控制	12
6.8	概念辨析: 从小实验到大训练的风险控制	12
6.9	从小实验到大训练的风险控制的小结	12
7	综合讨论: 从局部机制到完整系统	12
7.1	为什么 scaling laws 有用在系统中的位置	12
7.2	IsoFLOPs 与 compute-optimal tradeoff 在系统中的位置	13
7.3	从小实验到大训练的风险控制在系统中的位置	13
7.4	把本章知识用于读论文和复现实验	13
8	例题: 把概念变成可计算检查	14
8.1	固定 compute 下选 N 与 D	14
9	实验设计: 从小例子到可复现结论	14
9.1	最小输入	14
9.2	资源账本	14
9.3	单变量消融	14
9.4	失败条件	14
9.5	记录与报告	15
9.6	从小实验到大结论	15
9.7	把本章重新读成一条证据链	15
10	课程资料与回看路径	15
10.1	视频回看路径	15
10.2	课程资料阅读路径	16
11	实践说明、历史位置与风险	16

12 复习要点	17
12.1 综合自测	17
13 总结与延伸	17
13.1 本章小结	17
13.2 延伸解释	18
13.3 练习	18

1 本章导读

本章讨论 **Scaling laws 基础**。CS336 的第一层目标不是把现成大模型当作黑箱使用，而是把 language model 从输入文本、训练目标、模型结构、数据、系统和评估这些部件重新拆开。只有拆开之后，读者才能判断一个设计选择究竟改变了什么。设想你只有预算训练一次大模型。Scaling laws（缩放律）的作用，是用一组小实验预测大训练，并在固定 compute 下选择参数量和 token 数，而不是用昂贵试错赌一个配置。本章对应 CS336 Spring 2026 第 09 个公开视频，并结合课程页提供的可解析资料。视频和课程页给出事实边界；正文把这些材料改写为可自学的教材章节。阅读本章时，先理解问题为什么存在，再看定义、公式和实现形态，随后通过例题和练习检查自己是否能独立复现这条 reasoning chain。

Lecture 9

SCALING LAWS - BASICS

CS336



图 1: 第 09 讲的课程图像锚点。

1.1 本章知识路线

- 本章首先说明 Scaling laws 基础为什么是 language modeling pipeline 中不可跳过的一环。
- 其次定义本章反复使用的术语，并说明这些术语对应的计算对象或系统对象。
- 随后用公式和伪代码表达主要机制，让概念能够落到可计算的变量上。
- 最后给出例题、风险讨论和练习，便于读者检查自己是否真正掌握了机制。

1.2 结构图

下面的图用于帮助读者定位本章的核心结构。先看概念之间的依赖，再回到正文中的公式、伪代码和例题。

2 本章主线

Scaling laws 基础的主线是从小规模实验走向大规模决策。读者需要同时追踪参数量、token 数、compute budget、loss 和 benchmark 之间的关系。

2.1 本章要解决的核心问题

本讲介绍 scaling laws 的基础动机：用小规模实验预测大规模训练，而不是在昂贵大模型上盲目调参。读完这一段后，应能用一两句话说明 Scaling laws 基础要解决的瓶颈，并指出这个瓶颈发生在数据、模型、优化、

Taking scaling seriously

Imagine the following scenario..

Your friend has given you ten thousand B200s for a month,
and asked you to build a good open source LM.

What do you do?

- Put together your infra team and distributed training framework (A2)
- Put together a great pretraining dataset (A4)
- Run a big model (but which one??) <- we are here.

图 2: 官方材料图页: Scaling laws 基础的课程页/PDF/script 图像锚点。

Lecture 9

SCALING LAWS - BASICS

CS336

图 3: 官方材料图页: Scaling laws 基础的课程页/PDF/script 图像锚点。

系统还是评估层。

2.2 从机制到资源账本

核心问题是固定 compute budget 时如何选择参数量 N 和训练 token 数 D 。Chinchilla 式分析把模型大小、数据量和 loss 连接到一个可决策的曲面。随后把机制写成账本: 输入规模是什么, 主要状态是什么, 成本或质量指标怎样随变量改变。这个账本让后面的公式不再只是符号。

2.3 从课堂讲解到可复现实验

scaling law 是经验预测工具, 不是自然定律。数据分布变化、优化失败、architecture 改动和评估污染都会让外推失效。最后把课堂讲解转成可复现实验: 固定协议, 改变一个变量, 记录中间量, 并解释结果为何支持或反驳原来的机制判断。

3 术语、符号与问题边界

本章的术语横跨模型、数据和系统。读者需要先知道每个词指向的对象：有些词描述数学目标，有些词描述张量形状，有些词描述硬件瓶颈，还有一些词描述评估协议。术语边界不清，后面的公式和实现就会变成空洞的缩写。

#	术语	阅读要求
1	scaling law（缩放律）	给出定义、一个最小例子、一个关联公式或代码位置，以及一个典型失败情形。
2	loss（损失）	说明它测量的对象、协议依赖和可能的 contamination 或 prompt 敏感性。
3	compute-optimal（计算最优）	把它放入资源账本：单位是什么，随输入规模怎样变化，最容易被哪类 benchmark 误读。
4	Chinchilla	给出定义、一个最小例子、一个关联公式或代码位置，以及一个典型失败情形。
5	IsoFLOP curve（等 FLOPs 曲线）	把它放入资源账本：单位是什么，随输入规模怎样变化，最容易被哪类 benchmark 误读。

这些术语之间有依赖关系。例如 tokenization 改变 sequence length，sequence length 又改变 attention FLOPs、KV cache 和 evaluation token budget；parallelism 改变显存占用，也改变通信瓶颈和故障恢复方式。

3.1 术语之间的关系

在本章中，scaling law（缩放律）给出问题入口，loss（损失）描述主要机制，compute-optimal（计算最优）则把机制连接到可测量的结果。读教材时应当沿着这个链条追问：输入是什么，中间状态怎样改变，输出指标为什么随之变化。课程材料还会反复出现 scaling、data、laws、size、batch、performance 等词。它们不是一组同义标签，而是提示本章的不同层次：有的指对象，有的指操作，有的指约束或指标。因此，术语表不是背诵清单，而是后文阅读的索引。遇到一个术语时，先定位它属于 representation、optimization、systems、data 还是 evaluation，再判断它改变哪一项账本。

4 为什么 scaling laws 有用

本节讨论为什么 scaling laws 有用。它先限定 Scaling laws 基础要回答的基本问题：哪些现象需要解释，哪些变量可以测量，哪些结论必须回到参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系中检验。

4.1 课程目标与问题边界

视频把本讲称为离开 systems 后回到 deep learning 的 scaling law 基础。scaling law 让大规模训练从盲目试错变成可预测实验：用小 runs 估计大 run 的 loss。真正的用途是决策：给定 compute/data budget，应选多大模型、多少 tokens、什么训练长度。为什么 scaling laws 有用把 Scaling laws 基础连接到大规模决策。接下来要看的不是曲线是否平滑，而是实验点、预算变量和外推假设是否一致。

4.2 为什么 scaling laws 有用的机制

视频把本讲称为离开 systems 后回到 deep learning 的 scaling law 基础。在为什么 scaling laws 有用中，核心对象是模型规模、token 数和训练预算：小实验只有在预算、数据和优化条件清楚时，才可能支持大规模外推。scaling law 让大规模训练从盲目试错变成可预测实验：用小 runs 估计大 run 的 loss。因而同一个方法在不同规模下可能改变不同的变量，尤其是参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。比较方法时，必须同时给出问题规模和实验条件。真正的用途是决策：给定 compute/data budget，应选多大模型、多少 tokens、什么训练长度。可检验性来自多个实验点、残差分析和外推误差估计；单条曲线若没有不确定性，就不能支撑大规模决策。因此，为什么 scaling laws 有用的学习目标是建立一套外推判断：读者应能说明小实验为何能或不能指导 Scaling laws 基础中的大训练配置。

4.3 资源、效率与效果的关系

$$L(N, D) = L_{\infty} + AN^{-\alpha} + BD^{-\beta}$$

符号说明： L 是 validation loss， N 是参数量， D 是训练 tokens， α, β 控制随规模下降的速度。这个关系式给出为什么 scaling laws 有用的缩放假设。它把参数量、训练 token 数和 compute budget 放到同一张账本中，重点是判断小实验能否可靠外推到大训练。在 scaling 实验中，validation loss、benchmark transfer 和训练吞吐都只是不同侧面的 proxy。外推时要说明哪个 proxy 被拟合，哪个 proxy 只是辅助诊断。

4.4 把课程目标写成检查流程

把为什么 scaling laws 有用写成程序后，抽象机制会变成输入、状态和输出之间的变换。下面的伪代码保留核心计算顺序。

```
fit_loss_surface(small_runs)
for budget in budgets:
    choose_N_D_that_minimizes_predicted_loss(budget)
```

阅读这段流程时，重点看小规模实验怎样产生可外推曲线。参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系需要在每个实验点上同时记录，缺少其中一项都会改变 scaling 解释。

4.5 边界条件与常见误解

- 缩放律是经验模型，不是自然定律。
- 分布变化、优化失败、数据质量变化会破坏外推。
- 小规模 scaling 曲线不一定覆盖大训练的优化不稳定、数据瓶颈和系统瓶颈。
- compute-optimal 结论依赖目标指标；以 loss 最优并不自动意味着 benchmark、latency 或成本最优。

4.6 与本章其他概念的关系

为什么 scaling laws 有用连接本章的小实验和大规模决策：术语表标出预算变量，公式给出外推结构，伪代码组织实验点，例题检查 compute-optimal 判断是否稳健。

4.7 怎样检验这一课程目标

检验这一课程目标时，先把抽象说法落到模型规模、token 数和训练预算上。与 scaling laws、loss、parameters、tokens、predict 相关的对象必须能被构造、打印、计数或评分；否则实验只能得到描述性观察，不能得到可复现结论。一个合适的小实验应当保留本节机制，同时让参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系中至少一个量发生可解释变化。输入规模不必逼真；关键是读者能手算或打印关键中间量，并说明哪个变量触发了结果变化。随后把公式说明转成可记录的数量关系。符号说明： $\backslash(L\backslash)$ 是 validation loss， $\backslash(N\backslash)$ 是参数量， $\backslash(D\backslash)$ 是训练 tokens， $\backslash(\text{lpha},\text{beta}\backslash)$ 控制随规模下降的速度。如果数量只能间接观测，就必须说明使用了什么 proxy；如果使用 benchmark 或 reward，也要说明协议和随机性。scaling 消融通常一次只改变参数量、token 数、数据 pipeline 或优化 schedule。若多个轴同时移动，曲线拟合会混合不同机制。最后检查失败条件。工程判断往往在反例中变清楚：缩放律是经验模型，不是自然定律；分布变化、优化失败、数据质量变化会破坏外推。复习时可以把这些限制改写成反例测试，观察它们怎样改变参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。把实验结论放回 Scaling laws 基础时，要说明为什么 scaling laws 有用改变的是预算轴、拟合曲线、外推误差还是目标指标。能拆开这些因素，才说明读者真正理解 scaling。

4.8 概念辨析：为什么 scaling laws 有用

scaling laws、loss、parameters、tokens、predict 常一起出现在 scaling 讨论中，但它们分别指预算轴、拟合对象、外推假设或风险来源。读者应先确定曲线中的自变量和因变量。其中，scaling laws（缩放律）用小实验预测大模型 loss 或能力趋势。区分这些词时，可以先问它们是否改变参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。一个术语如果不能对应到变量、状态、代码路径或评估协议，就还没有形成可操作含义。围绕为什么 scaling laws 有用复习时，可以画三到五个小实验点：记录参数量、token 数、预算和 loss，再检查外推是否合理。

4.9 为什么 scaling laws 有用的小结

- 讨论为什么 scaling laws 有用时，应同时报告问题规模、实验设置和主要观测变量，尤其是参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。
- 如果方法声称可以外推，要说明实验点覆盖范围、拟合形式和数据管线是否一致；曲线本身不是自然定律。
- scaling 结论需要把 loss、benchmark 和成本之间的转换关系说清楚，否则 compute-optimal 只是一条局部经验曲线。

5 IsoFLOPs 与 compute-optimal tradeoff

现在进入 IsoFLOPs 与 compute-optimal tradeoff。这一节把模型大小、训练 token、compute budget 和 loss 放在同一坐标系里，讨论何时可以从小实验推断大训练。

5.1 为什么要讨论 IsoFLOPs 与 compute-optimal tradeoff

IsoFLOP curve 固定训练 compute，在不同 $\backslash(N,D\backslash)$ 组合中找最小 loss。Chinchilla 结论推动了对 under-trained large models 的反思：大模型不一定优于更小但训练更充分的模型。课程强调这种分析应服务于资源配置，而不是把某条论文曲线当作永恒配方。IsoFLOPs 与 compute-optimal tradeoff 把 Scaling laws 基础连接到大规模决策。接下来要看的不是曲线是否平滑，而是实验点、预算变量和外推假设是否一致。

5.2 IsoFLOPs 与 compute-optimal tradeoff 的机制

IsoFLOP curve 固定训练 compute, 在不同 (N, D) 组合中找最小 loss。在 IsoFLOPs 与 compute-optimal tradeoff 中, 核心对象是模型规模、token 数和训练预算: 小实验只有在预算、数据和优化条件清楚时, 才可能支持大规模外推。Chinchilla 结论推动了对 undertrained large models 的反思: 大模型不一定优于更小但训练更充分的模型。因而同一个方法在不同规模下可能改变不同的变量, 尤其是参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。比较方法时, 必须同时给出问题规模和实验条件。课程强调这种分析应服务于资源配置, 而不是把某条论文曲线当作永恒配方。可检验性来自多个实验点、残差分析和外推误差估计; 单条曲线若没有不确定性, 就不能支撑大规模决策。因此, IsoFLOPs 与 compute-optimal tradeoff 的学习目标是建立一套外推判断: 读者应能说明小实验为何能或不能指导 Scaling laws 基础中的大训练配置。

5.3 IsoFLOPs 与 compute-optimal tradeoff 的数学表达

$$C \approx 6ND, \quad (N^*, D^*) = \arg \min_{6ND=C} L(N, D)$$

符号说明: C 是总训练 FLOPs; N^*, D^* 是固定 compute 下预测最优的参数数量和 token 数。这个关系式给出 IsoFLOPs 与 compute-optimal tradeoff 的缩放假设。它把参数量、训练 token 数和 compute budget 放到同一张账本中, 重点是判断小实验能否可靠外推到大训练。在 scaling 实验中, validation loss、benchmark transfer 和训练吞吐都只是不同侧面的 proxy。外推时要说明哪个 proxy 被拟合, 哪个 proxy 只是辅助诊断。

5.4 从 IsoFLOPs 与 compute-optimal tradeoff 到程序

把 IsoFLOPs 与 compute-optimal tradeoff 写成程序后, 抽象机制会变成输入、状态和输出之间的变换。下面的伪代码保留核心计算顺序。

```
for N in candidate_model_sizes:
    D = compute_budget / (6 * N)
    loss = scaling_law(N, D)
select_min_loss_configuration()
```

阅读这段流程时, 重点看小规模实验怎样产生可外推曲线。参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系需要在每个实验点上同时记录, 缺少其中一项都会改变 scaling 解释。

5.5 边界条件与常见误解

- 公式里的 $6ND$ 是近似; architecture 和 sequence length 会改变常数。
- compute-optimal 不等于 latency-optimal 或 serving-cost-optimal。
- 小规模 scaling 曲线不一定覆盖大训练的优化不稳定、数据瓶颈和系统瓶颈。
- compute-optimal 结论依赖目标指标; 以 loss 最优并不自动意味着 benchmark、latency 或成本最优。

5.6 与本章其他概念的关系

IsoFLOPs 与 compute-optimal tradeoff 连接本章的小实验和大规模决策: 术语表标出预算变量, 公式给出外推结构, 伪代码组织实验点, 例题检查 compute-optimal 判断是否稳健。

5.7 怎样检验 IsoFLOPs 与 compute-optimal tradeoff

检验 IsoFLOPs 与 compute-optimal tradeoff 时，先把抽象说法落到模型规模、token 数和训练预算上。与 IsoFLOPs、compute-optimal、Chinchilla、6ND、budget 相关的对象必须能被构造、打印、计数或评分；否则实验只能得到描述性观察，不能得到可复现结论。一个合适的小实验应当保留本节机制，同时让参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系中至少一个量发生可解释变化。输入规模不必逼真；关键是读者能手算或打印关键中间量，并说明哪个变量触发了结果变化。随后把公式说明转成可记录的数量关系。符号说明： $\backslash(C\backslash)$ 是总训练 FLOPs； $\backslash(N^{\star}, D^{\star}\backslash)$ 是固定 compute 下预测最优的参数量和 token 数。如果数量只能间接观测，就必须说明使用了什么 proxy；如果使用 benchmark 或 reward，也要说明协议和随机性。scaling 消融通常一次只改变参数量、token 数、数据 pipeline 或优化 schedule。若多个轴同时移动，曲线拟合会混合不同机制。最后检查失败条件。工程判断往往在反例中变清楚：公式里的 6ND 是近似；architecture 和 sequence length 会改变常数；compute-optimal 不等于 latency-optimal 或 serving-cost-optimal。复习时可以把这些限制改写成反例测试，观察它们怎样改变参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。把实验结论放回 Scaling laws 基础时，要说明 IsoFLOPs 与 compute-optimal tradeoff 改变的是预算轴、拟合曲线、外推误差还是目标指标。能拆开这些因素，才说明读者真正理解 scaling。

5.8 概念辨析：IsoFLOPs 与 compute-optimal tradeoff

IsoFLOPs、compute-optimal、Chinchilla、6ND、budget 常一起出现在 scaling 讨论中，但它们分别指预算轴、拟合对象、外推假设或风险来源。读者应先确定曲线中的自变量和因变量。其中，FLOPs (floating-point operations) 是训练和推理成本账本的核心单位；Chinchilla 风格分析把参数量、token 数和 compute budget 联系起来。区分这些词时，可以先问它们是否改变参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。一个术语如果不能对应到变量、状态、代码路径或评估协议，就还没有形成可操作含义。围绕 IsoFLOPs 与 compute-optimal tradeoff 复习时，可以画三到五个小实验点：记录参数量、token 数、预算和 loss，再检查外推是否合理。

5.9 IsoFLOPs 与 compute-optimal tradeoff 的小结

- 讨论 IsoFLOPs 与 compute-optimal tradeoff 时，应同时报告问题规模、实验设置和主要观测变量，尤其是参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。
- 如果方法声称可以外推，要说明实验点覆盖范围、拟合形式和数据管线是否一致；曲线本身不是自然定律。
- scaling 结论需要把 loss、benchmark 和成本之间的转换关系说清楚，否则 compute-optimal 只是一条局部经验曲线。

6 从小实验到大训练的风险控制

现在进入从小实验到大训练的风险控制。这一节把模型大小、训练 token、compute budget 和 loss 放在同一坐标系里，讨论何时可以从小实验推断大训练。

6.1 为什么要讨论从小实验到大训练的风险控制

scaling law 实验要覆盖足够的模型大小、数据量和训练长度，否则拟合不稳定。validation loss 的测量要保持数据分布一致，并避免污染和重复。当预测大 run 时，置信区间、残差分析和 sanity checks 比单个点预测更重要。从小实验到大训练的风险控制把 Scaling laws 基础连接到大规模决策。接下来要看的不是曲线是否平滑，而是实验点、预算变量和外推假设是否一致。

6.2 从小实验到大训练的风险控制的机制

scaling law 实验要覆盖足够的模型大小、数据量和训练长度，否则拟合不稳定。在从小实验到大训练的风险控制中，核心对象是模型规模、token 数和训练预算：小实验只有在预算、数据和优化条件清楚时，才可能支持大规模外推。validation loss 的测量要保持数据分布一致，并避免污染和重复。因而同一个方法在不同规模下可能改变不同的变量，尤其是参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。比较方法时，必须同时给出问题规模和实验条件。当预测大 run 时，置信区间、残差分析和 sanity checks 比单个点预测更重要。可检验性来自多个实验点、残差分析和外推误差估计；单条曲线若没有不确定性，就不能支撑大规模决策。因此，从小实验到大训练的风险控制的学习目标是建立一套外推判断：读者应能说明小实验为何能或不能指导 Scaling laws 基础中的大训练配置。

6.3 从小实验到大训练的风险控制的数学表达

$$\hat{L}_{\text{large}} \pm z\sigma_{\text{residual}}$$

符号说明： $\hat{L}_{\text{large}}$ 是预测 loss， σ_{residual} 是小实验拟合残差的尺度。这个关系式给出从小实验到大训练的风险控制的缩放假设。它把参数量、训练 token 数和 compute budget 放到同一张账本中，重点是判断小实验能否可靠外推到大训练。在 scaling 实验中，validation loss、benchmark transfer 和训练吞吐都只是不同侧面的 proxy。外推时要说明哪个 proxy 被拟合，哪个 proxy 只是辅助诊断。

6.4 从从小实验到大训练的风险控制到程序

把从小实验到大训练的风险控制写成程序后，抽象机制会变成输入、状态和输出之间的变换。下面的伪代码保留核心计算顺序。

```
runs = launch_grid(model_sizes, token_counts)
fit = robust_fit(runs)
plot_residuals_and_refuse_bad_extrapolation(fit)
```

阅读这段流程时，重点看小规模实验怎样产生可外推曲线。参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系需要在每个实验点上同时记录，缺少其中一项都会改变 scaling 解释。

6.5 边界条件与常见误解

- 过度外推会把小模型 regime 的现象误用于大模型。
- 数据 pipeline 改变后，旧 scaling law 需要重新校准。
- 小规模 scaling 曲线不一定覆盖大训练的优化不稳定、数据瓶颈和系统瓶颈。
- compute-optimal 结论依赖目标指标；以 loss 最优并不自动意味着 benchmark、latency 或成本最优。

6.6 与本章其他概念的关系

从小实验到大训练的风险控制连接本章的小实验和大规模决策：术语表标出预算变量，公式给出外推结构，伪代码组织实验点，例题检查 compute-optimal 判断是否稳健。

6.7 怎样检验从小实验到大训练的风险控制

检验从小实验到大训练的风险控制时，先把抽象说法落到模型规模、token 数和训练预算上。与 extrapolation、residual、validation、grid、forecast 相关的对象必须能被构造、打印、计数或评分；否则实验只能得到描述性观察，不能得到可复现结论。一个合适的小实验应当保留本节机制，同时让参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系中至少一个量发生可解释变化。输入规模不必逼真；关键是读者能手算或打印关键中间量，并说明哪个变量触发了结果变化。随后把公式说明转成可记录的数量关系。符号说明： $\hat{L}_{\text{ext}\{\text{large}\}}$ 是预测 loss， $\sigma_{\text{ext}\{\text{residual}\}}$ 是小实验拟合残差的尺度。如果数量只能间接观测，就必须说明使用了什么 proxy；如果使用 benchmark 或 reward，也要说明协议和随机性。scaling 消融通常一次只改变参数量、token 数、数据 pipeline 或优化 schedule。若多个轴同时移动，曲线拟合会混合不同机制。最后检查失败条件。工程判断往往在反例中变清楚：过度外推会把小模型 regime 的现象误用于大模型；数据 pipeline 改变后，旧 scaling law 需要重新校准。复习时可以把这些限制改写成反例测试，观察它们怎样改变参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。把实验结论放回 Scaling laws 基础时，要说明从小实验到大训练的风险控制改变的是预算轴、拟合曲线、外推误差还是目标指标。能拆开这些因素，才说明读者真正理解 scaling。

6.8 概念辨析：从小实验到大训练的风险控制

extrapolation、residual、validation、grid、forecast 常一起出现在 scaling 讨论中，但它们分别指预算轴、拟合对象、外推假设或风险来源。读者应先确定曲线中的自变量和因变量。区分这些词时，可以先问它们是否改变参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。一个术语如果不能对应到变量、状态、代码路径或评估协议，就还没有形成可操作含义。围绕从小实验到大训练的风险控制复习时，可以画三到五个小实验点：记录参数量、token 数、预算和 loss，再检查外推是否合理。

6.9 从小实验到大训练的风险控制的小结

- 讨论从小实验到大训练的风险控制时，应同时报告问题规模、实验设置和主要观测变量，尤其是参数量、训练 token 数、compute budget、loss 外推误差和 benchmark 转化关系。
- 如果方法声称可以外推，要说明实验点覆盖范围、拟合形式和数据管线是否一致；曲线本身不是自然定律。
- scaling 结论需要把 loss、benchmark 和成本之间的转换关系说清楚，否则 compute-optimal 只是一条局部经验曲线。

7 综合讨论：从局部机制到完整系统

本章的主题是 Scaling laws 基础，但它不应被读成几个相邻知识点的拼接。为什么 scaling laws 有用、IsoFLOPs 与 compute-optimal tradeoff、从小实验到大训练的风险控制共同回答同一个问题：语言模型系统中哪些对象可以被定义，哪些成本可以被估算，哪些结论必须通过实验或评估来确认。这些对象包括 scaling law (缩放律)、loss (损失)、compute-optimal (计算最优)、Chinchilla、IsoFLOP curve (等 FLOPs 曲线)。读者可以把它们看成一组接口：有的接口连接文本和 token，有的连接模型结构和张量计算，有的连接数据样本和训练目标，有的连接离线评估和在线服务。接口一旦改变，后面的成本、错误类型和优化空间也会随之改变。

7.1 为什么 scaling laws 有用在系统中的位置

为什么 scaling laws 有用首先提供一个局部解释：视频把本讲称为离开 systems 后回到 deep learning 的 scaling law 基础。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、

输出、中间状态和失败条件，而不是只记住方法名。其次，为什么 scaling laws 有用会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，为什么 scaling laws 有用不能脱离边界条件理解。一个关键 caveat 是：缩放律是经验模型，不是自然定律。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.2 IsoFLOPs 与 compute-optimal tradeoff 在系统中的位置

IsoFLOPs 与 compute-optimal tradeoff 首先提供一个局部解释：IsoFLOP curve 固定训练 compute，在不同 (N,D) 组合中找最小 loss。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，IsoFLOPs 与 compute-optimal tradeoff 会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，IsoFLOPs 与 compute-optimal tradeoff 不能脱离边界条件理解。一个关键 caveat 是：公式里的 $6ND$ 是近似；architecture 和 sequence length 会改变常数。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.3 从小实验到大训练的风险控制在系统中的位置

从小实验到大训练的风险控制首先提供一个局部解释：scaling law 实验要覆盖足够的模型大小、数据量和训练长度，否则拟合不稳定。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，从小实验到大训练的风险控制会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，从小实验到大训练的风险控制不能脱离边界条件理解。一个关键 caveat 是：过度外推会把小模型 regime 的现象误用于大模型。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.4 把本章知识用于读论文和复现实验

读相关论文时，可以把本章变成一个检查表。第一，论文是否清楚定义了输入规模、模型规模、数据来源和评估协议；第二，论文声称的改进落在哪个变量上；第三，作者是否报告了会让结论失效的设置；第四，实验是否能分离模型结构、数据质量、优化设置和系统实现的影响。复现实验时，也应避免直接追求大规模。先用最小程序复现一个公式、一个伪代码分支或一个 profile 现象，再扩大输入规模。这样做的原因很简单：如果小规模程序无法解释中间量，大规模训练只会把错误隐藏在日志和随机波动里。把这些检查合在一起，本章给出的不是一个固定答案，而是一种阅读 CS336 的方法：每个模型机制都要落到变量，每个变量都要落到测量，每个测量都要说明协议，每个协议都要承认边界。因此，本章中的任何一句结论都可以被改写成一个可引用的完整句式：在给定数据、模型、硬件和评估协议下，某个机制改变了某个变量，并通过某个观测指标表现出来。这样的句子比单独背诵术语更长，但它包含了自学、复现和引用时真正需要的信息。把本章用于自学时，可以按三遍阅读。第一遍只追踪对象和定义，确认每个术语到底指向文本、token、张量、样本、请求还是评估记录。第二遍追踪公式和伪代码，确认每一步改变了哪些状态。第三遍追踪实验和 caveat，确认哪些结论只在特定规模、数据或硬件条件下成立。把本章用于复习时，则应反过来操作：先从一个失败案例或异常指标出发，再回到相应机制。loss 曲线异常可能指向数据、优化或模型容量；吞吐异常可能指向 kernel、通信或调度；

benchmark 异常可能指向 contamination、prompt protocol 或采样设置。能够从异常反推机制，是掌握本章的实用标准。

8 例题：把概念变成可计算检查

8.1 固定 compute 下选 N 与 D

给定 ‘C 6ND’，如果模型参数 ‘N’ 翻倍，而 compute 固定，则训练 tokens ‘D’ 约减半。

- 大模型 token 不足会 undertrained。
- 小模型 token 充足但容量可能限制 loss。
- IsoFLOP 实验通过多个 ‘N,D’ 点拟合 loss 曲面。

结论。 compute-optimal 是一个受数据、模型和目标指标共同影响的选择问题。这个例题的目的不是替代完整工程实现，而是给出一种最小推理形式：把问题转成变量，写出近似公式或伪代码，再说明近似何时失效。

9 实验设计：从小例子到可复现结论

学习 Scaling laws 基础不能停在概念层。一个教材化结论至少需要四件事：可构造的输入、可观测的中间量、可比较的指标，以及清楚的失败条件。下面的实验设计不是要求训练大模型，而是要求读者用小规模程序复现本章机制。

9.1 最小输入

先构造只触发本章核心机制的小输入。例如 tokenizer 章节可以用几个包含 rare words 和 Unicode 字符的字符串；GPU 章节可以用一个 elementwise kernel 和一个 GEMM；data 章节可以用十几篇近重复文档。小输入的价值在于它让错误可见。

9.2 资源账本

对同一输入写下 FLOPs、bytes moved、显存峰值、通信量或样本数量的估算。估算不需要一开始就精确，但必须说明单位和近似假设。随后用 profiler、benchmark、validation loss 或人工检查去验证估算是否同量级。

9.3 单变量消融

一次只改变一个因素，例如 vocabulary size、head 数、batch size、filter threshold、reward scale、decoding temperature 或 GPU 数量。若多个变量同时变化，实验只能说明系统变了，不能说明机制是什么。

9.4 失败条件

最后要刻意触发失败：极端 context length、错误 dtype、过小 batch、污染 benchmark、低质量数据或不可靠 verifier。失败条件常常比成功曲线更能说明一个方法的边界。

9.5 记录与报告

实验记录应能让另一个读者复现同一结论。最少要写清楚输入构造、代码版本、随机种子、硬件、batch shape、数据版本、评价指标和异常处理方式。报告结论时不要只写“更快”或“更好”，而要说明快在哪里、好在哪个指标上，以及是否牺牲了内存、稳定性、数据质量或可解释性。常见报告错误是把局部现象写成普遍规律。例如一次小模型实验里的 loss 改善，不等于更大模型或不同数据分布上也会改善；一次 kernel benchmark 的吞吐提升，不等于端到端 serving latency 一定降低。教材中的实验报告应始终把结论限定在可复现条件内。

9.6 从小实验到大结论

小实验的作用不是替代课程中的完整训练或系统实现，而是建立一条可检查的推理链。先在小输入上确认变量方向，再在中等规模上确认数量级，最后才讨论是否能外推到更大模型、更多 token 或更复杂 workload。缺少中间层级时，大结论通常只是在复述直觉。因此，实验报告最好同时包含正例和反例：正例说明机制在受控条件下怎样工作，反例说明条件稍变时哪里失效。对 CS336 这样的课程，反例尤其重要，因为 language model 的错误常来自多个层面叠加：数据分布、优化稳定性、硬件瓶颈、评估协议和服务负载都可能同时改变观察结果。还要记录资料版本与复现边界。公开视频、课程页、配套代码和 PDF 可能在不同时间更新；复现实验应写明使用的材料版本，并说明哪些结论来自课程事实，哪些是为了帮助理解而加入的解释性推导。这样才能把学习笔记变成可检查的技术记录。若复现实验与课程结论不一致，首先检查输入、版本和评估协议，而不是立即修改模型假设。

9.7 把本章重新读成一条证据链

完成小实验之后，可以把 Scaling laws 基础重新读成一条证据链：先用“为什么 scaling laws 有用”确定问题入口，再用“IsoFLOPs 与 compute-optimal tradeoff”解释主要机制，最后用“从小实验到大训练的风险控制”检查边界或外推条件。这种读法比按页背诵更接近教材训练，因为它要求每个结论都能说明前提、变量和证据。本章反复使用的术语包括 scaling law (缩放律)、loss (损失)、compute-optimal (计算最优)、Chinchilla、IsoFLOP curve (等 FLOPs 曲线)。复习时不要只写定义，而要为每个术语补上一句操作性说明：它在课程代码、公式、数据记录或评估协议中对应什么对象；如果这个对象被删除、替换或缩放，哪一个观测量会变化。最后，用一个反例结束复习。反例可以是资源估算不准、数据污染、reward 失真、benchmark 解析失败、长上下文显存爆炸或 scaling 外推失效。能解释反例的章节，才真正具备自学和引用价值；不能解释反例的章节，只是把课程材料换了一种排版。引用本章结论时，还应保留来源边界：哪些说法直接来自视频、课程页、slides 或代码，哪些是为了串联教材叙述而加入的解释性推导。这个边界不会削弱结论，反而让读者知道何处可以复核，何处需要在自己的实验中重新验证。如果后续课程材料更新，也可以沿着同一证据链替换来源，而不必重写整章结构。

10 课程资料与回看路径

教材正文已经把主要概念、公式和实现逻辑组织成连续叙述；本节只提供回到课程材料的阅读路径。读者复习时可以先完成前文练习，再按下面的时间段或资料组核对细节。

10.1 视频回看路径

时间	关键词	复习任务
----	-----	------

00:00:06-00:06:49	scaling, very, going, that's, laws, scale, your	回看定义、例子、推导或 caveat 在该段中的位置。
00:20:24-00:26:39	data, scaling, than, small, that's, mixture, laws	回看定义、例子、推导或 caveat 在该段中的位置。
00:39:11-00:45:44	batch, number, going, size, your, parameters, point	回看定义、例子、推导或 caveat 在该段中的位置。
00:52:07-00:58:35	very, going, think, scaling, data, it's, your	回看定义、例子、推导或 caveat 在该段中的位置。
01:11:20-01:17:53	think, scaling, chinchilla, compute, very, training, scale	回看定义、例子、推导或 caveat 在该段中的位置。

这些时间段用于定位视频中的讲解顺序。严肃引用时，应回到视频片段确认讲者表述、板书或幻灯片内容。回看视频时，不必逐字抄录字幕。更有效的方法是把每个时间段判定为定义、例子、推导、代码解释或 caveat，再把它放回本章对应小节。

10.2 课程资料阅读路径

资料组	标题/页块	关键词
official_01	Lecture 9 S C A L I N G L A W S - B A S I C S CS336	scaling, laws, your, together, simple, predictive, tune
official_02	Earliest (data) scaling law paper –1993	scaling, data, early, earliest, history, laws, hestness
official_03	Hestness II Very ahead of its time.. “Emergence” Scaling by compute Speed = accuracy	scaling, data, laws, performance, dataset, size, error
official_05	Side note – ‘Value of parameters’ With MoEs, we expect parameter scaling to change	scaling, batch, size, critical, data, joint, over
official_06	Explanation 2 Non-embedding vs total param choice + small nonlinearities	param, tokens, data, scaling, compute, chinchilla, small

课程资料通常给出更稳定的标题、公式、图或代码结构；视频则补充动机和口头解释。两者合起来构成本章的事实边界。阅读资料时，可以把每个资料组拆成三个对象：一个定义，一个公式或伪代码动作，一个边界条件。这样比逐字翻译页面或脚本更容易形成可用知识。

11 实践说明、历史位置与风险

Scaling laws 基础在 CS336 的课程结构中连接基础机制和规模化问题。基础机制解释方法为什么成立；规模化问题检验它在更大模型、更长上下文、更复杂数据或真实 serving workload 下是否仍成立。历史位置不等于模型年表。更重要的是识别问题如何迁移：早期方法解决小规模建模问题，现代方法常常解决同一问题在大规模数据、GPU 集群、长上下文或人类偏好约束下的新形态。

- 资料版本限制 (version risk): 课程页、公开视频和配套资料可能在学期中更新；引用时应注明访问日期或资料版本。
- 测量口径限制 (measurement risk): FLOPs、tokens/s、benchmark score、reward 等数字只有在协议完整时可比较。

- 规模外推限制 (scaling risk): 小模型或小 batch 的机制不必然外推到 frontier-scale。
- 数据分布限制 (data risk): 数据来源、过滤和去重策略会改变模型行为, 也会改变 evaluation contamination 风险。

12 复习要点

下面的问题把本章内容压缩为可反复检查的条目。每个条目都应能回到前文的解释、公式、伪代码或例题。

条目	对象	检查动作
条目 1	scaling law (缩放律)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 2	loss (损失)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 3	compute-optimal (计算最优)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 4	Chinchilla	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 5	IsoFLOP curve (等 FLOPs 曲线)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。

12.1 综合自测

- 我能否不用课程原句, 独立解释本章中心问题?
- 我能否把本章至少一个公式改写成可运行的估算函数?
- 我能否指出一个看似改进但实际转移成本的方法?
- 我能否回到视频和课程资料, 找到支持本章关键论断的位置?
- 我能否设计一个最小 ablation, 验证本章一个 caveat?

13 总结与延伸

13.1 本章小结

- Scaling laws 基础的核心不是记忆术语, 而是理解对象、变量和机制之间的关系。
- 视频给出讲解顺序, 课程资料提供可核对的公式、图、代码或页面结构。
- 复习时应把每个术语连接到至少一个变量、一个实现动作和一个失败模式。

13.2 延伸解释

本章中的延伸解释用于连接课程材料中的概念，例如说明公式里的 proxy、解释系统 tradeoff，或把多个材料片段串成一个完整推理链。若需要严肃引用，应回到课程视频和配套资料核对原始表述。

13.3 练习

- 定义题：用中英双语解释本章任意五个重要术语，并说明它们属于 compute、memory、data、optimization、evaluation 还是 deployment 账本。
- 推导题：选择本章一个公式，逐个解释符号、单位和近似假设，并说明哪个变量最难在真实系统中测量。
- 实现题：把本章伪代码改写成一个最小 Python sanity check，不要求训练大模型，但要输出可检查的中间量。
- 资料题：从“课程资料与回看路径”中选择一个视频时间段，回到原始视频核对讲者例子，并记录是否存在字幕误差。
- 评估题：为本章方法设计一个 ablation 或 benchmark，说明控制变量、数据版本、指标和 failure criteria。
- 边界题：说明本章一个结论在更长 context、更大 batch、更多 GPU 或更复杂数据分布下可能如何失效。
- 综合题：把本章内容和前一章或后一章连接起来，写出一个端到端训练/推理 pipeline 中的依赖关系。
- 批判题：指出一个容易被营销材料夸大的说法，并用本章的资源账本或评估协议反驳它。