课程笔记

CS336 第 11 讲：Scaling Laws II

Codex 基于 Stanford CS336 2025 第 11 讲视频、字幕与课程材料整理

2026 年 4 月 7 日

视频作者/频道：Stanford Online
发布日期：2025 年 06 月 02 日
视频时长：1:18:13
视频链接：`https://www.youtube.com/watch?v=OSYuUqGBQxw`

目录

1 Scaling Laws II：从漂亮曲线到可执行 recipe **2**

1.1 为什么第 11 讲要从 Chinchilla 继续往前走 2

1.2 公开案例的意义：CerebrasGPT、MiniCPM、DeepSeek 2

1.3 本章小结 2

2 muP：让小模型调参更像是在给大模型调参 **2**

2.1 muP 想解决的不是“性能更高”，而是“迁移更稳” 2

2.2 课程如何解释 muP 的原则 3

2.3 本章小结 4

3 MiniCPM：把 batch、学习率和数据配比都纳入缩放分析 **4**

3.1 从“固定配方”到“系统拟合最优超参数” 4

3.2 最优 batch size 和最优学习率为什么也值得拟合 4

3.3 WSD 学习率调度为什么能让 Chinchilla 拟合更便宜 4

3.4 本章小结 5

4 数据模型配比已经不止“20 倍参数量”了 **5**

4.1 joint fit 和 lower envelope 给出了更高的数据比 5

4.2 为什么“更多数据”这件事在现代 recipe 里越来越常见 6

4.3 本章小结 7

5 DeepSeek 和更近的 recipe：muP 不是唯一道路 **7**

5.1 DeepSeek 代表了另一种工程哲学 7

5.2 最近的公开模型在做什么 7

5.3 本章小结 8

6 总结与延伸 **8**

1 Scaling Laws II：从漂亮曲线到可执行 recipe

1.1 为什么第 11 讲要从 Chinchilla 继续往前走

第 9 讲把 scaling laws 当成一种方法论：在小规模上拟合规律，再把规律外推到大规模。第 11 讲则追问一个更现实的问题：到了 2024–2025 年，真正公开做出强模型的团队，到底是怎样把这套方法落地的？

课程给出的答案很明确。今天的 scaling recipe 已经不只是“估一个 data-to-model ratio”，而是把 **参数化方式、学习率调度、batch/LR 缩放、joint fit 和 isoflop 分析**一起纳入。换句话说，现代 recipe 不是一条单独的曲线，而是一整组互相配合的假设和操作。

第 11 讲的压缩目标

把 scaling laws 从“曲线长什么样”推进到“团队怎样真的用这些曲线来选模型、选 batch、选学习率、选调度以及选数据配比”。

1.2 公开案例的意义：CerebrasGPT、MiniCPM、DeepSeek

课程选择 CerebrasGPT、MiniCPM 和 DeepSeek 作为主要案例，很有代表性。它们都不是把 Chinchilla 原封不动复刻，而是在现代开源模型训练里把 scaling 进一步工程化。CerebrasGPT 更强调 muP 带来的稳定超参数迁移；MiniCPM 在 muP 之外又系统拟合最优 batch、最优学习率和数据配比；DeepSeek 则展示了即便不显式采用 muP，也可以用更直接的经验搜索和 isoflop 分析拿到很强结果。

这三条路线的共同点是：**它们都不再愿意在最大模型上盲试**。差别只在于，有的团队相信“先让参数化更可迁移”，有的团队相信“直接把关键超参数都做 scaling fit”。

第 11 讲最重要的边界提醒

不要把某一份 scaling recipe 当成“跨所有模型和数据都成立的物理定律”。课程一再强调：只要架构、训练目标、数据分布或优化细节发生变化，拟合就可能需要重做。

1.3 本章小结

第 11 讲的起点不是再复述 Kaplan，而是把问题推进到现代公开 recipe：今天真正有竞争力的模型团队，如何把 scaling 变成可以执行的训练流程。

2 muP：让小模型调参更像是在给大模型调参

2.1 muP 想解决的不是“性能更高”，而是“迁移更稳”

课程用非常工程化的语言介绍 muP。它的核心承诺不是神奇地让模型更强，而是让不同宽度模型之间的超参数搜索更有尺度不变性。对训练团队来说，这意味着：如果我在一个较小模型上找到了合适的学习率、初始化和若干缩放规则，那么这些设置在更大模型上仍然更可能保持有效。

这件事为什么重要？因为没有这种稳定性，小模型实验的外推价值会迅速下降。你在 100M 模型上扫出来的超参数，到了 10B 模型也许完全失效；那样一来，scaling laws 只能帮你估模型和数据比例，却帮不了最贵的调参问题。muP 的意义就是尽量把这道门重新打开。

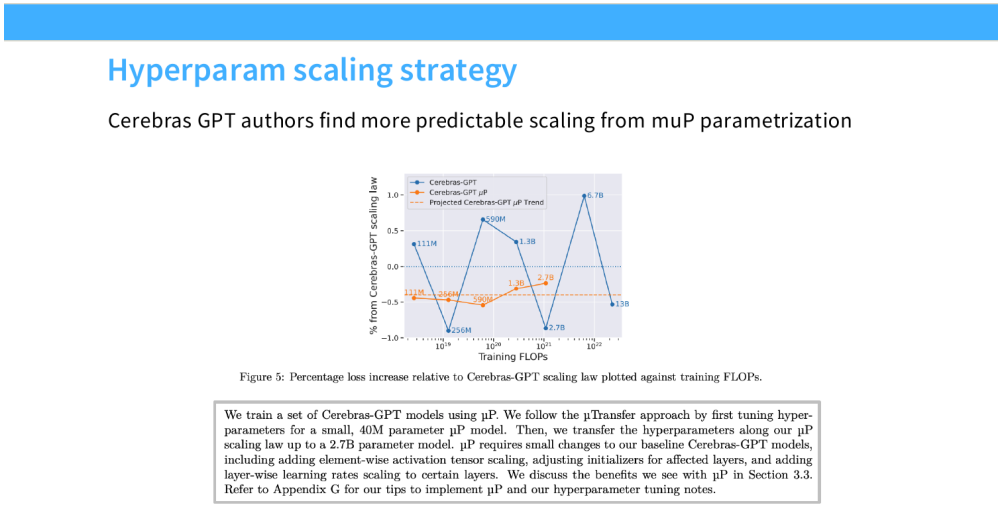

Figure 5: Percentage loss increase relative to Cerebras-GPT scaling law plotted against training FLOPs.

图 1: CerebrasGPT 的结果表明，muP 可以让超参数缩放关系更可预测。

2.2 课程如何解释 muP 的原则

课程没有停留在“这东西很好用”的经验论上，而是给出了两个直观条件：

- 初始化时各层激活量级应保持在 $\Theta(1)$，不要随着网络宽度爆炸或消失；
- 做一步梯度更新后，激活变化也应保持在合理量级，不要因为宽度变化而让更新完全失真。

这两个条件听上去抽象，但它们在工程上对应得很具体：embedding 输出如何缩放，残差分支如何缩放，权重初始化标准差怎样设定，不同张量的学习率是否要随宽度变化做补偿。课程的意思是，**muP 本质上是在给“宽度变化时什么东西应该保持不变”下规则**。

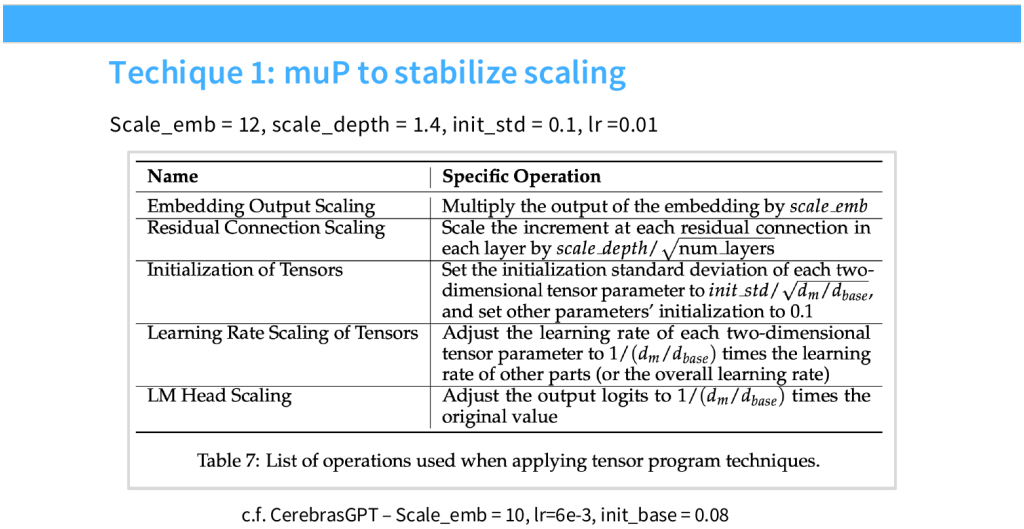

Name	Specific Operation
Embedding Output Scaling	Multiply the output of the embedding by $scale_emb$
Residual Connection Scaling	Scale the increment at each residual connection in each layer by $scale_depth/\sqrt{\text{num_layers}}$
Initialization of Tensors	Set the initialization standard deviation of each two-dimensional tensor parameter to $init_std/\sqrt{d_m/d_{base}}$, and set other parameters' initialization to 0.1
Learning Rate Scaling of Tensors	Adjust the learning rate of each two-dimensional tensor parameter to $1/(d_m/d_{base})$ times the learning rate of other parts (or the overall learning rate)
LM Head Scaling	Adjust the output logits to $1/(d_m/d_{base})$ times the original value

Table 7: List of operations used when applying tensor program techniques.

图 2: MiniCPM 公开列出了 muP 相关的具体操作：embedding 输出、残差、初始化和张量学习率缩放。

为什么 muP 值得单独讲一整段

因为它不是某个局部 trick，而是在回答 scaling workflow 里最贵的那个问题：怎样让小模型上的调参结果更可信地迁移到大模型上。

2.3 本章小结

muP 的真正价值不在于某一个公式，而在于它试图让“用小模型代替大模型做超参数搜索”这件事更可靠。对任何希望压缩试错成本的团队来说，这都是非常现实的收益。

3 MiniCPM：把 batch、学习率和数据配比都纳入缩放分析

3.1 从“固定配方”到“系统拟合最优超参数”

MiniCPM 是这讲里最系统的案例之一。课程强调，它并没有满足于“用了 muP，所以超参数更稳”这种粗粒度结论，而是进一步去拟合最优 batch、最优学习率和 token-to-size ratio。换句话说，MiniCPM 不只是想知道曲线往哪走，而是想知道在不同规模下具体该怎么训。

这让第 11 讲和第 9 讲形成了很好的呼应：第 9 讲说 scaling laws 可以指导工程变量，第 11 讲则展示了真的有人把工程变量一项项拿去拟合。这里最关键的思想，是把 hyperparameter scaling 本身也当成要建模的对象，而不是只拿固定经验值沿用到所有规模。

3.2 最优 batch size 和最优学习率为什么也值得拟合

课程给出的 MiniCPM 结果说明，随着模型规模和目标损失变化，最优 batch size 会呈现相当干净的规律；学习率在 muP 框架下则更接近尺度稳定。对训练团队来说，这意味着你不必在每个规模上从头大扫参数，而是可以先用较小模型找到一条趋势，再把它带到更大实验中。

这一步很重要，因为 batch 和 LR 直接决定训练稳定性、吞吐和最终收敛速度。只估数据和模型比例，却不估 batch/LR，得到的 recipe 仍然是不完整的。

3.3 WSD 学习率调度为什么能让 Chinchilla 拟合更便宜

课程特别看重 WSD（warmup-stable-decay）调度。传统 Chinchilla 分析为了得到不同模型、不同 token 数下的完整损失，需要做大量从头训练，成本接近平方级膨胀。WSD 的价值在于：你可以在 stable phase 结束后继续延长训练或重启，从而以更低成本估算不同 token-budget 下的表现。

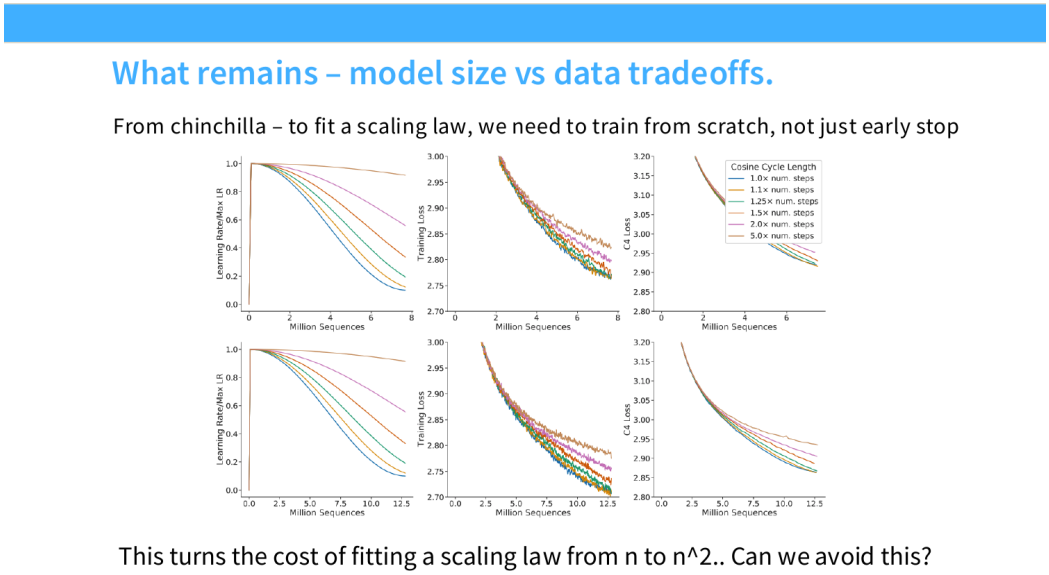

图 3: WSD 调度把训练过程拆成 warmup、stable 和 decay，使得 token-to-size 分析更便宜。

课程在这里传达了一个很务实的思想：**如果拟合 scaling law 本身太贵，那么这套方法论就会失去意义**。 WSD 并不只是一个学习率技巧，它是让 scaling analysis 变得“可承受”的流程设计。

3.4 本章小结

MiniCPM 的案例说明，现代 scaling recipe 可以比 Chinchilla 更细。团队不仅能估模型和数据比例，还能把 batch、学习率以及调度本身一起纳入拟合流程。

4 数据模型配比已经不止“20 倍参数量”了

4.1 joint fit 和 lower envelope 给出了更高的数据比

课程讲到 MiniCPM 的数据配比分析时，最值得注意的结论是：他们得到的最优 data-to-model ratio 显著高于经典的 Chinchilla 经验值。也就是说，随着架构、优化和训练流程改进，很多现代 LLM 可能值得喂远比“20 倍参数量”更多的数据。

这里课程展示了两种思路。一种是 lower envelope，也就是看一组不同模型在不同计算预算下的最优边界；另一种是 joint fit，直接拟合参数规模和数据规模共同作用的表面。两者形式不同，但目标相同：找到固定预算下模型和数据的更优耦合点。

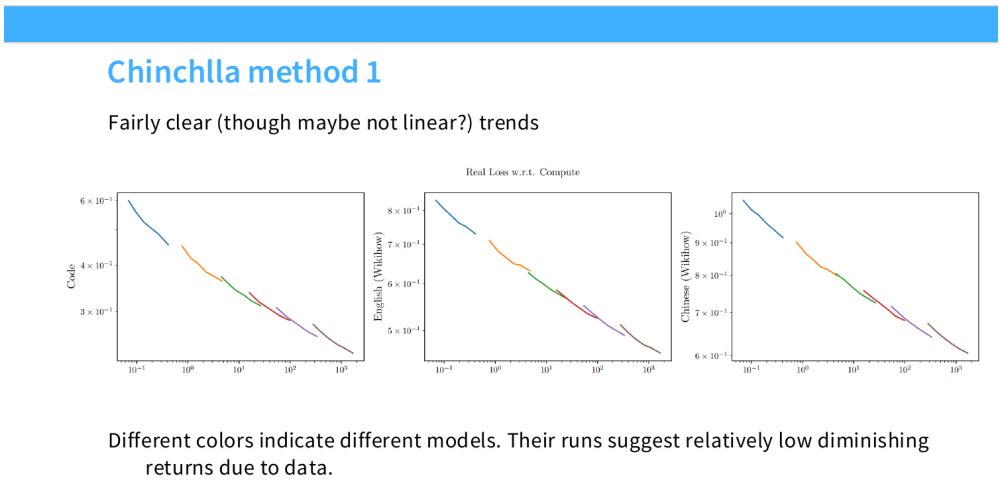

图 4: MiniCPM 的 Chinchilla method 1 说明：随着模型和数据变化，最优边界可以从实验点中读出来。

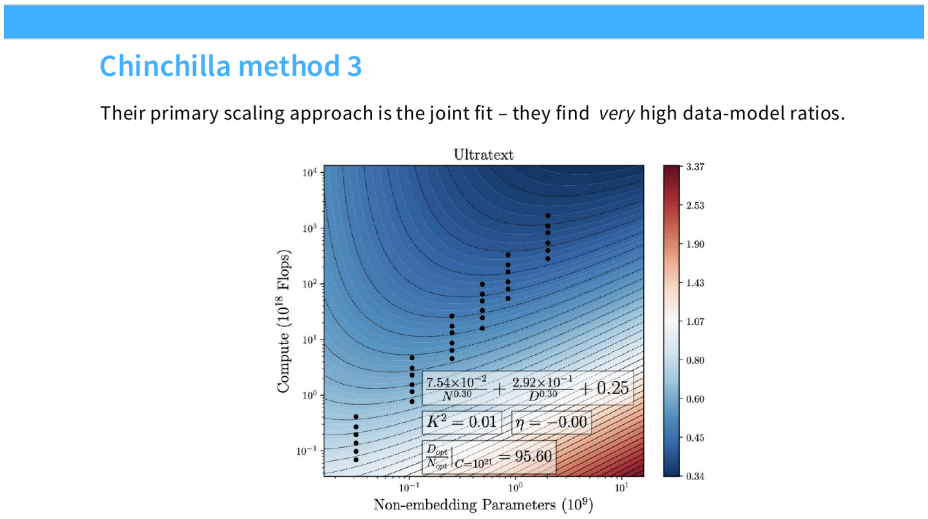

图 5: joint fit 直接在参数规模和计算预算上拟合二维曲面，从而得到数据与模型的最优配比。

4.2 为什么“更多数据”这件事在现代 recipe 里越来越常见

课程特别指出，LLaMA 3 等较新的模型也倾向于采用更高的数据配比。这个趋势并不意味着 Chinchilla 错了，而是说明最优配比不是静态常数，它会随着架构选择、学习率调度、优化器和训练细节一起变化。只要这些部分更好，模型也许就能更有效地消化更多数据。

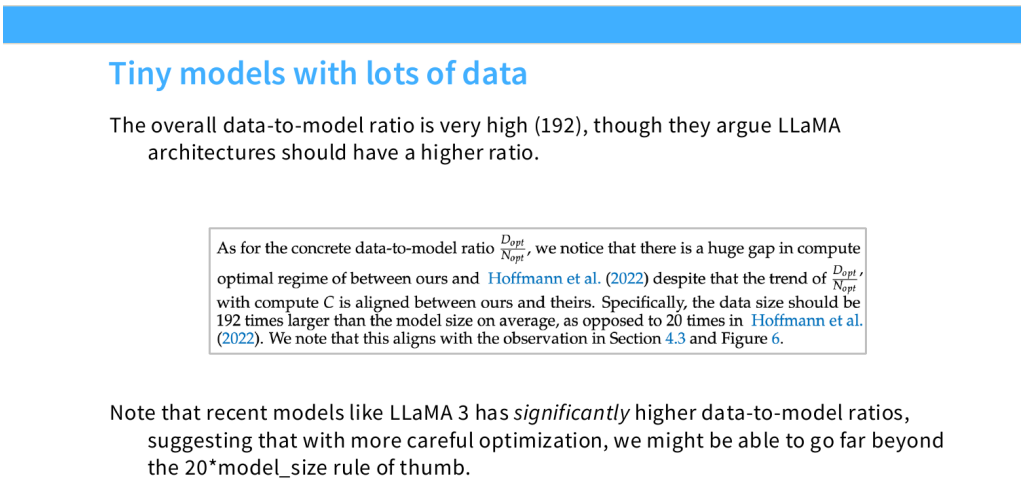

图 6: 课程明确指出：现代模型的数据配比可能远高于“20× 参数量”的老经验。

关于 data-to-model ratio 的真正结论

不要把某个具体数字当成永恒真理。第 11 讲真正想讲的是：最优配比是一个必须随着 recipe 变化而重估的量，而不是一个一劳永逸的常数。

4.3 本章小结

第 11 讲通过 MiniCPM 的 joint fit 说明，现代模型的最优数据配比很可能比老经验更高。真正应该保留的是“持续重估”的方法，而不是固守某个具体倍率。

5 DeepSeek 和更近的 recipe：muP 不是唯一道路

5.1 DeepSeek 代表了另一种工程哲学

课程选择 DeepSeek 的原因很清楚：它证明了即使不显式依赖 muP，也可以通过小规模实验直接拟合 batch/LR 缩放规律，并结合 WSD 风格调度与 isoflop 分析，拿到很强的模型。它的工程哲学更像是：先假设大多数 Transformer 超参数在尺度上变化不大，再把真正敏感的几个量重点拟合。

这和 MiniCPM 的区别在于，MiniCPM 更强调“先让参数化更可迁移”，DeepSeek 更强调“直接把关键变量经验化拟合出来”。课程把二者并列，不是为了评出唯一正确路线，而是要说明：现代 scaling recipe 是一个设计空间，不是一条单行道。

5.2 最近的公开模型在做什么

课程最后快速扫过 LLaMA 3、Hunyuan、MiniMax 等更新近的工作。它们有的主要公开 isoflop 结果，有的开始把 scaling 扩展到 MoE 架构和架构选择本身。课程在这里的态度很务实：公开细节越少，recipe 可复现性就越低；但即便如此，趋势仍然清楚，那就是大家都在用越来越细致的 scaling workflow 来替代粗糙经验。

为什么“看起来都用了 scaling laws”还不够

公开论文里只给一张 isoflop 图，不代表你就知道了完整 recipe。真正可复用的经验往往藏在 batch、LR、调度、数据配比和训练截断方式里，而这些细节未必都会公开。

5.3 本章小结

第 11 讲并没有宣判 muP 必胜或 DeepSeek 必胜。它真正展示的是：现代公开 recipe 至少已经分化出几条可行路线，而它们共同遵守的底层原则仍然是“小规模拟合，大规模外推”。

6 总结与延伸

第 11 讲把 scaling laws 从方法论推进成了 recipe 工程。

第一，**现代 scaling recipe 已经不止估数据和模型配比**。它同时涉及 muP、batch、学习率和学习率调度。

第二，**muP 的价值在于提高超参数迁移稳定性**。它让小模型调参对大模型更有参考价值，因此直接降低了大规模盲试成本。

第三，**MiniCPM 展示了更细的 scaling workflow**。最优 batch、最优 LR 和 WSD 调度都可以通过小规模实验拟合。

第四，**经典 Chinchilla 比例不是永恒常数**。更现代的 recipe 往往指向更高的数据配比，这意味着模型和数据的最优耦合点会随训练方法而变化。

第五，**DeepSeek 说明 muP 不是唯一道路**。你也可以不先追求尺度不变参数化，而是直接对关键超参数做经验拟合。

我对第 11 讲的压缩提醒

如果只把这讲理解成“又介绍了几个模型”，那就漏掉重点了。真正值得带走的是：**scaling laws 在现代训练里已经演化成一套 recipe 设计方法，而 recipe 的主体恰恰是那些以前最难调、最贵调的训练细节**。

接下来进入评估、数据和对齐章节时，可以把第 11 讲的视角保留下来：一套模型 recipe 之所以成立，不只是因为 loss 下降，还因为它在成本、可迁移性和可验证性上形成了闭环。