课程笔记

CS336 第 12 讲：评估体系

Codex 基于 Stanford CS336 2025 第 12 讲视频、字幕与课程材料整理

2026 年 4 月 9 日

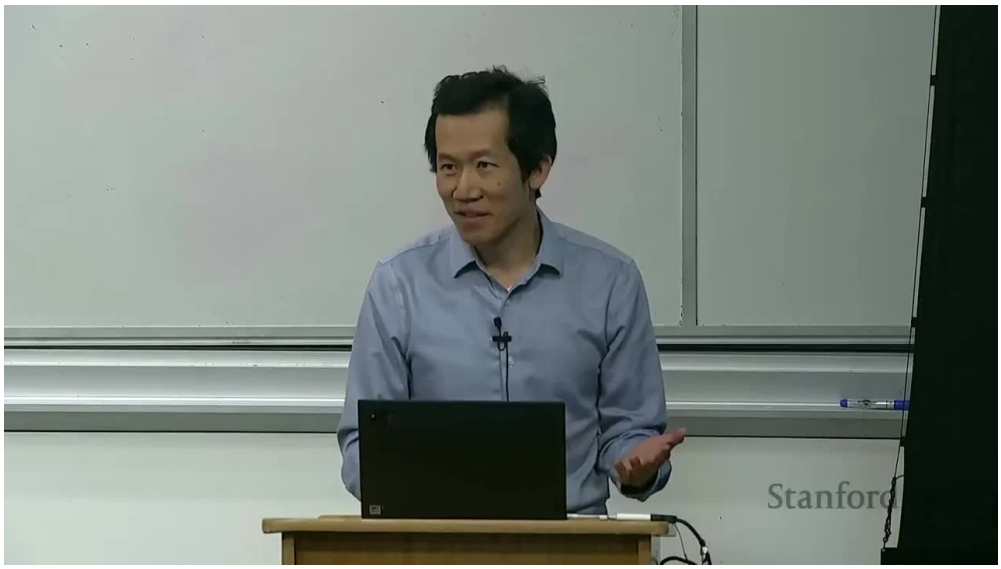

视频作者/频道：Stanford Online
发布日期：2025 年 06 月 04 日
视频时长：1:20:48
视频链接：`https://www.youtube.com/watch?v=x-R5l2HsXqM`

目录

1 评估不是排行榜，而是把“想知道什么”翻译成实验 2

1.1 课程为什么说 evaluation 决定模型的未来 2

1.2 评估框架：输入、调用、输出、解释 2

1.3 本章小结 3

2 从 perplexity 到能力 benchmark：分数为什么看起来客观，却未必回答了你要的问题 3

2.1 perplexity 仍然重要，但它不是全部 3

2.2 标准 benchmark 为何方便，也为何容易被误解 3

2.3 本章小结 4

3 当 benchmark 想测“更纯的推理”时，它又会遇到什么问题 4

3.1 HLE、ARC-AGI 与“知识和推理到底能不能分开” 4

3.2 “纯推理 benchmark”并不自动等于“更真实” 5

3.3 本章小结 5

4 开放式回答、偏好和 agent 任务：评估开始越来越像真实使用 5

4.1 从“会做题”到“用户愿不愿意用” 5

4.2 风格、长度和 judge bias 为什么会污染结论 5

4.3 agent benchmark 的出现，说明模型调用方式已经变了 6

4.4 本章小结 6

5 能力、安全和现实性：评估不只是“谁更聪明” 6

5.1 安全评估常常和能力评估纠缠在一起 6

5.2 真实使用场景与隐私、代表性之间的张力 6

5.3 MedHELM 为什么是个好例子 7

5.4 本章小结 7

6 如何知道分数靠得住：train-test overlap 与“游戏规则” 8

6.1 foundation model 时代，train-test overlap 成了常态风险 8

6.2 我们到底在评方法、模型还是系统 8

6.3 为什么课程会专门提 nanogpt speedrun 和 DataComp-LM 8

6.4 本章小结 9

7 总结与延伸 9

1 评估不是排行榜，而是把“想知道什么”翻译成实验

1.1 课程为什么说 evaluation 决定模型的未来

第 12 讲开头就故意打断一种常见直觉：评估不是把几个提示词扔给模型、算个平均分那么机械。评估实际上决定了研究者和公司会把资源优化到哪里，因此它会直接塑造下一代模型。你衡量什么，团队就会沿着什么方向爬坡；你忽略什么，模型就可能在那个维度悄悄退化。

课程用很简单但很扎实的框架来组织这个问题：评估之前，先问自己到底要回答什么问题。是用户要做采购决策，还是研究者要测原始能力，还是监管者要看风险，还是模型团队要得到调参反馈？这些目标不同，对应的输入、调用方式、评分方法和结果解释都会完全不同。

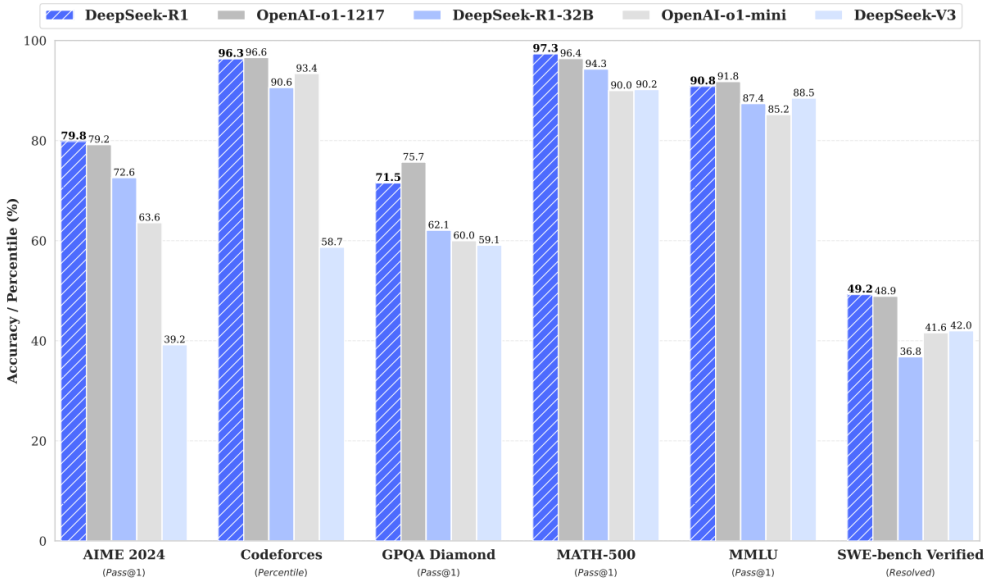

图 1: 课程先从大家最熟悉的 benchmark 汇总图切入，再追问这些分数到底在回答什么问题。

第 12 讲的总纲

不存在唯一正确的 evaluation。评估首先是一个问题定义任务，随后才是数据集、prompt、judge 和指标的技术实现。

1.2 评估框架：输入、调用、输出、解释

课程给出了一套非常值得记住的四步框架：

1. 输入是什么，覆盖了哪些 use case，尾部困难样本是否存在；
2. 模型怎么被调用，是否允许 CoT、tool use、RAG 或 agent scaffold；
3. 输出如何评分，用什么指标、是否计入成本、如何处理开放式答案；
4. 分数如何解释，它反映的是方法、模型、系统，还是部署准备度。

这套框架的价值在于，它强迫你把很多默认假设显式化。比如“91% 准确率”究竟意味着什么？如果 prompt 写法换了、judge 换了、是否允许工具换了，这个数字还代表同一件事吗？课程的答案很明确：**不先界定规则，就谈不上解释分数。**

1.3 本章小结

第 12 讲首先把评估从“收集分数”提升成“翻译目标”的工作。真正严肃的 evaluation 总是从问题定义开始，而不是从 leaderboard 开始。

2 从 perplexity 到能力 benchmark：分数为什么看起来客观，却未必回答了你要的问题

2.1 perplexity 仍然重要，但它不是全部

课程先回到语言建模最原始的评估指标：perplexity。因为语言模型本质上是一个序列分布 $p(x)$，所以 perplexity 衡量的是模型给测试数据赋予高概率的能力。它在预训练里特别自然，也因为连续、平滑，依旧非常适合做 scaling law 拟合。

但课程也明确指出，perplexity 并不能自动替代任务表现。它更像是一种“通用的、分布级的”评估，而下游任务往往关心某一类具体能力。于是从 GPT-2、GPT-3 之后，社区越来越多地转向 task accuracy、pass@k 和 benchmark score。课程在这里的立场并不是二选一，而是：**perplexity 仍然有价值，但它回答的问题更偏训练分布拟合，而不是直接的产品能力**。

2.2 标准 benchmark 为何方便，也为何容易被误解

MMLU、GPQA、HLE 这类 benchmark 的好处是清晰、可复现、便于横向比较。它们把评估问题变成近似标准化考试，方便我们快速感知一个模型在知识、专业题或高难度综合任务上的位置。

问题在于，这些 benchmark 也会把“模型强不强”偷换成“在这套题上强不强”。课程特别指出，MMLU 本质上更像知识测试而不是语言理解测试；MMLU-Pro 则通过去掉太简单或噪声较大的题、扩大选项数、允许 CoT，试图缓和饱和问题。也就是说，benchmark 本身也会演化，因为模型会把旧 benchmark 做穿。

Model	Mean score	MMLU-Pro - COT correct	GPQA - COT correct	IFEval - IFEval Strict Acc	WildBench - WB Score	Omni-MATH - Acc
o4-mini (2025-04-16)	0.812	0.82	0.735	0.929	0.854	**0.72**
o3 (2025-04-16)	0.811	0.859	**0.753**	0.869	**0.861**	0.714
Gemini 2.5 Pro (03-25 preview)	0.745	**0.863**	0.749	0.84	0.857	0.416
Grok 3 Beta	0.727	0.788	0.65	0.884	0.849	0.464
GPT-4.1 (2025-04-14)	0.727	0.811	0.659	0.838	0.854	0.471
GPT-4.1 mini (2025-04-14)	0.726	0.783	0.614	0.904	0.838	0.491
Llama 4 Maverick (17Bx128E) Instruct FP8	0.718	0.81	0.65	0.908	0.8	0.422
Grok 3 mini Beta	0.679	0.799	0.675	**0.951**	0.651	0.318
Gemini 2.0 Flash	0.679	0.737	0.556	0.841	0.8	0.459
Claude 3.7 Sonnet (20250219)	0.674	0.784	0.608	0.834	0.814	0.33
DeepSeek v3	0.665	0.723	0.538	0.832	0.831	0.403
Gemini 1.5 Pro (002)	0.657	0.737	0.534	0.837	0.813	0.364

图 2: 能力排行榜看上去很客观，但它始终是“在一套特定规则下”的客观。

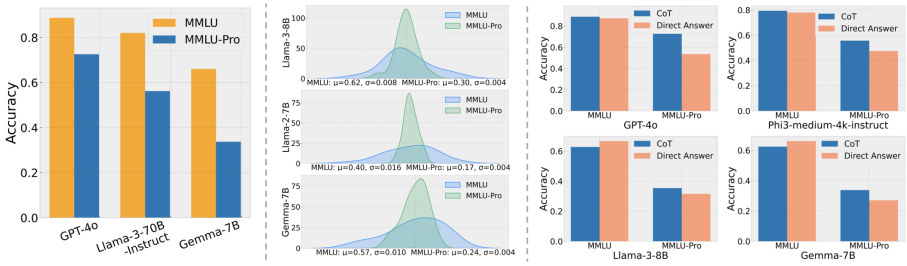

图 3: MMLU-Pro 通过去噪、加难和允许 CoT，试图延缓标准题库的饱和。

为什么课程反复说“看实例，不只看均分”

因为同样 80 分的两个模型，可能一个输在知识盲区，另一个输在格式约束、推理步骤或 prompt 适配；这些差异只有看具体样本和预测才能分辨。

2.3 本章小结

perplexity 和标准 benchmark 都很有用，但它们只回答了问题空间的一部分。课程真正想建立的是：没有哪个分数天然就是“模型综合实力”的代理。

3 当 benchmark 想测“更纯的推理”时，它又会遇到什么问题

3.1 HLE、ARC-AGI 与“知识和推理到底能不能分开”

官方 `lecture_12.py` 在这里继续往前追问：前面的 benchmark 大多仍然混合了世界知识、语言理解和推理步骤，那么能不能设计更像“纯推理”的评估？课程拿 Humanity's Last Exam 和 ARC-AGI 做了两个很有代表性的对照。

HLE 的特点是把多学科、多模态、高难短答和多项选择揉在一起，试图逼近“非常广义的专家级综合能力”；ARC-AGI 则反过来，尽量减少对具体知识背景的依赖，转而考查模式抽象、类比和规则发现。课程借这两个 benchmark 想说明：**你对 intelligence 的定义不同，评估形式就会完全不同**。

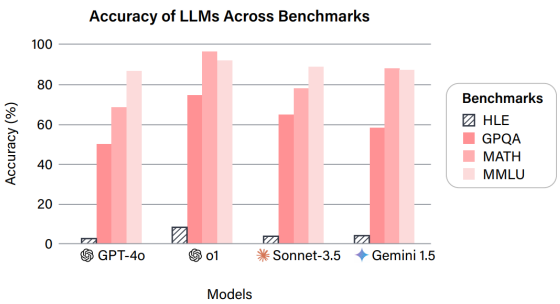

(a) HLE 更像极高难度、多模态综合考试。

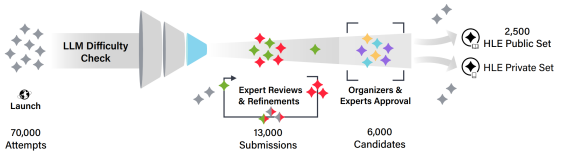

(b) 课程也强调了 HLE 自身复杂的题目筛选和构建流程。

图 4: 当 benchmark 想测“更高层能力”时，题目构造和评审流程本身也会急剧复杂化。

3.2 “纯推理 benchmark”并不自动等于“更真实”

课程在这一段的态度其实很克制。它承认 ARC-AGI 一类任务很吸引人，因为它们不像 MMLU 那样明显依赖记忆事实；但它也没有把这类 benchmark 神化成终局。原因很简单：真实世界里的有用智能往往既需要推理，也需要知识、工具和上下文交互。因此“更纯”不一定“更有产品价值”，它只是在回答另一类研究问题。

第 12 讲对 reasoning benchmark 的真正提醒

当你看到一个 benchmark 宣称自己在测“更纯的智能”时，先问它到底把哪些现实能力排除掉了。去掉知识负担可能更利于研究分析，但也可能离真实使用更远。

3.3 本章小结

HLE、ARC-AGI 这类 benchmark 提醒我们：评估并不只是在同一维度上不断加难，而是在不断更换“我们到底想测什么”的定义。

4 开放式回答、偏好和 agent 任务：评估开始越来越像真实使用

4.1 从“会做题”到“用户愿不愿意用”

课程接着把视角从标准化题目推进到开放式生成。Chatbot Arena、IFEval、AlpacaEval、WildBench 都在回答一个共同问题：如果答案不是选择题，没有唯一 ground truth，那模型到底好不好？

这里最关键的变化是，评估不再只看 correctness，还开始看偏好、约束满足、真实对话质量和使用体验。比如 Chatbot Arena 依靠随机用户对匿名模型两两比较，再用 ELO 聚合；IFEval 把开放式指令转成一组可自动验证的约束；WildBench 则直接从真实聊天流量里采样任务，再用更复杂的 judge 流程做打分。

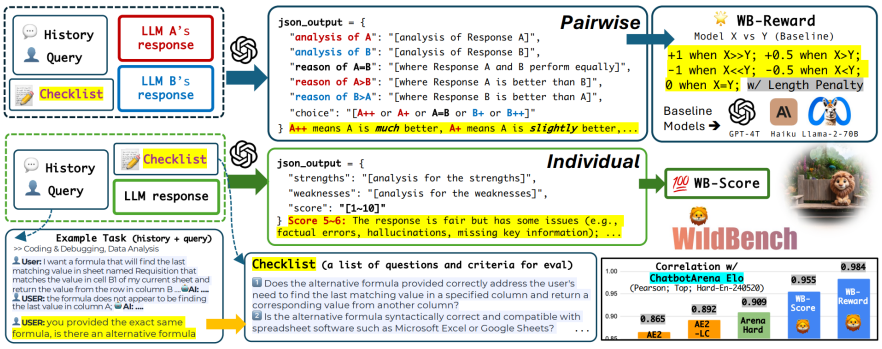

图 5: WildBench 的价值在于离真实人类聊天更近，因此常被拿来与 Arena 结果做 sanity check。

4.2 风格、长度和 judge bias 为什么会污染结论

课程专门强调了偏好评估的脆弱性。模型回答更长、更像“认真在答题”，就可能更容易赢得评审，无论这个答案是否真的更对。再加上 judge model 本身也有风格偏好、立场偏好和 prompt 敏感性，所谓“开放式评估”很容易从测能力滑向测包装。

这也是第 12 讲不停提醒学生要小心的地方：**当 benchmark 改为开放式时，judge 就成了评估系统的一部分**。这意味着你不仅在评模型，也在评你的 judge pipeline。

4.3 agent benchmark 的出现，说明模型调用方式已经变了

课程后面讲到 SWE-Bench、CyBench、MLEBench 时，评估对象已经不再是“裸模型”，而是“模型加外部环境和控制逻辑”的 agent 系统。SWE-Bench 要求模型在真实仓库里修 issue 并通过单元测试，CyBench 则看攻防任务，MLEBench 让系统去跑 Kaggle 式机器学习任务。

这类 benchmark 的意义是，它们更接近真实价值创造过程；但代价是，评估变量更多了。你到底是在测基础模型，还是在测 scaffold、工具调用、搜索策略和重试机制？课程非常明确地指出：**用户关心的是系统效果，模型研发者往往更关心纯模型能力；这两种 evaluation 不能混为一谈。**

Model	Unguided % Solved	Subtask-Guided % Solved	Subtasks % Solved	Most Difficult Task Solved (First Solve Time by Humans)	
				Unguided	Subtask-Guided
OpenAI o3-mini *†	22.5%	--	--	42 min	--
Claude 3.7 Sonnet *	20%	--	--	11 min	--
GPT-4.5-preview *	17.5%	--	--	11 min	--
Claude 3.5 Sonnet	17.5%	15%	43.9%	11 min	11 min
GPT-4o	12.5%	17.5%	28.7%	11 min	52 min
OpenAI o1-mini *†	10%	--	--	11 min	--
Claude 3 Opus	10%	12.5%	36.8%	11 min	11 min
OpenAI o1-preview	10%	10%	46.8%	11 min	11 min
Llama 3.1 405B Instruct	7.5%	15%	20.5%	9 min	11 min
Mixtral 8x22b Instruct	7.5%	5%	15.2%	9 min	7 min
Gemini 1.5 Pro	7.5%	5%	11.7%	9 min	6 min
Llama 3 70b Chat	5%	7.5%	8.2%	9 min	11 min

图 6: agent benchmark 已经开始把模型放进长期、多步、带工具的任务环境里。

4.4 本章小结

一旦任务变成开放式生成或 agent 行为，评估就会从“标准答案匹配”升级成“偏好、约束和环境交互”的组合问题。课程在这里最想提醒的是：调用方式变了，评估语义也跟着变了。

5 能力、安全和现实性：评估不只是“谁更聪明”

5.1 安全评估常常和能力评估纠缠在一起

课程在安全部分最有力量的一句话是：很多所谓“安全 benchmark”其实同时也是“能力 benchmark”。例如 CyBench 既能衡量一个系统是否擅长网络攻防，也会因此暴露它的双重用途风险。对 API 模型来说，propensity 很关键，因为系统可以拒绝；对开源权重模型来说，capability 更关键，因为拒绝行为很容易被微调掉。

这意味着安全不能被简单理解成“拒不拒绝坏请求”。一个模型在医疗场景里少幻觉，不只是更安全，也是在某种意义上更有能力。课程借此提醒学生：安全维度是高度情境化的，它和能力并不是简单对立关系。

5.2 真实使用场景与隐私、代表性之间的张力

课程后面讨论 Clio 和 MedHELM，非常有代表性。真正有价值的评估数据往往来自真实用户流量或真实专业工作流，但这类数据又会立刻碰到隐私、同意和去标识化问题。于是评估里经常存在一个两难：越真实，越难大规模公开；越标准化，越容易远离真实使用。

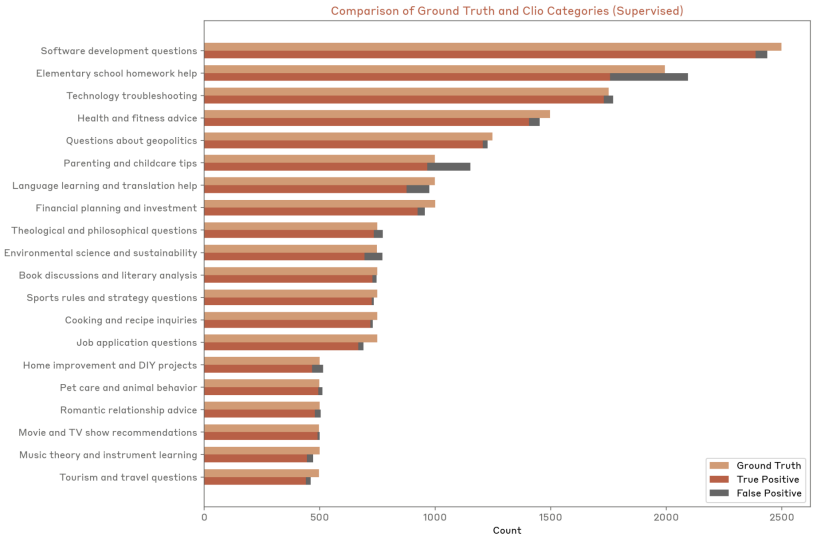

图 7: Clio 用真实用户数据去总结“人们实际上在拿模型做什么”，这是 realism 视角的一个代表。

官方 lecture script 在这里其实有一个很值得保留的区分：真实流量里的 prompt 大致可以分成 ‘quizzing‘ 和 ‘asking‘ 两类。前者像标准考试，用户知道答案、只是在考系统；后者才更像真实使用，用户不知道答案、希望系统替自己解决问题。课程想说的是，很多 benchmark 更接近 quizzing，而真正创造价值的应用往往更接近 asking。

5.3 MedHELM 为什么是个好例子

MedHELM 之所以在课程里被点名，不只是因为它是医疗 benchmark，而是因为它展示了 realism 与 privacy 的真实张力。和传统医学考试题不同，MedHELM 尝试从临床工作流里抽取更真实的任务；但任务一旦真实，就不可避免会卷入隐私保护、数据访问权限和去标识化复杂度。

这部分内容的意义在于，它把 evaluation 从“学术数据集设计”推进到了“真实世界数据治理”。课程并不是在说标准 benchmark 没价值，而是在说：**离真实工作流越近，评估的社会和制度成本就越高**。

现实性不是白拿的

如果 benchmark 完全像标准考试，它可能离真实用户太远；如果它完全来自真实流量，你又会碰到隐私、噪声和不可控偏差。课程的意思不是“二选一”，而是要在 realism 与 controllability 之间明确做设计取舍。

5.4 本章小结

第 12 讲把评估从“能力分数”扩展到了安全和现实性。对部署者来说，这几乎总是比单纯排行榜更重要，因为系统最终要在具体场景里承担收益和风险。

6 如何知道分数靠得住：train-test overlap 与“游戏规则”

6.1 foundation model 时代，train-test overlap 成了常态风险

课程最后把刀落在评估有效性上。传统机器学习时代的数据集通常有清楚的 train/test split；foundation model 时代，模型先在海量互联网文本上训练，开发者又未必完全公开训练数据，于是 train-test overlap 变成了常态风险。

这会带来一个很麻烦的问题：高分究竟来自真实泛化，还是来自模型在预训练时见过类似内容？课程介绍了两类思路，一类是从模型行为中反推重合迹象，另一类是推动更好的报告规范与置信区间披露。但无论采用哪条路，核心结论都一样：**不处理 contamination，很多 benchmark 分数都没法直接解释**。

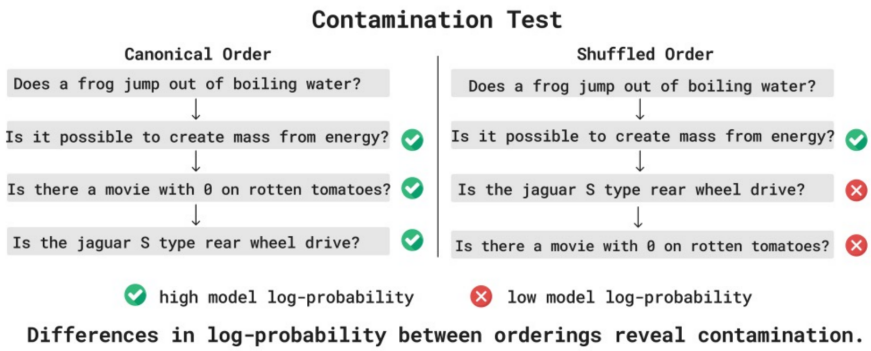

图 8: 课程用 train-test overlap 相关图示提醒：foundation model 时代的“泛化”解释比过去困难得多。

6.2 我们到底在评方法、模型还是系统

课程最后一个问题非常基础，但经常被忽略：规则到底是什么？过去很多 benchmark 评的是方法，因为大家共享训练集、验证集和测试集，模型差异主要来自算法；现在很多评估评的是模型或系统，因为训练数据、微调数据、推理技巧和外部工具都不受统一约束。

这两种游戏规则都合理，只是目标不同。评方法更利于研究创新，评系统更利于终端用户选型。课程的提醒是：**一定要把规则写明白**。不然同一个排行榜上的两个分数，可能根本不是在同一场比赛里得来的。

6.3 为什么课程会专门提 nanogpt speedrun 和 DataComp-LM

官方 script 在最后举的两个例子非常有代表性。‘nanogpt speedrun‘ 明确固定数据和目标验证损失，评的是“用同样规则更快抵达一个结果”的方法创新；‘DataComp-LM‘ 则固定训练 pipeline，让大家围绕数据处理算法做比较。它们都属于“规则极其明确”的评测，因此更适合推动算法研究。

和这类方法评测相对的，就是今天大量榜单式 model/system evaluation：训练数据不固定、后训练和推理技巧也不固定，榜单更像给终端用户做选型。课程真正想讲的是，这两类评估都合理，但**绝不能把它们混成一个游戏**。

“把规则写明白”不是形式主义

在 foundation model 时代，是否固定训练数据、是否允许 CoT、是否允许工具、是否记成本、是否评 judge pipeline，本身就是评估语义的一部分。规则不清，分数就没有稳定解释。

第 12 讲最值得反复回想的一句话

没有 one true evaluation。真正高质量的评估，不是追求一个万能分数，而是清楚说明自己想回答什么问题，以及为了回答它采用了什么规则。

6.4 本章小结

评估是否可信，最终取决于两件事：数据是否干净、规则是否明确。分数本身并不会告诉你这两件事，只有评估设计者能告诉你。

7 总结与延伸

第 12 讲把 evaluation 从排行榜解构成了一整套问题定义与实验设计流程。

第一，**评估先问目标，再选 benchmark**。用户选型、研究测能力、部署看风险、团队做反馈，这些目标天然不同。

第二，**perplexity 和标准 benchmark 仍然重要，但都不是总答案**。它们更像是不同问题的局部投影。

第三，**开放式评估和 agent benchmark 把调用方式也纳入了测量对象**。因此 judge、tool use 和 scaffold 不再是旁观者，而是评估系统的一部分。

第四，**安全、现实性和隐私会改变你对“好模型”的定义**。真实世界里的有用与安全，往往不能用一套标准考试完全代表。

第五，**foundation model 时代必须认真对待 contamination 和规则定义**。否则很多漂亮分数都没有稳定含义。

我对第 12 讲的压缩提醒

如果只把这讲理解成“介绍了一堆 benchmark”，那就错过了重点。真正重要的是：**evaluation 是把抽象目标翻译成具体规则的过程，而规则一旦变了，分数的语义也会跟着变。**

接下来进入数据章节时，第 12 讲的视角会继续起作用，因为“训练什么数据”和“用什么方法评估”本质上是同一件事的两面：前者决定模型会变成什么样，后者决定你能否看见它变成了什么样。