

第 13 讲：预训练数据：来源与数据集

CS336 Spring 2026 public videos and official course materials

目录

1 本章导读	4
1.1 本章知识路线	4
1.2 结构图	4
2 本章主线	4
2.1 本章要解决的核心问题	4
2.2 从机制到资源账本	5
2.3 从课堂讲解到可复现实验	5
3 术语、符号与问题边界	6
3.1 关键词	6
4 为什么数据最重要	6
4.1 课程目标与问题边界	6
4.2 为什么数据最重要的机制	7
4.3 资源、效率与效果的关系	7
4.4 把课程目标写成检查流程	7
4.5 边界条件与常见误解	7
4.6 与本章其他概念的关系	7
4.7 怎样检验这一课程目标	8
4.8 常见混淆：为什么数据最重要	8
4.9 为什么数据最重要的小结	8
5 Web、code、books 与 curated datasets	8
5.1 为什么要讨论 Web、code、books 与 curated datasets	9
5.2 Web、code、books 与 curated datasets 的机制	9
5.3 Web、code、books 与 curated datasets 的数据分布视角	9
5.4 Web、code、books 与 curated datasets 在数据管线中的实现	9
5.5 边界条件与常见误解	9

5.6	与本章其他概念的关系	10
5.7	怎样检验 Web、code、books 与 curated datasets	10
5.8	常见混淆：Web、code、books 与 curated datasets	10
5.9	Web、code、books 与 curated datasets 的小结	10
6	数据集记录与可复现性	11
6.1	为什么要讨论数据集记录与可复现性	11
6.2	数据集记录与可复现性的机制	11
6.3	数据集记录与可复现性的数学表达	11
6.4	从数据集记录与可复现性到程序	11
6.5	边界条件与常见误解	12
6.6	与本章其他概念的关系	12
6.7	怎样检验数据集记录与可复现性	12
6.8	常见混淆：数据集记录与可复现性	12
6.9	数据集记录与可复现性的小结	13
7	综合讨论：从局部机制到完整系统	13
7.1	为什么数据最重要在系统中的位置	13
7.2	Web、code、books 与 curated datasets 在系统中的位置	13
7.3	数据集记录与可复现性在系统中的位置	14
7.4	把本章知识用于读论文和复现实验	14
8	例题：把概念变成可计算检查	14
8.1	从网页到训练样本的 provenance	14
9	实验设计：从小例子到可复现结论	15
9.1	最小输入	15
9.2	资源账本	15
9.3	单变量消融	15
9.4	失败条件	15
9.5	记录与报告	15
10	课程资料与回看路径	15
10.1	视频回看路径	15
10.2	课程资料阅读路径	16
11	实践说明、历史位置与风险	16
12	复习要点	17

12.1 综合自测	17
13 总结与延伸	17
13.1 本章小结	17
13.2 延伸解释	18
13.3 练习	18

1 本章导读

本章讨论 **预训练数据：来源与数据集**。CS336 的第一层目标不是把现成大模型当作黑箱使用，而是把 language model 从输入文本、训练目标、模型结构、数据、系统和评估这些部件重新拆开。只有拆开之后，读者才能判断一个设计选择究竟改变了什么。设想有人说模型训练在“互联网上”。教材式回答必须拆开这句话：哪些 crawl、dump、licensed corpora、code、books、papers 和 curated datasets 被采集？谁允许使用？经过了哪些过滤？本章对应 CS336 Spring 2026 第 13 个公开视频，并结合课程页提供的可解析资料。视频和课程页给出事实边界；正文把这些材料改写为可自学的教材章节。阅读本章时，先理解问题为什么存在，再看定义、公式和实现形态，随后通过例题和练习检查自己是否能独立复现这条 reasoning chain。




图 1: 第 13 讲的课程图像锚点。

1.1 本章知识路线

- 本章首先说明预训练数据：来源与数据集为什么是 language modeling pipeline 中不可跳过的一环。
- 其次定义本章反复使用的术语，并说明这些术语对应的计算对象或系统对象。
- 随后用公式和伪代码表达主要机制，让概念能够落到可计算的变量上。
- 最后给出例题、风险讨论和练习，便于读者检查自己是否真正掌握了机制。

1.2 结构图

下面的图用于帮助读者定位本章的核心结构。先看概念之间的依赖，再回到正文中的公式、伪代码和例题。

2 本章主线

本章可以沿着三条线索阅读：课程为什么把这个主题放在这里，它改变了哪些变量，以及怎样用小实验检查这些变量。

2.1 本章要解决的核心问题

本讲进入 data：语言模型并不是训练在“整个互联网”上，而是训练在经过 crawl、dump、extraction、filtering、dedup 和 mixture 的数据产物上。这一点对应的学习动作是：找出对象，写出变量，说明变量如何被




图 2: 第 13 讲概念图：本章问题、术语和机制的关系。




图 3: 第 13 讲学习路径：从问题定义进入公式、实现、实验和练习。

测量。若输入规模、硬件、数据分布或评估协议改变，结论也必须重新检查。因此，预训练数据：来源与数据集不应被读成若干名词的集合，而应被读成一组可检验的机制。

2.2 从机制到资源账本

数据来源有技术、法律和伦理约束。robots.txt、ToS、paywall、copyright、privacy、PII、crawler behavior 都会影响可用数据。这一点对应的学习动作是：找出对象，写出变量，说明变量如何被测量。若输入规模、硬件、数据分布或评估协议改变，结论也必须重新检查。因此，预训练数据：来源与数据集不应被读成若干名词的集合，而应被读成一组可检验的机制。

2.3 从课堂讲解到可复现实验

数据 pipeline 必须版本化。没有 provenance、filter version、dedup strategy 和 mixture weights，就无法复现实验或解释模型行为。这一点对应的学习动作是：找出对象，写出变量，说明变量如何被测量。若输入规

模、硬件、数据分布或评估协议改变，结论也必须重新检查。因此，预训练数据：来源与数据集不应被读成若干名词的集合，而应被读成一组可检验的机制。

3 术语、符号与问题边界

本章的术语横跨模型、数据和系统。读者需要先知道每个词指向的对象：有些词描述数学目标，有些词描述张量形状，有些词描述硬件瓶颈，还有一些词描述评估协议。术语边界不清，后面的公式和实现就会变成空洞的缩写。

#	术语	阅读要求
1	pretraining data（预训练数据）	需要能说明它指向的对象、参与的公式或代码位置，以及一个典型失败情形。
2	Common Crawl	需要能说明它指向的对象、参与的公式或代码位置，以及一个典型失败情形。
3	data mixture（数据混合）	需要能说明它指向的对象、参与的公式或代码位置，以及一个典型失败情形。
4	dataset provenance（数据来源）	需要能说明它指向的对象、参与的公式或代码位置，以及一个典型失败情形。
5	licensing（许可证）	需要能说明它指向的对象、参与的公式或代码位置，以及一个典型失败情形。

这些术语之间有依赖关系。例如 tokenization 改变 sequence length，sequence length 又改变 attention FLOPs、KV cache 和 evaluation token budget；parallelism 改变显存占用，也改变通信瓶颈和故障恢复方式。

3.1 关键词

下面的关键词在课程材料中反复出现。它们不代替定义，只提示读者本章哪些对象需要在后文持续跟踪。

- data, function, e.g., https, copyright, books, filtering, train, training, tokens, language, text, wikipedia, quality

4 为什么数据最重要

本节讨论为什么数据最重要。本节关心的不是名称本身，而是它把预训练数据：来源与数据集中的哪些对象变成可计算、可测量或可优化的量。

4.1 课程目标与问题边界

视频开场说：给定数据后大家已知道如何训练，接下来问题是应该训练在什么数据上。数据决定模型看到的世界、语言、风格、知识和偏见，也决定 downstream 能力的上限。课程把互联网数据看作从 live services 到 dump/crawl 再到 processing pipeline 的产物。为什么数据最重要的作用是把预训练数据：来源与数据集中的 一个抽象问题变成可计算对象：哪些变量进入公式，哪些状态进入代码，哪些条件会让结果失效。

4.2 为什么数据最重要的机制

视频开场说：给定数据后大家已知道如何训练，接下来问题是应该训练在什么数据上。这给出本节的目标和边界。读者需要把其中的名词对应到张量、数据记录、训练状态或系统状态，而不是停留在缩写层面。数据决定模型看到的世界、语言、风格、知识和偏见，也决定 downstream 能力的上限。因而同一个方法在小规模示例、单机实验和集群训练中的意义并不相同。比较方法时，问题规模、硬件条件、数据分布和评估口径必须同时给出。课程把互联网数据看作从 live services 到 dump/crawl 再到 processing pipeline 的产物。这使本节具有可检验性：如果一个结论不能在公式、伪代码、profile trace、benchmark 或 ablation 中表现出来，它就还只是直觉。因此，为什么数据最重要应当被理解为一组可以实现和测试的假设。CS336 反复强调 from scratch，正是因为只有能被复现的机制，才可能被稳定改进。

4.3 资源、效率与效果的关系

$$\mathcal{D}_{\text{train}} \sim \sum_{k=1}^K w_k \mathcal{D}_k$$

符号说明： $\mathcal{D}_k$ 是第 k 个数据源， w_k 是混合权重；预训练分布是人为设计的混合。这个关系式给出了本节最小的数学骨架。读者应检查每个变量的单位、取值范围和可观测性；如果某个量只能间接估计，后续实验就必须说明 proxy 是什么。例如，validation loss 常被用作模型质量的 proxy，tokens/s 用作吞吐 proxy，Jaccard 或 MinHash 用作近重复 proxy，reward model score 用作偏好 proxy。proxy 不是目标本身；它只在评估协议清楚时才可引用。

4.4 把课程目标写成检查流程

本节机制可以写成下面的伪代码。它保留课程材料中的计算顺序和状态变化，但省略了工程代码中的错误处理、并行细节和框架样板。

```
sources = [web, books, code, wikipedia, papers]
for source in sources:
    collect_with_provenance(source)
    normalize_and_filter(source)
```

读这段伪代码时，重点不是语法，而是状态如何变化：输入是什么，中间变量是什么，主要计算或数据移动发生在哪里，哪些边界条件会破坏结果。

4.5 边界条件与常见误解

- 数据不是从天上掉下来；每个来源都有采集、许可和偏差问题。
- 更多 token 不等于更好，低质量 token 会稀释训练预算。
- 不要把小实验中的局部结论自动外推到 frontier-scale；scale、数据分布和硬件拓扑都会改变结论。
- 不要把 benchmark 或 profile 的单个数字当作机制解释；必须同时记录实验设置、输入形状、版本和评估口径。

4.6 与本章其他概念的关系

为什么数据最重要与本章其他部分的关系是互补的：术语表给出对象名称，公式给出最小数学结构，伪代码给出执行顺序，例题则把这些内容压缩成一个可检查的计算。

4.7 怎样检验这一课程目标

检验这一课程目标的第一步是确定测量对象。这里的测量对象通常不是一个抽象名词，而是与 data、Common Crawl、source、dataset、provenance 有关的张量、样本、请求、奖励、通信操作或评估记录。如果对象没有被具体化，后面的实验就只能得到描述性观察，不能得到可复现结论。第二步是构造最小输入。最小输入应该足够小，使读者能手算或打印关键中间量；同时又要保留本节机制。对于这一课程目标，最小输入不追求逼真规模，而追求暴露因果关系：改变一个变量时，哪些输出、成本或错误会随之改变。第三步是写出资源账本。账本可以是 FLOPs、bytes moved、显存峰值、通信量、token 数、样本数、reward 分布或 benchmark 分数。符号说明： $\mathcal{D}_k$ 是第 k 个数据源， w_k 是混合权重；预训练分布是人为设计的混合。这类说明应被转化为单位明确的数量关系；如果数量只能间接观测，就必须说明使用了什么 proxy。第四步是设置对照。一个好对照只改变一个因素，例如 batch size、sequence length、vocabulary size、attention heads、filter threshold、learning rate、decoding 参数或 verifier。如果多个因素同时改变，实验最多说明系统表现不同，不能说明是哪一个机制在起作用。第五步是观察失败条件。教材中的成功路径往往最容易记住，但工程中真正决定方法边界的是失败案例。本节至少要记住这些限制：数据不是从天上掉下来；每个来源都有采集、许可和偏差问题；更多 token 不等于更好，低质量 token 会稀释训练预算。复习时可以把这些限制改写成反例测试。最后，把实验结论放回预训练数据：来源与数据集的整体结构中。为什么数据最重要不是孤立技巧：它会影​​响训练目标、数据选择、系统成本或评估解释中的至少一项。能说清楚这种影响，才说明读者已经从名词记忆进入机制理解。

4.8 常见混淆：为什么数据最重要

data（数据）是模型能力、偏差和法律风险的主要来源。在“为什么数据最重要”中，这个概念用于解释预训练数据：来源与数据集的一个具体机制。Common Crawl 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“为什么数据最重要”中改变了哪个变量或约束。source 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“为什么数据最重要”中改变了哪个变量或约束。data（数据）是模型能力、偏差和法律风险的主要来源。在“为什么数据最重要”中，这个概念用于解释预训练数据：来源与数据集的一个具体机制。provenance 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“为什么数据最重要”中改变了哪个变量或约束。这些概念的共同点是：只有进入公式、代码或评估协议之后才有明确含义。单独背诵名称不会帮助判断一个训练 run、推理系统或数据 pipeline 是否正确。

4.9 为什么数据最重要的小结

- 为什么数据最重要的任何性能结论都必须同时报告问题规模和评估口径，否则不可比较。
- 如果一个方法声称降低主要成本，它通常会把成本转移到另一个变量，例如显存、通信、数据质量、训练稳定性或评估复杂度。
- 公式和伪代码提供推理骨架；真实系统仍需要 profiler、ablation 和 held-out evaluation。

5 Web、code、books 与 curated datasets

现在进入 Web、code、books 与 curated datasets。本节关心的不是名称本身，而是它把预训练数据：来源与数据集中的哪些对象变成可计算、可测量或可优化的量。

5.1 为什么要讨论 Web、code、books 与 curated datasets

Common Crawl 提供大规模网页原料，但需要 HTML extraction、language ID、质量过滤和去重。code 数据对编程能力关键，但有许可证、重复、生成数据污染和安全风险。books、Wikipedia、论文和问答数据更 curated，但规模、许可和代表性不同。数据部分的核心问题是分布控制。采集、过滤、去重和混合并不会只改变文件大小，它们会改变模型看到的语言、知识、偏差和 benchmark contamination 风险。

5.2 Web、code、books 与 curated datasets 的机制

Common Crawl 提供大规模网页原料，但需要 HTML extraction、language ID、质量过滤和去重。这给出本节的对象和边界。读者需要把其中的名词对应到张量、数据记录、训练状态或系统状态，而不是停留在缩写层面。code 数据对编程能力关键，但有许可证、重复、生成数据污染和安全风险。因而同一个方法在小规模示例、单机实验和集群训练中的意义并不相同。比较方法时，问题规模、硬件条件、数据分布和评估口径必须同时给出。books、Wikipedia、论文和问答数据更 curated，但规模、许可和代表性不同。这使本节具有可检验性：如果一个结论不能在公式、伪代码、profile trace、benchmark 或 ablation 中表现出来，它就还只是直觉。因此，Web、code、books 与 curated datasets 应当被理解为一组可以实现和测试的假设。CS336 反复强调 from scratch，正是因为只有能被复现的机制，才可能被稳定改进。

5.3 Web、code、books 与 curated datasets 的数据分布视角

$$\text{value/source} = \frac{\Delta \text{eval score}}{\text{tokens} \times \text{processing cost}}$$

符号说明：这个比值是延伸解释，用来表达单位 token 和单位处理成本的边际价值，不是官方唯一指标。这个关系式给出了本节最小的数学骨架。读者应检查每个变量的单位、取值范围和可观测性；如果某个量只能间接估计，后续实验就必须说明 proxy 是什么。例如，validation loss 常被用作模型质量的 proxy，tokens/s 用作吞吐 proxy，Jaccard 或 MinHash 用作近重复 proxy，reward model score 用作偏好 proxy。proxy 不是目标本身；它只在评估协议清楚时才可用。

5.4 Web、code、books 与 curated datasets 在数据管线中的实现

本节机制可以写成下面的伪代码。它保留课程材料中的计算顺序和状态变化，但省略了工程代码中的错误处理、并行细节和框架样板。

```
for document in crawl:
    text = extract_main_content(document.html)
    if language_ok(text) and quality_ok(text):
        write_jsonl(text, metadata=document.metadata)
```

读这段伪代码时，重点不是语法，而是状态如何变化：输入是什么，中间变量是什么，主要计算或数据移动发生在哪里，哪些边界条件会破坏结果。

5.5 边界条件与常见误解

- 网页抽取错误会把导航栏、广告、脚本或重复模板带入训练。
- 不同来源的 license 和 consent 不能在技术 pipeline 中被忽略。
- 不要把小实验中的局部结论自动外推到 frontier-scale；scale、数据分布和硬件拓扑都会改变结论。

- 不要把 benchmark 或 profile 的单个数字当作机制解释；必须同时记录实验设置、输入形状、版本和评估口径。

5.6 与本章其他概念的关系

Web、code、books 与 curated datasets 与本章其他部分的关系是互补的：术语表给出对象名称，公式给出最小数学结构，伪代码给出执行顺序，例题则把这些内容压缩成一个可检查的计算。

5.7 怎样检验 Web、code、books 与 curated datasets

检验 Web、code、books 与 curated datasets 的第一步是确定测量对象。这里的测量对象通常不是一个抽象名词，而是与 web、code、books、Wikipedia、license 有关的张量、样本、请求、奖励、通信操作或评估记录。如果对象没有被具体化，后面的实验就只能得到描述性观察，不能得到可复现结论。第二步是构造最小输入。最小输入应该足够小，使读者能手算或打印关键中间量；同时又要保留本节机制。对于 Web、code、books 与 curated datasets，最小输入不追求逼真规模，而追求暴露因果关系：改变一个变量时，哪些输出、成本或错误会随之改变。第三步是写出资源账本。账本可以是 FLOPs、bytes moved、显存峰值、通信量、token 数、样本数、reward 分布或 benchmark 分数。符号说明：这个比值是延伸解释，用来表达单位 token 和单位处理成本的边际价值，不是官方唯一指标。这类说明应被转化为单位明确的数量关系；如果数量只能间接观测，就必须说明使用了什么 proxy。第四步是设置对照。一个好对照只改变一个因素，例如 batch size、sequence length、vocabulary size、attention heads、filter threshold、learning rate、decoding 参数或 verifier。如果多个因素同时改变，实验最多说明系统表现不同，不能说明是哪一个机制在起作用。第五步是观察失败条件。教材中的成功路径往往最容易记住，但工程中真正决定方法边界的是失败案例。本节至少要记住这些限制：网页抽取错误会把导航栏、广告、脚本或重复模板带入训练；不同来源的 license 和 consent 不能在技术 pipeline 中被忽略。复习时可以把这些限制改写成反例测试。最后，把实验结论放回预训练数据：来源与数据集的整体结构中。Web、code、books 与 curated datasets 不是孤立技巧：它会影响训练目标、数据选择、系统成本或评估解释中的至少一项。能说清楚这种影响，才说明读者已经从名词记忆进入机制理解。

5.8 常见混淆：Web、code、books 与 curated datasets

web 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Web、code、books 与 curated datasets”中改变了哪个变量或约束。decode（解码）逐 token 生成，常受 memory bandwidth 和 KV cache 影响。在“Web、code、books 与 curated datasets”中，这个概念用于解释预训练数据：来源与数据集的一个具体机制。books 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Web、code、books 与 curated datasets”中改变了哪个变量或约束。Wikipedia 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Web、code、books 与 curated datasets”中改变了哪个变量或约束。license 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“Web、code、books 与 curated datasets”中改变了哪个变量或约束。这些概念的共同点是：只有进入公式、代码或评估协议之后才有明确含义。单独背诵名称不会帮助判断一个训练 run、推理系统或数据 pipeline 是否正确。

5.9 Web、code、books 与 curated datasets 的小结

- Web、code、books 与 curated datasets 的任何性能结论都必须同时报告问题规模和评估口径，否则不可比较。

- 如果一个方法声称降低主要成本，它通常会把成本转移到另一个变量，例如显存、通信、数据质量、训练稳定性或评估复杂度。
- 公式和伪代码提供推理骨架；真实系统仍需要 profiler、ablation 和 held-out evaluation。

6 数据集记录与可复现性

现在进入数据集记录与可复现性。本节关心的不是名称本身，而是它把预训练数据：来源与数据集中的哪些对象变成可计算、可测量或可优化的量。

6.1 为什么要讨论数据集记录与可复现性

课程强调开放模型与开放数据对信任和创新的作用；数据集 provenance 是可复现训练的基础。每个数据版本应记录来源 URL、抓取时间、过滤器版本、去重策略、tokenizer 和混合权重。数据集本身应当像模型 checkpoint 一样版本化，否则 evaluation 和 scaling 结果难以复现。数据集记录与可复现性的作用是把预训练数据：来源与数据集中的抽象问题变成可计算对象：哪些变量进入公式，哪些状态进入代码，哪些条件会让结果失效。

6.2 数据集记录与可复现性的机制

课程强调开放模型与开放数据对信任和创新的作用；数据集 provenance 是可复现训练的基础。这给出本节的目标和边界。读者需要把其中的名词对应到张量、数据记录、训练状态或系统状态，而不是停留在缩写层面。每个数据版本应记录来源 URL、抓取时间、过滤器版本、去重策略、tokenizer 和混合权重。因而同一个方法在小规模示例、单机实验和集群训练中的意义并不相同。比较方法时，问题规模、硬件条件、数据分布和评估口径必须同时给出。数据集本身应当像模型 checkpoint 一样版本化，否则 evaluation 和 scaling 结果难以复现。这使本节具有可检验性：如果一个结论不能在公式、伪代码、profile trace、benchmark 或 ablation 中表现出来，它就还只是直觉。因此，数据集记录与可复现性应当被理解为一组可以实现和测试的假设。CS336 反复强调 from scratch，正是因为只有能被复现的机制，才可能被稳定改进。

6.3 数据集记录与可复现性的数学表达

$$\text{dataset version} = f(\text{sources}, \text{filters}, \text{dedup}, \text{tokenizer}, \text{mixture})$$

符号说明：版本不是文件名，而是由完整 pipeline 决定的可审计对象。这个关系式给出了本节最小的数学骨架。读者应检查每个变量的单位、取值范围和可观测性；如果某个量只能间接估计，后续实验就必须说明 proxy 是什么。例如，validation loss 常被用作模型质量的 proxy，tokens/s 用作吞吐 proxy，Jaccard 或 MinHash 用作近重复 proxy，reward model score 用作偏好 proxy。proxy 不是目标本身；它只在评估协议清楚时才可引用。

6.4 从数据集记录与可复现性到程序

本节机制可以写成下面的伪代码。它保留课程材料中的计算顺序和状态变化，但省略了工程代码中的错误处理、并行细节和框架样板。

```
manifest = {
    'source': url,
    'crawl_time': timestamp,
    'filters': filter_hash,
```

```
'tokenizer': tokenizer_hash,
}
```

读这段伪代码时，重点不是语法，而是状态如何变化：输入是什么，中间变量是什么，主要计算或数据移动发生在哪里，哪些边界条件会破坏结果。

6.5 边界条件与常见误解

- 只发布 token count 不足以复现数据。
- 数据删除请求、法律要求和安全过滤会让数据版本随时间变化。
- 不要把小实验中的局部结论自动外推到 frontier-scale；scale、数据分布和硬件拓扑都会改变结论。
- 不要把 benchmark 或 profile 的单个数字当作机制解释；必须同时记录实验设置、输入形状、版本和评估口径。

6.6 与本章其他概念的关系

数据集记录与可复现性与本章其他部分的关系是互补的：术语表给出对象名称，公式给出最小数学结构，伪代码给出执行顺序，例题则把这些内容压缩成一个可检查的计算。

6.7 怎样检验数据集记录与可复现性

检验数据集记录与可复现性的第一步是确定测量对象。这里的测量对象通常不是一个抽象名词，而是与 manifest、version、provenance、filter、tokenizer 有关的张量、样本、请求、奖励、通信操作或评估记录。如果对象没有被具体化，后面的实验就只能得到描述性观察，不能得到可复现结论。第二步是构造最小输入。最小输入应该足够小，使读者能手算或打印关键中间量；同时又要保留本节机制。对于数据集记录与可复现性，最小输入不追求逼真规模，而追求暴露因果关系：改变一个变量时，哪些输出、成本或错误会随之改变。第三步是写出资源账本。账本可以是 FLOPs、bytes moved、显存峰值、通信量、token 数、样本数、reward 分布或 benchmark 分数。符号说明：版本不是文件名，而是由完整 pipeline 决定的可审计对象。这类说明应被转化为单位明确的数量关系；如果数量只能间接观测，就必须说明使用了什么 proxy。第四步是设置对照。一个好对照只改变一个因素，例如 batch size、sequence length、vocabulary size、attention heads、filter threshold、learning rate、decoding 参数或 verifier。如果多个因素同时改变，实验最多说明系统表现不同，不能说明是哪一个机制在起作用。第五步是观察失败条件。教材中的成功路径往往最容易记住，但工程中真正决定方法边界的是失败案例。本节至少要记住这些限制：只发布 token count 不足以复现数据；数据删除请求、法律要求和安全过滤会让数据版本随时间变化。复习时可以把这些限制改写成反例测试。最后，把实验结论放回预训练数据：来源与数据集的整体结构中。数据集记录与可复现性不是孤立技巧：它会影响训练目标、数据选择、系统成本或评估解释中的至少一项。能说清楚这种影响，才说明读者已经从名词记忆进入机制理解。

6.8 常见混淆：数据集记录与可复现性

数据清单 (manifest) 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“数据集记录与可复现性”中改变了哪个变量或约束。version 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“数据集记录与可复现性”中改变了哪个变量或约束。provenance 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“数据集记录与可复现性”中改变了哪个变量或约束。filter 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是

评估，并说明它在“数据集记录与可复现性”中改变了哪个变量或约束。tokenizer 在本节中应被看作一个技术对象，而不是一个孤立名词。需要判断它指向模型、数据、系统还是评估，并说明它在“数据集记录与可复现性”中改变了哪个变量或约束。这些概念的共同点是：只有进入公式、代码或评估协议之后才有明确含义。单独背诵名称不会帮助判断一个训练 run、推理系统或数据 pipeline 是否正确。

6.9 数据集记录与可复现性的小结

- 数据集记录与可复现性的任何性能结论都必须同时报告问题规模和评估口径，否则不可比较。
- 如果一个方法声称降低主要成本，它通常会把成本转移到另一个变量，例如显存、通信、数据质量、训练稳定性或评估复杂度。
- 公式和伪代码提供推理骨架；真实系统仍需要 profiler、ablation 和 held-out evaluation。

7 综合讨论：从局部机制到完整系统

本章的主题是预训练数据：来源与数据集，但它不应被读成几个相邻知识点的拼接。为什么数据最重要、Web、code、books 与 curated datasets、数据集记录与可复现性共同回答同一个问题：语言模型系统中哪些对象可以被定义，哪些成本可以被估算，哪些结论必须通过实验或评估来确认。这些对象包括 pretraining data (预训练数据)、Common Crawl、data mixture (数据混合)、dataset provenance (数据来源)、licensing (许可证)。读者可以把它们看成一组接口：有的接口连接文本和 token，有的连接模型结构和张量计算，有的连接数据样本和训练目标，有的连接离线评估和在线服务。接口一旦改变，后面的成本、错误类型和优化空间也会随之改变。

7.1 为什么数据最重要在系统中的位置

为什么数据最重要首先提供一个局部解释：视频开场说：给定数据后大家已知道如何训练，接下来问题是应该训练在什么数据上。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，为什么数据最重要会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，为什么数据最重要不能脱离边界条件理解。一个关键 caveat 是：数据不是从天上掉下来；每个来源都有采集、许可和偏差问题。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.2 Web、code、books 与 curated datasets 在系统中的位置

Web、code、books 与 curated datasets 首先提供一个局部解释：Common Crawl 提供大规模网页原料，但需要 HTML extraction、language ID、质量过滤和去重。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，Web、code、books 与 curated datasets 会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，Web、code、books 与 curated datasets 不能脱离边界条件理解。一个关键 caveat 是：网页抽取错误会把导航栏、广告、脚本或重复模板带入训练。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.3 数据集记录与可复现性在系统中的位置

数据集记录与可复现性首先提供一个局部解释：课程强调开放模型与开放数据对信任和创新的作用；数据集 provenance 是可复现训练的基础。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，数据集记录与可复现性会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，数据集记录与可复现性不能脱离边界条件理解。一个关键 caveat 是：只发布 token count 不足以复现数据。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.4 把本章知识用于读论文和复现实验

读相关论文时，可以把本章变成一个检查表。第一，论文是否清楚定义了输入规模、模型规模、数据来源和评估协议；第二，论文声称的改进落在哪个变量上；第三，作者是否报告了会让结论失效的设置；第四，实验是否能分离模型结构、数据质量、优化设置和系统实现的影响。复现实验时，也应避免直接追求大规模。先用小程序复现一个公式、一个伪代码分支或一个 profile 现象，再扩大输入规模。这样做的原因很简单：如果小规模程序无法解释中间量，大规模训练只会把错误隐藏在日志和随机波动里。把这些检查合在一起，本章给出的不是一个固定答案，而是一种阅读 CS336 的方法：每个模型机制都要落到变量，每个变量都要落到测量，每个测量都要说明协议，每个协议都要承认边界。因此，本章中的任何一句结论都可以被改写成一个可引用的完整句式：在给定数据、模型、硬件和评估协议下，某个机制改变了某个变量，并通过某个观测指标表现出来。这样的句子比单独背诵术语更长，但它包含了自学、复现和引用时真正需要的信息。把本章用于自学时，可以按三遍阅读。第一遍只追踪对象和定义，确认每个术语到底指向文本、token、张量、样本、请求还是评估记录。第二遍追踪公式和伪代码，确认每一步改变了哪些状态。第三遍追踪实验和 caveat，确认哪些结论只在特定规模、数据或硬件条件下成立。把本章用于复习时，则应反过来操作：先从一个失败案例或异常指标出发，再回到相应机制。loss 曲线异常可能指向数据、优化或模型容量；吞吐异常可能指向 kernel、通信或调度；benchmark 异常可能指向 contamination、prompt protocol 或采样设置。能够从异常反推机制，是掌握本章的实用标准。

8 例题：把概念变成可计算检查

8.1 从网页到训练样本的 provenance

一个网页进入训练集，要经过 crawl、HTML extraction、language ID、quality filter 和 dedup。

- 每一步都应写入数据清单 (manifest)，而不是只留下最终文本。
- 过滤器版本和阈值会改变数据分布。
- 许可、robots、PII 和删除请求会影响能否持续使用。

结论。数据集是 pipeline 的产物，不是文件夹里若干 ‘jsonl’ 的集合。这个例题的目的不是替代完整工程实现，而是给出一种最小推理形式：把问题转成变量，写出近似公式或伪代码，再说明近似何时失效。

9 实验设计：从小例子到可复现结论

学习预训练数据：来源与数据集不能停在概念层。一个教材化结论至少需要四件事：可构造的输入、可观测的中间量、可比较的指标，以及清楚的失败条件。下面的实验设计不是要求训练大模型，而是要求读者用小规模程序复现本章机制。

9.1 最小输入

先构造只触发本章核心机制的小输入。例如 tokenizer 章节可以用几个包含 rare words 和 Unicode 字符的字符串；GPU 章节可以用一个 elementwise kernel 和一个 GEMM；data 章节可以用十几篇近重复文档。小输入的价值在于它让错误可见。

9.2 资源账本

对同一输入写下 FLOPs、bytes moved、显存峰值、通信量或样本数量的估算。估算不需要一开始就精确，但必须说明单位和近似假设。随后用 profiler、benchmark、validation loss 或人工检查去验证估算是否同量级。

9.3 单变量消融

一次只改变一个因素，例如 vocabulary size、head 数、batch size、filter threshold、reward scale、decoding temperature 或 GPU 数量。若多个变量同时变化，实验只能说明系统变了，不能说明机制是什么。

9.4 失败条件

最后要刻意触发失败：极端 context length、错误 dtype、过小 batch、污染 benchmark、低质量数据或不可靠 verifier。失败条件常常比成功曲线更能说明一个方法的边界。

9.5 记录与报告

实验记录应能让另一个读者复现同一结论。最少要写清楚输入构造、代码版本、随机种子、硬件、batch shape、数据版本、评价指标和异常处理方式。报告结论时不要只写“更快”或“更好”，而要说明快在哪里、好在哪个指标上，以及是否牺牲了内存、稳定性、数据质量或可解释性。常见报告错误是把局部现象写成普遍规律。例如一次小模型实验里的 loss 改善，不等于更大模型或不同数据分布上也会改善；一次 kernel benchmark 的吞吐提升，不等于端到端 serving latency 一定降低。教材中的实验报告应始终把结论限定在可复现条件内。

10 课程资料与回看路径

教材正文已经把主要概念、公式和实现逻辑组织成连续叙述；本节只提供回到课程材料的阅读路径。读者复习时可以先完成前文练习，再按下面的时间段或资料组核对细节。

10.1 视频回看路径

时间	关键词	复习任务
----	-----	------

00:00:04-00:06:20	data, training, there's, data., that's, talk, train	回看定义、例子、推导或 caveat 在该段中的位置。
00:19:25-00:26:05	fair, copyright, license, creative, it's, that's, don't	回看定义、例子、推导或 caveat 在该段中的位置。
00:40:03-00:46:20	data, it's, github, books, there's, crawl, code	回看定义、例子、推导或 caveat 在该段中的位置。
00:53:24-01:00:55	data, think, books3, wikipedia, books, trained, quality	回看定义、例子、推导或 caveat 在该段中的位置。
01:14:57-01:21:49	data, it's, permissively, think, there's, very, whether	回看定义、例子、推导或 caveat 在该段中的位置。

这些时间段用于定位视频中的讲解顺序。严肃引用时，应回到视频片段确认讲者表述、板书或幻灯片内容。回看视频时，不必逐字抄录字幕。更有效的方法是把每个时间段判定为定义、例子、推导、代码解释或 caveat，再把它放回本章对应小节。

10.2 课程资料阅读路径

资料组	标题/页块	关键词
official_01	Lecture 13: Data I	data, train, training, live, language, pre-training, mid-training
official_03	- Threshold for copyright is extremely low (e.g., your website is copyrighted)	copyright, work, fair, license, training, copyrighted, over
official_05	- Repository: download through git protocol (rather than scraping the GitHub website)	https, github, metadata, arxiv, books, language, crawl
official_08	- ...	data, tokens, trained, classifier, result, remove, permissively
official_10	Reproduced by Together's RedPajama v1	function, refinedweb, dolma, stack, reproduced, together, redpajama

课程资料通常给出更稳定的标题、公式、图或代码结构；视频则补充动机和口头解释。两者合起来构成本章的事实边界。阅读资料时，可以把每个资料组拆成三个对象：一个定义，一个公式或伪代码动作，一个边界条件。这样比逐字翻译页面或脚本更容易形成可用知识。

11 实践说明、历史位置与风险

预训练数据：来源与数据集在 CS336 的课程结构中连接基础机制和规模化问题。基础机制解释方法为什么成立；规模化问题检验它在更大模型、更长上下文、更复杂数据或真实 serving workload 下是否仍成立。历史位置不等于模型年表。更重要的是识别问题如何迁移：早期方法解决小规模建模问题，现代方法常常解决同一问题在大规模数据、GPU 集群、长上下文或人类偏好约束下的新形态。

- 资料版本限制 (version risk): 课程页、公开视频和配套资料可能在学期中更新；引用时应注明访问日期或资料版本。

- 测量口径限制 (measurement risk): FLOPs、tokens/s、benchmark score、reward 等数字只有在协议完整时可比较。
- 规模外推限制 (scaling risk): 小模型或小 batch 的机制不必然外推到 frontier-scale。
- 数据分布限制 (data risk): 数据来源、过滤和去重策略会改变模型行为, 也会改变 evaluation contamination 风险。

12 复习要点

下面的问题把本章内容压缩为可反复检查的条目。每个条目都应能回到前文的解释、公式、伪代码或例题。

条目	对象	检查动作
条目 1	pretraining data (预训练数据)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 2	Common Crawl	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 3	data mixture (数据混合)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 4	dataset provenance (数据来源)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 5	licensing (许可证)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。

12.1 综合自测

- 我能否不用课程原句, 独立解释本章中心问题?
- 我能否把本章至少一个公式改写成可运行的估算函数?
- 我能否指出一个看似改进但实际转移成本的方法?
- 我能否回到视频和课程资料, 找到支持本章关键论断的位置?
- 我能否设计一个最小 ablation, 验证本章一个 caveat?

13 总结与延伸

13.1 本章小结

- 预训练数据: 来源与数据集的核心不是记忆术语, 而是理解对象、变量和机制之间的关系。
- 视频给出讲解顺序, 课程资料提供可核对的公式、图、代码或页面结构。
- 复习时应把每个术语连接到至少一个变量、一个实现动作和一个失败模式。

13.2 延伸解释

本章中的延伸解释用于连接课程材料中的概念，例如说明公式里的 proxy、解释系统 tradeoff，或把多个材料片段串成一个完整推理链。若需要严肃引用，应回到课程视频和配套资料核对原始表述。

13.3 练习

- 定义题：用中英双语解释本章任意五个重要术语，并说明它们属于 compute、memory、data、optimization、evaluation 还是 deployment 账本。
- 推导题：选择本章一个公式，逐个解释符号、单位和近似假设，并说明哪个变量最难在真实系统中测量。
- 实现题：把本章伪代码改写成一个最小 Python sanity check，不要求训练大模型，但要输出可检查的中间量。
- 资料题：从“课程资料与回看路径”中选择一个视频时间段，回到原始视频核对讲者例子，并记录是否存在字幕误差。
- 评估题：为本章方法设计一个 ablation 或 benchmark，说明控制变量、数据版本、指标和 failure criteria。
- 边界题：说明本章一个结论在更长 context、更大 batch、更多 GPU 或更复杂数据分布下可能如何失效。
- 综合题：把本章内容和前一章或后一章连接起来，写出一个端到端训练/推理 pipeline 中的依赖关系。
- 批判题：指出一个容易被营销材料夸大的说法，并用本章的资源账本或评估协议反驳它。