课程笔记

CS336 第 13 讲：数据工程 I

Codex 基于 Stanford CS336 2025 第 13 讲视频、字幕与课程材料整理

2026 年 4 月 7 日

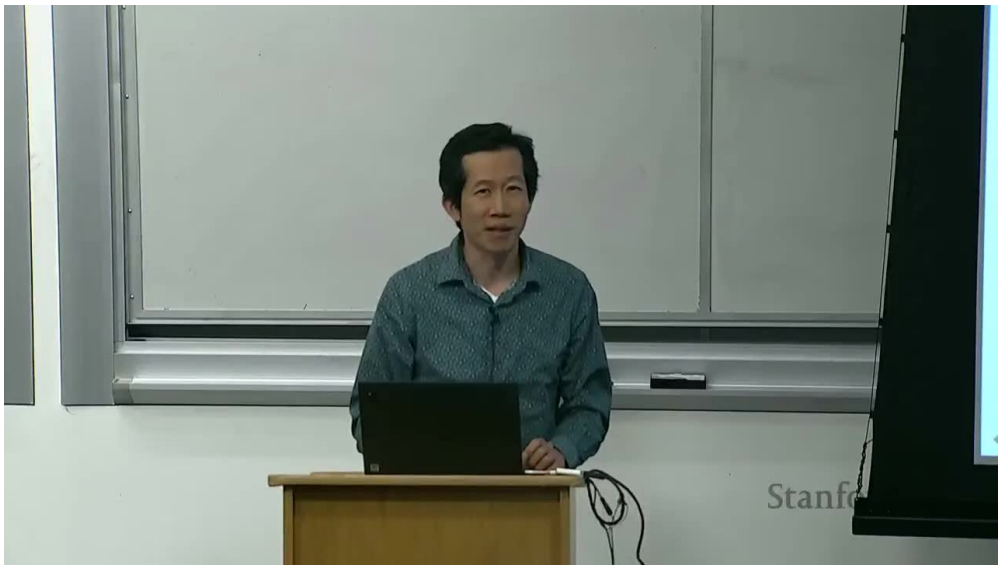

视频作者/频道：Stanford Online
发布日期：2025 年 06 月 10 日
视频时长：1:19:06
视频链接：`https://www.youtube.com/watch?v=WePxmeXU1xg`

目录

1 数据为何成了 foundation model 时代最难复制的护城河 **2**
1.1 为什么公司最不愿意公开的是数据 2
1.2 本章小结 2

2 从 pretraining 到 post-training：数据质量沿着训练阶段不断提高 **2**
2.1 三阶段视角：大而杂，逐渐走向小而精 2
2.2 为什么这套分层非常关键 4
2.3 本章小结 4

3 预训练数据到底来自哪里：网页、书籍、论文、代码与社区文本 **4**
3.1 预训练不是“全网抓一遍”，而是复杂的数据供应链 4
3.2 HTML 转文本、去重和过滤为什么会改变模型质量 5
3.3 不同来源带来不同能力和风险 5
3.4 本章小结 5

4 模型式过滤的兴起：从启发式规则到用模型选数据 **5**
4.1 为什么纯手工规则开始不够用 5
4.2 模型过滤的优势与新问题 6
4.3 本章小结 6

5 版权、许可、fair use 与 ToS：数据不是只要看见就能拿来训 **6**
5.1 版权法关心的是表达，不只是字面复制 6
5.2 许可、fair use 和 ToS 是三层不同约束 6
5.3 本章小结 7

6 mid-training 与 post-training 数据：能力增强和行为塑形的另一套世界 **7**
6.1 长上下文和能力增强往往不该在预训练里硬做 7
6.2 instruction data 与 synthetic data 已经形成自己的生态 7
6.3 本章小结 7

7 总结与延伸 **7**

1 数据为何成了 foundation model 时代最难复制的护城河

1.1 为什么公司最不愿意公开的是数据

第 13 讲一开场就抛出一个很尖锐的判断：如果说架构和训练系统在公开论文里越来越透明，那么真正最神秘的部分反而是数据。课程用 Llama 3 一类开源权重模型做例子指出，模型架构、优化器和部分训练细节常常会被详细披露，但数据来源、筛选和配比往往只给模糊描述。

课程给出的原因有两个。第一是竞争：数据直接决定模型差异化，是最难复制的资产。第二是法律风险：越具体披露数据来源，越容易暴露版权、隐私和合同义务问题。因此在 foundation model 时代，数据既是模型能力的来源，也是组织最不愿完全摊开的秘密。

3.1 Pre-Training Data

We create our dataset for language model pre-training from a variety of data sources containing knowledge until the end of 2023. We apply several de-duplication methods and data cleaning mechanisms on each data source to obtain high-quality tokens. We remove domains that contain large amounts of personally identifiable information (PII), and domains with known adult content.

图 1: 课程用公开模型的数据说明方式提醒学生：越重要的数据细节，往往越不透明。

第 13 讲的总判断

“数据最重要”不是鸡汤。课程真正想说的是：数据工作既长尾、又依赖人工判断、又有合规风险，因此它比架构和系统更难被完全标准化与复制。

1.2 本章小结

第 13 讲先把数据的战略地位钉住了。对大模型团队来说，数据不是训练流水线的输入材料，而是最核心、最难复制、也最难完全公开的能力来源。

2 从 pretraining 到 post-training：数据质量沿着训练阶段不断提高

2.1 三阶段视角：大而杂，逐渐走向小而精

课程把训练阶段拆成三层：pre-training、mid-training 和 post-training。这个划分非常重要，因为它解释了为什么“好数据”不能只按一个统一标准来看。预训练更关心覆盖广、规模大、信息密度足够高；中训练更关心能力增强，比如长上下文或学科强化；后训练则更关心行为控制、指令跟随和安全性。

课程给出的总体规律很值得记住：从前到后，数据通常会从“大规模、质量参差、贴近自然分布”逐步转向“小规模、质量更高、目标更明确”。这不意味着后面的数据绝对更“真实”，而是它们越来越像人为设计的干预信号。

Source	Type	Tokens	Words	Bytes	Docs
Pretraining ✦ OLMo 2 1124 Mix					
DCLM-Baseline	Web pages	3.71T	3.32T	21.32T	2.95B
StarCoder filtered version from OLMoE Mix	Code	83.0B	70.0B	459B	78.7M
peS2o from Dolma 1.7	Academic papers	58.6B	51.1B	413B	38.8M
arXiv	STEM papers	20.8B	19.3B	77.2B	3.95M
OpenWebMath	Math web pages	12.2B	11.1B	47.2B	2.89M
Algebraic Stack	Math proofs code	11.8B	10.8B	44.0B	2.83M
Wikipedia & Wikibooks from Dolma 1.7	Encyclopedic	3.7B	3.16B	16.2B	6.17M
Total		**3.90T**	**3.48T**	**22.38T**	**3.08B**

图 2: OLMo 2 的例子说明：预训练阶段首先关注的是大规模基础语料。

Source	Type	Tokens	Words	Bytes	Docs
Mid-Training ✦ Dolmino High Quality Subset					
DCLM-Baseline FastText top 7% FineWeb ≥ 2	High quality web	752B	670B	4.56T	606M
FLAN from Dolma 1.7 decontaminated	Instruction data	17.0B	14.4B	98.2B	57.3M
peS2o from Dolma 1.7	Academic papers	58.6B	51.1B	413B	38.8M
Wikipedia & Wikibooks from Dolma 1.7	Encyclopedic	3.7B	3.16B	16.2B	6.17M
Stack Exchange 09/30/2024 dump curated Q&A data	Q&A	1.26B	1.14B	7.72B	2.48M
High quality total		**832.6B**	**739.8B**	**5.09T**	**710.8M**
Mid-training ✦ Dolmino Math Mix					
TuluMath	Synthetic math	230M	222M	1.03B	220K
Dolmino SynthMath	Synthetic math	28.7M	35.1M	163M	725K
TinyGSM-MIND	Synthetic math	6.48B	5.68B	25.52B	17M
MathCoder2 Synthetic Ajibawa-2023 M-A-P Matrix	Synthetic Math	3.87B	3.71B	18.4B	2.83M
Metamath OWM-filtered	Math	84.2M	76.6M	741M	383K
CodeSearchNet OWM-filtered	Code	1.78M	1.41M	29.8M	7.27K
GSM8K Train split	Math	2.74M	3.00M	25.3M	17.6K
Math total		**10.7B**	**9.73B**	**45.9B**	**21.37M**

图 3: 课程用 OLMo 的中训练示意图说明：后续阶段会更针对能力缺口做数据干预。

Category	Prompt Dataset	Count	# Prompts used in SFT	# Prompts used in DPO	Reference
General	Tülu 3 Hardcoded[†]	24	240	–	–
	OpenAssistant[1,2,↓]	88,838	7,132	7,132	Köpf et al. (2024)
	No Robots	9,500	9,500	9,500	Rajani et al. (2023)
	WildChat (GPT-4 subset)[↓]	241,307	100,000	100,000	Zhao et al. (2024)
	UltraFeedback[α,2]	41,635	–	41,635	Cui et al. (2023)
Knowledge Recall	FLAN v2[1,2,↓]	89,982	89,982	12,141	Longpre et al. (2023)
	SciRIFF[↓]	35,357	10,000	17,590	Wadden et al. (2024)
	TableGPT[↓]	13,222	5,000	6,049	Zha et al. (2023)
Math Reasoning	Tülu 3 Persona MATH	149,960	149,960	–	–
	Tülu 3 Persona GSM	49,980	49,980	–	–
	Tülu 3 Persona Algebra	20,000	20,000	–	–
	OpenMathInstruct 2[↓]	21,972,791	50,000	26,356	Toshniwal et al. (2024)
	NuminaMath-TIR[α]	64,312	64,312	8,677	Beeching et al. (2024)
Coding	Tülu 3 Persona Python	34,999	34,999	–	–
	Evol CodeAlpaca[α]	107,276	107,276	14,200	Luo et al. (2023)
Safety & Non-Compliance	Tülu 3 CoCoNot	10,983	10,983	10,983	Brahman et al. (2024)
	Tülu 3 WildJailbreak[α,↓]	50,000	50,000	26,356	Jiang et al. (2024)
	Tülu 3 WildGuardMix[α,↓]	50,000	50,000	26,356	Han et al. (2024)
Multilingual	Aya[↓]	202,285	100,000	32,210	Singh et al. (2024b)
Precise IF	Tülu 3 Persona IF	29,980	29,980	19,890	–
	Tülu 3 IF-augmented	65,530	–	65,530	–
Total		23,327,961	939,344	425,145[γ]	

图 4: 后训练阶段的数据已经从“自然文档”转向更明确的行为和指令分布。

2.2 为什么这套分层非常关键

如果没有这套分层，学生就很容易把“训练数据”理解成某个固定大桶：从网络上抓下来，清洗一下，喂进去就行。课程明确反对这种看法。不同阶段的数据承担的是不同角色，预训练负责世界覆盖，mid-training 负责补特定能力，post-training 负责塑造交互行为。于是同一份数据在不同阶段的价值会完全不同。

base model 与 instruct model 的真正差别

课程在术语上也做了澄清：base model 往往是 pretraining 加 mid-training 之后的结果，而 instruct/chat model 则是在此基础上继续做 post-training。也就是说，两者往往不是不同架构，而是同一基础模型看到的数据分布不同。

2.3 本章小结

数据不是一锅炖。第 13 讲通过 pretraining、mid-training、post-training 的分层视角，让我们看到“规模、质量和目标”会随着训练阶段不断变化。

3 预训练数据到底来自哪里：网页、书籍、论文、代码与社区文本

3.1 预训练不是“全网抓一遍”，而是复杂的数据供应链

课程接下来做了非常密集的一次数据源巡礼：BooksCorpus、Wikipedia、WebText、Common Crawl、C4、The Pile、RedPajama、FineWeb、Dolma、The Stack、Project Gutenberg、Stack Exchange、

GitHub 等。课程的重点不是让你背名字，而是让你看到真实数据管线有多复杂。

例如 Common Crawl 只是一个定期抓取网页的大型基础设施，它给你的往往是 WARC 或 WET 文件，而不是可以直接训练的干净文本。网页要先转纯文本，模板和导航条要剔除，语言要识别，重复内容要去掉，低质量页面要过滤，PII 和明显不当内容也要处理。也就是说，**原始网页和可训练文档之间，隔着一整条数据加工链**。

3.2 HTML 转文本、去重和过滤为什么会改变模型质量

课程特别指出，很多人以为“数据工程就是脏活累活”，但事实上连 HTML 转文本这种看似基础的环节都会显著影响最终下游表现。Common Crawl 的不同处理方式会得到完全不同的文本分布，而 C4、RefinedWeb、FineWeb、Dolma 等数据集的差异，也大量体现在这些处理选择上。

这就是为什么课程反复讲 C4、CCNet、The Pile、RedPajama 这些项目。它们提供的不只是数据集本身，更是一组对于“什么叫可训练文本”的工程判断：哪些页面更像自然语言、哪些像模板垃圾、哪些虽然大但价值有限。

3.3 不同来源带来不同能力和风险

网页、书籍、论文、代码和问答社区文本各自承担不同角色。网页提供规模和广覆盖，书籍提供长程叙事和稳定文风，论文提供专业知识和形式化表达，代码对程序任务和某些推理任务都很有帮助，问答社区文本则更接近 instruction-following 和真实信息请求场景。

课程在这里特别有价值的一点，是没有把任何来源神化。Wikipedia 虽然高质量，但也会受编辑机制和投毒攻击影响；Books3 这类影子图书馆材料能力价值很高，却伴随极强版权风险；GitHub 和 Stack Exchange 有丰富元数据，但也充满重复、fork 和许可问题。也就是说，**每一种来源都是能力、噪声和法律风险的捆绑包**。

3.4 本章小结

预训练数据不是“从网上下载文件”的问题，而是一条涵盖抓取、转换、过滤、去重和源类型配比的供应链。课程通过大量具体数据集案例，把这条链的复杂度完整摊开了。

4 模型式过滤的兴起：从启发式规则到用模型选数据

4.1 为什么纯手工规则开始不够用

课程在 DataComp-LM、DCLM 和 Nemotron-CC 这一段里传达了一个明显趋势：随着预训练池越来越大，单靠启发式规则很难同时兼顾质量和规模。一套规则也许能去掉不少垃圾，但往往会过于保守，把大量潜在有用数据也一起删掉。

因此，越来越多团队开始用模型来做数据过滤。比如训练 fastText 分类器，把 OpenHermes、ELI5 这类较高质量样本当正例，把较粗糙的网页文本当负例，再把分类器跑到海量候选语料上。这一步让数据过滤从“写规则”升级成“学习一个 quality prior”。

Table 4: **Quality filtering comparison** (`1B-1x` scale). We evaluate various choices for model-based quality filters. Training a `fastText` classifier for filtering performs best.

Filter	CORE	EXTENDED
RefinedWeb reproduction	27.5	14.6
Top 20% by Pagerank	26.1	12.9
SemDedup [1]	27.1	13.8
Classifier on BGE features [185]	27.2	14.0
AskLLM [146]	28.6	14.3
Perplexity filtering	29.0	15.0
Top-k average logits	29.2	14.7
`fastText` [87] OH-2.5 +ELI5	**30.2**	**15.4**

图 5: 课程用 DCLM 相关结果说明：模型式质量过滤正在变成更常见的数据工程手段。

4.2 模型过滤的优势与新问题

模型式过滤的优势是更灵活，能在更大语料池里保留更多高价值样本；但新问题也很明显：你到底把什么视为“高质量”？如果正例来自 GPT-4 指令数据和 ELI5，那么过滤器就可能系统性偏向教育性、解释性或特定文风，而不是简单意义上的“通用好文本”。

课程因此没有把模型式过滤描绘成终局。它更像是在说：数据工程已经从“规则清洗”进入“模型筛选”的阶段，但筛选器本身的偏好、保守程度和覆盖范围都会反过来塑造模型。

关于 model-based filtering 的一个隐患

当你用模型去选训练数据时，你实际上把“什么值得学”这件事提前编码进了过滤器。过滤器越强，训练数据分布越不自然；这既可能提升质量，也可能压窄覆盖。

4.3 本章小结

第 13 讲在这里把数据工程继续推进了一步：过滤不再只是手写规则，而是越来越依赖模型和蒸馏式 quality signal。这让数据处理变得更强，但也引入了新的分布偏见来源。

5 版权、许可、fair use 与 ToS：数据不是只要看见就能拿来训

5.1 版权法关心的是表达，不只是字面复制

课程在法律部分非常清楚地说明：互联网绝大多数内容都自动受到版权保护。你是否能拿某份内容训练模型，不只取决于它有没有被模型 verbatim 记住，还取决于获取、复制、转换和最终市场影响这些更底层的问题。

课程特别强调了几个法律直觉。第一，copyright 保护的是 expression 而不是 abstract idea；第二，作品不需要注册就自动受保护；第三，foundation model 训练的第一步“复制数据”本身就已经进入版权讨论范围。这些事实足以打破“网上能看到就等于能拿来训练”的朴素想法。

5.2 许可、fair use 和 ToS 是三层不同约束

课程把合法性拆成三层。第一层是 license：如果拿到了许可，问题会简单很多。第二层是 fair use：在没有许可时，要根据使用目的、作品性质、使用比例和市场影响等因素做复杂判断。第三层则是 terms of service：即便某作品本身可能允许使用，平台合同仍可能禁止特定抓取和下载行为。

这三层约束叠在一起，解释了为什么许多团队宁愿少说细节。数据问题不是单纯的技术处理，而是工程、法务和风险管理的交叉点。

课程在法律部分最现实的提醒

“能训练”不是一个纯技术判断。它同时是许可判断、fair use 判断和合同合规判断。忽略任何一层，都会把数据工程理解得过于天真。

5.3 本章小结

第 13 讲并没有给出一条简单的合法性公式，而是让学生接受一个现实：数据使用总是在技术价值与法律风险之间做权衡，真正成熟的 pipeline 必须把二者一起管理。

6 mid-training 与 post-training 数据：能力增强和行为塑形的另一套世界

6.1 长上下文和能力增强往往不该在预训练里硬做

课程后半段开始转向 mid-training。一个典型例子是长上下文：如果直接在预训练阶段把序列长度推得很大，Transformer 的二次复杂度会让成本爆炸。因此很多团队会在基础预训练之后，再用更针对性的文档、数学和长上下文数据去做能力增强，比如 LongLoRA 一类工作。

这说明数据工程不仅决定“模型会不会”，还决定“哪个能力应该在哪个阶段补”。预训练不是包打天下的大桶；某些能力若在后续阶段补，反而更高效。

6.2 instruction data 与 synthetic data 已经形成自己的生态

课程最后扫过 Super-Natural Instructions、FLAN、Alpaca、Vicuna、WizardLM、MAmmoTH2、OpenHermes、Llama 2 chat、Llama-Nemotron 等数据集，传达出一个非常清晰的趋势：后训练数据已经形成了独立的工业体系，其中 synthetic data 和 dataset aggregation 占比越来越高。

课程尤其强调一个现实：高质量 vendor annotation 的数量未必很大，但往往价值很高；大规模 open 或 synthetic instruction data 则提供覆盖和多样性。团队真正做的是在这些来源之间找平衡，而不是相信某一种来源天然最好。

6.3 本章小结

到了 mid-training 和 post-training，数据从“自然文档”逐渐变成“带明确教学意图或行为意图的监督信号”。这使得后期数据的设计空间和预训练数据完全不同。

7 总结与延伸

第 13 讲把“数据”从抽象名词拆成了一整条现实管线。

第一，**数据是 foundation model 时代最难复制的护城河**。因为它同时涉及人工判断、长尾清洗和法律风险。

第二，**训练阶段不同，数据角色也不同**。pretraining 追求广覆盖与规模，mid-training 补能力，post-training 塑行为。

第三，**可训练语料来自复杂供应链**。从 Common Crawl 到 C4、The Pile、FineWeb、Dolma、The Stack，真正的价值在于如何转换、过滤、去重和配比，而不是原始来源本身。

第四，**数据过滤正在模型化**。 model-based filtering 能提升质量，但也会把过滤器的偏好编码进训练分布。

第五，**法律和合同不是外围问题**。许可、fair use 与 ToS 共同决定了某份数据能否进入训练 pipeline。

第六，**mid-training 与 post-training 已经形成独立数据生态**。长上下文、指令跟随、安全与 reasoning traces 往往都在这些后续阶段被强化。

我对第 13 讲的压缩提醒

如果只把这讲理解成“介绍了很多数据集”，那就太浅了。真正的结论是：**数据工程是一条同时处理来源、质量、重复、目标和合法性的供应链，而模型能力就是这条供应链的产物**。

下一讲进入 Data II 之后，课程会从“数据从哪里来、能不能用”进一步推进到“怎样具体做过滤、分类、重要性重采样和去重算法”。第 13 讲是全景图，第 14 讲是机械细节。