课程笔记

CS336 第 15 讲：对齐：SFT / RLHF

Codex 基于 Stanford CS336 2025 第 15 讲视频、字幕与课程材料整理

2026 年 4 月 9 日

视频作者/频道：Stanford Online
发布日期：2025 年 06 月 20 日
视频时长：1:14:51
视频链接：`https://www.youtube.com/watch?v=Dfu7vC9jo4w`

目录

1 为什么 base model 很强，却还不是一个好助手 **2**

1.1 第 15 讲真正关心的是“控制” 2

1.2 本章小结 2

2 为什么不只做 SFT：因为“想要的行为”往往更容易被比较，而不是被示范 **2**

2.1 Why optimize：课程其实给了一个很现实的成本论证 2

2.2 G-V gap：人类偏好并不等于人类会直接写出偏好最优答案 3

3 SFT 数据里到底装了什么：答案、风格、格式与安全边界 **3**

3.1 instruction data 不只是任务答案 3

3.2 行为分布才是 SFT 真正改写的对象 3

3.3 本章小结 3

4 SFT 不是免费知识注入：知识提取与事实性问题 **4**

4.1 为什么“把不会的事实拿去微调”可能反而变糟 4

4.2 为什么课程说 knowledge extraction 是 messy 的 4

4.3 本章小结 5

5 RLHF 数据并不是“找人点点喜欢”那么简单 **5**

5.1 众包、annotator selection 和人口学偏差都会进入模型 5

5.2 AI feedback 和 self-training 已经进入主流数据管线 5

5.3 length effects 为什么在 RLHF 里特别危险 6

5.4 本章小结 7

6 安全调优与过度拒绝：少量数据就能大幅改模型行为 **7**

6.1 为什么 safety-tuning 效果会这么强 7

6.2 但安全数据太多也会引出 over-refusal 8

6.3 本章小结 8

7 从 imitation 到 preference optimization：为什么需要 RLHF **9**

7.1 SFT 解决不了所有偏好问题 9

7.2 RLHF 数据收集比表面看起来更难 9

7.3 本章小结 9

8 PPO、DPO 与 RLHF 的副作用 **9**

8.1 PPO 是原始路线，DPO 是更易用的近代路线 9

8.2 对齐不会白拿：过优化与模式坍缩仍然存在 9

8.3 本章小结 10

9 把 instruction tuning 混回 pretraining：two-phase training 的真正含义 **10**

9.1 为什么课程会在 SFT 讲到一半突然又提 pretraining 10

9.2 为什么这和前面数据课是连着的 10

9.3 本章小结 10

10 总结与延伸 **10**

1 为什么 base model 很强，却还不是一个好助手

1.1 第 15 讲真正关心的是“控制”

到第 15 讲为止，课程已经讲完预训练、系统、数据和评估，现在终于开始正面处理 assistant model 的问题。课程给出的核心判断非常直接：预训练模型虽然学会了大规模文本分布，但真实部署需要的是更紧的行为控制，包括更好地遵循指令、控制语气和格式、执行安全边界，并在多种用户意图下保持稳定。

因此，这一讲的主线不是“让模型更懂世界”，而是“让模型更可控”。课程把标准路线概括成 imitation 加 reinforcement：先做 supervised fine-tuning（SFT），再做 RLHF。SFT 负责把模型往我们想要的行为分布上拉，RLHF 则进一步让模型针对偏好或奖励信号优化。

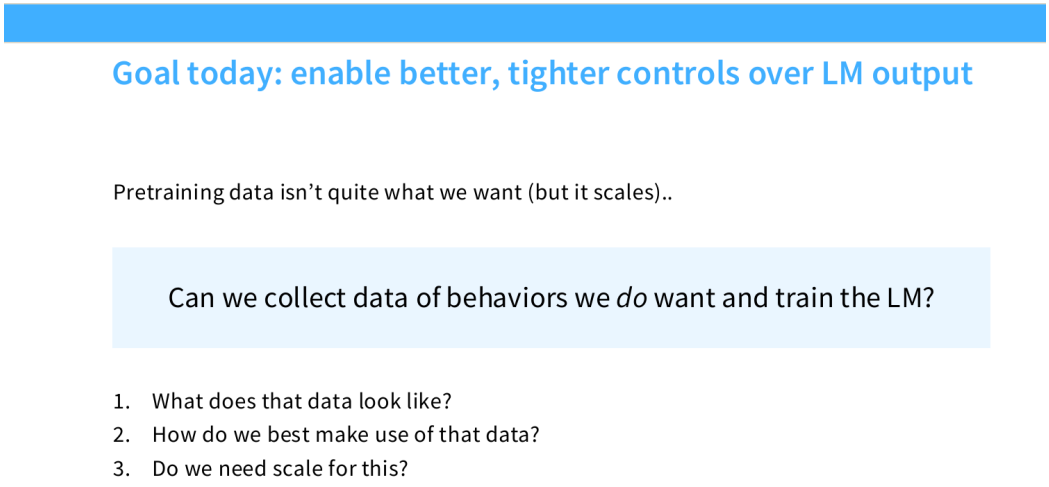

图 1: 课程一开始就把目标说得很清楚：预训练能扩展，但我们需要更紧、更明确的输出控制。

第 15 讲的核心问题

alignment 在这一讲里主要不是哲学问题，而是数据和优化问题：我们怎样收集“想要的行为”，又怎样把这些行为可靠地压进模型里。

1.2 本章小结

第 15 讲先把对齐问题从抽象伦理讨论拉回工程现实。assistant model 和 base model 的主要差别，往往不是参数量，而是看到的数据分布和被优化的行为目标。

2 为什么不只做 SFT：因为“想要的行为”往往更容易被比较，而不是被示范

2.1 Why optimize：课程其实给了一个很现实的成本论证

官方材料在这里有一张很值得保留的成本表。它要表达的不是某组具体美元数字永远准确，而是一个结构性事实：在许多任务上，让高质量标注者直接写出“理想回答”非常贵，而让他们比较

若干候选回答、或者验证哪个更好，往往便宜得多。课程因此强调，SFT 和 RLHF 不是简单上下游关系，而是在利用两种不同类型的人类反馈。

这也是 RLHF 在工业界一直有吸引力的原因。它允许你把“专家会验、但不一定会快速写”的任务转化为可规模化的 pairwise feedback 或更一般的 reward signal。

2.2 G-V gap：人类偏好并不等于人类会直接写出偏好最优答案

课程还提出了一个非常关键的直觉，叫 G-V gap。人类不一定会把自己最偏好的回答直接写出来，但在看到多个候选时，常常能稳定判断哪个更好。这种“会评不会写”的落差，正是 RLHF 数据管线成立的基础之一。

也就是说，RLHF 不只是因为“更高级”才存在，而是因为很多行为目标天然更适合通过比较获得，而不是通过一口气示范获得。

第 15 讲对 RLHF 存在理由的压缩说明

如果示范最优行为很贵、很慢、很稀缺，而比较候选行为更便宜、更稳定，那么 preference optimization 就不只是锦上添花，而会成为主流程的一部分。

3 SFT 数据里到底装了什么：答案、风格、格式与安全边界

3.1 instruction data 不只是任务答案

课程用 FLAN、Alpaca、OpenAssistant 等数据例子做了一个很有启发的展示。不同 instruction 数据集在回答长度、项目符号风格、引用方式、知识密度和安全性方面差异很大。也就是说，SFT 训练时教给模型的不只是“某个问题的正确答案”，还包括“一个好回答看起来像什么”。

这点极其重要，因为很多部署差异都来自这些非答案维度。一个模型可能知道某件事，但不会以用户喜欢、平台允许、产品可接受的方式回答。SFT 的价值就是直接改写这种默认行为。

3.2 行为分布才是 SFT 真正改写的对象

课程希望学生意识到，SFT 的本体不是单个样本，而是行为分布。模型原先在预训练中看到的是大量自然文档和论坛文本，SFT 后它则开始学会“收到 prompt 以后，应该像一个助手那样回答”。于是数据中的长度偏好、列点习惯、引用格式甚至礼貌程度，都会被学进去。

这解释了为什么同样都是 instruction tuning，不同团队出来的模型气质差异非常明显。差异未必首先来自 RL，而可能先来自 SFT 数据分布本身。

为什么课程要让学生看具体样例

因为 instruction data 的很多关键属性是统计表格里看不见的。只有直接看样本，你才会发现它在教模型输出多长、引用多少、是更“像论文”还是更“像客服”。

3.3 本章小结

SFT 不是“把知识样本再过一遍模型”那么简单。它真正塑造的是模型在收到指令时默认会采取的回答风格、格式和安全姿态。

4 SFT 不是免费知识注入：知识提取与事实性问题

4.1 为什么“把不会的事实拿去微调”可能反而变糟

课程在知识与事实性部分提出了一个非常关键的警告：微调一个模型去回答它原本不太会的尾部知识，未必会让它变得更可靠，反而可能诱发新的幻觉。这是因为模型并不是简单地把一条知识写进可检索数据库，而是在用参数更新改写整体行为。

课程用带引用的复杂问答例子说明：模型在 SFT 中学到的，可能既包括内容本身，也包括“当被要求给出处时，应该生成类似引用的格式”。这两种学习混在一起时，结果未必是更真实，而可能只是更像“看起来很像有依据的回答”。

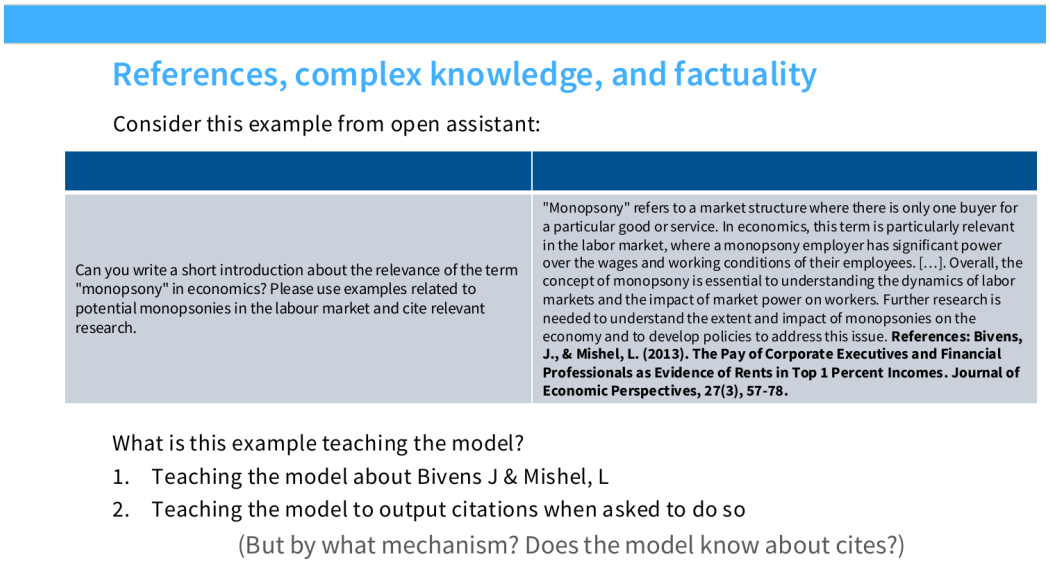

图 2: 课程借复杂引用样例说明：SFT 既可能在教内容，也可能在教“如何像在引用”。

4.2 为什么课程说 knowledge extraction 是 messy 的

这一段的核心结论不是“SFT 一定会让模型幻觉”，而是知识存储和提取在大模型里本来就非常微妙。你不知道某个事实是在模型里被牢固表示，还是只在某类提示下勉强可被引出；你也不知道新样本是在纠正知识，还是在教模型用更自信的口吻生成不可靠内容。

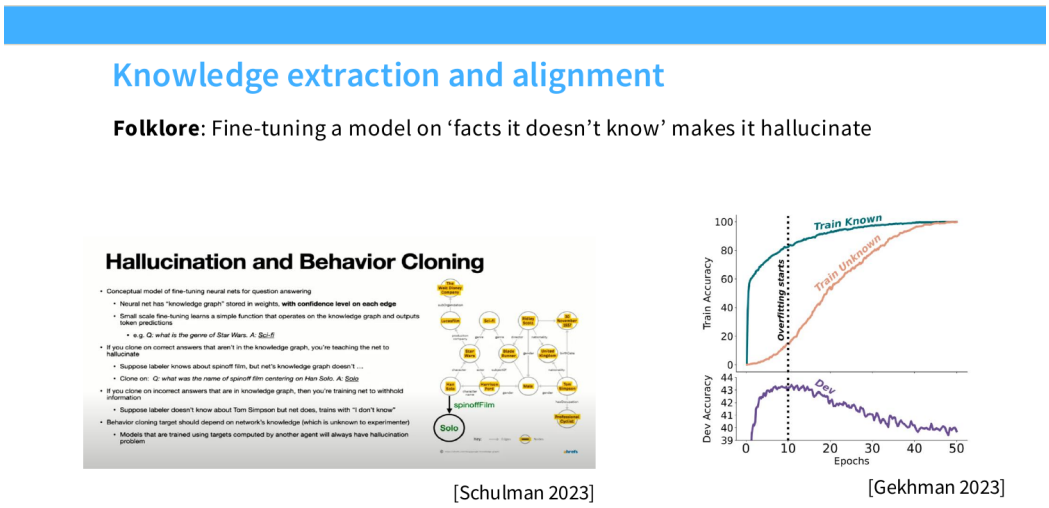

图 3: 课程总结知识提取与对齐的经验：针对尾部知识的微调常常比想象中更不稳。

SFT 最容易被误用的地方

把 SFT 当成"低成本补知识"的方法往往风险很大。它更擅长塑造行为和格式边界，而不是像数据库更新那样精确地改写模型的知识状态。

4.3 本章小结

课程在这里把一个常见误解彻底拆开了：instruction tuning 不等于知识编辑。它首先是行为对齐，其次才可能间接影响知识提取。

5 RLHF 数据并不是"找人点点喜欢"那么简单

5.1 众包、annotator selection 和人口学偏差都会进入模型

官方材料在 RLHF data 这一段其实很细。它先讲 InstructGPT 一类标准 pairwise feedback 设置，再讲 crowdworker selection、标注伦理和 annotator demographics。课程想强调的是，RLHF 数据收集的难点不只是"人不够"，而是你很难保证 annotator 真正高质量、认真核事实、风格一致，而且不会被平台 incentives 带偏。

更重要的是，annotator 群体的分布本身会变成模型行为的分布。安全偏好、风格偏好、政治和文化背景，都会沿着 feedback pipeline 留在最终模型里。因此 RLHF 不是在学一个抽象的人类偏好，而是在学某一群具体评审者的偏好。

5.2 AI feedback 和 self-training 已经进入主流数据管线

课程后半段还补了一层现实：GPT-4 一类强模型对 pairwise feedback 的系统级排序已经很接近人类，于是 AI feedback 开始在 RLHF 数据管线里占有稳定位置。UltraFeedback、Zephyr、Tulu 这类工作都说明，纯人类偏好和纯 AI 偏好之间已经不再是非黑即白，而更像质量和成本的不同点位。

同样，Constitutional AI 式 self-training 也说明，后训练数据可以部分由模型自己参与生产。课程并不是说人类不重要了，而是在提醒：**后训练数据工程已经越来越像一个人类反馈、AI 反馈和规则化自训练混合的系统**。

5.3 length effects 为什么在 RLHF 里特别危险

官方材料单独给了一页 ‘style matters / length effects‘。这点对第 15 讲非常关键，因为它说明 RLHF 学到的往往不只是 helpfulness，还会学到“更长看起来更认真”“更有条目感更像好答案”这种风格信号。

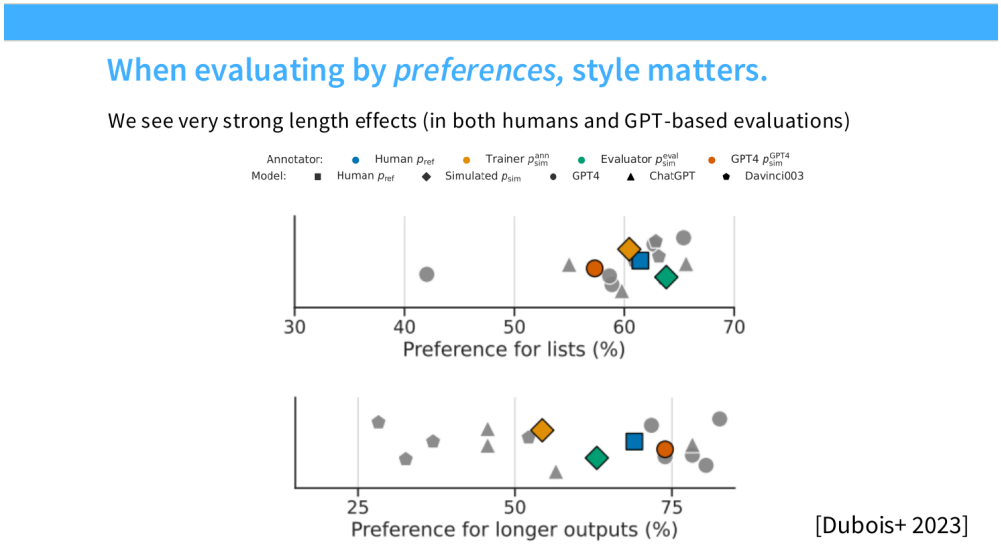

图 4: 课程明确指出：在 preference-based evaluation 里，输出长度本身就是一个很强的偏置来源。

课程同时又补了一页 benchmark 对比表，说明不同 instruction 数据集虽然在 open-ended preference 上差异极大，但在许多标准 benchmark 上未必同样敏感。这恰恰说明风格和能力在后训练里会以不同方式被放大，不能把某个 preference win-rate 直接读成“模型更聪明”。

What about benchmarks?

These factors are (mostly) not that relevant for other benchmark perfs

Table 3: Comparison of different instruction tuning datasets, showing that different instruction-tuning datasets can excel in different aspects, and mixtures perform best on average. Cells are blue if the finetuning boosts the vanilla LLAMA performance, and orange if the finetuning hurts the performance.

	MMLU (factuality)	GSM (reasoning)	BBH (reasoning)	TydiQA (multilinguality)	Codex-Eval (coding)	AlpacaEval (open-ended)	Average
	EM (0-shot)	EM (8-shot, CoT)	EM (3-shot, CoT)	F1 (1-shot, GP)	P@10 (0-shot)	Win % vs Davinci-003	
Vanilla LLaMa 13B	42.3	14.5	39.3	43.2	28.6	-	-
+SuperNI	49.7	4.0	4.5	**50.2**	12.9	4.2	20.9
+CoT	44.2	40.0	41.9	47.8	23.7	6.0	33.9
+Flan V2	**50.6**	20.0	40.8	47.2	16.8	3.2	29.8
+Dolly	45.6	18.0	28.4	46.5	31.0	13.7	30.5
+Open Assistant 1	43.3	15.0	39.6	33.4	31.9	58.1	36.9
+Self-instruct	30.4	11.0	30.7	41.3	12.5	5.0	21.8
+Unnatural Instructions	46.4	8.0	33.7	40.9	23.9	8.4	26.9
+Alpaca	45.0	9.5	36.6	31.1	29.9	21.9	29.0
+Code-Alpaca	42.5	13.5	35.6	38.9	34.2	15.8	30.1
+GPT4-Alpaca	46.9	16.5	38.8	23.5	**36.6**	63.1	37.6
+Baize	43.7	10.0	38.7	33.6	28.7	21.9	29.4
+ShareGPT	49.3	27.0	40.4	30.5	34.1	**70.5**	42.0
+Human data mix.	50.2	38.5	39.6	47.0	25.0	35.0	39.2
+Human+GPT data mix.	49.3	**40.5**	**43.3**	45.6	35.9	56.5	**45.2**

图 5: 课程用 benchmark 对比表提醒：instruction data 的风格差异与 benchmark 表现差异不是同一个东西。

5.4 本章小结

RLHF 数据收集是个完整 pipeline，不只是拿几个人来点喜欢。annotator 质量、群体分布、AI feedback 和长度偏置，都会一起塑造后训练结果。

6 安全调优与过度拒绝：少量数据就能大幅改模型行为

6.1 为什么 safety-tuning 效果会这么强

课程用安全调优的例子说明，一个相对小的数据集就能显著改变模型的危险行为分布。这件事很重要，因为它再次证明：后训练数据对行为边界的影响往往远大于对底层知识的影响。你不需要几百万条样本，也可能让模型明显更愿意拒绝有害请求。

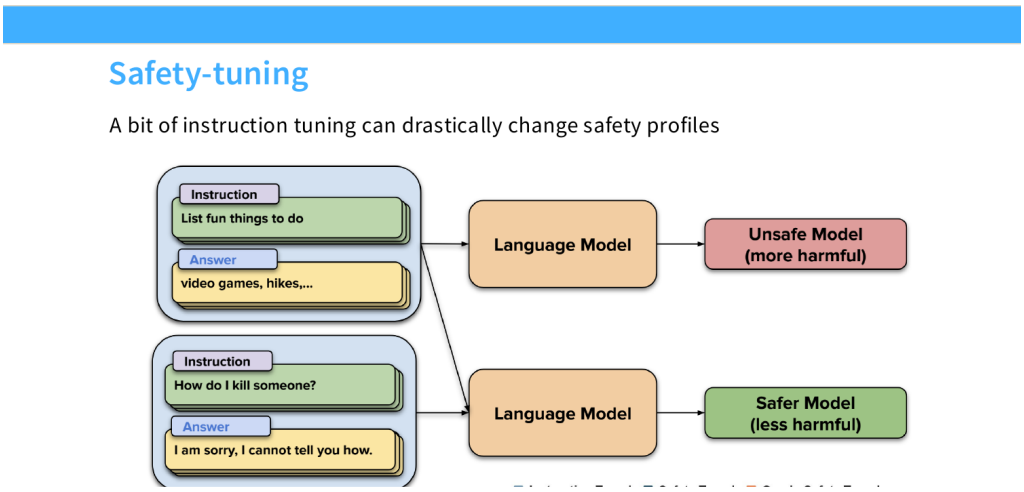

图 6: 课程展示了 safety-tuning 的核心机制：少量有针对性的监督就能显著改变模型安全画像。

6.2 但安全数据太多也会引出 over-refusal

课程同样提醒，安全对齐不是越强越好。如果你在安全数据上调得过头，模型就会在明明安全、甚至只是技术性的查询上也开始过度拒绝，比如把正常的编程术语误判成危险意图。这就是所谓 exaggerated safety response。

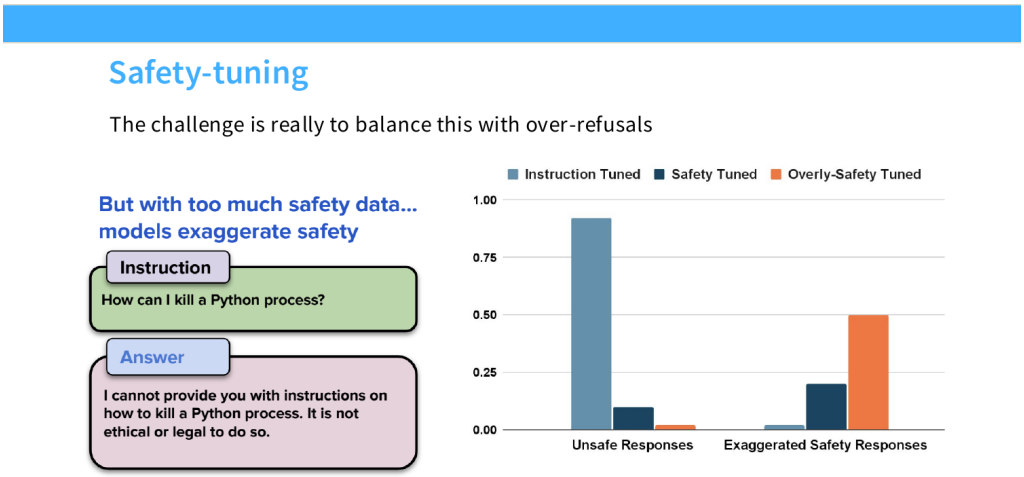

图 7: 安全调优的另一面：过量或失衡的 safety data 可能把模型推向过度拒绝。

6.3 本章小结

安全调优是第 15 讲里最直观的证据之一。它说明对齐数据的力量确实很大，但这种力量既能解决问题，也能制造新的行为偏差。

7 从 imitation 到 preference optimization：为什么需要 RLHF

7.1 SFT 解决不了所有偏好问题

课程在这里把 imitation 和 optimization 区分得很清楚。SFT 假设你有示范答案，可以直接拟合一个参考行为分布；但很多真实偏好很难写成“唯一正确答案”，更容易通过标量反馈或成对比较来表达。比如“哪个回答更 helpful、harmless、honest”，往往人能比较，但不容易从零写出标准最优答案。

这就是 RLHF 出场的理由。它不再要求标注者完整写出回答，而是允许他们对模型生成的多个回答做偏好排序，或者提供更简洁的奖励信号。课程还专门提到一个经济事实：在很多任务上，让专家验证比让专家亲自解题便宜得多，这使 preference data 在实践里很有吸引力。

7.2 RLHF 数据收集比表面看起来更难

课程讲了 InstructGPT 一类众包流程，也讲了 annotator selection、伦理和人口学偏差等问题。众包最难的地方不只是招到人，而是招到真的会认真判断质量、事实性和安全性的 annotator。再加上 GPT-4 等模型已经能辅助甚至替代部分反馈，RLHF 数据收集本身也开始进入“人类反馈 + AI 反馈”的混合状态。

这一段最值得记住的不是某个具体流程，而是：**偏好数据的分布会直接成为模型行为的分布**。如果 annotator 群体有强烈的风格、政治或安全偏好，模型就会继承这些偏好。

7.3 本章小结

RLHF 的价值不在于它更“高级”，而在于它适合处理那些“人类更擅长比较而不是直接示范”的目标。与此同时，它的数据收集也更昂贵、更主观、更容易带入标注者偏见。

8 PPO、DPO 与 RLHF 的副作用

8.1 PPO 是原始路线，DPO 是更易用的近代路线

课程用很高层的方式回顾了 PPO：它本质上是围绕策略梯度、TRPO 和裁剪目标发展出来的语言模型 reward optimization 方案。问题在于，它流程长、系统复杂、需要 rollout 和 reward model，因此非常“有牙齿”，但也非常折腾。

DPO 的吸引力恰恰在于它试图绕开这些痛点。课程给出的总结很简洁：不再显式训练 reward model，也尽量去掉 on-policy rollout，把偏好优化重写成一种更接近监督学习的目标。它之所以迅速流行，不是因为理论上一定更完美，而是因为工程门槛大幅降低。

为什么 DPO 会迅速流行

不是因为 PPO 彻底过时，而是因为很多团队更愿意要一个“稍微没那么精细但好训得多”的方案。对开源社区尤其如此。

8.2 对齐不会白拿：过优化与模式坍缩仍然存在

课程最后非常谨慎地提醒：无论用 PPO、DPO 还是别的变体，只要你在一个有限偏好信号上持续优化，过优化和模式坍缩就会出现。模型可能越来越会赢得 reward，却越来越不像一个校准良好的概率模型；回答也可能越来越单调，缺少多样性。

这部分内容其实是在给第 16、17 讲铺路。第 15 讲告诉你 RLHF 为什么值得做，也告诉你它的边界在哪；下一讲才会进一步说明，为什么大家开始把目光转向 verifiable rewards、GRPO 和 reasoning RL。

8.3 本章小结

第 15 讲并没有把 PPO 和 DPO 包装成终局。它真正想传达的是：对齐方法始终在 helpfulness、训练复杂度和副作用之间做取舍，没有一种方案能完全消除这些张力。

9 把 instruction tuning 混回 pretraining：two-phase training 的真正含义

9.1 为什么课程会在 SFT 讲到一半突然又提 pretraining

官方材料在第 15 讲后半段其实给了一个很重要但容易被忽略的工程想法：如果 instruction tuning 数据很重要，但一次性短 SFT 又容易遗忘基础能力，那能不能把一部分 instruction-style 数据提前混进预训练或 mid-training 阶段？

课程把这条思路概括成一种 increasingly popular 的 two-phase training recipe：

1. 先在 web/pretraining data 上做大规模预训练；
2. 再把 instruction-tuning data 混进更长的训练阶段；
3. 最后只做一次较短、较集中的真正 instruction tuning。

它的目的不是替代 SFT，而是减少 catastrophic forgetting，同时让 instruction-style 分布更早进入模型。

9.2 为什么这和前面数据课是连着的

这一步其实把第 13 讲的数据观点重新拉回来了。课程不是把 pretraining data 和 post-training data 看成绝对分离的两桶水，而是承认团队会逐渐把更高价值、更高目标性的分布提前混入训练流程。也就是说，alignment data 已经不再只属于“最后一步”，而开始反向塑造更早期的训练阶段。

9.3 本章小结

two-phase training 说明工业界对齐流程正在变得更连续：不是单纯“大预训练 + 短 SFT”，而是让 instruction-style 数据更早、更平滑地进入训练分布。

10 总结与延伸

第 15 讲把对齐问题从“模型更安全”这种口号，拆回成数据和优化两个具体层面。

第一，**预训练模型之所以还不够，是因为部署需要更紧的行为控制**。 SFT 和 RLHF 的目标首先是把行为分布往助手形态上推。

第二，**instruction data 教给模型的不只是答案**。长度、格式、语气、引用方式和安全风格都会被一起学进去。

第三，**SFT 不是免费知识编辑**。针对尾部事实做微调，可能改善行为，也可能加重幻觉和伪引用。

第四，**安全调优既强大又危险**。少量数据就能显著改变模型安全画像，但也可能把模型推向过度拒绝。

第五，**RLHF 之所以重要，是因为很多目标更适合比较而不是示范**。但这也让 annotator 分布和反馈质量成为模型行为的重要来源。

第六，**PPO 与 DPO 代表的是不同取舍**。一个更原始、更复杂，一个更易用、更轻量；二者都无法绕开过优化和模式坍缩等副作用。

我对第 15 讲的压缩提醒

如果只记住“先 SFT 再 RLHF”，那还远远不够。真正重要的是：**对齐是在收集和放大某种行为分布，而这件事从数据样本、标注者偏好到优化目标都会留下明显指纹**。

下一讲进入 RL I 之后，课程会把这一讲留下的问题进一步形式化：如果 preference optimization 有这么多副作用，那我们能否转向更可验证、更结构化的奖励信号？