

第 15 讲: Mid/Post-training: SFT 与 RLHF

CS336 Spring 2026 public videos and official course materials

目录

1 本章导读	4
1.1 本章知识路线	4
1.2 结构图	4
2 本章主线	4
2.1 本章要解决的核心问题	4
2.2 从机制到资源账本	5
2.3 从课堂讲解到可复现实验	5
3 术语、符号与问题边界	6
3.1 术语之间的关系	6
4 从 pretraining 到 assistant 行为	6
4.1 为什么要讨论从 pretraining 到 assistant 行为	6
4.2 从 pretraining 到 assistant 行为的机制	7
4.3 从 pretraining 到 assistant 行为的数学表达	7
4.4 从从 pretraining 到 assistant 行为到程序	7
4.5 边界条件与常见误解	7
4.6 与本章其他概念的关系	7
4.7 怎样检验从 pretraining 到 assistant 行为	8
4.8 概念辨析: 从 pretraining 到 assistant 行为	8
4.9 从 pretraining 到 assistant 行为的小结	8
5 Reward modeling 与 RLHF	8
5.1 为什么要讨论 Reward modeling 与 RLHF	8
5.2 Reward modeling 与 RLHF 的机制	9
5.3 Reward modeling 与 RLHF 的目标函数	9
5.4 Reward modeling 与 RLHF 的训练流程	9
5.5 边界条件与常见误解	9

5.6	与本章其他概念的关系	9
5.7	怎样检验 Reward modeling 与 RLHF	10
5.8	概念辨析: Reward modeling 与 RLHF	10
5.9	Reward modeling 与 RLHF 的小结	10
6	DPO 与直接偏好优化	10
6.1	为什么要讨论 DPO 与直接偏好优化	10
6.2	DPO 与直接偏好优化的机制	11
6.3	DPO 与直接偏好优化的目标函数	11
6.4	DPO 与直接偏好优化的训练流程	11
6.5	边界条件与常见误解	11
6.6	与本章其他概念的关系	11
6.7	怎样检验 DPO 与直接偏好优化	12
6.8	概念辨析: DPO 与直接偏好优化	12
6.9	DPO 与直接偏好优化的小结	12
7	综合讨论: 从局部机制到完整系统	12
7.1	从 pretraining 到 assistant 行为在系统中的位置	13
7.2	Reward modeling 与 RLHF 在系统中的位置	13
7.3	DPO 与直接偏好优化在系统中的位置	13
7.4	把本章知识用于读论文和复现实验	13
8	例题: 把概念变成可计算检查	14
8.1	DPO 目标如何偏向 chosen response	14
9	实验设计: 从小例子到可复现结论	14
9.1	最小输入	14
9.2	资源账本	14
9.3	单变量消融	14
9.4	失败条件	14
9.5	记录与报告	15
9.6	从小实验到大结论	15
9.7	把本章重新读成一条证据链	15
10	课程资料与回看路径	15
10.1	视频回看路径	15
10.2	课程资料阅读路径	16
11	实践说明、历史位置与风险	16

12 复习要点	17
12.1 综合自测	17
13 总结与延伸	18
13.1 本章小结	18
13.2 延伸解释	18
13.3 练习	18

1 本章导读

本章讨论 **Mid/Post-training: SFT 与 RLHF**。CS336 的第一层目标不是把现成大模型当作黑箱使用，而是把 language model 从输入文本、训练目标、模型结构、数据、系统和评估这些部件重新拆开。只有拆开之后，读者才能判断一个设计选择究竟改变了什么。设想 base model 会续写文本，却不会稳定遵循 instruction。Post-training（后训练）要把语言模型变成 assistant：SFT 提供示范行为，RLHF/DPO 用偏好约束输出风格和安全边界。本章对应 CS336 Spring 2026 第 15 个公开视频，并结合课程页提供的可解析资料。视频和课程页给出事实边界；正文把这些材料改写为可自学的教材章节。阅读本章时，先理解问题为什么存在，再看定义、公式和实现形态，随后通过例题和练习检查自己是否能独立复现这条 reasoning chain。

Lecture 15

“AFTER PRETRAINING” (MID/POSTTRAINING)

CS336



图 1: 第 15 讲的课程图像锚点。

1.1 本章知识路线

- 本章首先说明 Mid/Post-training: SFT 与 RLHF 为什么是 language modeling pipeline 中不可跳过的一环。
- 其次定义本章反复使用的术语，并说明这些术语对应的计算对象或系统对象。
- 随后用公式和伪代码表达主要机制，让概念能够落到可计算的变量上。
- 最后给出例题、风险讨论和练习，便于读者检查自己是否真正掌握了机制。

1.2 结构图

下面的图用于帮助读者定位本章的核心结构。先看概念之间的依赖，再回到正文中的公式、伪代码和例题。

2 本章主线

Mid/Post-training: SFT 与 RLHF 的主线是解释 base model 之后的行为塑形。课程关心的不是单个 post-training 名词，而是示范、偏好、奖励和评估怎样共同约束输出。

2.1 本章要解决的核心问题

本讲从 pretraining 转向 mid/post-training。SFT 用示范回答塑造 instruction-following，RLHF 用偏好数据进一步控制输出。读完这一段后，应能用一两句话说明 Mid/Post-training: SFT 与 RLHF 要解决的瓶颈，

The class thus far

We've now covered pre-training, which gets you to GPT3.. But how do we get to instructGPT?




图 2: 官方材料图页: Mid/Post-training: SFT 与 RLHF 的课程页/PDF/script 图像锚点。

Lecture 15

"AFTER PRETRAINING" (MID/POSTTRAINING)

CS336

图 3: 官方材料图页: Mid/Post-training: SFT 与 RLHF 的课程页/PDF/script 图像锚点。

并指出这个瓶颈发生在数据、模型、优化、系统还是评估层。

2.2 从机制到资源账本

post-training 更 artisanal: 数据稀缺、公开细节少、标注规范和 reward model 都会强烈影响模型行为。随后把机制写成账本: 输入规模是什么, 主要状态是什么, 成本或质量指标怎样随变量改变。这个账本让后面的公式不再只是符号。

2.3 从课堂讲解到可复现实验

DPO/PPO/RLHF 等方法的共同主题是让模型偏向更符合人类偏好的回答, 同时用 KL 或 reference policy 控制偏离。最后把课堂讲解转成可复现实验: 固定协议, 改变一个变量, 记录中间量, 并解释结果为何支持或反驳原来的机制判断。

3 术语、符号与问题边界

本章的术语横跨模型、数据和系统。读者需要先知道每个词指向的对象：有些词描述数学目标，有些词描述张量形状，有些词描述硬件瓶颈，还有一些词描述评估协议。术语边界不清，后面的公式和实现就会变成空洞的缩写。

#	术语	阅读要求
1	post-training（后训练）	给出定义、一个最小例子、一个关联公式或代码位置，以及一个典型失败情形。
2	supervised fine-tuning (SFT)	说明它约束的是模型行为、优化目标还是评估协议，并指出一个奖励或偏好失真的例子。
3	RLHF	说明它约束的是模型行为、优化目标还是评估协议，并指出一个奖励或偏好失真的例子。
4	reward model（奖励模型）	说明它约束的是模型行为、优化目标还是评估协议，并指出一个奖励或偏好失真的例子。
5	DPO	说明它约束的是模型行为、优化目标还是评估协议，并指出一个奖励或偏好失真的例子。
6	PPO	给出定义、一个最小例子、一个关联公式或代码位置，以及一个典型失败情形。

这些术语之间有依赖关系。例如 tokenization 改变 sequence length，sequence length 又改变 attention FLOPs、KV cache 和 evaluation token budget；parallelism 改变显存占用，也改变通信瓶颈和故障恢复方式。

3.1 术语之间的关系

在本章中，post-training（后训练）给出问题入口，supervised fine-tuning (SFT) 描述主要机制，RLHF 则把机制连接到可测量的结果。读教材时应当沿着这个链条追问：输入是什么，中间状态怎样改变，输出指标为什么随之变化。课程材料还会反复出现 data、rlhf、reward、many、instruction、safety 等词。它们不是一组同义标签，而是提示本章的不同层次：有的指对象，有的指操作，有的指约束或指标。因此，术语表不是背诵清单，而是后文阅读的索引。遇到一个术语时，先定位它属于 representation、optimization、systems、data 还是 evaluation，再判断它改变哪一项账本。

4 从 pretraining 到 assistant 行为

现在进入从 pretraining 到 assistant 行为。这一节讨论 base model 之外的行为塑形：示范、偏好、reward 或 verifier 怎样把模型输出推向课程定义的目标行为。

4.1 为什么要讨论从 pretraining 到 assistant 行为

视频开场说 post-training 比 pretraining 更 messy、更 artisanal；它把基础 LM 转成可交互助手。pretraining 学 next-token distribution，SFT 学示范回答格式和任务行为。mid-training/post-training 的核心是改变模型可见行为，而不是重新学习全部世界知识。从 pretraining 到 assistant 行为把 Mid/Post-training：SFT 与 RLHF 连接到行为目标。接下来要看的不是 reward 名称，而是反馈信号、采样分布和约束项怎样改变模型更新。

4.2 从 pretraining 到 assistant 行为的机制

视频开场说 post-training 比 pretraining 更 messy、更 artisanal；它把基础 LM 转成可交互助手。在从 pretraining 到 assistant 行为中，核心对象是行为、奖励和偏好状态：后训练方法并不直接制造知识，而是通过目标和反馈改变模型选择输出的方式。pretraining 学 next-token distribution，SFT 学示范回答格式和任务行为。因而同一个方法在不同规模下可能改变不同的变量，尤其是 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。比较方法时，必须同时给出问题规模和实验条件。mid-training/post-training 的核心是改变模型可见行为，而不是重新学习全部世界知识。可检验性来自训练日志、reward 分布、KL/length 统计和行为评估；只看最终回答样例无法判断更新方向。因此，从 pretraining 到 assistant 行为的学习目标是建立一条行为更新链：读者应能区分示范、偏好、奖励和约束分别给模型提供了什么信号。

4.3 从 pretraining 到 assistant 行为的数学表达

$$\mathcal{L}_{\text{SFT}}(\theta) = - \sum_{(x,y)} \sum_t \log p_{\theta}(y_t \mid x, y_{<t})$$

符号说明： x 是 instruction/context， y 是人工或高质量示范回答；SFT 仍是 token-level 监督学习。这个关系式说明从 pretraining 到 assistant 行为如何把行为偏好写入优化目标。关键不是符号复杂度，而是 reward、reference policy、采样分布和约束强度如何共同决定更新方向。在后训练实验中，reward model score、verifier pass rate、回答长度和人工偏好都是 proxy。它们会被采样策略和格式约束影响，因此不能直接等同于真实有用性。

4.4 从从 pretraining 到 assistant 行为到程序

把从 pretraining 到 assistant 行为写成训练流程时，要区分采样、打分、构造 loss 和更新参数。下面的伪代码保留这些边界。

```
for instruction, response in sft_data:
    loss = cross_entropy(model(instruction, response), response_tokens)
    update(loss)
```

阅读这段训练流程时，重点区分采样、打分和参数更新。只有同时记录 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率，才能判断行为改善来自奖励信号、采样分布还是约束强度。

4.5 边界条件与常见误解

- SFT 数据质量比数量更重要，坏示范会被直接模仿。
- SFT 可能降低 base model 的某些原始能力或校准。
- 后训练指标可能被格式、长度或 verifier 偏差驱动，不能直接等同于真实能力提升。
- 偏好优化可能改善目标行为，也可能牺牲多样性、校准性或某些下游能力。

4.6 与本章其他概念的关系

从 pretraining 到 assistant 行为连接本章的训练目标和输出行为：术语表区分示范、偏好与奖励，公式说明优化方向，伪代码展示采样和更新，例题检查行为约束的边界。对这一类主题，最常见的误解是只列方法名。更有用的做法是比较每个方法改变的成本项、依赖的假设和可能的失败模式。

4.7 怎样检验从 pretraining 到 assistant 行为

检验从 pretraining 到 assistant 行为时，先把抽象说法落到行为、奖励和偏好状态上。与 post-training、SFT、instruction、assistant、demonstration 相关的对象必须能被构造、打印、计数或评分；否则实验只能得到描述性观察，不能得到可复现结论。一个合适的小实验应当保留本节机制，同时让 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率中至少一个量发生可解释变化。输入规模不必逼真；关键是读者能手算或打印关键中间量，并说明哪个变量触发了结果变化。随后把公式说明转成可记录的数量关系。符号说明： $\backslash(x\backslash)$ 是 instruction/context， $\backslash(y\backslash)$ 是人工或高质量示范回答；SFT 仍是 token-level 监督学习。如果数量只能间接观测，就必须说明使用了什么 proxy；如果使用 benchmark 或 reward，也要说明协议和随机性。后训练消融通常一次只改变示范数据、reward scale、KL 约束、采样温度或 verifier。若训练目标和解码策略同时变化，行为差异就很难归因。最后检查失败条件。工程判断往往在反例中变清楚：SFT 数据质量比数量更重要，坏示范会被直接模仿；SFT 可能降低 base model 的某些原始能力或校准。复习时可以把这些限制改写成反例测试，观察它们怎样改变 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。把实验结论放回 Mid/Post-training：SFT 与 RLHF 时，要说明从 pretraining 到 assistant 行为改变的是目标函数、采样分布、反馈质量还是行为约束。能区分这些来源，才说明读者真正理解后训练。

4.8 概念辨析：从 pretraining 到 assistant 行为

post-training、SFT、instruction、assistant、demonstration 常一起出现在后训练讨论中，但它们分别指数据、反馈、目标函数或行为指标。读者应先判断每个词给优化过程提供什么信号。其中，supervised fine-tuning (SFT) 用示范回答塑造 assistant 行为。区分这些词时，可以先问它们是否改变 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。一个术语如果不能对应到变量、状态、代码路径或评估协议，就还没有形成可操作含义。围绕从 pretraining 到 assistant 行为复习时，可以构造几条 prompt-response：明确奖励或偏好规则，观察同一模型在更新前后的行为差异。

4.9 从 pretraining 到 assistant 行为的小结

- 讨论从 pretraining 到 assistant 行为时，应同时报告问题规模、实验设置和主要观测变量，尤其是 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。
- 如果方法声称行为更好，要说明示范、偏好、reward 或 verifier 哪一项提供了信号，并检查 reward hacking、length bias 和能力退化。
- 后训练结论需要把训练目标、采样策略和评估协议分开报告，否则无法判断改进来自哪里。

5 Reward modeling 与 RLHF

现在进入 Reward modeling 与 RLHF。这一节讨论 base model 之外的行为塑形：示范、偏好、reward 或 verifier 怎样把模型输出推向课程定义的目标行为。

5.1 为什么要讨论 Reward modeling 与 RLHF

RLHF 用人类偏好训练 reward model，再用 RL 优化策略模型。pairwise preference 更容易标注开放式回答质量，但 reward model 只是偏好的近似。PPO 等 RL 方法需要 KL penalty，防止模型远离 reference policy 而产生 reward hacking。后训练部分的核心问题是行为控制。模型已经学到语言分布，但还需要通过示范、偏好或可验证奖励，把输出推向可用、可评估、可约束的行为。

5.2 Reward modeling 与 RLHF 的机制

RLHF 用人类偏好训练 reward model，再用 RL 优化策略模型。在 Reward modeling 与 RLHF 中，核心对象是行为、奖励和偏好状态：后训练方法并不直接制造知识，而是通过目标和反馈改变模型选择输出的方式。pairwise preference 更容易标注开放式回答质量，但 reward model 只是偏好的近似。因而同一个方法在不同规模下可能改变不同的变量，尤其是 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。比较方法时，必须同时给出问题规模和实验条件。PPO 等 RL 方法需要 KL penalty，防止模型远离 reference policy 而产生 reward hacking。可检验性来自训练日志、reward 分布、KL/length 统计和行为评估；只看最终回答样例无法判断更新方向。因此，Reward modeling 与 RLHF 的学习目标是建立一条行为更新链：读者应能区分示范、偏好、奖励和约束分别给模型提供了什么信号。

5.3 Reward modeling 与 RLHF 的目标函数

$$\mathcal{L}_{\text{RM}} = -\log \sigma(r_\phi(x, y^+) - r_\phi(x, y^-))$$

符号说明： y^+ 是偏好回答， y^- 是较差回答， r_ϕ 是 reward model。这个关系式说明 Reward modeling 与 RLHF 如何把行为偏好写入优化目标。关键不是符号复杂度，而是 reward、reference policy、采样分布和约束强度如何共同决定更新方向。在后训练实验中，reward model score、verifier pass rate、回答长度和人工偏好都是 proxy。它们会被采样策略和格式约束影响，因此不能直接等同于真实有用性。

5.4 Reward modeling 与 RLHF 的训练流程

把 Reward modeling 与 RLHF 写成训练流程时，要区分采样、打分、构造 loss 和更新参数。下面的伪代码保留这些边界。

```
reward = reward_model(prompt, response)
kl = kl_divergence(policy, reference)
objective = reward - beta * kl
policy.update(objective)
```

阅读这段训练流程时，重点区分采样、打分和参数更新。只有同时记录 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率，才能判断行为改善来自奖励信号、采样分布还是约束强度。

5.5 边界条件与常见误解

- reward model 会被策略优化 exploited。
- 偏好数据反映标注规范和人群，不是客观真理。
- 后训练指标可能被格式、长度或 verifier 偏差驱动，不能直接等同于真实能力提升。
- 偏好优化可能改善目标行为，也可能牺牲多样性、校准性或某些下游能力。

5.6 与本章其他概念的关系

Reward modeling 与 RLHF 连接本章的训练目标和输出行为：术语表区分示范、偏好与奖励，公式说明优化方向，伪代码展示采样和更新，例题检查行为约束的边界。对这一类主题，最常见的误解是只列方法名。更有用的做法是比较每个方法改变的成本项、依赖的假设和可能的失败模式。

5.7 怎样检验 Reward modeling 与 RLHF

检验 Reward modeling 与 RLHF 时，先把抽象说法落到行为、奖励和偏好状态上。与 RLHF、reward model、preference、PPO、KL 相关的对象必须能被构造、打印、计数或评分；否则实验只能得到描述性观察，不能得到可复现结论。一个合适的小实验应当保留本节机制，同时让 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率中至少一个量发生可解释变化。输入规模不必逼真；关键是读者能手算或打印关键中间量，并说明哪个变量触发了结果变化。随后把公式说明转成可记录的数量关系。符号说明： $\langle y^+ \rangle$ 是偏好回答， $\langle y^- \rangle$ 是较差回答， $\langle r_\phi \rangle$ 是 reward model。如果数量只能间接观测，就必须说明使用了什么 proxy；如果使用 benchmark 或 reward，也要说明协议和随机性。后训练消融通常一次只改变示范数据、reward scale、KL 约束、采样温度或 verifier。若训练目标和解码策略同时变化，行为差异就很难归因。最后检查失败条件。工程判断往往在反例中变清楚：reward model 会被策略优化 exploited；偏好数据反映标注规范和人群，不是客观真理。复习时可以把这些限制改写成反例测试，观察它们怎样改变 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。把实验结论放回 Mid/Post-training：SFT 与 RLHF 时，要说明 Reward modeling 与 RLHF 改变的是目标函数、采样分布、反馈质量还是行为约束。能区分这些来源，才说明读者真正理解后训练。

5.8 概念辨析：Reward modeling 与 RLHF

RLHF、reward model、preference、PPO、KL 常一起出现在后训练讨论中，但它们分别指数据、反馈、目标函数或行为指标。读者应先判断每个词给优化过程提供什么信号。其中，RLHF 用人类偏好 reward 优化模型行为。区分这些词时，可以先问它们是否改变 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。一个术语如果不能对应到变量、状态、代码路径或评估协议，就还没有形成可操作含义。围绕 Reward modeling 与 RLHF 复习时，可以构造几条 prompt-response：明确奖励或偏好规则，观察同一模型在更新前后的行为差异。

5.9 Reward modeling 与 RLHF 的小结

- 讨论 Reward modeling 与 RLHF 时，应同时报告问题规模、实验设置和主要观测变量，尤其是 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。
- 如果方法声称行为更好，要说明示范、偏好、reward 或 verifier 哪一项提供了信号，并检查 reward hacking、length bias 和能力退化。
- 后训练结论需要把训练目标、采样策略和评估协议分开报告，否则无法判断改进来自哪里。

6 DPO 与直接偏好优化

现在进入 DPO 与直接偏好优化。这一节讨论 base model 之外的行为塑形：示范、偏好、reward 或 verifier 怎样把模型输出推向课程定义的目标行为。

6.1 为什么要讨论 DPO 与直接偏好优化

DPO 类方法把偏好优化写成监督式目标，避免显式训练 RL loop。它依然依赖偏好数据和 reference policy，只是把 reward 隐式化。post-training 方法选择应看数据类型、稳定性、compute、目标行为和安全约束。后训练部分的核心问题是行为控制。模型已经学到语言分布，但还需要通过示范、偏好或可验证奖励，把输出推向可用、可评估、可约束的行为。

6.2 DPO 与直接偏好优化的机制

DPO 类方法把偏好优化写成监督式目标，避免显式训练 RL loop。在 DPO 与直接偏好优化中，核心对象是行为、奖励和偏好状态：后训练方法并不直接制造知识，而是通过目标和反馈改变模型选择输出的方式。它依然依赖偏好数据和 reference policy，只是把 reward 隐式化。因而同一个方法在不同规模下可能改变不同的变量，尤其是 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。比较方法时，必须同时给出问题规模和实验条件。post-training 方法选择应看数据类型、稳定性、compute、目标行为和安全约束。可检验性来自训练日志、reward 分布、KL/length 统计和行为评估；只看最终回答样例无法判断更新方向。因此，DPO 与直接偏好优化的学习目标是建立一条行为更新链：读者应能区分示范、偏好、奖励和约束分别给模型提供了什么信号。

6.3 DPO 与直接偏好优化的目标函数

$$\mathcal{L}_{\text{DPO}} = -\log \sigma \left(\beta \log \frac{\pi_{\theta}(y^+ | x)}{\pi_{\text{ref}}(y^+ | x)} - \beta \log \frac{\pi_{\theta}(y^- | x)}{\pi_{\text{ref}}(y^- | x)} \right)$$

符号说明： π_{θ} 是待训练策略， π_{ref} 是参考模型， β 控制偏离参考模型的强度。这个关系式说明 DPO 与直接偏好优化如何把行为偏好写入优化目标。关键不是符号复杂度，而是 reward、reference policy、采样分布和约束强度如何共同决定更新方向。在后训练实验中，reward model score、verifier pass rate、回答长度和人工偏好都是 proxy。它们会被采样策略和格式约束影响，因此不能直接等同于真实有用性。

6.4 DPO 与直接偏好优化的训练流程

把 DPO 与直接偏好优化写成训练流程时，要区分采样、打分、构造 loss 和更新参数。下面的伪代码保留这些边界。

```
chosen_logp = policy.logprob(prompt, chosen)
rejected_logp = policy.logprob(prompt, rejected)
loss = dpo_loss(chosen_logp, rejected_logp, reference_logps)
```

阅读这段训练流程时，重点区分采样、打分和参数更新。只有同时记录 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率，才能判断行为改善来自奖励信号、采样分布还是约束强度。

6.5 边界条件与常见误解

- DPO 不是万能替代 RL；它受偏好数据覆盖范围限制。
- post-training 改善 helpfulness 可能牺牲 calibration 或 diversity。
- 后训练指标可能被格式、长度或 verifier 偏差驱动，不能直接等同于真实能力提升。
- 偏好优化可能改善目标行为，也可能牺牲多样性、校准性或某些下游能力。

6.6 与本章其他概念的关系

DPO 与直接偏好优化连接本章的训练目标和输出行为：术语表区分示范、偏好与奖励，公式说明优化方向，伪代码展示采样和更新，例题检查行为约束的边界。对这一类主题，最常见的误解是只列方法名。更有用的做法是比较每个方法改变的成本项、依赖的假设和可能的失败模式。

6.7 怎样检验 DPO 与直接偏好优化

检验 DPO 与直接偏好优化时，先把抽象说法落到行为、奖励和偏好状态上。与 DPO、preference optimization、reference、beta、alignment 相关的对象必须能被构造、打印、计数或评分；否则实验只能得到描述性观察，不能得到可复现结论。一个合适的小实验应当保留本节机制，同时让 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率中至少一个量发生可解释变化。输入规模不必逼真；关键是读者能手算或打印关键中间量，并说明哪个变量触发了结果变化。随后把公式说明转成可记录的数量关系。符号说明： π_{heta} 是待训练策略， π_{ref} 是参考模型， β 控制偏离参考模型的强度。如果数量只能间接观测，就必须说明使用了什么 proxy；如果使用 benchmark 或 reward，也要说明协议和随机性。后训练消融通常一次只改变示范数据、reward scale、KL 约束、采样温度或 verifier。若训练目标和解码策略同时变化，行为差异就很难归因。最后检查失败条件。工程判断往往在反例中变清楚：DPO 不是万能替代 RL；它受偏好数据覆盖范围限制；post-training 改善 helpfulness 可能牺牲 calibration 或 diversity。复习时可以把这些限制改写成反例测试，观察它们怎样改变 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。把实验结论放回 Mid/Post-training: SFT 与 RLHF 时，要说明 DPO 与直接偏好优化改变的是目标函数、采样分布、反馈质量还是行为约束。能区分这些来源，才说明读者真正理解后训练。

6.8 概念辨析：DPO 与直接偏好优化

DPO、preference optimization、reference、beta、alignment 常一起出现在后训练讨论中，但它们分别指数据、反馈、目标函数或行为指标。读者应先判断每个词给优化过程提供什么信号。其中，DPO 把偏好优化写成直接监督式目标。区分这些词时，可以先问它们是否改变 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。一个术语如果不能对应到变量、状态、代码路径或评估协议，就还没有形成可操作含义。围绕 DPO 与直接偏好优化复习时，可以构造几条 prompt-response：明确奖励或偏好规则，观察同一模型在更新前后的行为差异。

6.9 DPO 与直接偏好优化的小结

- 讨论 DPO 与直接偏好优化时，应同时报告问题规模、实验设置和主要观测变量，尤其是 reward 分布、偏好差异、KL 约束、回答长度和 verifier 通过率。
- 如果方法声称行为更好，要说明示范、偏好、reward 或 verifier 哪一项提供了信号，并检查 reward hacking、length bias 和能力退化。
- 后训练结论需要把训练目标、采样策略和评估协议分开报告，否则无法判断改进来自哪里。

7 综合讨论：从局部机制到完整系统

本章的主题是 Mid/Post-training: SFT 与 RLHF，但它不应被读成几个相邻知识点的拼接。从 pretraining 到 assistant 行为、Reward modeling 与 RLHF、DPO 与直接偏好优化共同回答同一个问题：语言模型系统中哪些对象可以被定义，哪些成本可以被估算，哪些结论必须通过实验或评估来确认。这些对象包括 post-training (后训练)、supervised fine-tuning (SFT)、RLHF、reward model (奖励模型)、DPO、PPO。读者可以把它们看成一组接口：有的接口连接文本和 token，有的连接模型结构和张量计算，有的连接数据样本和训练目标，有的连接离线评估和在线服务。接口一旦改变，后面的成本、错误类型和优化空间也会随之改变。

7.1 从 pretraining 到 assistant 行为在系统中的位置

从 pretraining 到 assistant 行为首先提供一个局部解释：视频开场说 post-training 比 pretraining 更 messy、更 artisanal；它把基础 LM 转成可交互助手。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，从 pretraining 到 assistant 行为会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，从 pretraining 到 assistant 行为不能脱离边界条件理解。一个关键 caveat 是：SFT 数据质量比数量更重要，坏示范会被直接模仿。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.2 Reward modeling 与 RLHF 在系统中的位置

Reward modeling 与 RLHF 首先提供一个局部解释：RLHF 用人类偏好训练 reward model，再用 RL 优化策略模型。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，Reward modeling 与 RLHF 会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，Reward modeling 与 RLHF 不能脱离边界条件理解。一个关键 caveat 是：reward model 会被策略优化 exploited。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.3 DPO 与直接偏好优化在系统中的位置

DPO 与直接偏好优化首先提供一个局部解释：DPO 类方法把偏好优化写成监督式目标，避免显式训练 RL loop。这类解释的价值在于把直觉压缩成可操作对象。一旦对象明确，读者就可以追问它的输入、输出、中间状态和失败条件，而不是只记住方法名。其次，DPO 与直接偏好优化会改变至少一个资源或评估变量。它可能改变 sequence length、activation size、memory bandwidth、communication volume、data mixture、reward distribution 或 benchmark protocol。这些变量在小例子里可以手算，在真实训练和服务系统里则需要 profiling、logging 和 held-out evaluation。最后，DPO 与直接偏好优化不能脱离边界条件理解。一个关键 caveat 是：DPO 不是万能替代 RL；它受偏好数据覆盖范围限制。。把 caveat 写出来不是为了削弱结论，而是为了说明结论在哪些输入、硬件、数据和评估条件下才成立。

7.4 把本章知识用于读论文和复现实验

读相关论文时，可以把本章变成一个检查表。第一，论文是否清楚定义了输入规模、模型规模、数据来源和评估协议；第二，论文声称的改进落在哪个变量上；第三，作者是否报告了会让结论失效的设置；第四，实验是否能分离模型结构、数据质量、优化设置和系统实现的影响。复现实验时，也应避免直接追求大规模。先用小程序复现一个公式、一个伪代码分支或一个 profile 现象，再扩大输入规模。这样做的原因很简单：如果小规模程序无法解释中间量，大规模训练只会把错误隐藏在日志和随机波动里。把这些检查合在一起，本章给出的不是一个固定答案，而是一种阅读 CS336 的方法：每个模型机制都要落到变量，每个变量都要落到测量，每个测量都要说明协议，每个协议都要承认边界。因此，本章中的任何一句结论都可以被改写成一个可引用的完整句式：在给定数据、模型、硬件和评估协议下，某个机制改变了某个变量，并通过某个观测指标表现出来。这样的句子比单独背诵术语更长，但它包含了自学、复现和引用时真正需要的信息。把本章用于自学时，可以按三遍阅读。第一遍只追踪对象和定义，确认每个术语到底指向文本、token、张量、样本、请求还是评估记录。第二遍追踪公式和伪代码，确认每一步改变了哪些状态。第三遍追踪实验和 caveat，确认哪些结论只

在特定规模、数据或硬件条件下成立。把本章用于复习时，则应反过来操作：先从一个失败案例或异常指标出发，再回到相应机制。loss 曲线异常可能指向数据、优化或模型容量；吞吐异常可能指向 kernel、通信或调度；benchmark 异常可能指向 contamination、prompt protocol 或采样设置。能够从异常反推机制，是掌握本章的实用标准。

8 例题：把概念变成可计算检查

8.1 DPO 目标如何偏向 chosen response

同一 prompt 有 chosen 和 rejected 两个回答，以及 reference model 的 log probability。

- DPO 比较 policy 相对 reference 对 chosen/rejected 的偏好差。
- 如果 chosen 的相对 log probability 提高，loss 下降。
- 参数 ‘ β ’ 控制偏离 reference 的力度。

结论。 偏好优化仍然依赖数据覆盖和 reference policy，不能把目标函数当成自动 alignment。这个例题的目的不是替代完整工程实现，而是给出一种最小推理形式：把问题转成变量，写出近似公式或伪代码，再说明近似何时失效。

9 实验设计：从小例子到可复现结论

学习 Mid/Post-training: SFT 与 RLHF 不能停在概念层。一个教材化结论至少需要四件事：可构造的输入、可观测的中间量、可比较的指标，以及清楚的失败条件。下面的实验设计不是要求训练大模型，而是要求读者用小规模程序复现本章机制。

9.1 最小输入

先构造只触发本章核心机制的小输入。例如 tokenizer 章节可以用几个包含 rare words 和 Unicode 字符的字符串；GPU 章节可以用一个 elementwise kernel 和一个 GEMM；data 章节可以用十几篇近重复文档。小输入的价值在于它让错误可见。

9.2 资源账本

对同一输入写下 FLOPs、bytes moved、显存峰值、通信量或样本数量的估算。估算不需要一开始就精确，但必须说明单位和近似假设。随后用 profiler、benchmark、validation loss 或人工检查去验证估算是否同量级。

9.3 单变量消融

一次只改变一个因素，例如 vocabulary size、head 数、batch size、filter threshold、reward scale、decoding temperature 或 GPU 数量。若多个变量同时变化，实验只能说明系统变了，不能说明机制是什么。

9.4 失败条件

最后要刻意触发失败：极端 context length、错误 dtype、过小 batch、污染 benchmark、低质量数据或不可靠 verifier。失败条件常常比成功曲线更能说明一个方法的边界。

9.5 记录与报告

实验记录应能让另一个读者复现同一结论。最少要写清楚输入构造、代码版本、随机种子、硬件、batch shape、数据版本、评价指标和异常处理方式。报告结论时不要只写“更快”或“更好”，而要说明快在哪里、好在哪个指标上，以及是否牺牲了内存、稳定性、数据质量或可解释性。常见报告错误是把局部现象写成普遍规律。例如一次小模型实验里的 loss 改善，不等于更大模型或不同数据分布上也会改善；一次 kernel benchmark 的吞吐提升，不等于端到端 serving latency 一定降低。教材中的实验报告应始终把结论限定在可复现条件内。

9.6 从小实验到大结论

小实验的作用不是替代课程中的完整训练或系统实现，而是建立一条可检查的推理链。先在小输入上确认变量方向，再在中等规模上确认数量级，最后才讨论是否能外推到更大模型、更多 token 或更复杂 workload。缺少中间层级时，大结论通常只是在复述直觉。因此，实验报告最好同时包含正例和反例：正例说明机制在受控条件下怎样工作，反例说明条件稍变时哪里失效。对 CS336 这样的课程，反例尤其重要，因为 language model 的错误常来自多个层面叠加：数据分布、优化稳定性、硬件瓶颈、评估协议和服务负载都可能同时改变观察结果。还要记录资料版本与复现边界。公开视频、课程页、配套代码和 PDF 可能在不同时间更新；复现实验应写明使用的材料版本，并说明哪些结论来自课程事实，哪些是为了帮助理解而加入的解释性推导。这样才能把学习笔记变成可检查的技术记录。若复现实验与课程结论不一致，首先检查输入、版本和评估协议，而不是立即修改模型假设。

9.7 把本章重新读成一条证据链

完成小实验之后，可以把 Mid/Post-training: SFT 与 RLHF 重新读成一条证据链：先用“从 pretraining 到 assistant 行为”确定问题入口，再用“Reward modeling 与 RLHF”解释主要机制，最后用“DPO 与直接偏好优化”检查边界或外推条件。这种读法比按页背诵更接近教材训练，因为它要求每个结论都能说明前提、变量和证据。本章反复使用的术语包括 post-training（后训练）、supervised fine-tuning (SFT)、RLHF、reward model（奖励模型）、DPO、PPO。复习时不要只写定义，而要为每个术语补上一句操作性说明：它在课程代码、公式、数据记录或评估协议中对应什么对象；如果这个对象被删除、替换或缩放，哪一个观测量会变化。最后，用一个反例结束复习。反例可以是资源估算不准、数据污染、reward 失真、benchmark 解析失败、长上下文内存爆炸或 scaling 外推失效。能解释反例的章节，才真正具备自学和引用价值；不能解释反例的章节，只是把课程材料换了一种排版。引用本章结论时，还应保留来源边界：哪些说法直接来自视频、课程页、slides 或代码，哪些是为了串联教材叙述而加入的解释性推导。这个边界不会削弱结论，反而让读者知道何处可以复核，何处需要在自己的实验中重新验证。如果后续课程材料更新，也可以沿着同一证据链替换来源，而不必重写整章结构。

10 课程资料与回看路径

教材正文已经把主要概念、公式和实现逻辑组织成连续叙述；本节只提供回到课程材料的阅读路径。读者复习时可以先完成前文练习，再按下面的时间段或资料组核对细节。

10.1 视频回看路径

时间	关键词	复习任务
----	-----	------

00:00:05-00:07:01	going, very, data, think, data., it's, pre-training	回看定义、例子、推导或 caveat 在该段中的位置。
00:20:45-00:27:19	think, knowledge, don't, it's, very, might, your	回看定义、例子、推导或 caveat 在该段中的位置。
00:40:35-00:46:32	good, going, that's, talk, pre-training, your, very	回看定义、例子、推导或 caveat 在该段中的位置。
00:53:43-01:00:14	that's, annotators, think, there's, it's, people, quite	回看定义、例子、推导或 caveat 在该段中的位置。
01:13:09-01:19:48	very, think, rlhf, take, going, good, step	回看定义、例子、推导或 caveat 在该段中的位置。

这些时间段用于定位视频中的讲解顺序。严肃引用时，应回到视频片段确认讲者表述、板书或幻灯片内容。回看视频时，不必逐字抄录字幕。更有效的方法是把每个时间段判定为定义、例子、推导、代码解释或 caveat，再把它放回本章对应小节。

10.2 课程资料阅读路径

资料组	标题/页块	关键词
official_01	Lecture 15 “A F T E R P R E T R A I N I N G ” (M I D / P O S T T R A I N I N G) ...	data, information, annotation, source, part, cs336, class
official_03	Style variations in data and models Models vary a lot in response length.. [Wang+ ...	knowledge, monopsony, market, style, relevant, teaching, extraction
official_05	RLHF Data What types of pairwise feedback. How do we get (good) pairwise feedback?	rlhf, data, pairwise, feedback, standard, types, good
official_06	Modern worker distribution Caveat: many platforms, covers only one (Outlier, ScaleAI)	rlhf, data, distribution, annotators, feedback, crowdsourcing, pairwise
official_08	DPO in LLaMA (and other open models) DPO + Expert iteration for post-training	rlhf, variants, many, watch, pref, lots, overoptimization

课程资料通常给出更稳定的标题、公式、图或代码结构；视频则补充动机和口头解释。两者合起来构成本章的事实边界。阅读资料时，可以把每个资料组拆成三个对象：一个定义，一个公式或伪代码动作，一个边界条件。这样比逐字翻译页面或脚本更容易形成可用知识。

11 实践说明、历史位置与风险

Mid/Post-training: SFT 与 RLHF 在 CS336 的课程结构中连接基础机制和规模化问题。基础机制解释方法为什么成立；规模化问题检验它在更大模型、更长上下文、更复杂数据或真实 serving workload 下是否仍成立。历史位置不等于模型年表。更重要的是识别问题如何迁移：早期方法解决小规模建模问题，现代方法常常解决同一问题在大规模数据、GPU 集群、长上下文或人类偏好约束下的新形态。

- 资料版本限制 (version risk): 课程页、公开视频和配套资料可能在学期中更新；引用时应注明访问日期或资料版本。

- 测量口径限制 (measurement risk): FLOPs、tokens/s、benchmark score、reward 等数字只有在协议完整时可比较。
- 规模外推限制 (scaling risk): 小模型或小 batch 的机制不必然外推到 frontier-scale。
- 数据分布限制 (data risk): 数据来源、过滤和去重策略会改变模型行为, 也会改变 evaluation contamination 风险。
- 对齐风险 (alignment risk): post-training 或 multimodal tuning 的行为变化可能提高 helpfulness, 同时降低校准、透明度或安全边界。

12 复习要点

下面的问题把本章内容压缩为可反复检查的条目。每个条目都应能回到前文的解释、公式、伪代码或例题。

条目	对象	检查动作
条目 1	post-training (后训练)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 2	supervised fine-tuning (SFT)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 3	RLHF	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 4	reward model (奖励模型)	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 5	DPO	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。
条目 6	PPO	定义它; 写出一个最小例子; 说明一个 failure mode; 指出它影响哪个资源或评估账本。

12.1 综合自测

- 我能否不用课程原句, 独立解释本章中心问题?
- 我能否把本章至少一个公式改写成可运行的估算函数?
- 我能否指出一个看似改进但实际转移成本的方法?
- 我能否回到视频和课程资料, 找到支持本章关键论断的位置?
- 我能否设计一个最小 ablation, 验证本章一个 caveat?

13 总结与延伸

13.1 本章小结

- Mid/Post-training: SFT 与 RLHF 的核心不是记忆术语，而是理解对象、变量和机制之间的关系。
- 视频给出讲解顺序，课程资料提供可核对的公式、图、代码或页面结构。
- 复习时应把每个术语连接到至少一个变量、一个实现动作和一个失败模式。

13.2 延伸解释

本章中的延伸解释用于连接课程材料中的概念，例如说明公式里的 proxy、解释系统 tradeoff，或把多个材料片段串成一个完整推理链。若需要严肃引用，应回到课程视频和配套资料核对原始表述。

13.3 练习

- 定义题：用中英双语解释本章任意五个重要术语，并说明它们属于 compute、memory、data、optimization、evaluation 还是 deployment 账本。
- 推导题：选择本章一个公式，逐个解释符号、单位和近似假设，并说明哪个变量最难在真实系统中测量。
- 实现题：把本章伪代码改写成一个最小 Python sanity check，不要求训练大模型，但要输出可检查的中间量。
- 资料题：从“课程资料与回看路径”中选择一个视频时间段，回到原始视频核对讲者例子，并记录是否存在字幕误差。
- 评估题：为本章方法设计一个 ablation 或 benchmark，说明控制变量、数据版本、指标和 failure criteria。
- 边界题：说明本章一个结论在更长 context、更大 batch、更多 GPU 或更复杂数据分布下可能如何失效。
- 综合题：把本章内容和前一章或后一章连接起来，写出一个端到端训练/推理 pipeline 中的依赖关系。
- 批判题：指出一个容易被营销材料夸大的说法，并用本章的资源账本或评估协议反驳它。