课程笔记

CS336 第 16 讲：对齐：RL I

Codex 基于 Stanford CS336 2025 第 16 讲视频、字幕与课程材料整理

2026 年 4 月 9 日

视频作者/频道：Stanford Online
发布日期：2025 年 07 月 01 日
视频时长：1:20:32
视频链接：`https://www.youtube.com/watch?v=46f2QTDB08Q`

目录

1 从 RLHF 的麻烦出发：为什么还需要 RLVR **2**

1.1 第 16 讲先做了一次很诚实的回顾 2

1.2 本章小结 2

2 DPO 的吸引力与它没法解决的问题 **2**

2.1 为什么 DPO 看起来像“RLHF without tears” 2

2.2 为什么课程仍然对 DPO 保持谨慎 3

2.3 本章小结 3

3 RLHF 的副作用：过优化与模式坍缩为什么会反复出现 **3**

3.1 为什么 RLHF 难以无限 scale out 3

3.2 模式坍缩说明模型不再像概率模型那样工作 3

3.3 本章小结 4

4 为什么这讲会把课程从 GPT-3.5 直接推进到 o1 / r1 **4**

4.1 课程主线在这里发生了明显转向 4

4.2 RLVR 的目标不是再做一遍 RLHF，而是扩大 RL 的适用域 5

4.3 本章小结 5

5 从 policy gradient 到 PPO：为什么在线 RL 还是会回来 **6**

5.1 课程先把最基本的 policy gradient 写出来 6

5.2 为什么课程还要给学生看 PPO 实现 6

5.3 PPO 在语言模型里到底比普通 RL 多了哪些部件 6

5.4 reward shaping 与 GAE 是 PPO 真正难训的地方 7

5.5 本章小结 8

6 GRPO：把语言模型的“同 prompt 多回答”结构直接用起来 **8**

6.1 GRPO 的核心思想不是更复杂，而是更简单 8

6.2 为什么课程马上开始挑 GRPO 的刺 8

6.3 为什么课程说“stdev normalization 不是有效 baseline” 9

6.4 length bias 为什么会变成 reasoning RL 里的真实问题 9

6.5 本章小结 9

7 为什么 RLVR 会把课程终点推到 o1 / R1 时代 **9**

7.1 可验证奖励让 RL 的目标第一次变得“硬”起来 9

7.2 R1、Kimi 和 Qwen 说明了什么 9

7.3 DeepSeek R1：为什么它成了这一波 RLVR 的中心案例 10

7.4 Kimi K1.5：另一条同时期路线说明 objective 还在快速演化 10

7.5 Qwen 3：低数据 RLVR 说明筛选质量可以替代纯数据量 10

7.6 本章小结 11

8 总结与延伸 **11**

1 从 RLHF 的麻烦出发：为什么还需要 RLVR

1.1 第 16 讲先做了一次很诚实的回顾

第 16 讲并没有直接宣告“旧方法不行了”，而是先承认 DPO 和 PPO 各自的价值。DPO 之所以流行，是因为它把一大块 RLHF 工程复杂度拿掉了：不再显式训练 reward model，也尽量避开 on-policy rollout 和 value function。PPO 则仍然是更传统、表达力更强的强化学习套路，在某些设置下依旧有效。

但课程真正想指出的是：如果你的反馈不是天然的 pairwise preference，或者你希望把可验证的正确性直接拿来做在线优化，那么单靠 DPO 这类离线偏好优化就会开始显得不够。此时，PPO 一类在线 RL 方法又会重新变得重要。

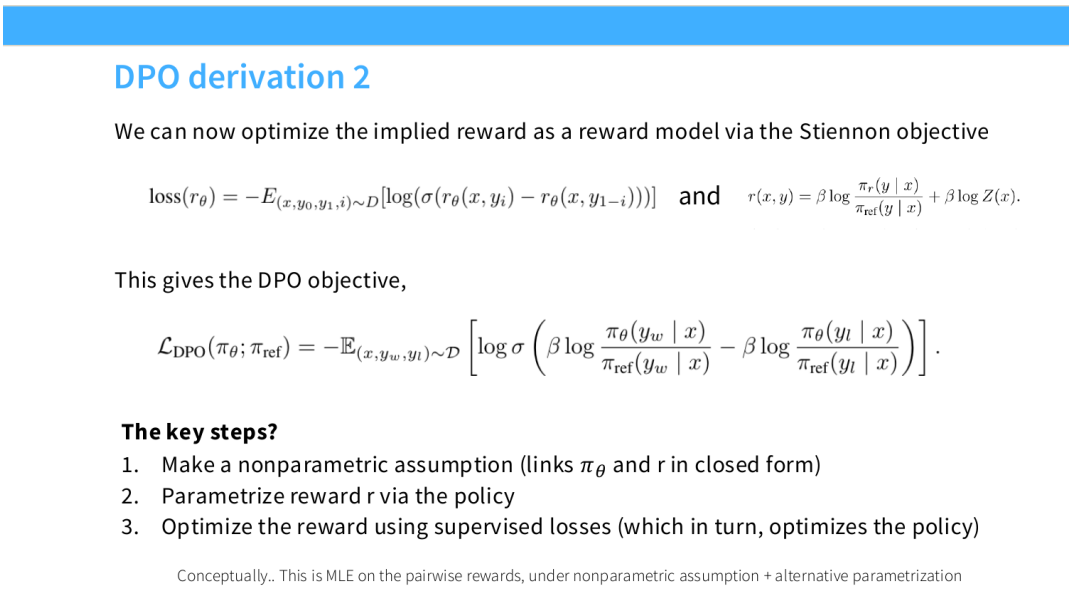

图 1: 课程用 DPO 的推导结果提醒学生：它的工程吸引力来自把 RLHF 重写成更像监督学习的目标。

第 16 讲的起点

这一讲不是在“推翻 DPO”，而是在问：当目标从偏好匹配走向可验证推理时，我们是否需要更直接、更在线的优化方式。

1.2 本章小结

第 16 讲先承认了 DPO 的现实价值，但也把它的边界暴露出来：不是所有反馈都天然长成偏好对，也不是所有目标都适合用离线 pairwise 数据来学。

2 DPO 的吸引力与它没法解决的问题

2.1 为什么 DPO 看起来像“RLHF without tears”

课程把 DPO 概括得非常清楚：在一个非参数假设下，策略 π_θ 和 reward 可以建立闭式联系，于是你可以把偏好优化重写成对策略对数比值的监督学习目标。这样一来，原本 RLHF 里最让人头

疼的 reward model、rollout 外循环和 critic 都能暂时退场。

从直觉上看，DPO 的更新像是在做“对好回答加正梯度、对坏回答加负梯度”，只是这个正负更新会被一个从偏好概率导出的误差项重新加权。课程在这里反复强调，它的魅力首先是工程上的，而不是哲学上的。

2.2 为什么课程仍然对 DPO 保持谨慎

课程同时非常明确地指出，DPO 的效果高度依赖实验设置。它在很多开源 RLHF 模型里确实好用，但 PPO 有时也能同样甚至更好地工作。更重要的是，一旦数据不是 Bradley-Terry 风格的成对比较，或者你想做真正在线的行为改进，DPO 的自然性就会下降。

课程对 DPO 的态度

DPO 很好，但它更像是“把一类偏好优化问题做得更可训练”，而不是解决所有对齐问题的总开关。

2.3 本章小结

DPO 的意义在于大幅降低偏好优化的门槛；它的边界在于，它仍然假设反馈能以特定的成对形式表达，而且主要是离线优化。

3 RLHF 的副作用：过优化与模式坍缩为什么会反复出现

3.1 为什么 RLHF 难以无限 scale out

课程在这一段的语气明显变得更谨慎。只要你在有限偏好信号上持续做优化，就很容易把模型推到 reward 过拟合区间。也就是说，reward 确实会上升，但真实目标不一定同步提升，甚至可能开始变差。这正是 overoptimization 的经典结构。

课程给出的洞察很重要：偏好奖励并不是“真理”，它只是某个噪声很大、覆盖有限的近似目标。所以在这个目标上过度优化，几乎必然会出现过拟合。对于 RLHF 来说，这不是实现 bug，而是问题设定内生的风险。

3.2 模式坍缩说明模型不再像概率模型那样工作

课程用 calibration 和 entropy 分布的变化说明 mode collapse 的含义。经过 RLHF 之后，模型往往不再像一个良好校准的概率模型，而更像一个被特定偏好信号强行拉扯过的决策器。它可能更“会赢 reward”，却更不多样、也更不可信。

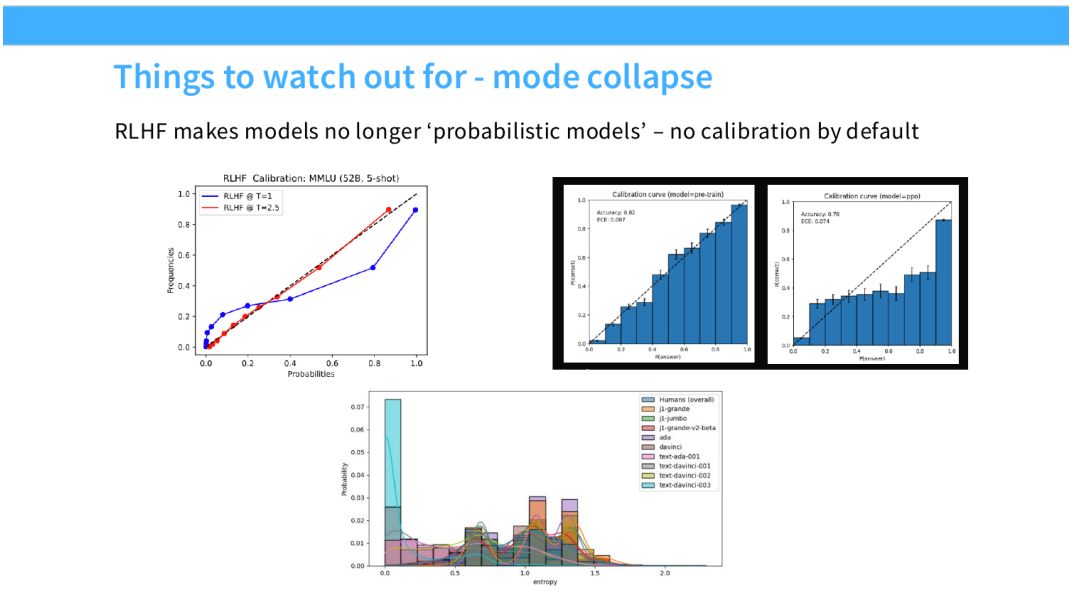

图 2: 课程把模式坍缩和校准恶化并列展示，提醒学生 RLHF 会改变模型的概率结构。

为什么这件事对 reasoning 很关键

如果你想让模型在数学、代码或长链推理上持续探索，模式坍缩会直接伤害这种探索能力。模型越早收缩到几种“看起来最容易赢”的响应模式，就越难继续从奖励中学出更强推理。

3.3 本章小结

第 16 讲在这里做了一个非常关键的转向：与其在一个有噪声的偏好信号上无休止优化，不如寻找那些更可验证、更难被奖励黑客化的目标。

4 为什么这讲会把课程从 GPT-3.5 直接推进到 o1 / r1

4.1 课程主线在这里发生了明显转向

官方材料在这里给了一页很直白的过渡：‘pre-training + RLHF‘ 大致把行业推到了 GPT-3.5 / ChatGPT 这一代，而这讲想讨论的，是为什么后续的 reasoning 模型会明显更依赖 RL 和 test-time compute，而不是只靠更大的预训练。

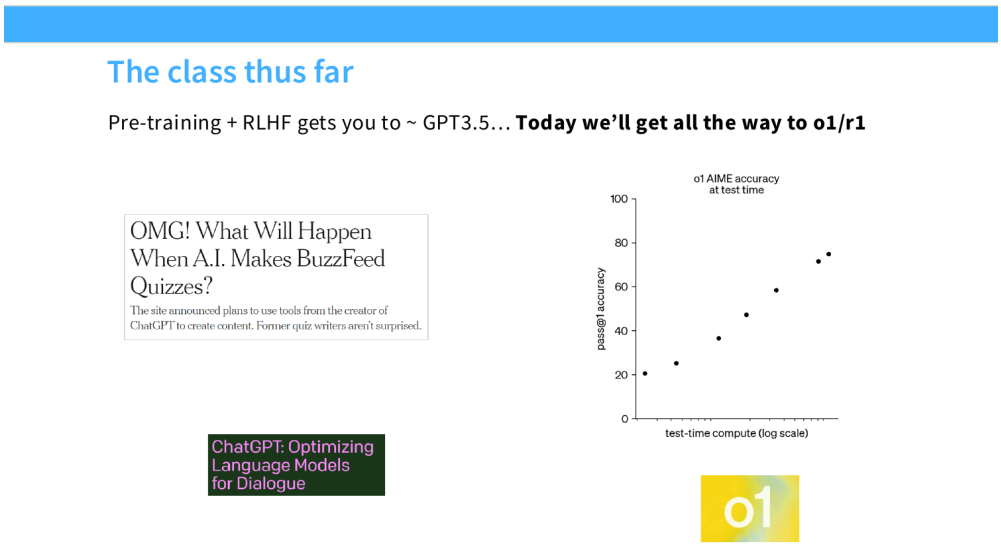

图 3: 课程明确把这一讲定位成“从 GPT-3.5 时代推进到 o1 / r1 时代”的转折点。

4.2 RLVR 的目标不是再做一遍 RLHF，而是扩大 RL 的适用域

课程紧接着又补了一页非常关键的动机图：问题不在于 RLHF 没有价值，而在于它在偏好信号上难以 cleanly scale out。一旦过优化开始变成主导风险，继续在 noisy preference reward 上堆更多 rollout，收益就会越来越差。

于是，第 16 讲真正想问的是：能不能转向那些 RL 本来就最擅长的场景，也就是奖励更接近“exactly what we want”的场景？课程用 AlphaGo、蛋白质设计和形式化数学的图示来提示学生，这类场景往往有更硬的目标函数，因此更适合被持续优化。

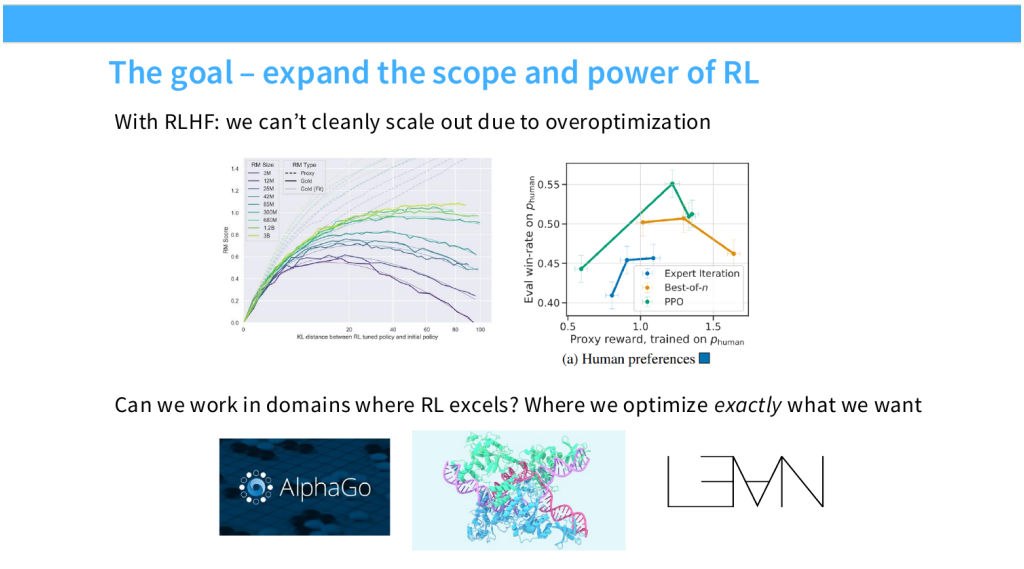

图 4: 课程把 RLVR 的动机说得很直接：在可验证领域里，RL 才更像是在优化真正想要的目标。

4.3 本章小结

这讲之所以重要，不是因为它又介绍了一个新缩写，而是因为它明确重设了增长路径：当偏好优化开始遇到硬上限，更可验证的奖励就成了新的扩展方向。

5 从 policy gradient 到 PPO：为什么在线 RL 还是会回来

5.1 课程先把最基本的 policy gradient 写出来

PPO 再复杂，底层仍然是 policy gradient。课程先回顾最基本的式子：

$$\nabla_\theta \mathbb{E}[R] = \mathbb{E}\left[\nabla_\theta \log \pi_\theta(a \mid s)\, R(s,a)\right].$$

其中 s 是状态，a 是动作，π_θ 是当前策略，$R(s,a)$ 是最终奖励。语言模型场景里，状态可以理解为 prompt 加已生成前缀，动作则可以是逐 token 的生成选择。

这个公式足够简单，但直接拿来做语言模型 RL 会有极高方差。于是才会有 TRPO 的信赖域思路，再到 PPO 用 clip 目标在稳定性和可优化性之间做折中。

5.2 为什么课程还要给学生看 PPO 实现

课程非常坦率地说，只看博客文章谈 PPO 容易产生错觉，真正难的是实现。rollout 怎么收集，KL 惩罚怎么加，advantage 怎么算，value model 怎么训练，外循环和内循环怎么配合，这些才是 PPO 在语言模型里真正昂贵的地方。

5.3 PPO 在语言模型里到底比普通 RL 多了哪些部件

官方 PDF 在 PPO 部分其实给了三层结构，而不只是一个 clipped objective。第一层是策略网络本身，也就是要被更新的语言模型；第二层是 reward model 和 value model，它们分别给出标量反馈和 advantage 所需的 baseline；第三层是经验缓存与 reference model，用于做 ratio、KL 和多步 inner loop 更新。

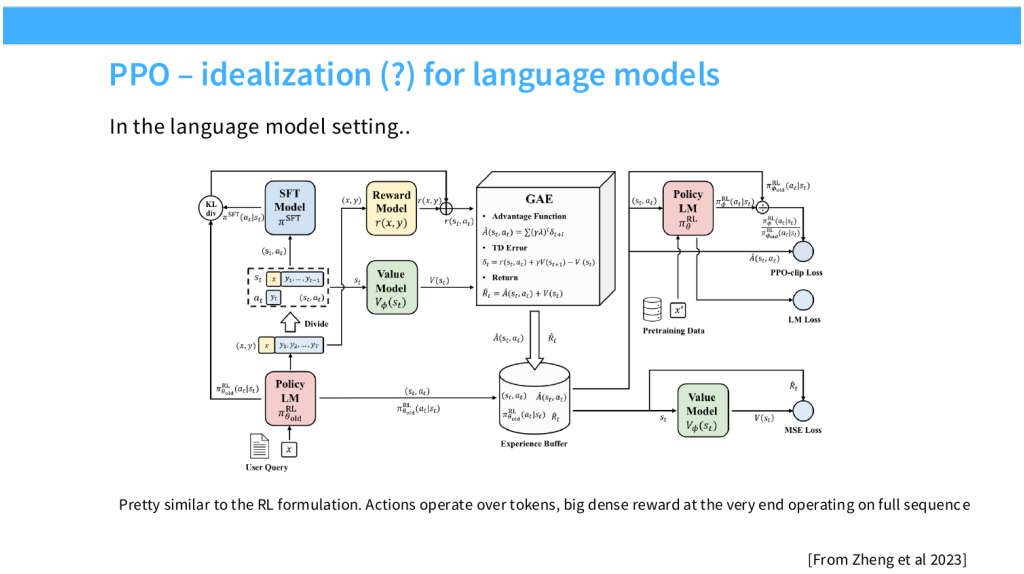

图 5: 语言模型里的 PPO 不是只多一个 loss，而是 reward model、value model、reference policy、experience buffer 一起进入系统。

课程在这一页想告诉学生的是：哪怕把环境简化成“整段回答末尾给一个 dense reward”，PPO 仍然会自然长出一大套附属对象。也正因此，它在大模型里的真正代价不只是数学复杂，而是显存、推理和训练调度全都一起变重。

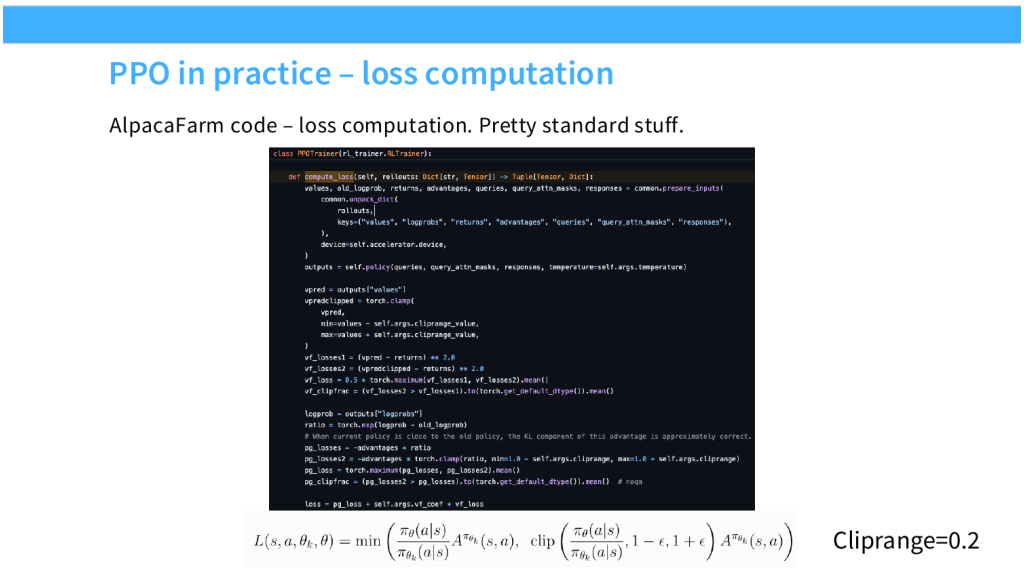

图 6: 课程直接拿 AlpacaFarm 的 PPO 实现讲 loss 计算，强调 PPO 的复杂度主要来自工程细节。

这部分内容非常重要，因为它解释了为什么开源社区在看到 DPO 后会那么兴奋。不是大家突然不喜欢 RL 了，而是 PPO 的完整系统成本确实太高。

5.4 reward shaping 与 GAE 是 PPO 真正难训的地方

官方文本在 ‘PPO in practice‘ 里还点了两个经常被忽略但非常关键的实现点。

第一是 reward shaping：语言模型 RL 往往不是只在最后一个 token 上打一笔总奖，而是会沿 token 维度加上 KL 惩罚，让新策略不要离 reference 太远。官方描述得很具体：高层上是 “每个 token 加 KL，末尾再加总 reward”；实践里则还会对 KL 做额外裁剪，避免 policy 突然跑飞。

第二是 generalized advantage estimate。课程特别提醒，在语言模型 RL 的很多设置里，这其实很接近一个 bandit 问题，因此会看到 $\gamma = \lambda = 1$ 这种和经典连续控制场景不太一样的设定。它的意思不是 “GAE 不重要”，而是说 reward-to-go 与 value decomposition 在这里比在机器人任务里更简单，但仍然需要一个能稳定训练的 advantage 管线。

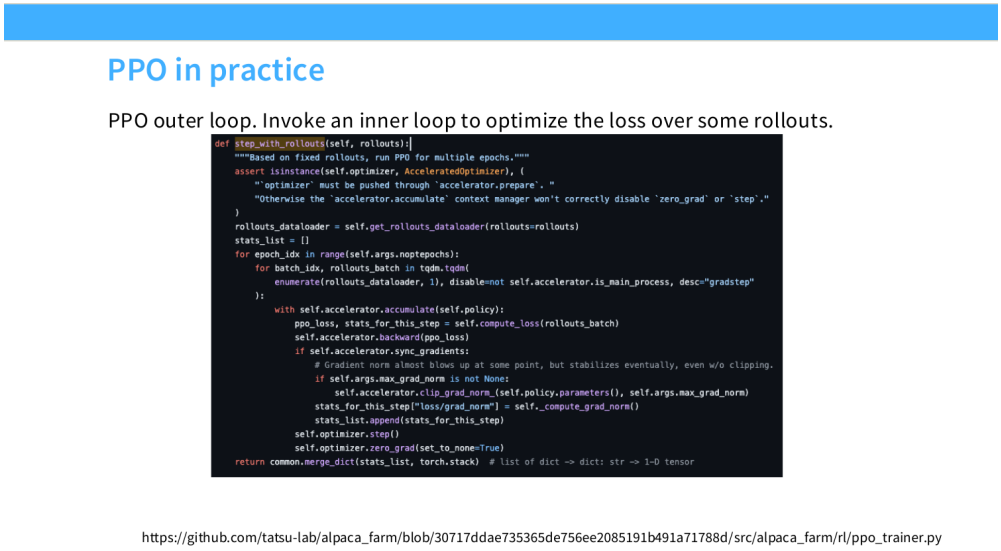

图 7: PPO outer loop 的实践图景：先收 rollout，再在固定 rollout 上做若干 inner-loop 优化。

5.5 本章小结

PPO 仍然是理解现代 RL 方法的参考系。课程通过回顾 policy gradient 和 PPO 实现，让学生看到“在线 RL 很强”与“在线 RL 很麻烦”这两件事为何会同时成立。

6 GRPO：把语言模型的“同 prompt 多回答”结构直接用起来

6.1 GRPO 的核心思想不是更复杂，而是更简单

课程把 GRPO 介绍成“从 PPO 出发，去掉 value function，再把 advantage 写成组内归一化奖励”。在语言模型场景里，这种做法特别自然，因为同一个 prompt 下本来就可以采样多条回答。于是每组回答天然形成一个小比较集合，你不一定要额外训练 critic 才知道哪些回答相对更好。

直观上，GRPO 的做法是：同一个 prompt 采样若干 rollout，计算每条回答的 reward，然后对组内 reward 做中心化和标准化，再用这个组内相对分数当作更新信号。课程借此说明：**语言模型的输出结构本身，就能提供一种廉价 baseline**。

6.2 为什么课程马上开始挑 GRPO 的刺

课程并没有把 GRPO 塑造成完美解。它明确指出，组内均值部分可以视作 baseline，但标准差归一化会引入额外偏差；同时长度归一化项还可能带来 length bias，让模型更偏向某种 CoT 长度。这说明 GRPO 的成功很大程度上来自“足够简单、足够好用”，而不是“严格无偏”。

课程对 GRPO 的真实评价

GRPO 的魅力不是它理论上最纯，而是它在去掉 value model 之后，极大降低了 reasoning RL 的实现门槛，因此让 RLVR 快速扩散到了更多团队。

6.3 为什么课程说“stdev normalization 不是有效 baseline”

官方材料这里有一个很值得认真保留的细节：减去组内均值这一步可以被解释成 baseline，但除以组内标准差这一步就不再是简单的 state-dependent baseline 了，它会改变梯度估计的缩放方式，因此不再保持严格无偏。

这也是课程会专门提到“unbiased-gradient version of GRPO”的原因。后来的一些修正思路，本质上是在往‘REINFORCE with leave-one-out baseline‘靠，尽量保留组结构带来的便宜优势估计，同时减少标准差归一化引入的额外偏差。

6.4 length bias 为什么会变成 reasoning RL 里的真实问题

官方页里还单独点出‘Length biases of GRPO‘。原因很现实：一旦你对组内 reward 做标准化，并再叠加某种长度归一化或长度惩罚，模型就会开始系统性偏向某种 CoT 长度。对 reasoning 模型来说，这不是小问题，因为它会直接影响探索深度和最终答案质量。

课程在这里的态度很务实：GRPO 的成功并不意味着 objective 已经定型，相反，它说明一个足够简单的 objective 先把门打开了，接下来大家会围绕 unbiasedness、length control 和 variance scaling 再继续修。

为什么 GRPO 不是“公式抄下来就能复现”的方法

只要 objective 里出现组内标准差、长度归一化和 KL 项，不同实现就可能隐含非常不同的偏置。reasoning RL 的效果，往往恰恰卡在这些看似只是常数项的地方。

6.5 本章小结

GRPO 把语言模型的组结构直接变成优势估计工具。它简化了 PPO，也引入了新的偏差和长度问题，这正是后续变体不断出现的原因。

7 为什么 RLVR 会把课程终点推到 o1 / R1 时代

7.1 可验证奖励让 RL 的目标第一次变得“硬”起来

第 16 讲最重要的转向，是从 RLHF 走向 RLVR。课程的意思不是说偏好奖励没用，而是说：如果你能在数学、代码、形式逻辑或某些规则明确的任务里定义“对就是对，错就是错”的可验证奖励，那么 RL 才真正回到它最擅长的领域。

这件事的重要性在于，它把奖励从含糊的人类偏好换成了更坚硬、更抗黑客化的目标。只要奖励真能准确反映正确性，模型就更有机会通过长链推理和测试时计算获得真实能力提升，而不只是更擅长讨好 judge。

7.2 R1、Kimi 和 Qwen 说明了什么

课程在 case study 里反复对比 DeepSeek R1、Kimi K1.5 和 Qwen 3。它们路径不同，但都指向同一个事实：reasoning RL 的关键不只是“用了 RL”，而是奖励足够可验证、SFT 初始化足够好、难度筛选足够严格，以及 RL 基础设施能支撑长 CoT 训练。

R1 说明了 GRPO 风格 reasoning RL 可以把系统推到极强水平；Kimi 展示了不同 policy gradient 变体和长度控制策略；Qwen 则说明即便数据量没有那么大，只要筛选和训练流程够好，RLVR 仍然能非常有效。课程因此把 “GPT-3.5 时代的 RLHF” 推进到了 “o1 / R1 时代的 reasoning RL”。

7.3 DeepSeek R1：为什么它成了这一波 RLVR 的中心案例

官方后半段对 R1 的拆解其实相当具体。第一，R1-zero 说明仅靠 reasoning RL 加上极简的可验证奖励，就已经能得到相当强的性能；第二，真正的 R1 又在此基础上加回了 SFT 初始化、语言一致性奖励，以及后续的常规 post-training。

课程尤其强调两点：一是 ‘SFT initialization‘ 对 reasoning RL 的启动阶段非常重要，即便只有少量高质量长 CoT 样本，也能大幅改善后续 RL 可训练性；二是 R1 并没有靠复杂的 process supervision 或 MCTS 才成功，这直接改变了大家对 reasoning RL 门槛的认知。

7.4 Kimi K1.5：另一条同时期路线说明 objective 还在快速演化

Kimi 的价值在于它不是简单重复 R1。官方材料说明，它同样依赖难度筛选、长 CoT SFT 和 RL，但在具体损失、长度控制和 curriculum 上给了另一套设计。特别是长度控制部分，Kimi 会在后期显式鼓励更短的正确链条，说明 reasoning RL 的一个真实工程目标，不只是 “答对”，还包括 “答对且不要太🅵嗦”。

这让课程的 message 更完整了：GRPO 打开了门，但真正的工业路线并不会只用一个原始 objective 原封不动地跑到底，而是会围绕数据难度、长度、语言一致性和 reward 设计不断叠 patch。

7.5 Qwen 3：低数据 RLVR 说明筛选质量可以替代纯数据量

Qwen 3 的 case study 则把另一个信号拉了出来：reasoning RL 不一定非要海量 RL 数据。官方摘要里明确提到，他们通过 best-of-n 筛难题、剔除无需 CoT 就能做对的样本、手工检查 CoT 质量，并最终只在大约四千级别的例子上做 GRPO。这说明当 reward 足够硬、样本筛选足够狠时，小数据 RLVR 也可能有很高杠杆。

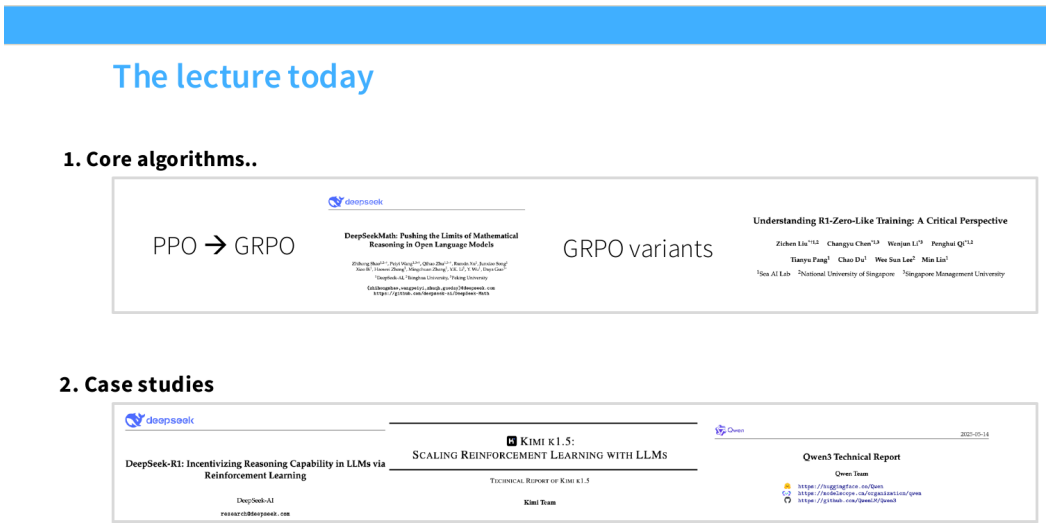

图 8: 课程在一页里并排展示了 PPO→GRPO 与 R1/Kimi/Qwen 三组 case study，意思很明确：这已经是一个正在快速演化的 recipe 家族。

RLVR 的真实含义

RLVR 不是“换了一个缩写”。它意味着强化学习第一次在一类大模型任务里拿到了足够硬、足够便宜、足够可扩展的奖励信号。

7.6 本章小结

RLVR 之所以重要，不在于它看起来更潮，而在于它让强化学习的优化目标变得更可信。这才是 reasoning 模型近两年突飞猛进的真正背景。

8 总结与延伸

第 16 讲把对齐从偏好优化推进到了更结构化的 RL 视角。

第一，**DPO 之所以流行，是因为它大幅降低了偏好优化门槛**。但它并不适合所有反馈形式。

第二，**RLHF 的核心难题不是“会不会实现”，而是目标本身太容易被过优化**。过优化和模式坍缩几乎是内生风险。

第三，**PPO 仍然是理解语言模型 RL 的参考系**。它表达力强，但系统复杂度高、value model 成本大。

第四，**GRPO 通过组内归一化大幅简化了在线 RL**。它牺牲了一些理论洁净性，换来了 reasoning RL 的可用性。

第五，**RLVR 的突破来自奖励变硬**。当奖励足够可验证时，RL 才真正有机会把模型往更强推理能力上推。

第六，**R1、Kimi、Qwen 说明 reasoning RL 已经不再只是实验室玩具**。它是一整套奖励设计、数据筛选、SFT 初始化和 RL 系统工程共同作用的结果。

我对第 16 讲的压缩提醒

如果只把这讲理解成“介绍了 PPO、DPO 和 GRPO”，那就漏掉了真正的转向。更重要的结论是：**一旦偏好奖励开始限制我们继续 scale，能够提供可验证正确性的奖励信号就会成为新的增长引擎**。

下一讲会把这里留下的核心机制继续拆开：policy gradient、baseline、advantage 和 GRPO 的具体数学细节，到底为什么能起作用，又为什么会带来长度偏置。