


课程笔记

MIT RES.9-009 第 12 讲: Parameter Fitting using Optimization

五道口纳什 & Codex

2026 年 4 月 16 日



视频作者/频道: MIT Neuroblox 官方课程页

发布日期: 官方课程页最后修改 2025-07-22

视频时长: 无嵌入视频

视频链接: MIT course page

目录

1 逆问题：参数拟合到底在解决什么	2
1.1 本章小结	2
2 模型定义：四个耦合参数和带噪观测	2
2.1 本章小结	3
3 初始猜测：让误差先暴露出来	3
3.1 本章小结	4
4 用优化求解参数：损失函数、有限差分与 LBFGS	4
4.1 本章小结	5
5 结果：参数回收与轨迹对齐	5
5.1 本章小结	6
6 从 synthetic recovery 到 real-data workflow：这一讲真正教会了什么	7
6.1 本章小结	7
7 参考文献	7
7.1 本章小结	8
7.2 拓展阅读	8
8 总结与延伸	8

证据说明

本讲没有官方嵌入视频，教学内容主要来自 MIT Neuroblox 官方课程页 [optimization](#) 及其结构化页面提取。官方 slide PDF 目前仍未找到，因此没有把缺失的 PDF 当作正文内容展开；这类缺口已经记录在 `omission_log.jsonl` 中。正文中的两张图都来自官方页面资产，而不是额外生成的示意图。

1 逆问题：参数拟合到底在解决什么

课程先从一个很明确的对比开始：我们前面的工作主要是在解 **forward problem**，也就是给定参数以后去构造并模拟一个微分方程系统；这一讲则转向 **inverse problem**，也就是从数据反推模型参数。换句话说，前者回答“这个系统会怎样演化”，后者回答“什么参数能让模型尽量复现观测数据”。

用数学语言说，参数拟合要找的是

$$\mathbf{p}^* = \arg \min_{\mathbf{p}} \mathcal{L}(\mathbf{p}; \mathcal{D}), \quad (1)$$

其中 $\mathcal{D}$ 是观测数据， $\mathbf{p}$ 是待估计的参数向量， $\mathcal{L}$ 是衡量模拟轨迹和数据差异的损失函数。

这里最重要的教学点是：课程并没有直接上真实数据，而是先建议用 *fictive data*。做法是先用一个已知参数的模型生成假数据，再尝试把这些参数“找回来”。这一步的意义不是为了省事，而是为了检验模型和数据是否足以支持参数回收。如果连假数据都拟合不回来，那真实数据上的拟合就更没有把握。

为什么要先用假数据

假数据拟合本质上是在做可辨识性检查。它能告诉我们当前模型、观测变量和时间采样方式是否足以把参数区分出来，而不只是“让优化器跑完”。

课程还补了一句：如果换成真实数据，工作流几乎不变，只是把“先生成数据”改成“从文件读取数据”，例如用 `CSV.jl` 和 `DataFrames.jl`。

1.1 本章小结

这一段建立了全讲的主线：参数拟合不是单纯求一个最优数值，而是在检验模型是否有能力从数据中恢复机制参数。假数据只是方法论上的第一道门槛。

2 模型定义：四个耦合参数和带噪观测

这一讲使用的是一个 **next generation neural mass model**，也就是前面已经见过的兴奋-抑制平衡模型。课程把四个耦合系数当作未知参数来拟合：

$$k_{ee}, \quad k_{ii}, \quad k_{ei}, \quad k_{ie}.$$

它们分别对应兴奋-兴奋、抑制-抑制、兴奋-抑制和抑制-兴奋四种耦合方向。课程用的 ground truth 是

$$\mathbf{p}_{\text{gt}} = [2, 1.5, 5.5, 7].$$

为了让例子更接近真实问题，课程在假数据上加入了观测噪声。代码里用的是均值为 0、标准差为 0.1 的高斯噪声，也就是

$$\varepsilon_{t,s} \sim \mathcal{N}(0, 0.1^2), \quad x_{t,s}^{\text{data}} = x_{t,s}^{\text{sim}} + \varepsilon_{t,s}. \quad (2)$$

这里：

- t 表示时间点。
- s 表示状态变量。
- $x_{t,s}^{\text{sim}}$ 是无噪声模拟轨迹。
- $x_{t,s}^{\text{data}}$ 是加噪后的观测数据。

代码结构也很清楚。课程先用 `Random.seed!(1)` 固定随机种子，确保例子可复现；然后定义时间区间 `tspan = (0, 100)`，并把保存点设成整数时间步 `0:100`。接着构造 `ODEProblem`，用 `Tsit5()` 先把 `ground truth` 参数对应的轨迹解出来，再把噪声加到结果上，形成后续拟合的目标。

这一段真正做了什么

模型定义的目标不是“把模型写出来”这么简单，而是先制造一个可控的逆问题环境：参数已知、轨迹可生成、噪声可注入，这样后面才有资格谈拟合是否成功。

2.1 本章小结

这一段把拟合问题具体化成一个可执行的实验：四个耦合参数、一个确定的时间窗、一个带噪观测数据集。后续所有优化步骤都只是在这个环境里更新参数而已。

3 初始猜测：让误差先暴露出来

课程接下来强调了一件很实在的事：大多数优化方法都需要一个 **initial guess**。这里给出的初值是

$$\mathbf{p}_0 = [0.2, 3.3, 2, 3.5].$$

这个起点和 `ground truth` 相比差得并不小，这正是教学上想要的效果，因为它能把“未优化时的偏差”直接展示出来。

课程用了一个 `setp setter`，把系统里的四个待拟合参数绑定起来，这样优化过程中每换一个参数向量，就能立刻更新 `ODEProblem`。随后重新求解模型，并把数据轨迹和初始猜测下的模拟轨迹画在同一张图里。




图 1: 初始猜测参数下的状态轨迹与观测数据对比, 显示未优化时偏差明显。图源: MIT Neuroblox 官方课程页 [optimization](#)。

这张图的作用不是“好看”，而是提醒我们：如果初始猜测离正确区域太远，优化器很可能要花更久时间，甚至落到不理想的局部区域。对这类 inverse problem 来说，起点本身就是实验设计的一部分。

为什么初始猜测重要

优化器不是读心术。它只能沿着损失函数的地形往下走，因此起点决定了搜索从哪里开始，也决定了我们看到的是哪一块参数空间。

3.1 本章小结

初始猜测这一步的价值，在于把“模型和数据目前差多远”直接显影出来。它既是优化的起点，也是判断问题难度的第一张诊断图。

4 用优化求解参数：损失函数、有限差分与 LBFGS

课程的核心是把参数拟合写成一个标准优化问题。最小化的目标是 least squares loss，也就是让模拟轨迹尽量贴近噪声观测：

$$\mathcal{L}(\mathbf{p}) = \sum_{t,s} (x_{t,s}^{\text{sim}}(\mathbf{p}) - x_{t,s}^{\text{data}})^2. \quad (3)$$

这里：

- $\mathbf{p}$ 是当前候选参数。
- $x_{t,s}^{\text{sim}}(\mathbf{p})$ 表示用参数 $\mathbf{p}$ 重新求解模型得到的轨迹。
- $x_{t,s}^{\text{data}}$ 是加噪后的目标数据。
- 求和覆盖所有时间点和所有状态。

这也是代码中 `sum(abs2, sol .- data)` 的含义：把每个时刻、每个状态的残差平方累加起来。损失函数前面那层 `loss(p, data, prob)` 的作用，则是把候选参数写回 `ODEProblem`，再调用 `solve(prob, Tsit5())` 生成当前轨迹。

优化管线的四个关键动作

- `setter!(prob, p)`：把候选参数写回模型。
- `solve(prob, Tsit5())`：得到当前参数下的模拟轨迹。
- `OptimizationFunction(..., AutoFiniteDiff())`：用自动有限差分近似梯度。
- `solve(prob_opt, Optimization.LBFGS())`：用 LBFGS 搜索更优参数。

这里的 `AutoFiniteDiff()` 很关键。它说明课程没有手工推导梯度，而是用数值有限差分来近似目标函数的梯度。对这个例子来说，这很合理，因为每次目标函数评估都要重新求解一个 ODE 系统，手工推导梯度既繁琐也不必要。

LBFGS 的全称是 limited-memory BFGS。课程把它称为 quasi-Newton method，是因为它不直接计算 Hessian，而是利用梯度历史去近似 Hessian 的逆。直观上讲，它比纯梯度下降更会“看地形”，但又比完整牛顿法更省内存，适合这种中等维度、光滑的参数拟合问题。

代码里还有一个小但重要的检查：

```
res.retcode = SciMLBase.ReturnCode.Success.
```

这只是说明优化过程正常结束，不代表参数一定是全球最优；它的意义是先确认数值求解没有报错。

4.1 本章小结

这一段把参数拟合正式落成一个优化问题。真正的逻辑链条是：候选参数 → 重新模拟 → 计算残差 → 数值梯度 → LBFGS 更新参数。

5 结果：参数回收与轨迹对齐

课程给出的优化结果有两层验证。第一层是直接比较参数值，第二层是把优化后的参数再放回模型里，重新看轨迹是否更接近数据。课程强调的重点是第二层，因为参数不必逐项完全相等，只要生成的动力学轨迹足够接近观测，就说明拟合在模型语义上已经有意义。




图 2: 优化后参数对应的状态轨迹与观测数据对比, 展示拟合显著改善。图源: MIT Neuroblox 官方课程页 [optimization](#)。

表 1: ground truth、初始猜测与优化结果的对比

参数	Ground truth	Initial guess	Optimized
k_{ee}	2.0	0.2	0.6622
k_{ii}	1.5	3.3	1.5202
k_{ei}	5.5	2.0	4.5868
k_{ie}	7.0	3.5	6.9863

从表里可以直接看出两点。第一, 优化结果整体上比初始猜测更接近 ground truth。第二, 参数并没有被“精确还原”到每一位小数都一致, 尤其是第一个耦合系数仍有明显偏差。这不是意外, 而是噪声观测和逆问题本身都会让参数恢复变成近似问题。

但课程更看重的是轨迹质量: 用优化后的参数重新模拟后, 时序曲线和数据已经明显贴近, 说明模型在动力学层面达到了更好的解释能力。换句话说, 这一讲的成功标准不是“数字完全相等”, 而是“模型用更合理的参数重建了更合理的行为”。

结果该怎么读

参数表和轨迹图要一起看。参数接近 ground truth 说明优化方向是对的; 轨迹更接近数据说明这个方向在建模语义上真的有用。

5.1 本章小结

结果验证告诉我们, 拟合成功至少有两层含义: 参数值往正确方向收敛, 模拟轨迹也同步贴近观测。对于噪声数据, 这两层不必完全一致, 但应该相互支持。

6 从 synthetic recovery 到 real-data workflow: 这一讲真正教会了什么

如果把这讲只读成“如何调用 LBFGS”，其实会错过它最重要的方法学价值。课程页在 Introduction 里已经明确说，这种 fictive-data fitting 是任何 parameter fitting analysis 的推荐第一步，因为它能告诉你：在当前模型、当前观测变量和当前时间采样下，哪些参数原则上是可恢复的，哪些即使优化器运行成功，也未必能被稳定辨识出来。

这一点和结果表里的现象正好呼应。虽然四个耦合参数总体朝 ground truth 靠近，但并不是每个参数都同样容易被回收到原值附近，尤其是 k_{ee} 的偏差仍然明显。这意味着拟合流程已经成功，但问题本身仍然保留了 inverse problem 的典型特征：多个参数方向对观测的敏感度并不相同。

表 2: 课程页实际上教给读者的参数拟合诊断顺序

步骤	诊断目的
先生成 fictive data	检查模型与观测设置是否具备参数回收可能性
加入 observation noise	让问题更接近真实数据场景，而非无噪声理想环境
给出 initial guess 并可 可视化偏差	判断搜索起点是否过远，误差形态是否合理
再做 least-squares + LBFGS	在标准优化流程中验证参数与轨迹能否共同改善
回头比较参数表与轨迹 图	区分“数值收敛”与“建模上真正有解释力”

这张顺序表的关键在于，它把“拟合成功”拆成了几个不同的问题：优化器有没有报错、参数是否移动到合理区域、轨迹是否贴近数据、以及这个数据本身是否真的足以约束参数。课程并没有把这些问题混成一句“loss 下降了”，而是把它们放在一个更审慎的 workflow 里。

真实数据阶段最该继承的不是哪一个优化器，而是这一套顺序

当你换成真实数据时，最应该保留的不是某个固定数值技巧，而是“先做可辨识性检查，再谈拟合结果解释”的研究习惯。否则，优化流程可能只是把不充分的信息压进一个看似精确的参数向量里。

6.1 本章小结

这一节把课程页中隐含的方法学主张显式化了：synthetic recovery 不是热身，而是逆问题分析的第一道质量控制。真正成熟的参数拟合工作，应该把这一步当成标准流程，而不是可有可无的附加实验。

7 参考文献

课程页在这一讲只给出了一条核心参考：

- Byrd, R. H., Lu, P., Nocedal, J., & Zhu, C. (1995). *A Limited Memory Algorithm for Bound Constrained Optimization*. SIAM J. Sci. Comput., 16, 1190–1208.

这条文献对应的就是课程中使用的 LBFGS 方法。它把这一讲的实现细节和经典数值优化文献连了起来。

7.1 本章小结

参考文献部分虽然短，但它把课程的实现和算法来源对应起来了。对这讲来说，LBFGS 不是一个黑盒名字，而是一条能追溯到经典优化论文的具体方法线索。

7.2 拓展阅读

如果要把这一讲继续推进到更严肃的研究工作，最自然的拓展方向有两个。第一，是回到 LBFGS 所代表的 quasi-Newton 思路，思考在更高维、更多参数和更复杂损失函数下，哪些问题仍适合这样的二阶近似方法。第二，是把课程页反复强调的 synthetic-data check 延伸成更系统的 identifiability study：不是只问“能不能拟合”，而是问“哪些参数组合在现有观测下根本不可区分”。

8 总结与延伸

这一讲的核心信息很集中：参数拟合不是“调参”，而是把模型、数据和优化方法绑成一个可检验的逆问题。课程用假数据先做一遍，是为了回答“这套模型在原则上能不能把参数找回来”；用最小二乘和 LBFGS 去做，是为了把这个问题放进一个标准、可复现的数值流程里。

如果把这一讲迁移到真实数据，结构几乎不变。唯一的变化是：不再用模型生成数据，而是从文件读取观测；不再验证“能不能回收 ground truth”，而是验证“模型能不能解释真实信号”。在这个意义上，假数据拟合是方法学训练，真实数据拟合才是应用阶段。

这一讲留下的两个判断标准

第一，看参数是否往合理方向移动；第二，看重新模拟的轨迹是否更接近数据。前者检验优化，后者检验模型。

课程还给了一个更宽的提示：最小二乘不是唯一选择，优化目标可以替换成别的 objective。也就是说，这一讲给出的不是单一配方，而是一套可以迁移到不同数据和不同模型上的参数拟合模板。