


课程笔记

MIT RES.9-009 第 14 讲: Experimental Design (实验设计)

五道口纳什 & Codex

2026 年 4 月 15 日



视频作者/频道: MIT Video Productions (讲者: Lilianne Mujica-Parodi)

发布日期: 课程日期 2025-01-15; YouTube 上传 2025-04-15

视频时长: 07:05

视频链接: <https://www.youtube.com/watch?v=NU9K81-gg-Q>

目录

1	为什么实验设计不能脱离建模	2
1.1	本章小结	2
2	多通道与长时间窗：不要把动态平均掉	2
2.1	本章小结	3
3	关键实验：让竞争假设在数据上分道扬镳	3
3.1	本章小结	4
4	多尺度验证：从底层到上层都要可测	4
4.1	本章小结	5
5	总结与延伸	5
5.1	本章小结	5

证据说明

本讲的官方课程页几乎只提供了标题、视频嵌入和一条参考文献；真正的教学内容主要来自字幕与课程页结构化证据。官方 slide PDF 仍未找到，因此正文没有把“缺失幻灯片”当作教学内容展开，而是将其记录在 `omission_log.jsonl` 中。

1 为什么实验设计不能脱离建模

这讲一开始就把一个常见误区摆在台面上：我们往往习惯于把“数据分析”和“实验设计”分开考虑，但在计算建模里，这两件事必须同时想。原因很简单。模型不是静态表格里的几个值，而是一个需要随时间演化的动力系统；如果实验本身不能支持这种动力学表述，那么模型再漂亮，也只是停留在纸面上的解释。

课程把这个区别说得很直接。传统统计分析更关心的是一个值是不是“更高”或“更低”，是否存在统计学意义上的差别；而建模关心的是，系统在时间上如何变化，这种变化能否被一个 ODE 系统表达出来。换句话说，统计分析经常在比较“值”，建模则是在构造“过程”。

核心区别

统计分析常常回答“有没有差异”；建模必须进一步回答“差异如何随时间展开、如何被机制解释、能否被实验检验”。

课程还提醒了一点：很多为统计目的而优化过的实验，不一定能无缝迁移到建模。也就是说，原本对一个统计检验很友好的实验设计，未必能提供足够的时间分辨率、变量覆盖和因果约束来支撑一个动态模型。这个提醒对课程后面的所有例子都成立。

最早的例子来自 `glucose-insulin model`。若只看单个时间点，很多不同的 `disorder` 可能在表面上看起来差不多，甚至近乎等价；但一旦把动态过程纳入视野，它们就会显出差异。课程借这个例子强调了一件事：单点值可以遮蔽机制，时间结构才更接近模型要解释的对象。

1.1 本章小结

本章建立了整门课的逻辑前提：实验设计不是建模完成后的附属步骤，而是建模本身的一部分。模型要能被测试，实验就必须为动态、机制和因果区分提供条件。

2 多通道与长时间窗：不要把动态平均掉

从“值”转向“过程”之后，下一个问题就变成：到底该测什么、在什么位置测、测多久。课程给出的第一个建议是，理想情况下应该尽量采集连续测量，而且要覆盖回路中的多个组成部分。因为如果你面对的是一个负反馈环路，只看一个节点，通常不足以判断环路是如何工作的；至少要同时看到兴奋性和抑制性两个方向，才有机会把动态与因果链条拼起来。

这也解释了为什么课程特别强调“strategically picking those areas”。对做 `electrophysiology` 的人来说，插入电极本身就是代价高昂的动作；正因如此，更要把有限的测量位置用在最能提供结构信息的地方。若条件允许，测点越多越好，因为覆盖越完整，越容易重建系统动态，也更容易追踪因果关系。

实验设计的方向感

对于动态系统，测量的目标不是“尽量拿到一个平均数”，而是“尽量保留系统中的差异、方向和时序结构”。

课程接着指出，时间序列平均化本身可能是问题。原因不是平均本身错误，而是平均会把动态信号洗平。既然你关心的是系统如何变化，那么过度压缩时间结构就会损失最关键的信息。所以在可能的情况下，应该优先提高 SNR，并尽量保持较长的数据窗口；课程甚至明确说，这一点有时会与神经影像里的某些大规模数据策略相冲突。

这里最值得注意的对比，是课程拿 UK Biobank 一类神经影像设计来作参照。那类研究常见的做法是单个被试的 resting-state 数据很短，但被试人数极大；它的逻辑是“人多补质量”。而本讲的建模语境不同：如果目标是刻画动态机制，就往往更需要长窗口、高质量、可追踪的信号，而不是只靠大量短片段来平均掉个体内部的变化。

表 1: 课程对“统计分析型实验”和“建模型实验”的侧重点区分

视角	常见偏好	对实验设计的含义
统计分析	关注值的高低、显著性、群体差异	单点观测有时足够，但不一定支持机制解释
建模	关注时序、动力学与 ODE 结构	需要连续测量、多个节点、尽量少把动态平均掉
大规模影像	以人数补偿扫描短、单体质量低	适合群体统计，不一定适合精细回路建模

2.1 本章小结

如果实验的目标是给模型提供辨识能力，那么测量位置、测量数量、测量时长和信噪比，都是和理论同等重要的设计变量。课程在这一段的态度很明确：要保留动力学，不要把动力学平均没了。

3 关键实验：让竞争假设在数据上分道扬镳

课程后半段给出的是更具建模味道的思路：利用模型去设计关键实验 (critical experiment)。这不是先把所有参数都钉死，再被动等待数据来“验证”；相反，是先把可能的竞争假设都放进一个 provisional circuit，再看这些假设的输出在什么地方最大程度分歧，然后把实验专门设计在这些分歧点上。

这个方法有两个直接收益。第一，你不再只是问“哪个模型更像数据”，而是问“哪个观测最能区分模型”。第二，模型不再只是一个解释器，而成为实验生成器：它先告诉你应该在哪些点上测，才能最大化辨识力。




图 1: 关键实验的设计循环: 从竞争假设出发, 经由模型推演找到最大分歧点, 再把实验和扰动放到最有区分度的位置。

课程还把这个思路进一步推进到 *in silico* perturbation。也就是说, 既然已经有了模型, 就可以先在模型里问: 如果我刺激这个位置, 而不是那个位置, 动态会怎样变化? 这种虚拟刺激不会替代真实实验, 但它能帮助你提前筛选出最有信息量的操作条件, 从而把真实实验的资源花在最值得做的地方。

为什么叫“关键实验”

关键实验不是最昂贵的实验, 而是最能把竞争假设区分开的实验。它的判据是区分力, 不是规模感。

课程强调的一个细节也很重要: 有时即使你没有足够信息去完全确定系统结构, 仍然可以先搭一个 provisional circuit, 并穷举其组合方式, 再让数据告诉你哪些配置与观测相容、哪些不相容。也就是说, 模型可以先粗后细, 关键是每一步都在朝“可区分、可检验”推进。

3.1 本章小结

建模在这里的角色不只是解释数据, 而是主动生成实验方案。先比较模型输出的分歧, 再去设计观测和扰动位置, 这是课程对“模型如何服务实验”的最核心回答。

4 多尺度验证: 从底层到上层都要可测

课程最后把视角从单一回路扩展到多尺度系统。若要真正利用 Neuroblox 的 multiscale capabilities, 就不能只盯着某一层的观测; 更稳妥的做法, 是在多个尺度上同时采集数据, 然后据此建立从底层到上一层、再到更高层的 transfer functions。

这一步的意义在于, 模型不再只是某一尺度上的拟合, 而是可以追问“怎样从底层走到上层”。课程用的表达很朴素: 你要知道如何从 bottom layer 到 next layer, 再到 next layer。这样的表达背后, 其实是在要求一个跨尺度的可追踪映射, 而不是只在单尺度上看起来好看。

最后的建模标准

如果你的最终目标是 rigorous model, 那么多尺度验证不是可选项, 而是模型可信度的一部分。单尺度看起来正确, 并不等于跨尺度也成立。

⁰ 依据字幕 00:04:28–00:06:18 以及 00:06:23–00:07:04 的内容综合绘制。

课程也没有回避难度：这样的实验并不容易做，尤其当同时采集多个尺度意味着额外的设备、同步、噪声控制和分析复杂度时。不过，课程的态度并不是“因为难就不做”，而是“如果目标真的是 rigorous model，就必须把这个难题算进去”。

4.1 本章小结

多尺度验证把实验设计从“测到一点信息”提升为“建立尺度之间的可追踪关系”。这也是课程最后把实验设计和模型严谨性重新绑回一起的地方。

5 总结与延伸

这讲的主线其实很统一：对计算神经科学来说，实验设计不是建模之外的外部条件，而是模型是否站得住脚的前提。先要有动态观测，而不是只看单点值；再要有多通道覆盖，而不是只盯一个节点；然后要用模型构造关键实验，找出竞争假设的最大分歧；最后还要做多尺度验证，让模型不只在—个层面上成立。

如果把整讲压缩成—句话，那就是：**好的实验设计，是为了让模型“有机会被证明错”，从而更可靠地被证明对。**

官方课程页参考

官方课程页在这一讲只列出了—条参考文献：A. Królikowski 与 P. Eykhoff, *Input Signal Design for System Identification: A Comparative Analysis*, IFAC Proceedings Volumes, 18(5), 1985, 915–920, doi 链接。这与本讲的主题很—致：实验输入怎么设计，往往决定了系统能否被辨识出来。

5.1 本章小结

实验设计的价值，不是把数据变得更像预期，而是把数据变得更能回答模型问题。对于 Neuroblox 这类分层、动态、可扰动的建模框架，这一点尤其重要。