

CMU S11-751/18-781: Speech Recognition and Understanding

(Fall 2023)

Codex harness-managed build from course page, public videos, and supplemental official materials

2026 年 4 月 16 日

目录

课程说明	3
课程目录	3
来源说明	3
1 Course Overview	5
2 Introduction of Speech Recognition	10
3 Speech Recognition Formulations	19
4 Feature Extraction	29
5 Acoustic Model Overview	38
6 Alignment Problems	46
7 K-means, GMM, EM Algorithm	55
8 Forward-Backward Algorithm for HMM	60
9 Forward-Backward Algorithm for HMM	65
10 Forward-Backward Algorithm for CTC and Viterbi Algorithm	70
11 N-gram Language Models	75
12 Search	80
13 ESPnet Hands-on Tutorial I	85
14 ESPnet Hands-on Tutorial II	90
15 Deep Neural Network for Acoustic Modeling	95
16 Neural Network Language Model	104

17 End-to-End ASR: Attention	114
18 End-to-End ASR: CTC	123
19 End-to-End ASR: RNN-T	135
20 Advanced Topics on End-to-End ASR I	145
21 Advanced Topics on End-to-End ASR II	154
22 Guest Lecture I	162
23 Guest Lecture II	170

课程说明

本教材按 harness-managed 流水线逐讲生成，并只纳入通过 evaluator gate 的章节。

课程目录

讲次	主题	日期	状态
01	Course Overview	2023-08-28	deliverable
02	Introduction of Speech Recognition	2023-08-30	deliverable
03	Speech Recognition Formulations	2023-09-06	deliverable
04	Feature Extraction	2023-09-11	deliverable
05	Acoustic Model Overview	2023-09-13	deliverable
06	Alignment Problems	2023-09-18	deliverable
07	K-means, GMM, EM Algorithm	2023-09-20	deliverable
08	Forward-Backward Algorithm for HMM	2023-09-25	deliverable
09	Forward-Backward Algorithm for HMM	2023-09-27	deliverable
10	Forward-Backward Algorithm for CTC and Viterbi Algorithm	2023-10-02	deliverable
11	N-gram Language Models	2023-10-02	deliverable
12	Search	2023-10-11	deliverable
13	ESPnet Hands-on Tutorial I	2023-10-23	deliverable
14	ESPnet Hands-on Tutorial II	2023-10-25	deliverable
15	Deep Neural Network for Acoustic Modeling	2023-10-30	deliverable
16	Neural Network Language Model	2023-11-01	deliverable
17	End-to-End ASR: Attention	2023-11-06	deliverable
18	End-to-End ASR: CTC	2023-11-08	deliverable
19	End-to-End ASR: RNN-T	2023-11-13	deliverable
20	Advanced Topics on End-to-End ASR I	2023-11-15	deliverable
21	Advanced Topics on End-to-End ASR II	2023-11-20	deliverable
22	Guest Lecture I	2023-11-27	deliverable
23	Guest Lecture II	2023-11-29	deliverable

来源说明

本书以 2023 年课程页与官方公开录像为主；当某讲在 2023 年没有公开视频时，才使用同门课同主题的官方公开辅助材料或明确标注的官方重建材料。

讲次	主题	来源类型	说明
01	Course Overview	official auxiliary video	Reconstructed from the 2023 course row plus an official same-course auxiliary public video.
02	Introduction of Speech Recognition	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.

03	Speech Recognition Formulations	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
04	Feature Extraction	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
05	Acoustic Model Overview	official auxiliary video	Reconstructed from the 2023 course row plus an official same-course auxiliary public video.
06	Alignment Problems	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
07	K-means, GMM, EM Algorithm	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
08	Forward-Backward Algorithm for HMM	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
09	Forward-Backward Algorithm for HMM	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
10	Forward-Backward Algorithm for CTC and Viterbi Algorithm	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
11	N-gram Language Models	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
12	Search	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
13	ESPnet Hands-on Tutorial I	official auxiliary video	Reconstructed from the 2023 course row plus an official same-course auxiliary public video.
14	ESPnet Hands-on Tutorial II	official auxiliary video	Reconstructed from the 2023 course row plus an official same-course auxiliary public video.
15	Deep Neural Network for Acoustic Modeling	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
16	Neural Network Language Model	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
17	End-to-End ASR: Attention	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
18	End-to-End ASR: CTC	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
19	End-to-End ASR: RNN-T	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
20	Advanced Topics on End-to-End ASR I	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.
21	Advanced Topics on End-to-End ASR II	2023 official video	Directly grounded in the official Fall 2023 WAVLab public playlist.

22	Guest Lecture I	official reconstruction	Reconstructed from official course-page rows and other official public materials without a recovered lecture video.
23	Guest Lecture II	official reconstruction	Reconstructed from official course-page rows and other official public materials without a recovered lecture video.

1 Course Overview

课程笔记

Course Overview

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日



11-751/18-781 Speech Recognition and Understanding

Lecture1: Course overview



Carnegie Mellon University
Language Technologies Institute



视频作者/频道: WAVLab

发布日期: 2023-08-28

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=DsYDmg72K1k>

目录

1	1.0 课程导论与课程结构	2
1.1	Course Overview	2
1.2	本章小结	3
2	总结与延伸	3

Source Discrepancy

2023 course page does not expose a public 2023 overview recording. This lecture is reconstructed using the official 2023 course-page schedule entry plus the official WAVLab Fall 2022 same-course overview video as an explicitly labeled auxiliary source.

1 1.0 课程导论与课程结构

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 1.0 课程导论与课程结构这一部分主要围绕 Course Overview | Course explanation and introduction 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Course Overview Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

01-u01 |
Course Overview | Course explanation and
introduction

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Course Overview Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-08-28
Course Overview | Course explanation and
introduction

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Course Overview

从证据位置看，这一部分对应的课程证据区间是 2023-08-28。课程在这里强调的核心内容可以概括为：Course Overview | Course explanation and introduction。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：This lecture now uses the official 2023 schedule row together with the official WAVLab Fall 2022 same-course overview video as an auxiliary official source.

在本章结构中，这一单元被并入“1.0 课程导论与课程结构”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

1.0 课程导论与课程结构这一部分把 Course Overview 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 总结与延伸

Course Overview 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Course Overview 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

2 Introduction of Speech Recognition

课程笔记

Introduction of Speech Recognition

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Levenshtein distance (edit distance)



- The minimum number of word/character edits (insertions, deletions or substitutions) required to change one sentence into the other

	Hypothesis (i)			
		see	a	campus
	0	1	2	3
	to	1		
	the	2		
Reference (j)	CMU	3		
	campus	4		

- Compute the accumulated cost for each element $[i, j]$ by using the following equation
- The **local substitution cost** is **0 (correct), 1 (incorrect)**, i.e., $1 - \delta(w[i], w[j])$ in our case (usual case)
- We initialize the cost in the extra row and column

$$d[i, j] = \min \begin{cases} d[i-1, j] + 1, & \# \text{ insertion} \\ d[i, j-1] + 1, & \# \text{ deletion} \\ d[i-1, j-1] + \text{local_substitution}(i, j) & \# \text{ substitution} \end{cases}$$



视频作者/频道: WAVLab

发布日期: 2023-08-30

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=thEKvvFwMvQ>

目录

1	2.0 课程主题总览	2
1.1	Introduction of Speech Recognition	3
1.2	本章小结	4
2	2.1 评价指标 (evaluation metric)	4
2.1	Evaluation metric	4
2.2	本章小结	4
3	2.2 转写规范 (transcription policy)	4
3.1	How to transcribe speech	5
3.2	本章小结	5
4	2.3 语音数据库 (databases)	5
4.1	Databases	5
4.2	本章小结	5
5	2.4 语料比较与标注一致性	5
5.1	Corpus comparison	6
5.2	本章小结	6
6	2.5 录制与数据收集	6
6.1	Speech data collection	6
6.2	本章小结	6
7	2.6 基准、工具链与实践注意事项	6
7.1	Resource scale	7
7.2	本章小结	7
8	总结与延伸	7

1 2.0 课程主题总览

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 2.0 课程主题总览这一部分主要围绕 Introduction of Speech Recognition | Evaluation metric | How to transcribe speech | Databases 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Introduction of Speech Recognition Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

02-u01 | 2.0

Introduction of Speech Recognition |
Evaluation metric | How to transcribe speech
| Databases

02-u02 | 2.1 evaluation metric

Evaluation metric | Word error rate | Edit
distance intuition

02-u03 | 2.2 transcription policy

How to transcribe speech | Orthographic
normalization | Boundary decisions

02-u04 | 2.3 databases

Databases | Corpus design | Train/dev/test
splits

02-u05 | 2.4

Corpus comparison | Annotation consistency |
Subjective judgments

02-u06 | 2.5

Speech data collection | Spontaneous speech
| Recording conditions

02-u07 | 2.6

Resource scale | Toolkits | Benchmarking and
practical caveats

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Introduction of Speech Recognition Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-08-30

Introduction of Speech Recognition | Evaluation metric | How to transcribe speech | Databases

00:00:00,080 -- 00:07:19,919

Evaluation metric | Word error rate | Edit distance intuition

00:07:16,120 -- 00:13:45,399

How to transcribe speech | Orthographic normalization | Boundary decisions

00:13:42,680 -- 00:21:03,559

Databases | Corpus design | Train/dev/test splits

00:20:59,320 -- 00:27:26,559

Corpus comparison | Annotation consistency | Subjective judgments

00:27:22,880 -- 00:33:40,279

Speech data collection | Spontaneous speech | Recording conditions

00:33:36,320 -- 00:40:31,000

Resource scale | Toolkits | Benchmarking and practical caveats

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Introduction of Speech Recognition

从证据位置看,这一部分对应的课程证据区间是 2023-08-30。课程在这里强调的核心内容可以概括为: Introduction of Speech Recognition | Evaluation metric | How to transcribe speech | Databases。这一部分把语音识别系统的好坏从“听起来差不多”转成可重复计算的误差统计,这也是后续比较不同模型与搜索策略时的统一标尺。

记录系统中的附加说明指出: Course-page schedule entry is restated in the chapter introduction and section roadmap.

在本章结构中,这一单元被并入“2.0 课程主题总览”,目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

2.0 课程主题总览这一部分把 Introduction of Speech Recognition 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 2.1 评价指标 (evaluation metric)

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 2.1 评价指标 (evaluation metric) 这一部分主要围绕 Evaluation metric | Word error rate | Edit distance intuition 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 Evaluation metric

从证据位置看，这一部分对应的课程证据区间是 00:00:00,080 – 00:07:19,919。课程在这里强调的核心内容可以概括为：Evaluation metric | Word error rate | Edit distance intuition。这一部分把语音识别系统的好坏从“听起来差不多”转成可重复计算的误差统计，这也是后续比较不同模型与搜索策略时的统一标尺。

记录系统中的附加说明指出：WER and edit distance are expanded with formula and symbol explanation.

在本章结构中，这一单元被并入“2.1 评价指标 (evaluation metric)”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$\text{WER} = \frac{S + D + I}{N}$$

符号说明如下：

- S : substitutions, 替换错误数；
- D : deletions, 删除错误数；
- I : insertions, 插入错误数；
- N : 参考转写中的词数。

2.2 本章小结

2.1 评价指标 (evaluation metric) 这一部分把 Introduction of Speech Recognition 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 2.2 转写规范 (transcription policy)

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 2.2 转写规范 (transcription policy) 这一部分主要围绕 How to transcribe speech | Orthographic normalization | Boundary decisions 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 How to transcribe speech

从证据位置看,这一部分对应的课程证据区间是 00:07:16,120 – 00:13:45,399。课程在这里强调的核心内容可以概括为: How to transcribe speech | Orthographic normalization | Boundary decisions。课程强调,转写规范并不是纯粹的标注细节,而是直接决定训练目标、评测方式与跨语料可比性的建模前提。

记录系统中的附加说明指出: Orthographic normalization, punctuation, and boundary conventions are covered as transcription policy.

在本章结构中,这一单元被并入“2.2 转写规范 (transcription policy)”,目的是把同一阶段的定义、机制和权衡集中讲清。

3.2 本章小结

2.2 转写规范 (transcription policy) 这一部分把 Introduction of Speech Recognition 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题,也交代了方法、推理或工程权衡为什么要这样组织。

4 2.3 语音数据库 (databases)

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 2.3 语音数据库 (databases) 这一部分主要围绕 Databases | Corpus design | Train/dev/test splits 展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清,再压缩成适合复习的结构。

4.1 Databases

从证据位置看,这一部分对应的课程证据区间是 00:13:42,680 – 00:21:03,559。课程在这里强调的核心内容可以概括为: Databases | Corpus design | Train/dev/test splits。从教材视角看,语料库设计决定了系统能学到什么分布,也决定了实验结果是否能被正确解释。

记录系统中的附加说明指出: Corpus design, split hygiene, and scale tradeoffs are covered.

在本章结构中,这一单元被并入“2.3 语音数据库 (databases)”,目的是把同一阶段的定义、机制和权衡集中讲清。

4.2 本章小结

2.3 语音数据库 (databases) 这一部分把 Introduction of Speech Recognition 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题,也交代了方法、推理或工程权衡为什么要这样组织。

5 2.4 语料比较与标注一致性

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 2.4 语料比较与标注一致性这一部分主要围绕 Corpus comparison | Annotation consistency | Subjective judgments 展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清,再压缩成适合复习的结构。

5.1 Corpus comparison

从证据位置看，这一部分对应的课程证据区间是 00:20:59,320 – 00:27:26,559。课程在这里强调的核心内容可以概括为：Corpus comparison | Annotation consistency | Subjective judgments。从教材视角看，语料库设计决定了系统能学到什么分布，也决定了实验结果是否能被正确解释。

记录系统中的附加说明指出：Comparison criteria are written up as annotation consistency and subjective judgment caveats.

在本章结构中，这一单元被并入“2.4 语料比较与标注一致性”，目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

2.4 语料比较与标注一致性这一部分把 Introduction of Speech Recognition 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 2.5 录制与数据收集

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，2.5 录制与数据收集这一部分主要围绕 Speech data collection | Spontaneous speech | Recording conditions 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 Speech data collection

从证据位置看，这一部分对应的课程证据区间是 00:27:22,880 – 00:33:40,279。课程在这里强调的核心内容可以概括为：Speech data collection | Spontaneous speech | Recording conditions。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：Spontaneous speech and recording conditions are described in the data-collection section.

在本章结构中，这一单元被并入“2.5 录制与数据收集”，目的是把同一阶段的定义、机制和权衡集中讲清。

6.2 本章小结

2.5 录制与数据收集这一部分把 Introduction of Speech Recognition 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 2.6 基准、工具链与实践注意事项

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，2.6 基准、工具链与实践注意事项这一部分主要围绕 Resource scale | Toolkits | Benchmarking and practical caveats 展开。写作上保

持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

7.1 Resource scale

从证据位置看，这一部分对应的课程证据区间是 00:33:36,320 – 00:40:31,000。课程在这里强调的核心内容可以概括为：Resource scale | Toolkits | Benchmarking and practical caveats。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：Toolkits, benchmarking, and practical cautions are covered, with CS224S mentioned only as an extension where relevant.

在本章结构中，这一单元被并入“2.6 基准、工具链与实践注意事项”，目的是把同一阶段的定义、机制和权衡集中讲清。

CS224S 补充

Toolkits, benchmarking, and practical cautions are covered, with CS224S mentioned only as an extension where relevant.

7.2 本章小结

2.6 基准、工具链与实践注意事项这一部分把 Introduction of Speech Recognition 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

8 总结与延伸

Introduction of Speech Recognition 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Introduction of Speech Recognition 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

3 Speech Recognition Formulations

Speech Recognition Formulations

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Other rules



- **Bayes rule**

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)} = \frac{p(y|x)p(x)}{\sum_x p(y|x)p(x)}$$

- **Probabilistic chain rule**

$$p(x_1, \dots, x_N) = \prod_{n=1}^N p(x_n | x_{1:n-1}) \quad \text{where} \quad p(x_1 | x_{1:0}) = p(x_1)$$

- Both are derived with a combination of the product and/or sum rules

🔍 🔗 📄 📌 📁 📂

视频作者/频道: WAVLab

发布日期: 2023-09-06

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=GjcOmSTsoms>

目录

1	3.0 课程主题总览	2
1.1	Speech Recognition Formulations	3
1.2	本章小结	4
2	3.1 概率化建模基础 (probabilistic rules)	4
2.1	Probabilistic rules	4
2.2	本章小结	4
3	3.2 Bayes decision theory 与 noisy channel	5
3.1	Bayes decision theory	5
3.2	本章小结	5
4	3.3 HMM + n-gram baseline	5
4.1	HMM + n-gram baseline	5
4.2	本章小结	6
5	3.4 CTC (Connectionist Temporal Classification)	6
5.1	CTC	6
5.2	本章小结	7
6	3.5 RNN-T / transducer	7
6.1	RNN-T	7
6.2	本章小结	7
7	3.6 attention-based seq2seq	7
7.1	Attention-based seq2seq	8
7.2	本章小结	8
8	3.7 统一视角与 tradeoffs	8
8.1	Unified view	8
8.2	本章小结	8
9	总结与延伸	8

1 3.0 课程主题总览

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 3.0 课程主题总览这一部分主要围绕 Speech Recognition Formulations | Probabilistic rules | From Bayes decision theory to HMM + n-gram, CTC, RNN-T, and attention 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Speech Recognition Formulations Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

03-u01 | 3.0

Speech Recognition Formulations |
Probabilistic rules | From Bayes decision
theory to HMM + n-gram, CTC, RNN-T, and
attention

03-u02 | 3.1 probabilistic rules
Probabilistic rules | Sequence modeling
setup | Bayes decision theory

03-u03 | 3.2 Bayes decision theory noisy channel
Bayes decision theory | Noisy channel
factorization | Chain rule

03-u04 | 3.3 HMM + n-gram baseline
HMM + n-gram baseline | Tractable
decomposition | Sequence probability

03-u05 | 3.4 CTC Connectionist Temporal Classification
CTC | Monotonic alignments | Path summation

03-u06 | 3.5 RNN-T / transducer
RNN-T | Prediction network | Transducer
objective

03-u07 | 3.6 attention-based seq2seq
Attention-based seq2seq | Soft alignments |
Decoding tradeoffs

03-u08 | 3.7 tradeoffs
Unified view | Model tradeoffs |
Low-resource and practical remarks

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Speech Recognition Formulations Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-09-06

Speech Recognition Formulations | Probabilistic rules | From Bayes decision theory to HMM + n-gram, CTC, RNN-T, and attention

00:00:00,240 -- 00:06:38,960

Probabilistic rules | Sequence modeling setup | Bayes decision theory

00:06:36,639 -- 00:13:35,199

Bayes decision theory | Noisy channel factorization | Chain rule

00:13:32,240 -- 00:20:11,640

HMM + n-gram baseline | Tractable decomposition | Sequence probability

00:20:09,799 -- 00:27:16,720

CTC | Monotonic alignments | Path summation

00:27:14,919 -- 00:33:34,960

RNN-T | Prediction network | Transducer objective

00:33:32,000 -- 00:40:25,040

Attention-based seq2seq | Soft alignments | Decoding tradeoffs

00:40:22,880 -- 00:46:44,000

Unified view | Model tradeoffs | Low-resource and practical remarks

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Speech Recognition Formulations

从证据位置看,这一部分对应的课程证据区间是 2023-09-06。课程在这里强调的核心内容可以概括为: Speech Recognition Formulations | Probabilistic rules | From Bayes decision theory to HMM + n-gram, CTC, RNN-T, and attention。这一步把识别问题写成一个清晰的概率分解,也奠定了后面 HMM、n-gram、以及更现代端到端模型之间的比较框架。

在本章结构中,这一单元被并入“3.0 课程主题总览”,目的是把同一阶段的定义、机制和权衡集中讲清。

$$\hat{W} = \arg \max_W P(W | X) = \arg \max_W P(X | W)P(W)$$

符号说明如下:

- X : 观测到的语音特征序列;
- W : 候选词序列;
- $P(X | W)$: 声学模型或观测模型;
- $P(W)$: 语言模型。

1.2 本章小结

3.0 课程主题总览这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

2 3.1 概率化建模基础 (probabilistic rules)

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 3.1 概率化建模基础 (probabilistic rules) 这一部分主要围绕 Probabilistic rules | Sequence modeling setup | Bayes decision theory 展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

2.1 Probabilistic rules

从证据位置看, 这一部分对应的课程证据区间是 00:00:00,240 – 00:06:38,960。课程在这里强调的核心内容可以概括为: Probabilistic rules | Sequence modeling setup | Bayes decision theory。这一步把识别问题写成一个清晰的概率分解, 也奠定了后面 HMM、n-gram、以及更现代端到端模型之间的比较框架。

在本章结构中, 这一单元被并入 “3.1 概率化建模基础 (probabilistic rules)”, 目的是把同一阶段的定义、机制和权衡集中讲清。

$$\hat{W} = \arg \max_W P(W | X) = \arg \max_W P(X | W)P(W)$$

符号说明如下:

- X : 观测到的语音特征序列;
- W : 候选词序列;
- $P(X | W)$: 声学模型或观测模型;
- $P(W)$: 语言模型。

2.2 本章小结

3.1 概率化建模基础 (probabilistic rules) 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

3 3.2 Bayes decision theory 与 noisy channel

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 3.2 Bayes decision theory 与 noisy channel 这一部分主要围绕 Bayes decision theory | Noisy channel factorization | Chain rule 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 Bayes decision theory

从证据位置看，这一部分对应的课程证据区间是 00:06:36,639 – 00:13:35,199。课程在这里强调的核心内容可以概括为：Bayes decision theory | Noisy channel factorization | Chain rule。这一步把识别问题写成一个清晰的概率分解，也奠定了后面 HMM、n-gram、以及更现代端到端模型之间的比较框架。

在本章结构中，这一单元被并入 “3.2 Bayes decision theory 与 noisy channel”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$\hat{W} = \arg \max_W P(W | X) = \arg \max_W P(X | W)P(W)$$

符号说明如下：

- X ：观测到的语音特征序列；
- W ：候选词序列；
- $P(X | W)$ ：声学模型或观测模型；
- $P(W)$ ：语言模型。

3.2 本章小结

3.2 Bayes decision theory 与 noisy channel 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 3.3 HMM + n-gram baseline

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 3.3 HMM + n-gram baseline 这一部分主要围绕 HMM + n-gram baseline | Tractable decomposition | Sequence probability 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 HMM + n-gram baseline

从证据位置看，这一部分对应的课程证据区间是 00:13:32,240 – 00:20:11,640。课程在这里强调的核心内容可以概括为：HMM + n-gram baseline | Tractable decomposition | Sequence probability。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

在本章结构中，这一单元被并入“3.3 HMM + n-gram baseline”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(w_1, \dots, w_T) = \prod_{t=1}^T P(w_t \mid w_1, \dots, w_{t-1}) \approx \prod_{t=1}^T P(w_t \mid w_{t-n+1}, \dots, w_{t-1})$$

符号说明如下：

- w_t ：第 t 个词；
- T ：句子长度；
- n ： n -gram 的上下文窗口长度。

4.2 本章小结

3.3 HMM + n-gram baseline 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 3.4 CTC (Connectionist Temporal Classification)

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，3.4 CTC (Connectionist Temporal Classification) 这一部分主要围绕 CTC | Monotonic alignments | Path summation 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 CTC

从证据位置看，这一部分对应的课程证据区间是 00:20:09,799 – 00:27:16,720。课程在这里强调的核心内容可以概括为：CTC | Monotonic alignments | Path summation。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入“3.4 CTC (Connectionist Temporal Classification)”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y \mid X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t \mid X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

5.2 本章小结

3.4 CTC (Connectionist Temporal Classification) 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 3.5 RNN-T / transducer

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，3.5 RNN-T / transducer 这一部分主要围绕 RNN-T | Prediction network | Transducer objective 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 RNN-T

从证据位置看，这一部分对应的课程证据区间是 00:27:14,919 – 00:33:34,960。课程在这里强调的核心内容可以概括为：RNN-T | Prediction network | Transducer objective。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入 “3.5 RNN-T / transducer”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：目标标签序列；
- $\mathcal{A}(X, Y)$ ：满足转导约束的对齐集合；
- h_t ：encoder 在时间步 t 的表示；
- g_u ：prediction network 在输出步 u 的表示。

6.2 本章小结

3.5 RNN-T / transducer 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 3.6 attention-based seq2seq

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，3.6 attention-based seq2seq 这一部分主要围绕 Attention-based seq2seq | Soft alignments | Decoding tradeoffs 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

7.1 Attention-based seq2seq

从证据位置看，这一部分对应的课程证据区间是 00:33:32,000 – 00:40:25,040。课程在这里强调的核心内容可以概括为：Attention-based seq2seq | Soft alignments | Decoding tradeoffs。与单调模型不同，attention encoder-decoder 更强调全局条件化能力，但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中，这一单元被并入 “3.6 attention-based seq2seq”，目的是把同一阶段的定义、机制和权衡集中讲清。

7.2 本章小结

3.6 attention-based seq2seq 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

8 3.7 统一视角与 tradeoffs

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，3.7 统一视角与 tradeoffs 这一部分主要围绕 Unified view | Model tradeoffs | Low-resource and practical remarks 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

8.1 Unified view

从证据位置看，这一部分对应的课程证据区间是 00:40:22,880 – 00:46:44,000。课程在这里强调的核心内容可以概括为：Unified view | Model tradeoffs | Low-resource and practical remarks。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入 “3.7 统一视角与 tradeoffs”，目的是把同一阶段的定义、机制和权衡集中讲清。

8.2 本章小结

3.7 统一视角与 tradeoffs 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

9 总结与延伸

Speech Recognition Formulations 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Speech Recognition Formulations 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

4 Feature Extraction


Feature Extraction

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Very beginning
What is a speech waveform?

- Waveform: Converting a sound pressure into a time series
- Usually **1-dimensional waveform** (mono) in this lecture
 - A lot of recording devices support stereo waveforms.
 - Then, it would be 2 (left and right) dimensional waveform
 - We also use a microphone array to capture N-dimensional waveform where N means the number of channels captured by N microphones (e.g., Alexa has 7 microphones, N=7)



视频作者/频道: WAVLab

发布日期: 2023-09-11

视频时长: unknown

视频链接: https://www.youtube.com/watch?v=Z5v_hj__CWU

目录

1	4.0 课程主题总览	2
1.1	Feature Extraction	3
1.2	本章小结	4
2	4.1 语音信号与采样	4
2.1	Feature extraction pipeline	4
2.2	本章小结	4
3	4.2 预处理、downsampling 与 framing	4
3.1	Sampling	4
3.2	本章小结	4
4	4.3 STFT / spectrogram	5
4.1	Framing	5
4.2	本章小结	5
5	4.4 Mel scale / filterbanks	5
5.1	Spectrograms	5
5.2	本章小结	5
6	4.5 MFCC / cepstrum	5
6.1	MFCC	6
6.2	本章小结	6
7	4.6 normalization / delta / context	6
7.1	Normalization	6
7.2	本章小结	6
8	4.7 learned front ends	6
8.1	Advanced front ends	7
8.2	本章小结	7
9	4.8 practical tradeoffs	7
9.1	Practical tradeoffs	7
9.2	本章小结	7
10	总结与延伸	7

1 4.0 课程主题总览

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，4.0 课程主题总览这一部分主要围绕 Feature Extraction | Basic pipeline | Some advances in feature extractions 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Feature Extraction Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

04-u01 | 4.0

Feature Extraction | Basic pipeline | Some
advances in feature extractions

04-u02 | 4.1

Feature extraction pipeline | Signal
acquisition | Preprocessing motivation

04-u03 | 4.2 downsampling framing
Sampling | Downsampling | Preprocessing and
framing entry point

04-u04 | 4.3 STFT / spectrogram

Framing | Windowing | Short-time spectral
analysis

04-u05 | 4.4 Mel scale / filterbanks
Spectrograms | Mel scale | Filterbanks

04-u06 | 4.5 MFCC / cepstrum

MFCC | Cepstrum | DCT and compact acoustic
features

04-u07 | 4.6 normalization / delta / context

Normalization | Delta features | Context
stacking

04-u08 | 4.7 learned front ends

Advanced front ends | Learned features |
Robustness

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Feature Extraction Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-09-11

Feature Extraction | Basic pipeline | Some
advances in feature extractions

00:00:00,919 -- 00:06:38,039

Feature extraction pipeline | Signal acquisition
| Preprocessing motivation

00:06:33,680 -- 00:13:37,839

Sampling | Downsampling | Preprocessing and
framing entry point

00:13:34,519 -- 00:21:06,360

Framing | Windowing | Short-time spectral
analysis

00:21:02,440 -- 00:27:50,279

Spectrograms | Mel scale | Filterbanks

00:27:46,360 -- 00:34:44,480

MFCC | Cepstrum | DCT and compact acoustic
features

00:34:42,040 -- 00:41:28,560

Normalization | Delta features | Context
stacking

00:41:25,160 -- 00:47:28,640

Advanced front ends | Learned features |
Robustness

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Feature Extraction

从证据位置看，这一部分对应的课程证据区间是 2023-09-11。课程在这里强调的核心内容可以概括为：Feature Extraction | Basic pipeline | Some advances in feature extractions。这部分相当于把波形如何变成可建模特征的整条前端链路重新拆开，方便读者理解后续 acoustic model 到底在消费什么信息。

在本章结构中，这一单元被并入“4.0 课程主题总览”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

4.0 课程主题总览这一部分把 Feature Extraction 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 4.1 语音信号与采样

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，4.1 语音信号与采样这一部分主要围绕 Feature extraction pipeline | Signal acquisition | Preprocessing motivation 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 Feature extraction pipeline

从证据位置看，这一部分对应的课程证据区间是 00:00:00,919 – 00:06:38,039。课程在这里强调的核心内容可以概括为：Feature extraction pipeline | Signal acquisition | Preprocessing motivation。这部分相当于把波形如何变成可建模特征的整条前端链路重新拆开，方便读者理解后续 acoustic model 到底在消费什么信息。

在本章结构中，这一单元被并入“4.1 语音信号与采样”，目的是把同一阶段的定义、机制和权衡集中讲清。

2.2 本章小结

4.1 语音信号与采样这一部分把 Feature Extraction 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 4.2 预处理、downsampling 与 framing

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，4.2 预处理、downsampling 与 framing 这一部分主要围绕 Sampling | Downsampling | Preprocessing and framing entry point 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 Sampling

从证据位置看，这一部分对应的课程证据区间是 00:06:33,680 – 00:13:37,839。课程在这里强调的核心内容可以概括为：Sampling | Downsampling | Preprocessing and framing entry point。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入“4.2 预处理、downsampling 与 framing”，目的是把同一阶段的定义、机制和权衡集中讲清。

3.2 本章小结

4.2 预处理、downsampling 与 framing 这一部分把 Feature Extraction 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样

组织。

4 4.3 STFT / spectrogram

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 4.3 STFT / spectrogram 这一部分主要围绕 Framing | Windowing | Short-time spectral analysis 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 Framing

从证据位置看，这一部分对应的课程证据区间是 00:13:34,519 – 00:21:06,360。课程在这里强调的核心内容可以概括为：Framing | Windowing | Short-time spectral analysis。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入“4.3 STFT / spectrogram”，目的是把同一阶段的定义、机制和权衡集中讲清。

4.2 本章小结

4.3 STFT / spectrogram 这一部分把 Feature Extraction 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 4.4 Mel scale / filterbanks

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 4.4 Mel scale / filterbanks 这一部分主要围绕 Spectrograms | Mel scale | Filterbanks 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 Spectrograms

从证据位置看，这一部分对应的课程证据区间是 00:21:02,440 – 00:27:50,279。课程在这里强调的核心内容可以概括为：Spectrograms | Mel scale | Filterbanks。这部分相当于把波形如何变成可建模特征的整条前端链路重新拆开，方便读者理解后续 acoustic model 到底在消费什么信息。

在本章结构中，这一单元被并入“4.4 Mel scale / filterbanks”，目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

4.4 Mel scale / filterbanks 这一部分把 Feature Extraction 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 4.5 MFCC / cepstrum

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 4.5 MFCC / cepstrum 这一部分主要围绕 MFCC | Cepstrum | DCT and compact acoustic features 展开。写作上保持 coverage-first

原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 MFCC

从证据位置看，这一部分对应的课程证据区间是 00:27:46,360 – 00:34:44,480。课程在这里强调的核心内容可以概括为：MFCC | Cepstrum | DCT and compact acoustic features。这部分相当于把波形如何变成可建模特征的整条前端链路重新拆开，方便读者理解后续 acoustic model 到底在消费什么信息。

在本章结构中，这一单元被并入“4.5 MFCC / cepstrum”，目的是把同一阶段的定义、机制和权衡集中讲清。

6.2 本章小结

4.5 MFCC / cepstrum 这一部分把 Feature Extraction 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 4.6 normalization / delta / context

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 4.6 normalization / delta / context 这一部分主要围绕 Normalization | Delta features | Context stacking 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

7.1 Normalization

从证据位置看，这一部分对应的课程证据区间是 00:34:42,040 – 00:41:28,560。课程在这里强调的核心内容可以概括为：Normalization | Delta features | Context stacking。这部分相当于把波形如何变成可建模特征的整条前端链路重新拆开，方便读者理解后续 acoustic model 到底在消费什么信息。

在本章结构中，这一单元被并入“4.6 normalization / delta / context”，目的是把同一阶段的定义、机制和权衡集中讲清。

7.2 本章小结

4.6 normalization / delta / context 这一部分把 Feature Extraction 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

8 4.7 learned front ends

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 4.7 learned front ends 这一部分主要围绕 Advanced front ends | Learned features | Robustness 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

8.1 Advanced front ends

从证据位置看，这一部分对应的课程证据区间是 00:41:25,160 – 00:47:28,640。课程在这里强调的核心内容可以概括为：Advanced front ends | Learned features | Robustness。这部分相当于把波形如何变成可建模特征的整条前端链路重新拆开，方便读者理解后续 acoustic model 到底在消费什么信息。

在本章结构中，这一单元被并入“4.7 learned front ends”，目的是把同一阶段的定义、机制和权衡集中讲清。

8.2 本章小结

4.7 learned front ends 这一部分把 Feature Extraction 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

9 4.8 practical tradeoffs

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，4.8 practical tradeoffs 这一部分主要围绕 Practical tradeoffs | Why feature design still matters 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

9.1 Practical tradeoffs

从证据位置看，这一部分对应的课程证据区间是 00:47:26,599 – 00:53:28,000。课程在这里强调的核心内容可以概括为：Practical tradeoffs | Why feature design still matters。这部分相当于把波形如何变成可建模特征的整条前端链路重新拆开，方便读者理解后续 acoustic model 到底在消费什么信息。

在本章结构中，这一单元被并入“4.8 practical tradeoffs”，目的是把同一阶段的定义、机制和权衡集中讲清。

9.2 本章小结

4.8 practical tradeoffs 这一部分把 Feature Extraction 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

10 总结与延伸

Feature Extraction 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Feature Extraction 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

5 Acoustic Model Overview

课程笔记

Acoustic Model Overview

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日



11-751/18-781

Speech Recognition and Understanding

Lecture 12: Advanced Acoustic Modeling



Carnegie Mellon University
Language Technologies Institute

视频作者/频道: WAVLab

发布日期: 2023-09-13

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=GTaqSmQSHBs>

目录

1	5.0 重建前言：为什么需要 Acoustic Model Overview	2
1.1	2023 course row: Acoustic Model Overview	3
1.2	本章小结	3
2	5.1 系统视角下的 Acoustic Model	4
2.1	从系统视角比较 HMM-based systems 与 end-to-end systems, 并解释 acoustic model 在整条识别流水线中的位置	4
2.2	本章小结	4
3	5.2 经典 Advanced Acoustic Modeling	4
3.1	phonetic decision tree、context-dependent states 与 adaptation 为何是 advanced acoustic modeling 的核心	4
3.2	本章小结	5
4	5.3 从 GMM-HMM 到 DNN Acoustic Model	5
4.1	从 GMM-HMM 过渡到 DNN acoustic model, 解释 posterior、state targets 与 hybrid recipe	5
4.2	本章小结	5
5	5.4 现代 Acoustic Model 架构	5
5.1	CNN、RNN、self-attention 作为 acoustic model architecture 的扩展路径	5
5.2	本章小结	6
6	5.5 输出单元、词典与建模接口	6
6.1	output units、pronunciation lexicon 与 acoustic model interface 之间的耦合关系 . .	6
6.2	本章小结	6
7	总结与延伸	6

Source Discrepancy

2023 course page lists Acoustic Model Overview but no public 2023 recording was found. This chapter is reconstructed from the 2023 schedule row plus official WAVLab Fall 2022 same-course materials on advanced acoustic modeling, deep acoustic models, and system overview.

1 5.0 重建前言：为什么需要 Acoustic Model Overview

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 5.0 重建前言：为什么需要 Acoustic Model Overview 这一部分主要围绕 2023 course row: Acoustic Model Overview | role of the acoustic model in an ASR system 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Acoustic Model Overview Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

05-u01 | 5.0 Acoustic Model Overview
2023 course row: Acoustic Model Overview |
role of the acoustic model in an ASR system

05-u02 | 5.1 Acoustic Model
HMM-based systems end-to-end
systems acoustic model

05-u03 | 5.2 Advanced Acoustic Modeling
phonetic decision tree context-dependent
states adaptation advanced acoustic
modeling

05-u04 | 5.3 GMM-HMM DNN Acoustic Model
GMM-HMM DNN acoustic model
posterior state targets hybrid recipe

05-u05 | 5.4 Acoustic Model
CNN RNN self-attention acoustic model
architecture

05-u06 | 5.5
output units pronunciation lexicon
acoustic model interface

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Acoustic Model Overview

Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-09-13

2023 course row: Acoustic Model Overview | role of the acoustic model in an ASR system

00:00:00,000 - 00:12:00,000

systems	HMM-based systems	end-to-end
	acoustic model	

00:12:00,000 - 00:25:00,000

- phonetic decision tree
- context-dependent states
- adaptation
- advanced acoustic modeling

00:25:00,000 - 00:40:00,000

GMM-HMM DNN acoustic model
posterior state targets hybrid recipe

2022-10-31 row

CNN RNN self-attention acoustic model architecture

2022 rows

```
output units  pronunciation lexicon  acoustic
model interface
```

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 2023 course row: Acoustic Model Overview

从证据位置看，这一部分对应的课程证据区间是 2023-09-13。课程在这里强调的核心内容可以概括为：2023 course row: Acoustic Model Overview | role of the acoustic model in an ASR system。从课程组织上看，这一部分承担的是把局部概念嵌入整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出: This section is reconstructed from the 2023 course row and official same-course auxiliary materials because no public 2023 recording or slides were found.

在本章结构中，这一单元被并入“5.0 重建前言：为什么需要 Acoustic Model Overview”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

5.0 重建前言：为什么需要 Acoustic Model Overview 这一部分把 Acoustic Model Overview 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 5.1 系统视角下的 Acoustic Model

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 5.1 系统视角下的 Acoustic Model 这一部分主要围绕从系统视角比较 HMM-based systems 与 end-to-end systems, 并解释 acoustic model 在整条识别流水线中的位置。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

2.1 从系统视角比较 HMM-based systems 与 end-to-end systems, 并解释 acoustic model 在整条识别流水线中的位置

从证据位置看, 这一部分对应的课程证据区间是 00:00:00,000–00:12:00,000。课程在这里强调的核心内容可以概括为: 从系统视角比较 HMM-based systems 与 end-to-end systems, 并解释 acoustic model 在整条识别流水线中的位置。。这里的重点不是把 HMM 当作过时历史, 而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

记录系统中的附加说明指出: Grounded in official Fall 2022 same-course materials; used as auxiliary reconstruction for the missing 2023 public session.

在本章结构中, 这一单元被并入 “5.1 系统视角下的 Acoustic Model”, 目的是把同一阶段的定义、机制和权衡集中讲清。

2.2 本章小结

5.1 系统视角下的 Acoustic Model 这一部分把 Acoustic Model Overview 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

3 5.2 经典 Advanced Acoustic Modeling

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 5.2 经典 Advanced Acoustic Modeling 这一部分主要围绕 phonetic decision tree、context-dependent states 与 adaptation 为何是 advanced acoustic modeling 的核心。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

3.1 phonetic decision tree、context-dependent states 与 adaptation 为何是 advanced acoustic modeling 的核心

从证据位置看, 这一部分对应的课程证据区间是 00:12:00,000–00:25:00,000。课程在这里强调的核心内容可以概括为: phonetic decision tree、context-dependent states 与 adaptation 为何是 advanced acoustic modeling 的核心。。从课程组织上看, 这一部分承担的是把局部概念嵌回整条识别流水线中的作用, 避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出: Auxiliary reconstruction using official Fall 2022 Advanced Acoustic Modeling video and same-course page row.

在本章结构中, 这一单元被并入 “5.2 经典 Advanced Acoustic Modeling”, 目的是把同一阶段的定义、机制和权衡集中讲清。

3.2 本章小结

5.2 经典 Advanced Acoustic Modeling 这一部分把 Acoustic Model Overview 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 5.3 从 GMM-HMM 到 DNN Acoustic Model

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 5.3 从 GMM-HMM 到 DNN Acoustic Model 这一部分主要围绕从 GMM-HMM 过渡到 DNN acoustic model, 解释 posterior、state targets 与 hybrid recipe。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 从 GMM-HMM 过渡到 DNN acoustic model, 解释 posterior、state targets 与 hybrid recipe

从证据位置看，这一部分对应的课程证据区间是 00:25:00,000–00:40:00,000。课程在这里强调的核心内容可以概括为：从 GMM-HMM 过渡到 DNN acoustic model, 解释 posterior、state targets 与 hybrid recipe。。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

记录系统中的附加说明指出：Auxiliary reconstruction from official same-course materials on advanced acoustic modeling and deep learning for speech recognition.

在本章结构中，这一单元被并入“5.3 从 GMM-HMM 到 DNN Acoustic Model”，目的是把同一阶段的定义、机制和权衡集中讲清。

4.2 本章小结

5.3 从 GMM-HMM 到 DNN Acoustic Model 这一部分把 Acoustic Model Overview 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 5.4 现代 Acoustic Model 架构

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 5.4 现代 Acoustic Model 架构这一部分主要围绕 CNN、RNN、self-attention 作为 acoustic model architecture 的扩展路径。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 CNN、RNN、self-attention 作为 acoustic model architecture 的扩展路径

从证据位置看，这一部分对应的课程证据区间是 2022-10-31 row。课程在这里强调的核心内容可以概括为：CNN、RNN、self-attention 作为 acoustic model architecture 的扩展路径。。与单调模型不同，attention encoder-decoder 更强调全局条件化能力，但也因此引入了对齐自由度和部署层面的权衡。

记录系统中的附加说明指出：Taken from the official same-course 2022 row titled Advanced neural network architectures for acoustic model.

在本章结构中，这一单元被并入“5.4 现代 Acoustic Model 架构”，目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

5.4 现代 Acoustic Model 架构这一部分把 Acoustic Model Overview 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 5.5 输出单元、词典与建模接口

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，5.5 输出单元、词典与建模接口这一部分主要围绕 output units、pronunciation lexicon 与 acoustic model interface 之间的耦合关系展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 output units、pronunciation lexicon 与 acoustic model interface 之间的耦合关系

从证据位置看，这一部分对应的课程证据区间是 2022 rows。课程在这里强调的核心内容可以概括为：output units、pronunciation lexicon 与 acoustic model interface 之间的耦合关系。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：Reconstructed from official same-course system overview materials because the 2023 lecture lacks public artifacts.

在本章结构中，这一单元被并入“5.5 输出单元、词典与建模接口”，目的是把同一阶段的定义、机制和权衡集中讲清。

6.2 本章小结

5.5 输出单元、词典与建模接口这一部分把 Acoustic Model Overview 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 总结与延伸

Acoustic Model Overview 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Acoustic Model Overview 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开课以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

6 Alignment Problems

Alignment Problems

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Attention-based ASR



- Our starting point $p(W|O)$
 - Input: $O = (\mathbf{o}_t | t = 1, \dots, T)$
 - It is difficult to deal with $W = (w_i \in \mathcal{V} | i = 1, \dots, N)$
 - $T \neq N$
- Instead, we **factorize** $p(W|O)$ as follows based on a **probabilistic chain rule**

$$p(W|O) = \prod_{i=1}^N p(w_i | w_{1:i-1}, O)$$



视频作者/频道: WAVLab

发布日期: 2023-09-18

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=cnd25kvveZk>

目录

1	6.0 课程主题总览	2
1.1	Alignment Problems	3
1.2	本章小结	4
2	6.1 3-state left-to-right HMM	4
2.1	3-state left-to-right HMM	4
2.2	本章小结	4
3	6.2 forward-backward	4
3.1	Forward-backward on HMMs	4
3.2	本章小结	5
4	6.3 CTC	5
4.1	CTC	5
4.2	本章小结	5
5	6.4 transducer / RNN-T	5
5.1	Transducer / RNN-T	6
5.2	本章小结	6
6	6.5 alignment comparison and search implications	6
6.1	Alignment variables	6
6.2	本章小结	6
7	总结与延伸	7

Source Discrepancy

The public video numbering is offset relative to the official syllabus row count.

1 6.0 课程主题总览

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 6.0 课程主题总览这一部分主要围绕 Alignment Problems | 3 state left-to-right HMM | CTC | Transducer 展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

Alignment Problems Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

06-u01 | 6.0

Alignment Problems | 3 state left-to-right
HMM | CTC | Transducer

06-u02 | 6.1 3-state left-to-right HMM

3-state left-to-right HMM | Alignment
intuition

06-u03 | 6.2 forward-backward

Forward-backward on HMMs | Posterior
alignments

06-u04 | 6.3 CTC

CTC | Blank symbol | Path marginalization

06-u05 | 6.4 transducer / RNN-T

Transducer / RNN-T | Joint network |
Monotonic decoding

06-u06 | 6.5 alignment comparison and search implications

Alignment variables | Sum-rule view |
Monotonicity and comparison

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Alignment Problems Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-09-18

Alignment Problems | 3 state left-to-right HMM |
CTC | Transducer

00:00:00,120 -- 00:07:44,039

3-state left-to-right HMM | Alignment intuition

00:07:40,000 -- 00:15:08,680

Forward-backward on HMMs | Posterior alignments

00:15:05,480 -- 00:22:54,640

CTC | Blank symbol | Path marginalization

00:22:51,960 -- 00:30:38,399

Transducer / RNN-T | Joint network | Monotonic
decoding

00:30:35,720 -- 00:37:54,119

Alignment variables | Sum-rule view |
Monotonicity and comparison

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Alignment Problems

从证据位置看，这一部分对应的课程证据区间是 2023-09-18。课程在这里强调的核心内容可以概括为：Alignment Problems | 3 state left-to-right HMM | CTC | Transducer。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

记录系统中的附加说明指出：The public video numbering is offset relative to the official syllabus row count.

在本章结构中，这一单元被并入“6.0 课程主题总览”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；

- $\mathcal{B}$: 把路径压缩为最终标签序列的映射。

1.2 本章小结

6.0 课程主题总览这一部分把 Alignment Problems 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 6.1 3-state left-to-right HMM

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 6.1 3-state left-to-right HMM 这一部分主要围绕 3-state left-to-right HMM | Alignment intuition 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 3-state left-to-right HMM

从证据位置看，这一部分对应的课程证据区间是 00:00:00,120 – 00:07:44,039。课程在这里强调的核心内容可以概括为：3-state left-to-right HMM | Alignment intuition。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

在本章结构中，这一单元被并入 “6.1 3-state left-to-right HMM”，目的是把同一阶段的定义、机制和权衡集中讲清。

2.2 本章小结

6.1 3-state left-to-right HMM 这一部分把 Alignment Problems 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 6.2 forward-backward

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 6.2 forward-backward 这一部分主要围绕 Forward-backward on HMMs | Posterior alignments 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 Forward-backward on HMMs

从证据位置看，这一部分对应的课程证据区间是 00:07:40,000 – 00:15:08,680。课程在这里强调的核心内容可以概括为：Forward-backward on HMMs | Posterior alignments。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

在本章结构中，这一单元被并入 “6.2 forward-backward”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$\alpha_t(j) = \left(\sum_i \alpha_{t-1}(i) a_{ij} \right) b_j(x_t), \quad \beta_t(i) = \sum_j a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)$$

符号说明如下：

- $\alpha_t(j)$: 到时间 t 、落在状态 j 的前向概率;
- $\beta_t(i)$: 从时间 t 的状态 i 出发解释后续观测的后向概率;
- a_{ij} : 状态转移概率;
- $b_j(x_t)$: 状态 j 生成观测 x_t 的概率。

3.2 本章小结

6.2 forward-backward 这一部分把 Alignment Problems 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 6.3 CTC

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 6.3 CTC 这一部分主要围绕 CTC | Blank symbol | Path marginalization 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 CTC

从证据位置看，这一部分对应的课程证据区间是 00:15:05,480 – 00:22:54,640。课程在这里强调的核心内容可以概括为：CTC | Blank symbol | Path marginalization。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入“6.3 CTC”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X : 输入语音特征序列;
- Y : 输出标签序列;
- π : 带有 blank 的对齐路径;
- $\mathcal{B}$: 把路径压缩为最终标签序列的映射。

4.2 本章小结

6.3 CTC 这一部分把 Alignment Problems 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 6.4 transducer / RNN-T

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 6.4 transducer / RNN-T 这一部分主要围绕 Transducer / RNN-T | Joint network | Monotonic decoding 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 Transducer / RNN-T

从证据位置看,这一部分对应的课程证据区间是 00:22:51,960 – 00:30:38,399。课程在这里强调的核心内容可以概括为: Transducer / RNN-T | Joint network | Monotonic decoding。课程把 RNN-T 放在 streaming ASR 的语境里讨论,强调它保留了单调约束,却让模型可以更灵活地联合时间和输出历史。

在本章结构中,这一单元被并入“6.4 transducer / RNN-T”,目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X,Y)} \prod_{(t,u) \in \pi} P(k_{t,u} | h_t, g_u)$$

符号说明如下:

- X : 输入语音特征序列;
- Y : 目标标签序列;
- $\mathcal{A}(X,Y)$: 满足转导约束的对齐集合;
- h_t : encoder 在时间步 t 的表示;
- g_u : prediction network 在输出步 u 的表示。

5.2 本章小结

6.4 transducer / RNN-T 这一部分把 Alignment Problems 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题,也交代了方法、推理或工程权衡为什么要这样组织。

6 6.5 alignment comparison and search implications

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 6.5 alignment comparison and search implications 这一部分主要围绕 Alignment variables | Sum-rule view | Monotonicity and comparison 展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清,再压缩成适合复习的结构。

6.1 Alignment variables

从证据位置看,这一部分对应的课程证据区间是 00:30:35,720 – 00:37:54,119。课程在这里强调的核心内容可以概括为: Alignment variables | Sum-rule view | Monotonicity and comparison。从课程组织上看,这一部分承担的是把局部概念嵌入整条识别流水线中的作用,避免读者把公式或模块孤立地记忆。

在本章结构中,这一单元被并入“6.5 alignment comparison and search implications”,目的是把同一阶段的定义、机制和权衡集中讲清。

6.2 本章小结

6.5 alignment comparison and search implications 这一部分把 Alignment Problems 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题,也交代了方法、推理或工程权衡为什么要这样组织。

7 总结与延伸

Alignment Problems 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Alignment Problems 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

7 K-means, GMM, EM Algorithm

K-means, GMM, EM Algorithm

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Why we use the EM algorithm?



- We usually use a **maximum likelihood estimation** to estimate θ
$$\hat{\theta} = \operatorname{argmax}_{\theta} p(O|\theta)$$
- Introduction of **latent variable** (S in this example) makes the problem of estimating θ very difficult

$$p(O|\theta) = \sum_S p(O, S|\theta)$$

- HMM, GMM
- Instead, we use an **expectation-maximization (EM)** algorithm

$$Q(\theta, \theta') = \sum_S p(S|O, \theta') \log p(O, S|\theta)$$

- θ' is obtained by a previous iteration (iterative algorithm)

视频作者/频道: WAVLab

发布日期: 2023-09-20

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=-1jTd8zM6r4>

目录

1	Hidden Markov Models	2
1.1	K-means, GMM, EM Algorithm	2
1.2	本章小结	3
2	总结与延伸	3

Source Discrepancy

The official course page lists K-means/GMM/EM on 2023-09-20, but the public recording and transcript open with Hidden Markov Models. Treat this as a source-title discrepancy in the record system.

1 Hidden Markov Models

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Hidden Markov Models 这一部分主要围绕 K-means, GMM, EM Algorithm | K-means | GMM | EM algorithm 展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

K-means, GMM, EM Algorithm Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

07-u01 | Hidden Markov Models
K-means, GMM, EM Algorithm | K-means | GMM |
EM algorithm

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

K-means, GMM, EM Algorithm Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-09-20
K-means, GMM, EM Algorithm | K-means | GMM | EM
algorithm

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 K-means, GMM, EM Algorithm

从证据位置看, 这一部分对应的课程证据区间是 2023-09-20。课程在这里强调的核心内容可以概括为: K-means, GMM, EM Algorithm | K-means | GMM | EM algorithm。从课程组织上看, 这一部分承担的是把局部概念嵌回整条识别流水线中的作用, 避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出: The official course page lists K-means/GMM/EM on 2023-09-20, but the public recording title and transcript both open with Hidden Markov Models material. Keep this as a resolved source-title discrepancy in the record system.

在本章结构中，这一单元被并入“Hidden Markov Models”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

Hidden Markov Models 这一部分把 K-means, GMM, EM Algorithm 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 总结与延伸

K-means, GMM, EM Algorithm 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 K-means, GMM, EM Algorithm 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

8 Forward-Backward Algorithm for HMM

课程笔记

Forward-Backward Algorithm for HMM


Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Meaning of $p(s_{t-1} = i, s_t = j | O, \Theta') \triangleq \xi_{t-1}(i, j)$



- Example, the case for $t = 4$, and the transition from $/UW/_2$ to $/UW/_3$, i.e., $\xi_3(/UW/_2, /UW/_3)$
- Posterior distribution of all paths transits from $/UW/_1$ to $/UW/_2$ when $t = 3$ to $t = 4$ (**red arrow** in the following figure)
 - **Blue lines** are not considered due to the left-to-right constraint



16

视频作者/频道: WAVLab

发布日期: 2023-09-25

视频时长: unknown

视频链接: https://www.youtube.com/watch?v=6_oNjh0nf-E

目录

1	Forward-Backward Algorithm for HMM	2
1.1	Forward-Backward Algorithm for HMM	2
1.2	本章小结	3
2	总结与延伸	3

Source Discrepancy

Public video title uses Hidden Markov Models part II, while the syllabus row emphasizes the forward-backward algorithm.

1 Forward-Backward Algorithm for HMM

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Forward-Backward Algorithm for HMM 这一部分主要围绕 Forward-Backward Algorithm for HMM | Forward-backward algorithm for HMM 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Forward-Backward Algorithm for HMM Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

08-u01 | Forward-Backward Algorithm for HMM
Forward-Backward Algorithm for HMM |
Forward-backward algorithm for HMM

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Forward-Backward Algorithm for HMM Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-09-25
Forward-Backward Algorithm for HMM |
Forward-backward algorithm for HMM

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Forward-Backward Algorithm for HMM

从证据位置看，这一部分对应的课程证据区间是 2023-09-25。课程在这里强调的核心内容可以概括为：Forward-Backward Algorithm for HMM | Forward-backward algorithm for HMM。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

记录系统中的附加说明指出：Public video title uses Hidden Markov Models part II, while the syllabus row emphasizes the forward-backward algorithm; the transcript reviews the previous lecture, forward-backward computation, and BW/GMM extension material.

在本章结构中，这一单元被并入 “Forward-Backward Algorithm for HMM”，目的是把同一阶

段的定义、机制和权衡集中讲清。

$$\alpha_t(j) = \left(\sum_i \alpha_{t-1}(i) a_{ij} \right) b_j(x_t), \quad \beta_t(i) = \sum_j a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)$$

符号说明如下：

- $\alpha_t(j)$: 到时间 t 、落在状态 j 的前向概率；
- $\beta_t(i)$: 从时间 t 的状态 i 出发解释后续观测的后向概率；
- a_{ij} : 状态转移概率；
- $b_j(x_t)$: 状态 j 生成观测 x_t 的概率。

1.2 本章小结

Forward-Backward Algorithm for HMM 这一部分把 Forward-Backward Algorithm for HMM 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 总结与延伸

Forward-Backward Algorithm for HMM 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Forward-Backward for HMM I 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开课以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。



9 Forward-Backward Algorithm for HMM

Forward-Backward Algorithm for HMM

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

1. Introduce latent variable



$$S = (s_t \in \{1, \dots, J\} | t = 1, \dots, T)$$

$$V = (v_t \in \{1, \dots, K\} | t = 1, \dots, T)$$

视频作者/频道: WAVLab

发布日期: 2023-09-27

视频时长: unknown

视频链接: https://www.youtube.com/watch?v=ct_ZEdYi12Q

目录

1	Forward-Backward Algorithm for HMM	2
1.1	Forward-Backward Algorithm for HMM	2
1.2	本章小结	3
2	总结与延伸	3

Source Discrepancy

Public video title uses Hidden Markov Models part III, while the official syllabus keeps the forward-backward naming.

1 Forward-Backward Algorithm for HMM

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Forward-Backward Algorithm for HMM 这一部分主要围绕 Forward-Backward Algorithm for HMM | Forward-backward algorithm for HMM 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Forward-Backward Algorithm for HMM Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

09-u01 | Forward-Backward Algorithm for HMM
Forward-Backward Algorithm for HMM |
Forward-backward algorithm for HMM

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Forward-Backward Algorithm for HMM Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-09-27
Forward-Backward Algorithm for HMM |
Forward-backward algorithm for HMM

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Forward-Backward Algorithm for HMM

从证据位置看，这一部分对应的课程证据区间是 2023-09-27。课程在这里强调的核心内容可以概括为：Forward-Backward Algorithm for HMM | Forward-backward algorithm for HMM。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

记录系统中的附加说明指出：Public video title uses Hidden Markov Models part III, while the official syllabus keeps the forward-backward naming; the transcript emphasizes the GMM extension and Baum-Welch/BW algorithm details.

在本章结构中，这一单元被并入 “Forward-Backward Algorithm for HMM”，目的是把同一阶

段的定义、机制和权衡集中讲清。

$$\alpha_t(j) = \left(\sum_i \alpha_{t-1}(i) a_{ij} \right) b_j(x_t), \quad \beta_t(i) = \sum_j a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)$$

符号说明如下：

- $\alpha_t(j)$: 到时间 t 、落在状态 j 的前向概率；
- $\beta_t(i)$: 从时间 t 的状态 i 出发解释后续观测的后向概率；
- a_{ij} : 状态转移概率；
- $b_j(x_t)$: 状态 j 生成观测 x_t 的概率。

1.2 本章小结

Forward-Backward Algorithm for HMM 这一部分把 Forward-Backward Algorithm for HMM 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 总结与延伸

Forward-Backward Algorithm for HMM 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Forward-Backward for HMM II 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

10 Forward-Backward Algorithm for CTC and Viterbi Algorithm

Forward-Backward Algorithm for CTC and Viterbi Algorithm

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Take the derivative of the CTC loss



$$\mathcal{L}^{\text{ctc}}(\Theta) = (-\log p(W|O, \Theta)) = -\log \left(\sum_{Z \in f^{-1}(W, T)} \prod_t p(z_t|O, \Theta) \right)$$

- We face the issue of the summation over sequence Z
- We cannot deal with this case in the normal gradient descent
- We use the forward-backward algorithm

视频作者/频道: WAVLab

发布日期: 2023-10-02

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=kSIndDl35X8>

目录

1	Forward-Backward Algorithm for CTC and Viterbi Algorithm	2
1.1	Forward-Backward Algorithm for CTC and Viterbi Algorithm	2
1.2	本章小结	3
2	总结与延伸	3

1 Forward-Backward Algorithm for CTC and Viterbi Algorithm

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Forward-Backward Algorithm for CTC and Viterbi Algorithm 这一部分主要围绕 Forward-Backward Algorithm for CTC and Viterbi Algorithm | Forward-backward algorithm for CTC | Viterbi algorithm 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Forward-Backward Algorithm for CTC and Viterbi Algorithm Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

10-u01 | Forward-Backward Algorithm for CTC and Viterbi Algorithm
Forward-Backward Algorithm for CTC and
Viterbi Algorithm | Forward-backward
algorithm for CTC | Viterbi algorithm

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Forward-Backward Algorithm for CTC and Viterbi Algorithm Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-10-02
Forward-Backward Algorithm for CTC and Viterbi
Algorithm | Forward-backward algorithm for CTC |
Viterbi algorithm

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Forward-Backward Algorithm for CTC and Viterbi Algorithm

从证据位置看, 这一部分对应的课程证据区间是 2023-10-02。课程在这里强调的核心内容可以概括为: Forward-Backward Algorithm for CTC and Viterbi Algorithm | Forward-backward algorithm for CTC | Viterbi algorithm。CTC 的关键在于保持单调对齐假设, 同时把对齐路径视作潜变量并在训练时进行求和。

记录系统中的附加说明指出: The transcript recaps CTC, introduces the latent alignment variable, and then walks through forward-backward and Viterbi computation for the CTC objective.

在本章结构中, 这一单元被并入 “Forward-Backward Algorithm for CTC and Viterbi Algorithm”, 目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

1.2 本章小结

Forward-Backward Algorithm for CTC and Viterbi Algorithm 这一部分把 Forward-Backward Algorithm for CTC and Viterbi Algorithm 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 总结与延伸

Forward-Backward Algorithm for CTC and Viterbi Algorithm 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 CTC Forward-Backward and Viterbi 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

11 N-gram Language Models


课程笔记

N-gram Language Models

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

CTC forward algorithm



• Definition

$$\alpha_t(u_i) = \sum_{Z_{1:t-1} \in f^{-1}(W, T)} p(Z_{1:t-1}, z_t = u_i | O, \Theta)$$

- $Z \in f^{-1}(W, T)$ is a set of paths that generates W
- Paths a node at (t, i)
- $\sum_{Z_{1:t-1}}$: Summation of all possible paths from the beginning ($t=1$) to (t, i)



17

视频作者/频道: WAVLab

发布日期: 2023-10-02

视频时长: unknown

视频链接: https://www.youtube.com/watch?v=8_Y3g7pM88Y

目录

1	N-gram Language Models	2
1.1	N-gram Language Models	2
1.2	本章小结	3
2	总结与延伸	3

1 N-gram Language Models

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, N-gram Language Models 这一部分主要围绕 N-gram Language Models | N-gram language models 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

N-gram Language Models Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

11-u01 | N-gram Language Models
N-gram Language Models | N-gram language models

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

N-gram Language Models Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-10-02
N-gram Language Models | N-gram language models

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 N-gram Language Models

从证据位置看，这一部分对应的课程证据区间是 2023-10-02。课程在这里强调的核心内容可以概括为：N-gram Language Models | N-gram language models。课程把 n-gram language model 放在“可解释但近似”的框架里讨论，重点是条件独立假设、估计、平滑以及搜索中的作用。

记录系统中的附加说明指出：The transcript continues CTC training, then turns to N-gram language models and smoothing; the lecture closes by connecting smoothing to speech recognition systems.

在本章结构中，这一单元被并入“N-gram Language Models”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(w_1, \dots, w_T) = \prod_{t=1}^T P(w_t | w_1, \dots, w_{t-1}) \approx \prod_{t=1}^T P(w_t | w_{t-n+1}, \dots, w_{t-1})$$

符号说明如下：

- w_t : 第 t 个词；

- T : 句子长度;
- n : n -gram 的上下文窗口长度。

1.2 本章小结

N-gram Language Models 这一部分把 N-gram Language Models 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

2 总结与延伸

N-gram Language Models 这一讲在整门《Speech Recognition and Understanding》课程中的位置, 是把 N-gram Language Models 讲成一个可复用的建模模块。从教材化角度看, 本讲最重要的不是记住单一术语, 而是理解它如何嵌入完整的 automatic speech recognition pipeline: 输入语音如何被表示、模型如何被训练、解码如何得到最终转写, 以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF, 本章在正文里尽量把术语、方法和工程语境解释完整, 并把缺失项留在 omission 和 manifest 里, 而不是凭空补写。

12 Search




课程笔记

Search

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Beam search



- We can escape from heavy computations
- The early "wrong" decision can be recovered (especially the beam size is large)



11

视频作者/频道: WAVLab

发布日期: 2023-10-11

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=rRGgO8vZEW8>

目录

1	Search	2
1.1	Search	2
1.2	本章小结	3
2	总结与延伸	3

Source Discrepancy

Public video numbering appears to skip a non-public lecture slot around the midterm week.

1 Search

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Search 这一部分主要围绕 Search | Time-synchronous beam search | Label-synchronous beam search | N-best and lattice | Rescoring 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Search Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

12-u01 | Search
Search | Time-synchronous beam search |
Label-synchronous beam search | N-best and
lattice | Rescoring

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Search Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-10-11
Search | Time-synchronous beam search |
Label-synchronous beam search | N-best and
lattice | Rescoring

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Search

从证据位置看，这一部分对应的课程证据区间是 2023-10-11。课程在这里强调的核心内容可以概括为：Search | Time-synchronous beam search | Label-synchronous beam search | N-best and lattice | Rescoring。Search 这一讲把前面所有模型真正接到了 decoding pipeline 上，也就是把训练得到的分数转成最终转写结果。

记录系统中的附加说明指出：Public video numbering appears to skip a non-public lecture slot around the midterm week; the transcript focuses on search as the practical decoding step and discusses beam search, lattice/N-best, and rescoring.

在本章结构中，这一单元被并入 “Search”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

Search 这一部分把 Search 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 总结与延伸

Search 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Search 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。


13 ESPnet Hands-on Tutorial I

课程笔记

ESPnet Hands-on Tutorial I

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日



视频作者/频道: WAVLab

发布日期: 2023-10-23

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=YDN8cVjxSik>

目录

1	13.0 ESPnet recipe workflow	2
1.1	ESPnet Hands-on Tutorial I	2
1.2	本章小结	3
2	总结与延伸	3

Source Discrepancy

No public 2023 recording was found. This lecture is reconstructed from the 2023 schedule entry plus official WAVLab Fall 2022 same-course ESPnet tutorial I video and official ESPnet documentation/notebooks as auxiliary official material.

1 13.0 ESPnet recipe workflow

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 13.0 ESPnet recipe workflow 这一部分主要围绕 ESPnet Hands-on Tutorial I | Introduction of toolkit | How to make a new recipe 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

ESPnet Hands-on Tutorial I Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

13-u01 | 13.0 ESPnet recipe workflow
ESPnet Hands-on Tutorial I | Introduction of
toolkit | How to make a new recipe

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

ESPnet Hands-on Tutorial I Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-10-23
ESPnet Hands-on Tutorial I | Introduction of
toolkit | How to make a new recipe

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 ESPnet Hands-on Tutorial I

从证据位置看，这一部分对应的课程证据区间是 2023-10-23。课程在这里强调的核心内容可以概括为：ESPnet Hands-on Tutorial I | Introduction of toolkit | How to make a new recipe。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：This lecture now uses the official 2023 schedule row together with the official WAVLab Fall 2022 ESPnet tutorial I video and official ESPnet notebooks/docs as auxiliary official material.

在本章结构中，这一单元被并入“13.0 ESPnet recipe workflow”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

13.0 ESPnet recipe workflow 这一部分把 ESPnet Hands-on Tutorial I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 总结与延伸

ESPnet Hands-on Tutorial I 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 ESPnet Tutorial I 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

14 ESPnet Hands-on Tutorial II

ESPnet Hands-on Tutorial II

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日



Warm-up for ESPnet Tutorial2 (How to add new tasks/models)

Presented by Jiatong Shi
jiatongs@cs.cmu.edu

视频作者/频道: WAVLab

发布日期: 2023-10-25

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=Css3XAes7SU>

目录

1	14.0 ESPnet new task workflow	2
1.1	ESPnet Hands-on Tutorial II	2
1.2	本章小结	3
2	总结与延伸	3

Source Discrepancy

No public 2023 recording was found. This lecture is reconstructed from the 2023 schedule entry plus official WAVLab Fall 2022 same-course ESPnet tutorial II video and official ESPnet documentation/notebooks as auxiliary official material.

1 14.0 ESPnet new task workflow

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 14.0 ESPnet new task workflow 这一部分主要围绕 ESPnet Hands-on Tutorial II | How to make a new task 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

ESPnet Hands-on Tutorial II Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

14-u01 | 14.0 ESPnet new task workflow
ESPnet Hands-on Tutorial II | How to make a
new task

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

ESPnet Hands-on Tutorial II Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-10-25
ESPnet Hands-on Tutorial II | How to make a new
task

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 ESPnet Hands-on Tutorial II

从证据位置看，这一部分对应的课程证据区间是 2023-10-25。课程在这里强调的核心内容可以概括为：ESPnet Hands-on Tutorial II | How to make a new task。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：This lecture now uses the official 2023 schedule row together with the official WAVLab Fall 2022 ESPnet tutorial II video and official ESPnet notebooks/docs as auxiliary official material.

在本章结构中，这一单元被并入“14.0 ESPnet new task workflow”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

14.0 ESPnet new task workflow 这一部分把 ESPnet Hands-on Tutorial II 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 总结与延伸

ESPnet Hands-on Tutorial II 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 ESPnet Tutorial II 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

15 Deep Neural Network for Acoustic Modeling


Deep Neural Network for Acoustic Modeling

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Feed-forward neural network for acoustic model

- Configurations
 - Input features
 - Context expansion
 - Output class
 - Softmax function
 - Training criterion
 - Number of layers
 - Number of hidden states
 - Type of non-linear activations



© / 🔍 📄 📺 📢 📧

18

视频作者/频道: WAVLab

发布日期: 2023-10-30

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=HnaLmkym0Ec>

目录

1 DNN-HMM hybrid motivation	2
1.1 Deep Neural Network for Acoustic Modeling	3
1.2 DNN-HMM hybrid acoustic modeling 的动机、后验解释, 以及 acoustic model 作为分类器的基本框架	4
1.3 本章小结	4
2 State targets and posterior interpretation	4
2.1 state-level training targets、posterior / prior 归一化, 以及 HMM 输出如何与 DNN 结合并相对传统方法做对比	4
2.2 本章小结	4
3 Network structure and state outputs	4
3.1 输出状态空间、标签设计与多层网络的中间表示如何对应 acoustic states	5
3.2 本章小结	5
4 Activations and softmax output	5
4.1 激活函数、softmax 输出与层间计算, 把非线性映射变成可训练的分类器	5
4.2 本章小结	5
5 Mini-batch SGD and optimization	6
5.1 隐藏层表示、mini-batch 训练与 SGD / 学习率等优化细节	6
5.2 本章小结	6
6 Training efficiency and batching	6
6.1 训练样本划分、批训练与实现层面的效率问题	6
6.2 本章小结	6
7 Overtraining and recap	7
7.1 overtraining、学习率调整、regularization 以及整讲收束	7
7.2 本章小结	7
8 总结与延伸	7

Deep Neural Network for Acoustic Modeling

Time-aligned topic summary derived from transcript and coverage units

2023-10-30

Deep Neural Network for Acoustic Modeling | Deep neural network for acoustic modeling

00:00:00,640 - 00:07:28,840

DNN-HMM hybrid acoustic modeling

00:07:25,759 - 00:15:06,120

state-level training targets	posterior / prior
HMM	DNN

00:15:02,560 - 00:22:14,039

acoustic states

00:22:10,600 - 00:30:04,120

softmax

00:30:01,840 - 00:37:32,280

mini-batch

SGD /

00:37:28,800 - 00:44:59,720

00:44:57,559 - 00:52:04,760

overtraining

regularization

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Deep Neural Network for Acoustic Modeling

从证据位置看，这一部分对应的课程证据区间是 2023-10-30。课程在这里强调的核心内容可以概括为：Deep Neural Network for Acoustic Modeling | Deep neural network for acoustic modeling。从课程组织上看，这一部分承担的是把局部概念嵌入整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入“DNN-HMM hybrid motivation”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 DNN-HMM hybrid acoustic modeling 的动机、后验解释，以及 acoustic model 作为分类器的基本框架

从证据位置看，这一部分对应的课程证据区间是 00:00:00,640–00:07:28,840。课程在这里强调的核心内容可以概括为：DNN-HMM hybrid acoustic modeling 的动机、后验解释，以及 acoustic model 作为分类器的基本框架。。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

在本章结构中，这一单元被并入 “DNN-HMM hybrid motivation”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.3 本章小结

DNN-HMM hybrid motivation 这一部分把 Deep Neural Network for Acoustic Modeling 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 State targets and posterior interpretation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，State targets and posterior interpretation 这一部分主要围绕 state-level training targets、posterior / prior 归一化，以及 HMM 输出如何与 DNN 结合并相对传统方法做对比。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 state-level training targets、posterior / prior 归一化，以及 HMM 输出如何与 DNN 结合并相对传统方法做对比

从证据位置看，这一部分对应的课程证据区间是 00:07:25,759–00:15:06,120。课程在这里强调的核心内容可以概括为：state-level training targets、posterior / prior 归一化，以及 HMM 输出如何与 DNN 结合并相对传统方法做对比。。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

在本章结构中，这一单元被并入 “State targets and posterior interpretation”，目的是把同一阶段的定义、机制和权衡集中讲清。

2.2 本章小结

State targets and posterior interpretation 这一部分把 Deep Neural Network for Acoustic Modeling 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 Network structure and state outputs

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Network structure and state outputs 这一部分主要围绕输出状态空间、标签设计与多层网络的中间表示如何对应 acoustic states。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 输出状态空间、标签设计与多层网络的中间表示如何对应 acoustic states

从证据位置看，这一部分对应的课程证据区间是 00:15:02,560–00:22:14,039。课程在这里强调的核心内容可以概括为：输出状态空间、标签设计与多层网络的中间表示如何对应 acoustic states。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入 “Network structure and state outputs”，目的是把同一阶段的定义、机制和权衡集中讲清。

3.2 本章小结

Network structure and state outputs 这一部分把 Deep Neural Network for Acoustic Modeling 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 Activations and softmax output

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Activations and softmax output 这一部分主要围绕激活函数、softmax 输出与层间计算，把非线性映射变成可训练的分类器。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 激活函数、softmax 输出与层间计算，把非线性映射变成可训练的分类器

从证据位置看，这一部分对应的课程证据区间是 00:22:10,600–00:30:04,120。课程在这里强调的核心内容可以概括为：激活函数、softmax 输出与层间计算，把非线性映射变成可训练的分类器。。这一段的教学重点在于把 DNN acoustic model 看作对传统 GMM-HMM 的替换，而不是孤立地谈神经网络。

在本章结构中，这一单元被并入 “Activations and softmax output”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(s | x) = \frac{\exp(z_s)}{\sum_{s'} \exp(z_{s'})}$$

符号说明如下：

- x ：输入特征或隐藏表示；
- z_s ：类别 s 的 logit；
- $P(s | x)$ ：归一化后的后验概率。

4.2 本章小结

Activations and softmax output 这一部分把 Deep Neural Network for Acoustic Modeling 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 Mini-batch SGD and optimization

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Mini-batch SGD and optimization 这一部分主要围绕隐藏层表示、mini-batch 训练与 SGD / 学习率等优化细节。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 隐藏层表示、mini-batch 训练与 SGD / 学习率等优化细节

从证据位置看，这一部分对应的课程证据区间是 00:30:01,840–00:37:32,280。课程在这里强调的核心内容可以概括为：隐藏层表示、mini-batch 训练与 SGD / 学习率等优化细节。。这一段的教学重点在于把 DNN acoustic model 看作对传统 GMM-HMM 的替换，而不是孤立地谈神经网络。

在本章结构中，这一单元被并入“Mini-batch SGD and optimization”，目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

Mini-batch SGD and optimization 这一部分把 Deep Neural Network for Acoustic Modeling 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 Training efficiency and batching

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Training efficiency and batching 这一部分主要围绕训练样本划分、批训练与实现层面的效率问题。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 训练样本划分、批训练与实现层面的效率问题

从证据位置看，这一部分对应的课程证据区间是 00:37:28,800–00:44:59,720。课程在这里强调的核心内容可以概括为：训练样本划分、批训练与实现层面的效率问题。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入“Training efficiency and batching”，目的是把同一阶段的定义、机制和权衡集中讲清。

6.2 本章小结

Training efficiency and batching 这一部分把 Deep Neural Network for Acoustic Modeling 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 Overtraining and recap

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Overtraining and recap 这一部分主要围绕 overtraining、学习率调整、regularization 以及整讲收束。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

7.1 overtraining、学习率调整、regularization 以及整讲收束

从证据位置看，这一部分对应的课程证据区间是 00:44:57,559–00:52:04,760。课程在这里强调的核心内容可以概括为：overtraining、学习率调整、regularization 以及整讲收束。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入 “Overtraining and recap”，目的是把同一阶段的定义、机制和权衡集中讲清。

7.2 本章小结

Overtraining and recap 这一部分把 Deep Neural Network for Acoustic Modeling 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

8 总结与延伸

Deep Neural Network for Acoustic Modeling 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 DNN for Acoustic Modeling 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。


16 Neural Network Language Model

Neural Network Language Model

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Mean pooling across the frame for an utterance



- **Mean pooling** across the frame for an utterance

$$\bar{y}_d = \frac{\sum_{t=1}^T y_{td}}{T}$$

- This operation is often used to extract an **utterance-level feature**, e.g., speaker embedding



视频作者/频道: WAVLab

发布日期: 2023-11-01

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=JmDeT8X9Izg>

目录

1 CNNs for sequence inputs	2
1.1 Neural Network Language Model	3
1.2 从前一讲的 acoustic modeling 回到序列建模, 说明 CNN / spectrogram 输入如何延 伸到文本或声学序列	4
1.3 本章小结	4
2 CNN design choices	4
2.1 CNN 设计、batch normalization、activation、residual / gating 等结构细节	4
2.2 本章小结	4
3 Recurrent sequence models	4
3.1 time-delay / recurrent 视角下的序列模型, 以及从局部卷积到递归建模的过渡	5
3.2 本章小结	5
4 Bidirectional recurrence	5
4.1 bidirectional networks、双向信息流与长时依赖的建模问题	5
4.2 本章小结	5
5 LSTM and memory	5
5.1 LSTM / memory 机制如何缓解长程依赖, 并过渡到 neural language model 的概率 视角	6
5.2 本章小结	6
6 Neural language model formulation	6
6.1 neural language model 的表示、embedding / inner product 以及序列概率建模, 并与 n-gram / 计数式 LM 做方法对比	6
6.2 本章小结	6
7 Transformer masking and implementation	7
7.1 Transformer / masking / implementation pitfalls, 作为神经语言模型的现代收束 . . .	7
7.2 本章小结	7
8 Implementation checks and recap	7
8.1 实现检查、masking 细节与整讲收尾	7
8.2 本章小结	7
9 总结与延伸	8

1 CNNs for sequence inputs

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, CNNs for sequence inputs 这一部分主要围绕 Neural Network Language Model | Neural network language model; 从前一讲的 acoustic modeling 回到序列建模, 说明 CNN / spectrogram 输入如何延伸到文本或声学序列。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

Neural Network Language Model Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

16-u01 |
Neural Network Language Model | Neural
network language model

16-u02 | CNNs for sequence inputs
acoustic modeling CNN /
spectrogram

16-u03 | CNN design choices
CNN batch
normalization activation residual / gating

16-u04 | Recurrent sequence models
time-delay / recurrent

16-u05 | Bidirectional recurrence
bidirectional networks

16-u06 | LSTM and memory
LSTM / memory neural
language model

16-u07 | Neural language model formulation
neural language model embedding / inner
product n-gram / LM

16-u08 | Transformer masking and implementation
Transformer / masking / implementation
pitfalls

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Neural Network Language Model Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-01

Neural Network Language Model | Neural network
language model

00:00:00,960 - 00:07:03,319

acoustic modeling CNN /
spectrogram

00:06:59,680 - 00:14:30,600

CNN batch normalization activation residual /
gating

00:14:27,199 - 00:22:29,919

time-delay / recurrent

00:22:26,559 - 00:29:55,760

bidirectional networks

00:29:53,240 - 00:37:17,960

LSTM / memory neural language
model

00:37:13,839 - 00:44:42,559

neural language model embedding / inner
product n-gram / LM

00:44:40,200 - 00:51:55,240

Transformer / masking / implementation
pitfalls

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Neural Network Language Model

从证据位置看，这一部分对应的课程证据区间是 2023-11-01。课程在这里强调的核心内容可以概括为：Neural Network Language Model | Neural network language model。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入“CNNs for sequence inputs”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 从前一讲的 acoustic modeling 回到序列建模，说明 CNN / spectrogram 输入如何延伸到文本或声学序列

从证据位置看，这一部分对应的课程证据区间是 00:00:00,960–00:07:03,319。课程在这里强调的核心内容可以概括为：从前一讲的 acoustic modeling 回到序列建模，说明 CNN / spectrogram 输入如何延伸到文本或声学序列。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入“CNNs for sequence inputs”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.3 本章小结

CNNs for sequence inputs 这一部分把 Neural Network Language Model 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 CNN design choices

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，CNN design choices 这一部分主要围绕 CNN 设计、batch normalization、activation、residual / gating 等结构细节。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 CNN 设计、batch normalization、activation、residual / gating 等结构细节

从证据位置看，这一部分对应的课程证据区间是 00:06:59,680–00:14:30,600。课程在这里强调的核心内容可以概括为：CNN 设计、batch normalization、activation、residual / gating 等结构细节。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入“CNN design choices”，目的是把同一阶段的定义、机制和权衡集中讲清。

2.2 本章小结

CNN design choices 这一部分把 Neural Network Language Model 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 Recurrent sequence models

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Recurrent sequence models 这一部分主要围绕 time-delay / recurrent 视角下的序列模型，以及从局部卷积到递归建模的过渡。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 time-delay / recurrent 视角下的序列模型，以及从局部卷积到递归建模的过渡

从证据位置看，这一部分对应的课程证据区间是 00:14:27,199–00:22:29,919。课程在这里强调的核心内容可以概括为：time-delay / recurrent 视角下的序列模型，以及从局部卷积到递归建模的过渡。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入 “Recurrent sequence models”，目的是把同一阶段的定义、机制和权衡集中讲清。

3.2 本章小结

Recurrent sequence models 这一部分把 Neural Network Language Model 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 Bidirectional recurrence

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Bidirectional recurrence 这一部分主要围绕 bidirectional networks、双向信息流与长时依赖的建模问题。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 bidirectional networks、双向信息流与长时依赖的建模问题

从证据位置看，这一部分对应的课程证据区间是 00:22:26,559–00:29:55,760。课程在这里强调的核心内容可以概括为：bidirectional networks、双向信息流与长时依赖的建模问题。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入 “Bidirectional recurrence”，目的是把同一阶段的定义、机制和权衡集中讲清。

4.2 本章小结

Bidirectional recurrence 这一部分把 Neural Network Language Model 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 LSTM and memory

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，LSTM and memory 这一部分主要围绕 LSTM / memory 机制如何缓解长程依赖，并过渡到 neural language model 的概率视角。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 LSTM / memory 机制如何缓解长程依赖，并过渡到 neural language model 的概率视角

从证据位置看，这一部分对应的课程证据区间是 00:29:53,240–00:37:17,960。课程在这里强调的核心内容可以概括为：LSTM / memory 机制如何缓解长程依赖，并过渡到 neural language model 的概率视角。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入 “LSTM and memory”，目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

LSTM and memory 这一部分把 Neural Network Language Model 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 Neural language model formulation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Neural language model formulation 这一部分主要围绕 neural language model 的表示、embedding / inner product 以及序列概率建模，并与 n-gram / 计数式 LM 做方法对比。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 neural language model 的表示、embedding / inner product 以及序列概率建模，并与 n-gram / 计数式 LM 做方法对比

从证据位置看，这一部分对应的课程证据区间是 00:37:13,839–00:44:42,559。课程在这里强调的核心内容可以概括为：neural language model 的表示、embedding / inner product 以及序列概率建模，并与 n-gram / 计数式 LM 做方法对比。。课程把 n-gram language model 放在 “可解释但近似” 的框架里讨论，重点是条件独立假设、估计、平滑以及搜索中的作用。

在本章结构中，这一单元被并入 “Neural language model formulation”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(w_1, \dots, w_T) = \prod_{t=1}^T P(w_t \mid w_1, \dots, w_{t-1}) \approx \prod_{t=1}^T P(w_t \mid w_{t-n+1}, \dots, w_{t-1})$$

符号说明如下：

- w_t : 第 t 个词；
- T : 句子长度；
- n : n -gram 的上下文窗口长度。

6.2 本章小结

Neural language model formulation 这一部分把 Neural Network Language Model 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 Transformer masking and implementation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Transformer masking and implementation 这一部分主要围绕 Transformer / masking / implementation pitfalls, 作为神经语言模型的现代收束。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

7.1 Transformer / masking / implementation pitfalls, 作为神经语言模型的现代收束

从证据位置看, 这一部分对应的课程证据区间是 00:44:40,200–00:51:55,240。课程在这里强调的核心内容可以概括为: Transformer / masking / implementation pitfalls, 作为神经语言模型的现代收束。。从课程组织上看, 这一部分承担的是把局部概念嵌回整条识别流水线中的作用, 避免读者把公式或模块孤立地记忆。

在本章结构中, 这一单元被并入 “Transformer masking and implementation”, 目的是把同一阶段的定义、机制和权衡集中讲清。

7.2 本章小结

Transformer masking and implementation 这一部分把 Neural Network Language Model 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

8 Implementation checks and recap

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Implementation checks and recap 这一部分主要围绕实现检查、masking 细节与整讲收尾。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

8.1 实现检查、masking 细节与整讲收尾

从证据位置看, 这一部分对应的课程证据区间是 00:51:53,160–00:59:08,319。课程在这里强调的核心内容可以概括为: 实现检查、masking 细节与整讲收尾。。从课程组织上看, 这一部分承担的是把局部概念嵌回整条识别流水线中的作用, 避免读者把公式或模块孤立地记忆。

在本章结构中, 这一单元被并入 “Implementation checks and recap”, 目的是把同一阶段的定义、机制和权衡集中讲清。

8.2 本章小结

Implementation checks and recap 这一部分把 Neural Network Language Model 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

9 总结与延伸

Neural Network Language Model 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Neural Network Language Model 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

17 End-to-End ASR: Attention


课程笔记

End-to-End ASR: Attention

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Encoder-Decoder Network



11

视频作者/频道: WAVLab

发布日期: 2023-11-06

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=1FsamWmR07Q>

目录

1	Attention-based seq2seq overview	2
1.1	End-to-End ASR: Attention	3
1.2	attention-based ASR 的总览、encoder-decoder 复习，以及该方法相对前序模型的定位	4
1.3	本章小结	4
2	Attention computation and context vectors	4
2.1	attention 权重、context vector 与 weighted sum 如何把 encoder 信息接到 decoder .	4
2.2	本章小结	4
3	Training pathologies and alignment	4
3.1	训练阶段的对齐失败、错误模式与 attention 何时会变得不稳定	5
3.2	本章小结	5
4	Decoding and beam search	5
4.1	beam search、解码路径与 token / frame 对齐在生成式 ASR 中的作用	5
4.2	本章小结	5
5	Translation and LM connections	5
5.1	translation / language-model 连接，以及 attention-based 方法与更大生成模型的关系	6
5.2	本章小结	6
6	Transition to Transformer attention	6
6.1	从 RNN attention 过渡到 Transformer attention，说明注意力如何成为主导范式 . .	6
6.2	本章小结	6
7	Stability and encoder design bridge	6
7.1	attention 计算、稳定训练与后续现代 encoder 设计之间的连接	7
7.2	本章小结	7
8	Recap and transition	7
8.1	整讲收束	7
8.2	本章小结	7
9	总结与延伸	7

End-to-End ASR: Attention Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-06		
End-to-End ASR: Attention End-to-End ASR: Attention		
00:00:00,480 - 00:07:26,720		
attention-based ASR		encoder-decoder
00:07:23,879 - 00:14:55,639		
attention encoder	context vector decoder	weighted sum
00:14:51,560 - 00:22:33,880		
attention		
00:22:30,200 - 00:30:15,880		
beam search	token / frame	ASR
00:30:11,120 - 00:37:46,040		
translation / language-model attention-based		
00:37:43,920 - 00:44:45,720		
RNN attention	Transformer	
attention		
00:44:43,720 - 00:51:51,880		
attention		encoder

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 End-to-End ASR: Attention

从证据位置看，这一部分对应的课程证据区间是 2023-11-06。课程在这里强调的核心内容可以概括为: End-to-End ASR: Attention | End-to-End ASR: Attention。与单调模型不同，attention encoder-decoder 更强调全局条件化能力，但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中，这一单元被并入 “Attention-based seq2seq overview”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 attention-based ASR 的总览、encoder-decoder 复习，以及该方法相对前序模型的定位

从证据位置看，这一部分对应的课程证据区间是 00:00:00,480–00:07:26,720。课程在这里强调的核心内容可以概括为：attention-based ASR 的总览、encoder-decoder 复习，以及该方法相对前序模型的定位。。与单调模型不同，attention encoder-decoder 更强调全局条件化能力，但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中，这一单元被并入 “Attention-based seq2seq overview”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.3 本章小结

Attention-based seq2seq overview 这一部分把 End-to-End ASR: Attention 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 Attention computation and context vectors

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Attention computation and context vectors 这一部分主要围绕 attention 权重、context vector 与 weighted sum 如何把 encoder 信息接到 decoder。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 attention 权重、context vector 与 weighted sum 如何把 encoder 信息接到 decoder

从证据位置看，这一部分对应的课程证据区间是 00:07:23,879–00:14:55,639。课程在这里强调的核心内容可以概括为：attention 权重、context vector 与 weighted sum 如何把 encoder 信息接到 decoder。。与单调模型不同，attention encoder-decoder 更强调全局条件化能力，但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中，这一单元被并入 “Attention computation and context vectors”，目的是把同一阶段的定义、机制和权衡集中讲清。

2.2 本章小结

Attention computation and context vectors 这一部分把 End-to-End ASR: Attention 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 Training pathologies and alignment

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Training pathologies and alignment 这一部分主要围绕训练阶段的对齐失败、错误模式与 attention 何时会变得不稳定。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 训练阶段的对齐失败、错误模式与 attention 何时会变得不稳定

从证据位置看，这一部分对应的课程证据区间是 00:14:51,560–00:22:33,880。课程在这里强调的核心内容可以概括为：训练阶段的对齐失败、错误模式与 attention 何时会变得不稳定。。与单调模型不同，attention encoder-decoder 更强调全局条件化能力，但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中，这一单元被并入 “Training pathologies and alignment”，目的是把同一阶段的定义、机制和权衡集中讲清。

3.2 本章小结

Training pathologies and alignment 这一部分把 End-to-End ASR: Attention 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 Decoding and beam search

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Decoding and beam search 这一部分主要围绕 beam search、解码路径与 token / frame 对齐在生成式 ASR 中的作用。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 beam search、解码路径与 token / frame 对齐在生成式 ASR 中的作用

从证据位置看，这一部分对应的课程证据区间是 00:22:30,200–00:30:15,880。课程在这里强调的核心内容可以概括为：beam search、解码路径与 token / frame 对齐在生成式 ASR 中的作用。。Search 这一讲把前面所有模型真正接到了 decoding pipeline 上，也就是把训练得到的分数转成最终转写结果。

在本章结构中，这一单元被并入 “Decoding and beam search”，目的是把同一阶段的定义、机制和权衡集中讲清。

4.2 本章小结

Decoding and beam search 这一部分把 End-to-End ASR: Attention 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 Translation and LM connections

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Translation and LM connections 这一部分主要围绕 translation / language-model 连接，以及 attention-based 方法与更大生成模型的关系。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 translation / language-model 连接, 以及 attention-based 方法与更大生成模型的关系

从证据位置看, 这一部分对应的课程证据区间是 00:30:11,120–00:37:46,040。课程在这里强调的核心内容可以概括为: translation / language-model 连接, 以及 attention-based 方法与更大生成模型的关系。。与单调模型不同, attention encoder-decoder 更强调全局条件化能力, 但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中, 这一单元被并入 “Translation and LM connections”, 目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

Translation and LM connections 这一部分把 End-to-End ASR: Attention 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

6 Transition to Transformer attention

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Transition to Transformer attention 这一部分主要围绕从 RNN attention 过渡到 Transformer attention, 说明注意力如何成为主导范式。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

6.1 从 RNN attention 过渡到 Transformer attention, 说明注意力如何成为主导范式

从证据位置看, 这一部分对应的课程证据区间是 00:37:43,920–00:44:45,720。课程在这里强调的核心内容可以概括为: 从 RNN attention 过渡到 Transformer attention, 说明注意力如何成为主导范式。。与单调模型不同, attention encoder-decoder 更强调全局条件化能力, 但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中, 这一单元被并入 “Transition to Transformer attention”, 目的是把同一阶段的定义、机制和权衡集中讲清。

6.2 本章小结

Transition to Transformer attention 这一部分把 End-to-End ASR: Attention 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

7 Stability and encoder design bridge

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Stability and encoder design bridge 这一部分主要围绕 attention 计算、稳定训练与后续现代 encoder 设计之间的连接。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

7.1 attention 计算、稳定训练与后续现代 encoder 设计之间的连接

从证据位置看，这一部分对应的课程证据区间是 00:44:43,720–00:51:51,880。课程在这里强调的核心内容可以概括为：attention 计算、稳定训练与后续现代 encoder 设计之间的连接。。与单调模型不同，attention encoder-decoder 更强调全局条件化能力，但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中，这一单元被并入 “Stability and encoder design bridge”，目的是把同一阶段的定义、机制和权衡集中讲清。

7.2 本章小结

Stability and encoder design bridge 这一部分把 End-to-End ASR: Attention 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

8 Recap and transition

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Recap and transition 这一部分主要围绕整讲收束：attention-based ASR 的优势、局限，以及下一讲过渡。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

8.1 整讲收束

从证据位置看，这一部分对应的课程证据区间是 00:51:49,240–00:58:27,839。课程在这里强调的核心内容可以概括为：整讲收束：attention-based ASR 的优势、局限，以及下一讲过渡。。与单调模型不同，attention encoder-decoder 更强调全局条件化能力，但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中，这一单元被并入 “Recap and transition”，目的是把同一阶段的定义、机制和权衡集中讲清。

8.2 本章小结

Recap and transition 这一部分把 End-to-End ASR: Attention 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

9 总结与延伸

End-to-End ASR: Attention 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 E2E ASR: Attention 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开课以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

18 End-to-End ASR: CTC

课程笔记



End-to-End ASR: CTC

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

From transformer to conformer

- Two feed-forward layers (Macaron)
- Convolution block
- Absolute $\rightarrow$ relative positional embedding



53

视频作者/频道: WAVLab

发布日期: 2023-11-08

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=00GHpnRTAQE>

目录

1	Modern encoder variants and Conformer bridge	2
1.1	End-to-End ASR: CTC	3
1.2	补完 attention 讨论后, 引入 global/local / Branchformer-style encoder 设计, 并把 Conformer 作为现代 ASR 编码器的代表	4
1.3	实现视角与伪代码	4
1.4	本章小结	4
2	CTC formulation	5
2.1	CTC 的基本 formulation、标签序列与输入帧序列之间的长度不匹配问题	5
2.2	本章小结	5
3	Blank symbol and path marginalization	5
3.1	blank symbol、路径求和与 many-to-one alignments 如何把 CTC 变成可优化目标	5
3.2	本章小结	6
4	Dynamic programming for CTC	6
4.1	forward-backward / Viterbi 这类 dynamic programming 如何服务于 CTC 训练	6
4.2	本章小结	7
5	CTC decoding and LM fusion	7
5.1	CTC 的 decoding、beam search 与语言模型融合, 及其在实际 ASR 系统中的角色	7
5.2	本章小结	7
6	Data and robustness	8
6.1	external data、误标记 / 数据噪声与 CTC 系统鲁棒性的关系	8
6.2	本章小结	8
7	Decode-time efficiency	8
7.1	更快的决策路径、beam search 约束以及对实时推理的影响	8
7.2	本章小结	9
8	Alignment extensions and masked prediction	9
8.1	mask prediction、alignment issues 与 CTC 相关的扩展视角	9
8.2	本章小结	9
9	Recap and assignment note	9
9.1	CTC 整讲收束、优缺点与作业 / 实验提示	10
9.2	本章小结	10
10	总结与延伸	10

1 Modern encoder variants and Conformer bridge

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Modern encoder variants and Conformer bridge 这一部分主要围绕 End-to-End ASR: CTC | End-to-End ASR: CTC; 补完 attention 讨论后, 引入 global/local / Branchformer-style encoder 设计, 并把 Conformer 作为现代 ASR 编码器的代表。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

End-to-End ASR: CTC Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

18-u01 | End-to-End ASR: CTC | End-to-End ASR: CTC

18-u02 | Modern encoder variants and Conformer bridge
attention global/local /
Branchformer-style encoder Conformer
ASR

18-u03 | CTC formulation
CTC
formulation

18-u04 | Blank symbol and path marginalization
blank symbol many-to-one alignments
CTC

18-u05 | Dynamic programming for CTC
forward-backward / Viterbi dynamic
programming CTC

18-u06 | CTC decoding and LM fusion
CTC decoding beam search ASR

18-u07 | Data and robustness
external data / CTC

18-u08 | Decode-time efficiency
beam search

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

End-to-End ASR: CTC Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-08

End-to-End ASR: CTC | End-to-End ASR: CTC

00:00:01,040 - 00:07:24,120

attention global/local /
Branchformer-style encoder Conformer
ASR

00:07:21,000 - 00:14:10,000

CTC formulation

00:14:06,079 - 00:20:51,720

blank symbol many-to-one alignments
CTC

00:20:48,320 - 00:28:11,080

forward-backward / Viterbi dynamic
programming CTC

00:28:09,760 - 00:36:35,599

CTC decoding beam search ASR

00:36:31,800 - 00:43:39,040

external data / CTC

00:43:37,200 - 00:50:45,920

beam search

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 End-to-End ASR: CTC

从证据位置看, 这一部分对应的课程证据区间是 2023-11-08。课程在这里强调的核心内容可以概括为: End-to-End ASR: CTC | End-to-End ASR: CTC。CTC 的关键在于保持单调对齐假设, 同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中, 这一单元被并入 “Modern encoder variants and Conformer bridge”, 目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下:

- X : 输入语音特征序列;
- Y : 输出标签序列;
- π : 带有 blank 的对齐路径;
- B : 把路径压缩为最终标签序列的映射。

1.2 补完 attention 讨论后, 引入 global/local / Branchformer-style encoder 设计, 并把 Conformer 作为现代 ASR 编码器的代表

从证据位置看, 这一部分对应的课程证据区间是 00:00:01,040–00:07:24,120。课程在这里强调的核心内容可以概括为: 补完 attention 讨论后, 引入 global/local / Branchformer-style encoder 设计, 并把 Conformer 作为现代 ASR 编码器的代表。。与单调模型不同, attention encoder-decoder 更强调全局条件化能力, 但也因此引入了对齐自由度和部署层面的权衡。

记录系统中的附加说明指出: CS224S supplement anchor: Conformer / Branchformer / Whisper-style encoders; useful if you want a modern encoder comparison.

在本章结构中, 这一单元被并入 “Modern encoder variants and Conformer bridge”, 目的是把同一阶段的定义、机制和权衡集中讲清。

CS224S 补充

CS224S supplement anchor: Conformer / Branchformer / Whisper-style encoders; useful if you want a modern encoder comparison.

1.3 实现视角与伪代码

为了把这一讲的算法流程落到工程实现层面, 下面给出一个教材化的伪代码 (pseudocode) 摘要。它不是逐行复刻讲者的实现, 而是把 lecture 中反复强调的计算顺序、状态更新与解码决策压缩成可复查的程序骨架。

```

1 for utterance in dataset:
2     logits = encoder(utterance)
3     alpha = forward_dp(logits, target_with_blank)
4     beta = backward_dp(logits, target_with_blank)
5     loss = -log(sum_valid_paths(alpha, beta))
6     update_model(loss)

```

Listing 1: CTC training sketch

把这一段放在正文里有两个目的: 第一, 让读者把抽象的模型或动态规划递推与真实实现步骤对齐; 第二, 为后续阅读 ESPnet、Kaldi 或其它 toolkit 时建立可迁移的 mental model。

1.4 本章小结

Modern encoder variants and Conformer bridge 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

2 CTC formulation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, CTC formulation 这一部分主要围绕 CTC 的基本 formulation、标签序列与输入帧序列之间的长度不匹配问题。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 CTC 的基本 formulation、标签序列与输入帧序列之间的长度不匹配问题

从证据位置看，这一部分对应的课程证据区间是 00:07:21,000–00:14:10,000。课程在这里强调的核心内容可以概括为：CTC 的基本 formulation、标签序列与输入帧序列之间的长度不匹配问题。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “CTC formulation”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

2.2 本章小结

CTC formulation 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 Blank symbol and path marginalization

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Blank symbol and path marginalization 这一部分主要围绕 blank symbol、路径求和与 many-to-one alignments 如何把 CTC 变成可优化目标。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 blank symbol、路径求和与 many-to-one alignments 如何把 CTC 变成可优化目标

从证据位置看，这一部分对应的课程证据区间是 00:14:06,079–00:20:51,720。课程在这里强调的核心内容可以概括为：blank symbol、路径求和与 many-to-one alignments 如何把 CTC 变成可优化目标。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Blank symbol and path marginalization”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

3.2 本章小结

Blank symbol and path marginalization 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 Dynamic programming for CTC

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Dynamic programming for CTC 这一部分主要围绕 forward-backward / Viterbi 这类 dynamic programming 如何服务于 CTC 训练展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 forward-backward / Viterbi 这类 dynamic programming 如何服务于 CTC 训练

从证据位置看，这一部分对应的课程证据区间是 00:20:48,320–00:28:11,080。课程在这里强调的核心内容可以概括为：forward-backward / Viterbi 这类 dynamic programming 如何服务于 CTC 训练。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Dynamic programming for CTC”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

4.2 本章小结

Dynamic programming for CTC 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 CTC decoding and LM fusion

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, CTC decoding and LM fusion 这一部分主要围绕 CTC 的 decoding、beam search 与语言模型融合，及其在实际 ASR 系统中的角色。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 CTC 的 decoding、beam search 与语言模型融合，及其在实际 ASR 系统中的角色

从证据位置看，这一部分对应的课程证据区间是 00:28:09,760–00:36:35,599。课程在这里强调的核心内容可以概括为：CTC 的 decoding、beam search 与语言模型融合，及其在实际 ASR 系统中的角色。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

记录系统中的附加说明指出：CS224S supplement anchor: compare with the lecture on Conformer / fine-tuning base speech models.

在本章结构中，这一单元被并入“CTC decoding and LM fusion”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

CS224S 补充

CS224S supplement anchor: compare with the lecture on Conformer / fine-tuning base speech models.

5.2 本章小结

CTC decoding and LM fusion 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 Data and robustness

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Data and robustness 这一部分主要围绕 external data、误标记 / 数据噪声与 CTC 系统鲁棒性的关系。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 external data、误标记 / 数据噪声与 CTC 系统鲁棒性的关系

从证据位置看，这一部分对应的课程证据区间是 00:36:31,800–00:43:39,040。课程在这里强调的核心内容可以概括为：external data、误标记 / 数据噪声与 CTC 系统鲁棒性的关系。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Data and robustness”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

6.2 本章小结

Data and robustness 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 Decode-time efficiency

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Decode-time efficiency 这一部分主要围绕更快的决策路径、beam search 约束以及对实时推理的影响。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

7.1 更快的决策路径、beam search 约束以及对实时推理的影响

从证据位置看，这一部分对应的课程证据区间是 00:43:37,200–00:50:45,920。课程在这里强调的核心内容可以概括为：更快的决策路径、beam search 约束以及对实时推理的影响。。Search 这一讲把前面所有模型真正接到了 decoding pipeline 上，也就是把训练得到的分数转成最终转写结果。

在本章结构中，这一单元被并入 “Decode-time efficiency”，目的是把同一阶段的定义、机制和权衡集中讲清。

7.2 本章小结

Decode-time efficiency 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

8 Alignment extensions and masked prediction

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Alignment extensions and masked prediction 这一部分主要围绕 mask prediction、alignment issues 与 CTC 相关的扩展视角。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

8.1 mask prediction、alignment issues 与 CTC 相关的扩展视角

从证据位置看，这一部分对应的课程证据区间是 00:50:43,280–00:57:34,240。课程在这里强调的核心内容可以概括为：mask prediction、alignment issues 与 CTC 相关的扩展视角。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Alignment extensions and masked prediction”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

8.2 本章小结

Alignment extensions and masked prediction 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

9 Recap and assignment note

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Recap and assignment note 这一部分主要围绕 CTC 整讲收束、优缺点与作业 / 实验提示。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

9.1 CTC 整讲收束、优缺点与作业 / 实验提示

从证据位置看，这一部分对应的课程证据区间是 00:57:31,760–01:04:35,119。课程在这里强调的核心内容可以概括为：CTC 整讲收束、优缺点与作业 / 实验提示。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Recap and assignment note”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

9.2 本章小结

Recap and assignment note 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

10 总结与延伸

End-to-End ASR: CTC 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 E2E ASR: CTC 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开课以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

19 End-to-End ASR: RNN-T

End-to-End ASR: RNN-T


Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Alignment path in the RNN-transduce



- Alternative alignment paths
 - $W = (w_1, \dots, w_J)$: J -length label sequence
 - $O = (o_1, \dots, o_T)$: T -length input sequence
- Similar to CTC, consider all possible paths in the right-side trellis
 - Start: **left bottom corner**, i.e., $\langle s \rangle$ (start of sentence) at $t = 1$
 - End: **top right corner**, $\odot$
 - $\uparrow$: output token (it does not consume the input frame)!
 - $\rightarrow$: no output ($\langle \text{br} \rangle$)
- Consider all possible paths including the case that it allows the output of the token W



This is based on the notation in the original paper

视频作者/频道: WAVLab

发布日期: 2023-11-13

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=BQB0u9B0Fpc>

目录

1 RNN-T overview	2
1.1 End-to-End ASR: RNN-T	3
1.2 RNN-T 的总体结构、它和 CTC / attention 的关系，以及为什么它适合 end-to-end ASR	4
1.3 本章小结	4
2 Encoder-predictor-joiner architecture	4
2.1 encoder / prediction network / joiner 三部分如何共同定义 transducer 计算	4
2.2 本章小结	5
3 Alignment factorization	5
3.1 从 acoustic model 到 sequence-level objective，说明 RNN-T 的对齐分解	5
3.2 本章小结	6
4 Training and approximation	6
4.1 teacher forcing、近似训练与优化细节如何影响 transducer 学习	6
4.2 本章小结	6
5 Decoding and streaming	6
5.1 beam search decoding、language model integration 与在线 / streaming 场景	7
5.2 本章小结	7
6 Tradeoffs and recap	7
6.1 RNN-T 的优势、局限与和前述 attention / CTC 方法的对比收束	7
6.2 本章小结	7
7 总结与延伸	8

1 RNN-T overview

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, RNN-T overview 这一部分主要围绕 End-to-End ASR: RNN-T | End-to-End ASR: RNN-T; RNN-T 的总体结构、它和 CTC / attention 的关系, 以及为什么它适合 end-to-end ASR。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

End-to-End ASR: RNN-T Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

19-u01 |
End-to-End ASR: RNN-T | End-to-End ASR:
RNN-T

19-u02 | RNN-T overview
RNN-T CTC / attention
end-to-end ASR

19-u03 | Encoder-predictor-joiner architecture
encoder / prediction network / joiner
transducer

19-u04 | Alignment factorization
acoustic model sequence-level
objective RNN-T

19-u05 | Training and approximation
teacher forcing transducer

19-u06 | Decoding and streaming
beam search decoding language model
integration / streaming

19-u07 | Tradeoffs and recap
RNN-T attention / CTC

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

End-to-End ASR: RNN-T Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-13

End-to-End ASR: RNN-T | End-to-End ASR: RNN-T

00:00:00,880 - 00:07:57,479

RNN-T CTC / attention
end-to-end ASR

00:07:55,639 - 00:16:23,759

encoder / prediction network / joiner
transducer

00:16:20,720 - 00:23:46,039

acoustic model sequence-level objective
RNN-T

00:23:41,440 - 00:31:40,799

teacher forcing transducer

00:31:37,919 - 00:39:49,560

beam search decoding language model integration
/ streaming

00:39:46,880 - 00:46:44,839

RNN-T attention / CTC

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 End-to-End ASR: RNN-T

从证据位置看，这一部分对应的课程证据区间是 2023-11-13。课程在这里强调的核心内容可以概括为：End-to-End ASR: RNN-T | End-to-End ASR: RNN-T。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入“RNN-T overview”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：目标标签序列；

- $\mathcal{A}(X, Y)$: 满足转导约束的对齐集合;
- h_t : encoder 在时间步 t 的表示;
- g_u : prediction network 在输出步 u 的表示。

1.2 RNN-T 的总体结构、它和 CTC / attention 的关系，以及为什么它适合 end-to-end ASR

从证据位置看，这一部分对应的课程证据区间是 00:00:00,880–00:07:57,479。课程在这里强调的核心内容可以概括为：RNN-T 的总体结构、它和 CTC / attention 的关系，以及为什么它适合 end-to-end ASR。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “RNN-T overview”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X : 输入语音特征序列;
- Y : 输出标签序列;
- π : 带有 blank 的对齐路径;
- $\mathcal{B}$: 把路径压缩为最终标签序列的映射。

1.3 本章小结

RNN-T overview 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 Encoder-predictor-joiner architecture

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Encoder-predictor-joiner architecture 这一部分主要围绕 encoder / prediction network / joiner 三部分如何共同定义 transducer 计算。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 encoder / prediction network / joiner 三部分如何共同定义 transducer 计算

从证据位置看，这一部分对应的课程证据区间是 00:07:55,639–00:16:23,759。课程在这里强调的核心内容可以概括为：encoder / prediction network / joiner 三部分如何共同定义 transducer 计算。。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入“Encoder-predictor-joiner architecture”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：目标标签序列；
- $\mathcal{A}(X, Y)$ ：满足转导约束的对齐集合；
- h_t ：encoder 在时间步 t 的表示；
- g_u ：prediction network 在输出步 u 的表示。

2.2 本章小结

Encoder-predictor-joiner architecture 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 Alignment factorization

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Alignment factorization 这一部分主要围绕从 acoustic model 到 sequence-level objective，说明 RNN-T 的对齐分解。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 从 acoustic model 到 sequence-level objective，说明 RNN-T 的对齐分解

从证据位置看，这一部分对应的课程证据区间是 00:16:20,720–00:23:46,039。课程在这里强调的核心内容可以概括为：从 acoustic model 到 sequence-level objective，说明 RNN-T 的对齐分解。。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入“Alignment factorization”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：目标标签序列；
- $\mathcal{A}(X, Y)$ ：满足转导约束的对齐集合；
- h_t ：encoder 在时间步 t 的表示；
- g_u ：prediction network 在输出步 u 的表示。

3.2 本章小结

Alignment factorization 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 Training and approximation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Training and approximation 这一部分主要围绕 teacher forcing、近似训练与优化细节如何影响 transducer 学习。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 teacher forcing、近似训练与优化细节如何影响 transducer 学习

从证据位置看，这一部分对应的课程证据区间是 00:23:41,440–00:31:40,799。课程在这里强调的核心内容可以概括为：teacher forcing、近似训练与优化细节如何影响 transducer 学习。。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入 “Training and approximation”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：目标标签序列；
- $\mathcal{A}(X, Y)$ ：满足转导约束的对齐集合；
- h_t ：encoder 在时间步 t 的表示；
- g_u ：prediction network 在输出步 u 的表示。

4.2 本章小结

Training and approximation 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 Decoding and streaming

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Decoding and streaming 这一部分主要围绕 beam search decoding、language model integration 与在线 / streaming 场景。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 beam search decoding、language model integration 与在线 / streaming 场景

从证据位置看，这一部分对应的课程证据区间是 00:31:37,919–00:39:49,560。课程在这里强调的核心内容可以概括为：beam search decoding、language model integration 与在线 / streaming 场景。。Search 这一讲把前面所有模型真正接到了 decoding pipeline 上，也就是把训练得到的分数转成最终转写结果。

在本章结构中，这一单元被并入 “Decoding and streaming”，目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

Decoding and streaming 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 Tradeoffs and recap

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Tradeoffs and recap 这一部分主要围绕 RNN-T 的优势、局限与和前述 attention / CTC 方法的对比收束。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 RNN-T 的优势、局限与和前述 attention / CTC 方法的对比收束

从证据位置看，这一部分对应的课程证据区间是 00:39:46,880–00:46:44,839。课程在这里强调的核心内容可以概括为：RNN-T 的优势、局限与和前述 attention / CTC 方法的对比收束。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Tradeoffs and recap”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

6.2 本章小结

Tradeoffs and recap 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 总结与延伸

End-to-End ASR: RNN-T 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 E2E ASR: RNN-T 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

20 Advanced Topics on End-to-End ASR I

课程笔记

Advanced Topics on End-to-End ASR I

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理



2026 年 4 月 16 日

SpecAugment

Park, Daniel S., et al. "SpecAugment: A Simple Augmentation Method for Automatic Speech Recognition." *Proc. Interspeech 2019* (2019).
Shinji Watanabe



- **Randomly** apply a line mask in the **frequency** and **time** axes



- Hyper-parameter: range and how often we apply a mask
- Behaving similar to data dropout!

🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍

8

视频作者/频道: WAVLab

发布日期: 2023-11-15

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=08BIo02n-TM>

目录

1	Data variation and orientation	2
1.1	Advanced Topics on End-to-End ASR I	3
1.2	speech data 的 variation 来源、data orientation, 以及为什么鲁棒性是 advanced ASR 的起点	4
1.3	本章小结	4
2	Augmentation and robustness	4
2.1	SpecAugment / noise perturbation / augmentation 技术如何改善 ASR 训练	4
2.2	本章小结	4
3	Pronunciation and lexicon issues	4
3.1	pronunciation mapping、lexicon 质量与语言资源不齐时的建模困难	5
3.2	本章小结	5
4	Multilingual ASR motivation	5
4.1	multilingual ASR 的动机、shared components 和跨语言共享的边界	5
4.2	本章小结	5
5	Benchmarks and related tasks	5
5.1	benchmarks、评价指标、speech translation 与 direct ID 等多任务关系	6
5.2	本章小结	6
6	Whisper and speech foundation models	6
6.1	Whisper and other speech foundation-model style methods 在多语种 / 转写 / 时间戳方面的表现	6
6.2	本章小结	7
7	Fine-tuning and adaptation	7
7.1	fine-tuning、adaptation 与整讲总结	7
7.2	本章小结	7
8	总结与延伸	7

1 Data variation and orientation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Data variation and orientation 这一部分主要围绕 Advanced Topics on End-to-End ASR I | Advanced topics on end-to-end ASR I; speech data 的 variation 来源、data orientation, 以及为什么鲁棒性是 advanced ASR 的起点。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

Advanced Topics on End-to-End ASR I Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

20-u01 |
Advanced Topics on End-to-End ASR I |
Advanced topics on end-to-end ASR I

20-u02 | Data variation and orientation
speech data variation data
orientation advanced ASR

20-u03 | Augmentation and robustness
SpecAugment / noise perturbation /
augmentation ASR

20-u04 | Pronunciation and lexicon issues
pronunciation mapping lexicon

20-u05 | Multilingual ASR motivation
multilingual ASR shared components

20-u06 | Benchmarks and related tasks
benchmarks speech translation direct
ID

20-u07 | Whisper and speech foundation models
Whisper and other speech foundation-model
style methods / /

20-u08 | Fine-tuning and adaptation
fine-tuning adaptation
speech

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Advanced Topics on End-to-End ASR I Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-15

Advanced Topics on End-to-End ASR I | Advanced topics on end-to-end ASR I

00:00:00,120 - 00:07:05,000

speech data variation data
orientation advanced ASR

00:07:02,400 - 00:13:38,560

SpecAugment / noise perturbation / augmentation
ASR

00:13:36,120 - 00:20:29,760

pronunciation mapping lexicon

00:20:25,080 - 00:27:22,840

multilingual ASR shared components

00:27:20,799 - 00:33:46,440

benchmarks speech translation direct ID

00:33:44,480 - 00:40:32,920

Whisper and other speech foundation-model style
methods / /

00:40:28,680 - 00:46:55,359

fine-tuning adaptation speech

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Advanced Topics on End-to-End ASR I

从证据位置看，这一部分对应的课程证据区间是 2023-11-15。课程在这里强调的核心内容可以概括为：Advanced Topics on End-to-End ASR I | Advanced topics on end-to-end ASR I。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入“Data variation and orientation”，目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 speech data 的 variation 来源、data orientation, 以及为什么鲁棒性是 advanced ASR 的起点

从证据位置看, 这一部分对应的课程证据区间是 00:00:00,120–00:07:05,000。课程在这里强调的核心内容可以概括为: speech data 的 variation 来源、data orientation, 以及为什么鲁棒性是 advanced ASR 的起点。。从课程组织上看, 这一部分承担的是把局部概念嵌回整条识别流水线中的作用, 避免读者把公式或模块孤立地记忆。

在本章结构中, 这一单元被并入 “Data variation and orientation”, 目的是把同一阶段的定义、机制和权衡集中讲清。

1.3 本章小结

Data variation and orientation 这一部分把 Advanced Topics on End-to-End ASR I 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

2 Augmentation and robustness

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Augmentation and robustness 这一部分主要围绕 SpecAugment / noise perturbation / augmentation 技术如何改善 ASR 训练。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

2.1 SpecAugment / noise perturbation / augmentation 技术如何改善 ASR 训练

从证据位置看, 这一部分对应的课程证据区间是 00:07:02,400–00:13:38,560。课程在这里强调的核心内容可以概括为: SpecAugment / noise perturbation / augmentation 技术如何改善 ASR 训练。。从课程组织上看, 这一部分承担的是把局部概念嵌回整条识别流水线中的作用, 避免读者把公式或模块孤立地记忆。

在本章结构中, 这一单元被并入 “Augmentation and robustness”, 目的是把同一阶段的定义、机制和权衡集中讲清。

2.2 本章小结

Augmentation and robustness 这一部分把 Advanced Topics on End-to-End ASR I 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

3 Pronunciation and lexicon issues

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Pronunciation and lexicon issues 这一部分主要围绕 pronunciation mapping、lexicon 质量与语言资源不齐时的建模困难。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

3.1 pronunciation mapping、lexicon 质量与语言资源不齐时的建模困难

从证据位置看，这一部分对应的课程证据区间是 00:13:36,120–00:20:29,760。课程在这里强调的核心内容可以概括为：pronunciation mapping、lexicon 质量与语言资源不齐时的建模困难。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入 “Pronunciation and lexicon issues”，目的是把同一阶段的定义、机制和权衡集中讲清。

3.2 本章小结

Pronunciation and lexicon issues 这一部分把 Advanced Topics on End-to-End ASR I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 Multilingual ASR motivation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Multilingual ASR motivation 这一部分主要围绕 multilingual ASR 的动机、shared components 和跨语言共享的边界。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 multilingual ASR 的动机、shared components 和跨语言共享的边界

从证据位置看，这一部分对应的课程证据区间是 00:20:25,080–00:27:22,840。课程在这里强调的核心内容可以概括为：multilingual ASR 的动机、shared components 和跨语言共享的边界。。这一段更像课程的现代延伸：它把传统 ASR 课程内容与 multilingual transfer、speech foundation model、fine-tuning 实践接到了一起。

在本章结构中，这一单元被并入 “Multilingual ASR motivation”，目的是把同一阶段的定义、机制和权衡集中讲清。

4.2 本章小结

Multilingual ASR motivation 这一部分把 Advanced Topics on End-to-End ASR I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 Benchmarks and related tasks

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Benchmarks and related tasks 这一部分主要围绕 benchmarks、评价指标、speech translation 与 direct ID 等多任务关系。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 benchmarks、评价指标、speech translation 与 direct ID 等多任务关系

从证据位置看，这一部分对应的课程证据区间是 00:27:20,799–00:33:46,440。课程在这里强调的核心内容可以概括为：benchmarks、评价指标、speech translation 与 direct ID 等多任务关系。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：CS224S supplement anchor: multilingual ASR, Whisper, and foundation-model style evaluation; use this block if you want a modern comparison.

在本章结构中，这一单元被并入 “Benchmarks and related tasks”，目的是把同一阶段的定义、机制和权衡集中讲清。

CS224S 补充

CS224S supplement anchor: multilingual ASR, Whisper, and foundation-model style evaluation; use this block if you want a modern comparison.

5.2 本章小结

Benchmarks and related tasks 这一部分把 Advanced Topics on End-to-End ASR I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 Whisper and speech foundation models

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Whisper and speech foundation models 这一部分主要围绕 Whisper and other speech foundation-model style methods 在多语种 / 转写 / 时间戳方面的表现。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 Whisper and other speech foundation-model style methods 在多语种 / 转写 / 时间戳方面的表现

从证据位置看，这一部分对应的课程证据区间是 00:33:44,480–00:40:32,920。课程在这里强调的核心内容可以概括为：Whisper and other speech foundation-model style methods 在多语种 / 转写 / 时间戳方面的表现。。这一段更像课程的现代延伸：它把传统 ASR 课程内容与 multilingual transfer、speech foundation model、fine-tuning 实践接到了一起。

记录系统中的附加说明指出：CS224S supplement anchor: compare with the Spring 2025 lectures on foundation models and speech recognition beyond English.

在本章结构中，这一单元被并入 “Whisper and speech foundation models”，目的是把同一阶段的定义、机制和权衡集中讲清。

CS224S 补充

CS224S supplement anchor: compare with the Spring 2025 lectures on foundation models and speech recognition beyond English.

6.2 本章小结

Whisper and speech foundation models 这一部分把 Advanced Topics on End-to-End ASR I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 Fine-tuning and adaptation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Fine-tuning and adaptation 这一部分主要围绕 fine-tuning、adaptation 与整讲总结：如何把大模型迁移到特定 speech 任务。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

7.1 fine-tuning、adaptation 与整讲总结

从证据位置看，这一部分对应的课程证据区间是 00:40:28,680–00:46:55,359。课程在这里强调的核心内容可以概括为：fine-tuning、adaptation 与整讲总结：如何把大模型迁移到特定 speech 任务。。这一段更像课程的现代延伸：它把传统 ASR 课程内容与 multilingual transfer、speech foundation model、fine-tuning 实践接到了一起。

记录系统中的附加说明指出：CS224S supplement anchor: fine-tuning base speech models and multilingual adaptation.

在本章结构中，这一单元被并入“Fine-tuning and adaptation”，目的是把同一阶段的定义、机制和权衡集中讲清。

CS224S 补充

CS224S supplement anchor: fine-tuning base speech models and multilingual adaptation.

7.2 本章小结

Fine-tuning and adaptation 这一部分把 Advanced Topics on End-to-End ASR I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

8 总结与延伸

Advanced Topics on End-to-End ASR I 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Advanced E2E ASR I 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

21 Advanced Topics on End-to-End ASR II

Advanced Topics on End-to-End ASR II

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Speech Foundation Models

Speech



Large AI Models



4

视频作者/频道: WAVLab

发布日期: 2023-11-20

视频时长: unknown

视频链接: https://www.youtube.com/watch?v=Mtwol0Gs0_A

目录

1	Multilingual ASR recap and constraints	2
1.1	Advanced Topics on End-to-End ASR II	3
1.2	multilingual ASR 的继续讨论	3
1.3	本章小结	4
2	Whisper-style speech foundation models	4
2.1	Whisper-style speech foundation model 的开源设计、模型边界与主要取舍	4
2.2	本章小结	4
3	Inference details and timestamps	4
3.1	模型 architecture 的修改、timestamp / window shifting 等推理细节	4
3.2	本章小结	5
4	Open-source design choices and results	5
4.1	开源 demo、实验结果与具体 design choices, 说明大模型在多语种场景中的实际行为	5
4.2	本章小结	5
5	Scaling and open questions	5
5.1	scaling、emergent capabilities 与 speech 领域的开放问题	6
5.2	本章小结	6
6	总结与延伸	6

1 Multilingual ASR recap and constraints

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Multilingual ASR recap and constraints 这一部分主要围绕 Advanced Topics on End-to-End ASR II | Advanced topics on end-to-end ASR II; multilingual ASR 的继续讨论: 为什么字典 / 词表假设在很多语言里并不成立。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

Advanced Topics on End-to-End ASR II Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

21-u01 |
Advanced Topics on End-to-End ASR II |
Advanced topics on end-to-end ASR II

21-u02 | Multilingual ASR recap and constraints
multilingual ASR /

21-u03 | Whisper-style speech foundation models
Whisper-style speech foundation model

21-u04 | Inference details and timestamps
architecture timestamp / window
shifting

21-u05 | Open-source design choices and results
demo design
choices

21-u06 | Scaling and open questions
scaling emergent capabilities speech

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Advanced Topics on End-to-End ASR II

Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-20

Advanced Topics on End-to-End ASR II | Advanced topics on end-to-end ASR II

00:00:00,840 - 00:07:21,080

multilingual ASR /

00:07:18,120 - 00:15:07,120

Whisper-style speech foundation model

00:15:04,600 - 00:21:57,559

architecture timestamp / window shifting

00:21:54,520 - 00:28:46,000

demo design choices

00:28:42,919 - 00:35:51,040

scaling emergent capabilities speech

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Advanced Topics on End-to-End ASR II

从证据位置看,这一部分对应的课程证据区间是 2023-11-20。课程在这里强调的核心内容可以概括为: Advanced Topics on End-to-End ASR II | Advanced topics on end-to-end ASR II。从课程组织上看,这一部分承担的是把局部概念嵌回整条识别流水线中的作用,避免读者把公式或模块孤立地记忆。

在本章结构中,这一单元被并入“Multilingual ASR recap and constraints”,目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 multilingual ASR 的继续讨论

从证据位置看,这一部分对应的课程证据区间是 00:00:00,840-00:07:21,080。课程在这里强调的核心内容可以概括为: multilingual ASR 的继续讨论: 为什么字典 / 词表假设在很多语言里并不成立。。这一段更像课程的现代延伸: 它把传统 ASR 课程内容与 multilingual transfer、speech foundation model、fine-tuning 实践接到了一起。

在本章结构中,这一单元被并入“Multilingual ASR recap and constraints”,目的是把同一阶段的定义、机制和权衡集中讲清。

1.3 本章小结

Multilingual ASR recap and constraints 这一部分把 Advanced Topics on End-to-End ASR II 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 Whisper-style speech foundation models

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Whisper-style speech foundation models 这一部分主要围绕 Whisper-style speech foundation model 的开源设计、模型边界与主要取舍。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 Whisper-style speech foundation model 的开源设计、模型边界与主要取舍

从证据位置看，这一部分对应的课程证据区间是 00:07:18,120–00:15:07,120。课程在这里强调的核心内容可以概括为：Whisper-style speech foundation model 的开源设计、模型边界与主要取舍。。这一段更像课程的现代延伸：它把传统 ASR 课程内容与 multilingual transfer、speech foundation model、fine-tuning 实践接到了一起。

记录系统中的附加说明指出：CS224S supplement anchor: foundation models for spoken language and speech recognition beyond English.

在本章结构中，这一单元被并入 “Whisper-style speech foundation models”，目的是把同一阶段的定义、机制和权衡集中讲清。

CS224S 补充

CS224S supplement anchor: foundation models for spoken language and speech recognition beyond English.

2.2 本章小结

Whisper-style speech foundation models 这一部分把 Advanced Topics on End-to-End ASR II 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 Inference details and timestamps

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Inference details and timestamps 这一部分主要围绕模型 architecture 的修改、timestamp / window shifting 等推理细节。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 模型 architecture 的修改、timestamp / window shifting 等推理细节

从证据位置看，这一部分对应的课程证据区间是 00:15:04,600–00:21:57,559。课程在这里强调的核心内容可以概括为：模型 architecture 的修改、timestamp / window shifting 等推理细节。。从课

程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：CS224S supplement anchor: compare with modern ASR encoders, Whisper inference, and multilingual decoding strategies.

在本章结构中，这一单元被并入 “Inference details and timestamps”，目的是把同一阶段的定义、机制和权衡集中讲清。

CS224S 补充

CS224S supplement anchor: compare with modern ASR encoders, Whisper inference, and multilingual decoding strategies.

3.2 本章小结

Inference details and timestamps 这一部分把 Advanced Topics on End-to-End ASR II 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 Open-source design choices and results

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Open-source design choices and results 这一部分主要围绕开源 demo、实验结果与具体 design choices，说明大模型在多语种场景中的实际行为。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 开源 demo、实验结果与具体 design choices，说明大模型在多语种场景中的实际行为

从证据位置看，这一部分对应的课程证据区间是 00:21:54,520–00:28:46,000。课程在这里强调的核心内容可以概括为：开源 demo、实验结果与具体 design choices，说明大模型在多语种场景中的实际行为。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入 “Open-source design choices and results”，目的是把同一阶段的定义、机制和权衡集中讲清。

4.2 本章小结

Open-source design choices and results 这一部分把 Advanced Topics on End-to-End ASR II 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 Scaling and open questions

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Scaling and open questions 这一部分主要围绕 scaling、emergent capabilities 与 speech 领域的开放问题。展开。写作上保持 coverage-

first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 scaling、emergent capabilities 与 speech 领域的开放问题

从证据位置看，这一部分对应的课程证据区间是 00:28:42,919–00:35:51,040。课程在这里强调的核心内容可以概括为：scaling、emergent capabilities 与 speech 领域的开放问题。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：CS224S supplement anchor: foundation models, multilingual ASR, and low-resource language varieties.

在本章结构中，这一单元被并入 “Scaling and open questions”，目的是把同一阶段的定义、机制和权衡集中讲清。

CS224S 补充

CS224S supplement anchor: foundation models, multilingual ASR, and low-resource language varieties.

5.2 本章小结

Scaling and open questions 这一部分把 Advanced Topics on End-to-End ASR II 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 总结与延伸

Advanced Topics on End-to-End ASR II 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Advanced E2E ASR II 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。

课程笔记

Guest Lecture I

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

公开视频封面不可用。

视频作者/频道: WAVLab

发布日期: 2023-11-27

视频时长: unknown

视频链接:

目录

1	22.0 重建前言：源缺失与重建边界	2
1.1	2023 course row: Guest Lecture	3
1.2	本章小结	3
2	22.1 Guest Lecture Reconstruction: Robust Training, Speech Enhancement, Separation, and Multichannel Processing	4
2.1	同门课 2022 官方 guest lecture row 指出主题聚焦 robust training method、speech enhancement and separation、multichannel processing	4
2.2	本章小结	4
3	22.2 研究主题一：Speech Enhancement and Separation	4
3.1	讲者官方主页把研究方向明确落在 speech enhancement、speech separation、robust ASR 与 array processing	4
3.2	本章小结	5
4	22.3 研究主题二：Multichannel Processing	5
4.1	TF-GridNet demo page 提供了多通道 separation / dereverberation / enhancement 的官方公开例子	5
4.2	本章小结	5
5	22.4 研究主题三：Robust Training and Data Efficiency	5
5.1	UNSSOR demo page 提供了 unsupervised neural speech separation 的公开研究材料, 可用来支撑 robust training 相关讨论	6
5.2	本章小结	6
6	总结与延伸	6

Source Discrepancy

2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest lecture metadata for Zhong-Qiu Wang, and the guest's official public research pages.

1 22.0 重建前言：源缺失与重建边界

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 22.0 重建前言：源缺失与重建边界这一部分主要围绕 2023 course row: Guest Lecture | no public title/video/slide on the 2023 page. 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Guest Lecture I Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

22-u01 | 22.0

2023 course row: Guest Lecture | no public title/video/slide on the 2023 page.

22-u02 | 22.1 Guest Lecture Reconstruction: Robust Training, Speech Enhancement, Separation, and Multichannel Processing

2022 guest lecture row robust
training method speech enhancement and separation multichannel processing

22-u03 | 22.2

Speech Enhancement and Separation
speech enhancement speech
separation robust ASR array processing

22-u04 | 22.3

TF-GridNet demo page separation /
dereverberation / enhancement

22-u05 | 22.4

UNSSOR demo page
speech separation
training

Robust Training and Data Efficiency
unsupervised neural
robust

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Guest Lecture I Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-27

2023 course row: Guest Lecture | no public title/video/slide on the 2023 page.

2022-11-28 row

2022 guest lecture row robust
training method speech enhancement and
separation multichannel processing

research summary

separation robust ASR speech enhancement speech
array processing

demo page

TF-GridNet demo page separation /
dereverberation / enhancement

demo page

UNSSOR demo page unsupervised neural speech
separation robust training

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 2023 course row: Guest Lecture

从证据位置看,这一部分对应的课程证据区间是 2023-11-27。课程在这里强调的核心内容可以概括为: 2023 course row: Guest Lecture | no public title/video/slide on the 2023 page.。从课程组织上看,这一部分承担的是把局部概念嵌回整条识别流水线中的作用,避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出: This chapter is an explicitly labeled reconstruction, not a verbatim transcript of a recovered 2023 public lecture.

在本章结构中,这一单元被并入“22.0 重建前言: 源缺失与重建边界”,目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

22.0 重建前言: 源缺失与重建边界这一部分把 Guest Lecture I 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题,也交代了方法、推理或工程权衡为什么要这样组织。

2 22.1 Guest Lecture Reconstruction: Robust Training, Speech Enhancement, Separation, and Multichannel Processing

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 22.1 Guest Lecture Reconstruction: Robust Training, Speech Enhancement, Separation, and Multichannel Processing 这一部分主要围绕同门课 2022 官方 guest lecture row 指出主题聚焦 robust training method、speech enhancement and separation、multichannel processing。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 同门课 2022 官方 guest lecture row 指出主题聚焦 robust training method、speech enhancement and separation、multichannel processing

从证据位置看，这一部分对应的课程证据区间是 2022-11-28 row。课程在这里强调的核心内容可以概括为：同门课 2022 官方 guest lecture row 指出主题聚焦 robust training method、speech enhancement and separation、multichannel processing。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest lecture metadata for Zhong-Qiu Wang, and the guest's official public research pages.

在本章结构中，这一单元被并入“22.1 Guest Lecture Reconstruction: Robust Training, Speech Enhancement, Separation, and Multichannel Processing”，目的是把同一阶段的定义、机制和权衡集中讲清。

2.2 本章小结

22.1 Guest Lecture Reconstruction: Robust Training, Speech Enhancement, Separation, and Multichannel Processing 这一部分把 Guest Lecture I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 22.2 研究主题一：Speech Enhancement and Separation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 22.2 研究主题一：Speech Enhancement and Separation 这一部分主要围绕讲者官方主页把研究方向明确落在 speech enhancement、speech separation、robust ASR 与 array processing。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 讲者官方主页把研究方向明确落在 speech enhancement、speech separation、robust ASR 与 array processing

从证据位置看，这一部分对应的课程证据区间是 research summary。课程在这里强调的核心内容可以概括为：讲者官方主页把研究方向明确落在 speech enhancement、speech separation、robust ASR 与 array processing。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest lecture metadata for Zhong-Qiu Wang, and the guest's official public research pages.

在本章结构中，这一单元被并入“22.2 研究主题一：Speech Enhancement and Separation”，目的是把同一阶段的定义、机制和权衡集中讲清。

3.2 本章小结

22.2 研究主题一：Speech Enhancement and Separation 这一部分把 Guest Lecture I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 22.3 研究主题二：Multichannel Processing

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，22.3 研究主题二：Multichannel Processing 这一部分主要围绕 TF-GridNet demo page 提供了多通道 separation / dereverberation / enhancement 的官方公开例子。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 TF-GridNet demo page 提供了多通道 separation / dereverberation / enhancement 的官方公开例子

从证据位置看，这一部分对应的课程证据区间是 demo page。课程在这里强调的核心内容可以概括为：TF-GridNet demo page 提供了多通道 separation / dereverberation / enhancement 的官方公开例子。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest lecture metadata for Zhong-Qiu Wang, and the guest's official public research pages.

在本章结构中，这一单元被并入“22.3 研究主题二：Multichannel Processing”，目的是把同一阶段的定义、机制和权衡集中讲清。

4.2 本章小结

22.3 研究主题二：Multichannel Processing 这一部分把 Guest Lecture I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 22.4 研究主题三：Robust Training and Data Efficiency

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，22.4 研究主题三：Robust Training and Data Efficiency 这一部分主要围绕 UNSSOR demo page 提供了 unsupervised neural speech separation 的公开研究材料，可用来支撑 robust training 相关讨论。展开。写作上保持 coverage-first

原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 UNSSOR demo page 提供了 unsupervised neural speech separation 的公开研究材料，可用来支撑 robust training 相关讨论

从证据位置看，这一部分对应的课程证据区间是 demo page。课程在这里强调的核心内容可以概括为：UNSSOR demo page 提供了 unsupervised neural speech separation 的公开研究材料，可用来支撑 robust training 相关讨论。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest lecture metadata for Zhong-Qiu Wang, and the guest's official public research pages.

在本章结构中，这一单元被并入“22.4 研究主题三：Robust Training and Data Efficiency”，目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

22.4 研究主题三：Robust Training and Data Efficiency 这一部分把 Guest Lecture I 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 总结与延伸

Guest Lecture I 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Guest Lecture I 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。

23 Guest Lecture II

课程笔记

Guest Lecture II

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

公开视频封面不可用。

视频作者/频道: WAVLab

发布日期: 2023-11-29

视频时长: unknown

视频链接:

目录

1	23.0 重建前言：从课程排程到工业语音系统	2
1.1	2023 course row: Guest Lecture	3
1.2	本章小结	3
2	23.1 Guest Lecture Reconstruction: Industrial Speech Systems and Clinical Documentation	4
2.1	同门课 2022 官方 guest lecture row 明确写出 Thomas Shaf at 3M	4
2.2	本章小结	4
3	23.2 Clinical Speech Recognition and Documentation	4
3.1	Fluency Direct fact sheet 直接描述 front-end speech recognition、clinical documentation、NLU 与 CAPD	4
3.2	本章小结	5
4	23.3 Ambient AI and Workflow Integration	5
4.1	Fluency Align fact sheet 讨论 ambient clinical documentation、virtual assistant、workflow integration	5
4.2	本章小结	5
5	23.4 Industrial Deep Learning for Speech Understanding	5
5.1	Fluency Direct deep learning fact sheet 把 speech recognition 与 speech understanding / deep learning 结合起来	6
5.2	本章小结	6
6	总结与延伸	6

Source Discrepancy

2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest lecture metadata naming Thomas Shaf at 3M | MModal, and official 3M / Solventum product documentation.

1 23.0 重建前言：从课程排程到工业语音系统

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 23.0 重建前言：从课程排程到工业语音系统这一部分主要围绕 2023 course row: Guest Lecture | no public title/video/slide on the 2023 page. 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Guest Lecture II Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

23-u01 | 23.0

2023 course row: Guest Lecture | no public title/video/slide on the 2023 page.

23-u02 | 23.1 Guest Lecture Reconstruction: Industrial Speech Systems and Clinical Documentation
2022 guest lecture row Thomas Shaf at 3M | MModal speech system

23-u03 | 23.2 Clinical Speech Recognition and Documentation
Fluency Direct fact sheet front-end
speech recognition clinical
documentation NLU CAPD

23-u04 | 23.3 Ambient AI and Workflow Integration
Fluency Align fact sheet ambient clinical
documentation virtual assistant workflow
integration

23-u05 | 23.4 Industrial Deep Learning for Speech Understanding
Fluency Direct deep learning fact sheet
speech recognition speech understanding /
deep learning

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Guest Lecture II Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-29

2023 course row: Guest Lecture | no public title/video/slide on the 2023 page.

2022-11-30 row

2022 guest lecture row Thomas Shaf
at 3M | MModal speech system

product fact sheet

Fluency Direct fact sheet front-end speech
recognition clinical documentation NLU CAPD

product fact sheet

Fluency Align fact sheet ambient clinical
documentation virtual assistant workflow
integration

product fact sheet

Fluency Direct deep learning fact sheet speech
recognition speech understanding / deep
learning

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 2023 course row: Guest Lecture

从证据位置看,这一部分对应的课程证据区间是 2023-11-29。课程在这里强调的核心内容可以概括为: 2023 course row: Guest Lecture | no public title/video/slide on the 2023 page.。从课程组织上看,这一部分承担的是把局部概念嵌回整条识别流水线中的作用,避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出: This chapter is an explicitly labeled reconstruction, not a recovered 2023 verbatim lecture.

在本章结构中,这一单元被并入“23.0 重建前言: 从课程排程到工业语音系统”,目的是把同一阶段的定义、机制和权衡集中讲清。

1.2 本章小结

23.0 重建前言: 从课程排程到工业语音系统这一部分把 Guest Lecture II 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题,也交代了方法、推理或工程权衡为什么要这样组织。

2 23.1 Guest Lecture Reconstruction: Industrial Speech Systems and Clinical Documentation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 23.1 Guest Lecture Reconstruction: Industrial Speech Systems and Clinical Documentation 这一部分主要围绕同门课 2022 官方 guest lecture row 明确写出 Thomas Shaf at 3M | MModal, 说明这一块是工业 speech system 主题。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

2.1 同门课 2022 官方 guest lecture row 明确写出 Thomas Shaf at 3M

从证据位置看, 这一部分对应的课程证据区间是 2022-11-30 row。课程在这里强调的核心内容可以概括为: 同门课 2022 官方 guest lecture row 明确写出 Thomas Shaf at 3M | MModal, 说明这一块是工业 speech system 主题。。从课程组织上看, 这一部分承担的是把局部概念嵌回整条识别流水线中的作用, 避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出: 2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest lecture metadata naming Thomas Shaf at 3M | MModal, and official 3M / Solventum product documentation.

在本章结构中, 这一单元被并入“23.1 Guest Lecture Reconstruction: Industrial Speech Systems and Clinical Documentation”, 目的是把同一阶段的定义、机制和权衡集中讲清。

2.2 本章小结

23.1 Guest Lecture Reconstruction: Industrial Speech Systems and Clinical Documentation 这一部分把 Guest Lecture II 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

3 23.2 Clinical Speech Recognition and Documentation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 23.2 Clinical Speech Recognition and Documentation 这一部分主要围绕 Fluency Direct fact sheet 直接描述 front-end speech recognition、clinical documentation、NLU 与 CAPD。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

3.1 Fluency Direct fact sheet 直接描述 front-end speech recognition、clinical documentation、NLU 与 CAPD

从证据位置看, 这一部分对应的课程证据区间是 product fact sheet。课程在这里强调的核心内容可以概括为: Fluency Direct fact sheet 直接描述 front-end speech recognition、clinical documentation、NLU 与 CAPD。。从课程组织上看, 这一部分承担的是把局部概念嵌回整条识别流水线中的作用, 避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出: 2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest

lecture metadata naming Thomas Shaf at 3M | MModal, and official 3M / Solventum product documentation.

在本章结构中，这一单元被并入“23.2 Clinical Speech Recognition and Documentation”，目的是把同一阶段的定义、机制和权衡集中讲清。

3.2 本章小结

23.2 Clinical Speech Recognition and Documentation 这一部分把 Guest Lecture II 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 23.3 Ambient AI and Workflow Integration

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，23.3 Ambient AI and Workflow Integration 这一部分主要围绕 Fluency Align fact sheet 讨论 ambient clinical documentation、virtual assistant、workflow integration。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 Fluency Align fact sheet 讨论 ambient clinical documentation、virtual assistant、workflow integration

从证据位置看，这一部分对应的课程证据区间是 product fact sheet。课程在这里强调的核心内容可以概括为：Fluency Align fact sheet 讨论 ambient clinical documentation、virtual assistant、workflow integration。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest lecture metadata naming Thomas Shaf at 3M | MModal, and official 3M / Solventum product documentation.

在本章结构中，这一单元被并入“23.3 Ambient AI and Workflow Integration”，目的是把同一阶段的定义、机制和权衡集中讲清。

4.2 本章小结

23.3 Ambient AI and Workflow Integration 这一部分把 Guest Lecture II 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 23.4 Industrial Deep Learning for Speech Understanding

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，23.4 Industrial Deep Learning for Speech Understanding 这一部分主要围绕 Fluency Direct deep learning fact sheet 把 speech recognition 与 speech understanding / deep learning 结合起来。展开。写作上保持 coverage-first 原

则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 Fluency Direct deep learning fact sheet 把 speech recognition 与 speech understanding / deep learning 结合起来

从证据位置看，这一部分对应的课程证据区间是 product fact sheet。课程在这里强调的核心内容可以概括为：Fluency Direct deep learning fact sheet 把 speech recognition 与 speech understanding / deep learning 结合起来。。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

记录系统中的附加说明指出：2023 course page exposes only a Guest Lecture placeholder. This chapter is reconstructed from the official 2023 schedule row, the official same-course 2022 guest lecture metadata naming Thomas Shaf at 3M | MModal, and official 3M / Solventum product documentation.

在本章结构中，这一单元被并入“23.4 Industrial Deep Learning for Speech Understanding”，目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

23.4 Industrial Deep Learning for Speech Understanding 这一部分把 Guest Lecture II 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 总结与延伸

Guest Lecture II 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Guest Lecture II 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。