

课程笔记

End-to-End ASR: RNN-T


Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Alignment path in the RNN-transduce



- Alternative alignment paths
 - $W = (w_1, \dots, w_J)$: J -length label sequence
 - $O = (o_1, \dots, o_T)$: T -length input sequence
- Similar to CTC, consider all possible paths in the right-side trellis
 - Start: **left bottom corner**, i.e., $\langle s \rangle$ (start of sentence) at $t = 1$
 - End: **top right corner**, $\odot$
 - $\uparrow$: output token (it does not consume the input frame)!
 - $\rightarrow$: no output ($\langle \text{br} \rangle$)
- Consider all possible paths including the case that it allows the output of the token W



This is based on the notation in the original paper

视频作者/频道: WAVLab

发布日期: 2023-11-13

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=BQB0u9B0Fpc>

目录

1	RNN-T overview	2
1.1	End-to-End ASR: RNN-T	3
1.2	RNN-T 的总体结构、它和 CTC / attention 的关系，以及为什么它适合 end-to-end ASR	4
1.3	本章小结	4
2	Encoder-predictor-joiner architecture	4
2.1	encoder / prediction network / joiner 三部分如何共同定义 transducer 计算	4
2.2	本章小结	5
3	Alignment factorization	5
3.1	从 acoustic model 到 sequence-level objective，说明 RNN-T 的对齐分解	5
3.2	本章小结	6
4	Training and approximation	6
4.1	teacher forcing、近似训练与优化细节如何影响 transducer 学习	6
4.2	本章小结	6
5	Decoding and streaming	6
5.1	beam search decoding、language model integration 与在线 / streaming 场景	7
5.2	本章小结	7
6	Tradeoffs and recap	7
6.1	RNN-T 的优势、局限与和前述 attention / CTC 方法的对比收束	7
6.2	本章小结	7
7	总结与延伸	8

1 RNN-T overview

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, RNN-T overview 这一部分主要围绕 End-to-End ASR: RNN-T | End-to-End ASR: RNN-T; RNN-T 的总体结构、它和 CTC / attention 的关系, 以及为什么它适合 end-to-end ASR。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

End-to-End ASR: RNN-T Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

19-u01 |
End-to-End ASR: RNN-T | End-to-End ASR:
RNN-T

19-u02 | RNN-T overview
RNN-T CTC / attention
end-to-end ASR

19-u03 | Encoder-predictor-joiner architecture
encoder / prediction network / joiner
transducer

19-u04 | Alignment factorization
acoustic model sequence-level
objective RNN-T

19-u05 | Training and approximation
teacher forcing transducer

19-u06 | Decoding and streaming
beam search decoding language model
integration / streaming

19-u07 | Tradeoffs and recap
RNN-T attention / CTC

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

End-to-End ASR: RNN-T Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-13

End-to-End ASR: RNN-T | End-to-End ASR: RNN-T

00:00:00,880 - 00:07:57,479

RNN-T CTC / attention
end-to-end ASR

00:07:55,639 - 00:16:23,759

encoder / prediction network / joiner
transducer

00:16:20,720 - 00:23:46,039

acoustic model sequence-level objective
RNN-T

00:23:41,440 - 00:31:40,799

teacher forcing transducer

00:31:37,919 - 00:39:49,560

beam search decoding language model integration
/ streaming

00:39:46,880 - 00:46:44,839

RNN-T attention / CTC

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 End-to-End ASR: RNN-T

从证据位置看，这一部分对应的课程证据区间是 2023-11-13。课程在这里强调的核心内容可以概括为：End-to-End ASR: RNN-T | End-to-End ASR: RNN-T。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入“RNN-T overview”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X : 输入语音特征序列；
- Y : 目标标签序列；

- $\mathcal{A}(X, Y)$: 满足转导约束的对齐集合;
- h_t : encoder 在时间步 t 的表示;
- g_u : prediction network 在输出步 u 的表示。

1.2 RNN-T 的总体结构、它和 CTC / attention 的关系，以及为什么它适合 end-to-end ASR

从证据位置看，这一部分对应的课程证据区间是 00:00:00,880–00:07:57,479。课程在这里强调的核心内容可以概括为：RNN-T 的总体结构、它和 CTC / attention 的关系，以及为什么它适合 end-to-end ASR。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “RNN-T overview”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X : 输入语音特征序列;
- Y : 输出标签序列;
- π : 带有 blank 的对齐路径;
- $\mathcal{B}$: 把路径压缩为最终标签序列的映射。

1.3 本章小结

RNN-T overview 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

2 Encoder-predictor-joiner architecture

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Encoder-predictor-joiner architecture 这一部分主要围绕 encoder / prediction network / joiner 三部分如何共同定义 transducer 计算。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 encoder / prediction network / joiner 三部分如何共同定义 transducer 计算

从证据位置看，这一部分对应的课程证据区间是 00:07:55,639–00:16:23,759。课程在这里强调的核心内容可以概括为：encoder / prediction network / joiner 三部分如何共同定义 transducer 计算。。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入“Encoder-predictor-joiner architecture”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：目标标签序列；
- $\mathcal{A}(X, Y)$ ：满足转导约束的对齐集合；
- h_t ：encoder 在时间步 t 的表示；
- g_u ：prediction network 在输出步 u 的表示。

2.2 本章小结

Encoder-predictor-joiner architecture 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 Alignment factorization

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Alignment factorization 这一部分主要围绕从 acoustic model 到 sequence-level objective，说明 RNN-T 的对齐分解。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 从 acoustic model 到 sequence-level objective，说明 RNN-T 的对齐分解

从证据位置看，这一部分对应的课程证据区间是 00:16:20,720–00:23:46,039。课程在这里强调的核心内容可以概括为：从 acoustic model 到 sequence-level objective，说明 RNN-T 的对齐分解。。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入“Alignment factorization”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：目标标签序列；
- $\mathcal{A}(X, Y)$ ：满足转导约束的对齐集合；
- h_t ：encoder 在时间步 t 的表示；
- g_u ：prediction network 在输出步 u 的表示。

3.2 本章小结

Alignment factorization 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 Training and approximation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Training and approximation 这一部分主要围绕 teacher forcing、近似训练与优化细节如何影响 transducer 学习。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 teacher forcing、近似训练与优化细节如何影响 transducer 学习

从证据位置看，这一部分对应的课程证据区间是 00:23:41,440–00:31:40,799。课程在这里强调的核心内容可以概括为：teacher forcing、近似训练与优化细节如何影响 transducer 学习。。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入 “Training and approximation”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：目标标签序列；
- $\mathcal{A}(X, Y)$ ：满足转导约束的对齐集合；
- h_t ：encoder 在时间步 t 的表示；
- g_u ：prediction network 在输出步 u 的表示。

4.2 本章小结

Training and approximation 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 Decoding and streaming

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Decoding and streaming 这一部分主要围绕 beam search decoding、language model integration 与在线 / streaming 场景。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 beam search decoding、language model integration 与在线 / streaming 场景

从证据位置看，这一部分对应的课程证据区间是 00:31:37,919–00:39:49,560。课程在这里强调的核心内容可以概括为：beam search decoding、language model integration 与在线 / streaming 场景。。Search 这一讲把前面所有模型真正接到了 decoding pipeline 上，也就是把训练得到的分数转成最终转写结果。

在本章结构中，这一单元被并入 “Decoding and streaming”，目的是把同一阶段的定义、机制和权衡集中讲清。

5.2 本章小结

Decoding and streaming 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 Tradeoffs and recap

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Tradeoffs and recap 这一部分主要围绕 RNN-T 的优势、局限与和前述 attention / CTC 方法的对比收束。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 RNN-T 的优势、局限与和前述 attention / CTC 方法的对比收束

从证据位置看，这一部分对应的课程证据区间是 00:39:46,880–00:46:44,839。课程在这里强调的核心内容可以概括为：RNN-T 的优势、局限与和前述 attention / CTC 方法的对比收束。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Tradeoffs and recap”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

6.2 本章小结

Tradeoffs and recap 这一部分把 End-to-End ASR: RNN-T 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 总结与延伸

End-to-End ASR: RNN-T 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 E2E ASR: RNN-T 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。