

课程笔记

Speech Recognition Formulations

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理

2026 年 4 月 16 日

Other rules



- **Bayes rule**

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)} = \frac{p(y|x)p(x)}{\sum_x p(y|x)p(x)}$$

- **Probabilistic chain rule**

$$p(x_1, \dots, x_N) = \prod_{n=1}^N p(x_n | x_{1:n-1}) \quad \text{where} \quad p(x_1 | x_{1:0}) = p(x_1)$$

- Both are derived with a combination of the product and/or sum rules

🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍

视频作者/频道: WAVLab

发布日期: 2023-09-06

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=GjcOmSTsoms>

目录

1	3.0 课程主题总览	2
1.1	Speech Recognition Formulations	3
1.2	本章小结	4
2	3.1 概率化建模基础 (probabilistic rules)	4
2.1	Probabilistic rules	4
2.2	本章小结	4
3	3.2 Bayes decision theory 与 noisy channel	5
3.1	Bayes decision theory	5
3.2	本章小结	5
4	3.3 HMM + n-gram baseline	5
4.1	HMM + n-gram baseline	5
4.2	本章小结	6
5	3.4 CTC (Connectionist Temporal Classification)	6
5.1	CTC	6
5.2	本章小结	7
6	3.5 RNN-T / transducer	7
6.1	RNN-T	7
6.2	本章小结	7
7	3.6 attention-based seq2seq	7
7.1	Attention-based seq2seq	8
7.2	本章小结	8
8	3.7 统一视角与 tradeoffs	8
8.1	Unified view	8
8.2	本章小结	8
9	总结与延伸	8

1 3.0 课程主题总览

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 3.0 课程主题总览这一部分主要围绕 Speech Recognition Formulations | Probabilistic rules | From Bayes decision theory to HMM + n-gram, CTC, RNN-T, and attention 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

Speech Recognition Formulations Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

03-u01 | 3.0

Speech Recognition Formulations |
Probabilistic rules | From Bayes decision
theory to HMM + n-gram, CTC, RNN-T, and
attention

03-u02 | 3.1 probabilistic rules
Probabilistic rules | Sequence modeling
setup | Bayes decision theory

03-u03 | 3.2 Bayes decision theory noisy channel
Bayes decision theory | Noisy channel
factorization | Chain rule

03-u04 | 3.3 HMM + n-gram baseline
HMM + n-gram baseline | Tractable
decomposition | Sequence probability

03-u05 | 3.4 CTC Connectionist Temporal Classification
CTC | Monotonic alignments | Path summation

03-u06 | 3.5 RNN-T / transducer
RNN-T | Prediction network | Transducer
objective

03-u07 | 3.6 attention-based seq2seq
Attention-based seq2seq | Soft alignments |
Decoding tradeoffs

03-u08 | 3.7 tradeoffs
Unified view | Model tradeoffs |
Low-resource and practical remarks

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

Speech Recognition Formulations Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-09-06

Speech Recognition Formulations | Probabilistic rules | From Bayes decision theory to HMM + n-gram, CTC, RNN-T, and attention

00:00:00,240 -- 00:06:38,960

Probabilistic rules | Sequence modeling setup | Bayes decision theory

00:06:36,639 -- 00:13:35,199

Bayes decision theory | Noisy channel factorization | Chain rule

00:13:32,240 -- 00:20:11,640

HMM + n-gram baseline | Tractable decomposition | Sequence probability

00:20:09,799 -- 00:27:16,720

CTC | Monotonic alignments | Path summation

00:27:14,919 -- 00:33:34,960

RNN-T | Prediction network | Transducer objective

00:33:32,000 -- 00:40:25,040

Attention-based seq2seq | Soft alignments | Decoding tradeoffs

00:40:22,880 -- 00:46:44,000

Unified view | Model tradeoffs | Low-resource and practical remarks

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 Speech Recognition Formulations

从证据位置看,这一部分对应的课程证据区间是 2023-09-06。课程在这里强调的核心内容可以概括为: Speech Recognition Formulations | Probabilistic rules | From Bayes decision theory to HMM + n-gram, CTC, RNN-T, and attention。这一步把识别问题写成一个清晰的概率分解,也奠定了后面 HMM、n-gram、以及更现代端到端模型之间的比较框架。

在本章结构中,这一单元被并入“3.0 课程主题总览”,目的是把同一阶段的定义、机制和权衡集中讲清。

$$\hat{W} = \arg \max_W P(W | X) = \arg \max_W P(X | W)P(W)$$

符号说明如下:

- X : 观测到的语音特征序列;
- W : 候选词序列;
- $P(X | W)$: 声学模型或观测模型;
- $P(W)$: 语言模型。

1.2 本章小结

3.0 课程主题总览这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

2 3.1 概率化建模基础 (probabilistic rules)

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 3.1 概率化建模基础 (probabilistic rules) 这一部分主要围绕 Probabilistic rules | Sequence modeling setup | Bayes decision theory 展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

2.1 Probabilistic rules

从证据位置看, 这一部分对应的课程证据区间是 00:00:00,240 – 00:06:38,960。课程在这里强调的核心内容可以概括为: Probabilistic rules | Sequence modeling setup | Bayes decision theory。这一步把识别问题写成一个清晰的概率分解, 也奠定了后面 HMM、n-gram、以及更现代端到端模型之间的比较框架。

在本章结构中, 这一单元被并入 “3.1 概率化建模基础 (probabilistic rules)”, 目的是把同一阶段的定义、机制和权衡集中讲清。

$$\hat{W} = \arg \max_W P(W | X) = \arg \max_W P(X | W)P(W)$$

符号说明如下:

- X : 观测到的语音特征序列;
- W : 候选词序列;
- $P(X | W)$: 声学模型或观测模型;
- $P(W)$: 语言模型。

2.2 本章小结

3.1 概率化建模基础 (probabilistic rules) 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

3 3.2 Bayes decision theory 与 noisy channel

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 3.2 Bayes decision theory 与 noisy channel 这一部分主要围绕 Bayes decision theory | Noisy channel factorization | Chain rule 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 Bayes decision theory

从证据位置看，这一部分对应的课程证据区间是 00:06:36,639 – 00:13:35,199。课程在这里强调的核心内容可以概括为：Bayes decision theory | Noisy channel factorization | Chain rule。这一步把识别问题写成一个清晰的概率分解，也奠定了后面 HMM、n-gram、以及更现代端到端模型之间的比较框架。

在本章结构中，这一单元被并入 “3.2 Bayes decision theory 与 noisy channel”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$\hat{W} = \arg \max_W P(W | X) = \arg \max_W P(X | W)P(W)$$

符号说明如下：

- X ：观测到的语音特征序列；
- W ：候选词序列；
- $P(X | W)$ ：声学模型或观测模型；
- $P(W)$ ：语言模型。

3.2 本章小结

3.2 Bayes decision theory 与 noisy channel 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 3.3 HMM + n-gram baseline

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, 3.3 HMM + n-gram baseline 这一部分主要围绕 HMM + n-gram baseline | Tractable decomposition | Sequence probability 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 HMM + n-gram baseline

从证据位置看，这一部分对应的课程证据区间是 00:13:32,240 – 00:20:11,640。课程在这里强调的核心内容可以概括为：HMM + n-gram baseline | Tractable decomposition | Sequence probability。这里的重点不是把 HMM 当作过时历史，而是把它当作对齐、状态建模与动态规划最清晰的教学载体。

在本章结构中，这一单元被并入“3.3 HMM + n-gram baseline”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(w_1, \dots, w_T) = \prod_{t=1}^T P(w_t \mid w_1, \dots, w_{t-1}) \approx \prod_{t=1}^T P(w_t \mid w_{t-n+1}, \dots, w_{t-1})$$

符号说明如下：

- w_t ：第 t 个词；
- T ：句子长度；
- n ： n -gram 的上下文窗口长度。

4.2 本章小结

3.3 HMM + n-gram baseline 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 3.4 CTC (Connectionist Temporal Classification)

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，3.4 CTC (Connectionist Temporal Classification) 这一部分主要围绕 CTC | Monotonic alignments | Path summation 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 CTC

从证据位置看，这一部分对应的课程证据区间是 00:20:09,799 – 00:27:16,720。课程在这里强调的核心内容可以概括为：CTC | Monotonic alignments | Path summation。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入“3.4 CTC (Connectionist Temporal Classification)”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y \mid X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t \mid X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

5.2 本章小结

3.4 CTC (Connectionist Temporal Classification) 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 3.5 RNN-T / transducer

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，3.5 RNN-T / transducer 这一部分主要围绕 RNN-T | Prediction network | Transducer objective 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 RNN-T

从证据位置看，这一部分对应的课程证据区间是 00:27:14,919 – 00:33:34,960。课程在这里强调的核心内容可以概括为：RNN-T | Prediction network | Transducer objective。课程把 RNN-T 放在 streaming ASR 的语境里讨论，强调它保留了单调约束，却让模型可以更灵活地联合时间和输出历史。

在本章结构中，这一单元被并入 “3.5 RNN-T / transducer”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{A}(X, Y)} \prod_{(t, u) \in \pi} P(k_{t, u} | h_t, g_u)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：目标标签序列；
- $\mathcal{A}(X, Y)$ ：满足转导约束的对齐集合；
- h_t ：encoder 在时间步 t 的表示；
- g_u ：prediction network 在输出步 u 的表示。

6.2 本章小结

3.5 RNN-T / transducer 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 3.6 attention-based seq2seq

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，3.6 attention-based seq2seq 这一部分主要围绕 Attention-based seq2seq | Soft alignments | Decoding tradeoffs 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

7.1 Attention-based seq2seq

从证据位置看，这一部分对应的课程证据区间是 00:33:32,000 – 00:40:25,040。课程在这里强调的核心内容可以概括为：Attention-based seq2seq | Soft alignments | Decoding tradeoffs。与单调模型不同，attention encoder-decoder 更强调全局条件化能力，但也因此引入了对齐自由度和部署层面的权衡。

在本章结构中，这一单元被并入 “3.6 attention-based seq2seq”，目的是把同一阶段的定义、机制和权衡集中讲清。

7.2 本章小结

3.6 attention-based seq2seq 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

8 3.7 统一视角与 tradeoffs

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，3.7 统一视角与 tradeoffs 这一部分主要围绕 Unified view | Model tradeoffs | Low-resource and practical remarks 展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

8.1 Unified view

从证据位置看，这一部分对应的课程证据区间是 00:40:22,880 – 00:46:44,000。课程在这里强调的核心内容可以概括为：Unified view | Model tradeoffs | Low-resource and practical remarks。从课程组织上看，这一部分承担的是把局部概念嵌回整条识别流水线中的作用，避免读者把公式或模块孤立地记忆。

在本章结构中，这一单元被并入 “3.7 统一视角与 tradeoffs”，目的是把同一阶段的定义、机制和权衡集中讲清。

8.2 本章小结

3.7 统一视角与 tradeoffs 这一部分把 Speech Recognition Formulations 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

9 总结与延伸

Speech Recognition Formulations 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 Speech Recognition Formulations 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于公开课以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。