

课程笔记


End-to-End ASR: CTC

Codex 基于课程页、公开视频字幕、coverage ledger 与补充官方材料整理


2026 年 4 月 16 日

From transformer to conformer

- Two feed-forward layers (Macaron)
- Convolution block
- Absolute $\rightarrow$ relative positional embedding



Transformer



Conformer

53

视频作者/频道: WAVLab

发布日期: 2023-11-08

视频时长: unknown

视频链接: <https://www.youtube.com/watch?v=00GHpnRTAQE>

目录

1	Modern encoder variants and Conformer bridge	2
1.1	End-to-End ASR: CTC	3
1.2	补完 attention 讨论后, 引入 global/local / Branchformer-style encoder 设计, 并把 Conformer 作为现代 ASR 编码器的代表	4
1.3	实现视角与伪代码	4
1.4	本章小结	4
2	CTC formulation	5
2.1	CTC 的基本 formulation、标签序列与输入帧序列之间的长度不匹配问题	5
2.2	本章小结	5
3	Blank symbol and path marginalization	5
3.1	blank symbol、路径求和与 many-to-one alignments 如何把 CTC 变成可优化目标	5
3.2	本章小结	6
4	Dynamic programming for CTC	6
4.1	forward-backward / Viterbi 这类 dynamic programming 如何服务于 CTC 训练	6
4.2	本章小结	7
5	CTC decoding and LM fusion	7
5.1	CTC 的 decoding、beam search 与语言模型融合, 及其在实际 ASR 系统中的角色	7
5.2	本章小结	7
6	Data and robustness	8
6.1	external data、误标记 / 数据噪声与 CTC 系统鲁棒性的关系	8
6.2	本章小结	8
7	Decode-time efficiency	8
7.1	更快的决策路径、beam search 约束以及对实时推理的影响	8
7.2	本章小结	9
8	Alignment extensions and masked prediction	9
8.1	mask prediction、alignment issues 与 CTC 相关的扩展视角	9
8.2	本章小结	9
9	Recap and assignment note	9
9.1	CTC 整讲收束、优缺点与作业 / 实验提示	10
9.2	本章小结	10
10	总结与延伸	10

1 Modern encoder variants and Conformer bridge

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Modern encoder variants and Conformer bridge 这一部分主要围绕 End-to-End ASR: CTC | End-to-End ASR: CTC; 补完 attention 讨论后, 引入 global/local / Branchformer-style encoder 设计, 并把 Conformer 作为现代 ASR 编码器的代表。展开。写作上保持 coverage-first 原则: 先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清, 再压缩成适合复习的结构。

End-to-End ASR: CTC Coverage Map

Coverage-first lecture roadmap generated from coverage_units.jsonl

18-u01 | End-to-End ASR: CTC | End-to-End ASR: CTC

18-u02 | Modern encoder variants and Conformer bridge
attention global/local /
Branchformer-style encoder Conformer
ASR

18-u03 | CTC formulation
CTC
formulation

18-u04 | Blank symbol and path marginalization
blank symbol many-to-one alignments
CTC

18-u05 | Dynamic programming for CTC
forward-backward / Viterbi dynamic
programming CTC

18-u06 | CTC decoding and LM fusion
CTC decoding beam search ASR

18-u07 | Data and robustness
external data / CTC

18-u08 | Decode-time efficiency
beam search

图 1: 本讲 coverage map: 按 coverage_units.jsonl 归纳出的核心主题与章节映射。

End-to-End ASR: CTC Segment Timeline

Time-aligned topic summary derived from transcript and coverage units

2023-11-08

End-to-End ASR: CTC | End-to-End ASR: CTC

00:00:01,040 - 00:07:24,120

attention global/local /
Branchformer-style encoder Conformer
ASR

00:07:21,000 - 00:14:10,000

CTC formulation

00:14:06,079 - 00:20:51,720

blank symbol many-to-one alignments
CTC

00:20:48,320 - 00:28:11,080

forward-backward / Viterbi dynamic
programming CTC

00:28:09,760 - 00:36:35,599

CTC decoding beam search ASR

00:36:31,800 - 00:43:39,040

external data / CTC

00:43:37,200 - 00:50:45,920

beam search

图 2: 本讲 timeline: 根据字幕时间范围归纳的主题推进顺序。

1.1 End-to-End ASR: CTC

从证据位置看,这一部分对应的课程证据区间是 2023-11-08。课程在这里强调的核心内容可以概括为: End-to-End ASR: CTC | End-to-End ASR: CTC。CTC 的关键在于保持单调对齐假设,同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中,这一单元被并入“Modern encoder variants and Conformer bridge”,目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下:

- X : 输入语音特征序列;
- Y : 输出标签序列;
- π : 带有 blank 的对齐路径;
- $\mathcal{B}$: 把路径压缩为最终标签序列的映射。

1.2 补完 attention 讨论后, 引入 global/local / Branchformer-style encoder 设计, 并把 Conformer 作为现代 ASR 编码器的代表

从证据位置看, 这一部分对应的课程证据区间是 00:00:01,040–00:07:24,120。课程在这里强调的核心内容可以概括为: 补完 attention 讨论后, 引入 global/local / Branchformer-style encoder 设计, 并把 Conformer 作为现代 ASR 编码器的代表。。与单调模型不同, attention encoder-decoder 更强调全局条件化能力, 但也因此引入了对齐自由度和部署层面的权衡。

记录系统中的附加说明指出: CS224S supplement anchor: Conformer / Branchformer / Whisper-style encoders; useful if you want a modern encoder comparison.

在本章结构中, 这一单元被并入 “Modern encoder variants and Conformer bridge”, 目的是把同一阶段的定义、机制和权衡集中讲清。

CS224S 补充

CS224S supplement anchor: Conformer / Branchformer / Whisper-style encoders; useful if you want a modern encoder comparison.

1.3 实现视角与伪代码

为了把这一讲的算法流程落到工程实现层面, 下面给出一个教材化的伪代码 (pseudocode) 摘要。它不是逐行复刻讲者的实现, 而是把 lecture 中反复强调的计算顺序、状态更新与解码决策压缩成可复查的程序骨架。

```

1 for utterance in dataset:
2     logits = encoder(utterance)
3     alpha = forward_dp(logits, target_with_blank)
4     beta = backward_dp(logits, target_with_blank)
5     loss = -log(sum_valid_paths(alpha, beta))
6     update_model(loss)

```

Listing 1: CTC training sketch

把这一段放在正文里有两个目的: 第一, 让读者把抽象的模型或动态规划递推与真实实现步骤对齐; 第二, 为后续阅读 ESPnet、Kaldi 或其它 toolkit 时建立可迁移的 mental model。

1.4 本章小结

Modern encoder variants and Conformer bridge 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事: 既交代了这一阶段要解决的问题, 也交代了方法、推理或工程权衡为什么要这样组织。

2 CTC formulation

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, CTC formulation 这一部分主要围绕 CTC 的基本 formulation、标签序列与输入帧序列之间的长度不匹配问题。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

2.1 CTC 的基本 formulation、标签序列与输入帧序列之间的长度不匹配问题

从证据位置看，这一部分对应的课程证据区间是 00:07:21,000–00:14:10,000。课程在这里强调的核心内容可以概括为：CTC 的基本 formulation、标签序列与输入帧序列之间的长度不匹配问题。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “CTC formulation”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

2.2 本章小结

CTC formulation 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

3 Blank symbol and path marginalization

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Blank symbol and path marginalization 这一部分主要围绕 blank symbol、路径求和与 many-to-one alignments 如何把 CTC 变成可优化目标。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

3.1 blank symbol、路径求和与 many-to-one alignments 如何把 CTC 变成可优化目标

从证据位置看，这一部分对应的课程证据区间是 00:14:06,079–00:20:51,720。课程在这里强调的核心内容可以概括为：blank symbol、路径求和与 many-to-one alignments 如何把 CTC 变成可优化目标。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Blank symbol and path marginalization”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

3.2 本章小结

Blank symbol and path marginalization 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

4 Dynamic programming for CTC

根据课程页主题、公开视频字幕以及本讲的 coverage ledger，Dynamic programming for CTC 这一部分主要围绕 forward-backward / Viterbi 这类 dynamic programming 如何服务于 CTC 训练。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

4.1 forward-backward / Viterbi 这类 dynamic programming 如何服务于 CTC 训练

从证据位置看，这一部分对应的课程证据区间是 00:20:48,320–00:28:11,080。课程在这里强调的核心内容可以概括为：forward-backward / Viterbi 这类 dynamic programming 如何服务于 CTC 训练。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Dynamic programming for CTC”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

4.2 本章小结

Dynamic programming for CTC 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

5 CTC decoding and LM fusion

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, CTC decoding and LM fusion 这一部分主要围绕 CTC 的 decoding、beam search 与语言模型融合，及其在实际 ASR 系统中的角色。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

5.1 CTC 的 decoding、beam search 与语言模型融合，及其在实际 ASR 系统中的角色

从证据位置看，这一部分对应的课程证据区间是 00:28:09,760–00:36:35,599。课程在这里强调的核心内容可以概括为：CTC 的 decoding、beam search 与语言模型融合，及其在实际 ASR 系统中的角色。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

记录系统中的附加说明指出：CS224S supplement anchor: compare with the lecture on Conformer / fine-tuning base speech models.

在本章结构中，这一单元被并入“CTC decoding and LM fusion”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

CS224S 补充

CS224S supplement anchor: compare with the lecture on Conformer / fine-tuning base speech models.

5.2 本章小结

CTC decoding and LM fusion 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

6 Data and robustness

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Data and robustness 这一部分主要围绕 external data、误标记 / 数据噪声与 CTC 系统鲁棒性的关系。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

6.1 external data、误标记 / 数据噪声与 CTC 系统鲁棒性的关系

从证据位置看，这一部分对应的课程证据区间是 00:36:31,800–00:43:39,040。课程在这里强调的核心内容可以概括为：external data、误标记 / 数据噪声与 CTC 系统鲁棒性的关系。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Data and robustness”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

6.2 本章小结

Data and robustness 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

7 Decode-time efficiency

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Decode-time efficiency 这一部分主要围绕更快的决策路径、beam search 约束以及对实时推理的影响。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

7.1 更快的决策路径、beam search 约束以及对实时推理的影响

从证据位置看，这一部分对应的课程证据区间是 00:43:37,200–00:50:45,920。课程在这里强调的核心内容可以概括为：更快的决策路径、beam search 约束以及对实时推理的影响。。Search 这一讲把前面所有模型真正接到了 decoding pipeline 上，也就是把训练得到的分数转成最终转写结果。

在本章结构中，这一单元被并入 “Decode-time efficiency”，目的是把同一阶段的定义、机制和权衡集中讲清。

7.2 本章小结

Decode-time efficiency 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

8 Alignment extensions and masked prediction

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Alignment extensions and masked prediction 这一部分主要围绕 mask prediction、alignment issues 与 CTC 相关的扩展视角。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

8.1 mask prediction、alignment issues 与 CTC 相关的扩展视角

从证据位置看，这一部分对应的课程证据区间是 00:50:43,280–00:57:34,240。课程在这里强调的核心内容可以概括为：mask prediction、alignment issues 与 CTC 相关的扩展视角。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Alignment extensions and masked prediction”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

8.2 本章小结

Alignment extensions and masked prediction 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

9 Recap and assignment note

根据课程页主题、公开视频字幕以及本讲的 coverage ledger, Recap and assignment note 这一部分主要围绕 CTC 整讲收束、优缺点与作业 / 实验提示。展开。写作上保持 coverage-first 原则：先把老师在这一阶段真正讲过的问题设定、模型部件、训练或推理逻辑讲清，再压缩成适合复习的结构。

9.1 CTC 整讲收束、优缺点与作业 / 实验提示

从证据位置看，这一部分对应的课程证据区间是 00:57:31,760–01:04:35,119。课程在这里强调的核心内容可以概括为：CTC 整讲收束、优缺点与作业 / 实验提示。。CTC 的关键在于保持单调对齐假设，同时把对齐路径视作潜变量并在训练时进行求和。

在本章结构中，这一单元被并入 “Recap and assignment note”，目的是把同一阶段的定义、机制和权衡集中讲清。

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_{t=1}^T P(\pi_t | X)$$

符号说明如下：

- X ：输入语音特征序列；
- Y ：输出标签序列；
- π ：带有 blank 的对齐路径；
- $\mathcal{B}$ ：把路径压缩为最终标签序列的映射。

9.2 本章小结

Recap and assignment note 这一部分把 End-to-End ASR: CTC 中相邻的教学单元串成了一条连续叙事：既交代了这一阶段要解决的问题，也交代了方法、推理或工程权衡为什么要这样组织。

10 总结与延伸

End-to-End ASR: CTC 这一讲在整门《Speech Recognition and Understanding》课程中的位置，是把 E2E ASR: CTC 讲成一个可复用的建模模块。从教材化角度看，本讲最重要的不是记住单一术语，而是理解它如何嵌入完整的 automatic speech recognition pipeline：输入语音如何被表示、模型如何被训练、解码如何得到最终转写，以及这些设计分别带来什么假设和权衡。由于开源以课程页和公开视频字幕为主、缺少官方 slide PDF，本章在正文里尽量把术语、方法和工程语境解释完整，并把缺失项留在 omission 和 manifest 里，而不是凭空补写。