

课程笔记

课程笔记：视觉如何指导动作

五道口纳什 & Codex

2026 年 4 月 16 日

Vision and Action

Jitendra Malik

视频作者/频道：CS294-277 Fall 2024 / Jitendra Malik

发布日期：2024-09-30

视频时长：未提供

视频链接：<https://www.youtube.com/watch?v=iUB0vRmTPVE>

目录

1 为什么是 Vision for Action	2
1.1 这门课里的 vision 不是“看见”，而是“指导动作”	2
1.2 进化视角与速度差异	2
1.3 本章小结	2
2 眼动、注视与近未来信息	2
2.1 做一杯茶的眼动研究	2
2.2 为什么眼睛总是提前看	3
2.3 Gaze precedes movement	3
2.4 本章小结	3
3 Vision for locomotion	4
3.1 从步态到导航	4
3.2 以 egocentric depth 驱动复杂地形行走	4
3.3 视觉在 locomotion 里的真实角色	4
3.4 本章小结	5
4 预测、注视与动作准备	5
4.1 Goal-directed action 里的预测	5
4.2 体育中的预测：cricket 和 baseball	5
4.3 Efference copy：把“我自己造成的变化”扣掉	6
4.4 Mental models	7
4.5 本章小结	8
5 从发展角度理解深度线索	8
5.1 深度信息并不是一开始就齐全	8
5.2 本章小结	9
6 总结与延伸	9
6.1 综合回看	9
6.2 本讲的三个结论	9
6.3 拓展阅读	9

1 为什么是 Vision for Action

1.1 这门课里的 vision 不是“看见”，而是“指导动作”

这讲的关键词不是 perception 本身，而是 vision 如何进入 action loop。讲义一开始就把 action 拆成两类：manipulation 和 navigation。也就是说，这里的视觉不是为了做“纯识别”，而是为了让身体在世界里正确地动。

核心判断

vision 对动作很重要，但它通常不是执行过程中最靠前、最快、最稳定的那一层。快速动作更多依赖 proprioception；vision 更像是用于规划和出错修正的慢通道。

1.2 进化视角与速度差异

课程把行动和感知放到一个演化叙事里：先是 perception for guiding movement，再到 perception for guiding manipulation，最后才是 language 的复杂化。这个顺序的意思并不是“语言更高级所以更晚出现”，而是提醒我们：感知-动作耦合先于抽象符号系统成为智能的底座。

vision 之所以常常显得“慢”，原因很简单：视觉处理的链条长、涉及的信息量大。相对地，本体感觉的传递链路更短，因此能在控制环里提供更快的反馈。

1.3 本章小结

在本讲里，vision 的角色不是单独完成任务，而是和 proprioception、触觉、内部模型共同构成动作控制系统。理解这一点后，后面的 gaze、locomotion、prediction 才会连成一条线。

2 眼动、注视与近未来信息

2.1 做一杯茶的眼动研究

讲义引用了 Land, Mennie and Rusted (1999) 的经典研究：让被试完成泡茶任务，同时记录头戴相机和 gaze pattern。这类 ego-exo video 的价值，在于它把“看什么”和“怎么做”同时放进一个自然任务里。




图 1: 做一杯茶时的眼动研究: 视线并不是随机扫过场景, 而是提前落到未来会用到的信息上。

2.2 为什么眼睛总是提前看

讲义强调了一个朴素但关键的结论: eyes are directed towards where information that will be useful in the near future is likely to be found。换句话说, 眼睛不是被动接收器, 而是任务调度器。人在做茶、走路、弹琴、看画时都会提前把 gaze 转向下一个需要的信息源。

这也解释了 fovea 的意义。整张视野并不是等分的高分辨率地图; 高分辨率只集中在视网膜中央, 因此视觉系统必须主动安排注视点, 才能把最重要的信息送进高分辨率通道。

2.3 Gaze precedes movement

讲义还给出一个很实用的动作原则: gaze often precedes and guides arm or leg movement。眼睛先扫到目标或下一步的信息, 身体再跟上。这个现象在自然任务里几乎无处不在: 泡茶、走路、看画、演奏、运动都如此。

行动中的视觉

视觉在这里不是“边走边看”的连续监控, 而更像“先规划、后执行、必要时纠错”。这就是为什么闭眼走向纸张仍然能停到差不多正确位置: 主要规划已经在前面完成了。

2.4 本章小结

眼动不是动作的附属现象, 而是动作准备的一部分。视觉会提前把未来几步所需的信息放到 fovea 附近, 这让身体能够在执行阶段更多依赖本体感觉和局部反馈。

3 Vision for locomotion

3.1 从步态到导航


讲义把 locomotion 和 navigation 一起看待。对动物和机器人来说，视觉的作用不只是“看见前面有障碍”，而是构建一个可用于决策的环境表征：地形、障碍、坡度、落脚点、目标位置，最后都要进入运动规划。

Legged Locomotion in Challenging Terrains using Egocentric Vision

CORL 2022



Ananye Agarwal*
CMU



Ashish Kumar*
UC Berkeley



Jitendra Malik†
UC Berkeley



Deepak Pathak†
CMU

图 2: Egocentric vision 让腿足机器人在复杂地形上行走：视觉提供前瞻信息，而控制策略则把它转成稳定步态。

3.2 以 egocentric depth 驱动复杂地形行走

讲义引用了 challenging terrains using egocentric vision 的工作。其关键点有三个：

- 机器人只用前向 depth camera 就能处理台阶、路沿、石块和空隙；
- 训练通常在 simulation 中完成，先用 cheap-to-compute 的深度表征训练一个策略，再把它 distill 到最终策略；
- 由于相机是 egocentric 的，策略必须记住过去的信息，才能推断后腿即将踩到的地形。

3.3 视觉在 locomotion 里的真实角色

这部分最重要的不是某个特定算法，而是一个控制观念：视觉往往提供较慢但较全局的前瞻信息，而腿部控制本身则依赖更快的本体感觉反馈和局部闭环。换句话说，视觉负责“先看远处怎么走”，本体感觉负责“当前一步落得稳不稳”。

3.4 本章小结

在导航和步行里，视觉的最大作用不是实时纠正每一次足端接触，而是建立前瞻性的地形理解。真正的稳定行走，通常是“视觉规划 + 本体感觉执行 + 必要时视觉修正”的组合。

4 预测、注视与动作准备

4.1 Goal-directed action 里的预测

讲义引用 Fiehler et al. 的框架，把预测拆成三层：

- 预测外部世界的感知变化；
- 预测自己动作的后果；
- 把眼、手、物体的运动预测整合起来。

这三层预测共同让动作从“被动反应”变成“前馈准备”。机器人如果没有这类内部预测，就只能等误差发生以后再修正。

预测类型	作用
世界状态预测	帮助规划下一步会看到什么、碰到什么。
动作后果预测	让系统在动作执行前就知道可能产生什么感觉变化。
多模态联合预测	把眼动、手动和对象运动统一在同一时序里。

4.2 体育中的预测：cricket 和 baseball

讲义用 cricket batting 和 baseball hitting 说明“提前量”有多重要。高手不是等球撞上来再反应，而是根据早期轨迹、身体姿态和经验模型推断未来的位置，然后把 gaze 和身体动作提前布置到合适位置。这里的技能差距，部分就来自预测能力差距。

Prediction in goal-directed action

Fiehler et al

- **Prediction allows humans and other animals to prepare for future interactions with their environment. This is important in our dynamically changing world that requires fast and accurate reactions to external events.**
- **Knowing when and where an event is likely to occur allows us to plan eye, hand, and body movements that are suitable for the circumstances.**
- **Predicting the sensory consequences of such movements helps to differentiate between self-produced and externally generated movements.**

图 3: goal-directed action 里的预测：知道事件何时、何地发生，动作就能提前准备。

Efference copy as a form of prediction

- Imagine watching a train pass by. If you do not follow the train with your eyes, its image will sweep across the retina while the image of the context surrounding the train will not. If you do follow the train with your eyes, its image will be (more or less) stable on the retina, while the context's image will produce a motion sweep.
- How does the brain figure out when to attribute retinal motion to object motion and when to attribute it to movements of the eyes?
- Von Holst and Mittelstaedt (1950) proposed that when a motor command is sent to the muscles that move the eyes, a copy of the efferent signal is simultaneously sent to visual areas of the brain.

图 4: efference copy 试图解释：当眼睛自己在动时，视网膜上的运动信息并不必然意味着外界在动。

4.3 Efference copy：把“我自己造成的变化”扣掉

Von Holst 和 Mittelstaedt 提出的 efference copy 是本讲最关键的预测概念之一。它的直觉很简单：当大脑发出眼动命令时，同时把一份 copy 送给视觉系统，用来预测自己即将看到什么。这样，系统就能区分“是对象动了”还是“是我自己在看它”。

这个机制之所以重要，是因为 perception 从来不是纯被动的。若没有对自我动作的预测，视觉系统会把大量自造成的变化误判为外部世界变化。

~~Predictive signals change perception~~


- One of the prime examples of predictive sensory attenuation is the phenomenon that we cannot tickle ourselves. Humans experience a touch on their own body as less ticklish if they produce the tactile stimulation themselves (Blakemore, Frith, & Wolpert, 1999).

图 5: predictive signals 会改变 perception; “自己挠自己不痒”是最经典的例子。

4.4 Mental models

讲义最后把话题收束到 Craik (1943) 的 internal model 观点：如果系统在头脑里携带一份外部世界和自身动作的小模型，它就能先试错、再决策、再执行。讲义的结论非常直接：common sense 不是一堆事实，而是一组 model。

—AI systems need to build “mental models”—



If the organism carries a ‘small-scale model’ of external reality and of its own possible actions within its head, it is able to try out various alternatives, conclude which is the best of them, react to future situations before they arise, utilize the knowledge of past events in dealing with the present and the future, and in every way to react in a much fuller, safer, and more competent manner to the emergencies which face it (Craik, 1943, Ch. 5, p.61)

Commonsense is not just facts, it is a collection of models

图 6: AI 系统为什么需要 mental models: 它们让系统可以在行动前模拟结果。

4.5 本章小结

预测不是装饰性能力，而是视觉指导动作的核心。眼动、动作准备、自我动作消除和内部模型，实际上是同一条控制链上的不同环节。

5 从发展角度理解深度线索

5.1 深度信息并不是一开始就齐全

讲义最后借用婴儿发展研究提醒我们：对 depth information 的敏感性是逐步发展的。kinetic depth、binocular depth 和 pictorial depth 的敏感顺序并不完全一样，这说明视觉系统并不是一开始就拥有完整的几何理解，而是在发育过程中逐步搭建起来的。

The Development of Sensitivity of Kinetic, Binocular and Pictorial
Depth Information in Human Infants

Albert Yonas, Carl E. Granrud

Brain Mechanisms of Spatial Vision, pp. 113-145 (1985)

- A program of research is described that explores the development of sensitivity to three classes of spatial information in human infants. The research suggests that sensitivity to kinetic, binocular and pictorial depth information develops in a fixed sequence. Some sensitivity to kinetic information may be present at birth or soon thereafter; sensitivity to binocular information appears between three and five months; and sensitivity to static monocular information appears between five and 7 months of age. These findings may direct research on the development of neural mechanisms that underlie the emergence of responsiveness to spatial information in human infants.

23

图 7: 婴儿对不同深度线索的敏感性发展并不同步, 这为“视觉如何逐渐服务于动作”提供了发育学证据。

5.2 本章小结

这一页把讲义前面的哲学收束到一个现实结论: 视觉用于动作, 不是天生全能, 而是随着感知、运动和经验逐步耦合出来的能力。

6 总结与延伸

6.1 综合回看

这讲的结构可以浓缩成一句话: vision 提供慢而广的前瞻信息, proprioception 提供快而稳的执行反馈, prediction 则把二者连接到同一个动作控制系统里。无论是泡茶、走路、接球, 还是机器人走复杂地形, 真正有效的系统都不会只靠“看见”。

6.2 本讲的三个结论

- 视觉更多用于规划和修正, 而不是持续替代本体感觉。
- gaze 不是旁观动作, 而是动作准备的一部分。
- internal model / mental model 是从感觉到动作的中间层, 没有它就很难做出稳定的 goal-directed action。

6.3 拓展阅读

如果要继续深入, 推荐从 Land et al. (1999) 的茶水任务、Matthis et al. 的 terrain walking、Fiehler et al. 的 goal-directed prediction、Von Holst & Mittelstaedt 的 efference copy, 以及 Craik

的 internal model 观点继续往外扩展。它们共同构成了“视觉不是为了看，而是为了行动”的理论骨架。

来源说明

本讲义主要依据课程页上的 slides、transcript 与课程 notes 摘录重建；正文中对若干跨页主题做了教材式重排，因此不严格沿用原始幻灯片顺序。