

课程笔记

课程笔记：Lecture 7 行为克隆 (Behavior Cloning)

Codex

2026 年 4 月 16 日

Behavior Cloning: Diffusion Policies

With tutorial material on VAEs and diffusion models
Jitendra Malik

视频作者/频道: Robots That Learn / UC Berkeley CS 294-277

发布日期: 课程讲次日期: 2024-10-21

视频时长: 44:19

视频链接: <https://www.youtube.com/watch?v=UC-hdat5YqU>

目录

1 课程定位与本讲学习目标	2
1.1 为什么这一讲不是“纯监督学习”那么简单	2
1.2 本章小结	2
2 从 Learning from Demonstration 到 Behavior Cloning	2
2.1 LfD 的基本定义	2
2.2 三种教学方式	3
2.3 本章小结	3
3 行为克隆的核心难点：分布、泛化与鲁棒性	3
3.1 为什么只拟合示范并不总是够用	3
3.2 为什么 diffusion policies 进入这个舞台	3
3.3 本章小结	3
4 Diffusion Policies：把动作生成做成去噪过程	4
4.1 Diffusion policy 的基本直觉	4
4.2 与传统生成式建模的关系	4
4.3 本章小结	4
5 Denoising Diffusion Models：从噪声到数据	4
5.1 前向扩散过程	4
5.2 反向去噪过程	5
5.3 变分上界与训练目标	5
5.4 训练时真正优化的是什么	5
5.5 本章小结	6
6 模型设计、条件生成与 VAEs 的关系	6
6.1 模型结构：U-Net、ResNet 与 self-attention	6
6.2 与 VAE 的关系	6
6.3 条件扩散模型	6
6.4 本章小结	6
7 总结与延伸	6
7.1 本讲的三个结论	7
7.2 拓展阅读	7
7.3 结束语	7

Behavior Cloning: Diffusion Policies

With tutorial material on VAEs and diffusion models
Jitendra Malik

图 1: 课程官方材料中的代表性页面, 用于帮助读者在进入本讲正文前建立整体上下文。

1 课程定位与本讲学习目标

这一讲从行为克隆 (Behavior Cloning, BC) 和学习示范 (Learning from Demonstration, LfD) 出发, 逐步走到 diffusion policies。讲者的基本判断是: 很多机器人任务并不适合先写奖励再做优化, 而更适合直接从专家示范中学习行为。

1.1 为什么这一讲不是“纯监督学习”那么简单

行为克隆表面上很像监督学习: 给定观测输入, 学习输出动作。但机器人里的 imitation learning 不只是拟合标签, 还牵涉到示范怎么来、状态怎么覆盖、策略在部署时如何面对偏离训练分布的状态, 以及为什么某些任务需要更强的生成式策略表示。

这讲的中心线索

示范数据可以替代手写 reward, 但示范学习并不自动消除机器人控制里的复杂性。真正难的是把“会模仿”变成“在真实环境里稳定模仿”。

1.2 本章小结

本讲先回答“为什么要做 LfD”, 再回答“示范可以怎么采集”, 最后引出 diffusion policies 作为一个兼具表达力和稳定性的现代方案。

2 从 Learning from Demonstration 到 Behavior Cloning

2.1 LfD 的基本定义

课程摘录引用了 Ravichandar et al. 的表述: 在 robotics 和 automation 里, LfD 指的是机器人通过模仿专家来学习新技能。它适合那些既难以用传统编程明确写出、也难以直接写成优化问题, 但又可以通过演示来描述的任务。

这一定义很重要，因为它说明 LfD 不是“退而求其次”，而是一种适合复杂任务的建模方式。当任务目标难以精确量化时，专家演示本身就成为了监督信号。

2.2 三种教学方式

课程把示范采集方式分成三类：

- kinesthetic teaching (示教/手把手示教)：直接把机器人拖到目标轨迹上并记录关节运动；
- teleoperation (遥操作)：通过控制器远程操纵机器人；
- passive observation (被动观察)：机器人只观察示范，不直接被人拉着做。

这三种方式的区别不只是“采集姿势”不同，而是示范数据的成本、可扩展性和安全性不同。示教最直观，但需要人工接触机器人；遥操作更安全，也更适合大型或危险任务；被动观察最接近互联网视频数据的设想，但对感知和对齐要求更高。

2.3 本章小结

LfD 的关键不在于把动作复制出来，而在于把专家行为转化成机器人可以学习的数据。示范采集方式越不同，后续训练能利用的信息和约束就越不同。

3 行为克隆的核心难点：分布、泛化与鲁棒性

3.1 为什么只拟合示范并不总是够用

从形式上讲，behavior cloning 就是用监督学习拟合示范轨迹中的动作。但机器人策略一旦偏离演示分布，就可能进入训练中没见过的状态，随后误差会累积。这也是 imitation learning 里最常见的现实问题：看起来模型在离线数据上拟合得不错，真正上机器人后却开始跑偏。

行为克隆的现实风险

如果训练时的数据只覆盖“专家状态附近”，而部署时策略稍有偏差就会进入没见过的区域，那么误差会逐步放大。这个问题在机器人任务里比在静态分类任务里更严重。

3.2 为什么 diffusion policies 进入这个舞台

讲者接着把注意力引向 diffusion policies：如果动作分布本身是多峰的、复杂的，或者输出维度很高，那么直接回归一个单点动作往往会把多种合理方案平均掉。Diffusion policy 的思路是把动作生成变成逐步去噪的过程，从而保留复杂分布的结构。

3.3 本章小结

行为克隆的本质难题不是“有没有标签”，而是示范分布和部署分布之间是否一致，以及策略能否在复杂动作空间里保住多样性与稳定性。

4 Diffusion Policies: 把动作生成做成去噪过程

4.1 Diffusion policy 的基本直觉

课程把 diffusion policy 描述为一种把机器人策略表示成条件去噪扩散过程的方法。它通常把图像或其他传感输入作为条件，输出动作序列或轨迹。和直接回归一个动作相比，这种做法有几个明显好处：

- 可以表达 multimodal action distributions (多模态动作分布)；
- 可以处理高维动作输出，而不是只预测下一步单动作；
- 训练通常更稳定，因为优化目标更接近去噪而不是直接生成高复杂度样本。

为什么多模态在机器人里很重要

机器人任务里经常存在多条都可行的路径或多组都合理的操作方式。单点回归容易把这些模式平均成一个“谁都不太对”的动作，而 diffusion policy 可以保留这些模式。

4.2 与传统生成式建模的关系

课程把 diffusion policies 放进更大的 deep generative learning 图景里：normalizing flows、autoregressive models、variational autoencoders (VAE)、denoising diffusion models 和 energy-based models 都属于这一谱系。Diffusion policy 之所以受到重视，是因为它把生成式建模的稳定性和动作学习的条件性结合起来了。

4.3 本章小结

Diffusion policy 的关键不是“把动作直接预测出来”，而是“在条件输入下逐步把噪声变成动作”。这给了机器人任务一个可以表达复杂动作分布的生成式接口。

5 Denoising Diffusion Models: 从噪声到数据

5.1 前向扩散过程

讲者先回顾 diffusion model 的两个过程：forward diffusion 和 reverse denoising。前向过程可以写成马尔可夫链：

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I),$$

因此整条链满足

$$q(x_{1:T} | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}).$$

其中：

- x_0 是原始数据；
- x_t 是第 t 步加噪后的样本；
- $\beta_t \in (0, 1)$ 是每一步的噪声日程 (noise schedule)；

- I 是单位矩阵。

课程进一步给出直接从 x_0 到 x_t 的写法。定义

$$\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s),$$

则

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I).$$

这个式子的意义是：随着 t 增大，数据逐渐被噪声淹没；当 T 足够大时， x_T 近似标准高斯分布。

5.2 反向去噪过程

反向过程要做的是从噪声中生成数据，形式上写成

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \sigma_t^2 I).$$

也就是说，模型学习的是：给定当前带噪样本 x_t 和时间步 t ，如何预测前一步的分布参数。训练时，目标是让这个反向过程尽量逼近前向过程对应的真实后验。

5.3 变分上界与训练目标

课程把训练写成对负对数似然的变分上界：

$$\mathbb{E}_{q(x_0)}[-\log p_\theta(x_0)] \leq \mathbb{E}_{q(x_0)q(x_{1:T}|x_0)} \left[-\log \frac{p_\theta(x_{0:T})}{q(x_{1:T} | x_0)} \right] =: \mathcal{L}.$$

进一步展开后可以得到

$$\mathcal{L} \approx \mathbb{E}_q \left[\text{D}_{\text{KL}}(q(x_T | x_0) \| p(x_T)) + \sum_{t>1} \text{D}_{\text{KL}}(q(x_{t-1} | x_t, x_0) \| p_\theta(x_{t-1} | x_t)) - \log p_\theta(x_0 | x_1) \right].$$

其中 $q(x_{t-1} | x_t, x_0)$ 是可计算的后验分布，课程写成

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t I),$$

并给出

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} x_0 \frac{\sqrt{1 - \beta_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t, \quad \tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t.$$

这些公式的作用不是为了“背下来”，而是说明 diffusion 的训练本质上是在让学到的反向分布逼近真实去噪过程。

5.4 训练时真正优化的是什么

课程在算法视角上还强调：训练通常等价于让网络预测噪声 ϵ 与 ϵ_θ 之间的平方误差。也就是说，模型学会的不是直接输出成品图像，而是学会在各个时间步把噪声往回推。

diffusion 的一个关键现象

去噪生成通常先恢复低频结构，再逐渐恢复高频细节。因此不同时间步的损失权重并不只是技术细节，而会影响内容与细节之间的平衡。

5.5 本章小结

Diffusion model 的核心是一个前向加噪、反向去噪的马尔可夫过程。训练通过变分上界和噪声预测目标完成，而稳定性和高质量生成正是这种逐步建模带来的优势。

6 模型设计、条件生成与 VAEs 的关系

6.1 模型结构：U-Net、ResNet 与 self-attention

讲者指出，diffusion models 常用 U-Net 结构，并配合 ResNet blocks 和 self-attention layers。最近 transformer 也成为更流行的选择。这里的关键不是某个架构名词，而是模型必须在多尺度上处理“当前带噪样本 + 时间步 + 条件输入”的组合信息。

6.2 与 VAE 的关系

课程把 diffusion models 看成 hierarchical VAE 的一种特殊形式，但两者仍有重要差别：

- diffusion 的 forward process 是固定的，不是学习出来的 encoder；
- diffusion 没有传统 VAE 那种单一步的潜变量瓶颈，而是一个逐步演化的链式表示；
- 因为是逐步去噪，diffusion 往往更容易兼顾稳定训练和高质量生成。

6.3 条件扩散模型

在条件生成里，条件可以通过额外输入进入 reverse process。课程列举的典型例子包括：

- text-to-image generation；
- super-resolution；
- colorization；
- panorama generation。

对于机器人来说，这个机制非常自然：图像、状态或传感器输入可以作为条件，动作序列作为生成目标。于是 diffusion policy 就把“给定观测生成动作”变成了一个条件生成问题。

6.4 本章小结

Diffusion models 之所以重要，不只是因为它能生成图像，更因为它提供了一种稳定、可条件化、可扩展的生成方式。Diffusion policy 正是把这套机制迁移到了机器人动作生成上。

7 总结与延伸

这一讲的主线可以概括为：行为克隆之所以值得做，不只是因为简单，而是因为很多机器人任务更适合从示范中学习；diffusion policy 之所以值得关注，是因为它用逐步去噪的生成方式解决了多模态、高维动作和训练稳定性这些难点。

7.1 本讲的三个结论

- 示范学习 (LfD) 适合那些难以显式写 reward 的机器人任务；
- 纯粹的单点行为克隆可能会把多种可行动作平均掉；
- diffusion policies 把动作生成变成条件去噪问题，从而更适合复杂机器人动作分布。

7.2 拓展阅读

- *Diffusion Policy*
- *Denoising Diffusion-based Generative Modeling: Foundations and Applications*
- *Recent Advances in Robot Learning from Demonstration*

7.3 结束语

如果只记住一个结论，那就是：行为克隆不是“把专家动作抄下来”这么简单；在机器人里，它更像是在学习一个能覆盖多种合理行为、还能在噪声和偏差下持续生成动作的策略分布。Diffusion policy 就是这一思路的现代版本。