

课程笔记

Lecture 9: Case Studies in Locomotion

Codex

2026-04-16

Learning to Walk for Quadrupeds

Jitendra Malik
UC Berkeley

视频作者/频道: Toru

发布日期: 2024-11-04

视频时长: 1:26:05

视频链接: <https://www.youtube.com/watch?v=98uo20uXDYc>

目录

1 四足 locomotion: 从 pattern generator 到强化学习	2
1.1 问题从哪里来	2
1.2 早期方法: Pattern Generator 与 Raibert Controller	2
1.3 RL 的转折	2
1.4 本章小结	3
2 从仿真到现实: RMA 与速度自适应	3
2.1 Rapid Motor Adaptation	3
2.2 速度不同, 步态就不同	3
2.3 本章小结	4
3 视觉与本体感觉: 腿式机器人的导航	4
3.1 为什么还需要 vision	4
3.2 地图化与 map-free 方法	4
3.3 本章小结	5
4 双足与 humanoid: ZMP、MPC 与学习式控制	5
4.1 为什么 humanoid 更难	5
4.2 端到端 RL 控制	5
4.3 本章小结	6
5 从视频到序列: next-token prediction 与 challenging terrains	6
5.1 Humanoid Locomotion as Next Token Prediction	6
5.2 预训练再微调	7
5.3 本章小结	7
6 总结与延伸	7

1 四足 locomotion: 从 pattern generator 到强化学习

1.1 问题从哪里来


四足机器人 (quadruped) 看起来比 humanoid 更容易, 但真正能在现实中走稳、走快、跨越复杂地形, 依然非常难。课程先用自然界里的狗、马和山地地形作为直观背景, 再回到机器人: 腿式系统需要同时面对平衡、能量、接触切换和地形变化。

1.2 早期方法: Pattern Generator 与 Raibert Controller

早期腿式机器人控制强调 **pattern generator (节律发生器)** 和固定步态。核心思想是用预编程的中央模式发生器 (central pattern generator, CPG) 或 Raibert controller 产生重复、稳定、可解释的步态。它们的优点很明确: 实现简单、实时性强、在结构化环境里够用。

但这类方法也有明显局限: 它们依赖人工设计的步态和环境假设, 一旦地形、摩擦、负载或速度目标变化, 就需要重新调参。课程在这里给出的判断非常直接: **固定步态能走, 但不够“会走”。**

Computational Gaits — Central Pattern Generators



Matsuoka, Kiyotoshi.
"Mechanisms of
frequency and
pattern control in the
neural rhythm
generators." *Biologic
al cybernetics* (1987)

图 1: 中央模式发生器 (CPG) 是早期腿式 locomotion 的代表思路之一。

1.3 RL 的转折

现代四足 locomotion 的核心转折是: 让机器人在模拟器里用 **reinforcement learning (RL)** 自己学步态。课程里提到的关键奖励通常围绕两件事: **最小化工作量 (work)** 和 **最小化地面冲击 (ground impact)**。这和生物运动学里的能量规律是一致的, 因此会自然涌现 walking、trotting、galloping 等不同 gait。

为什么 RL 在 locomotion 里好用

locomotion 的一个优点是奖励相对容易写: 走得稳、走得快、摔得少、能耗低。这使 RL 比 manipulation 更容易先跑起来, 也更容易在 simulation 里大规模并行训练。

1.4 本章小结

四足 locomotion 的主线是从固定步态走向可学习步态。pattern generator 提供了早期可用的工程解，但 RL 才让机器人能根据速度、地形和扰动自适应地组织 gait。

2 从仿真到现实：RMA 与速度自适应


2.1 Rapid Motor Adaptation

课程把 **Rapid Motor Adaptation (RMA)** 作为从 simulation 到 real world 的代表方法。其关键不是只训练一个 policy，而是把系统拆成两层：

- **Base policy**：在模拟器中学会基本的行走控制。
- **Adaptation module**：根据观察到的历史状态，在线估计隐含的环境参数，例如摩擦、地形高度、载荷和地面柔软度。

在训练阶段，RMA 会利用 privileged terrain information 监督地形编码器；在部署阶段，这些 privileged 信息不可用，于是 adaptation module 只能根据过去的 observation-action history 推断 extrinsics。课程强调这一步实际上是一个 **system identification (系统辨识)** 风格的问题，只不过它是 learned 的、在线的。

Key Insight — Extrinsics from Observation History



- Discrepancy b/w expected movement and actual measured movement
- Continuously estimate these extrinsics online

图 2: RMA 的核心直觉：用历史观测在线估计不可见的环境外参 (extrinsics)。

2.2 速度不同，步态就不同

另一条线索是 **speed-adaptive gaits (速度自适应步态)**。课程展示了一个非常重要的现象：当训练目标从单一速度变成多个速度时，机器人会自发学出不同步态。低速更像 walk，中速更像 trot，高速则可能出现更明显的 bounce/gallop。这里不是人工“规定”步态，而是奖励函数与动力学共同诱发了步态分化。

讲义还强调了一个生物学上的对应关系：最小化能量消耗会和真实动物的 gait pattern 对齐。也就是说，机器人并不是在“模仿动物动作表面”，而是在重现某些深层的优化规律。

2.3 本章小结

RMA 证明了一个实用结论：如果环境外参可以从历史中估计，那么很多原本只能在仿真里训练的策略就能被搬到现实。速度自适应则进一步说明，步态并不是固定模板，而是可以由任务目标和能量约束自然生成的。

3 视觉与本体感觉：腿式机器人的导航

3.1 为什么还需要 vision

课程从 locomotion 走向 navigation 时，重点是补上 perception。仅靠 proprioception，机器人可以在一定程度上维持平衡，但遇到 stairs、curbs、stepping stones、slopes、glass walls 这样的复杂场景时，单靠内部状态并不够。于是需要 **egocentric vision (第一人称视觉)**，尤其是 depth 信息。

这里有一个很重要的现实判断：直接建 terrain map 在理论上很自然，但在现实中很脆弱，因为机器人自身和相机都在抖，累积噪声会让地图逐步失真。课程因此提出一个更直接的问题：**我们真的需要 terrain map 吗？**

Do we really need terrain maps?

We directly go from vision to control

图 3: 从视觉直接到控制，是这部分内容的转折点。

3.2 地图化与 map-free 方法

讲义先讲传统的 map-based perceptive locomotion：利用视觉构造地形图，再把地图输入低层 locomotion policy。随后给出的替代路线是 **map-free, gait-free**：不显式维护精细 terrain map，而是直接从视觉和历史状态中学习控制。课程展示的结果说明，在某些挑战地形上，这种方法反而比 noisy map 更稳。

这部分的中心结论

对于腿式机器人，感知的目标不是“重建一个完美世界模型”，而是“尽快提取对下一步足部放置有用的信息”。因此，地图并非唯一答案，甚至在某些场景里会是负担。

3.3 本章小结

vision 在腿式 locomotion 里的作用，不是让机器人更像传统导航系统，而是让控制系统更像一个可以实时理解地形的运动体。课程最后的经验结果表明，地图未必总是收益，直接从视觉到控制有时更有效。

4 双足与 humanoid: ZMP、MPC 与学习式控制

4.1 为什么 humanoid 更难

与四足相比，双足机器人更接近人类，但稳定性也更差。课程先用 ASIMO、ATLAS 等例子说明传统 humanoid 控制如何依赖 **zero-moment point (ZMP)** 和 **model-predictive control (MPC)**。这些方法在结构化环境里非常强，因为它们依赖明确的动力学模型和可预测的接触。

问题在于，一旦环境变得非结构化，或者模型不够准确，纯模型法就会迅速吃力。换句话说，humanoid 的难点不只是“做出一个步态”，而是“在现实里持续地、鲁棒地走”。

4.2 端到端 RL 控制

课程随后转向 Radosavovic et al. 的工作：用 **causal transformer** 和 **reinforcement learning** 训练一个端到端 humanoid controller。输入是历史 proprioception（关节角、速度等），输出是关节残差控制。多环境、不同摩擦、不同地形的 domain randomization 让策略学到在 context 下自适应的行为。

这部分最值得注意的现象包括：

- arm swing 并没有显式写进奖励，但会自发涌现；
- 在坡地上，步长会变小、步频会提高；
- 当机器人遇到台阶或扰动时，会出现 foot recovery 行为。

End-to-End Control



图 4: 端到端 humanoid control 的典型形态: 直接学控制, 而不是手写 ZMP/MPC 细节。

4.3 本章小结

humanoid locomotion 的重要变化是: 从模型优先转向学习优先。ZMP 和 MPC 仍然有价值, 但在现实复杂性面前, 学习式控制提供了更强的适应性, 尤其是在足够大的仿真训练和合理的 domain randomization 之后。

5 从视频到序列: next-token prediction 与 challenging terrains

5.1 Humanoid Locomotion as Next Token Prediction

课程后半段把 humanoid locomotion 重新表述成一个序列建模问题: 像语言模型预测下一个 token 一样, 预测下一个动作片段或控制信号。这是一个非常强的类比, 因为它把 locomotion 从“在线控制”改写成“序列建模 + in-context adaptation”。

这类方法通常先用 human walking videos 和 mocap 数据做 **kinematic retargeting (运动学重定向)**, 再在大规模数据上训练 transformer。课程强调了一个很现实的取舍: 数据可以 noisy, 但只要 scale 足够大, 模型仍然能学到有用的 gait priors。

Training with Missing Data




图 5: 训练中引入 missing data, 是把 locomotion 写成序列建模问题的关键手段之一。

5.2 预训练再微调

在 challenging terrain 上, 课程展示了另一条混合路线: 先用 sequence modeling / imitation 做预训练, 让机器人先“会走”; 再用 RL fine-tuning 去适应更难的 terrain。直觉很简单: 一个已经能走平地的机器人, 比一个完全不会走的机器人更容易学会上坡、跨越障碍和应对脚步失误。

这类方法的优势和代价都很清楚:

- 优势是 sample efficiency 高, 训练更稳定;
- 代价是它只能学习数据里存在的技能, 真正全新的技能仍然更依赖 RL。

课程最后的态度

对 locomotion 而言, imitation learning 和 RL 不是互斥的。更实用的范式往往是: 先用大规模视频和序列建模把策略带到一个好初值, 再让 RL 处理数据里没有覆盖到的鲁棒性和新技能。

5.3 本章小结

这部分把 locomotion 的前沿总结得很清楚: 一条线是更强的感知与控制闭环, 另一条线是把动作当作长序列来建模。二者最终都在追求同一个目标, 即让机器人在真实世界里以更少样本、更高稳定性学会走路。

6 总结与延伸

这讲的核心结论可以概括为三层。第一层, **quadruped locomotion** 证明 RL 可以学出自然步态, 且能把 energy-efficient gait 与生物规律联系起来。第二层, **RMA** 和 vision-proprioception coupling 说明, 现实部署的关键是处理不可见外参和感知噪声, 而不是只把 simulator 的 policy 原

封不动搬过去。第三层，**humanoid locomotion** 显示，未来会越来越像序列建模问题：先在大规模 noisy data 上学出先验，再用 RL 处理不可预见的环境与任务。

如果把这一讲和前后的课程放在一起看，它其实在反复强调同一个模式：**机器人学习最有效的路径，不是去掉结构，而是用学习把结构用起来**。locomotion 里这个结构是动力学、接触和能量；视觉里是人体先验和可供性；navigation 里则是语义地图和分层控制。

从教材角度看，这一讲值得记住的不是某一个单独模型，而是三个原则：一，simulation 是训练大型 policy 的基础设施；二，现实部署需要适应机制；三，越接近真实世界，越需要把感知、控制和任务结构放在同一个框架里思考。