

课程笔记

Lecture 10: Case Studies in Navigation

Codex

2026-04-16

**Navigating to Objects
in the Real World**

Theophile Gervet¹ Soumith Chintala⁴ Dhruv Batra^{3,4} Jitendra Malik^{2,4} Devendra Chaplot⁴

¹ Carnegie Mellon University ² Berkeley University of California ³ Georgia Tech ⁴ Meta AI

The slide is a presentation slide with a white background and a black border. It features the title 'Navigating to Objects in the Real World' in a large, bold, black font. Below the title are five portrait photos of the speakers, each with their name and affiliation below it. The affiliations are: Carnegie Mellon University (1), Berkeley University of California (2), Georgia Tech (3), and Meta AI (4). On the right side of the slide, there is a vertical list of names: Jitendra Malik, Toru, William Shen, Jerome Quenec'h, Samson Qi, Zhiqiang Liang, and Kaushik (Kunal) Singh.

视频作者/频道: Toru

发布日期: 2024-11-18

视频时长: 45:06

视频链接: <https://www.youtube.com/watch?v=HgK-86Hr1Wo>

目录

1 导航问题与三类方法	2
1.1 导航任务到底在做什么	2
1.2 三类主流路线	2
1.3 本章小结	2
2 经典方法与端到端方法	3
2.1 经典导航：建图再规划	3
2.2 端到端学习：从图像到动作	3
2.3 本章小结	3
3 模块化导航与 GOAT	3
3.1 为什么 modular 更稳	3
3.2 GOAT: Go to Any Thing	3
3.3 比较与结论	4
3.4 本章小结	4
4 总结与延伸	5

1 导航问题与三类方法

1.1 导航任务到底在做什么

这讲把导航定义得非常务实：给机器人一个第一人称相机，让它进入一个 **novel environment** (新环境)，并给出一个 goal。这个 goal 可以是几何的，例如走到某个 (x,y) 位置；也可以是语义的，例如“去厨房”“找一把椅子”“找到一棵植物”。课程特别强调，真实问题里最常见的其实是 **semantic goals** (语义目标)。

1.2 三类主流路线

讲义把 navigation 划成三大类：**classical**、**end-to-end** 和 **modular**。这是整讲最重要的组织框架，因为后面 GOAT 的讨论其实就是对 modular 方法的一个具体实例。




图 1: 课程给出的导航方法分类：classical、end-to-end、modular。

导航中的核心分工

如果把导航看成一个系统问题，那么前端负责 perception / mapping，后端负责 goal-directed exploration 和 collision-free control。三类方法的区别，主要就是这两个阶段到底谁来做、怎么分工、是否显式建图。

1.3 本章小结

导航不是单纯的“往前开”问题，而是一个把感知、地图、目标和控制连接起来的系统问题。课程把它拆成三类方法，为后面的比较埋下了主线。

2 经典方法与端到端方法

2.1 经典导航：建图再规划

经典方法的思路最直白：先用 mapping 或 SLAM 构建几何地图，再在地图上做 classical planning。如果目标点已经在地图里，就直接规划路径；如果目标还没有出现，就先做 frontier exploration 或启发式搜索。

这种方法的优点是几何和运动学约束很清晰，适合结构化环境。缺点也同样明显：它 **做得太多**，试图重建整个世界；同时又 **做得太少**，因为它几乎不理解语义。比如“去厨房”“找植物”这种目标，经典方法并没有自然的方式把常识知识注入系统。

2.2 端到端学习：从图像到动作

另一端是 **end-to-end learning (端到端学习)**。这类方法把导航直接写成 images-to-actions 的神经网络，可以是 recurrent model，也可以是 transformer。训练方式既可以是 imitation learning，也可以是 RL。

课程提醒了一个经常被忽略的问题：如果 expert 用的是 ground-truth world knowledge，而学习者只能看到部分观测，那么 expert 的问题实际上更像 MDP，而学习者面对的是 POMDP。这个差异会让 imitation 的数据分布过于理想化，最终导致探索行为学不出来。

端到端方法的真实代价

端到端并不是“更现代就更好”。它最大的成本通常是数据量和 sim-to-real gap。视觉 RGB 的 domain gap 尤其大，导致在 simulation 里看起来有效的策略，到了真实世界常常突然崩掉。

2.3 本章小结

经典方法强在可解释与几何稳定，端到端方法强在潜在表达能力，但二者都各有硬伤。课程由此引出第三类方法：把导航拆成语义地图和 goal-oriented policy 的 modular pipeline。

3 模块化导航与 GOAT

3.1 为什么 modular 更稳

模块化方法 (modular approaches) 把任务拆成两个责任清晰的模块。第一步是从视觉和语义信息构建 **semantic map (语义地图)**；第二步是在语义地图上执行 goal-oriented exploration。这样做的好处是，perception stack 可以使用真实世界上训练好的检测器、分割器和深度模型，而不必完全依赖仿真里学出来的视觉前端。

这也是课程里最关键的判断之一：**perception 不一定要在 simulation 里学，policy 却常常可以在 simulation 里学**。这让 modular 方法比纯 end-to-end 更容易跨域。

3.2 GOAT: Go to Any Thing

讲义用 **GOAT** 作为 modular 的案例。它不仅记录对象类别，还记录对象实例和 viewpoint，因此可以从“找一只熊”提升到“找那只红色毛绒熊”。这意味着导航目标不再局限于 closed-set

category，而可以是更精细的 instance description，甚至是 language + image 的组合。

GOAT 的两个有趣能力尤其值得注意：

- **Lifelong semantic memory**：机器人可以不断积累曾经见过的实例，之后直接导航到旧目标；
- **Incremental map update**：如果对象移动了，系统也可以通过新视角继续识别同一实例。




图 2: GOAT 的模块化架构：语义地图、实例记忆、高层目标生成和低层局部导航。

3.3 比较与结论

课程给出的比较结果很清楚：在 simulation 里三类方法可能差别没那么夸张，但到 real world 时，只有 classical 和 modular 相对稳，end-to-end 因为 RGB sim-to-real gap 很容易崩。这里并不是说 classical 永远优于 learning，而是说 **如果 perception 很难稳定迁移，模块化设计就比一体化端到端更现实**。

方法	优点	主要风险
Classical	几何清晰、可解释、易做规划	语义弱、难注入统计先验
End-to-End	表达能力强、端到端优化简单	数据需求大、sim-to-real gap 严重
Modular	视觉与策略可分开训练, 最容易利用现成感知模型	系统设计更复杂, 模块接口需要精心定义

表 1: 课程对三类导航方法的概括。

3.4 本章小结

GOAT 说明 modular 方法并不是“折中方案”，而是一种有明确工程优势的体系结构：让感知、地图和控制各做自己最擅长的事。对复杂导航来说，这种分工往往比单一网络更稳。

4 总结与延伸

这讲的核心信息是：导航问题的难点不只是“到达目标”，而是“在部分可观测、地形复杂、语义丰富的世界里，到达正确的目标”。classical、end-to-end 和 modular 分别代表了三种不同的系统观。

如果只看短期实验，end-to-end 往往最吸引人；但如果把部署落到真实世界，课程明显更看好 modular 的路线，因为它允许视觉和控制各自利用最合适的数据来源。GOAT 把这一点推进到实例级导航：不仅知道“那里有熊”，还知道“那只熊在哪里”。

从更高层看，这一讲与前面的 locomotion 和 visual imitation 形成了一个闭环：locomotion 处理“怎么动”，visual imitation 处理“看人怎么动”，navigation 处理“动到哪里去”。整门课实际上是在教我们如何把这些能力拆开、再重新组合成一个可以在真实世界运行的机器人系统。