

Appendix B: Spring 2026 的 Diffusion Models 与 Video World Models 补充

Codex

2026-04-16

Appendix B: Spring 2026 的 Diffusion Models 与 Video World Models 补充

Spring 2026 的 Lecture 3 明确以 Diffusion Models 为 guest lecture 主题，并把 Normalizing Flows 与 Flow Matching 放进官方 reading list。

Lecture 6B 明确加入 Video World Models，并在 reading list 中给出 World Action Models are Zero-shot Policies 与 Track2Act 两个近年的 primary sources。

这说明课程主线已经从单纯的 reinforcement learning / behavior cloning，扩展到生成式 action modeling、视频世界模型和更强的表征学习路线。

Lecture 1: N/A

Lecture 2: [Reading Assignment Submission Form]

Lecture 2 / Lecture 2A: T. K. Uchida and S. L. Delp. Biomechanics of movement: the science of sports, robotics, and rehabilitation. Mit Press, 2021.

Lecture 2 / Lecture 2A: P. Ramdya and A. J. Ijspeert. The neuromechanics of animal locomotion: From biology to robotics and back. Science Robotics, 8(78):eadg0279, 2023. [PDF]

Lecture 2 / Lecture 2A: (It is not expected to read the Uchida-Delp book, but we will cover a couple of chapters from it.)

来源边界：本章是 Fall 2024 主书的补充章；目录内没有公开视频，因此正文依据 Spring 2026 官方课程页、reading list、course notes excerpt、transcript.jsonl 与 slides.jsonl 重建，并只使用显式列出的官方论文链接。

课程页面：<https://robots-that-learn.github.io/>

目录

1 本章定位	2
1.1 为什么要把这两条线放在一起	2
2 Normalizing Flows: 显式似然的生成建模	3
2.1 基本思想	3
2.2 为什么机器人学习会关心 flows	3
2.3 课程为什么会把它放进 reading list	3
2.4 本章小结	3
3 Flow Matching: 用速度场描述生成过程	3
3.1 从密度到轨迹	3
3.2 Flow matching 的直觉	4
3.3 和 diffusion 的关系	4
3.4 本章小结	4
4 Diffusion Models: 生成式动作建模的课程入口	4
4.1 Diffusion 为什么适合 robot learning	4
4.2 条件生成视角	4
4.3 为什么它和 imitation / policy learning 兼容	5
4.4 本章小结	5
5 Video World Models: 从动作预测到未来预测	5
5.1 世界模型的角色	5
5.2 为什么视频很关键	5
5.3 From prediction to policy	5
5.4 本章小结	5
6 World Action Models 与 Track2Act	6
6.1 World Action Models are Zero-shot Policies	6
6.2 Track2Act: point tracks 作为动作中介	6
6.3 和视频模仿的关系	6
6.4 本章小结	6
7 把这几条线合在一起看	6
8 本章小结	7
9 总结与延伸	7
9.1 本章小结	7

Appendix B: Spring 2026 的 Diffusion Models 与 Video World Models 补充

Spring 2026 的 Lecture 3 明确以 Diffusion Models 为 guest lecture 主题，并把 Normalizing Flows 与 Flow Matching 放进官方 reading list。

Lecture 6B 明确加入 Video World Models，并在 reading list 中给出 World Action Models are Zero-shot Policies 与 Track2Act 两个近年的 primary sources。

这说明课程主线已经从单纯的 reinforcement learning / behavior cloning，扩展到生成式 action modeling、视频世界模型和更强的表征学习路线。

Lecture 1: N/A

Lecture 2: [Reading Assignment Submission Form]

Lecture 2 / Lecture 2A: T. K. Uchida and S. L. Delp. Biomechanics of movement: the science of sports, robotics, and rehabilitation. Mit Press, 2021.

Lecture 2 / Lecture 2A: P. Ramdya and A. J. Ijspeert. The neuromechanics of animal locomotion: From biology to robotics and back. Science Robotics, 8(78):eadg0279, 2023. [PDF]

Lecture 2 / Lecture 2A: (It is not expected to read the Uchida-Delp book, but we will cover a couple of chapters from it.)

图 1: 课程官方材料中的代表性页面，用于帮助读者在进入本讲正文前建立整体上下文。

Appendix B: Spring 2026 的 Diffusion Models 与 Video World Models 补充

Spring 2026 的 Lecture 3 明确以 Diffusion Models 为 guest lecture 主题，并把 Normalizing Flows 与 Flow Matching 放进官方 reading list。

Lecture 6B 明确加入 Video World Models，并在 reading list 中给出 World Action Models are Zero-shot Policies 与 Track2Act 两个近年的 primary sources。

这说明课程主线已经从单纯的 reinforcement learning / behavior cloning，扩展到生成式 action modeling、视频世界模型和更强的表征学习路线。

Lecture 1: N/A

Lecture 2: [Reading Assignment Submission Form]

Lecture 2 / Lecture 2A: T. K. Uchida and S. L. Delp. Biomechanics of movement: the science of sports, robotics, and rehabilitation. Mit Press, 2021.

Lecture 2 / Lecture 2A: P. Ramdya and A. J. Ijspeert. The neuromechanics of animal locomotion: From biology to robotics and back. Science Robotics, 8(78):eadg0279, 2023. [PDF]

Lecture 2 / Lecture 2A: (It is not expected to read the Uchida-Delp book, but we will cover a couple of chapters from it.)

图 2: Spring 2026 官方补充页的 provenance card。由于本目录没有公开视频，本章以官方页面和论文链接为主证据。

1 本章定位

这一章专门补 Spring 2026 里最关键的两条更新线：Normalizing Flows / Flow Matching，以及 Diffusion Models / Video World Models。它们共同构成了课程从“学习动作”走向“生成动作、预测未来、用世界模型组织行动”的方法更新。

1.1 为什么要把这两条线放在一起

从课程页的 reading list 看，Lecture 3 把 Normalizing Flows 和 Flow Matching 与 Diffusion Models 放在同一脉络中；Lecture 6B 又把 Video World Models、World Action Models are Zero-shot Policies 和 Track2Act 放在一起。换句话说，Spring 2026 并不是零散地追热点，而是在把一组相关的生成式与预测式方法编成一条连续技术链。

本章的事实来源

本章只把 Spring 2026 course page 与显式列出的论文标题当作课程事实来源。关于这些方法的机制解释，属于教材式延伸解释，用于帮助读者理解课程为什么会这样选题。

2 Normalizing Flows: 显式似然的生成建模

2.1 基本思想

归一化流 (normalizing flows) 是一类通过可逆变换 (invertible transformation) 来构造复杂分布的方法。设简单潜变量 $z \sim p_Z(z)$ ，通过可逆映射 $x = f_\theta(z)$ 得到数据变量 x 。由于映射可逆，数据密度可以写成

$$p_X(x) = p_Z(f_\theta^{-1}(x)) \left| \det \frac{\partial f_\theta^{-1}(x)}{\partial x} \right|.$$

这条公式之所以重要，是因为它保留了显式似然 (explicit likelihood)。对 robot learning 来说，这意味着我们不仅能采样动作，还可以评估动作在模型下的概率密度。

2.2 为什么机器人学习会关心 flows

机器人动作经常是多模态的，但又比普通图像生成更强调可控性和可解释性。normalizing flows 的价值在于：

- 它能保留概率结构，而不是把多个动作平均掉；
- 它在理论上非常适合做条件生成 (conditional generation)；
- 它与连续时间建模、ODE 视角和后续的 flow matching 很容易衔接。

2.3 课程为什么会把它放进 reading list

Spring 2026 选择了 Normalizing Flows for Probabilistic Modeling and Inference，说明课程希望读者把 diffusion 之前的生成式基础也补齐。对本书而言，这意味着：如果要讲清楚扩散策略，就不能只讲“去噪采样”，还要讲“概率变换如何把简单噪声变成复杂动作分布”。

2.4 本章小结

Normalizing flows 解决的是“如何用可逆结构表示复杂分布”这个问题。它在 robot learning 中的意义不只在于生成，而在于把生成过程重新变成可计算、可评估、可条件化的概率模型。

3 Flow Matching: 用速度场描述生成过程

3.1 从密度到轨迹

Flow matching (流匹配) 关注的不是直接拟合最终密度，而是拟合一个随时间变化的速度场 (velocity field) 或向量场 (vector field)。给定从简单分布到目标分布的一条概率路径 (probability path)，模型学习在每个时间点应该朝哪个方向移动。

一个典型的教材式写法是：

$$\min_{\theta} \mathbb{E}_{t, x_t} [\|v_{\theta}(x_t, t) - u_t(x_t)\|^2],$$

其中 v_{θ} 是模型学到的速度场， u_t 是目标轨迹上的真实速度或监督信号。

3.2 Flow matching 的直觉

如果说 normalizing flows 更偏向“显式变换”，那 flow matching 更偏向“连续运输 (transport)”。它把生成问题想成一条从简单分布流向复杂分布的轨迹，而不是一次性跳过去。

对机器人动作建模来说，这种视角很自然：动作并不是静态类别，而是时间上连续演化的轨迹。因而，用速度场而不是离散标签来描述动作，往往更符合物理过程。

3.3 和 diffusion 的关系

Diffusion models、flows 和 flow matching 经常被放在同一谱系里讨论，因为它们都在处理“如何从噪声走向数据”这件事。区别在于：

- diffusion 更强调逐步去噪；
- flows 更强调可逆变换与显式密度；
- flow matching 更强调学习中间的连续流场。

3.4 本章小结

Flow matching 提供的是一种更连续、更几何化的生成视角。它特别适合机器人，因为机器人动作本身就是连续时间对象，而不是离散类别。

4 Diffusion Models：生成式动作建模的课程入口

4.1 Diffusion 为什么适合 robot learning

扩散模型 (diffusion models) 最适合机器人学习的一点，是它天然支持多模态输出。机器人在同一状态下可能有多个合理动作；diffusion 的逐步采样过程，可以把这种不确定性保留下来，而不是强迫模型做单点回归。

动作平均不是好策略

如果把多个合理动作简单平均，得到的往往不是一个“折中可行解”，而是一个更危险的错误动作。扩散策略的价值就在于避免这种平均化塌缩。

4.2 条件生成视角

在 robot learning 中，扩散模型通常不是无条件生成，而是条件于观测、状态、任务指令或历史轨迹。于是问题变成：

$$p(a_{1:T} \mid o_{1:T}, \text{task})$$

如何建模，以及如何在采样时生成一个满足任务约束的动作序列。

4.3 为什么它和 imitation / policy learning 兼容

扩散策略之所以在机器人里流行，是因为它同时具备两种性质：

- 它像监督学习一样，能直接拟合示范数据；
- 它又像生成模型一样，能保留多模态和不确定性。

因此，扩散模型可以被理解为“生成式行为克隆 (generative behavior cloning)”的一种重要实现路线。

4.4 本章小结

Spring 2026 把 diffusion models 放到课程前端，说明它们已经不是辅助技巧，而是机器人策略建模的核心方法之一。

5 Video World Models: 从动作预测到未来预测

5.1 世界模型的角色

世界模型 (world model) 是一种学环境动力学与未来演化的表示。它不只回答“我下一步该做什么”，还回答“如果我这样做，世界会如何变化”。当这种模型以视频为主要输入和输出形式时，就形成了 video world model。

5.2 为什么视频很关键

视频比单帧图像更适合表达接触、遮挡、运动与事件顺序。对于机器人操作，最重要的信息往往不在静态外观，而在时间上的变化模式。视频世界模型的价值就在于，它能把这些变化模式编码成可用于规划或控制的中间表征。

5.3 From prediction to policy

Spring 2026 的 Lecture 6B 把 Video World Models 与 World Action Models are Zero-shot Policies 放在一起，这表明课程正在把“预测”和“行动”靠得更近。一个自然的教材式理解是：

- world model 负责预测未来状态或视频轨迹；
- policy 负责把这种预测转成行动；
- world action model 试图把两者合并成一个可以直接产出行为的系统。

5.4 本章小结

Video world models 的重要性不在于它们“会做视频”，而在于它们把未来的视觉演化变成了规划可用的中间层。

6 World Action Models 与 Track2Act

6.1 World Action Models are Zero-shot Policies

从标题本身可以看出，World Action Models are Zero-shot Policies 想讨论的是一种“无需专门任务微调即可执行”的策略形式。这里的关键概念是 zero-shot policy（零样本策略）：系统在没有针对当前任务重新训练的情况下，仍然能依靠世界建模和动作生成完成任务。

教材式地看，这意味着策略不再只是“输入观测，输出动作”，而是“借助世界表示，将任务推理嵌入动作生成”。

6.2 Track2Act: point tracks 作为动作中介

Track2Act: Predicting Point Tracks from Internet Videos enables Generalizable Robot Manipulation 提供了另一条特别实用的路线：先从互联网视频中抽取 point tracks，再把这些时空轨迹作为操作学习的中间表示。

point tracks 的价值在于它们是压缩过的几何信号：

- 比原始视频更轻；
- 比纯文本或类别标签更接近动作；
- 比直接预测低层关节命令更容易跨任务泛化。

6.3 和视频模仿的关系

Track2Act 与视频模仿（video imitation）的关系可以这样理解：视频模仿关注“从视频学策略”，而 Track2Act 更强调“先把视频中的运动线索结构化，再把结构化线索用于操作”。这一步很重要，因为它把原始视频中的复杂性压缩成更稳定的几何中间层。

6.4 本章小结

World action models 和 Track2Act 都表明：Spring 2026 已经把“从视频中学会行动”视为 robot learning 的主干方向之一，而不是边缘补充。

7 把这几条线合在一起看

如果把本章中的方法放在同一张地图上，可以得到一个很稳定的层级：

- Normalizing flows 处理可逆生成和显式似然；
- Flow matching 处理连续速度场与概率运输；
- Diffusion models 处理多模态动作生成；
- Video world models 处理未来视频和环境演化；
- World action models 处理预测与决策的耦合；
- Track2Act 处理从互联网视频到可操作几何中间层的转换。

这张地图告诉我们，Spring 2026 的更新不是一组分散的新名词，而是 robot learning 中“生成式建模 + 预测式表示 + 行动决策”三者逐渐融合的结果。

8 本章小结

本章的核心信息可以浓缩成一句话：Spring 2026 把 robot learning 从“学习动作”推进到了“学习如何生成动作、预测未来并组织行动”。

从课程页与显式 reading list 可以稳定得出的结论是：

- diffusion models 已成为 robot learning 的重要主线；
- normalizing flows 和 flow matching 是理解这一主线的理论前置；
- video world models、world action models 和 Track2Act 则把生成式建模进一步推向任务执行。

9 总结与延伸

如果把这章放回整本《Robots That Learn》的主书框架里，它最重要的作用不是补一个“前沿小节”，而是告诉读者：机器人学习正在从模仿轨迹，走向建模概率、流场、视频演化和可零样本泛化的世界表示。

后续最值得延伸的三个方向是：

- 生成式策略与控制理论如何统一；
- 视频世界模型如何真正进入长程 planning；
- point tracks、diffusion 和 language-conditioned policy 如何构成一个层级化动作系统。

9.1 本章小结

Spring 2026 的这条更新线不是“把新论文塞进课程”，而是在重写 robot learning 的方法骨架。对于主书来说，这意味着 diffusion、flow matching、world models 和 video-based action learning 都应该被视为核心章节，而不是附录里的边缘材料。